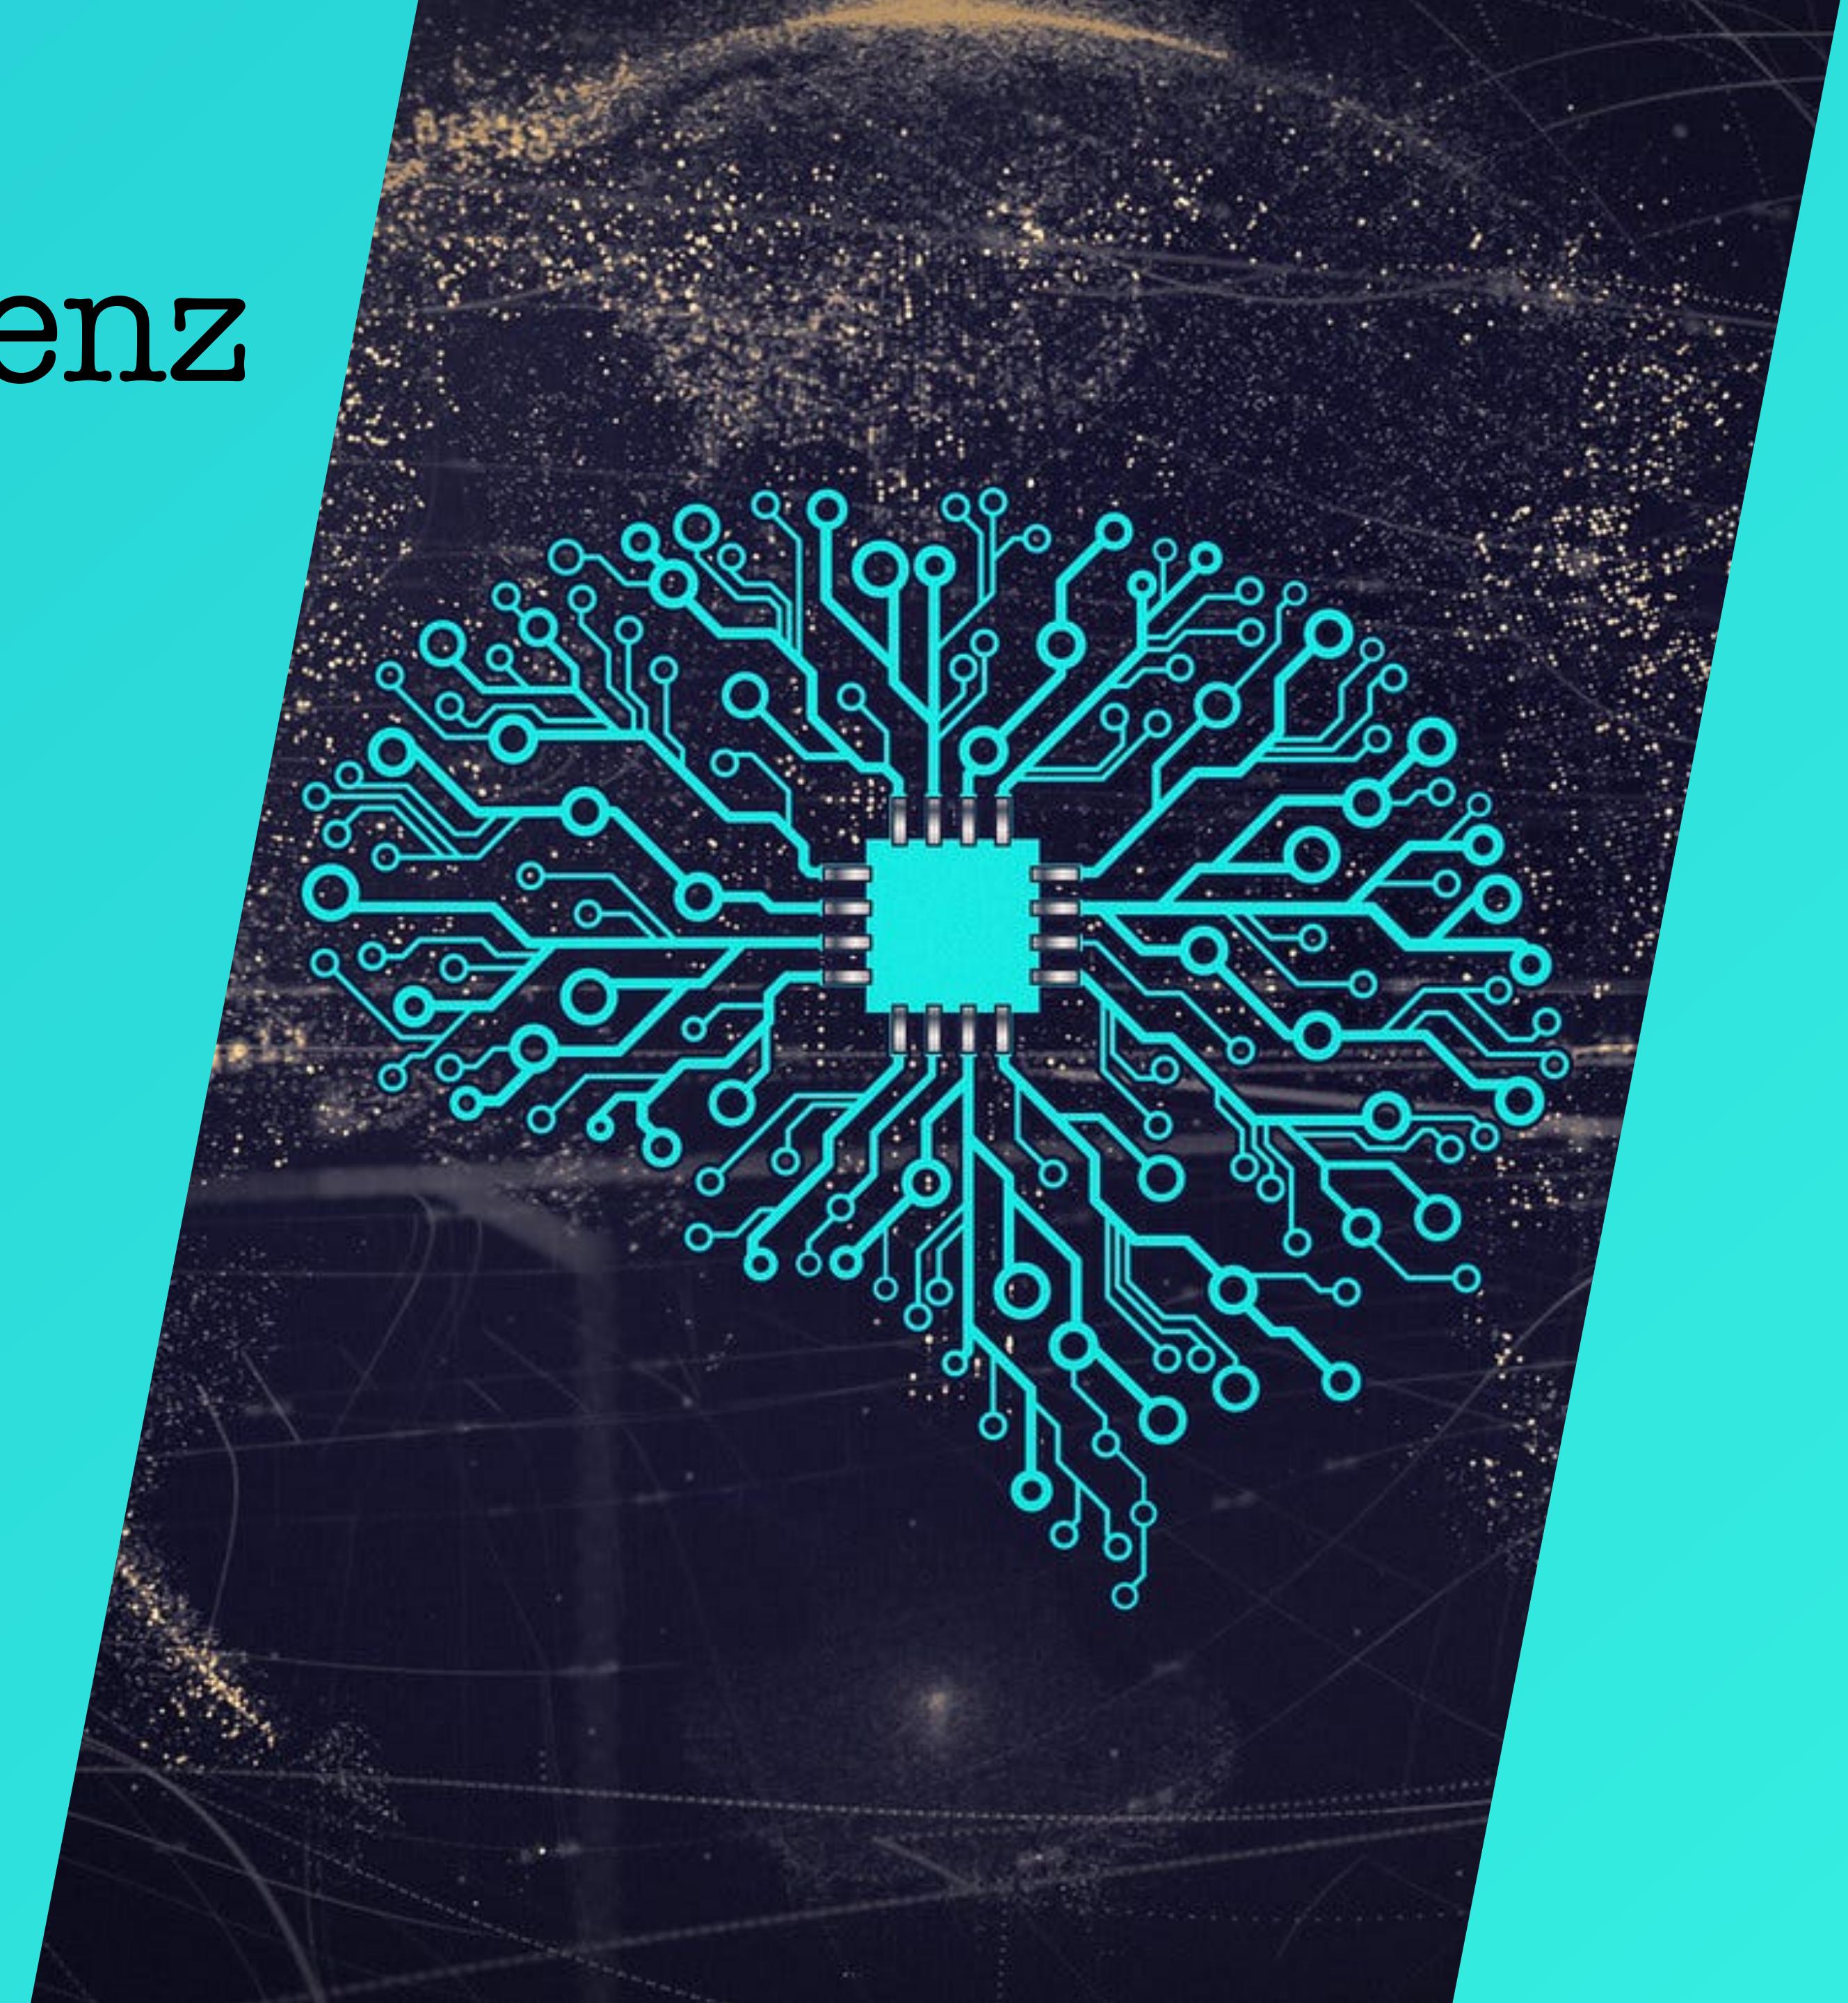


# Künstliche Intelligenz selbst gemacht

Ein neuronales Netz mit Python  
entwickeln



Diese Folien (und sämtlicher Code) sind verfügbar unter:

[tinyurl.com/python-nn](https://tinyurl.com/python-nn)

# „Künstliche Intelligenz“

# „Künstliche Intelligenz“

Regelbasierte KI



# „Künstliche Intelligenz“

Regelbasierte KI

Beispiel: Programmiersprache Prolog

```
● ● ●

mother_child(monica, jenny).
father_child(tom, jenny).
father_child(tom, emma).
father_child(mike, tom).

sibling(X, Y)      :- parent_child(Z, X), parent_child(Z, Y), not(X = Y).

parent_child(X, Y) :- father_child(X, Y).
parent_child(X, Y) :- mother_child(X, Y).

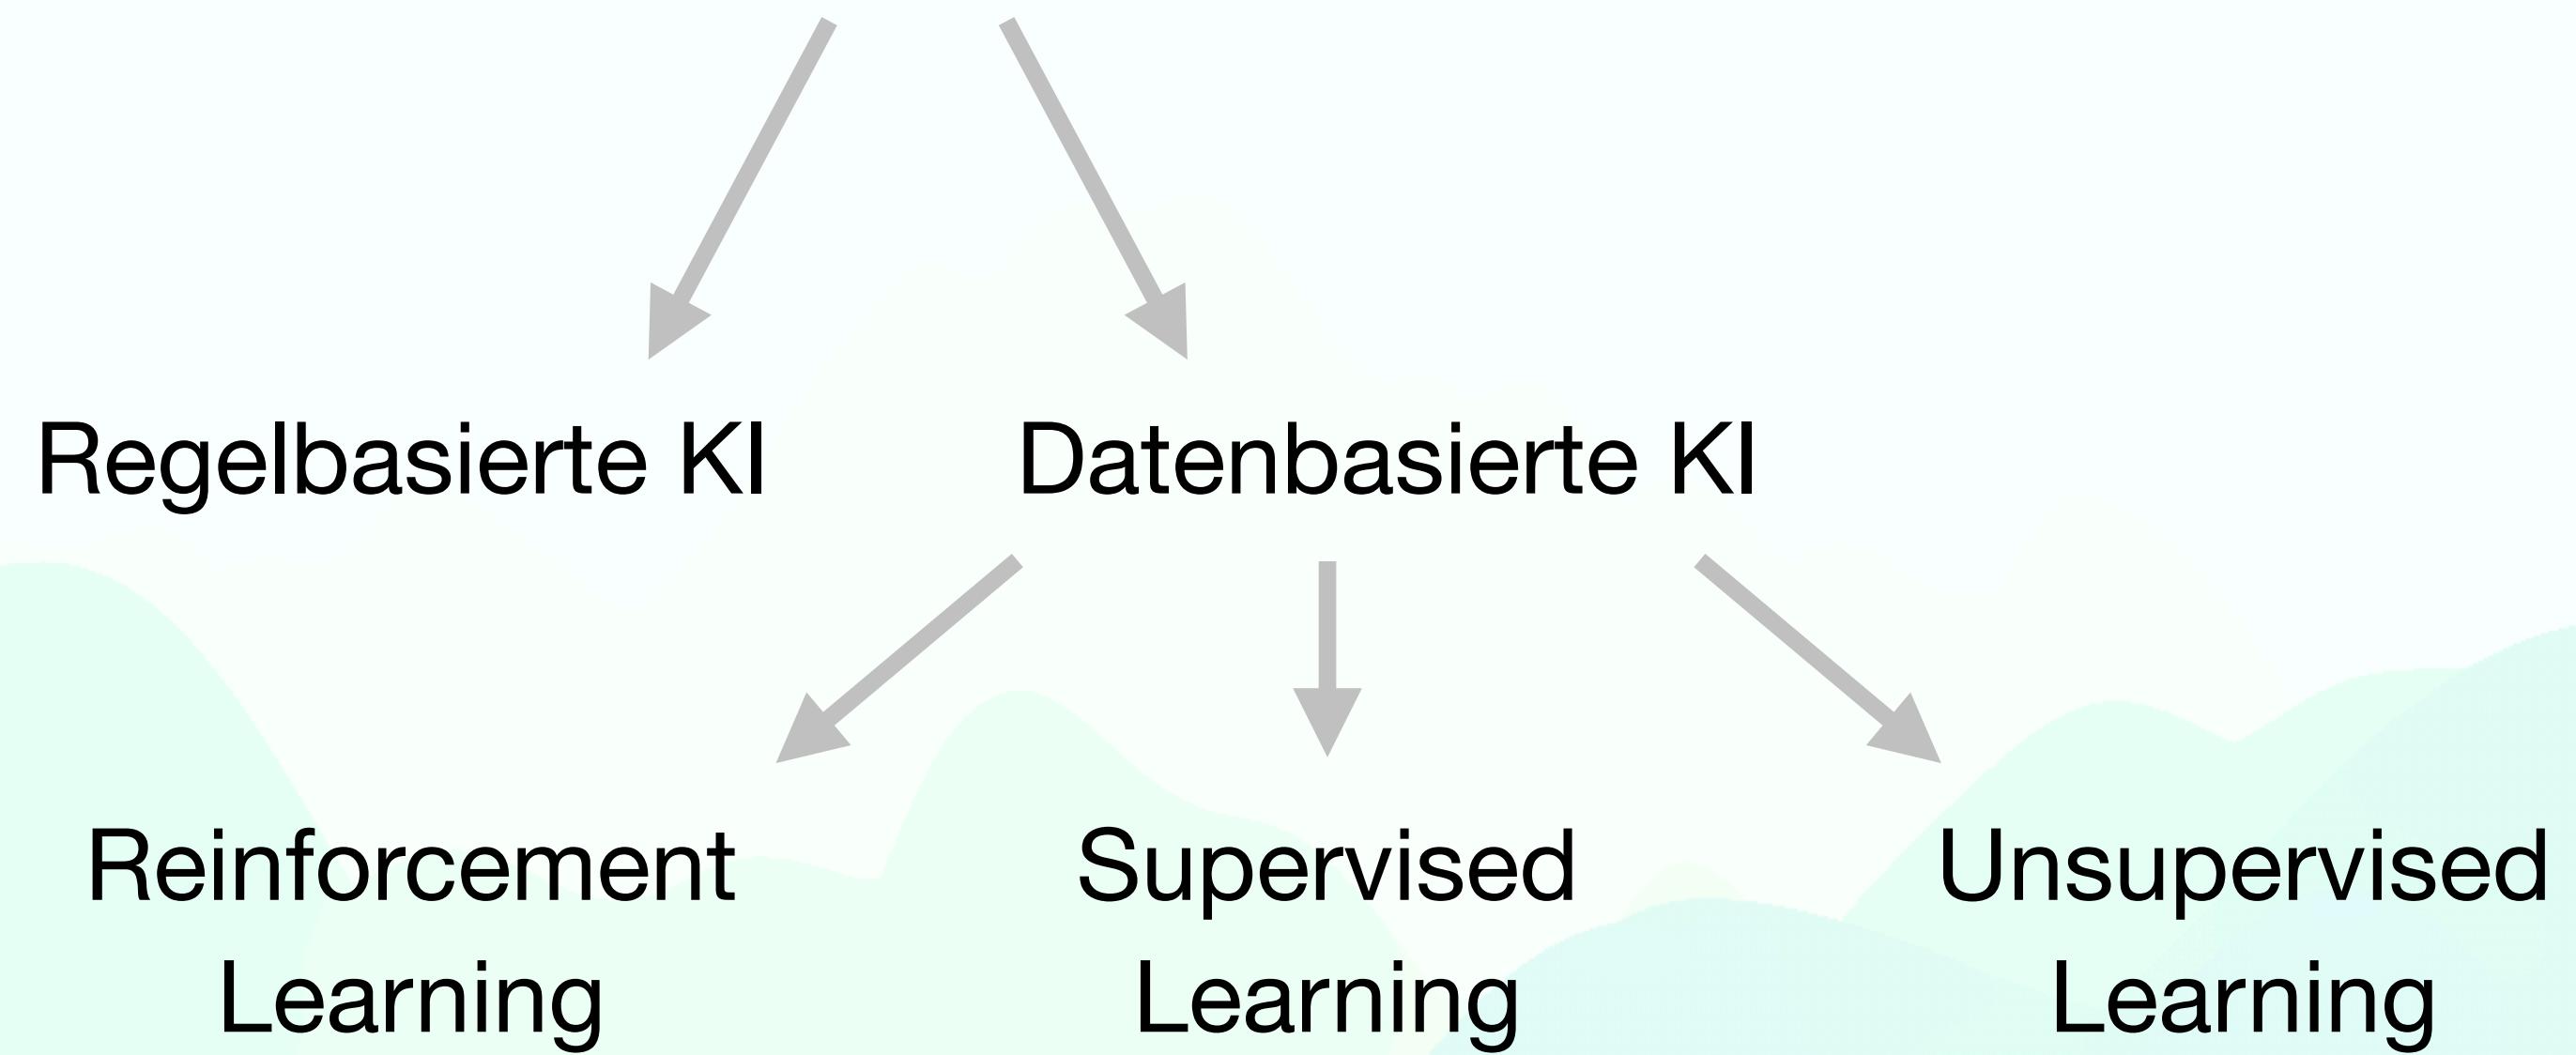
?- sibling(jenny, emma).
Yes
```

# „Künstliche Intelligenz“

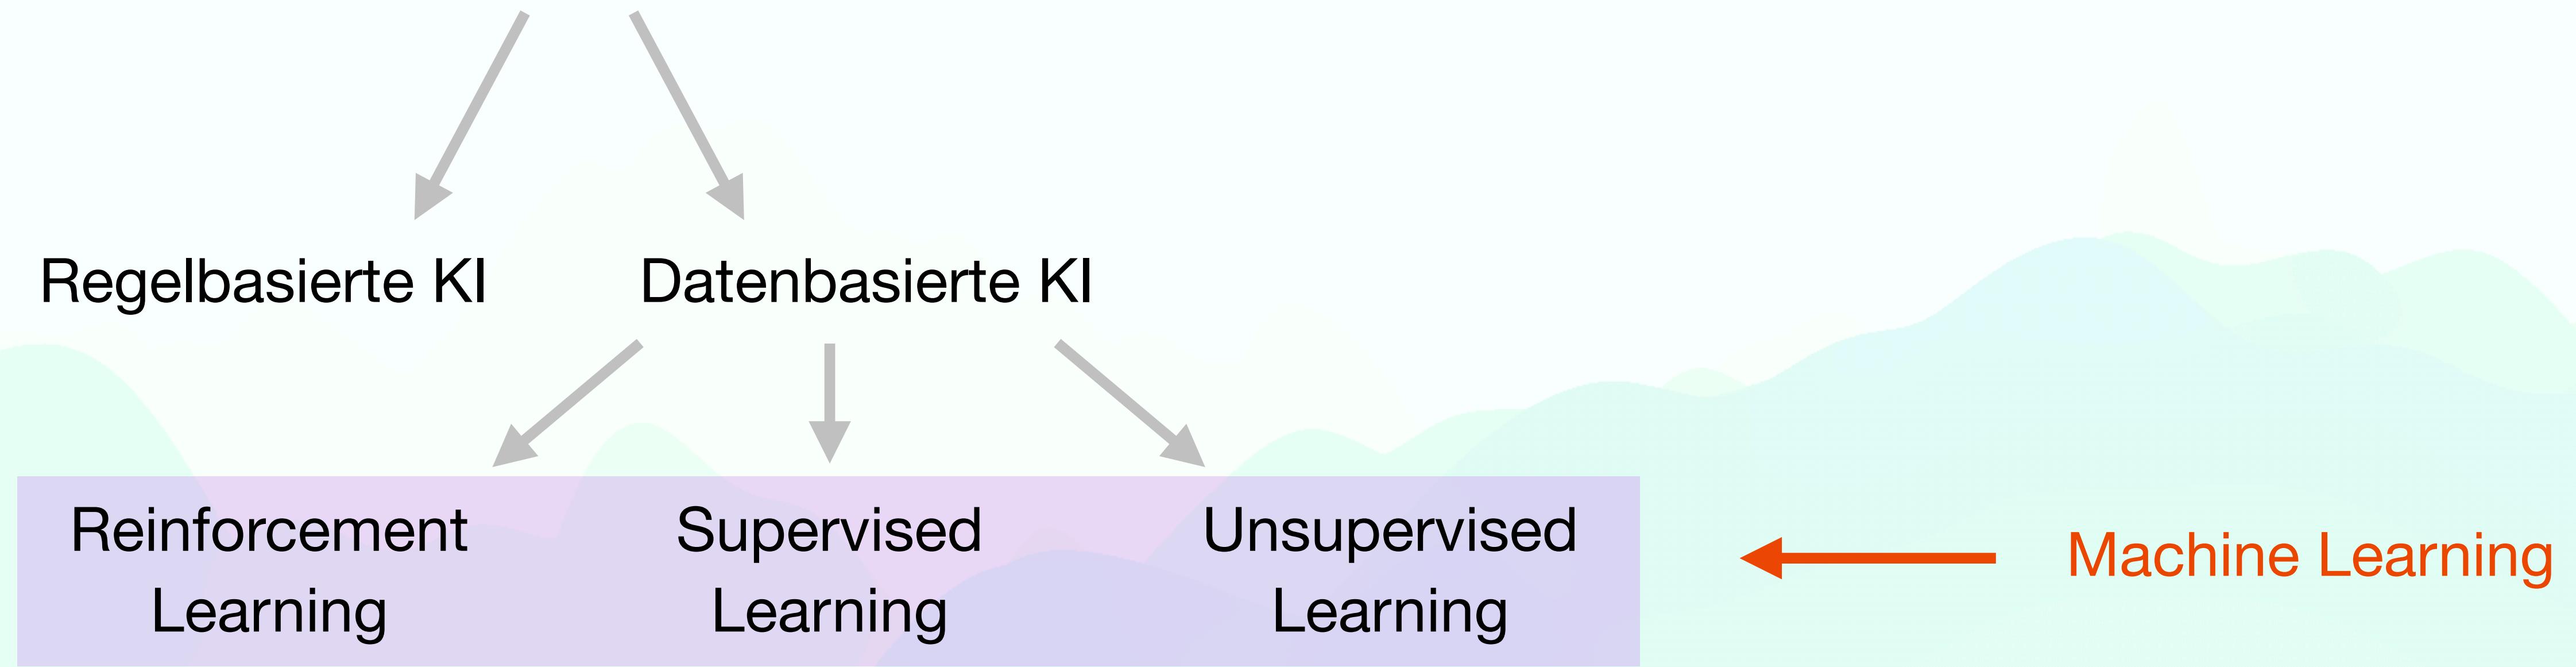
Regelbasierte KI

Datenbasierte KI

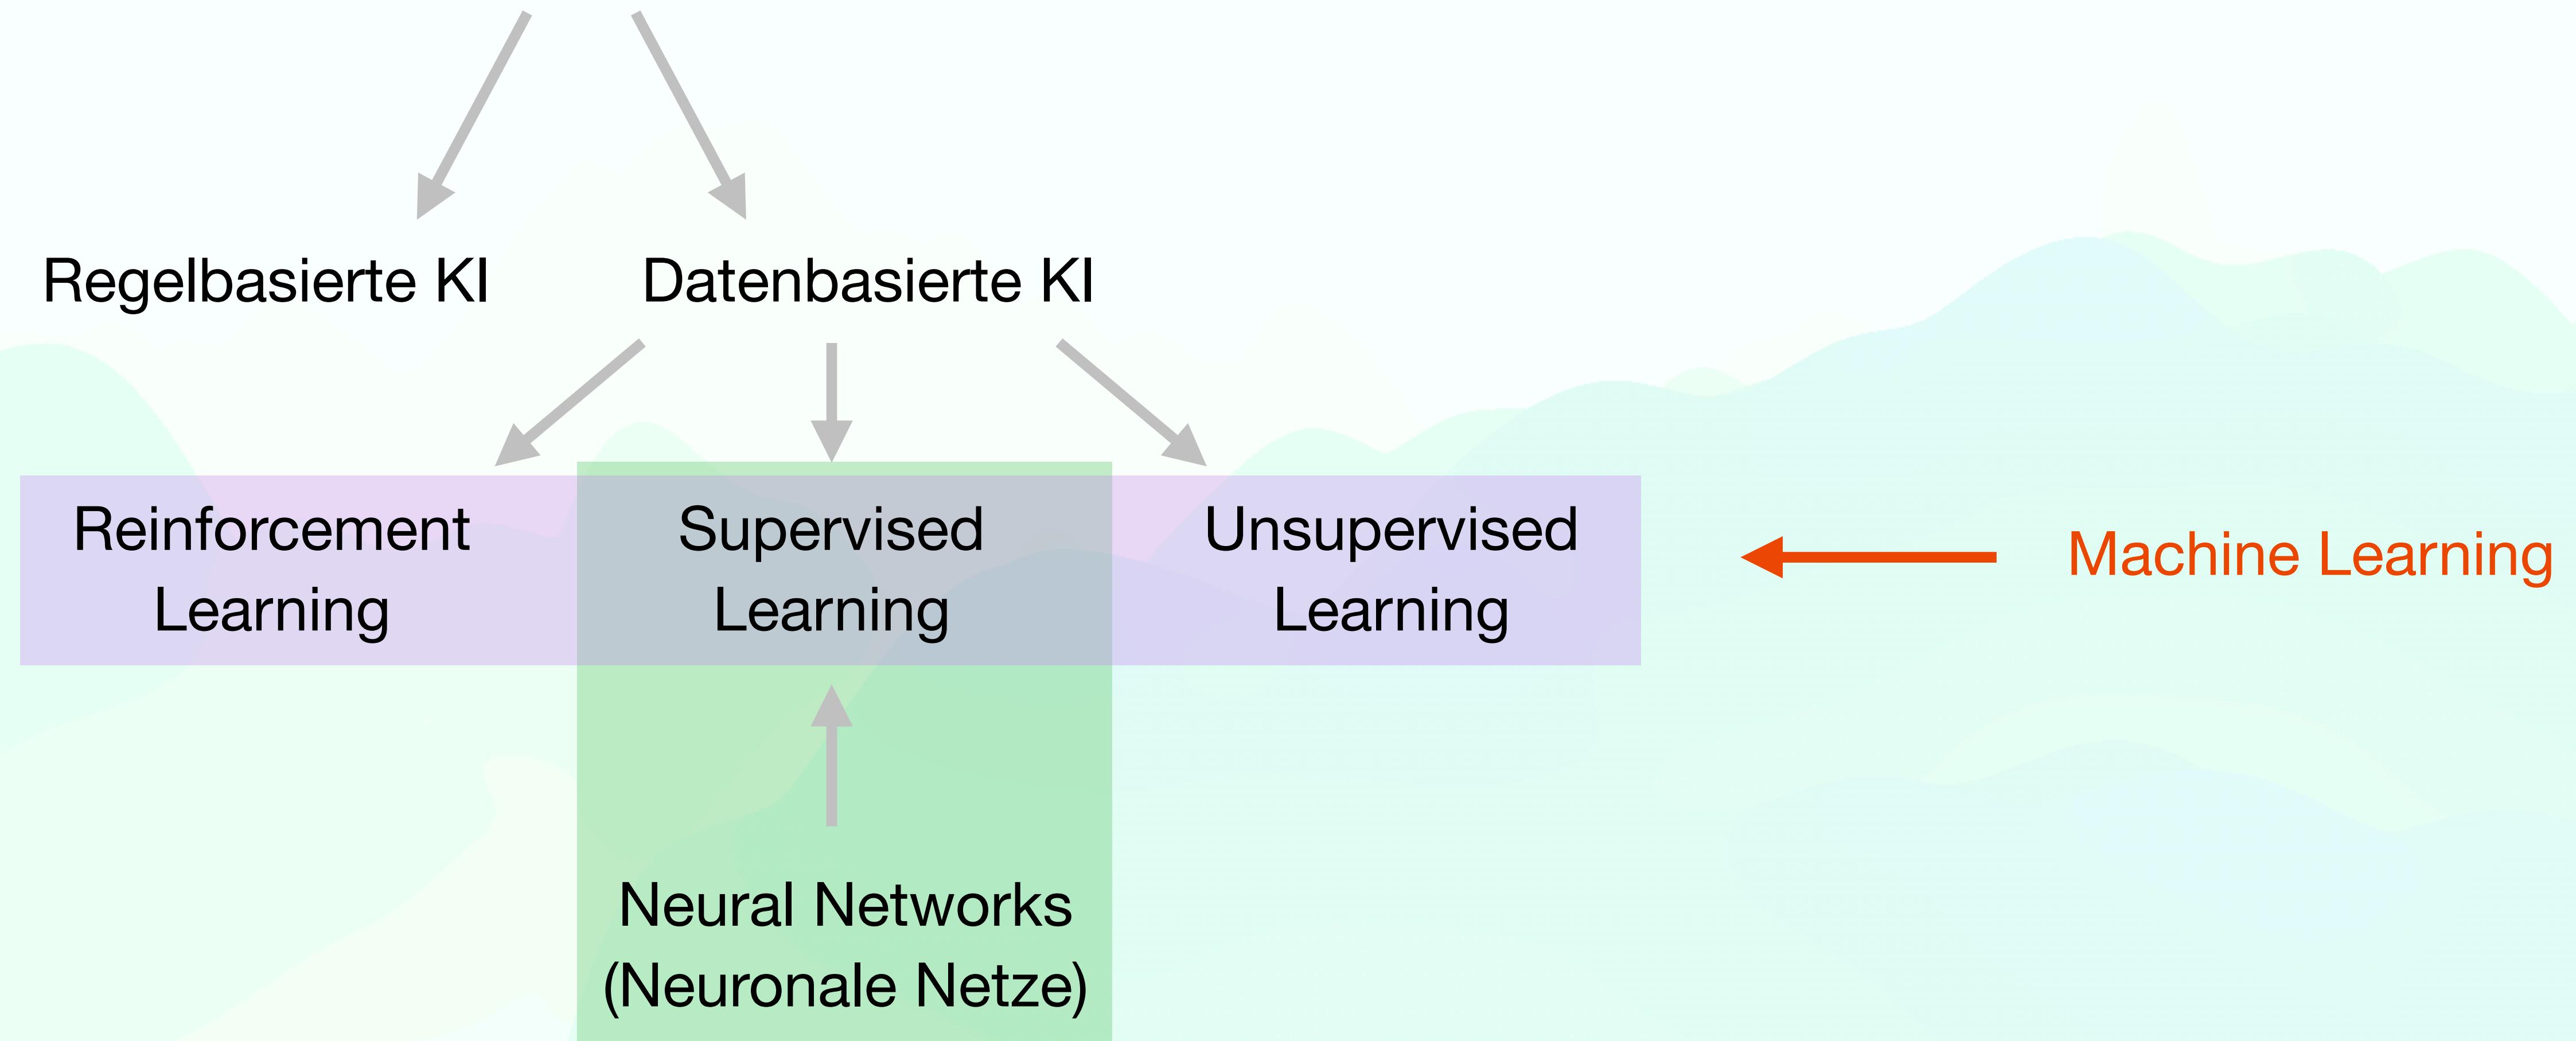
# „Künstliche Intelligenz“



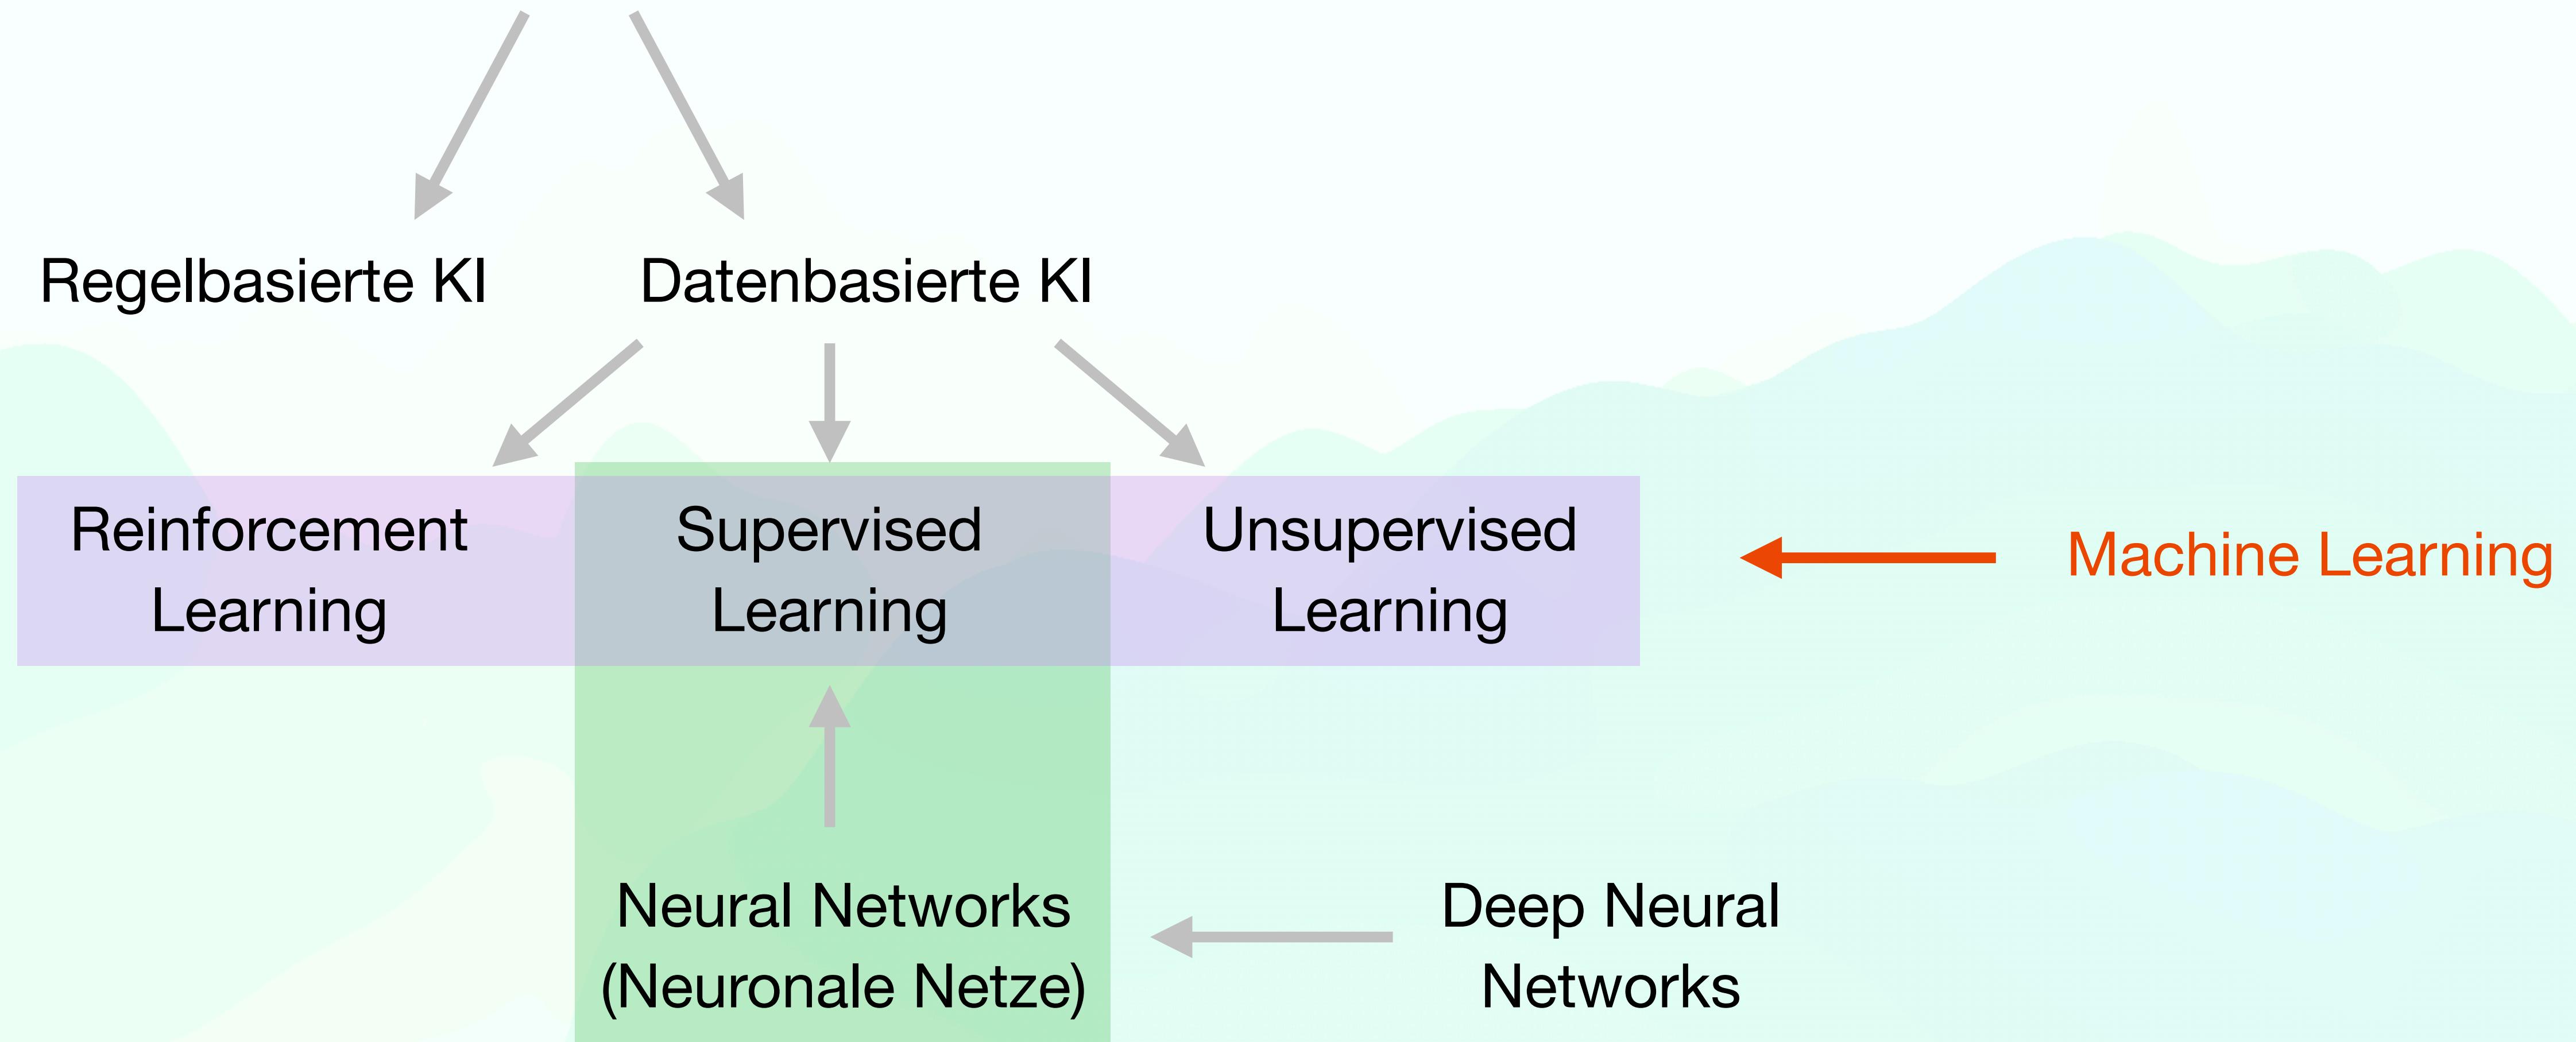
# „Künstliche Intelligenz“



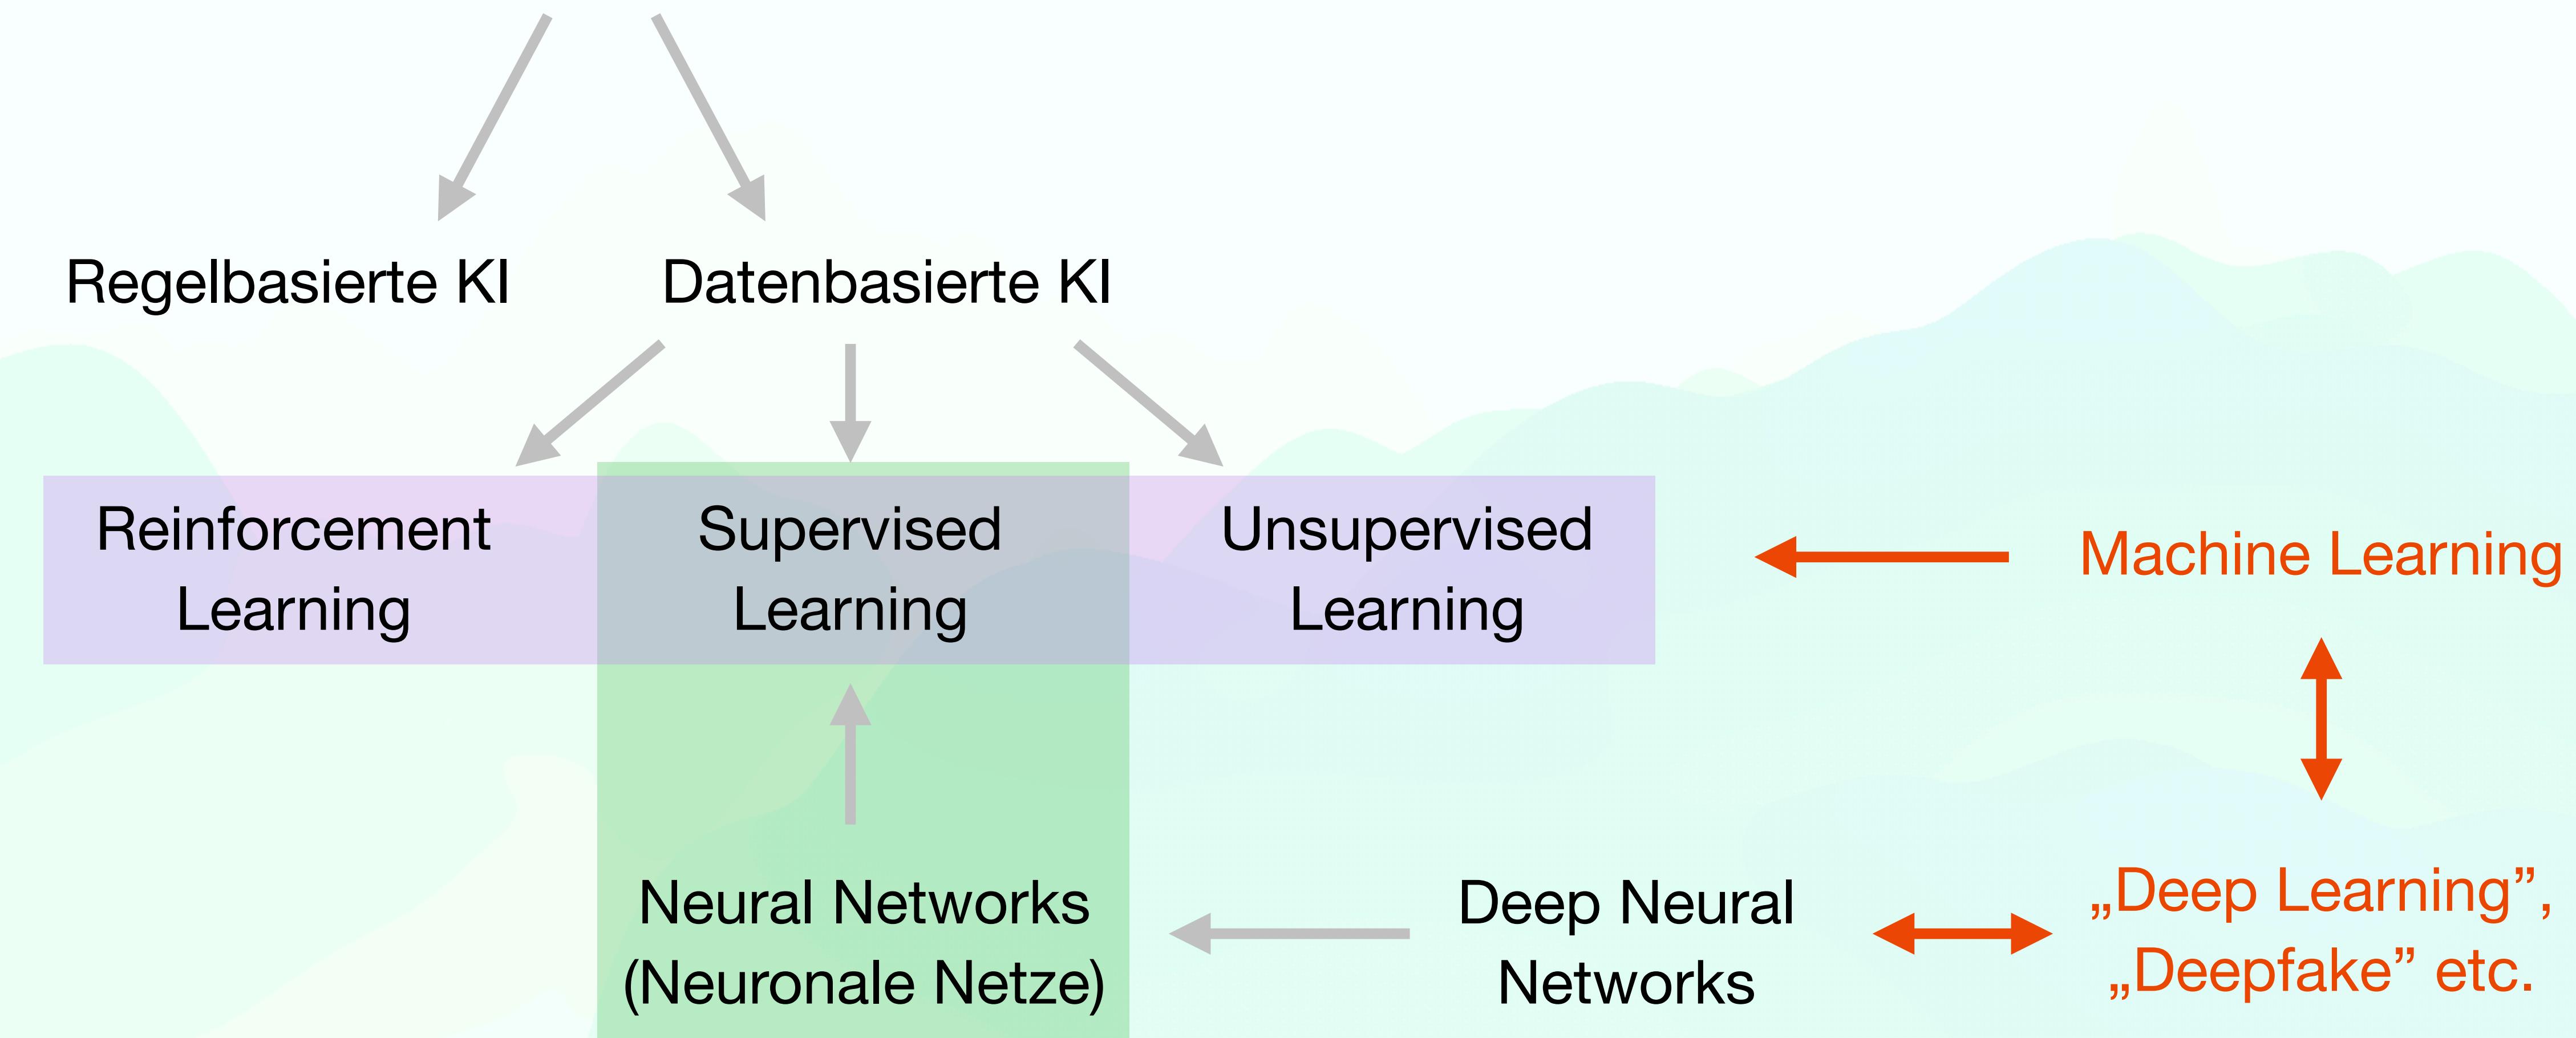
# „Künstliche Intelligenz“



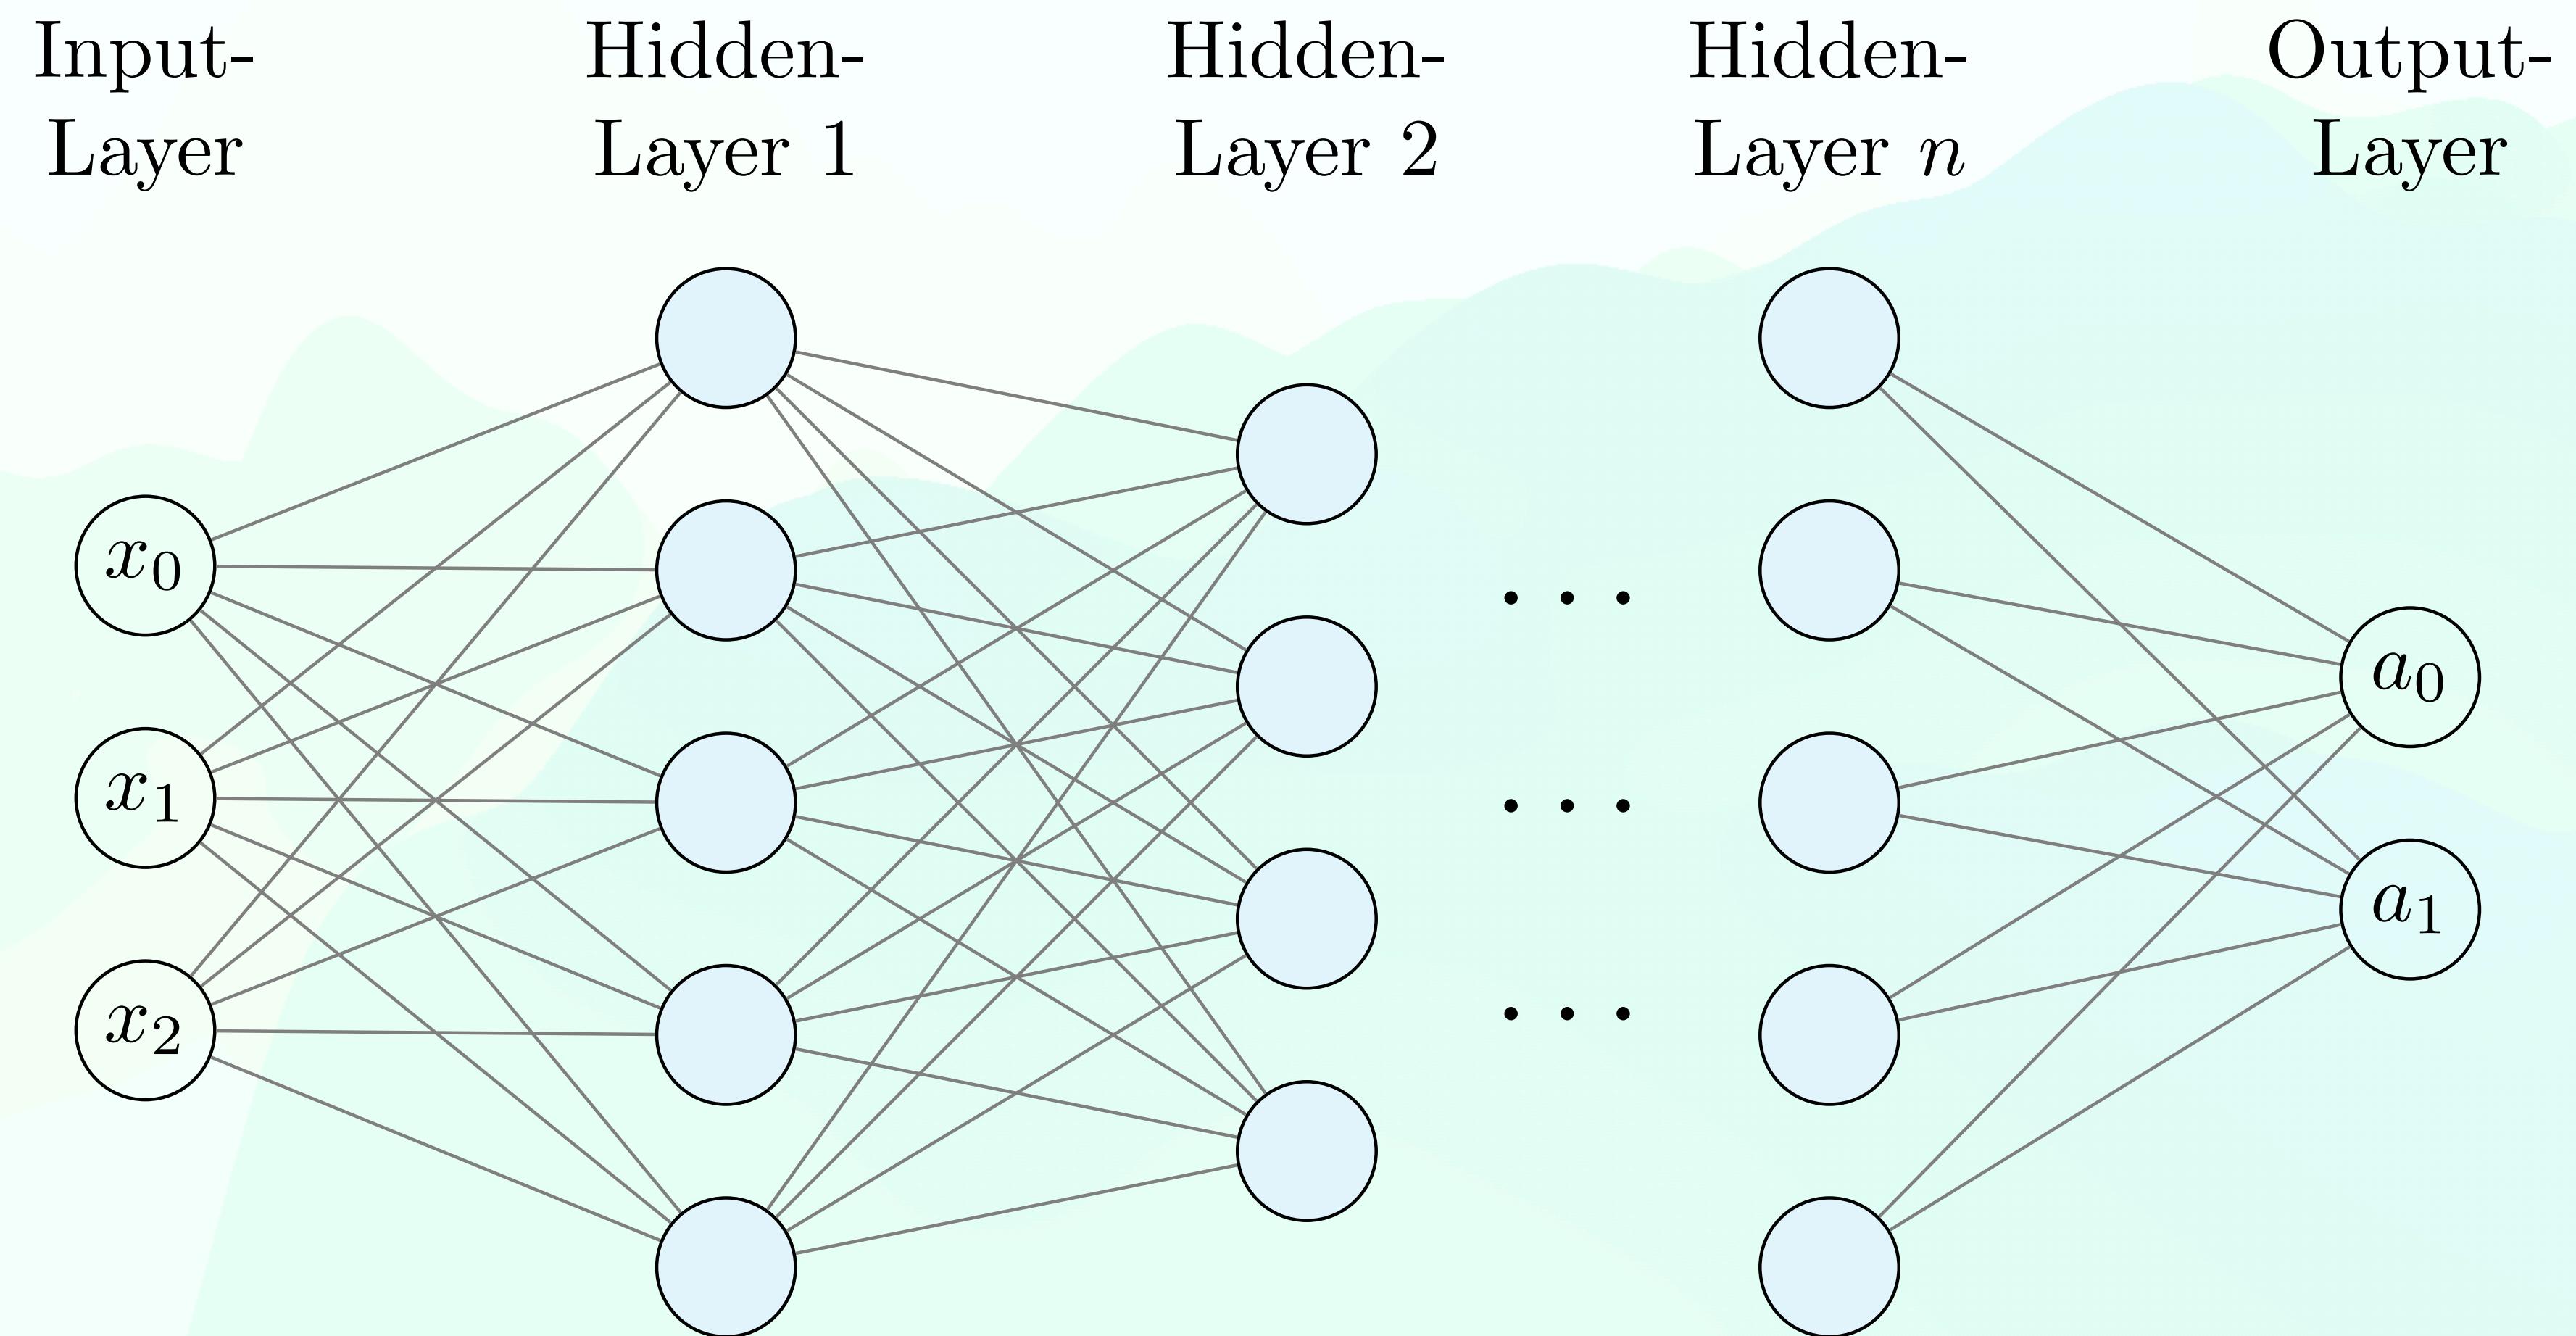
# „Künstliche Intelligenz“



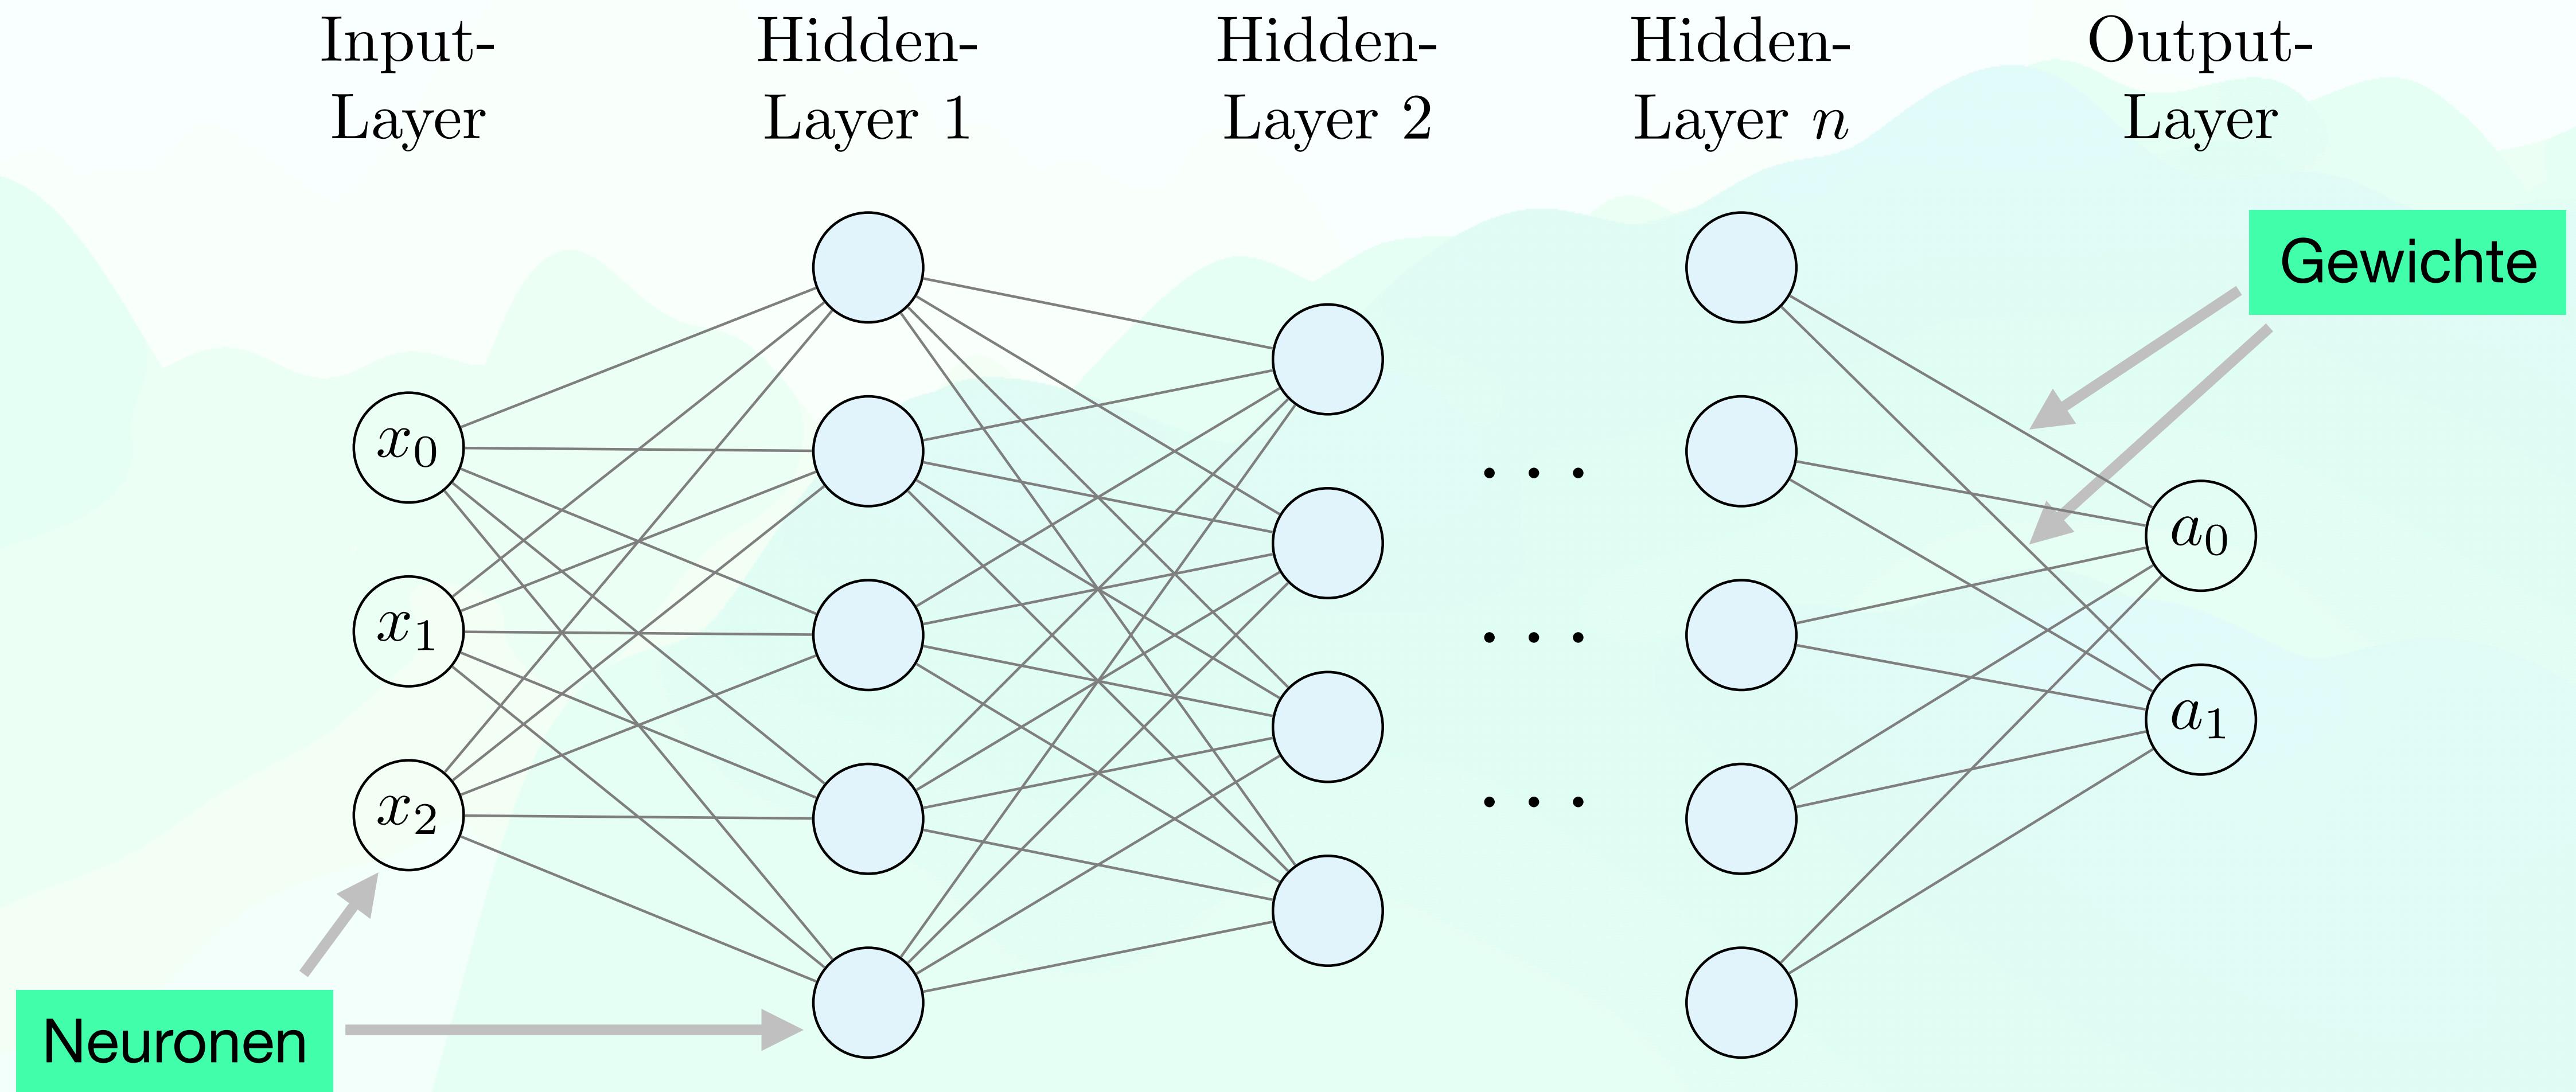
# „Künstliche Intelligenz“



# Überblick



# Überblick



# Überblick

Grundidee des **Supervised Learning** in einem neuronalen Netz:

# Überblick

Grundidee des **Supervised Learning** in einem neuronalen Netz:

- Gegeben: Ein Datensatz von vielen Trainingsbeispielen, jeweils mit Input und erwartetem Output

# Überblick

Grundidee des **Supervised Learning** in einem neuronalen Netz:

- Gegeben: Ein Datensatz von vielen Trainingsbeispielen, jeweils mit Input und erwartetem Output
- **Feedforward-Step:** Befülle den Input-Layer mit den Inputs eines Trainingsbeispiels und lass das Netzwerk einen Output vorhersagen (**Prediction**)

# Überblick

Grundidee des **Supervised Learning** in einem neuronalen Netz:

- Gegeben: Ein Datensatz von vielen Trainingsbeispielen, jeweils mit Input und erwartetem Output
- **Feedforward-Step:** Befülle den Input-Layer mit den Inputs eines Trainingsbeispiels und lass das Netzwerk einen Output vorhersagen (**Prediction**)
- **Cost Function/Loss Function:** Untersuche, wie groß die Abweichung zwischen erwartetem Output und vorhergesagtem Output ist

# Überblick

Grundidee des **Supervised Learning** in einem neuronalen Netz:

- Gegeben: Ein Datensatz von vielen Trainingsbeispielen, jeweils mit Input und erwartetem Output
- **Feedforward-Step:** Befülle den Input-Layer mit den Inputs eines Trainingsbeispiels und lass das Netzwerk einen Output vorhersagen (**Prediction**)
- **Cost Function/Loss Function:** Untersuche, wie groß die Abweichung zwischen erwartetem Output und vorhergesagtem Output ist
- **Backpropagation:**
  - Berechne, in welche Richtung (Gradient) die Gewichte angepasst werden müssen, um den Wert der Kostenfunktion zu minimieren (**Gradient Descent**)
  - Wiederhole all diese Schritte für alle weiteren Trainingsbeispiele
  - Bilde den Durchschnitt der Gradienten aller Trainingsbeispiele und passe die Gewichte entsprechend an

# Überblick

„Lernen“ in einem neuronalen Netz heißt, die **Gewichte** im Netz so **anzupassen**, dass der Fehler (die „**Kosten**“) im Durchschnitt über alle Trainingsbeispiele **minimiert** wird.

# „Hello world” in Python



```
if __name__ == '__main__':
    print("Hello world")
```

# „Hello world“ in Python



```
if __name__ == '__main__':
    print("Hello world")
```

Sorgt dafür, dass der nachfolgende Code nur aufgerufen wird, wenn unser Script als eigenständiges Programm aufgerufen wird.

# „Hello world“ in Python



```
if __name__ == '__main__':
    print("Hello world")
```

Ruft die **Funktion** `print` auf, die einen Text auf der Konsole ausgeben kann.

Als **Parameter** wird der **String** „Hello world“ übergeben.

# „Hello world“ in Python



```
if __name__ == '__main__':
    print("Hello world")
```

In Python ganz wichtig: Einrückung beachten!

# Überblick

- Wir betrachten **Fully Connected Neural Networks**:  
Jedes Neuron aus Layer  $l - 1$  ist mit jedem Neuron aus Layer  $l$  verbunden

# Überblick

- Wir betrachten **Fully Connected Neural Networks**:  
Jedes Neuron aus Layer  $l - 1$  ist mit jedem Neuron aus Layer  $l$  verbunden
- Grundsätzlich zwei mögliche Problemklassen, die mit NN gelöst werden können:
  - **Klassifikation:** *Zuordnung eines Inputs zu einer Kategorie*  
Beispiele: Handelt es sich bei einem Bild (Input) um das einer Katze (Kategorie 1), eines Hundes (Kategorie 2) oder eines Wellensittichs (Kategorie 3)?  
Ist eine E-Mail (Input) Spam (Kategorie 1) oder kein Spam (Kategorie 2)?

# Überblick

- Wir betrachten **Fully Connected Neural Networks**:  
Jedes Neuron aus Layer  $l - 1$  ist mit jedem Neuron aus Layer  $l$  verbunden
- Grundsätzlich zwei mögliche Problemklassen, die mit NN gelöst werden können:
  - **Klassifikation**: *Zuordnung eines Inputs zu einer Kategorie*  
Beispiele: Handelt es sich bei einem Bild (Input) um das einer Katze (Kategorie 1), eines Hundes (Kategorie 2) oder eines Wellensittichs (Kategorie 3)?  
Ist eine E-Mail (Input) Spam (Kategorie 1) oder kein Spam (Kategorie 2)?
  - **Regression**: *Vorhersage eines numerischen Outputs basierend auf dem Input*  
Beispiele: Bei gegebener Quadratmeterzahl, Lage und Sanierungszustand einer Wohnung (Inputs), wie hoch ist der Mietpreis (Output)?  
Wie schnell wird ein Mensch die 100 Meter laufen (Output), wenn von ihm Körpermaße und Fitness-Daten (Inputs) bekannt sind?

# Überblick

$x_i$   $i$ -ter Eintrag im Inputvektor des Trainingsdatensatzes

$a_j^{(l)}$  Aktivierung des  $j$ -ten Neurons im Layer  $l$

$b_j^{(l)}$  Bias des  $j$ -ten Neurons im Layer  $l$  zum Links-Rechts-Shift der Aktivierungsfunktion

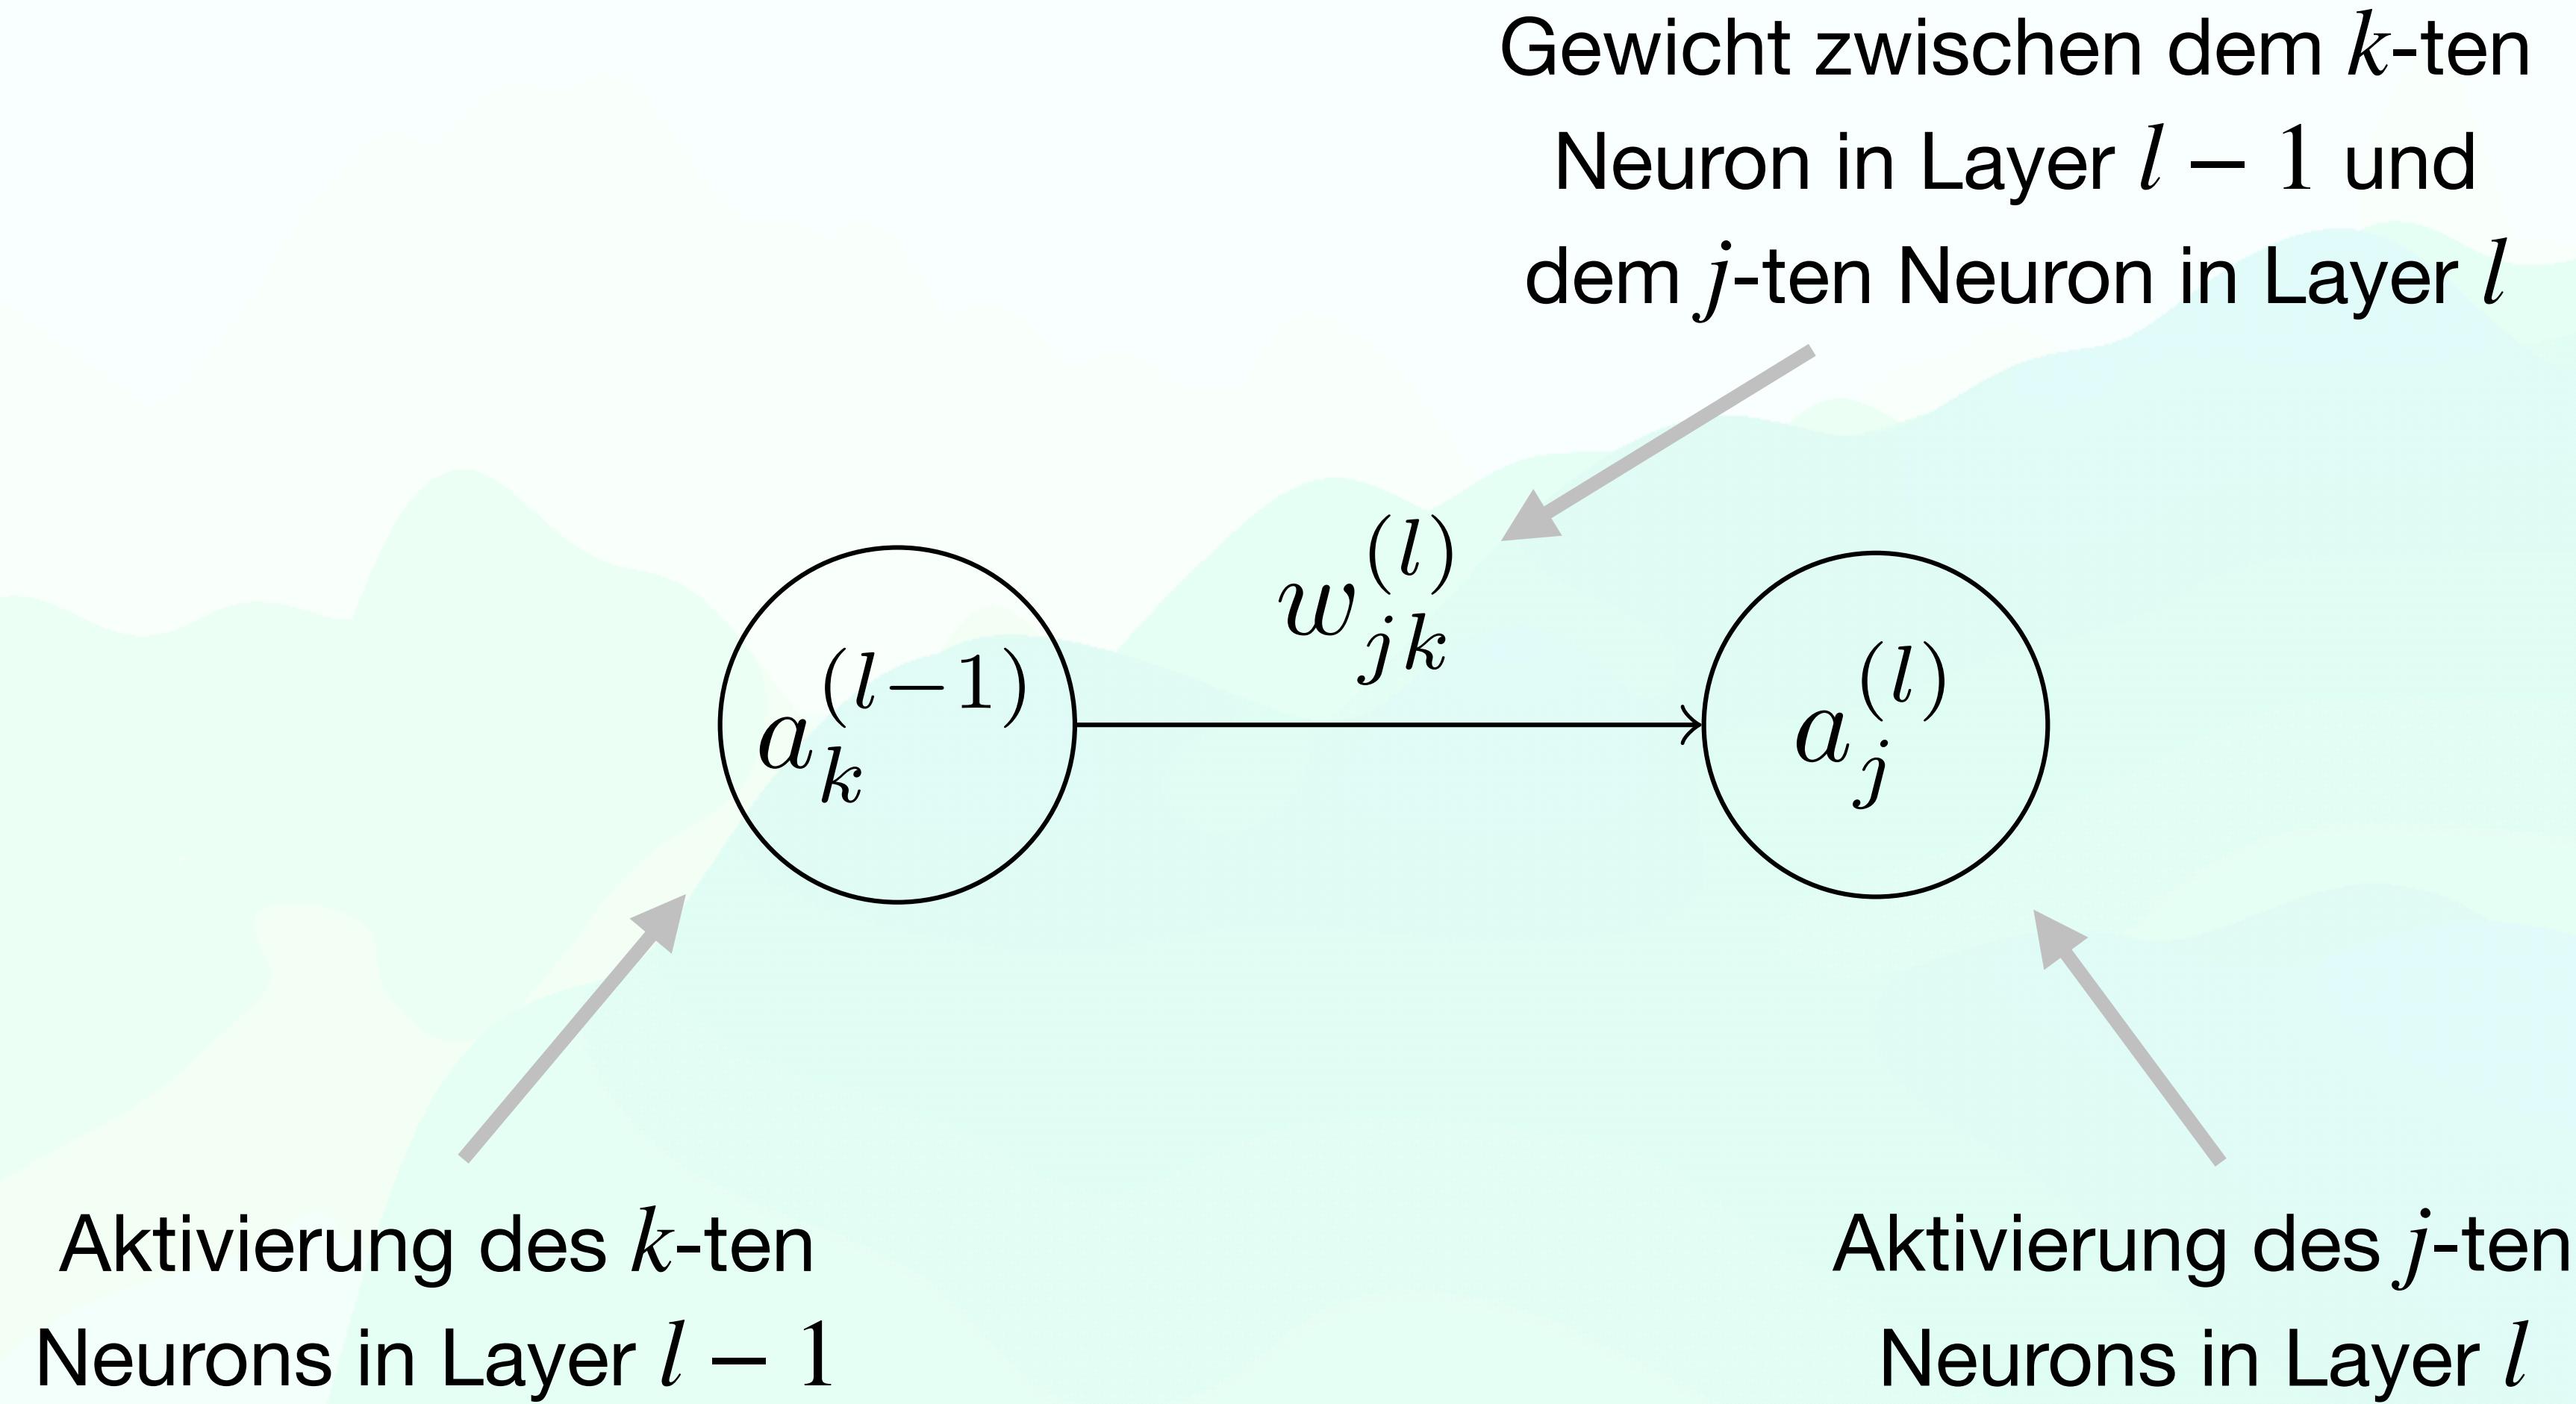
$w_{jk}^{(l)}$  Gewicht vom  $k$ -ten Neuron im Layer  $l - 1$  zum  $j$ -ten Neuron in Layer  $l$

$z_j^{(l)}$  Gewichtete Summe aller eingehenden Neuronenaktivierungen im  $j$ -ten Neuron im Layer  $l$

$\sigma^{(l)}$  Aktivierungsfunktion im Layer  $l$

$y_i$   $i$ -ter Eintrag im erwarteten Outputvektor des Trainingsdatensatzes

# Neuronen und Gewichte



# Neuronen und Gewichte

- Aktivierung eines Neurons  $a$  ist ein numerischer Wert

# Neuronen und Gewichte

- Aktivierung eines Neurons  $a$  ist ein numerischer Wert
  - **Im Input-Layer:** Ergibt sich direkt aus dem Input
    - Input muss entsprechend aufbereitet sein
    - Meist normalisiert auf Werte zwischen 0 und 1

# Neuronen und Gewichte

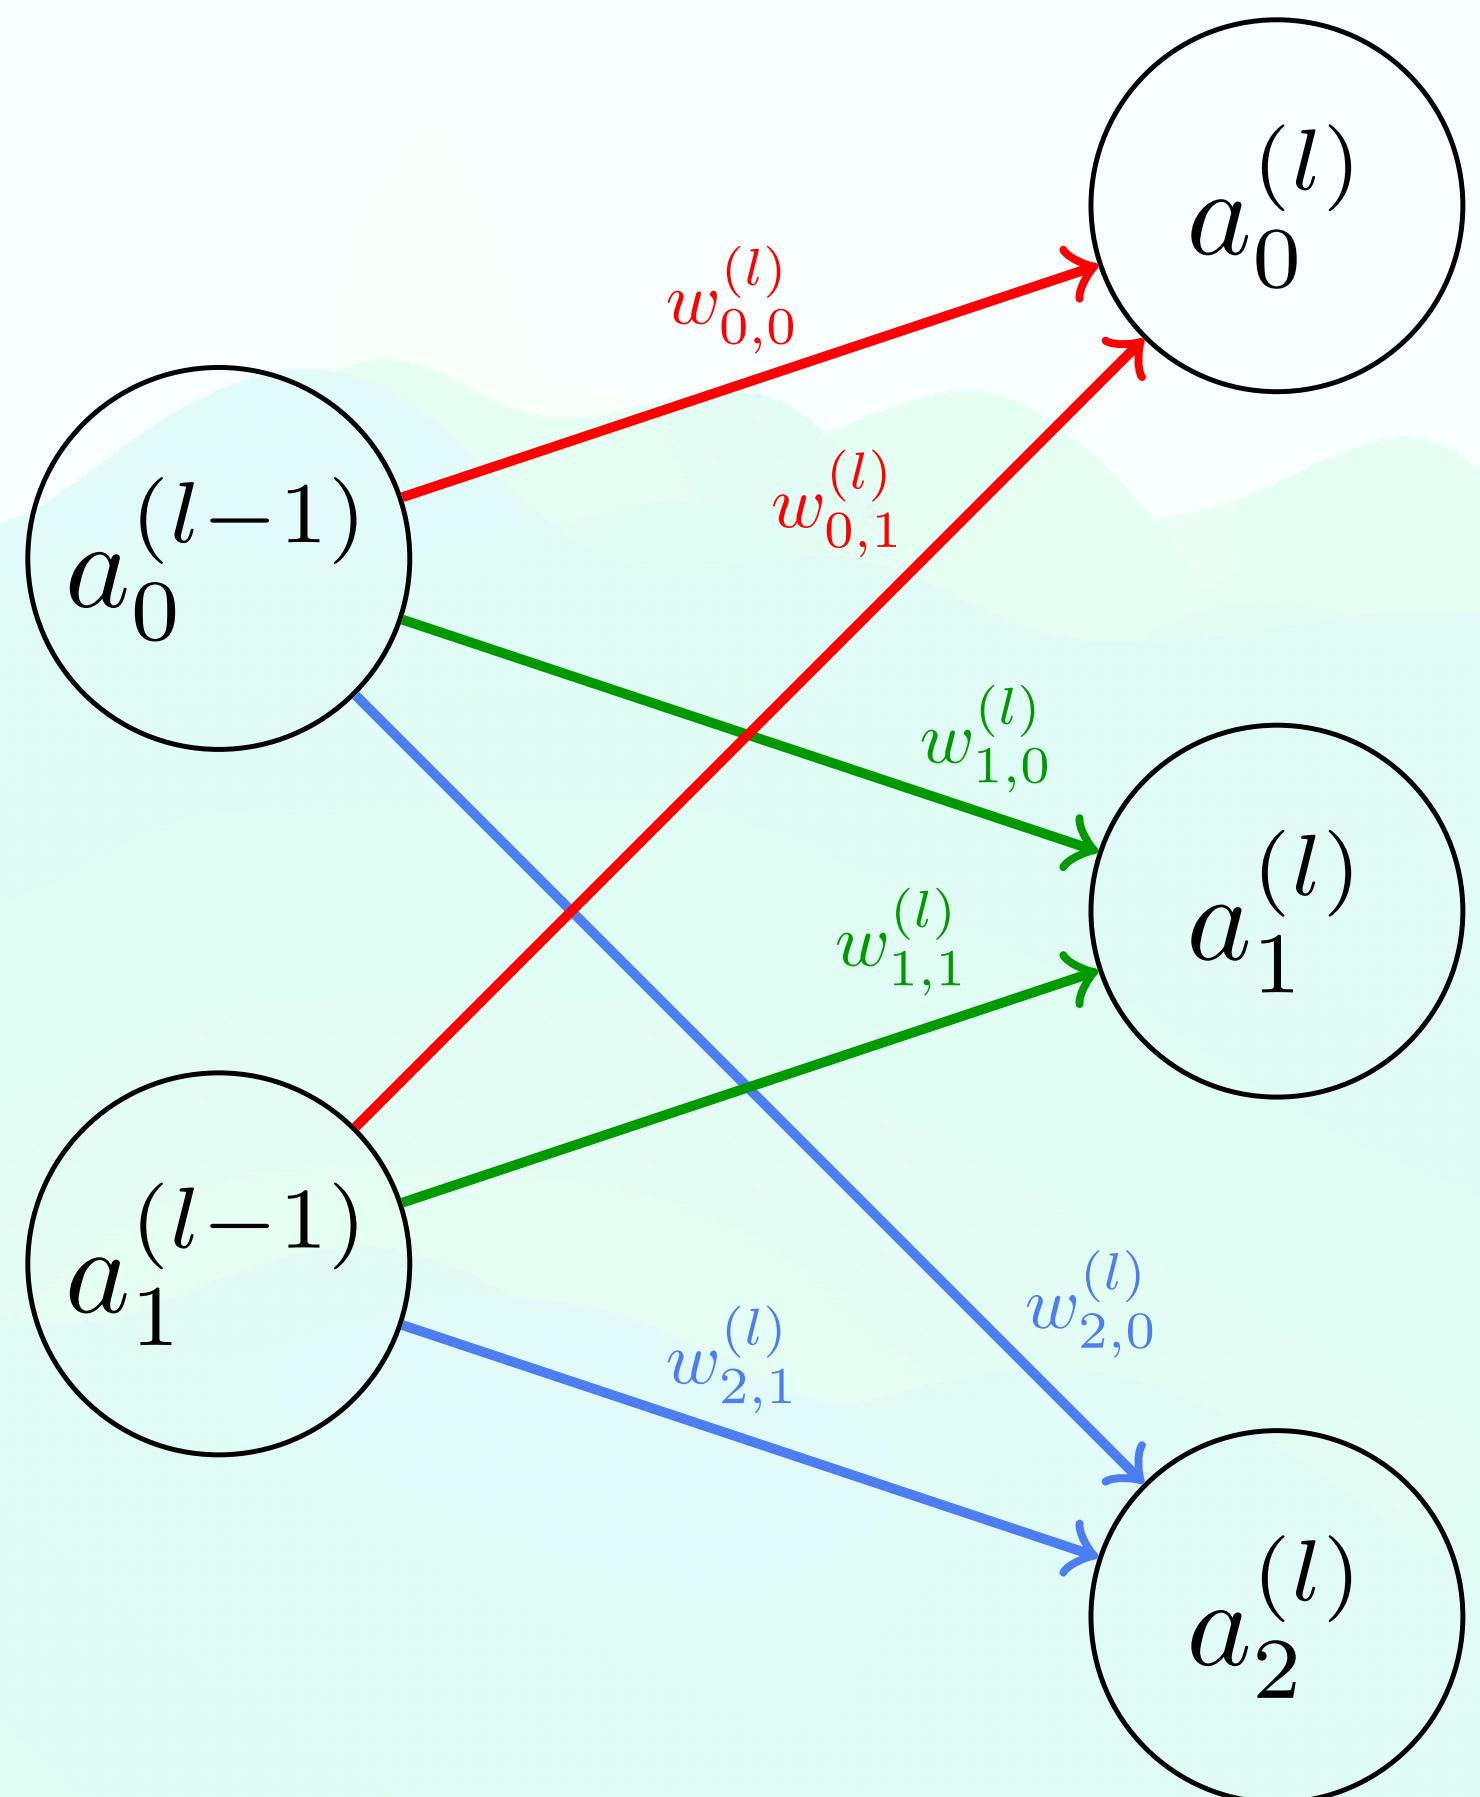
- Aktivierung eines Neurons  $a$  ist ein numerischer Wert
  - **Im Input-Layer:** Ergibt sich direkt aus dem Input
    - Input muss entsprechend aufbereitet sein
    - Meist normalisiert auf Werte zwischen 0 und 1
  - **In den Hidden Layers und im Output-Layer:** Ergibt sich aus gewichteter Summe  $z$  der Eingangs-Neuronen und Aktivierungsfunktion  $\sigma$ 
    - Output-Layer: bei Klassifikation zwischen 0 und 1 (interpretierbar als Wahrscheinlichkeiten), bei Regression beliebige Werte möglich

# Neuronen und Gewichte

- Aktivierung eines Neurons  $a$  ist ein numerischer Wert
  - **Im Input-Layer:** Ergibt sich direkt aus dem Input
    - Input muss entsprechend aufbereitet sein
    - Meist normalisiert auf Werte zwischen 0 und 1
  - **In den Hidden Layers und im Output-Layer:** Ergibt sich aus gewichteter Summe  $z$  der Eingangs-Neuronen und Aktivierungsfunktion  $\sigma$ 
    - Output-Layer: bei Klassifikation zwischen 0 und 1 (interpretierbar als Wahrscheinlichkeiten), bei Regression beliebige Werte möglich
- Gewicht  $w$  zwischen zwei Neuronen gibt an, wie groß der Einfluss der Aktivierung des ersten Neurons auf die des zweiten ist

# Neuronen und Gewichte

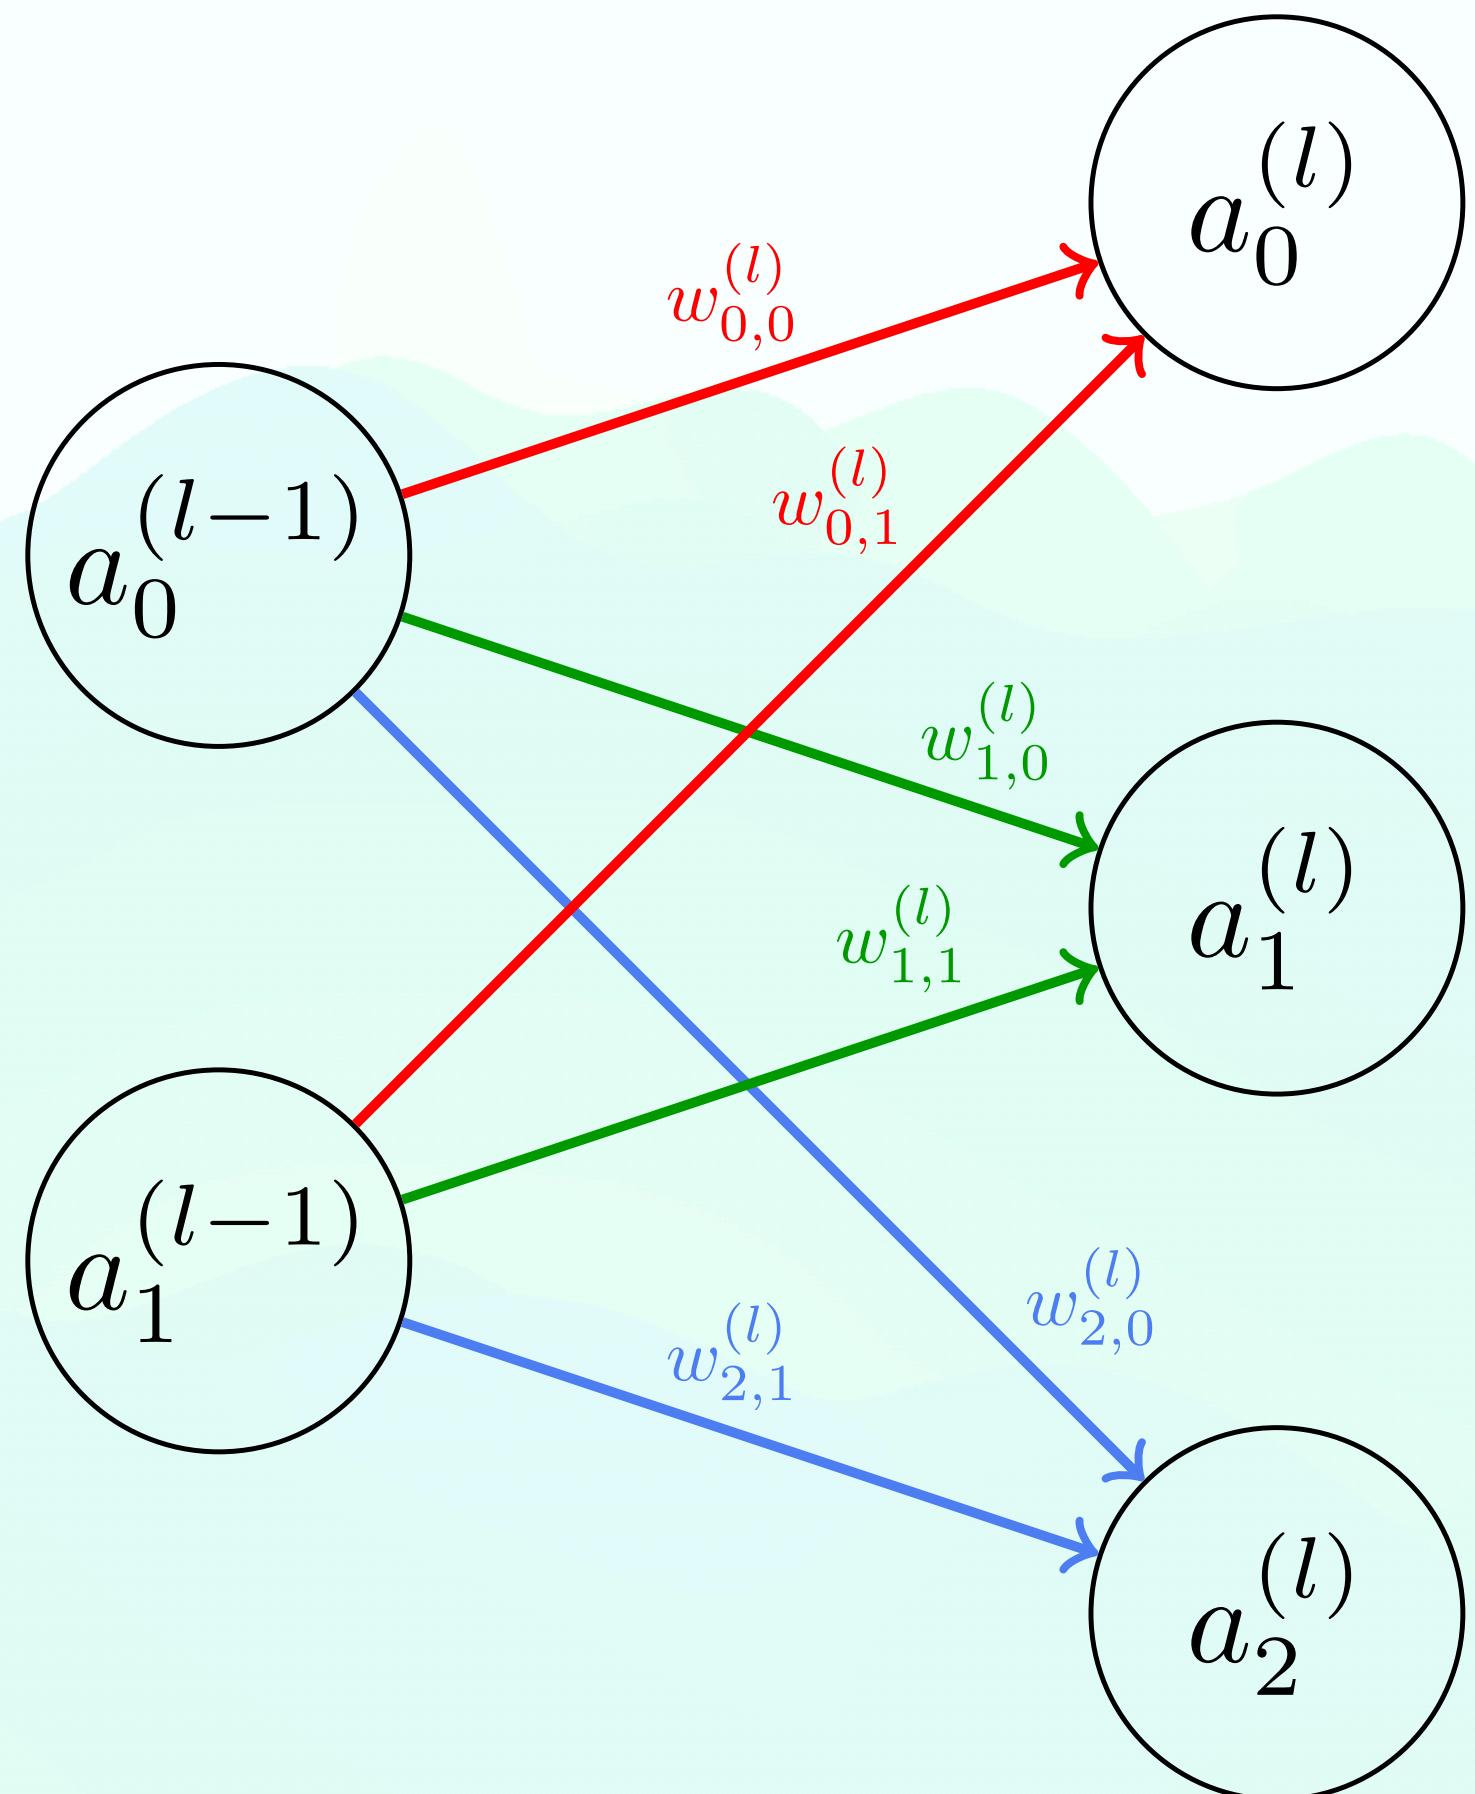
- Gewichtete Summe  $z$  ist die Summe der gewichteten Einflüsse aller Neuronen aus dem vorherigen Layer und dem Bias



# Neuronen und Gewichte

- Gewichtete Summe  $z$  ist die Summe der gewichteten Einflüsse aller Neuronen aus dem vorherigen Layer und dem Bias
- Sei  $n$  die Anzahl der Neuronen im Layer  $l - 1$ :

$$z_j^{(l)} = w_{j,0}^{(l)} a_0^{(l-1)} + w_{j,1}^{(l)} a_1^{(l-1)} + \dots + w_{j,n-1}^{(l)} a_{n-1}^{(l-1)} + b_j^{(l)}$$



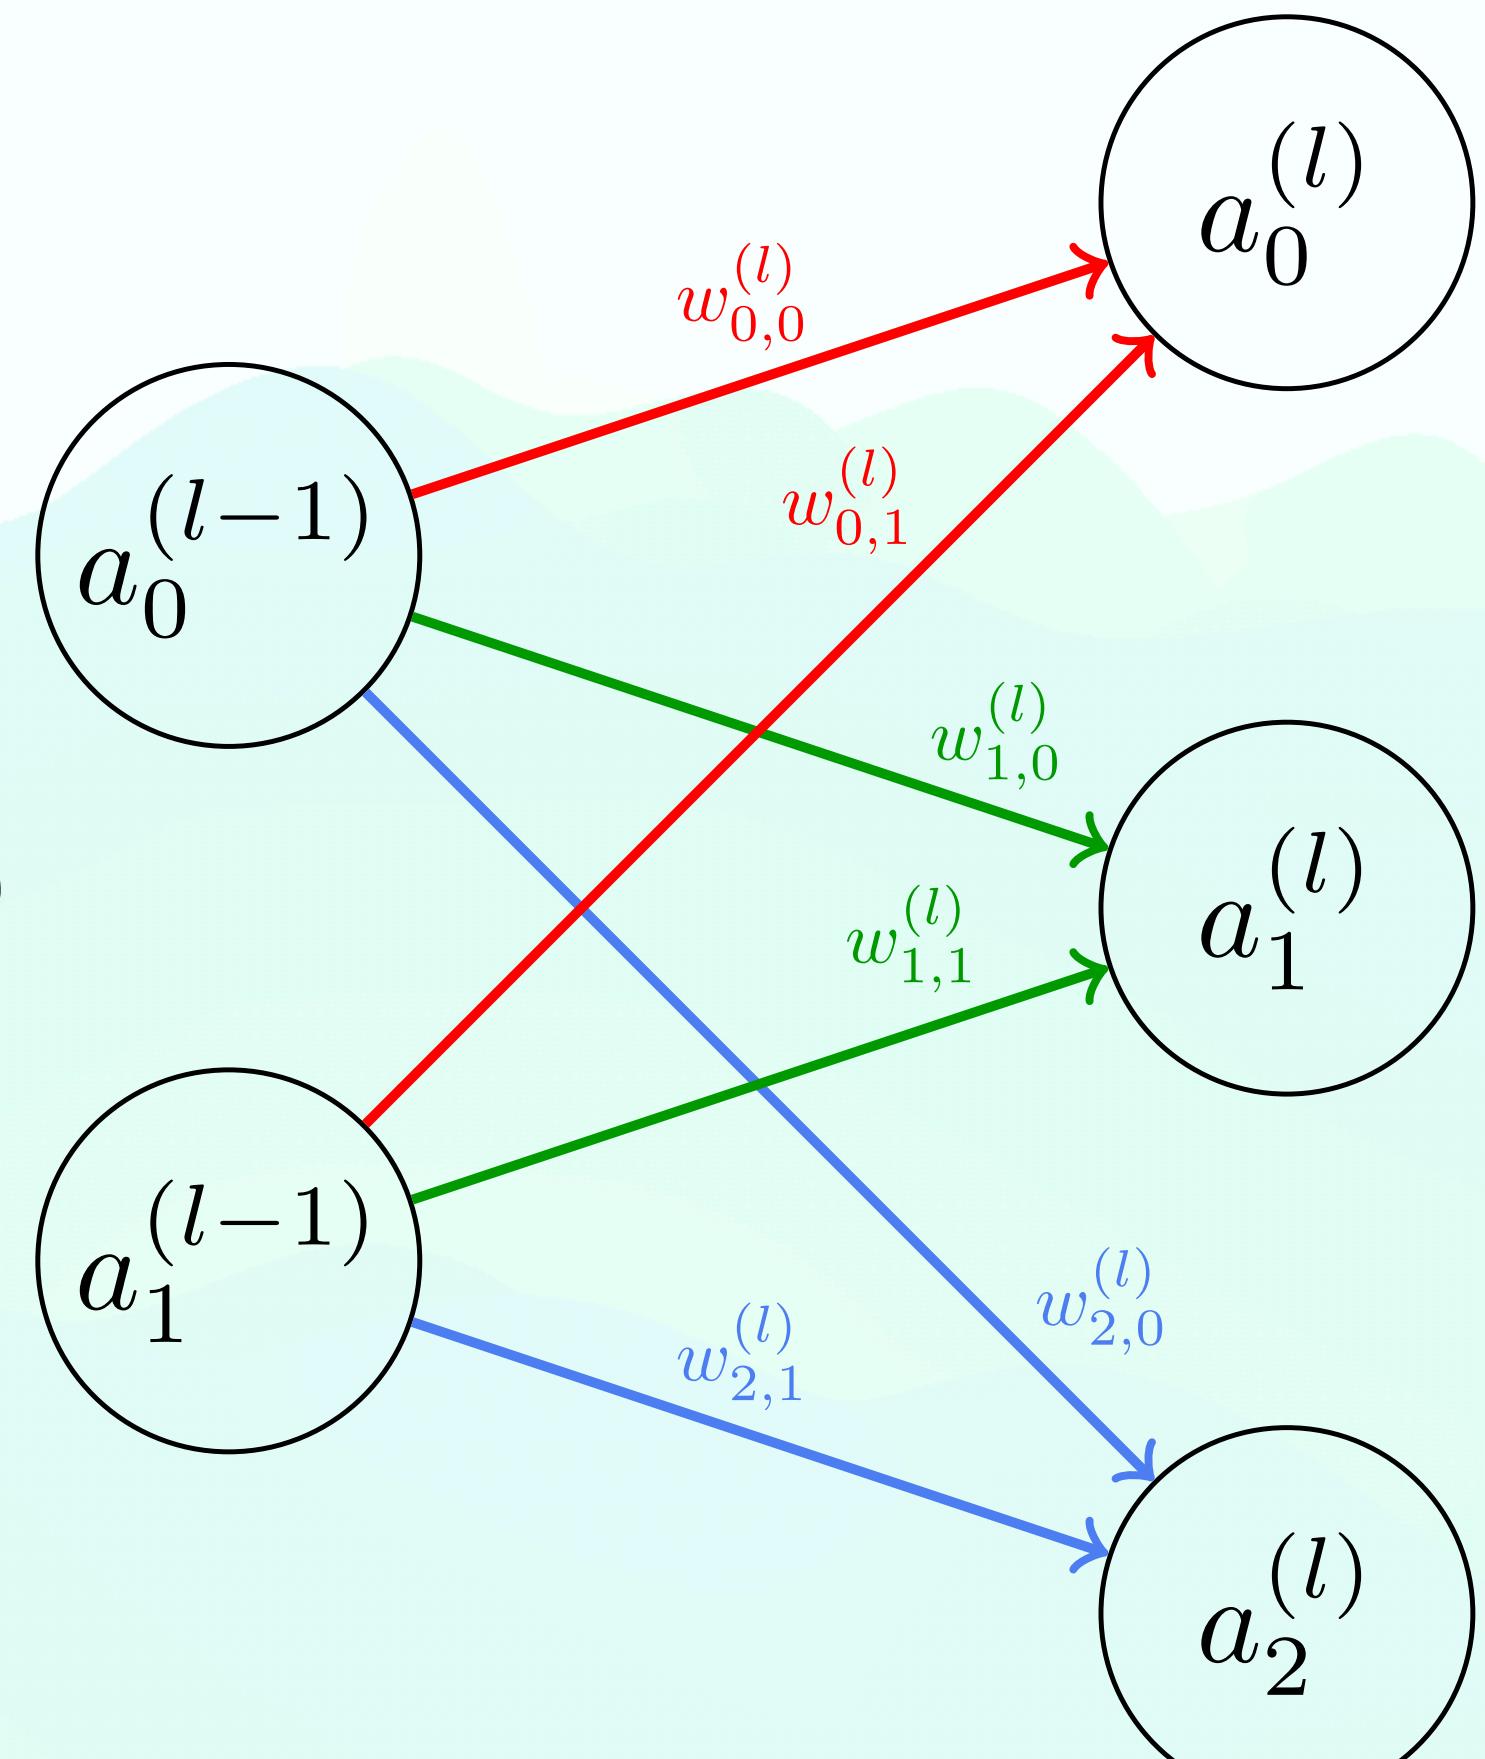
# Neuronen und Gewichte

- Gewichtete Summe  $z$  ist die Summe der gewichteten Einflüsse aller Neuronen aus dem vorherigen Layer und dem Bias
- Sei  $n$  die Anzahl der Neuronen im Layer  $l - 1$ :

$$z_j^{(l)} = w_{j,0}^{(l)} a_0^{(l-1)} + w_{j,1}^{(l)} a_1^{(l-1)} + \dots + w_{j,n-1}^{(l)} a_{n-1}^{(l-1)} + b_j^{(l)}$$

- Aktivierungsfunktion  $\sigma(z)$  berechnet die Aktivierung des Neurons basierend auf der gewichteten Summe  $z$ :

$$a_j^{(l)} = \sigma(z_j^{(l)})$$



# Neuronen und Gewichte

- **Trick:** Für den Bias fügen wir in jedem Layer (außer dem Output-Layer) einfach ein eigenes Bias-Neuron hinzu

# Neuronen und Gewichte

- **Trick:** Für den Bias fügen wir in jedem Layer (außer dem Output-Layer) einfach ein eigenes Bias-Neuron hinzu
- Bias-Neuronen: Feste Aktivierung von 1, keine eingehenden Gewichte
- Das Netz lernt dann die ausgehenden Gewichte der Bias-Neuronen auf die gleiche Weise wie die Gewichte zwischen allen anderen Neuronen

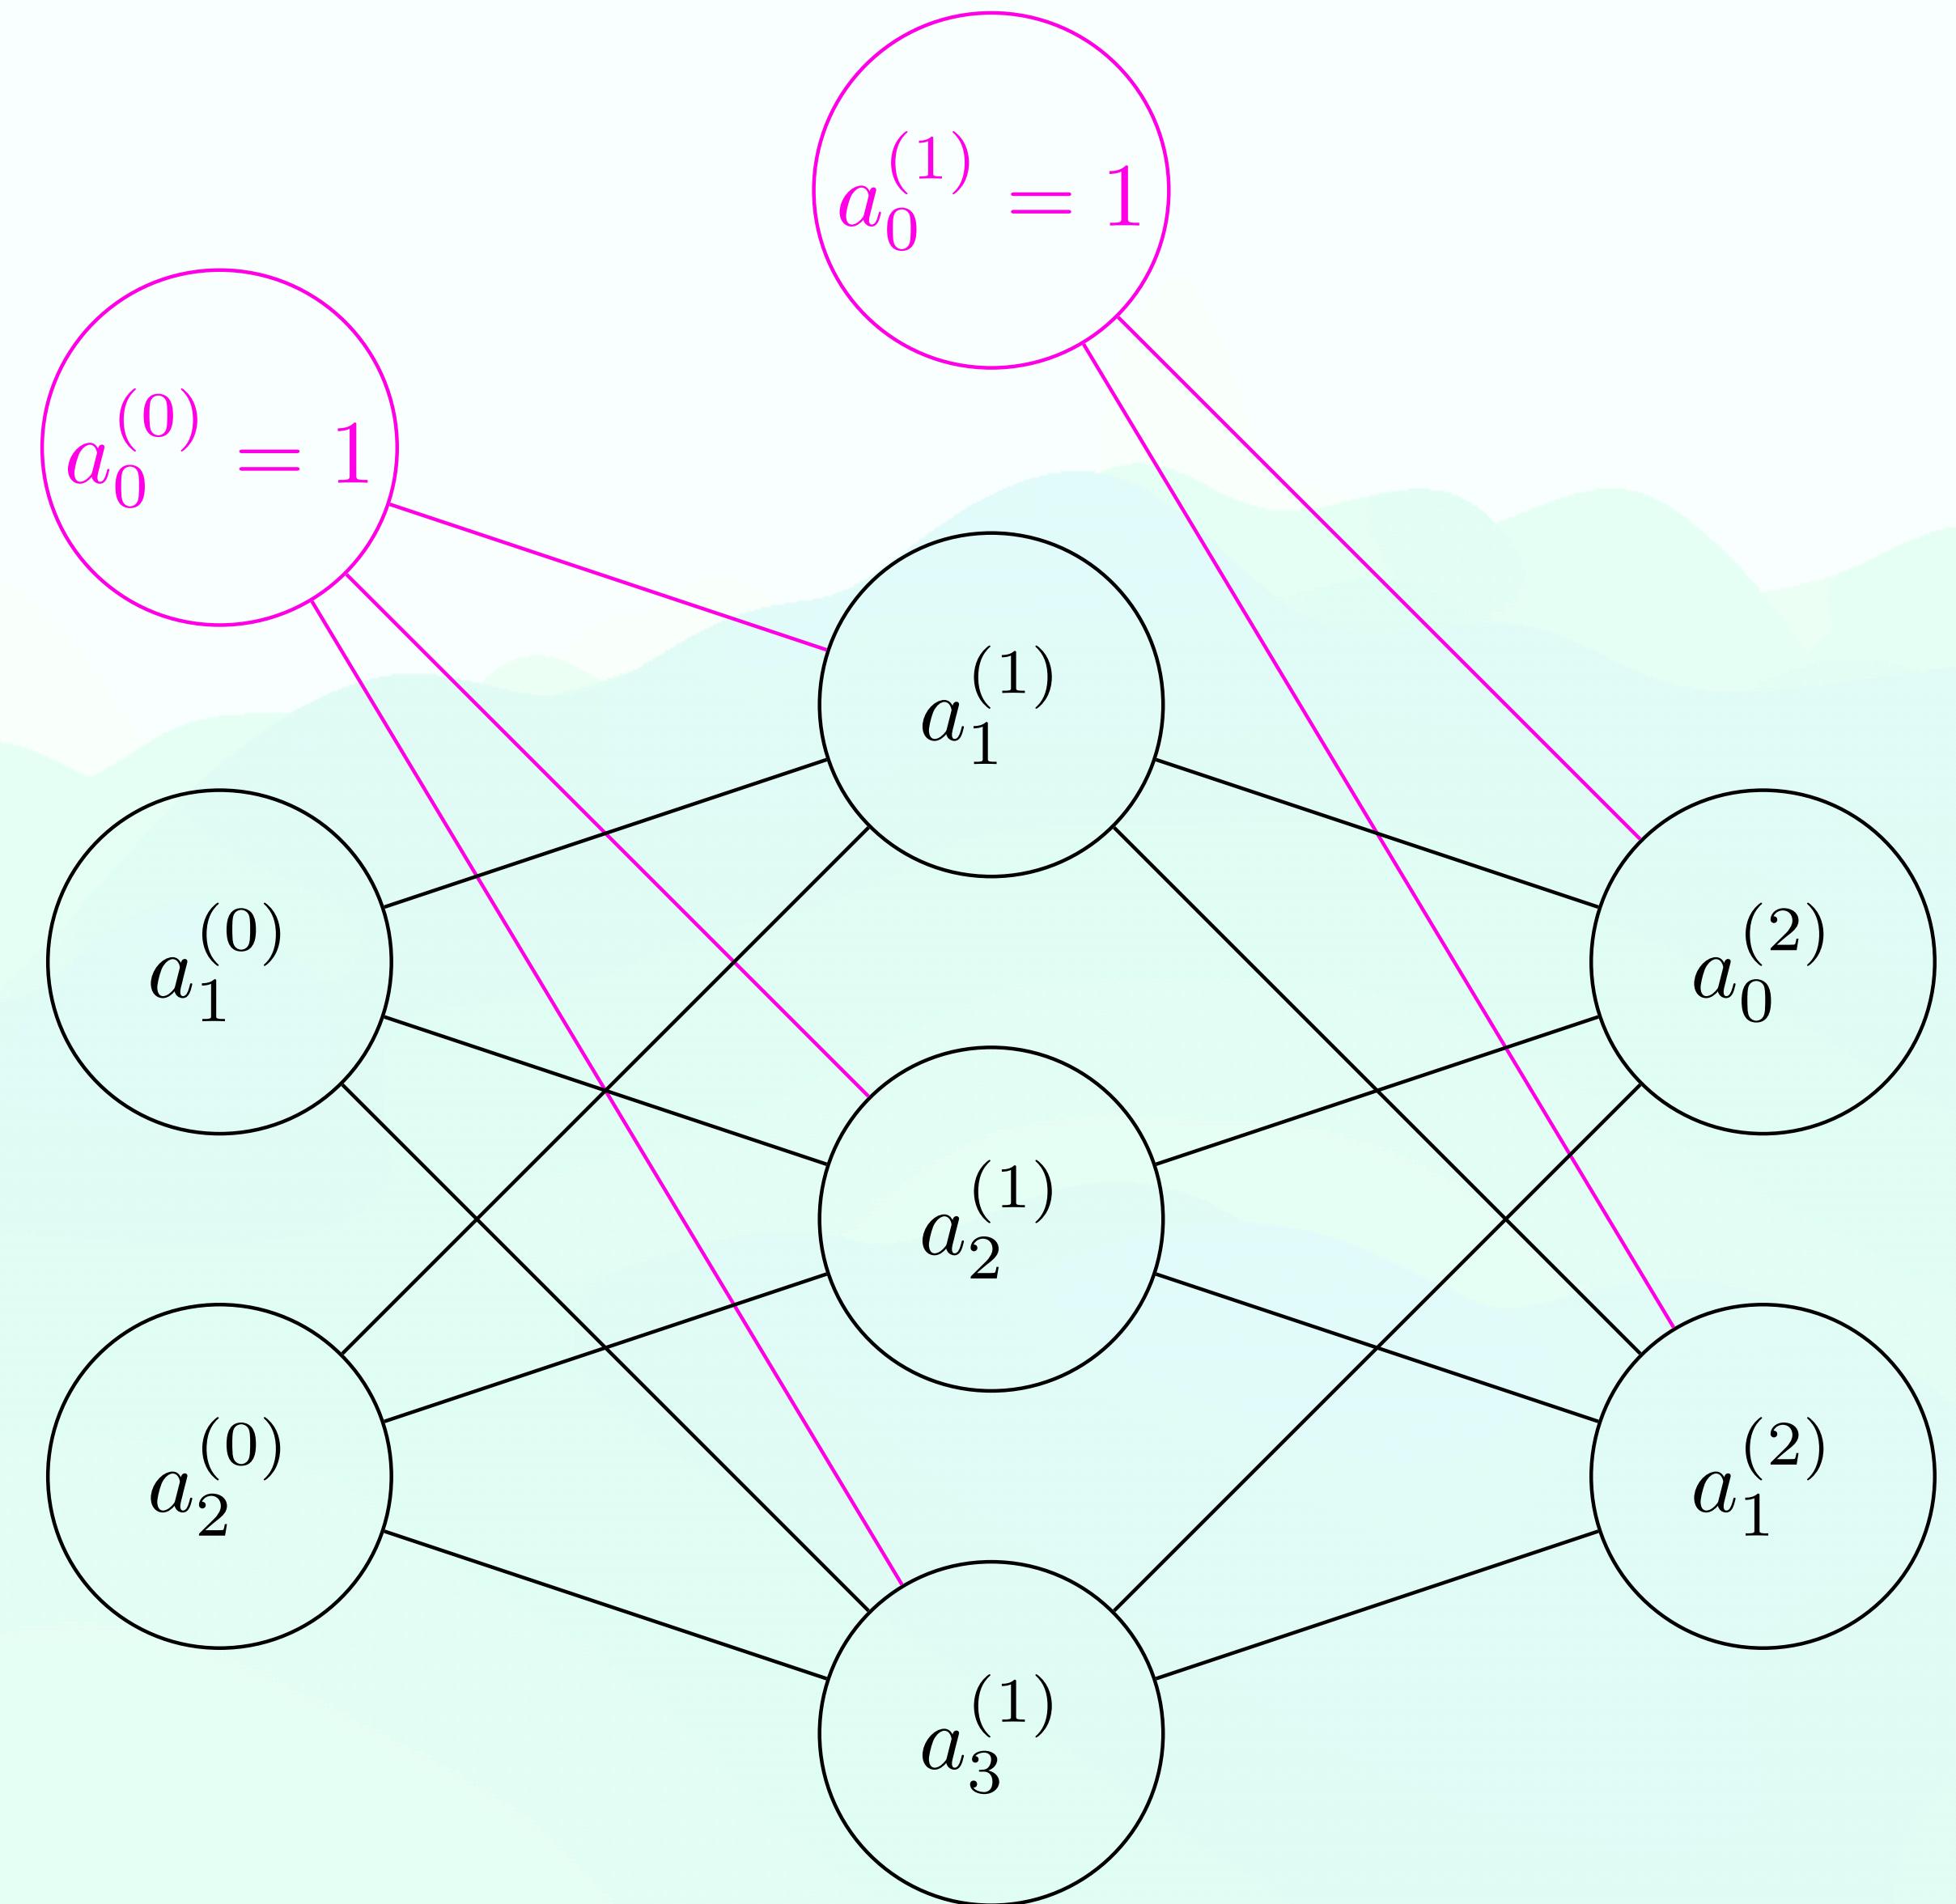
# Neuronen und Gewichte

- **Trick:** Für den Bias fügen wir in jedem Layer (außer dem Output-Layer) einfach ein eigenes Bias-Neuron hinzu
- Bias-Neuronen: Feste Aktivierung von 1, keine eingehenden Gewichte
- Das Netz lernt dann die ausgehenden Gewichte der Bias-Neuronen auf die gleiche Weise wie die Gewichte zwischen allen anderen Neuronen
- Damit entfällt für die Berechnung der gewichteten Summe der eigene Term für  $b_j^{(l)}$ :

$$z_j^{(l)} = w_{j,0}^{(l)} a_0^{(l-1)} + w_{j,1}^{(l)} a_1^{(l-1)} + \dots + w_{j,n-1}^{(l)} a_{n-1}^{(l-1)} = \sum_{k=0}^{n-1} w_{jk}^{(l)} a_k^{(l-1)}$$

# Neuronen und Gewichte

- Keine eingehenden Gewichte in **Biases**
- Daher keine Berechnung von gewichteten Summen und Aktivierungen in den Bias-Neuronen
- Bias fließt in die Berechnung des nächsten Layers ein, ist aber selbst unabhängig vom vorherigen Layer



# Klasse für neuronales Netz anlegen



```
class NeuralNetwork( ):
    def __init__(self, structure):
        self.structure = structure
        self.__init_layers()

    def __init_layers(self):
        pass
```

# Klasse für neuronales Netz anlegen



Deklariert eine **Klasse** namens NeuralNetwork. Sie enthält den „Bauplan“ für ein NN-**Objekt**, also alle seine **Eigenschaften** und **Methoden**.

```
class NeuralNetwork( ):
    def __init__(self, structure):
        self.structure = structure
        self.__init_layers()

    def __init_layers(self):
        pass
```

# Klasse für neuronales Netz anlegen



```
class NeuralNetwork( ):
    def __init__(self, structure):
        self.structure = structure
        self.__init_layers()

    def __init_layers(self):
        pass
```

Der **Konstruktor** der Klasse. Er wird beim Erzeugen des NN-Objekts aufgerufen, und ihm muss ein **Parameter** namens **structure** übergeben werden. Dieser Parameter soll später die Anzahl der **Layer** und ihrer **Neuronen** bestimmen.

# Klasse für neuronales Netz anlegen



```
class NeuralNetwork():
    def __init__(self, structure):
        self.structure = structure
        self.__init_layers()

    def __init_layers(self):
        pass
```

Im Parameter `self` bekommt jede Objektmethode in Python eine Referenz auf die eigene Objektinstanz übergeben. Darüber kann die Methode auf die Instanz zugreifen und darauf z. B. andere Methoden des Objekts aufrufen oder Eigenschaften des Objekts Werte zuweisen.

# Klasse für neuronales Netz anlegen



```
class NeuralNetwork():
    def __init__(self, structure):
        self.structure = structure
        self.__init_layers()

    def __init_layers(self):
        pass
```

Im Konstruktor wird die **Eigenschaft** `structure` angelegt und ihr der Wert des übergebenen, gleichnamigen **Parameters** zugewiesen.

# Klasse für neuronales Netz anlegen



```
class NeuralNetwork():
    def __init__(self, structure):
        self.structure = structure
        self.__init_layers()

    def __init_layers(self):
        pass
```

Danach rufen wir eine **Methode** namens `__init_layers` auf. Ein Methoden- oder Funktionsaufruf besteht immer aus dem Namen der Methode oder Funktion, gefolgt von der Parameterliste in runden Klammern. In diesem Fall übergeben wir der Methode keine Parameter.

# Klasse für neuronales Netz anlegen



```
class NeuralNetwork():
    def __init__(self, structure):
        self.structure = structure
        self.__init_layers()
```

```
def __init_layers(self):
    pass
```

Die **Methode `__init_layers`** wird deklariert.  
Die beiden Unterstriche am Beginn des Namens  
zeigen eine **private** Methode an. Sie kann nicht  
von außerhalb der Klasse aufgerufen werden.

# Klasse für neuronales Netz anlegen



```
class NeuralNetwork( ):
    def __init__(self, structure):
        self.structure = structure
        self.__init_layers()
```

```
def __init_layers(self):
    pass
```

Das `pass` zeigt an, dass der Inhalt dieser Methode vorerst leer ist. Es hat keine inhaltliche Funktion, aber es wäre ein Syntaxfehler, den Rumpf der Methode leer zu lassen.  
Wir fügen den Inhalt der Methode später hinzu.

# Objektinstanz für neuronales Netz erzeuaen



```
if __name__ == '__main__':
    nn = NeuralNetwork(structure=[3, 4, 2])
```

# Objektinstanz für neuronales Netz erzeugen



```
if __name__ == '__main__':
    nn = NeuralNetwork(structure=[3, 4, 2])
```

Erzeugt ein neues **Objekt** der `NeuralNetwork`-Klasse und weist es der **Variable** `nn` zu. Als `structure`-Parameter übergeben wir eine **Liste** mit drei Zahlen.

# Objektinstanz für neuronales Netz erzeugen



3 Neuronen im Input-Layer, 4 Neuronen im Hidden Layer, 2 Neuronen im Output-Layer

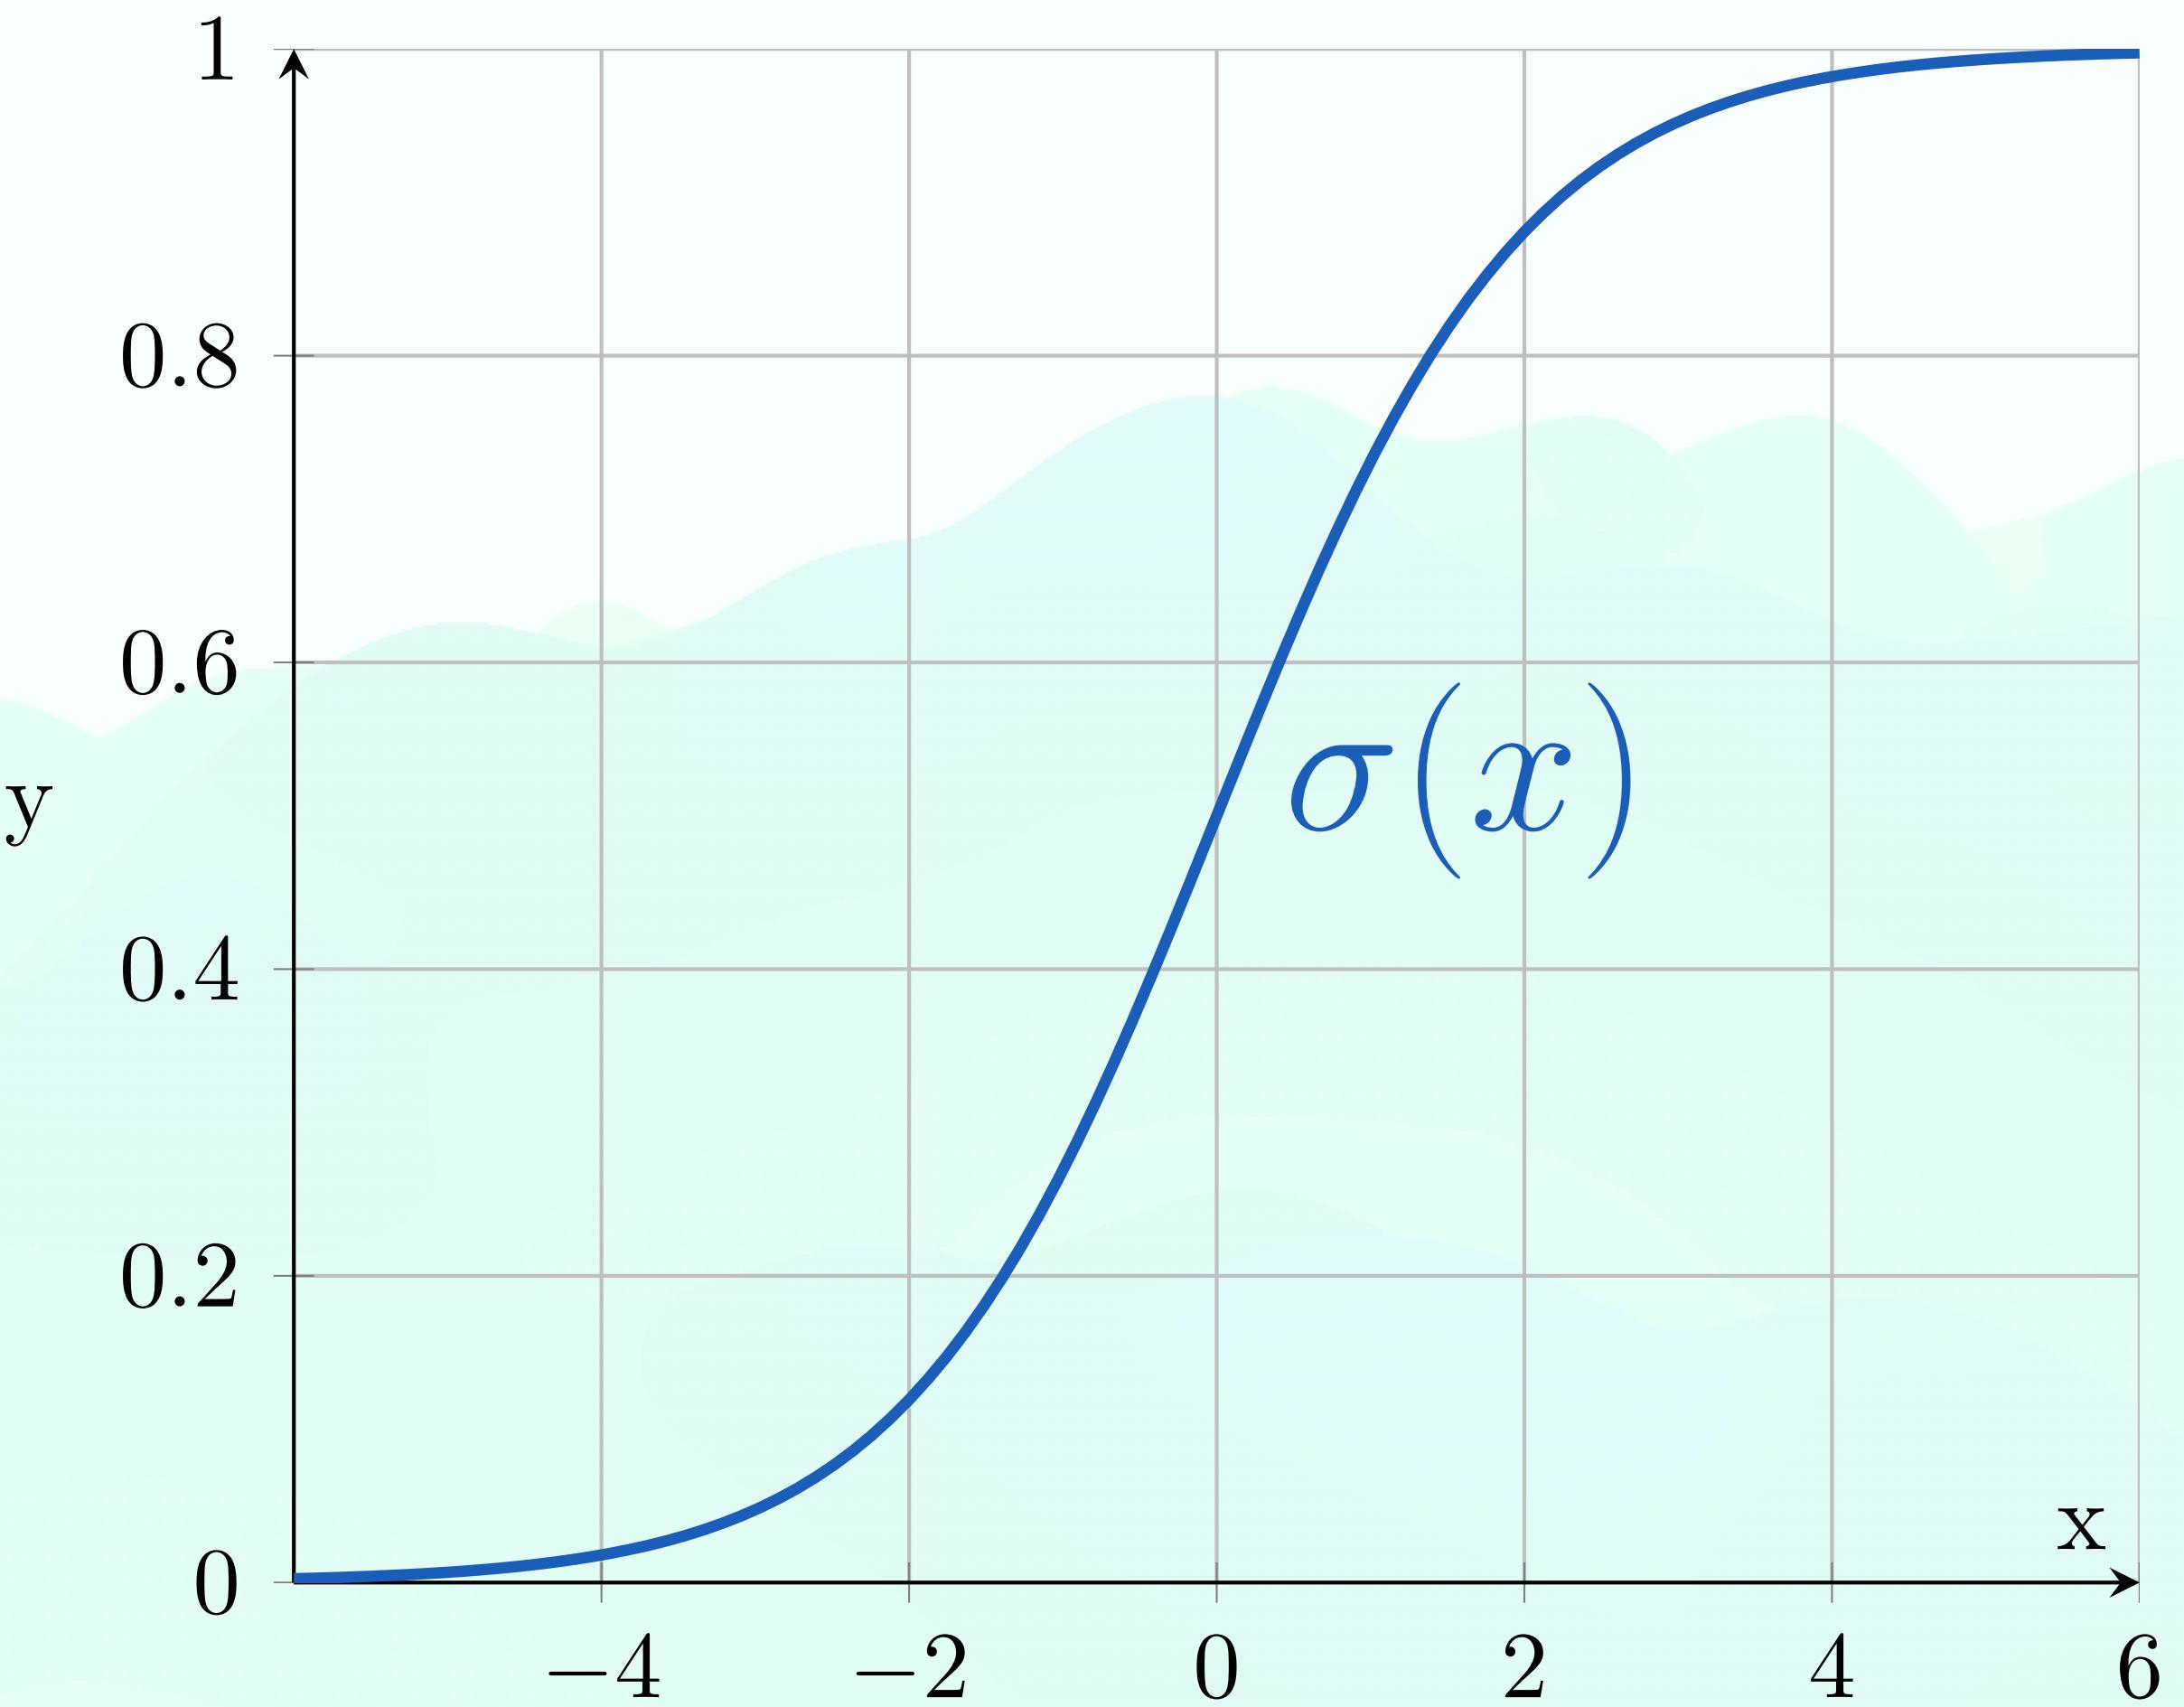
```
if __name__ == '__main__':
    nn = NeuralNetwork(structure=[3, 4, 2])
```

# Aktivierungsfunktionen

- Klassisch: Die Sigmoid-Funktion

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

- Abbildung einer reellen Zahl auf den Wertebereich 0 bis 1

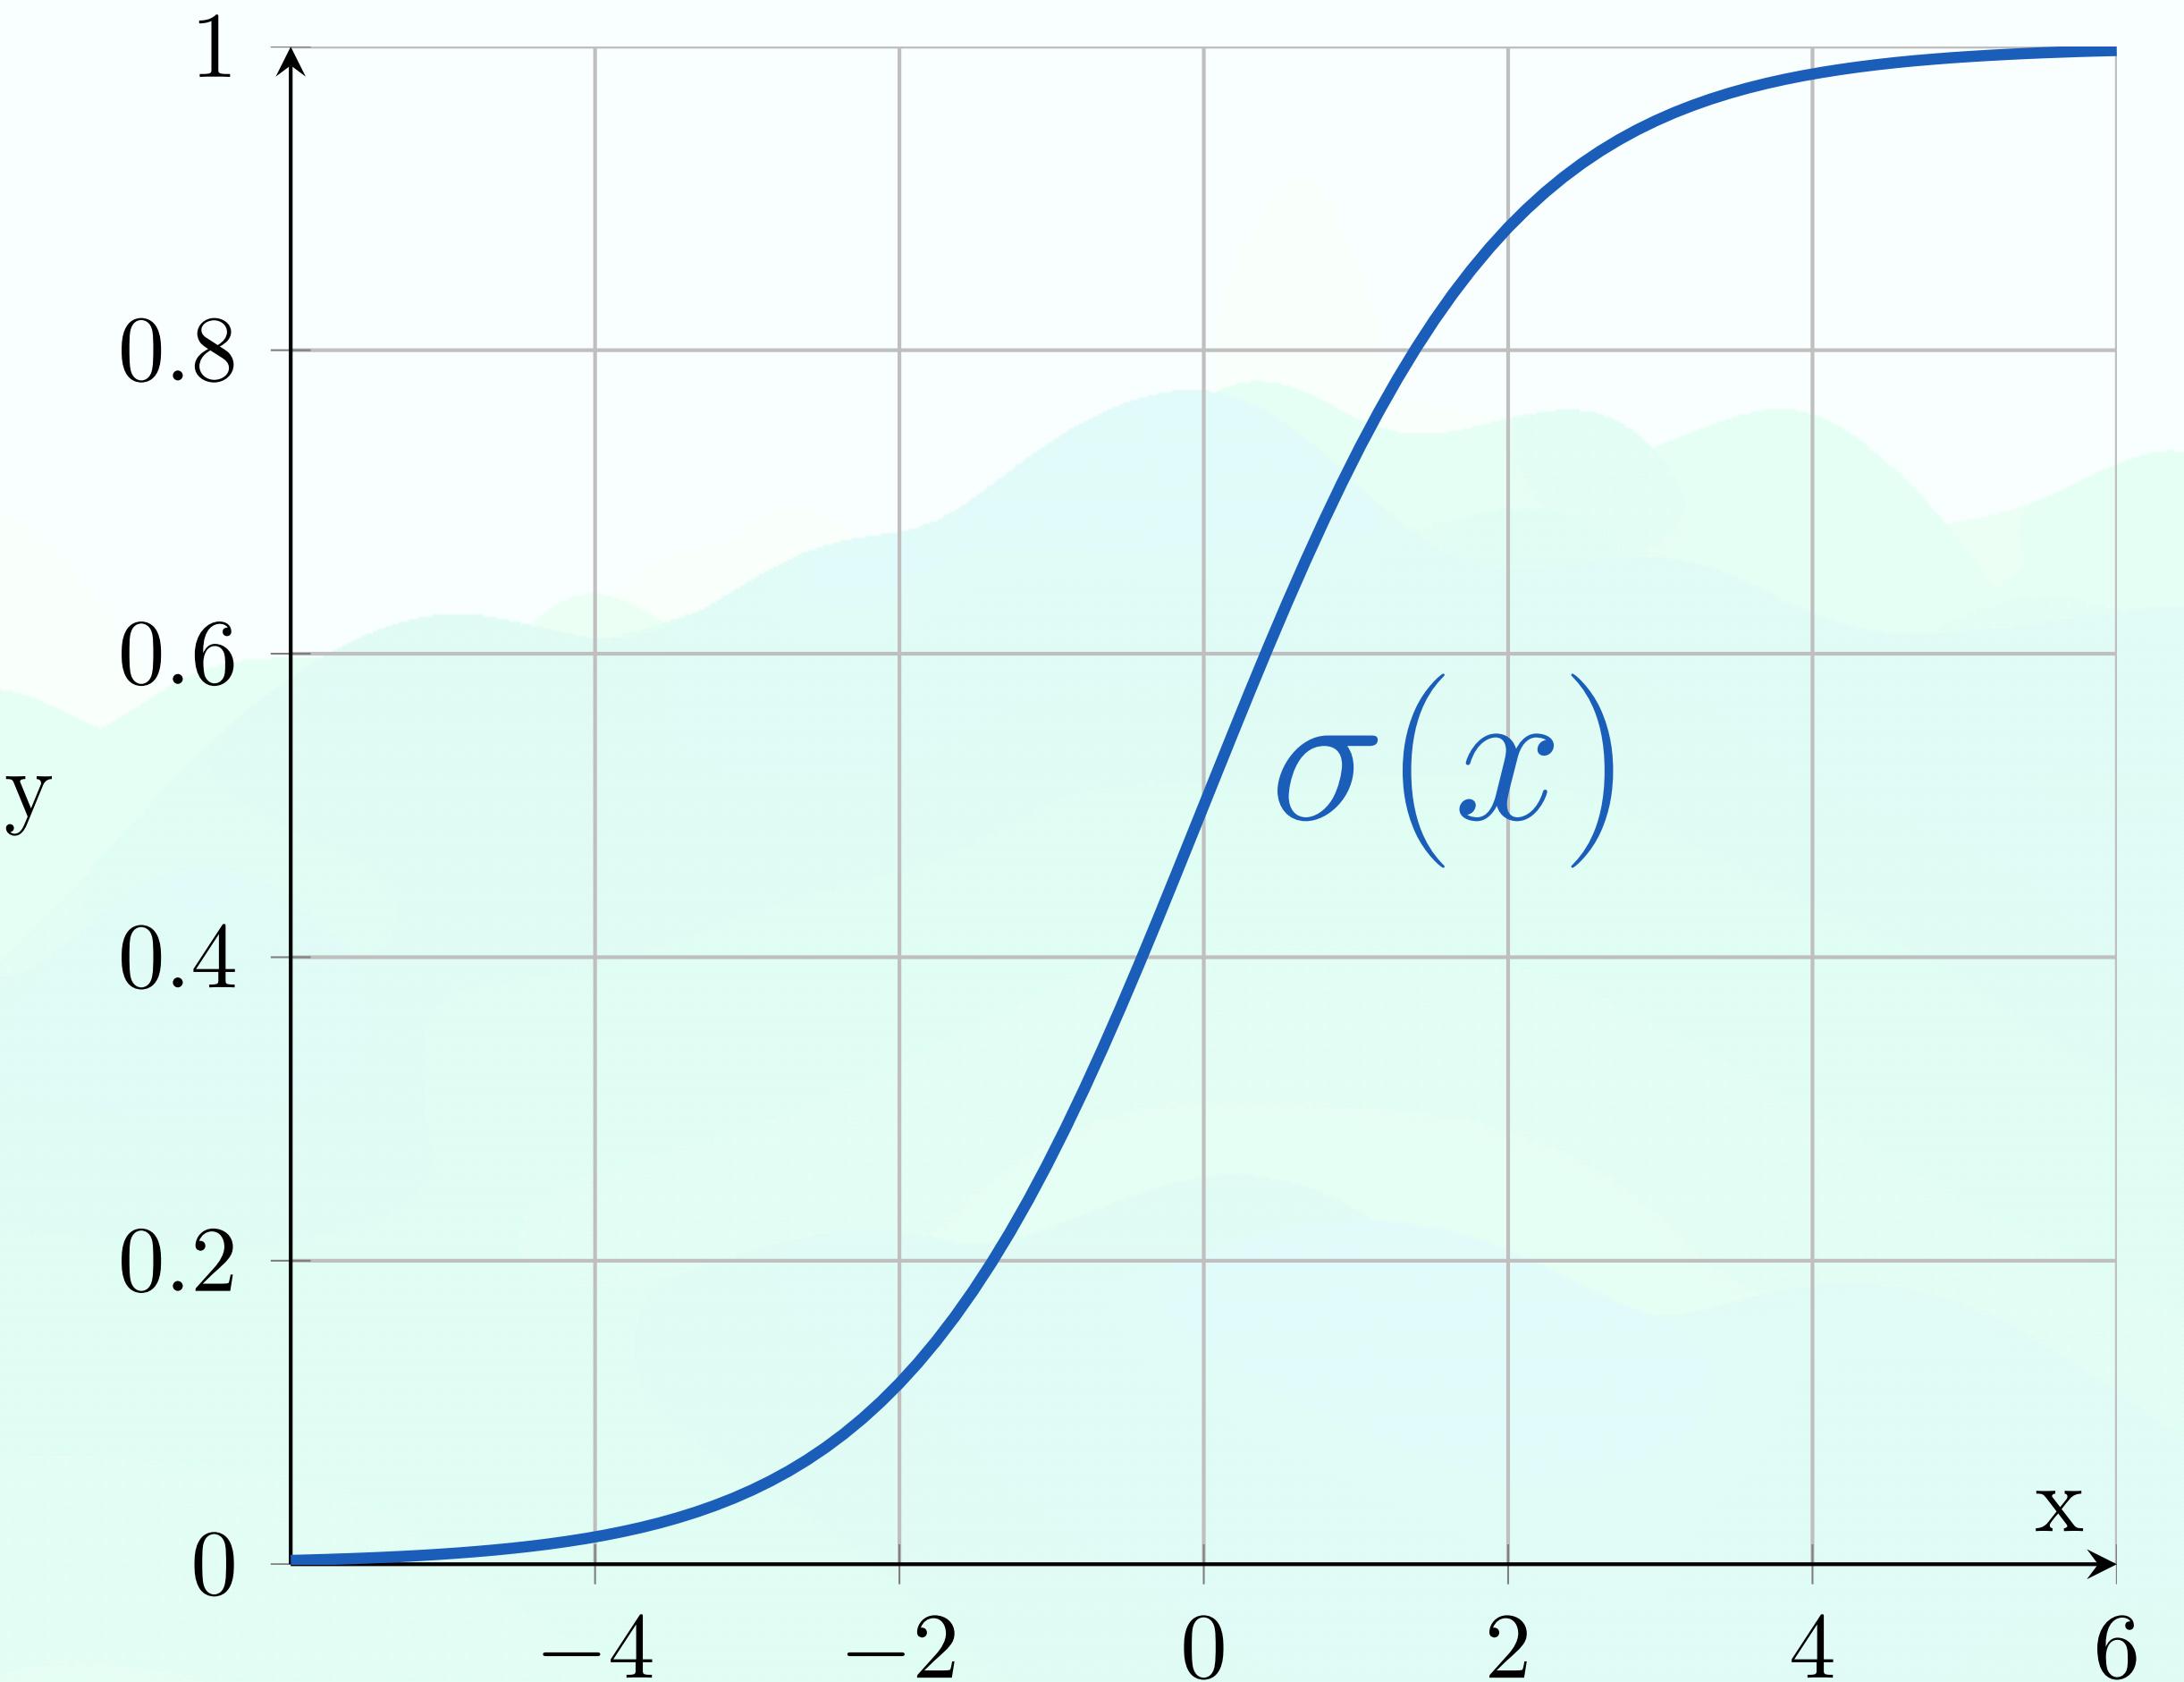


# Aktivierungsfunktionen

- Klassisch: Die Sigmoid-Funktion

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

- Abbildung einer reellen Zahl auf den Wertebereich 0 bis 1
- Problem: **Vanishing Gradients**
  - Nur sehr schmaler Bereich, in dem sich die Werte signifikant von 0 und 1 unterscheiden
  - Daher in den „Außenbereichen“ nur langsames Lernen möglich

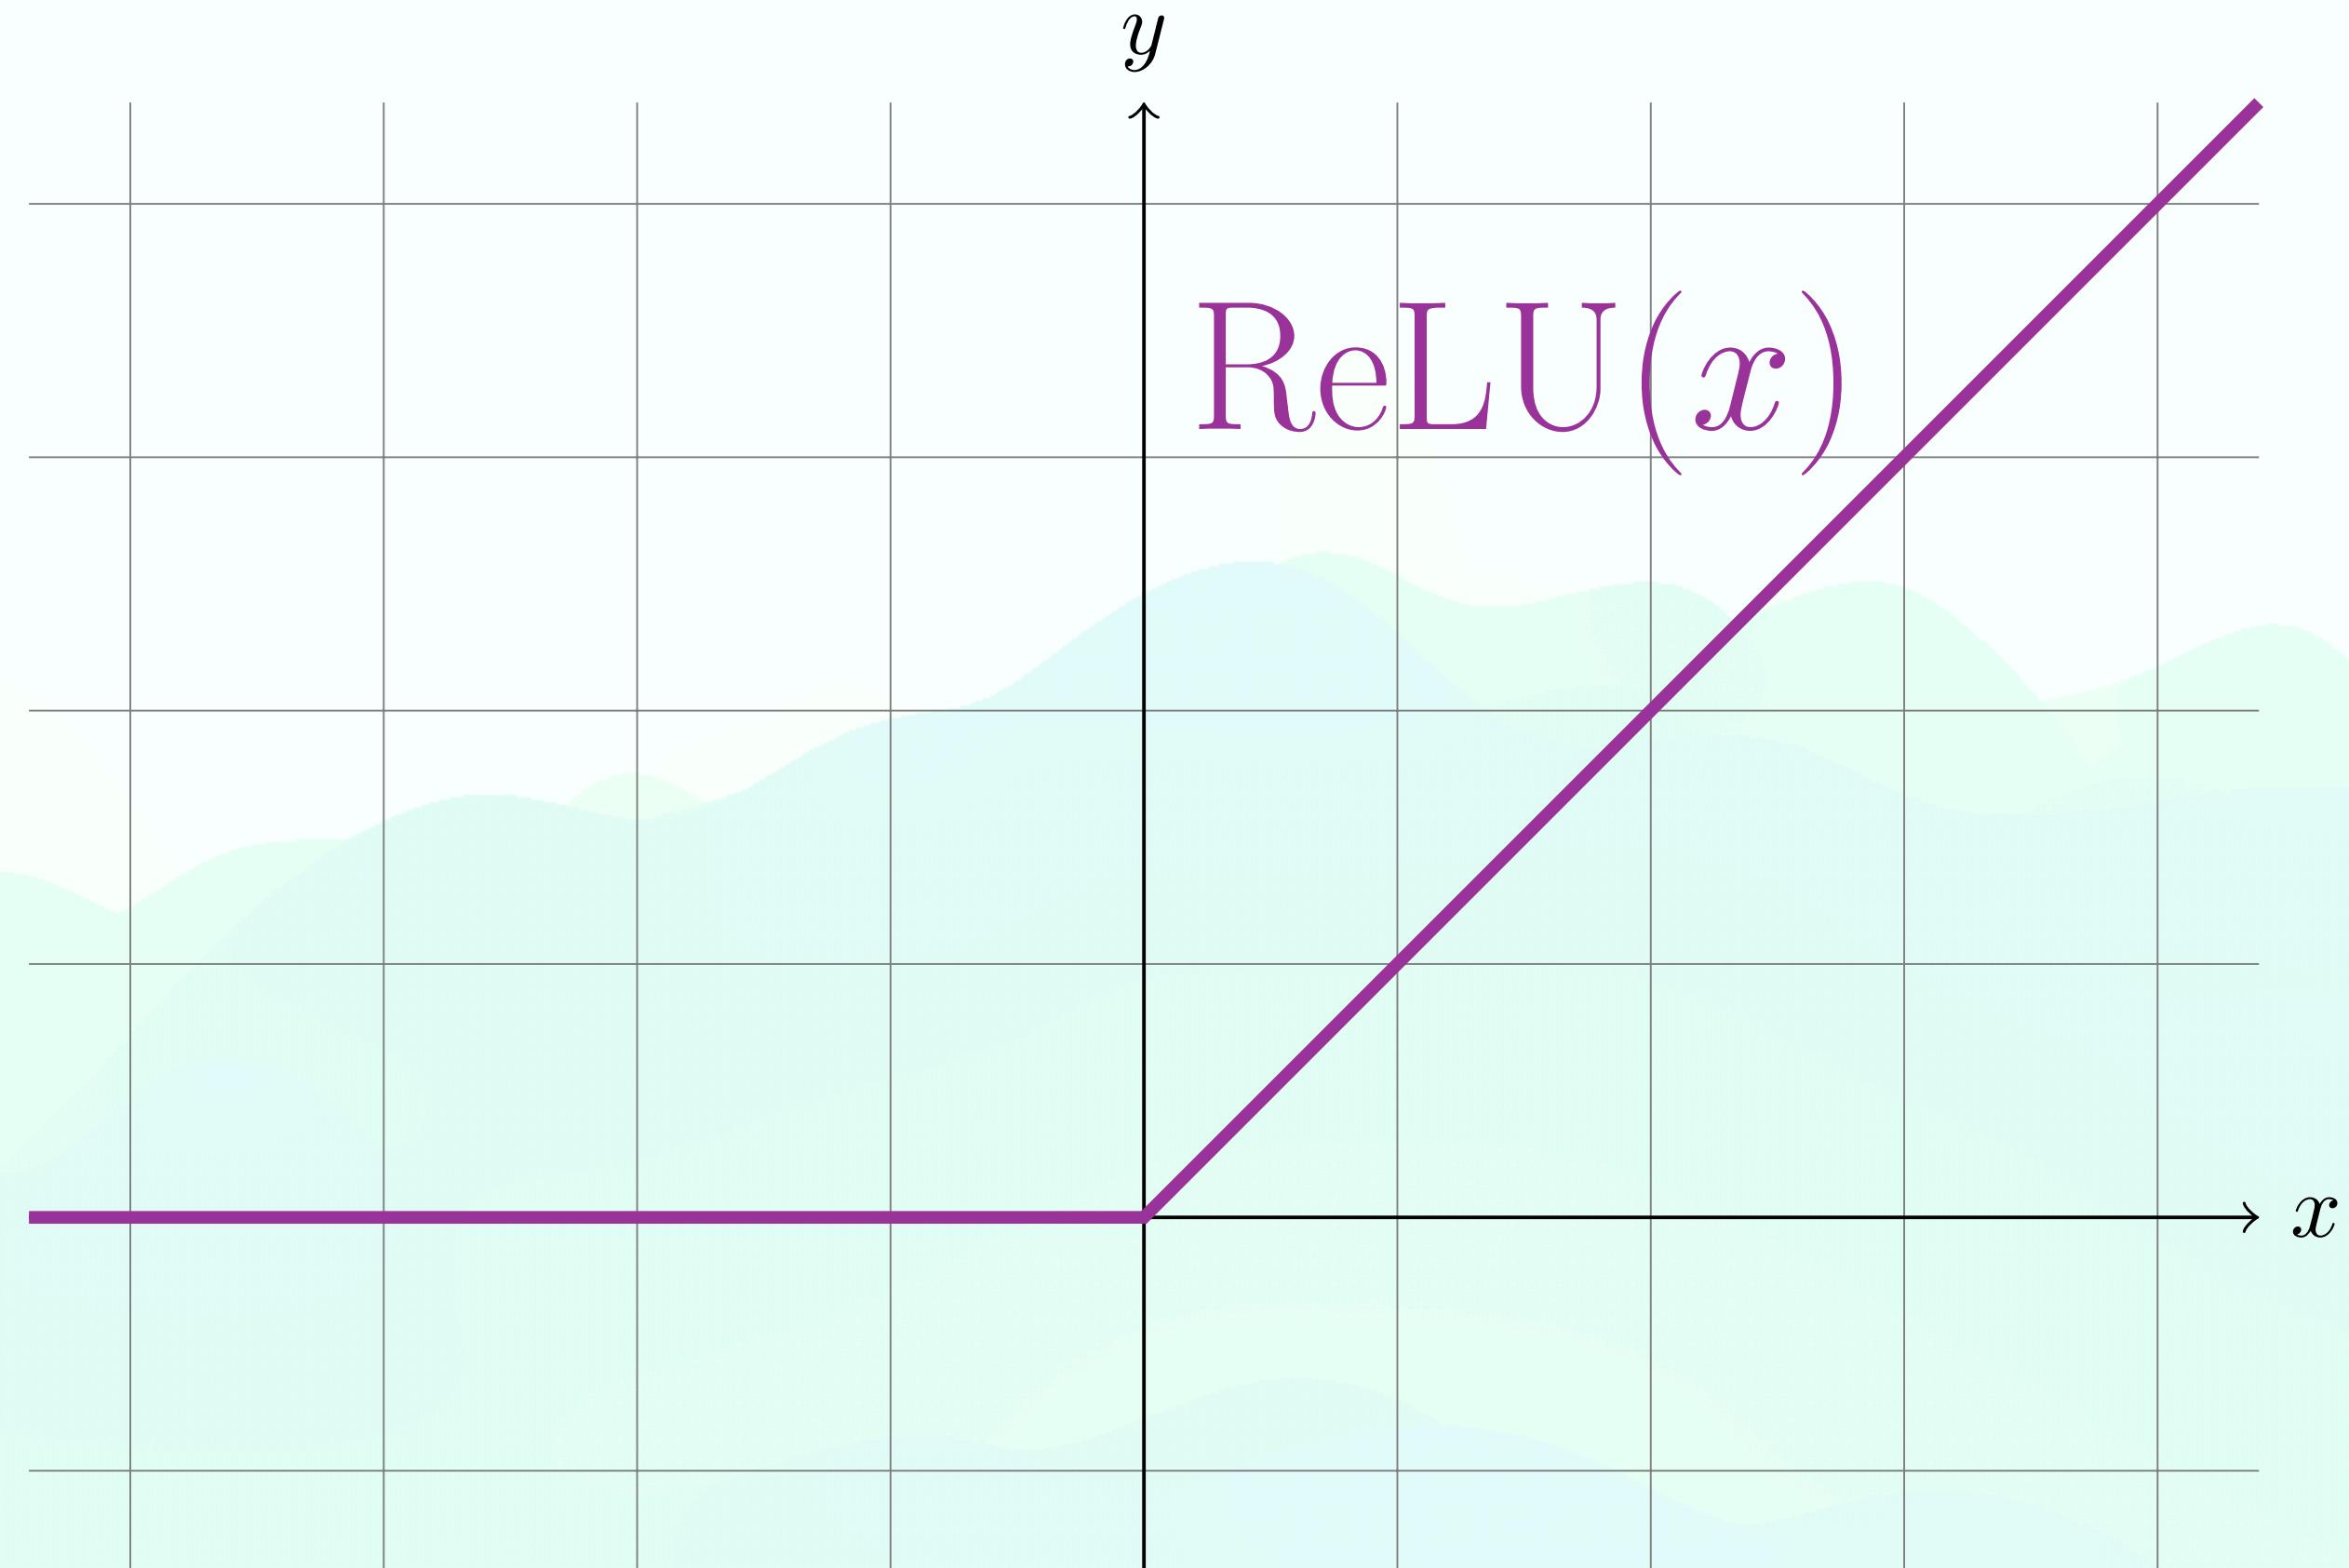


# Aktivierungsfunktionen

- ReLU (Rectified Linear Unit)

$$\text{ReLU}(x) = \max(0, x) = \begin{cases} x & \text{wenn } x > 0 \\ 0 & \text{sonst} \end{cases}$$

- Produziert Werte im Bereich  $y \geq 0$



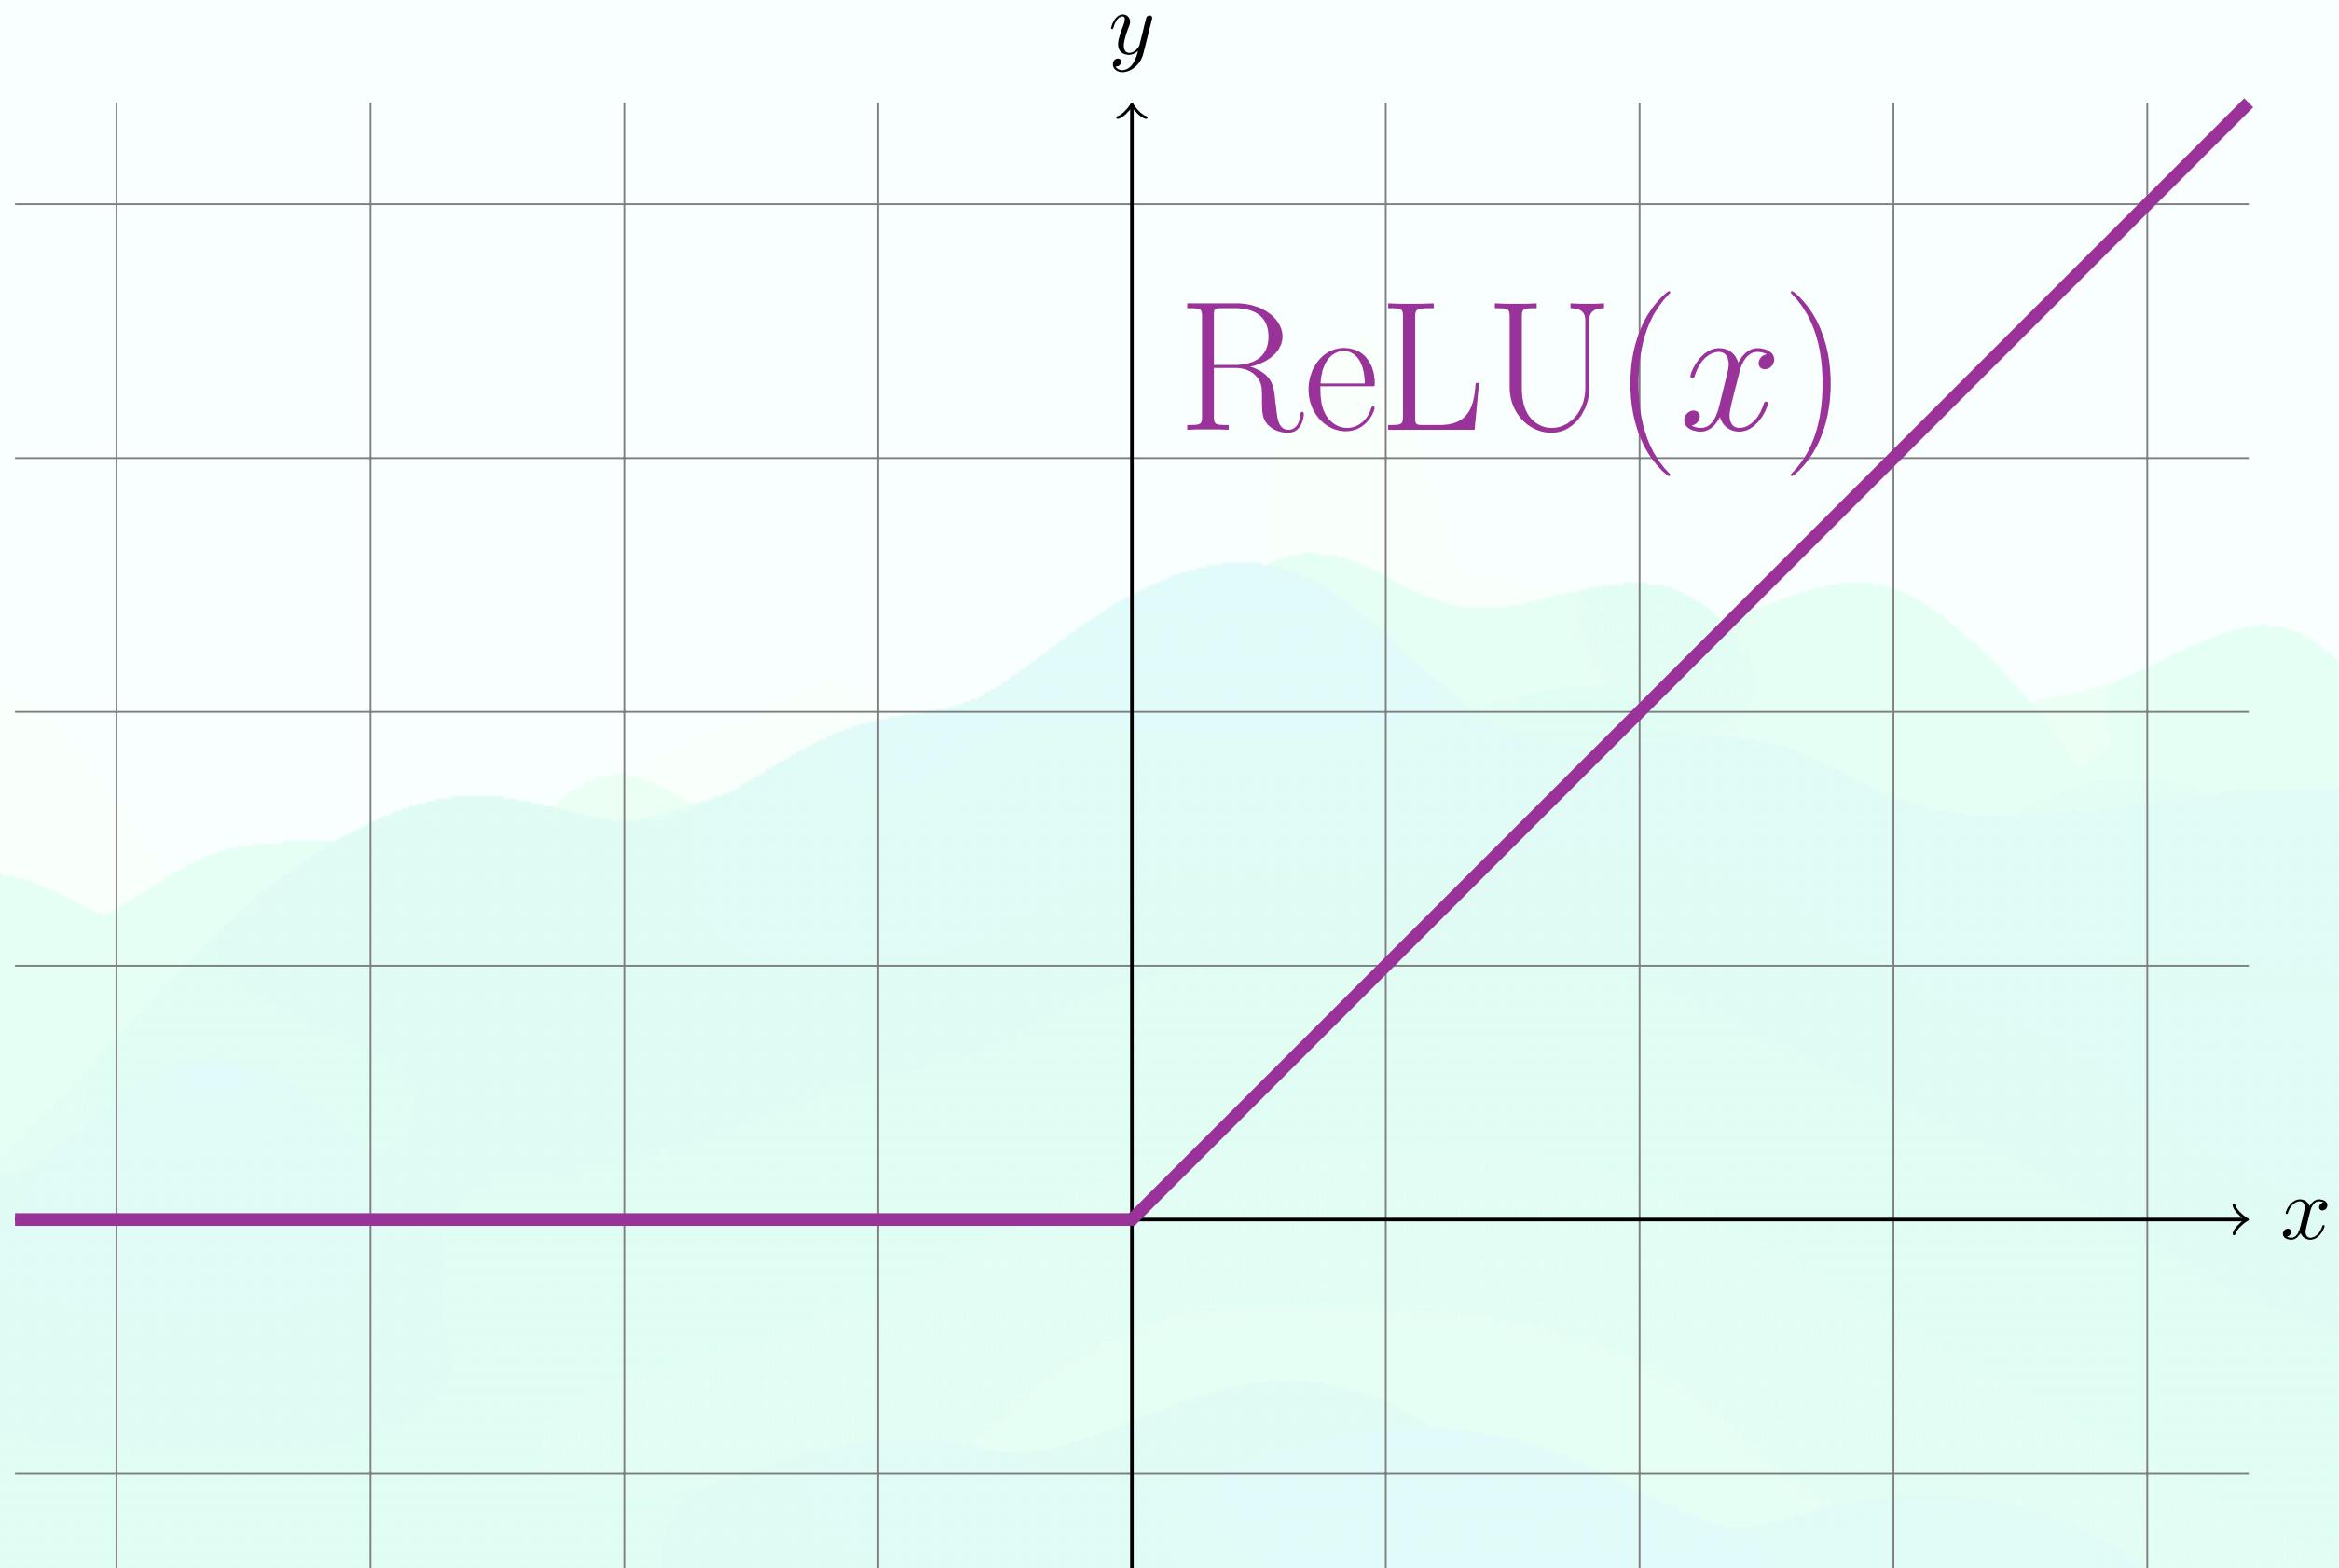
# Aktivierungsfunktionen

- ReLU (**Rectified Linear Unit**)

$$\text{ReLU}(x) = \max(0, x) = \begin{cases} x & \text{wenn } x > 0 \\ 0 & \text{sonst} \end{cases}$$

- Produziert Werte im Bereich  $y \geq 0$
- Schnelles Lernen durch konstanten Gradienten (kein **Vanishing Gradient**)
- Effiziente Backpropagation durch triviale Ableitung:

$$\text{ReLU}'(x) = \begin{cases} 1 & \text{wenn } x > 0 \\ 0 & \text{sonst} \end{cases}$$



# Aktivierungsfunktionen anlegen

```
import numpy

def relu(z):
    return numpy.maximum(z, 0)

def sigmoid(z):
    return 1 / (1 + numpy.exp(-z))

def identity(z):
    return z
```

# Aktivierungsfunktionen anlegen



```
import numpy
```

```
def relu(z):  
    return numpy.maximum(z, 0)
```

```
def sigmoid(z):  
    return 1 / (1 + numpy.exp(-z))
```

```
def identity(z):  
    return z
```

Wir importieren das über PIP installierte Package **numpy**, das uns viele mathematische Hilfsfunktionen anbietet. Erst durch den **import** können wir es auch in unserem Code benutzen.

# Aktivierungsfunktionen anlegen

$$\text{ReLU}(z) = \max(0, z) = \begin{cases} z & \text{wenn } z > 0 \\ 0 & \text{sonst} \end{cases}$$



```
import numpy

def relu(z):
    return numpy.maximum(z, 0)

def sigmoid(z):
    return 1 / (1 + numpy.exp(-z))

def identity(z):
    return z
```

Implementierung der ReLU-Funktion. Sie bekommt den **Parameter** `z` übergeben und gibt mit dem Schlüsselwort `return` das Maximum aus `z` und 0 zurück.

# Aktivierungsfunktionen anlegen

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

```
import numpy

def relu(z):
    return numpy.maximum(z, 0)

def sigmoid(z):
    return 1 / (1 + numpy.exp(-z))

def identity(z):
    return z
```

Auch die Funktion `sigmoid` erwartet einen Parameter `z`. Mithilfe der Funktion `numpy.exp` berechnen wir die Potenz  $e^{-z}$  und geben das Ergebnis mit `return` zurück.

# Aktivierungsfunktionen anlegen

$$f(z) = z$$

```
import numpy

def relu(z):
    return numpy.maximum(z, 0)

def sigmoid(z):
    return 1 / (1 + numpy.exp(-z))

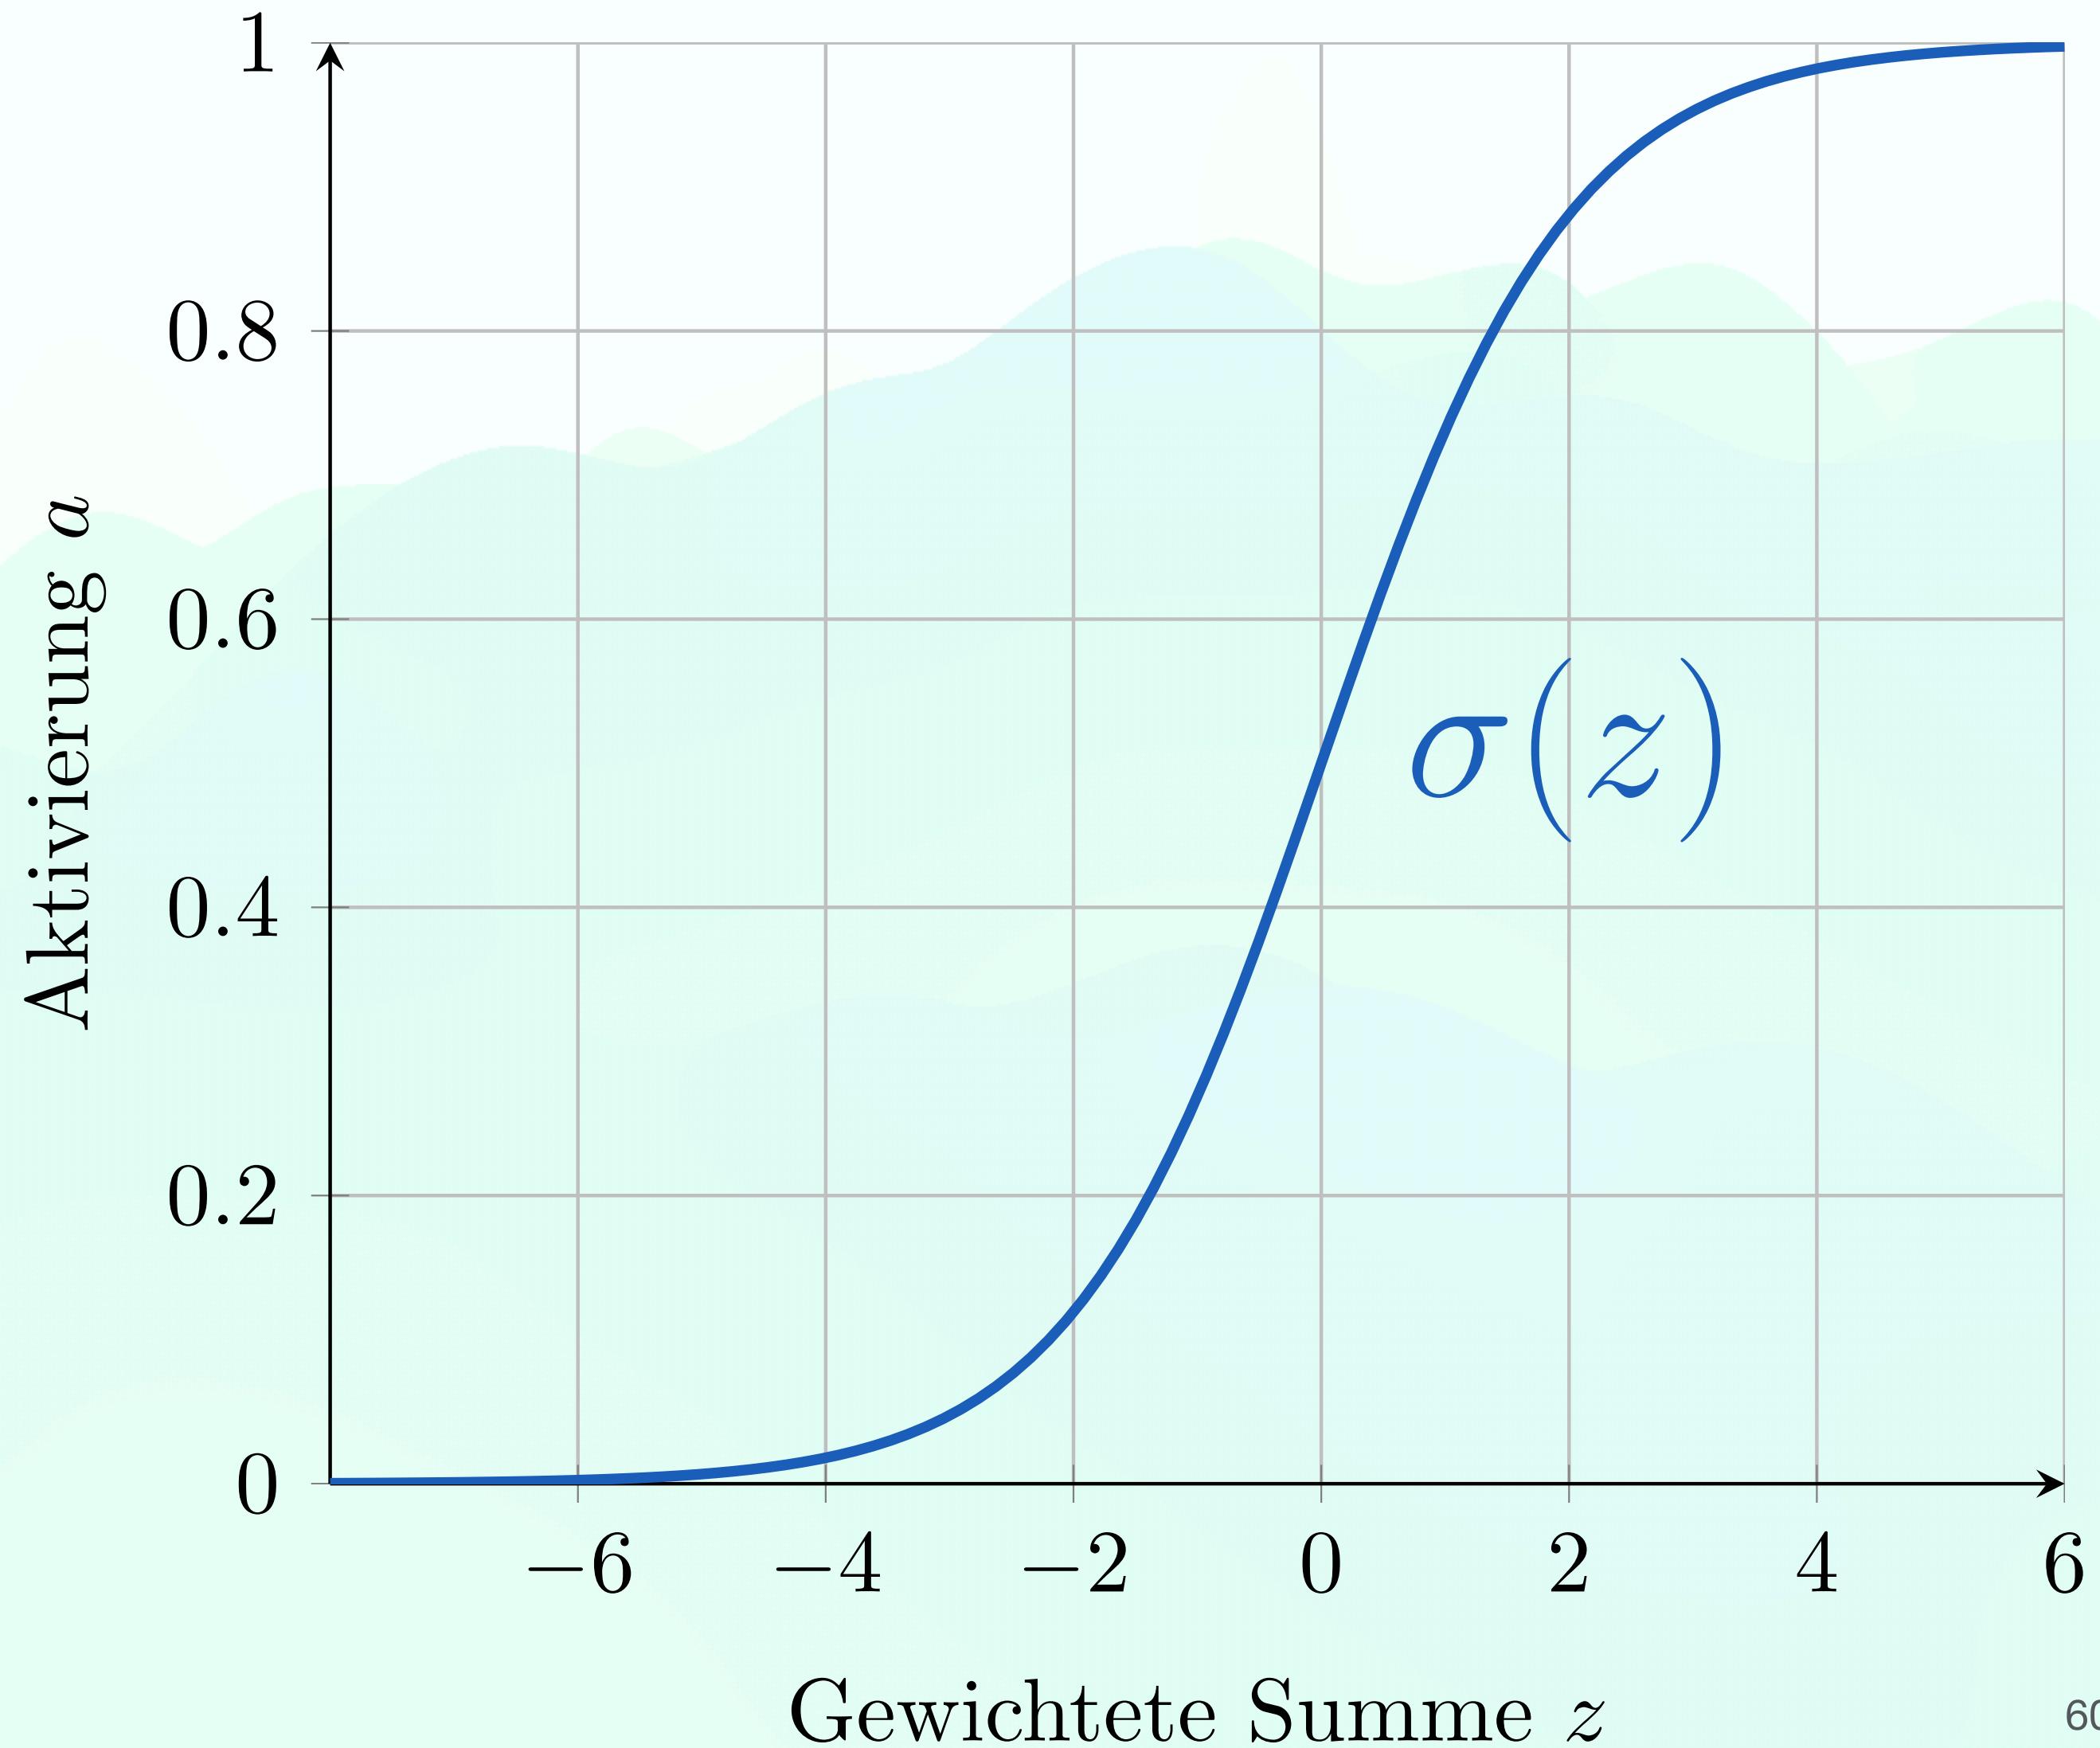
def identity(z):
    return z
```

Wir implementieren auch noch die Identitätsfunktion, die den übergebenen Wert einfach unverändert zurückgibt. Auch diese Aktivierungsfunktion kann für Testzwecke interessant sein.

# Bias

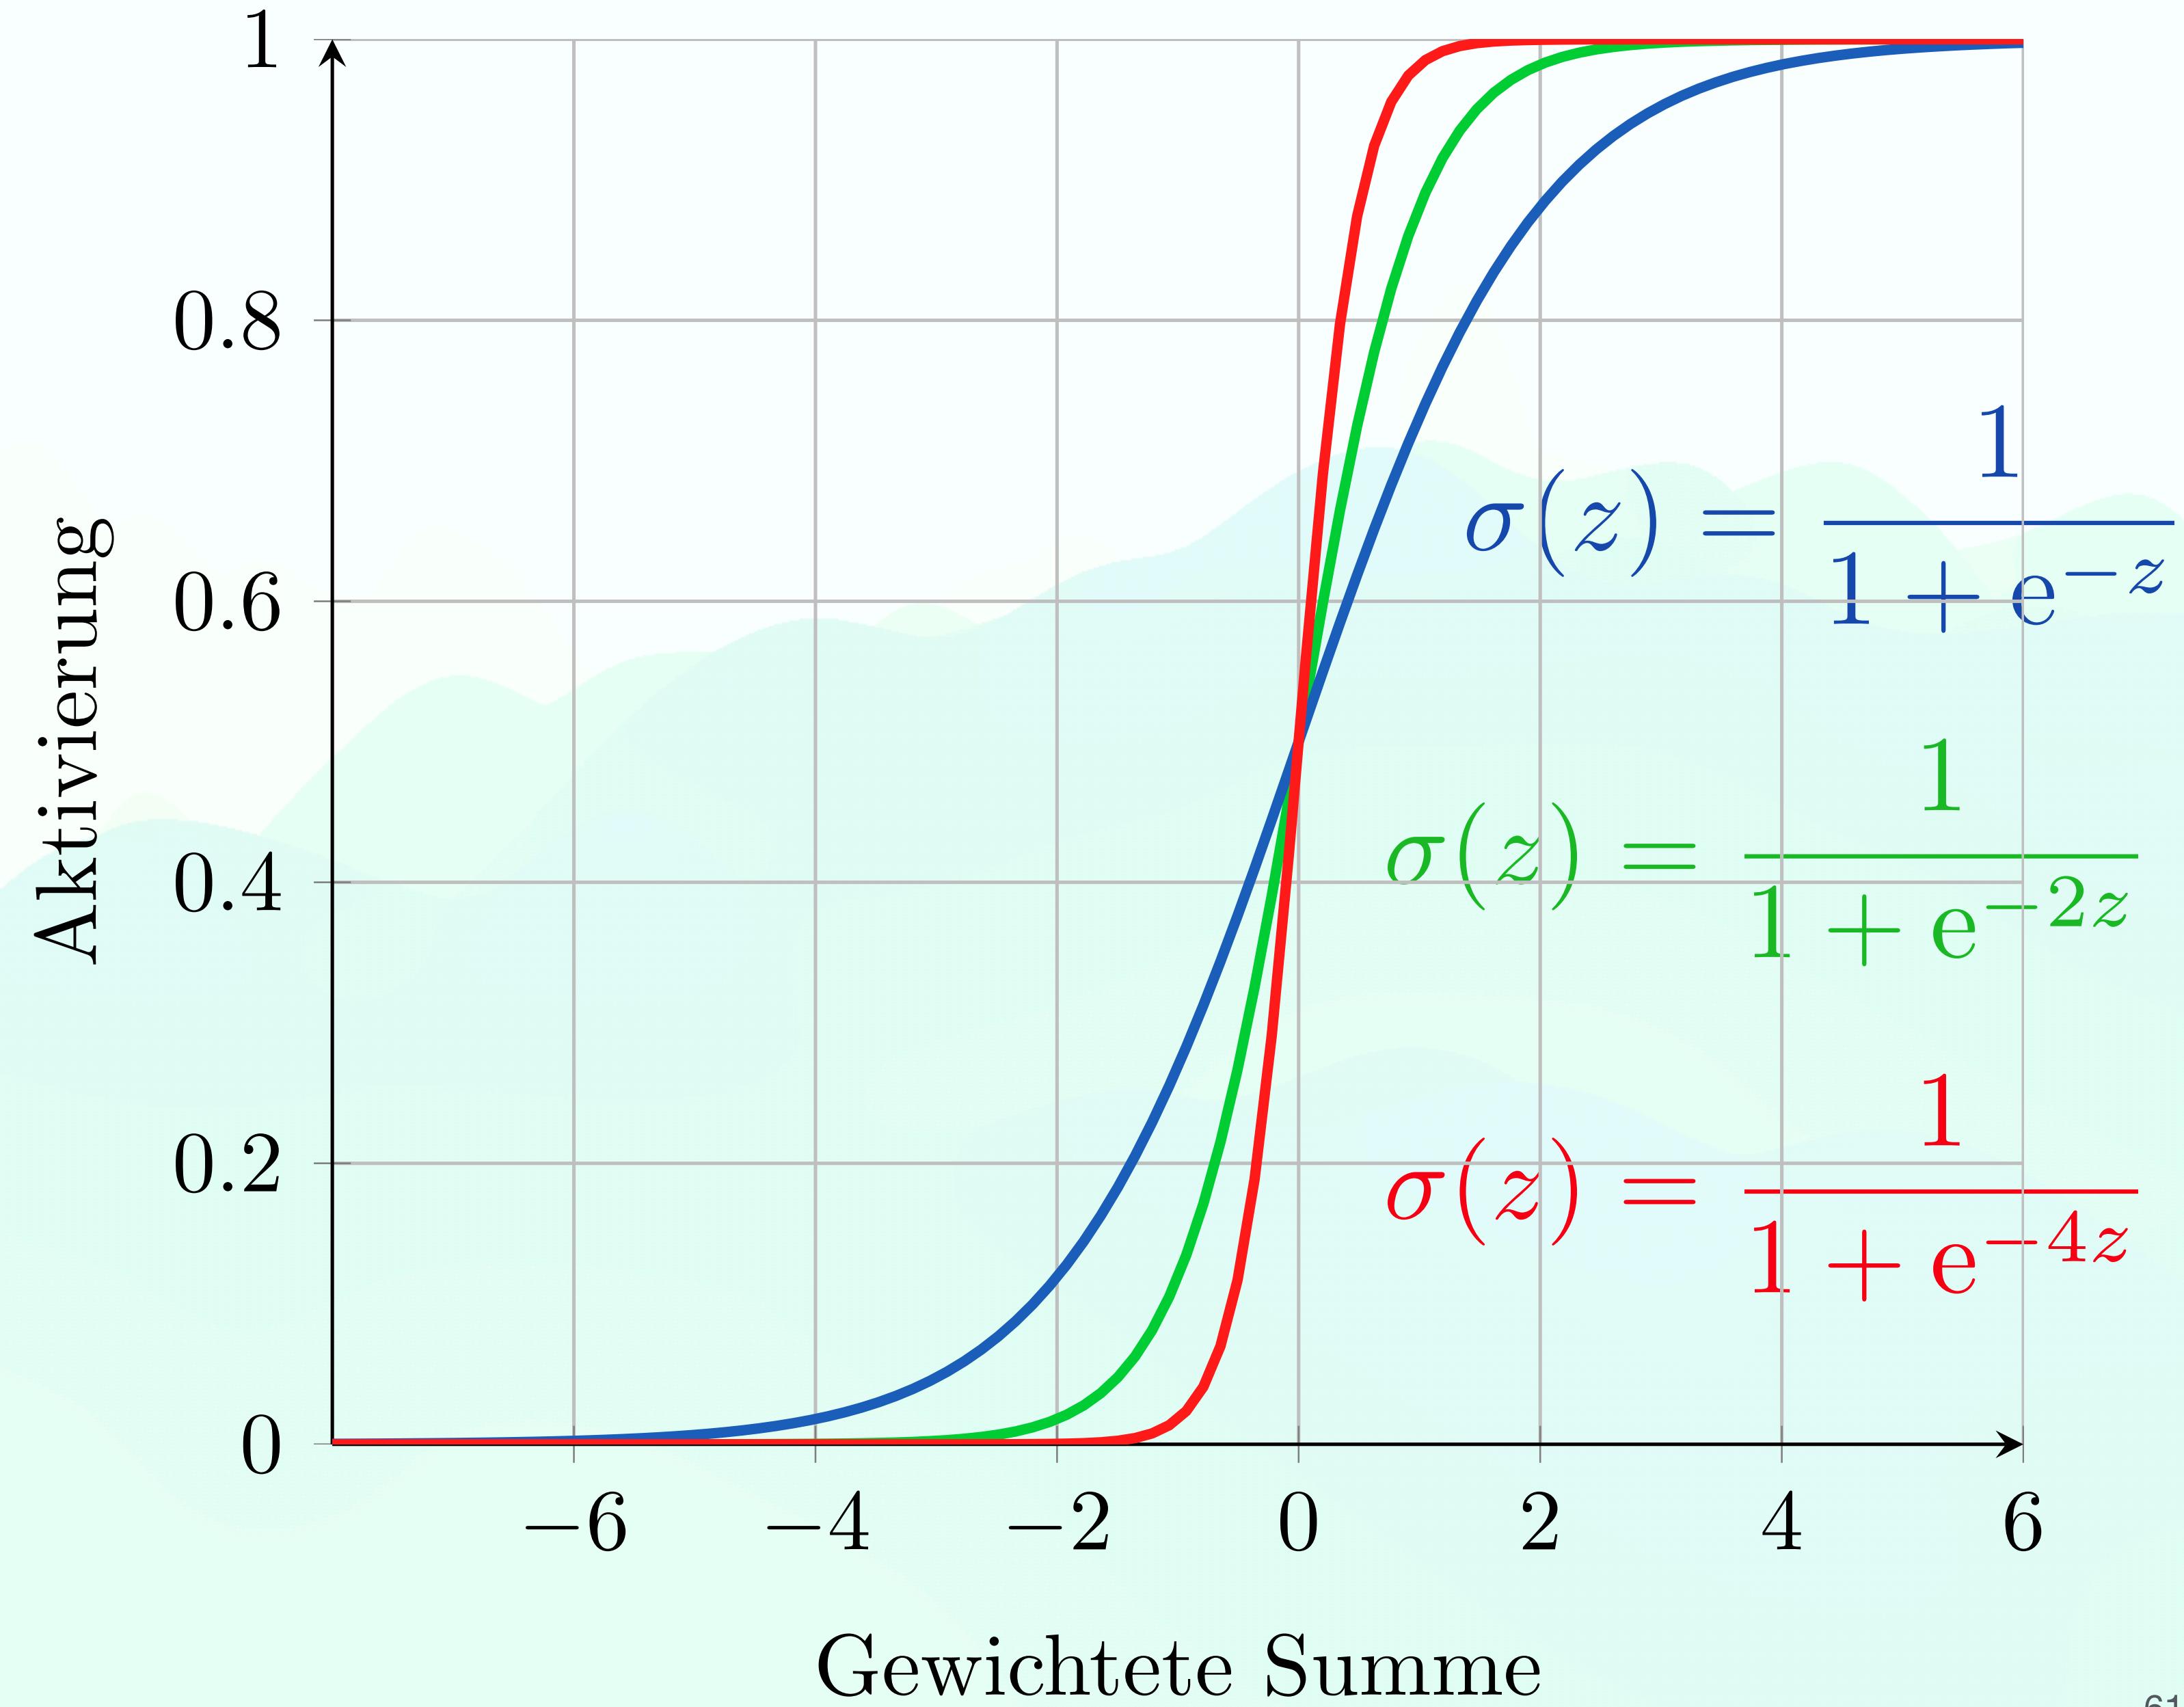
- Nur um  $z = 0$  herum verändert sich die Aktivierung signifikant
- Analog bei ReLU: Erst ab einer gewichteten Summe von  $z > 0$  beginnt die Aktivierung
- In vielen Anwendungsfällen soll die Aktivierung aber früher oder später beginnen
- Wir brauchen eine Möglichkeit, die Kurve der Aktivierungsfunktion zu **verschieben**

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$



# Bias

- Multiplikation des Inputs mit einem Faktor (z. B. einem Gewicht  $w$ ) macht die Kurve nur **steiler** oder **flacher**

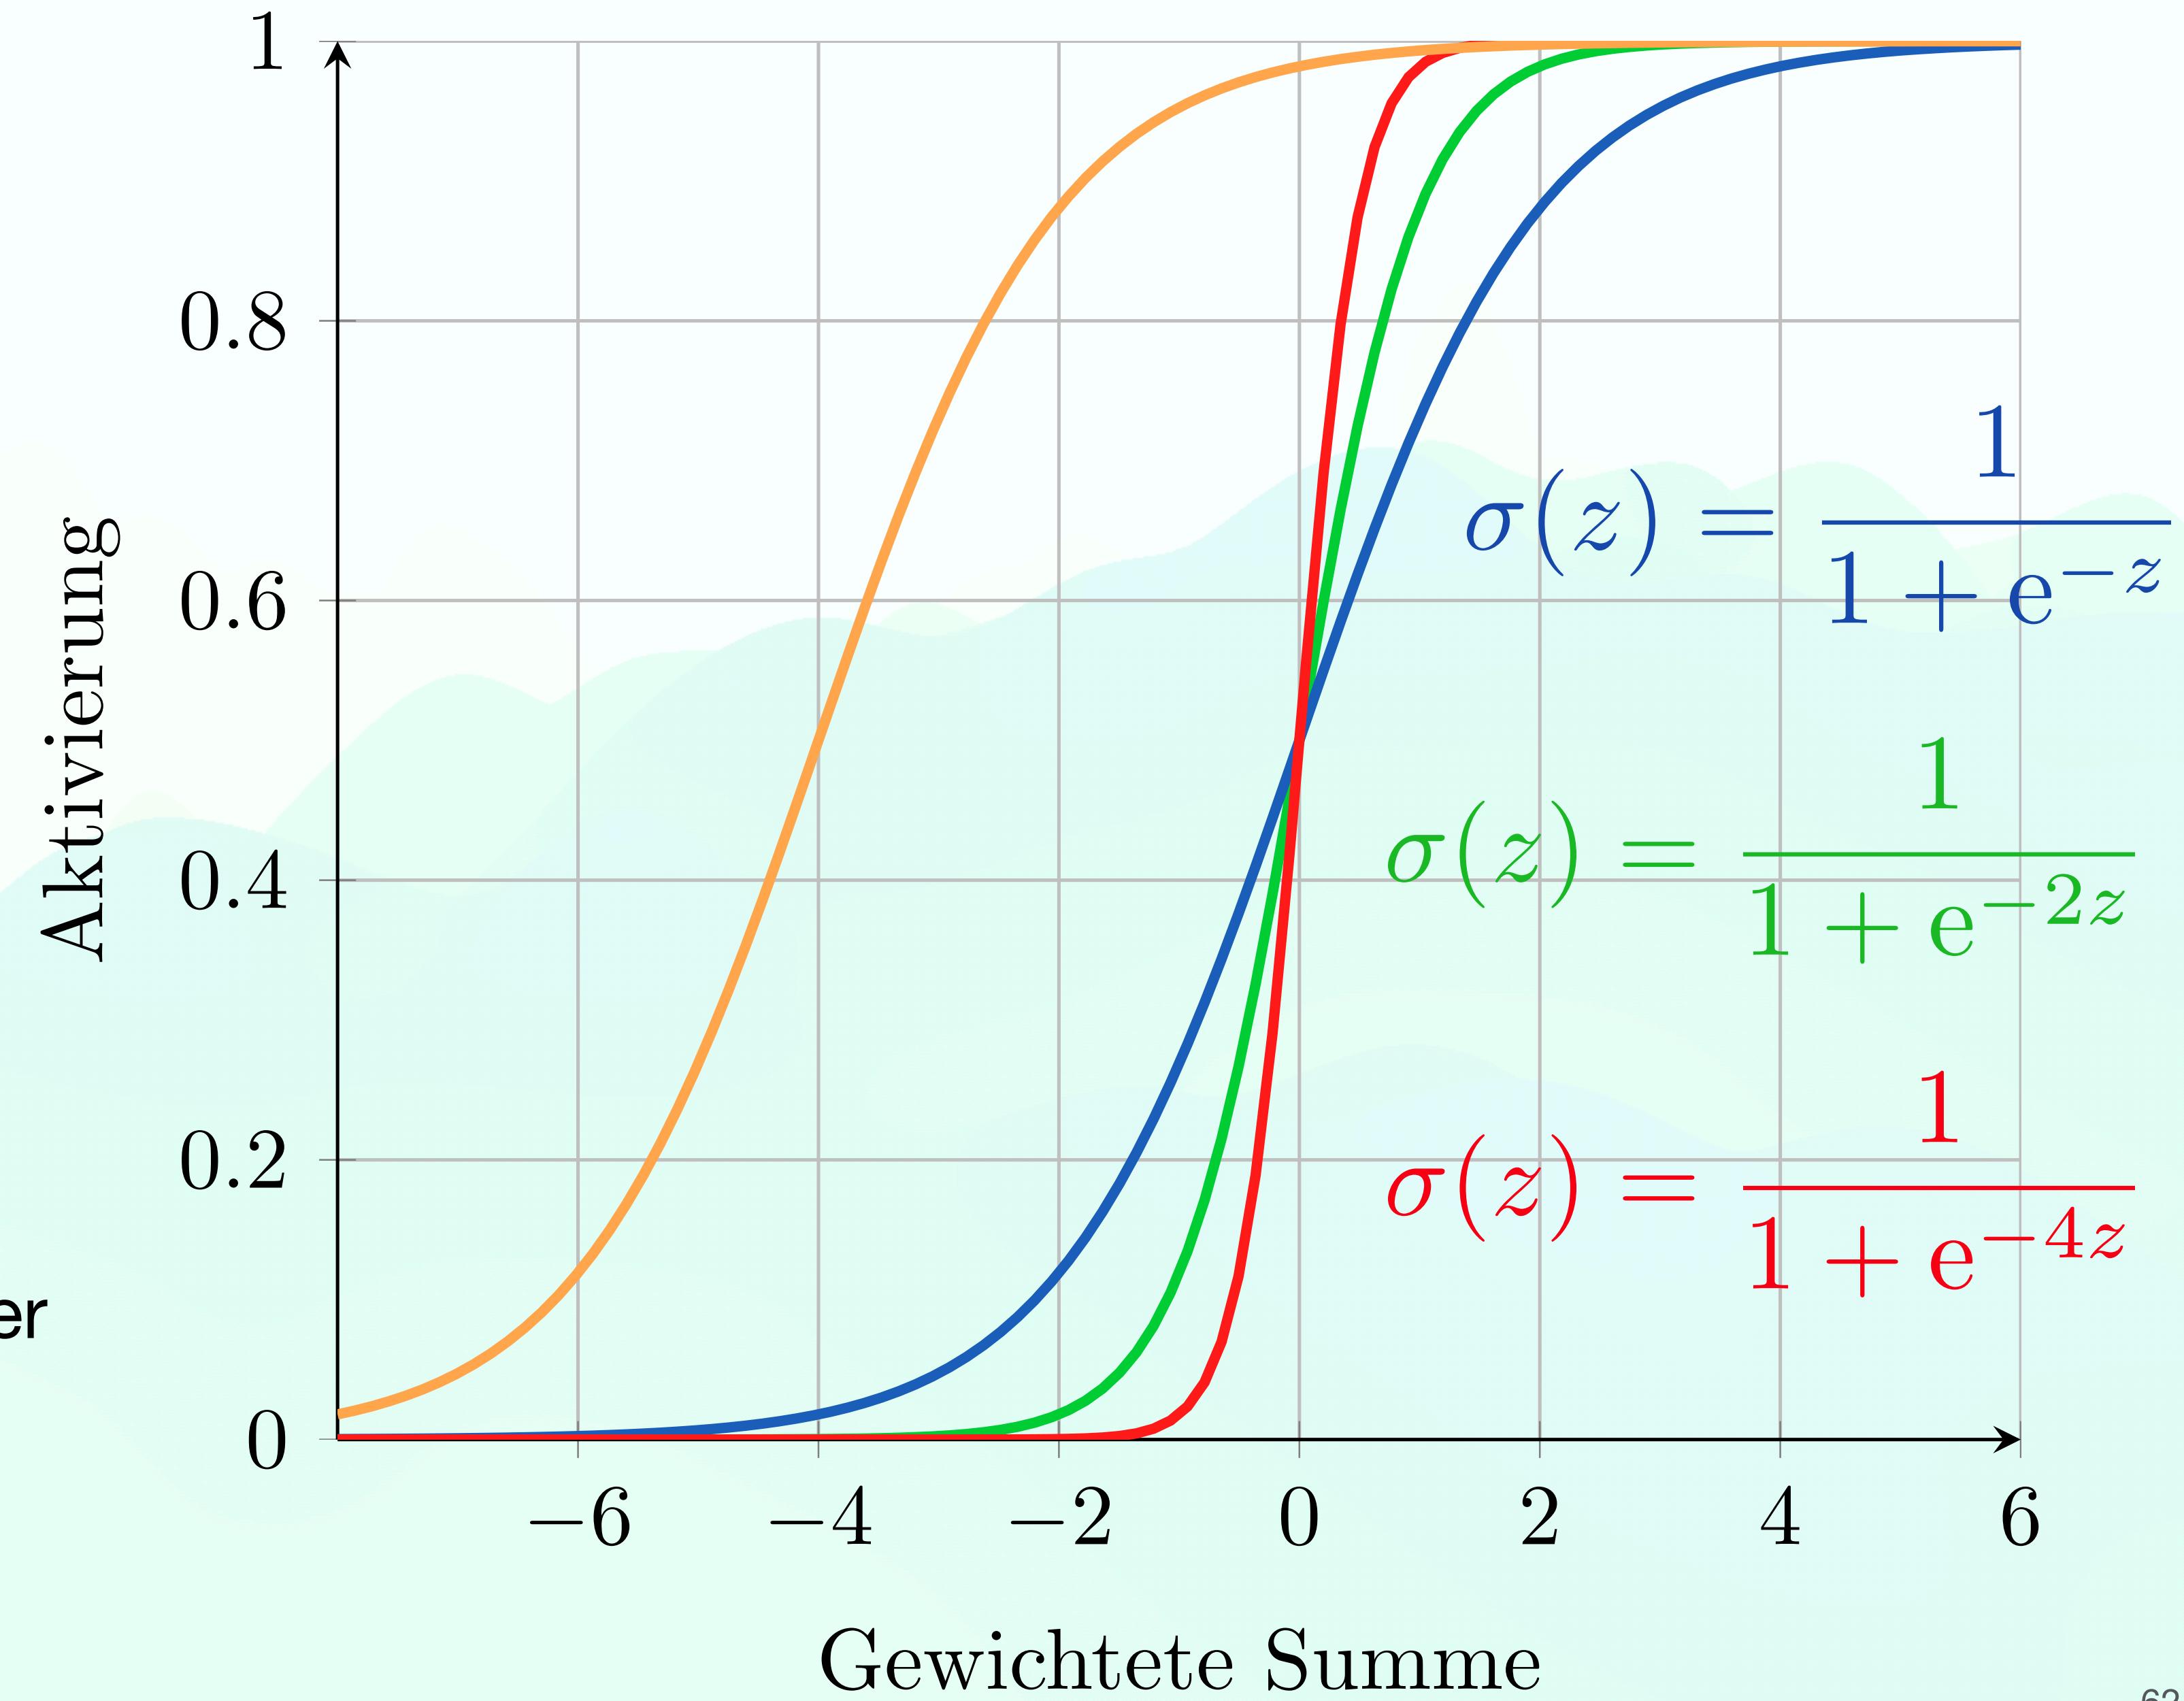


# Bias

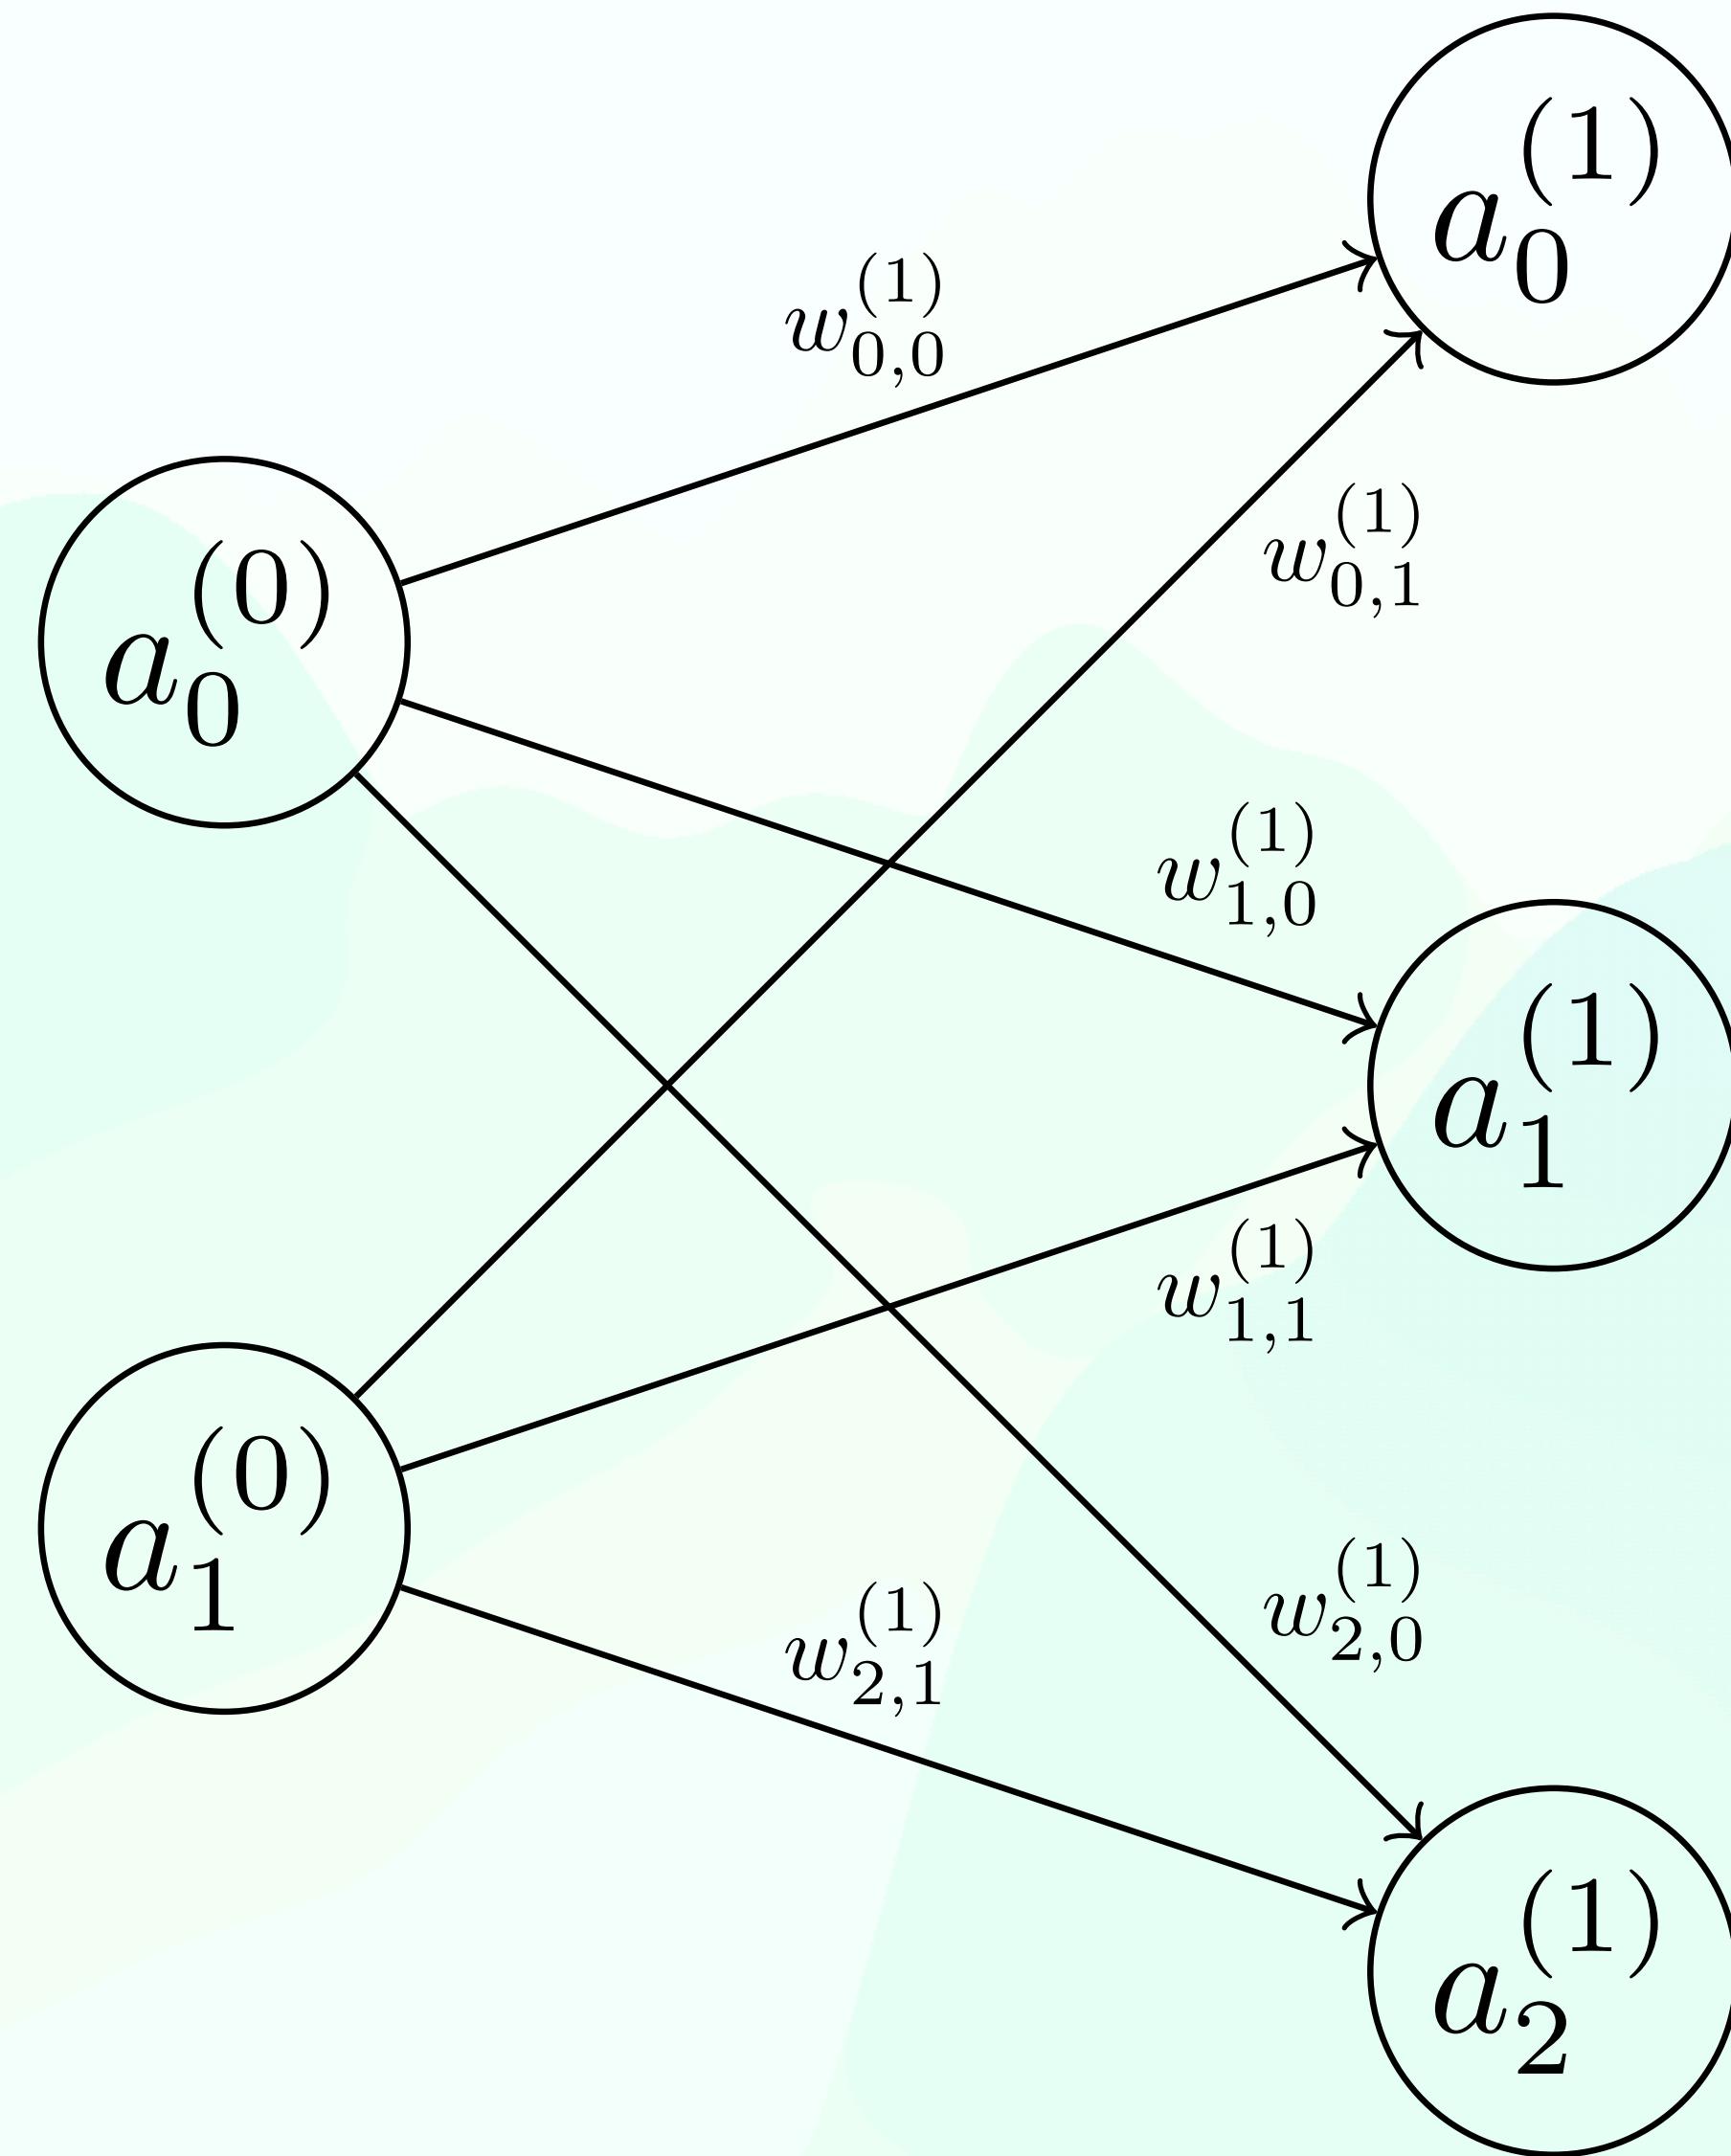
- Multiplikation des Inputs mit einem Faktor (z. B. einem Gewicht  $w$ ) macht die Kurve nur **steiler** oder **flacher**

$$\sigma(z) = \frac{1}{1 + e^{-z-4}}$$

Nur Addition (oder Subtraktion) der gewichteten Summe mit einer Konstante kann die Kurve nach rechts (oder links) **verschieben**

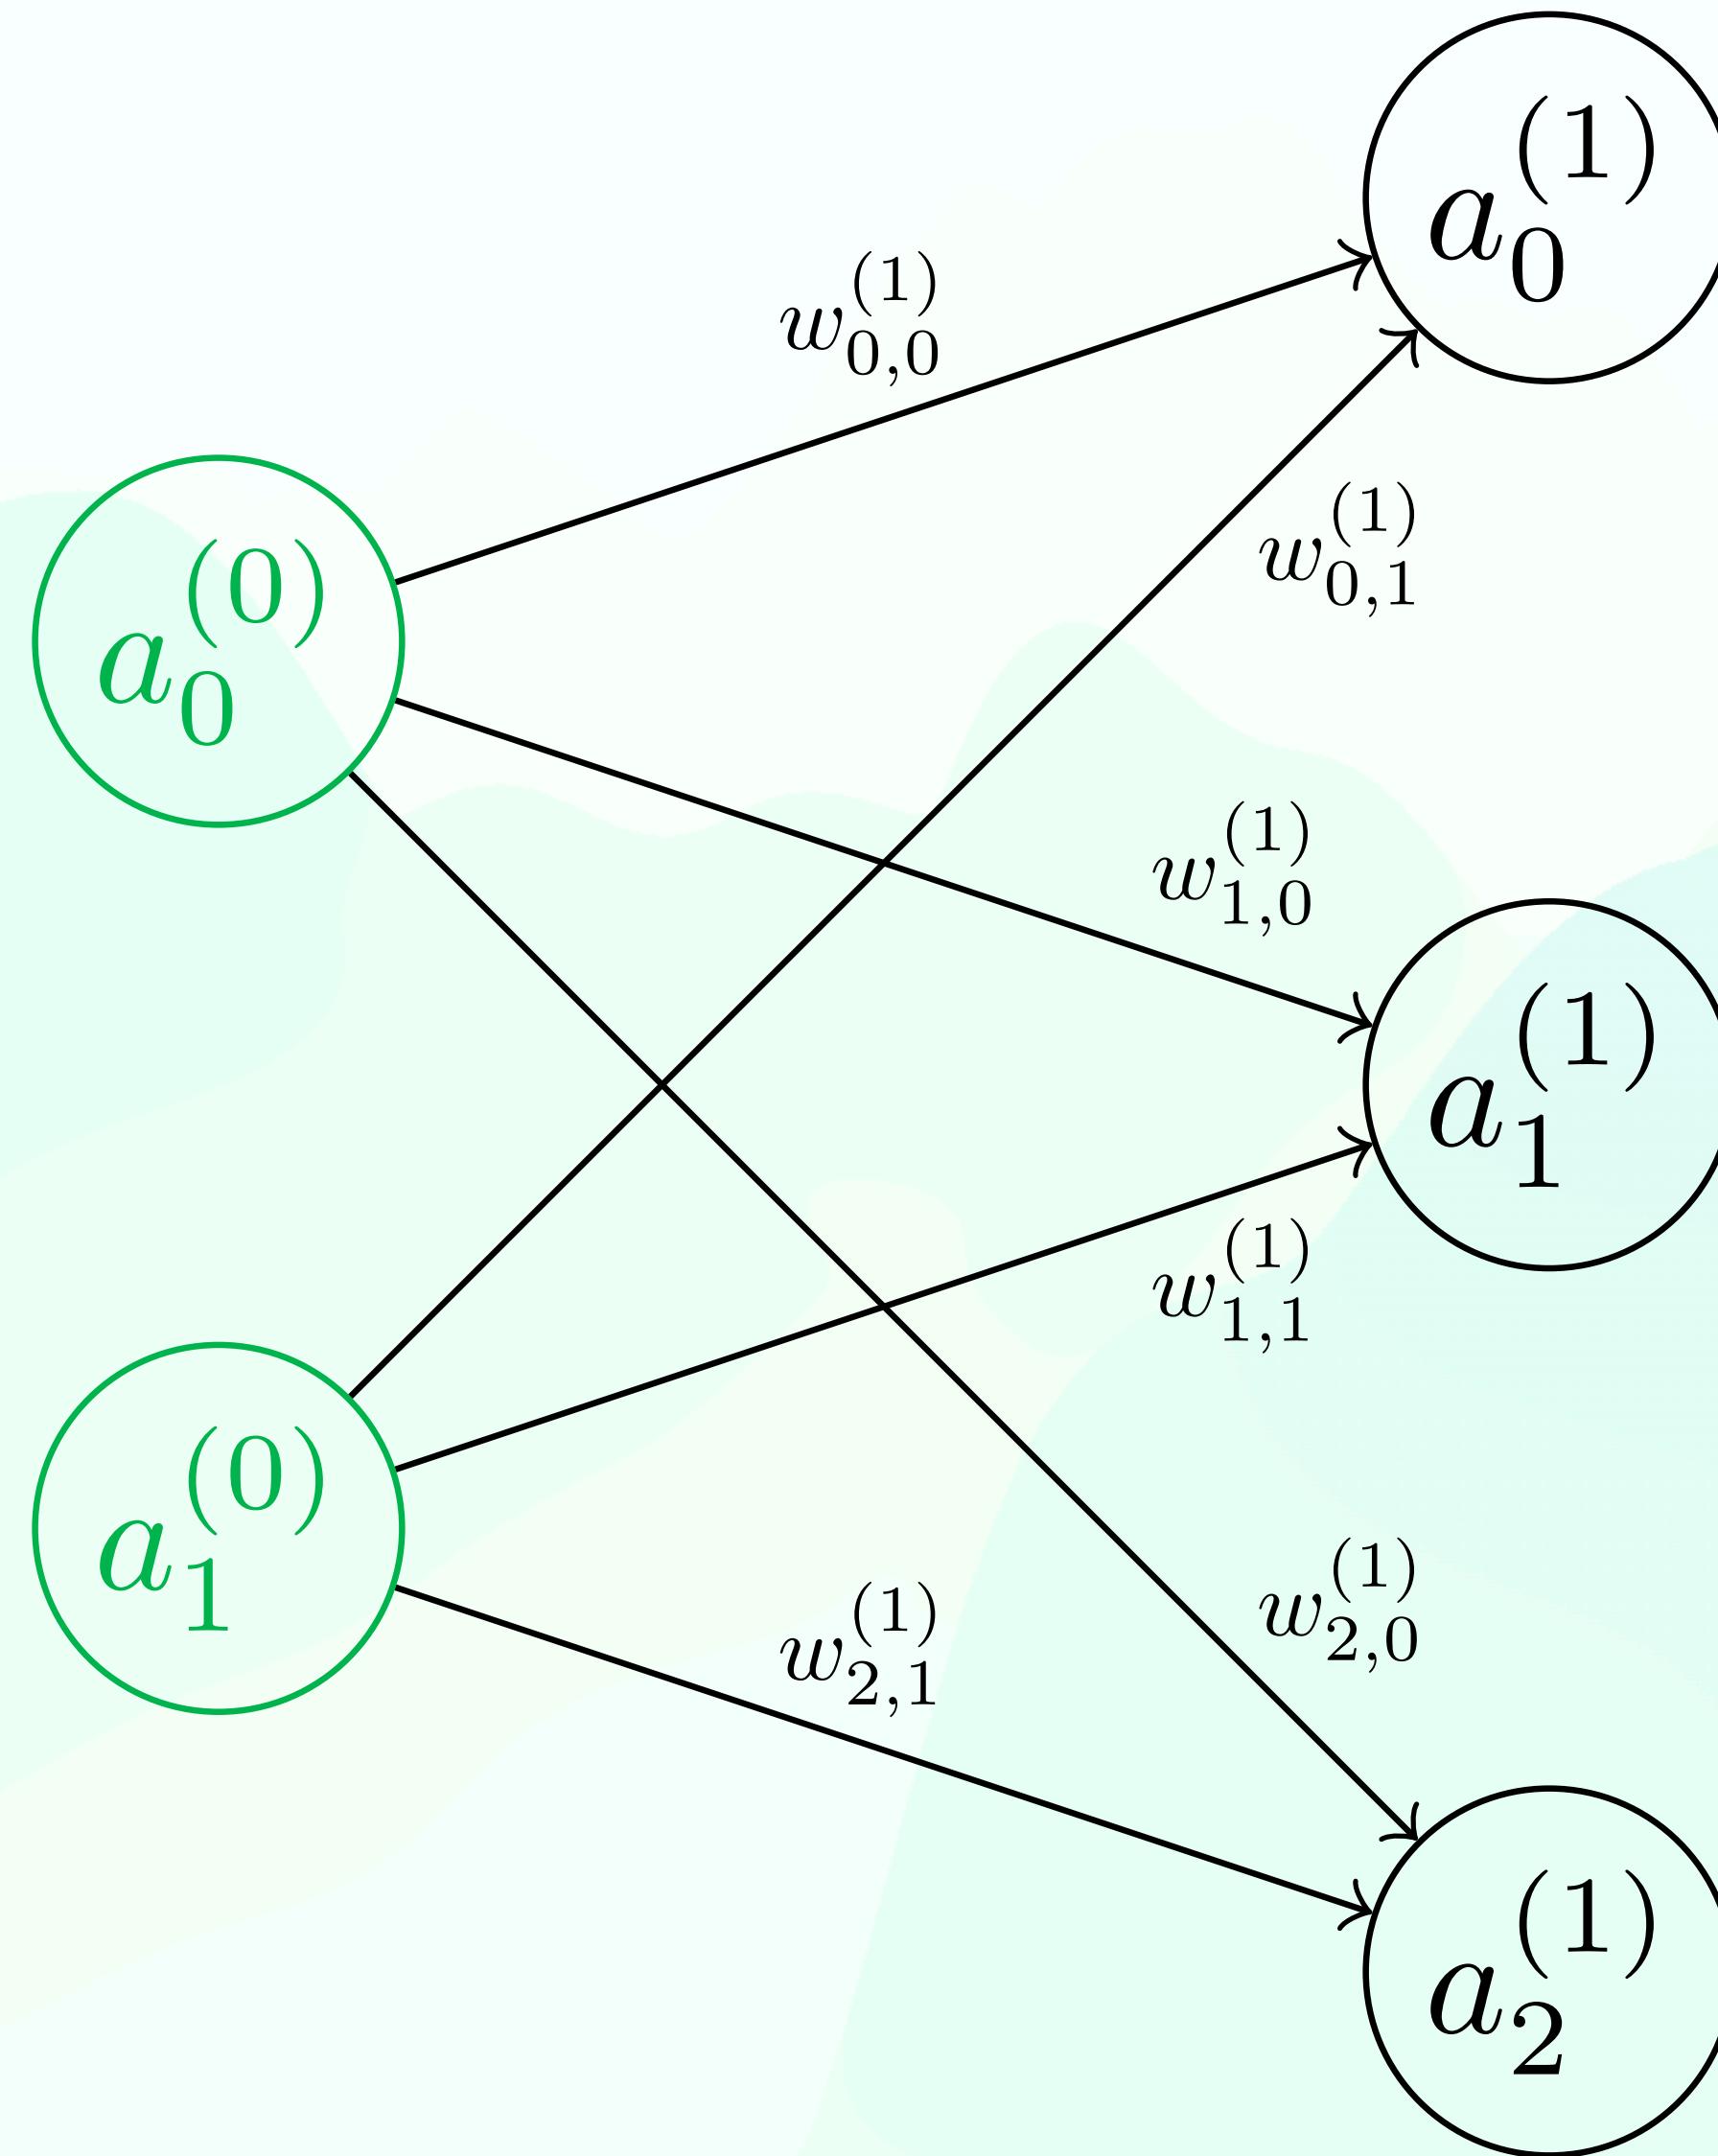


# Notation



Für Notation und Implementierung in Python hilfreich:  
Vektor- und Matrixschreibweise

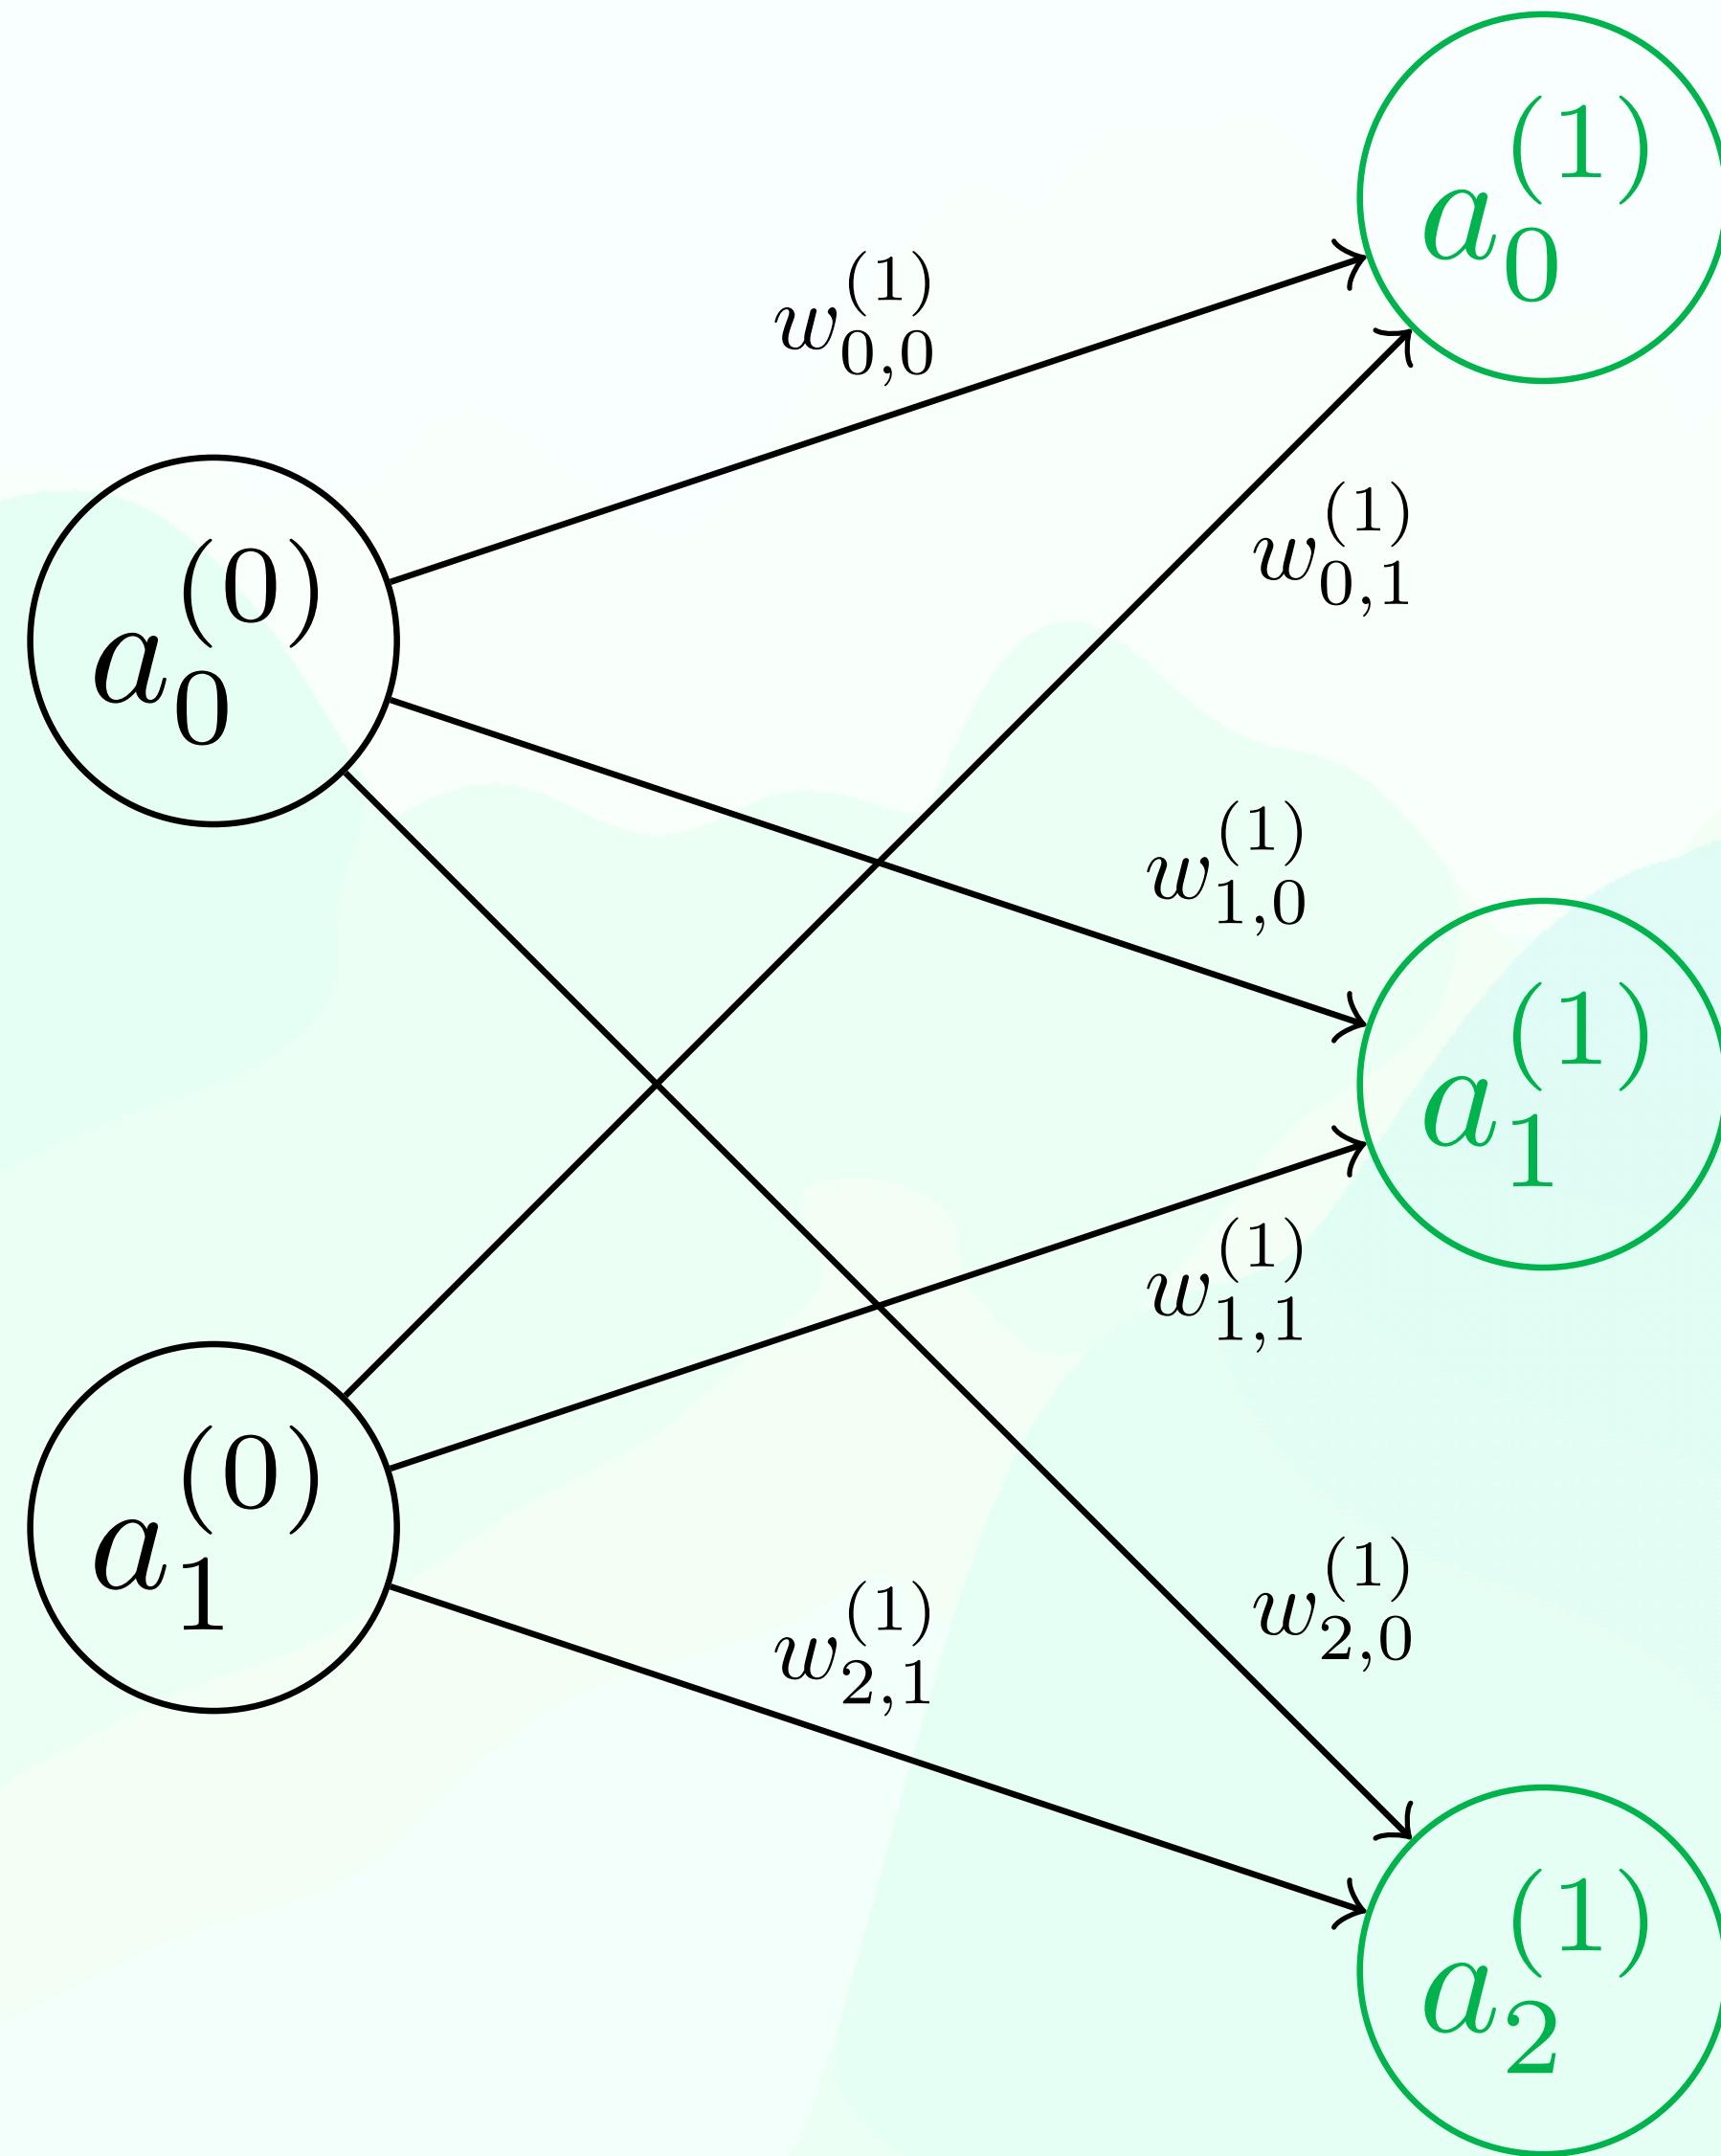
# Notation – Aktivierungsvektoren



Für Notation und Implementierung in Python hilfreich:  
Vektor- und Matrixschreibweise

$$A^{(0)} = \begin{pmatrix} a_0^{(0)} \\ a_1^{(0)} \end{pmatrix}$$

# Notation – Aktivierungsvektoren



Für Notation und Implementierung in Python hilfreich:  
Vektor- und Matrixschreibweise

$$A^{(1)} = \begin{pmatrix} a_0^{(1)} \\ a_1^{(1)} \\ a_2^{(1)} \end{pmatrix}$$

# Neuronenlayer initialisieren



```
def __init_layers(self):
    self.activations = []
    self.weighted_sums = []

    for l in range(len(self.structure)):
        is_output_layer = l == len(self.structure) - 1
        n_activations = self.structure[l] if is_output_layer else self.structure[l] + 1
        n_weighted_sums = self.structure[l]
        layer_weighted_sums = numpy.zeros((n_weighted_sums, 1))
        layer_activations = numpy.ones((n_activations, 1))

        self.weighted_sums.append(layer_weighted_sums)
        self.activations.append(layer_activations)
```

# Neuronenlayer initialisieren



```
def __init_layers(self):
    self.activations = []
    self.weighted_sums = []

    for l in range(len(self.structure)):
        is_output_layer = l == len(self.structure) - 1
        n_activations = self.structure[l] if is_output_layer else self.structure[l] + 1
        n_weighted_sums = self.structure[l]
        layer_weighted_sums = numpy.zeros((n_weighted_sums, 1))
        layer_activations = numpy.ones((n_activations, 1))

        self.weighted_sums.append(layer_weighted_sums)
        self.activations.append(layer_activations)
```

Wir erzeugen jeweils Listen für die Aktivierungen und für die gewichteten Summen der einzelnen Layer. Durch das `self.`-Präfix legen wir sie als **Objekteigenschaften** und nicht nur als lokale **Variable** der **Methode** an.

# Neuronenlayer initialisieren



```
def __init_layers(self):
    self.activations = []
    self.weighted_sums = []

    for l in range(len(self.structure)):
        is_output_layer = l == len(self.structure) - 1
        n_activations = self.structure[l] if is_output_layer else self.structure[l] + 1
        n_weighted_sums = self.structure[l]
        layer_weighted_sums = numpy.zeros((n_weighted_sums, 1))
        layer_activations = numpy.ones((n_activations, 1))

        self.weighted_sums.append(layer_weighted_sums)
        self.activations.append(layer_activations)
```

Die **for-Schleife** führt den nachfolgenden Code wiederholt aus, und zwar so oft, wie es der Aufruf der `range`-Funktion angibt.

# Neuronenlayer initialisieren



```
def __init_layers(self):
    self.activations = []
    self.weighted_sums = []

    for l in range(len(self.structure)):
        is_output_layer = l == len(self.structure) - 1
        n_activations = self.structure[l] if is_output_layer else self.structure[l] + 1
        n_weighted_sums = self.structure[l]
        layer_weighted_sums = numpy.zeros((n_weighted_sums, 1))
        layer_activations = numpy.ones((n_activations, 1))

        self.weighted_sums.append(layer_weighted_sums)
        self.activations.append(layer_activations)
```

In diesem Fall richtet sich die Anzahl der Wiederholungen nach der Anzahl der Layer, die in der Eigenschaft `structure` vorgegeben ist.

`structure` ist eine **Liste**, und mit `len` erhalten wir ihre Länge (Anzahl der Elemente).

# Neuronenlayer initialisieren



```
def __init_layers(self):
    self.activations = []
    self.weighted_sums = []

    for l in range(len(self.structure)):
        is_output_layer = l == len(self.structure) - 1
        n_activations = self.structure[l] if is_output_layer else self.structure[l] + 1
        n_weighted_sums = self.structure[l]
        layer_weighted_sums = numpy.zeros((n_weighted_sums, 1))
        layer_activations = numpy.ones((n_activations, 1))

        self.weighted_sums.append(layer_weighted_sums)
        self.activations.append(layer_activations)
```

Die **Laufvariable** `l` fängt bei 0 an und zählt bei jedem Schleifendurchlauf um 1 hoch. Ihr Maximalwert ist die **Anzahl der Layer minus 1**, danach bricht die Schleife ab.

# Neuronenlayer initialisieren

```
● ● ●  
def __init_layers(self):  
    self.activations = []  
    self.weighted_sums = []  
  
    for l in range(len(self.structure)):  
        is_output_layer = l == len(self.structure) - 1  
        n_activations = self.structure[l] if is_output_layer else self.structure[l] + 1  
        n_weighted_sums = self.structure[l]  
        layer_weighted_sums = numpy.zeros((n_weighted_sums, 1))  
        layer_activations = numpy.ones((n_activations, 1))  
  
        self.weighted_sums.append(layer_weighted_sums)  
        self.activations.append(layer_activations)
```

Listen in Python haben **0-basierte Indizes**. Die Liste [17, 12, 23] hat an Index 0 den Wert 17 und an Index 2 den Wert 23. Das müssen wir bei jedem Zugriff bedenken.

# Neuronenlayer initialisieren



```
def __init_layers(self):
    self.activations = []
    self.weighted_sums = []

    for l in range(len(self.structure)):
        is_output_layer = l == len(self.structure) - 1
        n_activations = self.structure[l] if is_output_layer else self.structure[l] + 1
        n_weighted_sums = self.structure[l]
        layer_weighted_sums = numpy.zeros((n_weighted_sums, 1))
        layer_activations = numpy.ones((n_activations, 1))

        self.weighted_sums.append(layer_weighted_sums)
        self.activations.append(layer_activations)
```

Das Ziel unserer `for`-Schleife ist, die einzelnen Layer des Netzes mit der jeweils korrekten Anzahl an Neuronen anzulegen.

# Neuronenlayer initialisieren



```
def __init_layers(self):
    self.activations = []
    self.weighted_sums = []

    for l in range(len(self.structure)):
        is_output_layer = l == len(self.structure) - 1
        n_activations = self.structure[l] if is_output_layer else self.structure[l] + 1
        n_weighted_sums = self.structure[l]
        layer_weighted_sums = numpy.zeros((n_weighted_sums, 1))
        layer_activations = numpy.ones((n_activations, 1))

        self.weighted_sums.append(layer_weighted_sums)
        self.activations.append(layer_activations)
```

Zunächst ermitteln wir, ob `l` gerade den Index des Output-Layers hat, da dieser eine Sonderbehandlung benötigt. Da Listenindizes 0-basiert sind, wäre der letzte Index die **Länge minus 1**.

# Neuronenlayer initialisieren



```
def __init_layers(self):  
    self.activations = []  
    self.weighted_sums = []  
  
    for l in range(len(self.structure)):  
        is_output_layer = l == len(self.structure) - 1  
        n_activations = self.structure[l] if is_output_layer else self.structure[l] + 1  
        n_weighted_sums = self.structure[l]  
        layer_weighted_sums = numpy.zeros((n_weighted_sums, 1))  
        layer_activations = numpy.ones((n_activations, 1))  
  
        self.weighted_sums.append(layer_weighted_sums)  
        self.activations.append(layer_activations)
```

Das Ergebnis weisen wir der **Variable is\_output\_layer** zu. Sie wird den Wert **True** erhalten, wenn wir im Output-Layer sind, und den Wert **False**, wenn nicht.

# Neuronenlayer initialisieren



```
def __init_layers(self):
    self.activations = []
    self.weighted_sums = []

    for l in range(len(self.structure)):
        is_output_layer = l == len(self.structure) - 1
        n_activations = self.structure[l] if is_output_layer else self.structure[l] + 1
        n_weighted_sums = self.structure[l]
        layer_weighted_sums = numpy.zeros((n_weighted_sums, 1))
        layer_activations = numpy.ones((n_activations, 1))

        self.weighted_sums.append(layer_weighted_sums)
        self.activations.append(layer_activations)
```

Man beachte den Unterschied: Ein doppeltes Gleichheitszeichen `==` führt einen **booleschen Vergleich** zwischen zwei Werten durch, dessen Ergebnis `True` oder `False` ist. Das einfache Gleichheitszeichen `=` weist einer Variable einen Wert zu. Es wird immer zuerst der Ausdruck rechts vom `=` ausgewertet und danach zugewiesen.

# Neuronenlayer initialisieren



```
def __init_layers(self):
    self.activations = []
    self.weighted_sums = []

    for l in range(len(self.structure)):
        is_output_layer = l == len(self.structure) - 1
        n_activations = self.structure[l] if is_output_layer else self.structure[l] + 1
        n_weighted_sums = self.structure[l]
        layer_weighted_sums = numpy.zeros((n_weighted_sums, 1))
        layer_activations = numpy.ones((n_activations, 1))

        self.weighted_sums.append(layer_weighted_sums)
        self.activations.append(layer_activations)
```

Wir legen die Variable `n_activations` für die Anzahl der Neuronen des aktuellen Layers an und weisen ihr die Anzahl zu, die wir aus dem entsprechenden Index der Liste in `structure` auslesen. Der Zugriff auf Elemente der Liste erfolgt durch den Index in eckigen Klammern.

# Neuronenlayer initialisieren



```
def __init_layers(self):
    self.activations = []
    self.weighted_sums = []

    for l in range(len(self.structure)):
        is_output_layer = l == len(self.structure) - 1
        n_activations = self.structure[l] if is_output_layer else self.structure[l] + 1
        n_weighted_sums = self.structure[l]
        layer_weighted_sums = numpy.zeros((n_weighted_sums, 1))
        layer_activations = numpy.ones((n_activations, 1))

        self.weighted_sums.append(layer_weighted_sums)
        self.activations.append(layer_activations)
```

Dabei verwenden wir die ausgelesene Anzahl für den Output-Layer direkt.

# Neuronenlayer initialisieren



```
def __init_layers(self):
    self.activations = []
    self.weighted_sums = []

    for l in range(len(self.structure)):
        is_output_layer = l == len(self.structure) - 1
        n_activations = self.structure[l] if is_output_layer else self.structure[l] + 1
        n_weighted_sums = self.structure[l]
        layer_weighted_sums = numpy.zeros((n_weighted_sums, 1))
        layer_activations = numpy.ones((n_activations, 1))

        self.weighted_sums.append(layer_weighted_sums)
        self.activations.append(layer_activations)
```

Für alle anderen Layer addieren wir 1 zu der ausgelesenen Zahl, da im Input- und Hidden Layer je ein Bias-Neuron zusätzlich angelegt werden soll.

# Neuronenlayer initialisieren



```
def __init_layers(self):
    self.activations = []
    self.weighted_sums = []

    for l in range(len(self.structure)):
        is_output_layer = l == len(self.structure) - 1
        n_activations = self.structure[l] if is_output_layer else self.structure[l] + 1
        n_weighted_sums = self.structure[l]
        layer_weighted_sums = numpy.zeros((n_weighted_sums, 1))
        layer_activations = numpy.ones((n_activations, 1))

        self.weighted_sums.append(layer_weighted_sums)
        self.activations.append(layer_activations)
```

Die Variable `n_weighted_sums` soll die Anzahl der gewichteten Summen des Layers enthalten. In den Bias-Neuronen soll es keine gewichteten Summen geben, da diese unbeeinflusst vom vorherigen Layer sein sollen. Daher können wir die Anzahl unmittelbar aus der `structure`-Liste auslesen.

# Neuronenlayer initialisieren



```
def __init_layers(self):
    self.activations = []
    self.weighted_sums = []

    for l in range(len(self.structure)):
        is_output_layer = l == len(self.structure) - 1
        n_activations = self.structure[l] if is_output_layer else self.structure[l] + 1
        n_weighted_sums = self.structure[l]
        layer_weighted_sums = numpy.zeros((n_weighted_sums, 1))
        layer_activations = numpy.ones((n_activations, 1))

        self.weighted_sums.append(layer_weighted_sums)
        self.activations.append(layer_activations)
```

Dann erzeugen wir mit der Funktion `numpy.zeros` für die gewichteten Summen des Layers eine Matrix, die mit **0en** vorbefüllt wird. Die Matrix soll **n\_weighted\_sums Zeilen** und **eine Spalte** haben (also ein Spaltenvektor sein).

# Neuronenlayer initialisieren



```
def __init_layers(self):
    self.activations = []
    self.weighted_sums = []

    for l in range(len(self.structure)):
        is_output_layer = l == len(self.structure) - 1
        n_activations = self.structure[l] if is_output_layer else self.structure[l] + 1
        n_weighted_sums = self.structure[l]
        layer_weighted_sums = numpy.zeros((n_weighted_sums, 1))
        layer_activations = numpy.ones((n_activations, 1))

        self.weighted_sums.append(layer_weighted_sums)
        self.activations.append(layer_activations)
```

Für die Aktivierungen gehen wir ähnlich vor. Hier befüllen wir die Matrix aber mithilfe von `numpy.ones` mit Einsen vor. Für das Bias-Neuron bleibt diese Aktivierung dauerhaft erhalten, alle anderen werden im Rahmen der Berechnungen überschrieben.

# Neuronenlayer initialisieren



```
def __init_layers(self):
    self.activations = []
    self.weighted_sums = []

    for l in range(len(self.structure)):
        is_output_layer = l == len(self.structure) - 1
        n_activations = self.structure[l] if is_output_layer else self.structure[l] + 1
        n_weighted_sums = self.structure[l]
        layer_weighted_sums = numpy.zeros((n_weighted_sums, 1))
        layer_activations = numpy.ones((n_activations, 1))

        self.weighted_sums.append(layer_weighted_sums)
        self.activations.append(layer_activations)
```

Man beachte jeweils die doppelten Klammern. Wir übergeben den numpy-Funktionen nicht zwei Parameter, sondern nur einen: Nämlich ein **Tupel**, das die Dimensionen der Matrix angibt, in diesem Fall im Format (**Zeilen, Spalten**).

# Neuronenlayer initialisieren



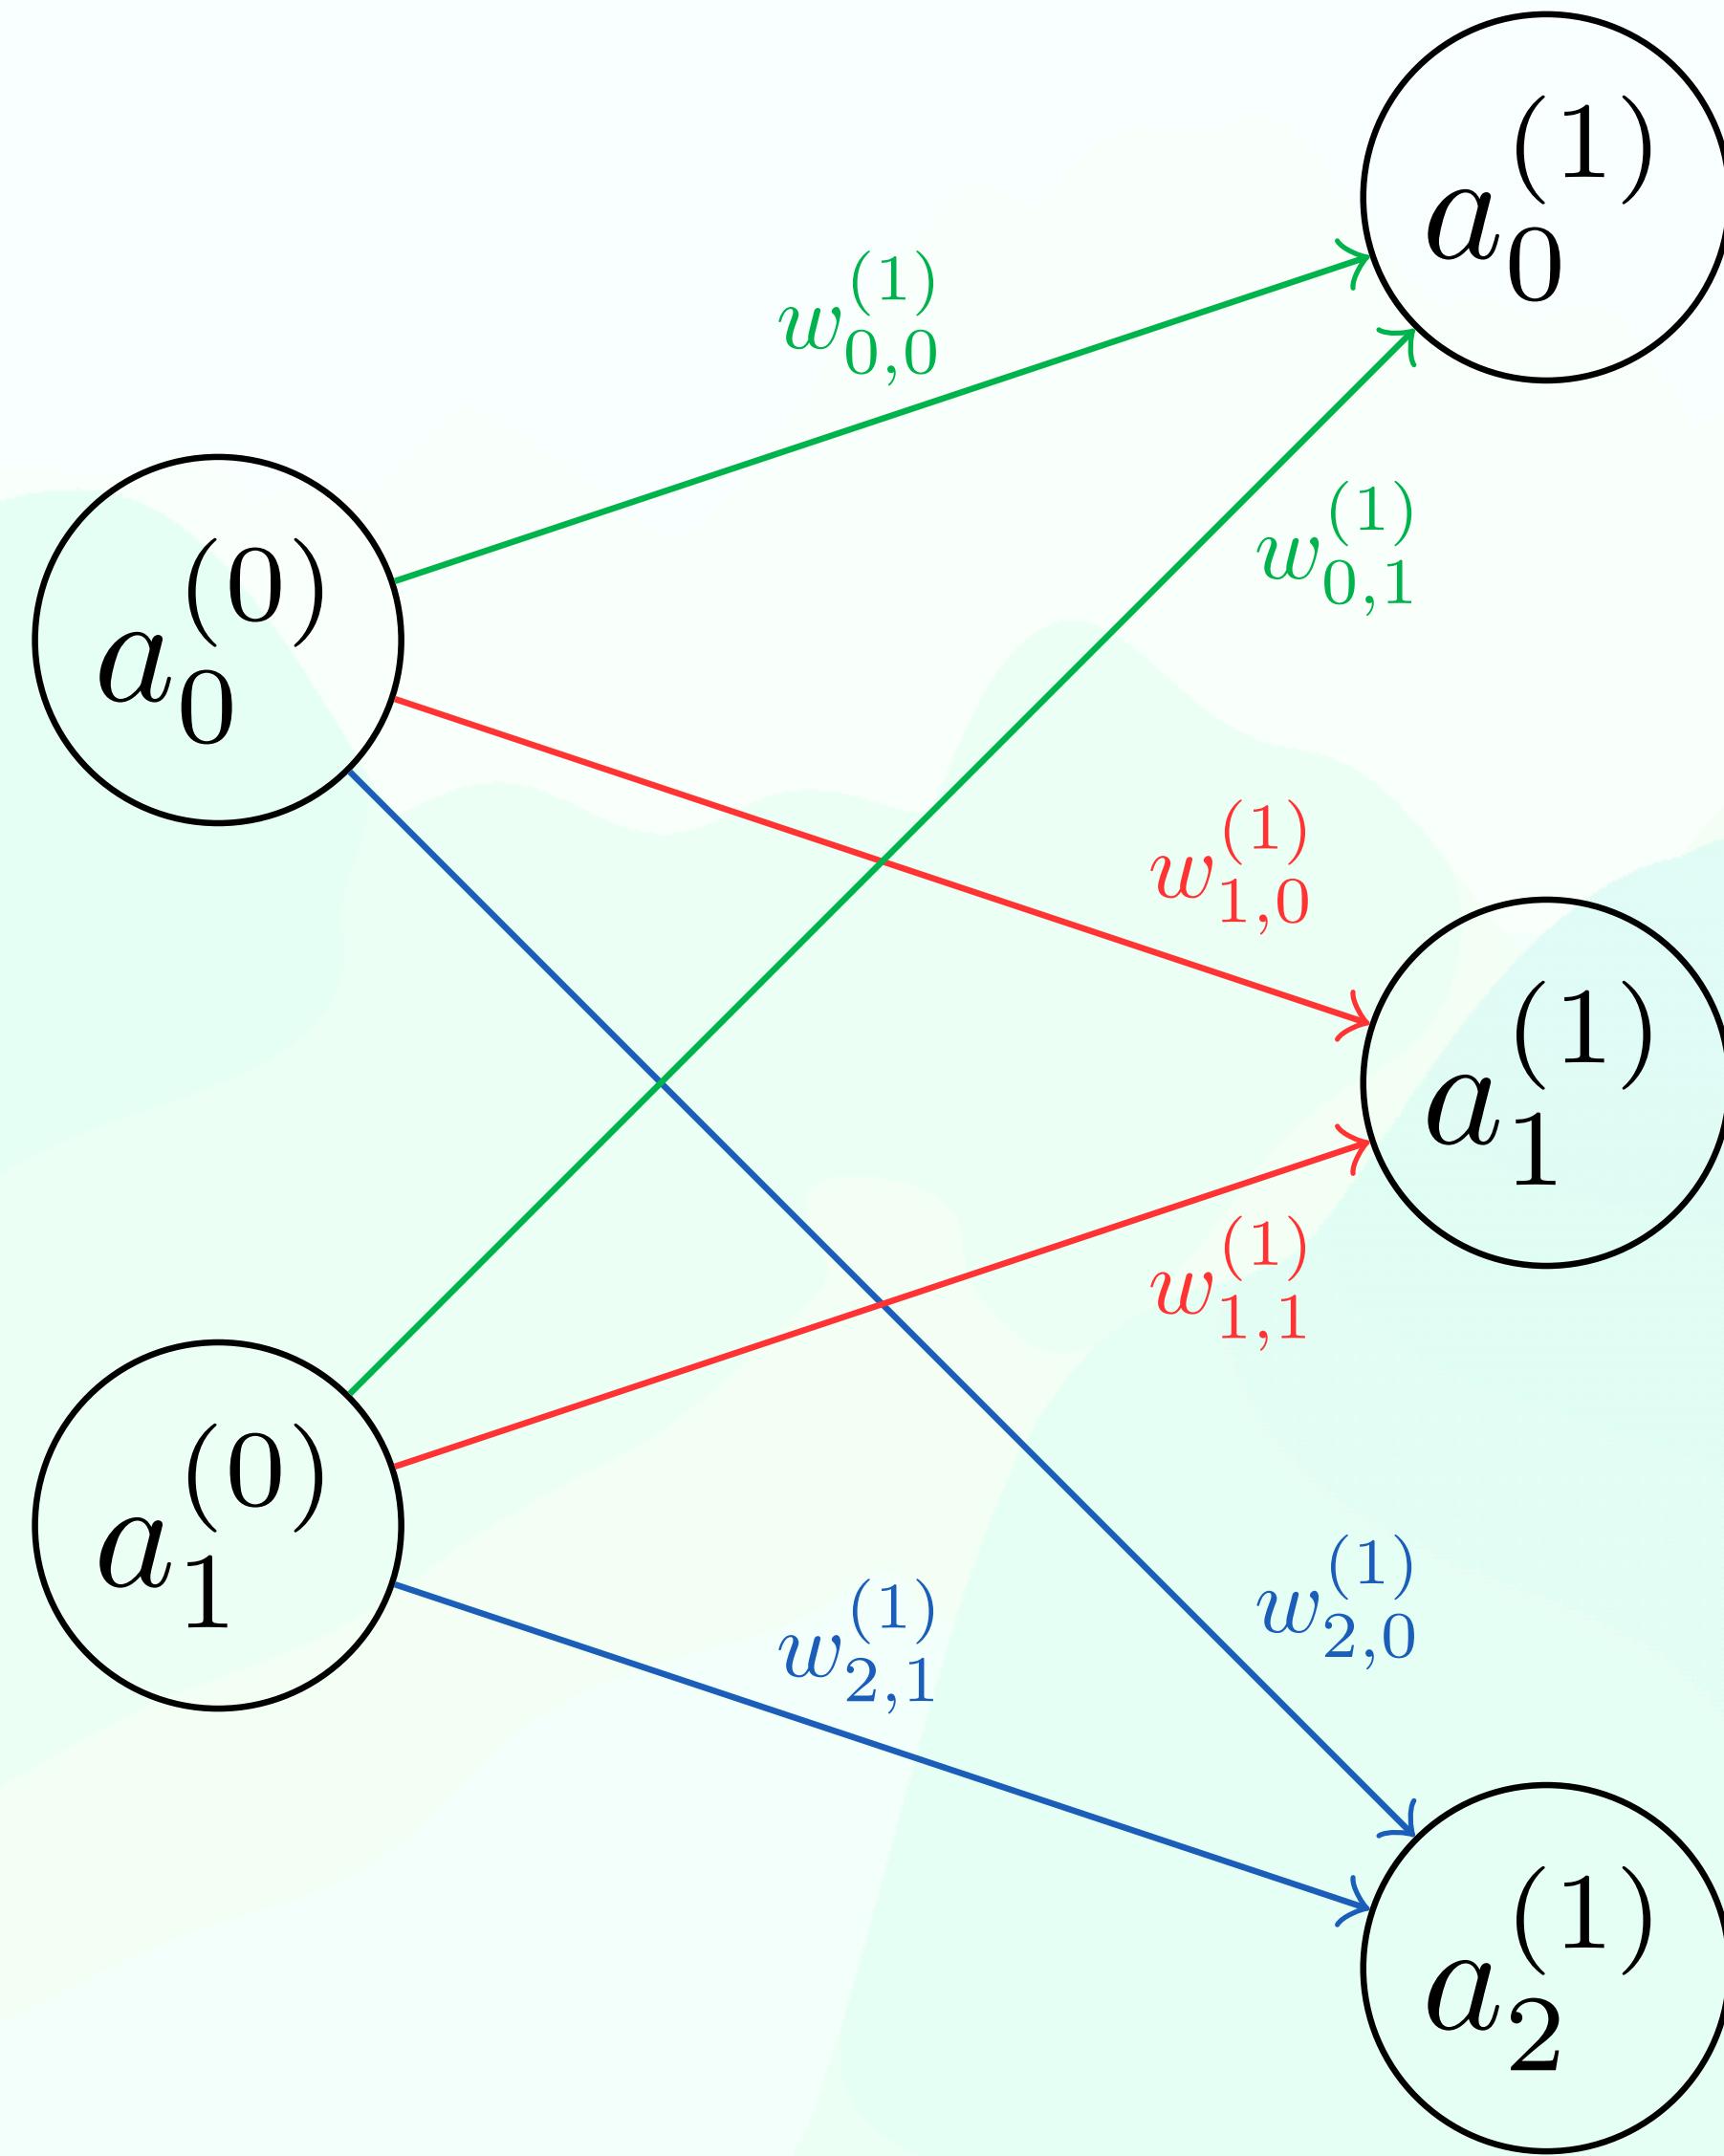
```
def __init_layers(self):
    self.activations = []
    self.weighted_sums = []

    for l in range(len(self.structure)):
        is_output_layer = l == len(self.structure) - 1
        n_activations = self.structure[l] if is_output_layer else self.structure[l] + 1
        n_weighted_sums = self.structure[l]
        layer_weighted_sums = numpy.zeros((n_weighted_sums, 1))
        layer_activations = numpy.ones((n_activations, 1))

        self.weighted_sums.append(layer_weighted_sums)
        self.activations.append(layer_activations)
```

Zum Schluss fügen wir die Matrizen (Vektoren) für den aktuellen Layer jeweils mit der `append`-Methode den Listen hinzu. Auf diese Weise bauen wir Layer für Layer die Struktur des neuronalen Netzes auf.

# Notation – Gewichtsmatrix



Für Notation und Implementierung in Python hilfreich:  
Vektor- und Matrixschreibweise

$$W^{(1)} = \begin{pmatrix} w_{0,0}^{(1)} & w_{0,1}^{(1)} \\ w_{1,0}^{(1)} & w_{1,1}^{(1)} \\ w_{2,0}^{(1)} & w_{2,1}^{(1)} \end{pmatrix}$$

# Gewichte initialisieren



```
def __init_weights(self):
    self.weights = [None]

    for l in range(1, len(self.structure)):
        layer_weights = numpy.random.randn(
            self.structure[l],
            self.structure[l-1] + 1
        ) * numpy.sqrt(2.0 / (self.structure[l-1] + 1))

        self.weights.append(layer_weights)
```

# Gewichte initialisieren



```
def __init_weights(self):
    self.weights = [None]

    for l in range(1, len(self.structure)):
        layer_weights = numpy.random.randn(
            self.structure[l],
            self.structure[l-1] + 1
        ) * numpy.sqrt(2.0 / (self.structure[l-1] + 1))

        self.weights.append(layer_weights)
```

Analog zu `__init_layers` deklarieren wir auch die Methode `__init_weights` zur Initialisierung der Gewichte in unserem Netz.

# Gewichte initialisieren



Wir legen zunächst eine Liste in der Eigenschaft `weights` an. Die einzelnen Einträge werden am Ende die Gewichtsmatrizen der einzelnen Layer sein.

```
def __init_weights(self):
    self.weights = [None]

    for l in range(1, len(self.structure)):
        layer_weights = numpy.random.randn(
            self.structure[l],
            self.structure[l-1] + 1
        ) * numpy.sqrt(2.0 / (self.structure[l-1] + 1))

        self.weights.append(layer_weights)
```

# Gewichte initialisieren



```
def __init_weights(self):
    self.weights = [None]

    for l in range(1, len(self.structure)):
        layer_weights = numpy.random.randn(
            self.structure[l],
            self.structure[l-1] + 1
        ) * numpy.sqrt(2.0 / (self.structure[l-1] + 1))

        self.weights.append(layer_weights)
```

Um eine konsistente Indizierung zu ermöglichen, fügen wir für den Index **0** einen Eintrag zur Liste hinzu, der später ignoriert wird. Damit bekommt die Gewichtsmatrix vom Input- zum ersten Hidden Layer den Index **1**, wie es auch in unseren Gleichungen vorgegeben ist.

# Gewichte initialisieren



```
def __init_weights(self):  
    self.weights = [None]  
  
    for l in range(1, len(self.structure)):  
        layer_weights = numpy.random.randn(  
            self.structure[l],  
            self.structure[l-1] + 1  
        ) * numpy.sqrt(2.0 / (self.structure[l-1] + 1))  
  
        self.weights.append(layer_weights)
```

Wir iterieren wieder durch die Layer, deren Anzahl uns durch die Länge der Liste in `self.structure` vorgegeben ist. Wieder wird `l` den jeweils aktuellen Index des Layers beinhalten.

# Gewichte initialisieren



```
def __init_weights(self):
    self.weights = [None]

    for l in range(1, len(self.structure)):
        layer_weights = numpy.random.randn(
            self.structure[l],
            self.structure[l-1] + 1
        ) * numpy.sqrt(2.0 / (self.structure[l-1] + 1))

        self.weights.append(layer_weights)
```

Wir beginnen die `range` erst bei Index 1, da Index 0 in der Liste der Gewichtsmatrizen durch das Dummy-Element bereits belegt ist.

# Gewichte initialisieren



```
def __init_weights(self):  
    self.weights = [None]  
  
    for l in range(1, len(self.structure)):  
        layer_weights = numpy.random.randn(  
            self.structure[l],  
            self.structure[l-1] + 1  
        ) * numpy.sqrt(2.0 / (self.structure[l-1] + 1))  
  
        self.weights.append(layer_weights)
```

Für alle Indizes ab 1 erzeugen wir echte Gewichtsmatrizen, diesmal mit der Funktion `numpy.random.randn`, die eine Matrix mit normalverteilten Zufallszahlen zwischen 0 und 1 erzeugt.

# Gewichte initialisieren



```
def __init_weights(self):  
    self.weights = [None]  
  
    for l in range(1, len(self.structure)):  
        layer_weights = numpy.random.randn(  
            self.structure[l],  
            self.structure[l-1] + 1  
        ) * numpy.sqrt(2.0 / (self.structure[l-1] + 1))  
  
        self.weights.append(layer_weights)
```

Der erste Parameter gibt die Anzahl der **Zeilen** der Matrix an. Es sollen so viele Zeilen wie **Neuronen im aktuellen Layer** sein, exklusive des Bias-Neurons, denn dorthin sollen keine Gewichte führen.

# Gewichte initialisieren



```
def __init_weights(self):
    self.weights = [None]

    for l in range(1, len(self.structure)):
        layer_weights = numpy.random.randn(
            self.structure[l],
            self.structure[l-1] + 1
        ) * numpy.sqrt(2.0 / (self.structure[l-1] + 1))

        self.weights.append(layer_weights)
```

Der zweite Parameter ist die Anzahl der **Spalten**. Sie ist so groß wie die Anzahl der **Neuronen im vorherigen Layer**, denn alle Neuronen des vorherigen Layers sollen in die gewichteten Summen des nächsten Layers einfließen, inkl. des Bias-Neurons. Daher addieren wir auf die Zahl, die wir aus der **structure**-Liste auslesen, eine 1.

# Gewichte initialisieren

$$W \sim \mathcal{N} \left( 0, \sqrt{\frac{2}{n}} \right)$$



```
def __init_weights(self):
    self.weights = [None]

    for l in range(1, len(self.structure)):
        layer_weights = numpy.random.randn(
            self.structure[l],
            self.structure[l-1] + 1
        ) * numpy.sqrt(2.0 / (self.structure[l-1] + 1))

        self.weights.append(layer_weights)
```

Wir wollen hier die Gewichtsinitialisierung nach He et al. [1] implementieren. Dazu müssen wir die Normalverteilung auf eine Standardabweichung skalieren, die sich nach der Anzahl der eingehenden Neuronen bemisst.

He-Initialisierung liefert bei ReLU-Aktivierungen besonders gute Ergebnisse.

[1] <https://arxiv.org/pdf/1502.01852>

# Gewichte initialisieren

$$W \sim \mathcal{N} \left( 0, \sqrt{\frac{2}{n}} \right)$$



```
def __init_weights(self):  
    self.weights = [None]  
  
    for l in range(1, len(self.structure)):  
        layer_weights = numpy.random.randn(  
            self.structure[l],  
            self.structure[l-1] + 1  
        ) * numpy.sqrt(2.0 / (self.structure[l-1] + 1))  
  
        self.weights.append(layer_weights)
```

Das  $n$  steht für die Anzahl der Neuronen des vorherigen Layers.

[1] <https://arxiv.org/pdf/1502.01852>

# Gewichte initialisieren



```
def __init_weights(self):  
    self.weights = [None]  
  
    for l in range(1, len(self.structure)):  
        layer_weights = numpy.random.randn(  
            self.structure[l],  
            self.structure[l-1] + 1  
        ) * numpy.sqrt(2.0 / (self.structure[l-1] + 1))  
  
        self.weights.append(layer_weights)
```

Zuletzt fügen wir die Gewichtsmatrix des aktuellen Layers zum Netz hinzu.

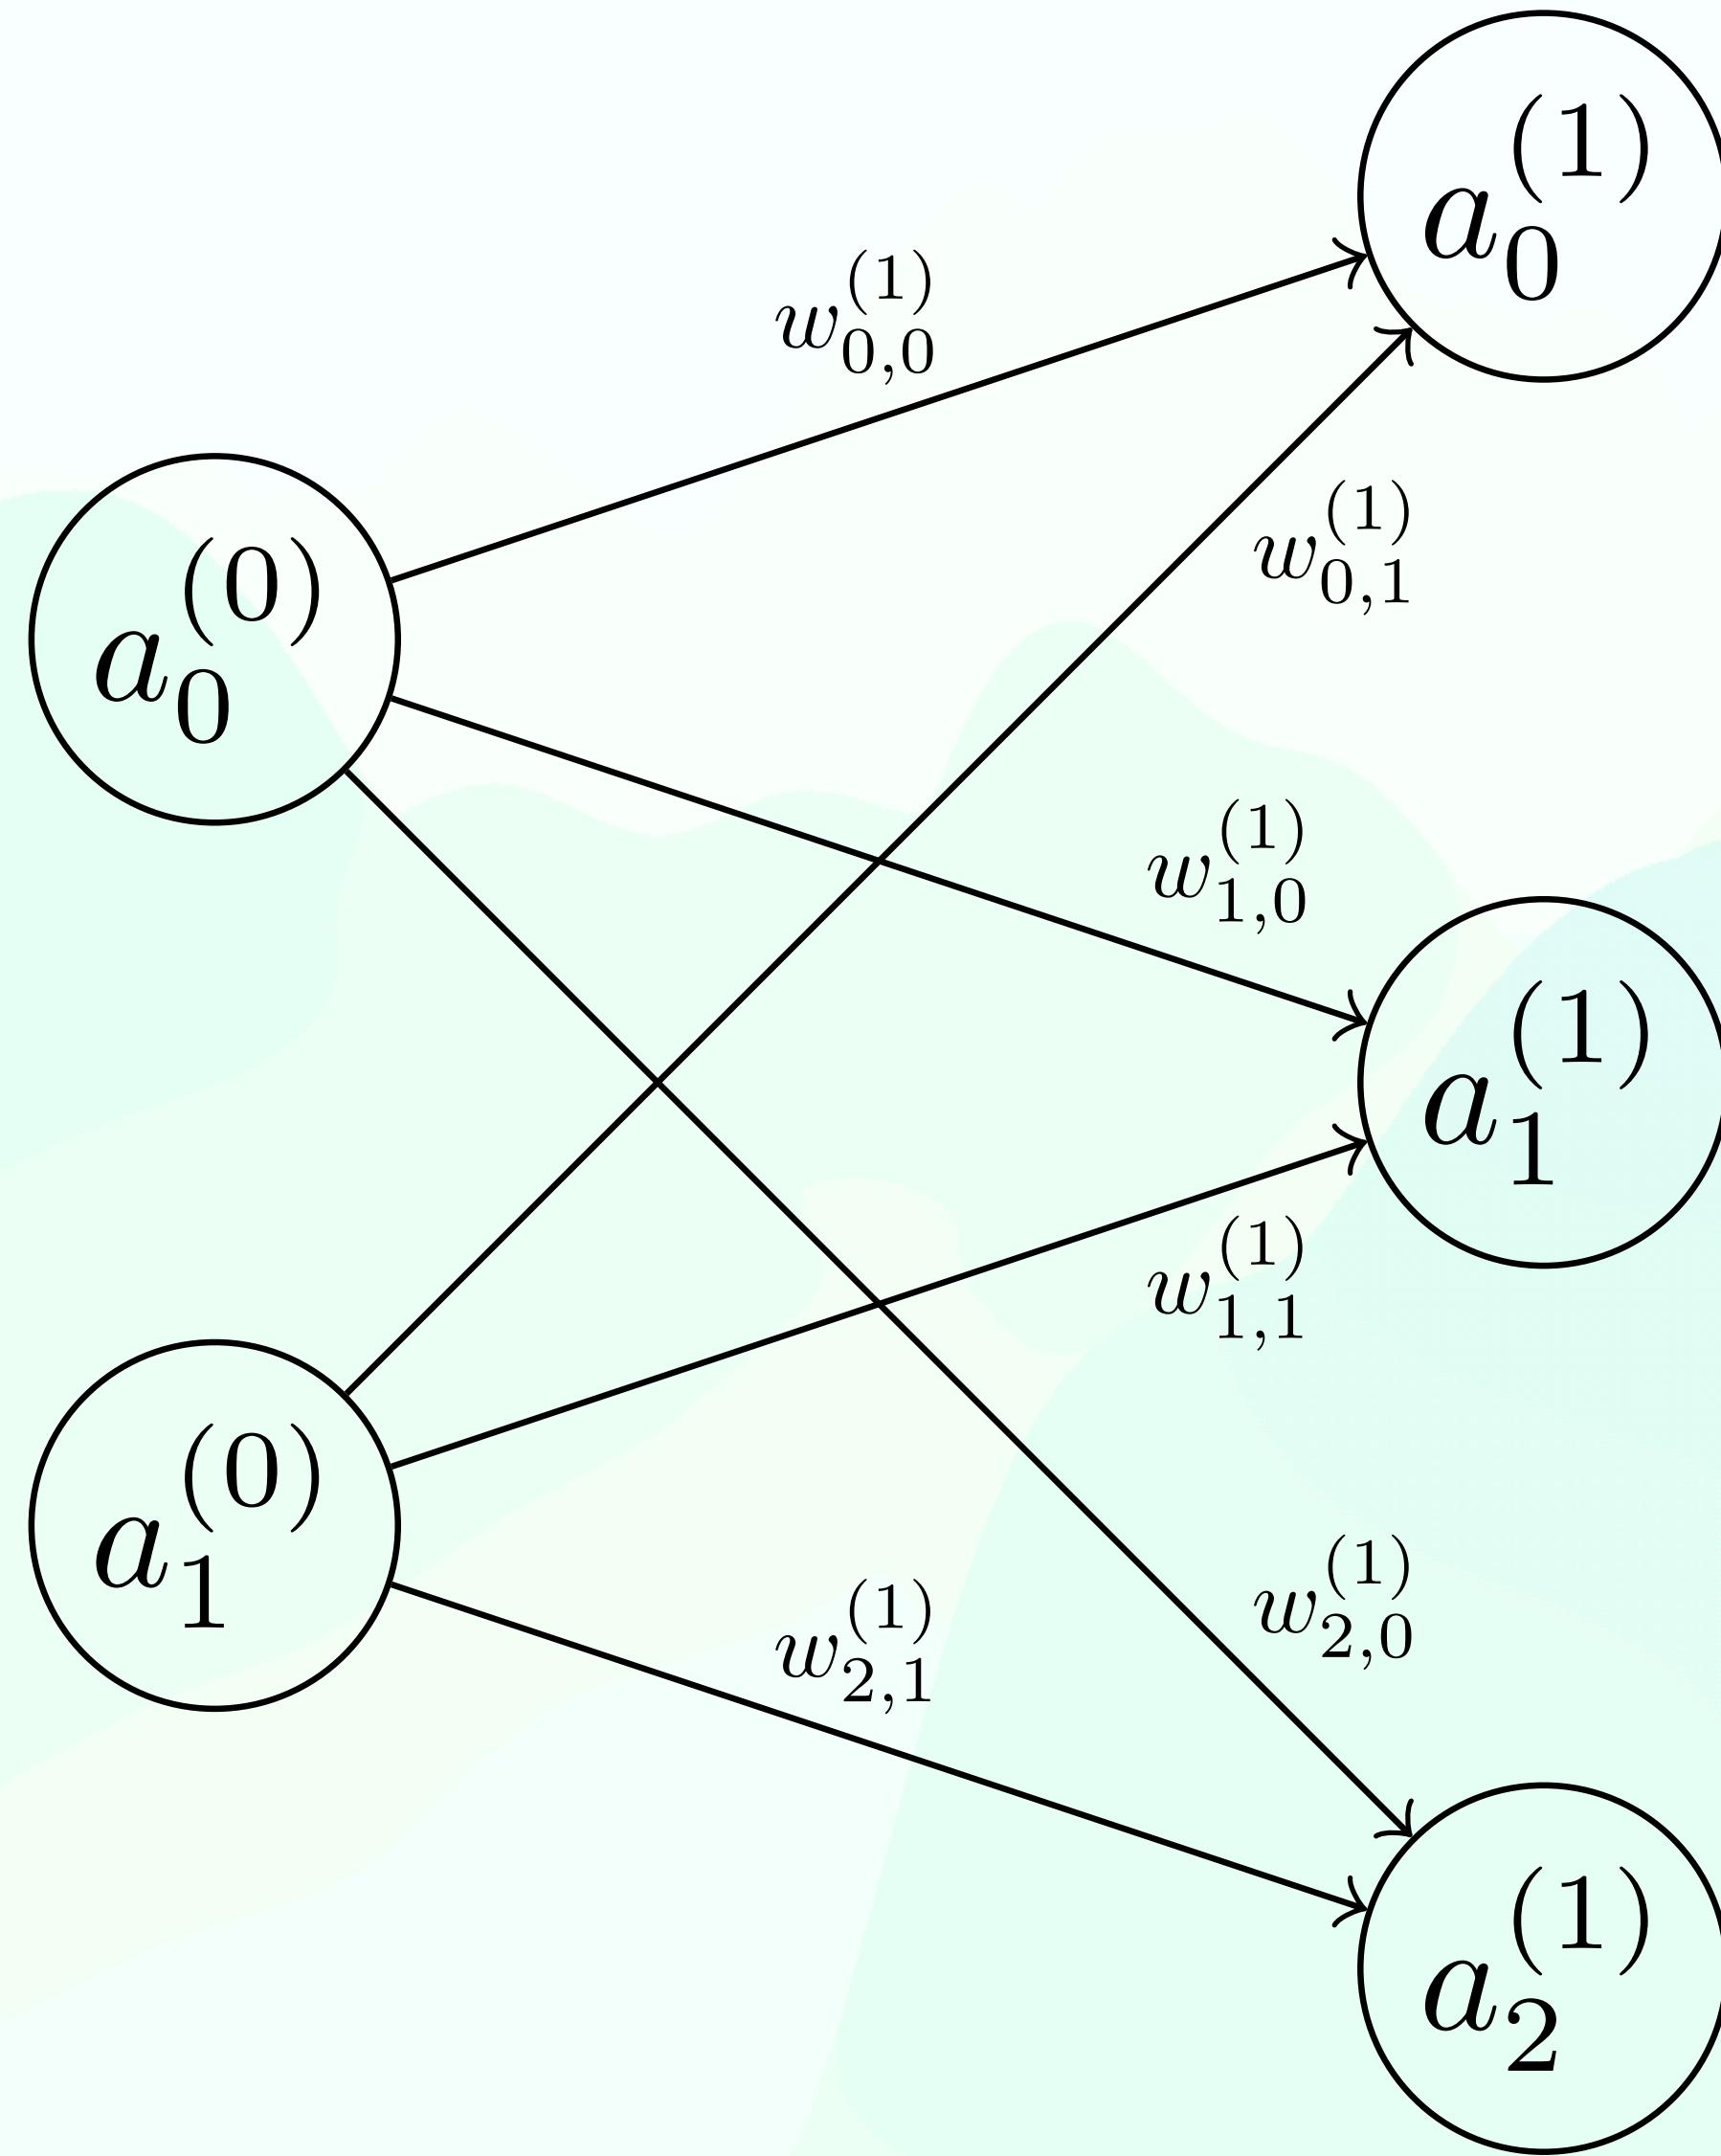
# Gewichte initialisieren



```
def __init__(self, structure):
    self.structure = structure
    self.__init_layers()
    self.__init_weights()
```

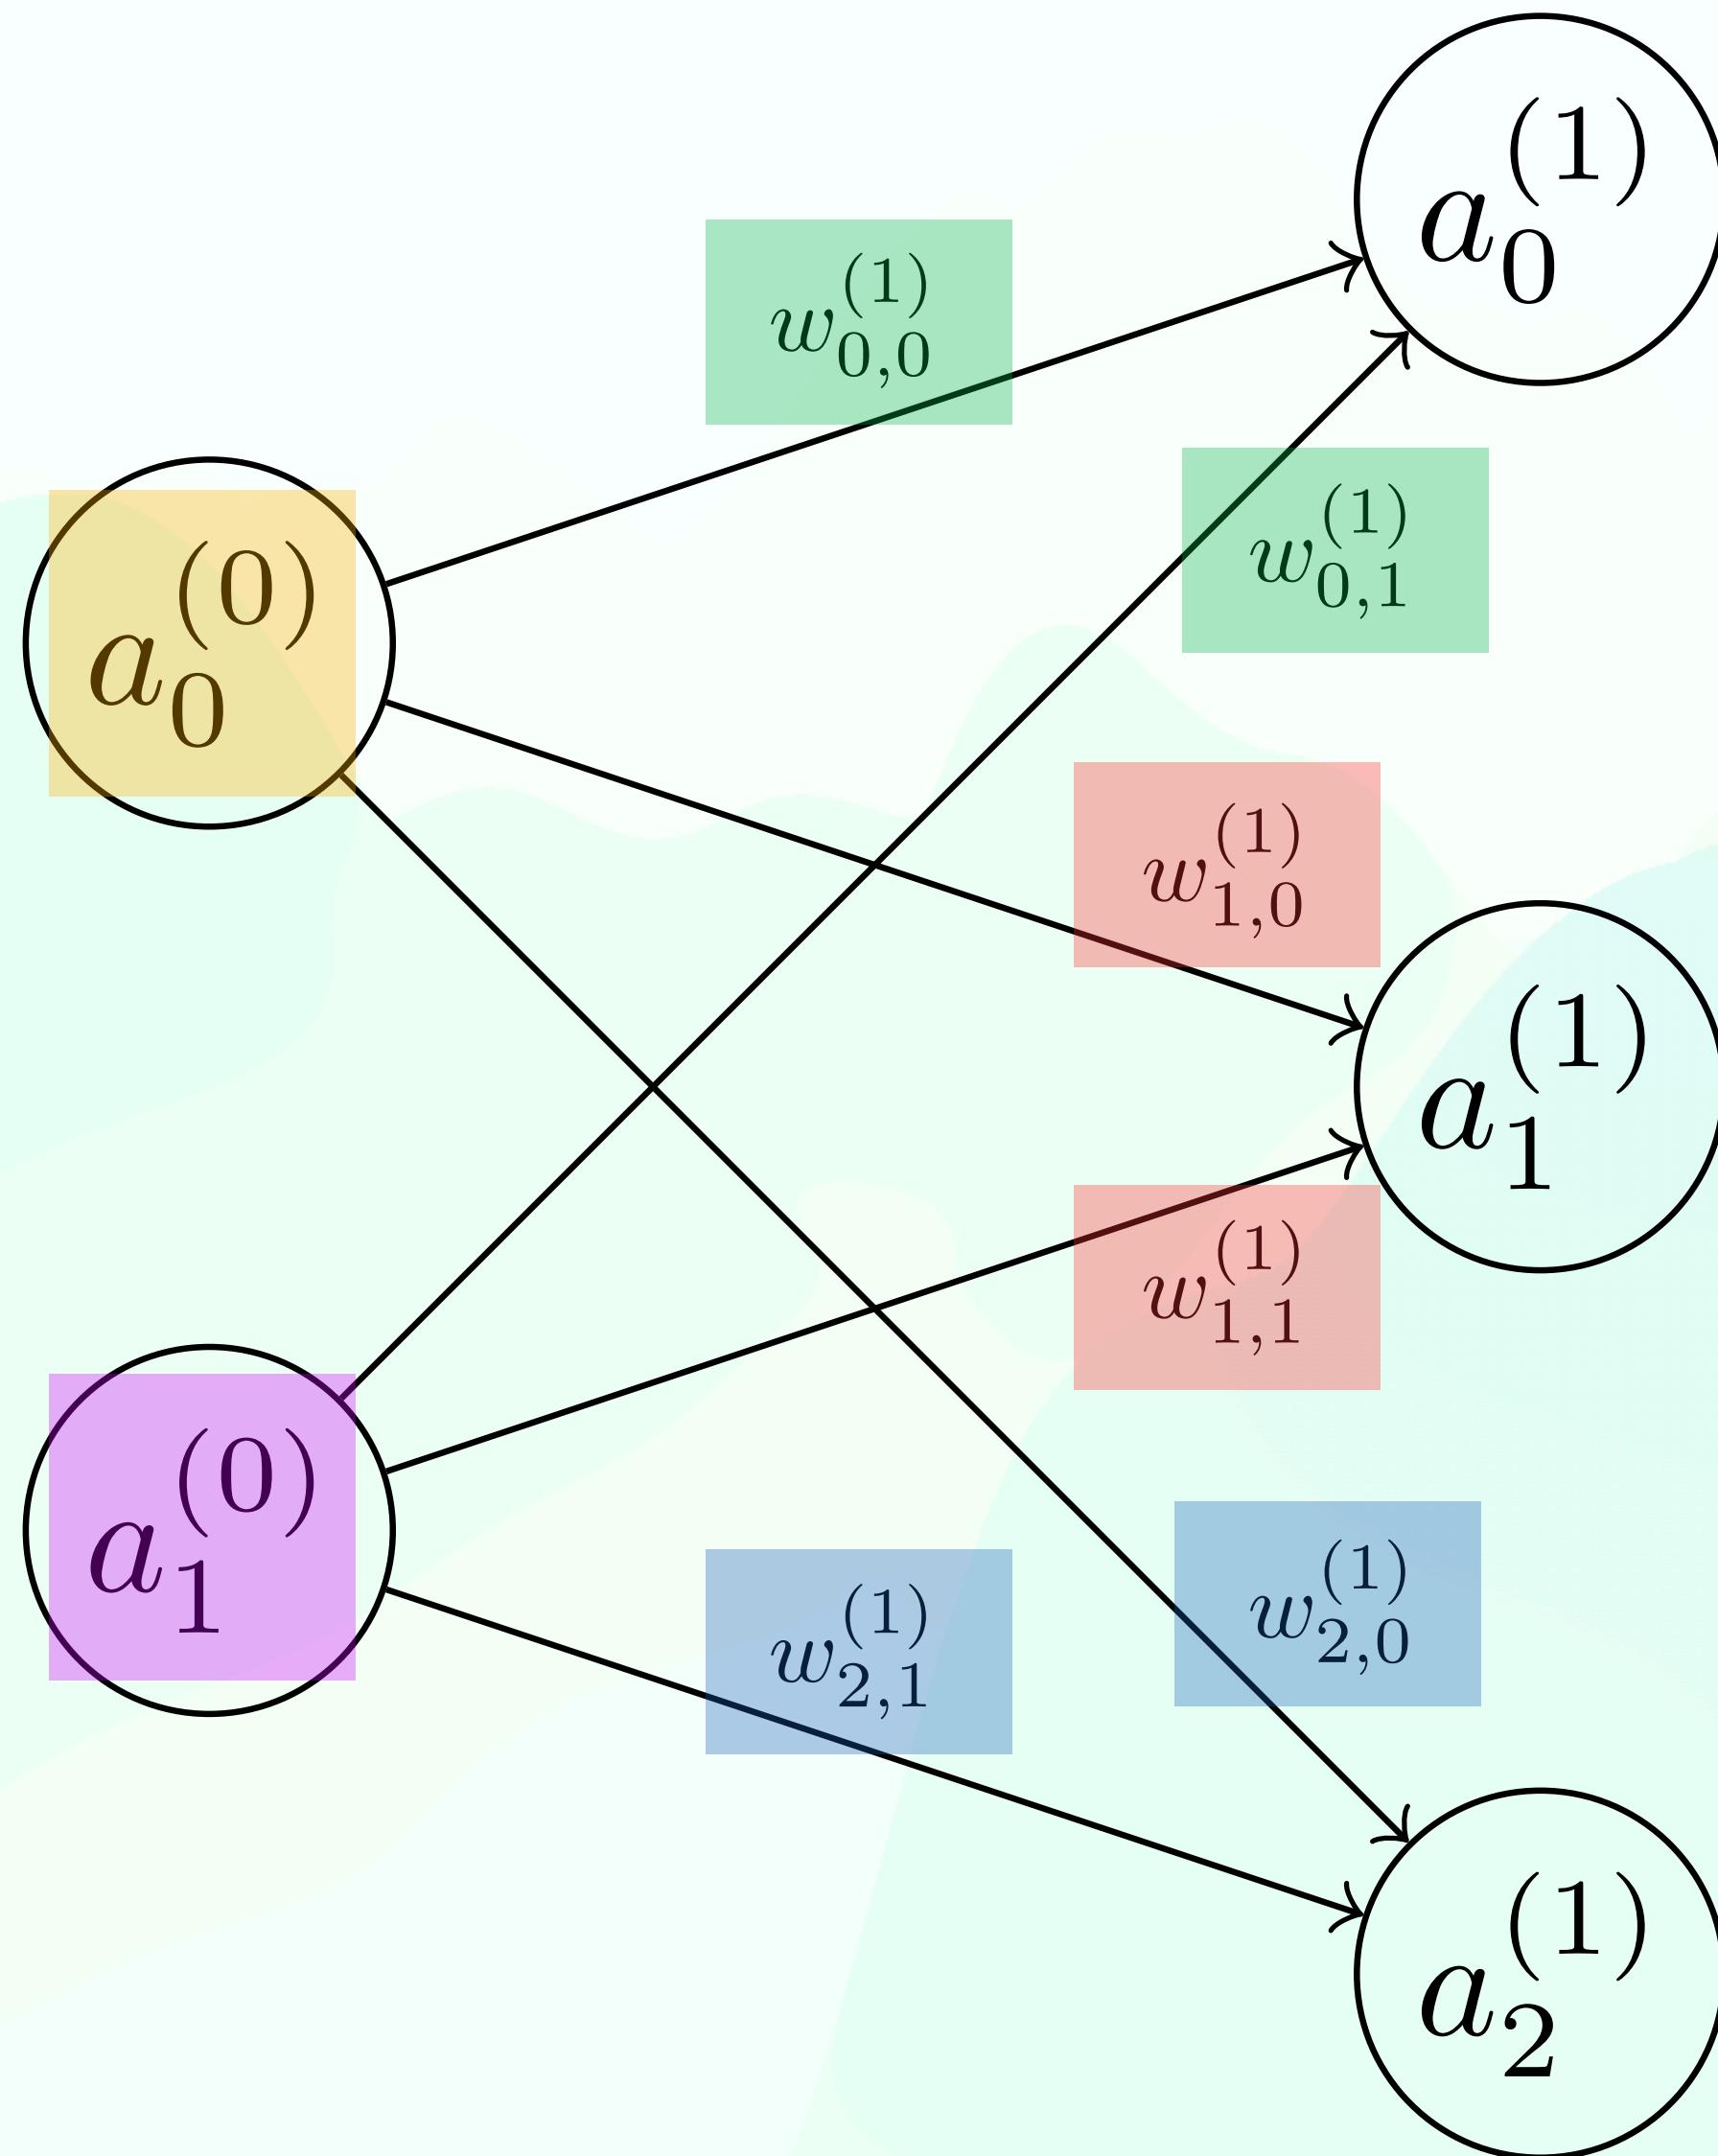
Natürlich muss unsere Methode zur Initialisierung der Gewichte auch im Konstruktor aufgerufen werden.

# Notation – Aktivierungsfunktion



$$\begin{aligned} A^{(1)} &= \sigma^{(1)} (Z^{(1)}) \\ &= \sigma^{(1)} (W^{(1)} A^{(0)}) \\ &= \sigma^{(1)} \left[ \begin{pmatrix} w_{0,0}^{(1)} & w_{0,1}^{(1)} \\ w_{1,0}^{(1)} & w_{1,1}^{(1)} \\ w_{2,0}^{(1)} & w_{2,1}^{(1)} \end{pmatrix} \begin{pmatrix} a_0^{(0)} \\ a_1^{(0)} \end{pmatrix} \right] \end{aligned}$$

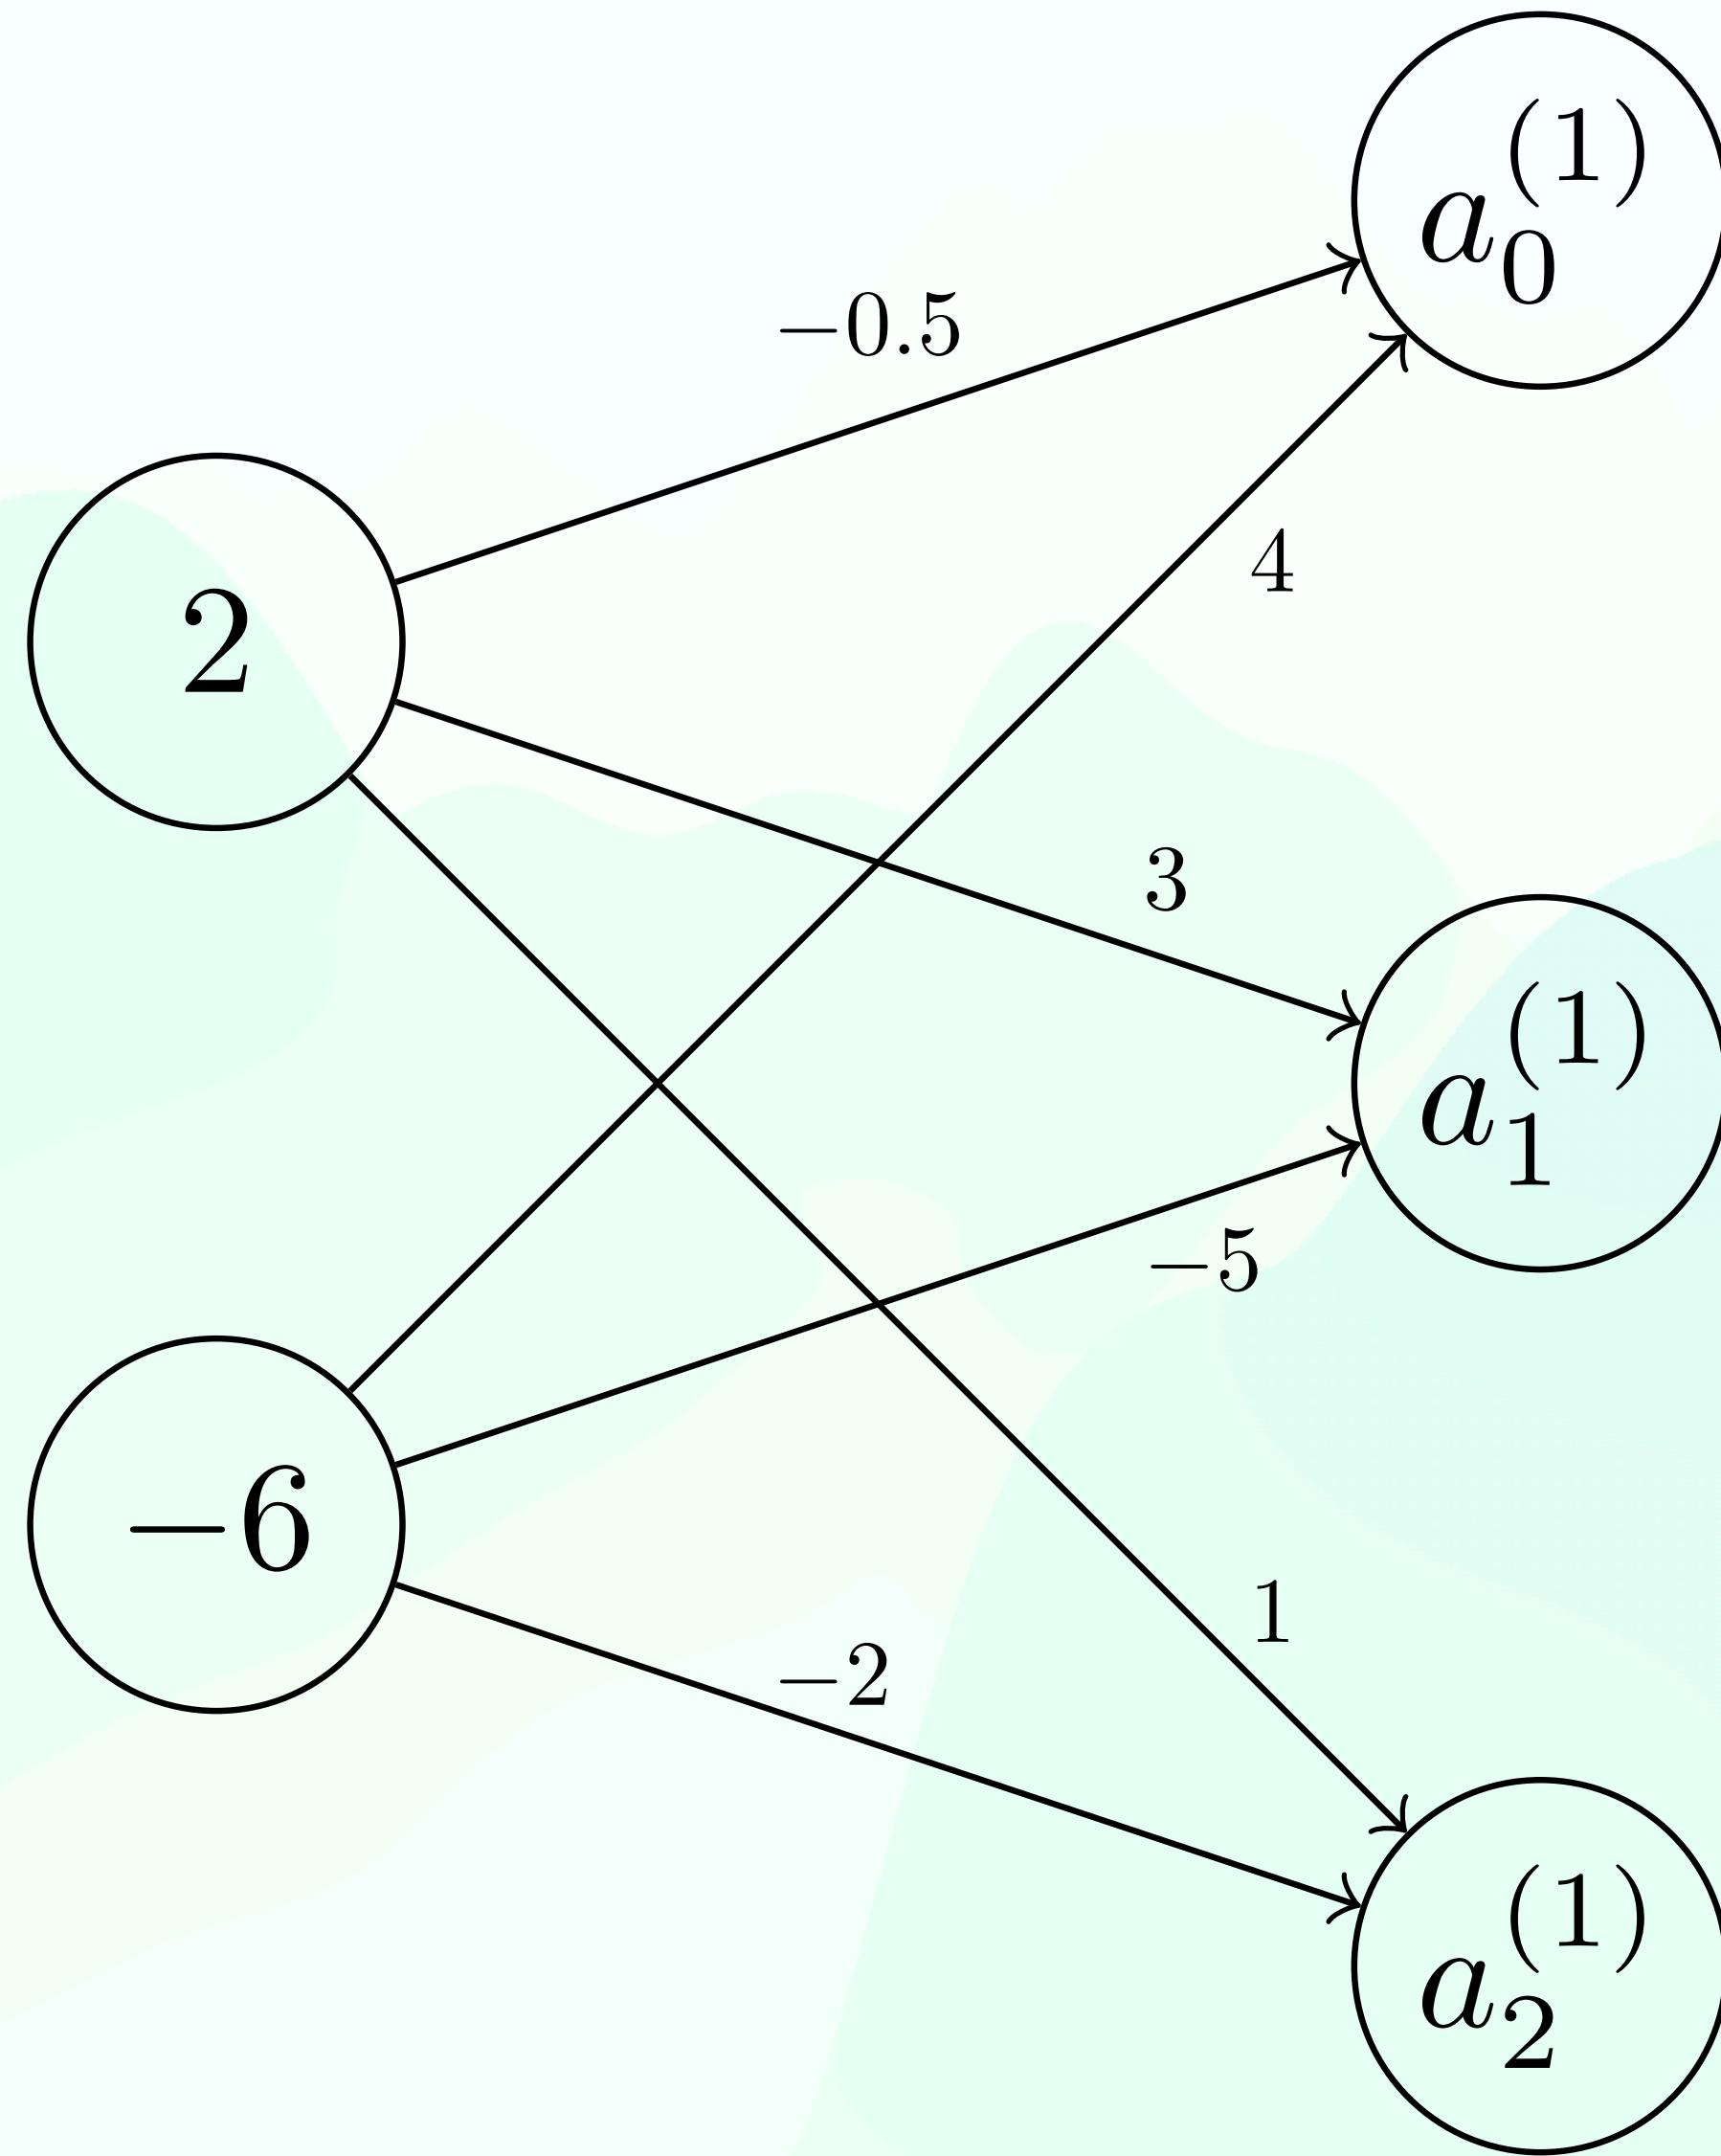
# Matrixmultiplikation



- Linke Matrix muss genauso viele **Spalten** haben wie die rechte Matrix **Zeilen** hat
- Ergebnis hat so viele **Zeilen** wie die linke Matrix und so viele **Spalten** wie die rechte
- Matrixmultiplikation ist **nicht** kommutativ!

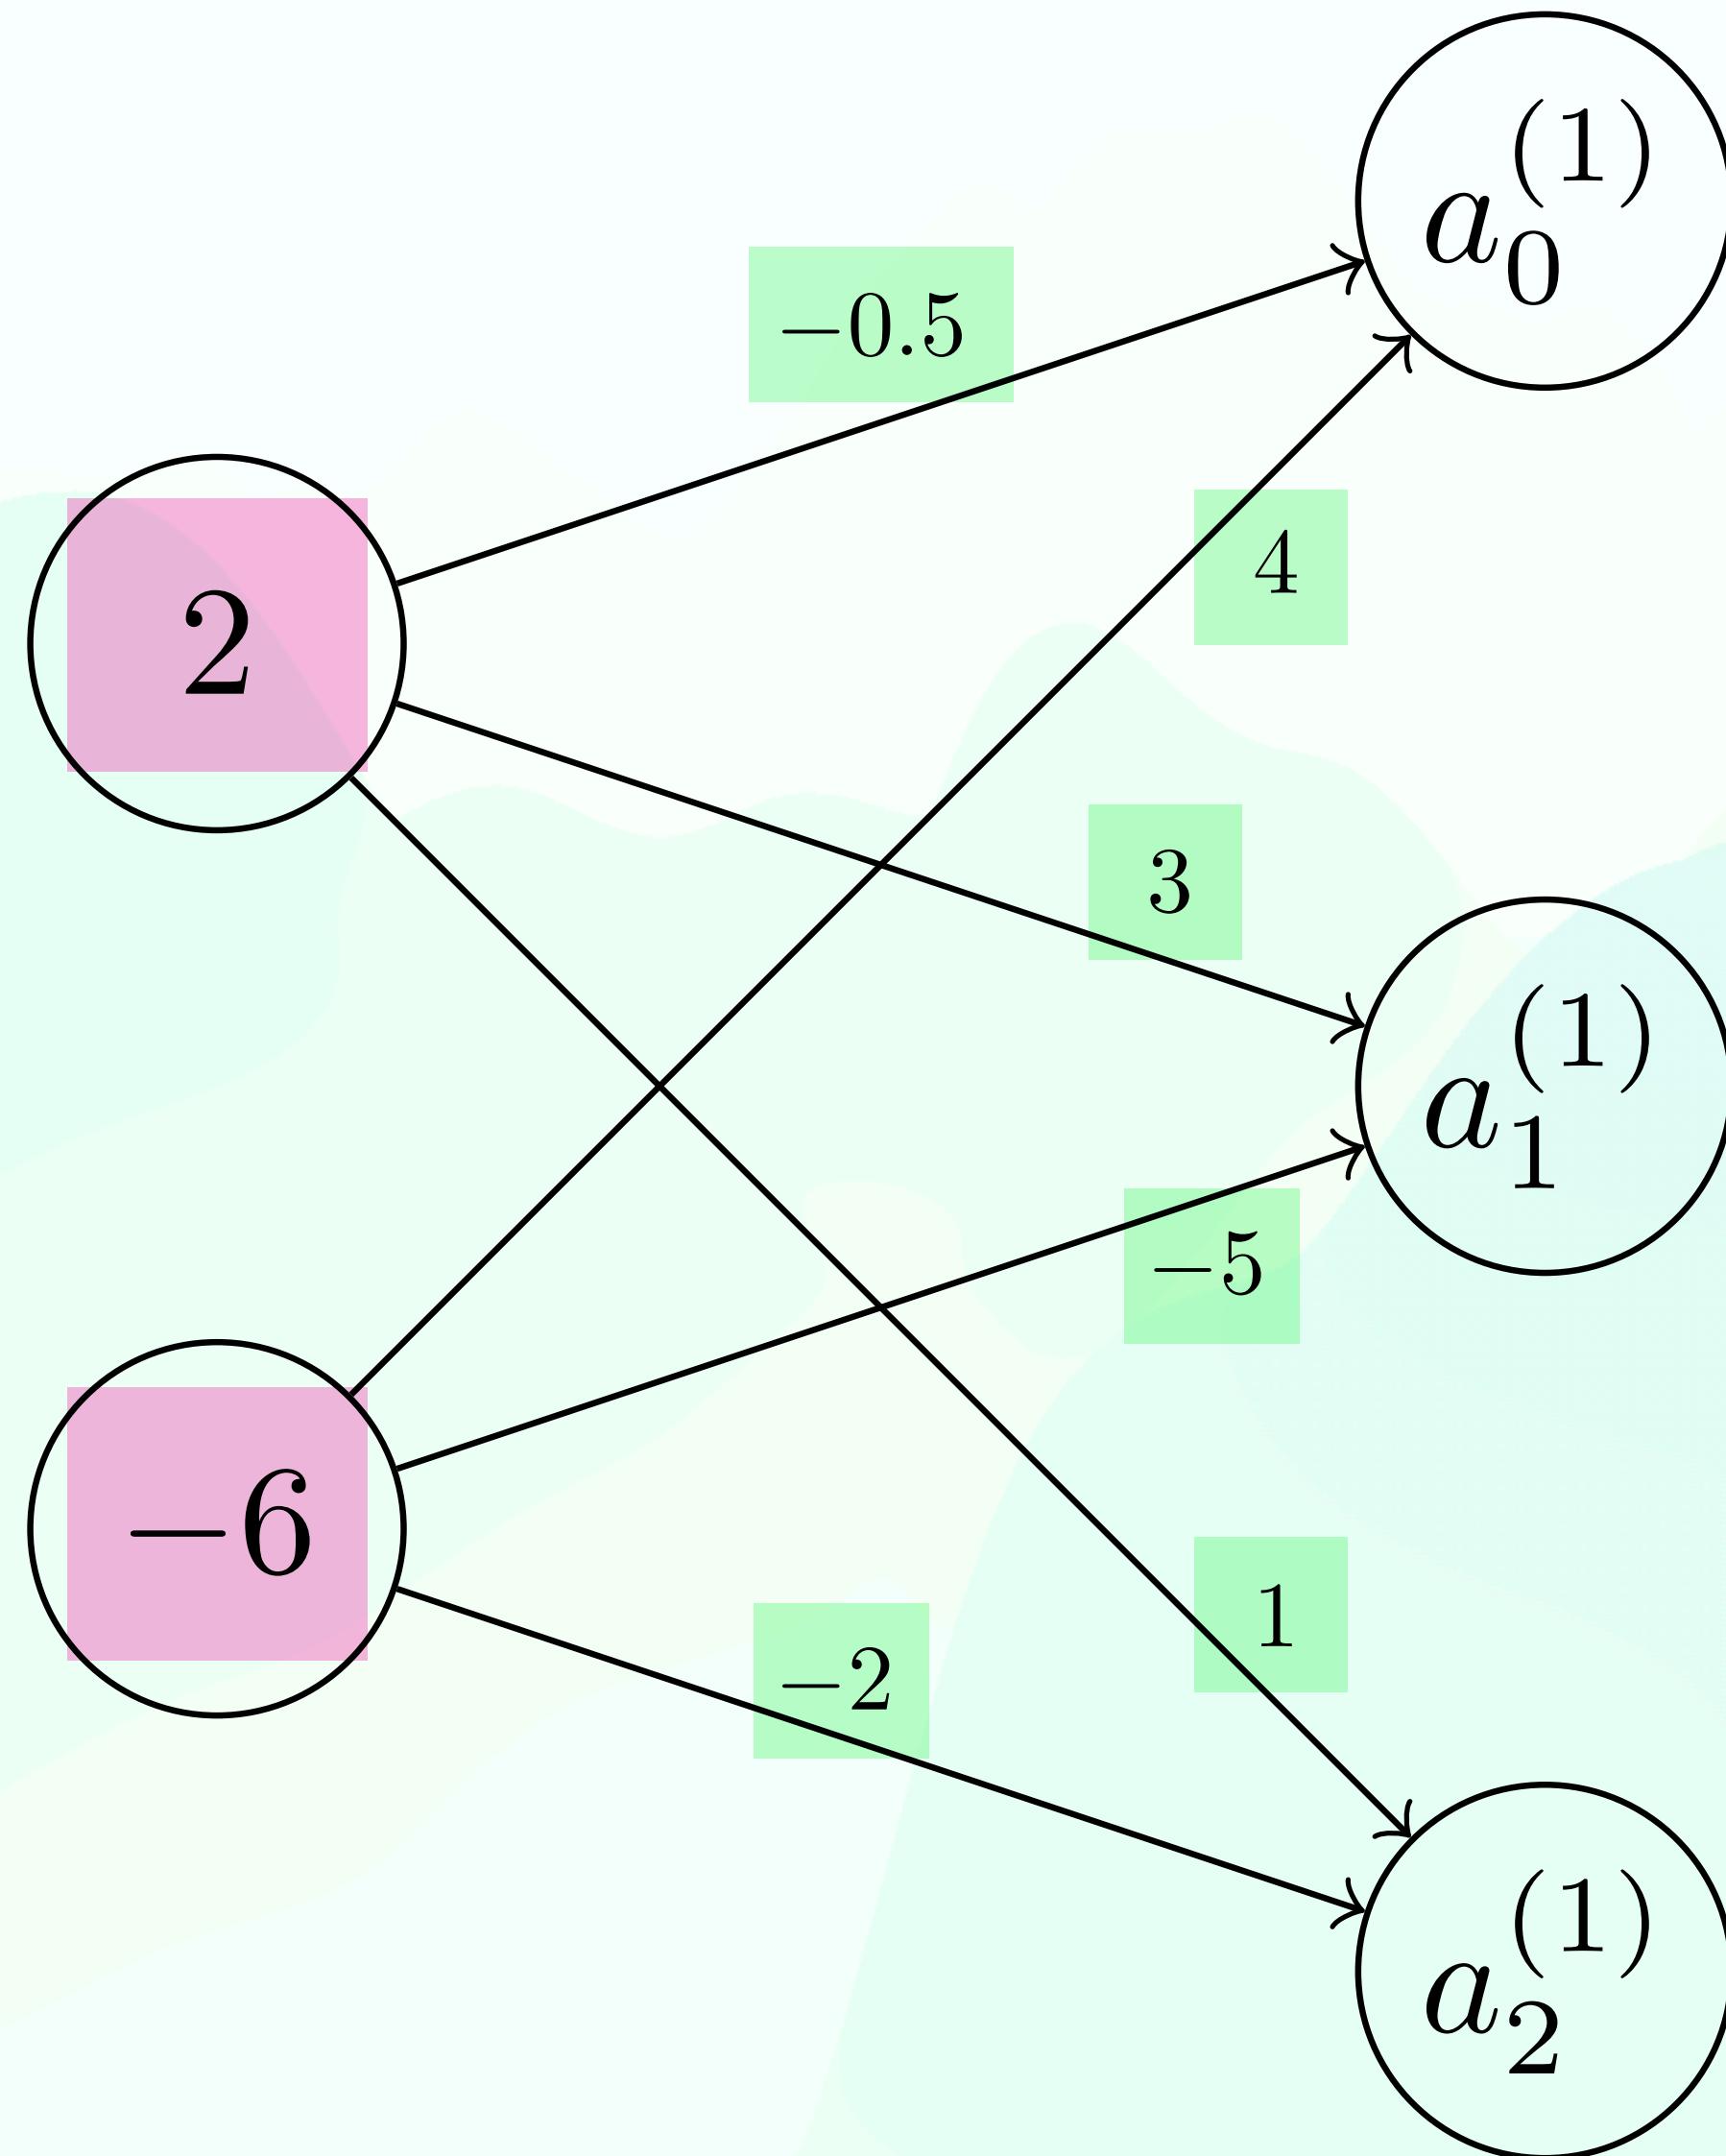
$$\begin{aligned}
 \begin{pmatrix} z_0^{(1)} \\ z_1^{(1)} \\ z_2^{(1)} \end{pmatrix} &= \begin{pmatrix} w_{0,0}^{(1)} & w_{0,1}^{(1)} \\ w_{1,0}^{(1)} & w_{1,1}^{(1)} \\ w_{2,0}^{(1)} & w_{2,1}^{(1)} \end{pmatrix} \begin{pmatrix} a_0^{(0)} \\ a_1^{(0)} \end{pmatrix} = \\
 &= \begin{pmatrix} w_{0,0}^{(1)} a_0^{(0)} + w_{0,1}^{(1)} a_1^{(0)} \\ w_{1,0}^{(1)} a_0^{(0)} + w_{1,1}^{(1)} a_1^{(0)} \\ w_{2,0}^{(1)} a_0^{(0)} + w_{2,1}^{(1)} a_1^{(0)} \end{pmatrix}
 \end{aligned}$$

# Matrixmultiplikation – Beispiel



$$\begin{pmatrix} z_0^{(1)} \\ z_1^{(1)} \\ z_2^{(1)} \end{pmatrix} = \begin{pmatrix} -0.5 & 4 \\ 3 & -5 \\ 1 & -2 \end{pmatrix} \begin{pmatrix} 2 \\ -6 \end{pmatrix} =$$
$$= \begin{pmatrix} -0.5 \cdot 2 + 4 \cdot (-6) \\ 3 \cdot 2 + (-5) \cdot (-6) \\ 1 \cdot 2 + (-2) \cdot (-6) \end{pmatrix} = \begin{pmatrix} -25 \\ 36 \\ 14 \end{pmatrix}$$

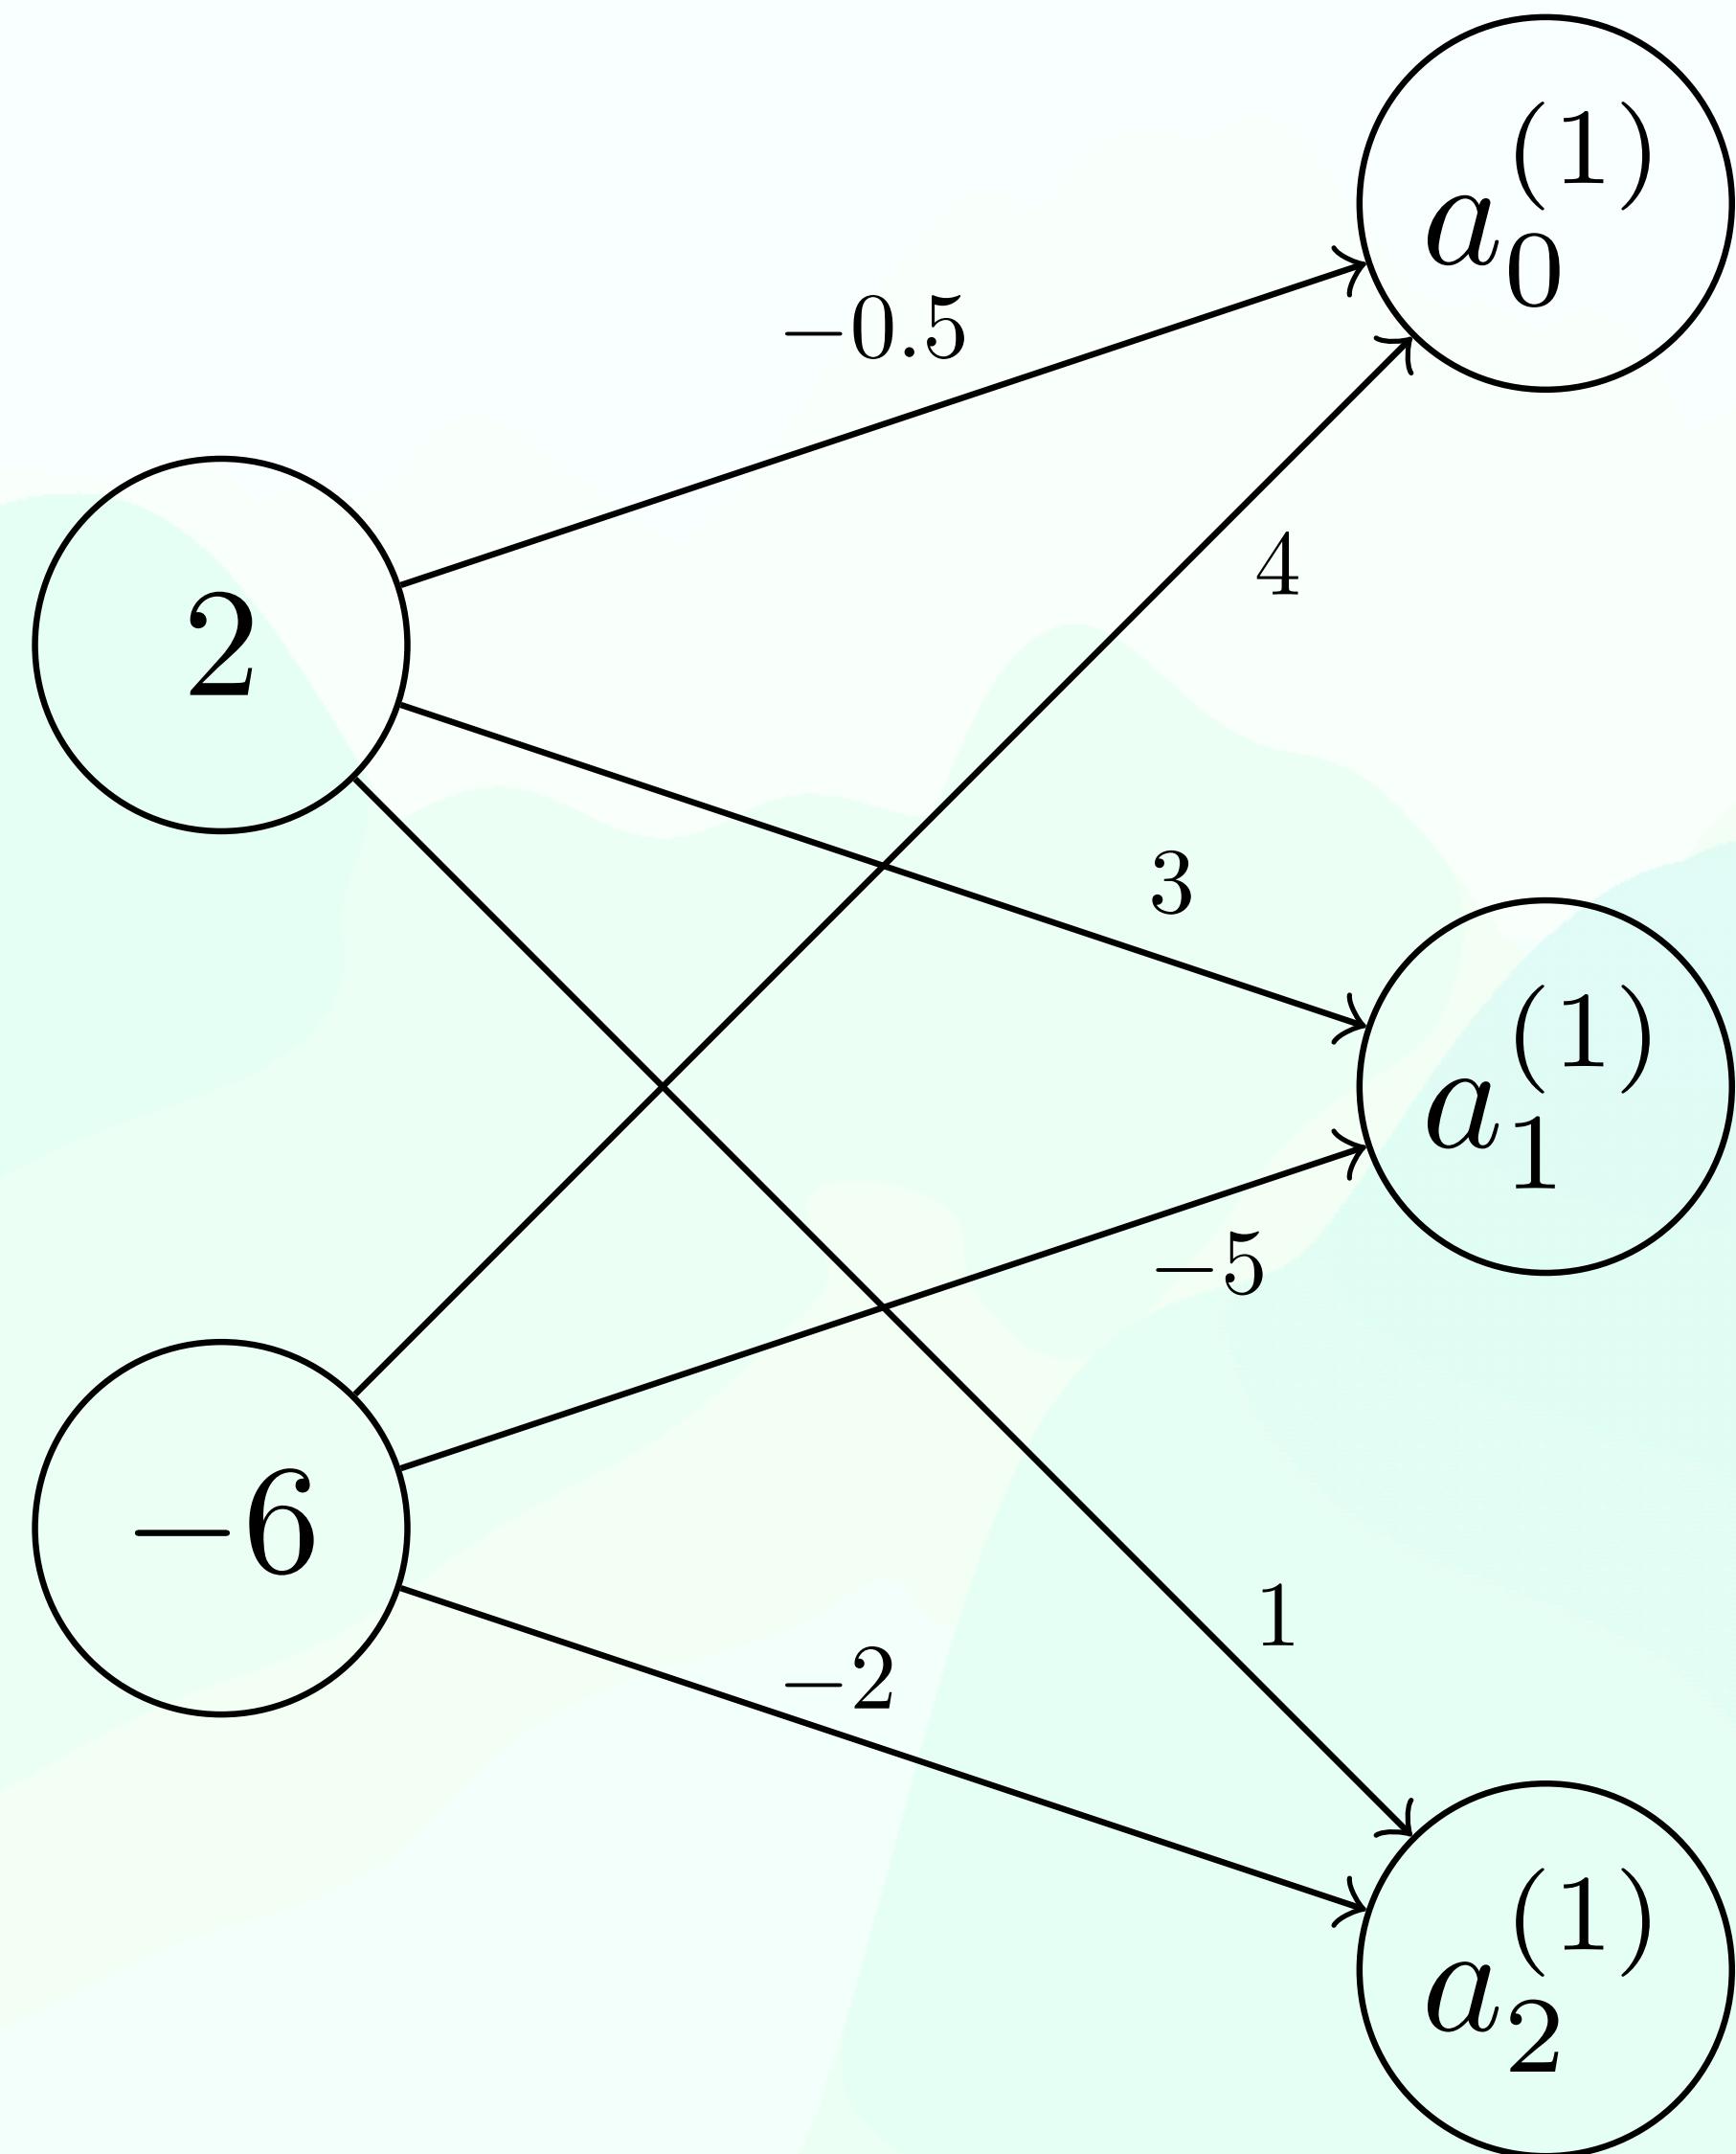
# Matrixmultiplikation – Beispiel



$$\begin{pmatrix} z_0^{(1)} \\ z_1^{(1)} \\ z_2^{(1)} \end{pmatrix} = \begin{pmatrix} -0.5 & 4 \\ 3 & -5 \\ 1 & -2 \end{pmatrix} \begin{pmatrix} 2 \\ -6 \end{pmatrix} =$$
$$= \begin{pmatrix} -0.5 \cdot 2 + 4 \cdot (-6) \\ 3 \cdot 2 + (-5) \cdot (-6) \\ 1 \cdot 2 + (-2) \cdot (-6) \end{pmatrix} = \begin{pmatrix} -25 \\ 36 \\ 14 \end{pmatrix}$$

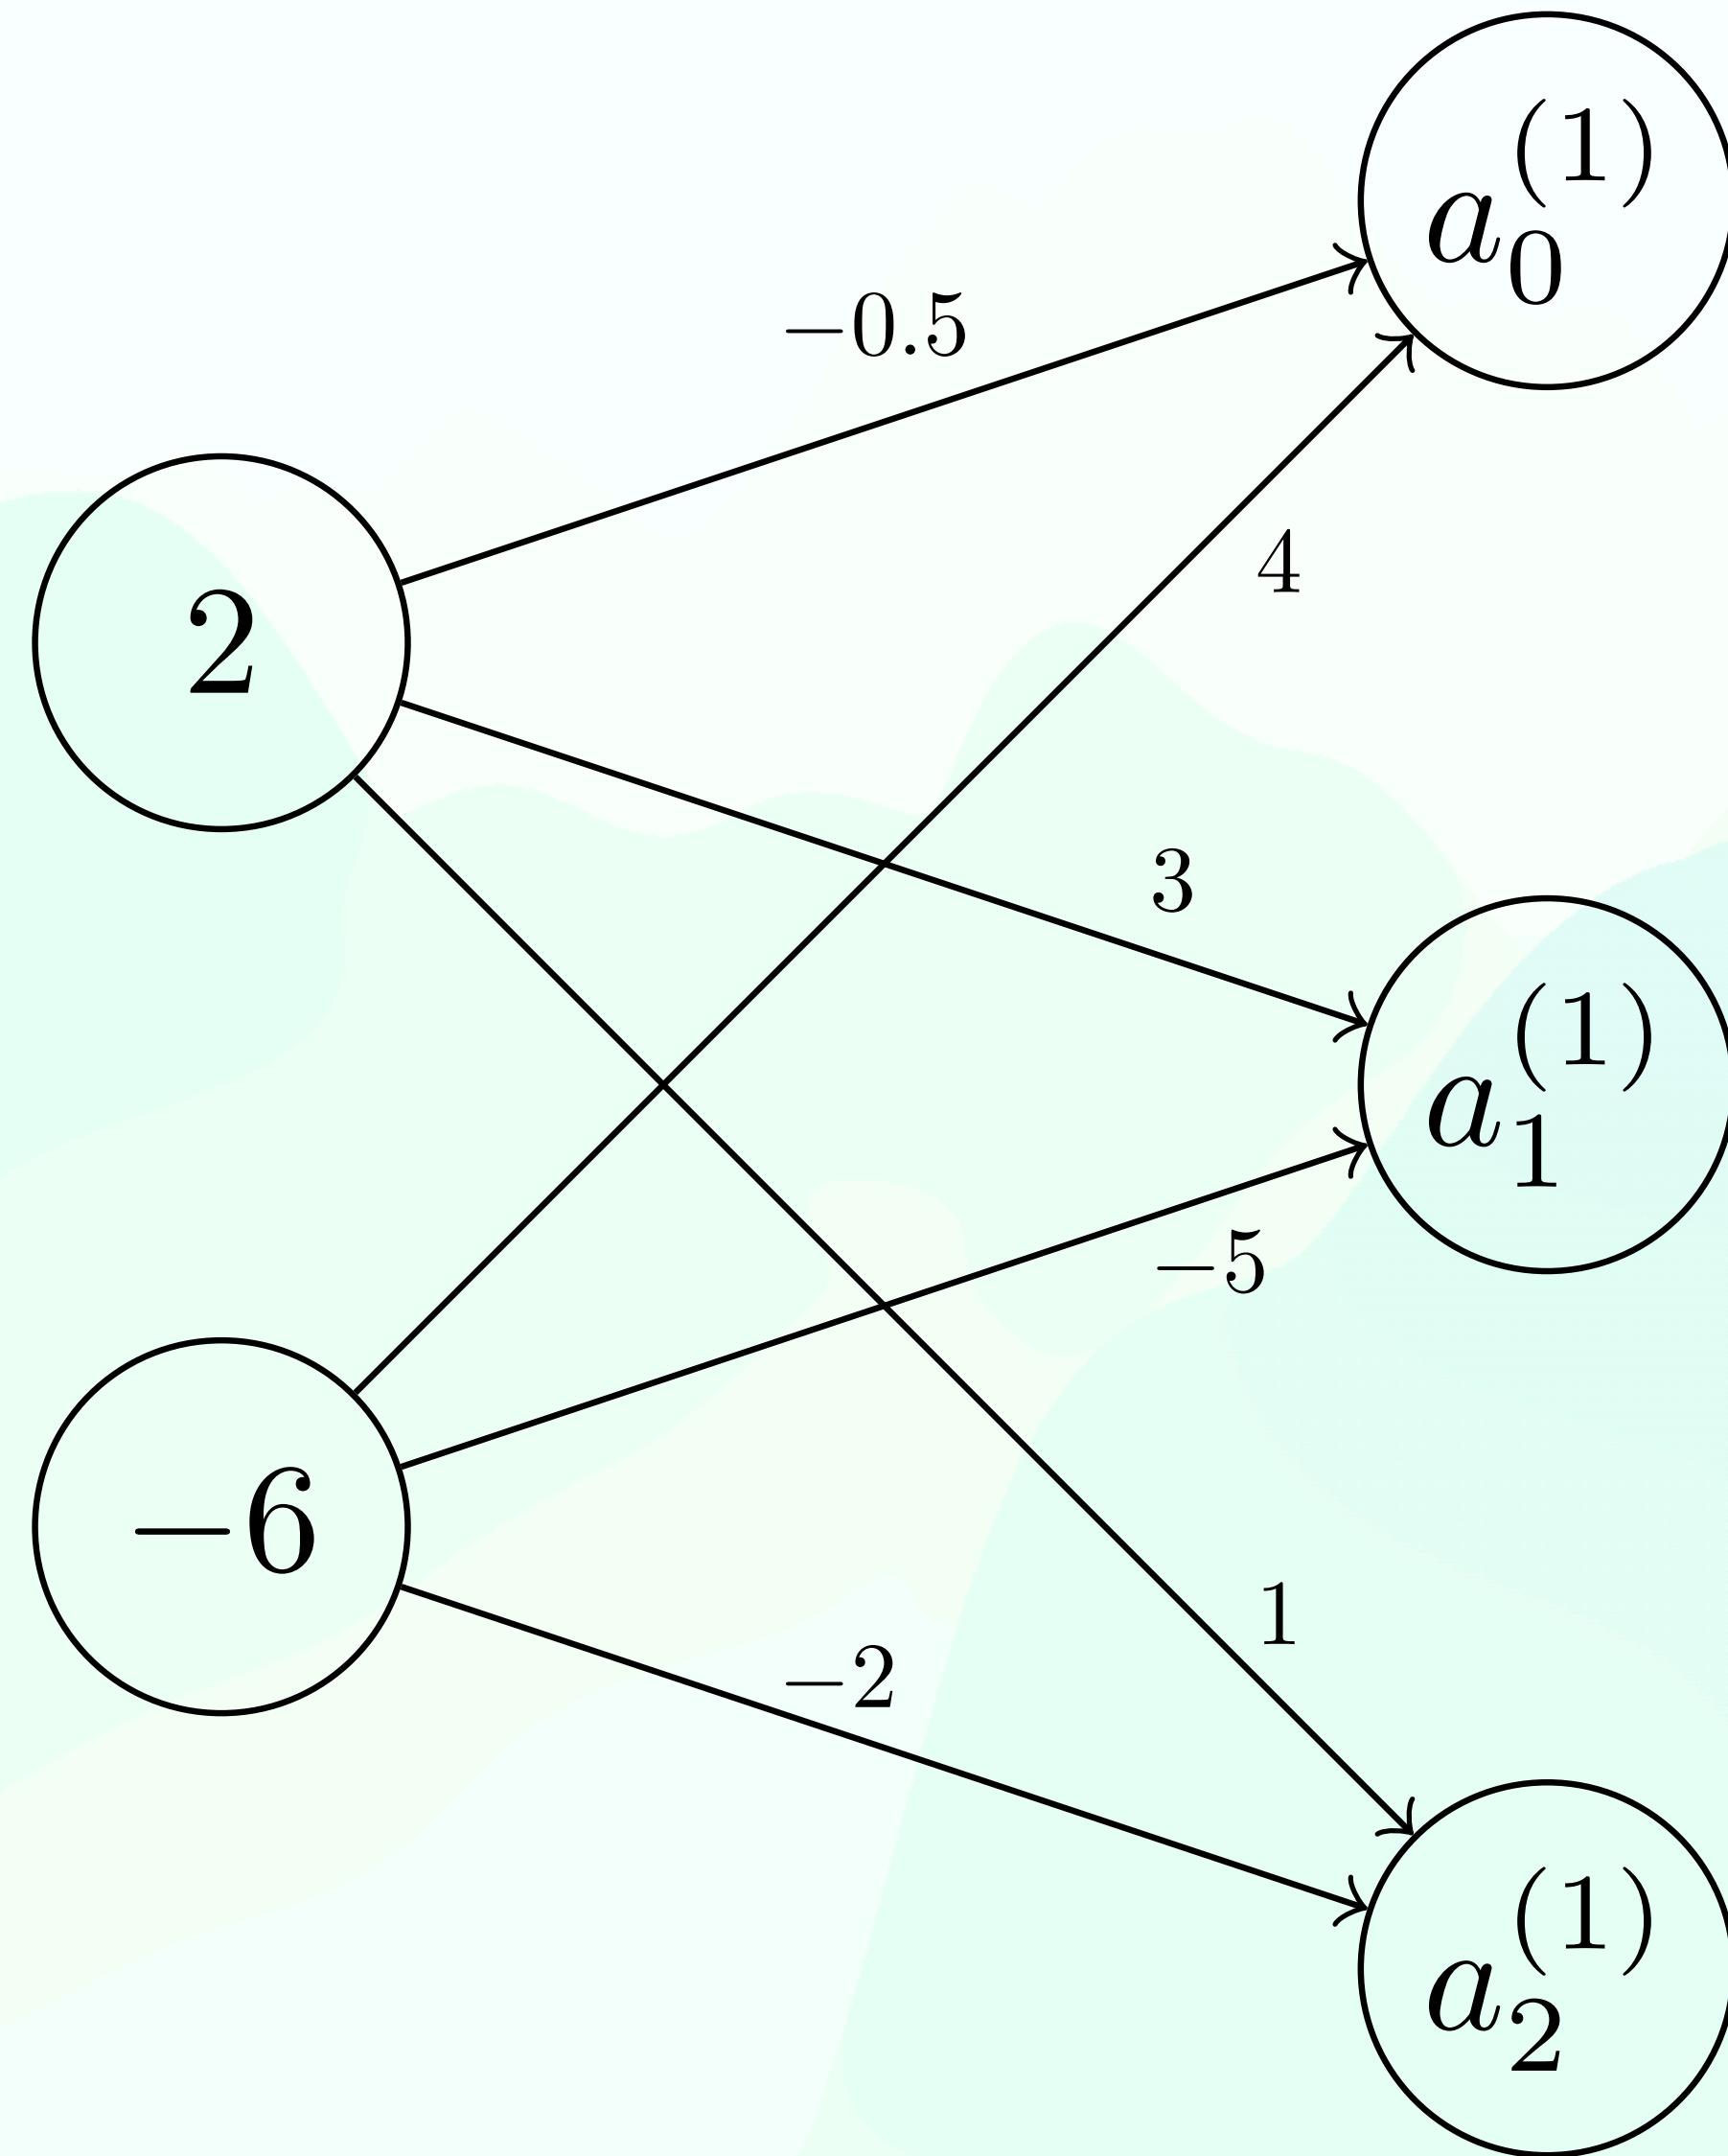
- Ergebnis der Multiplikation der **Gewichtsmatrix** mit dem **Aktivierungsvektor** ist die **gewichtete Summe  $z$**

# Feedforward-Schritt



- Aktivierung ergibt sich durch Aufruf der Aktivierungsfunktion  $\sigma$  mit gewichteter Summe  $z$

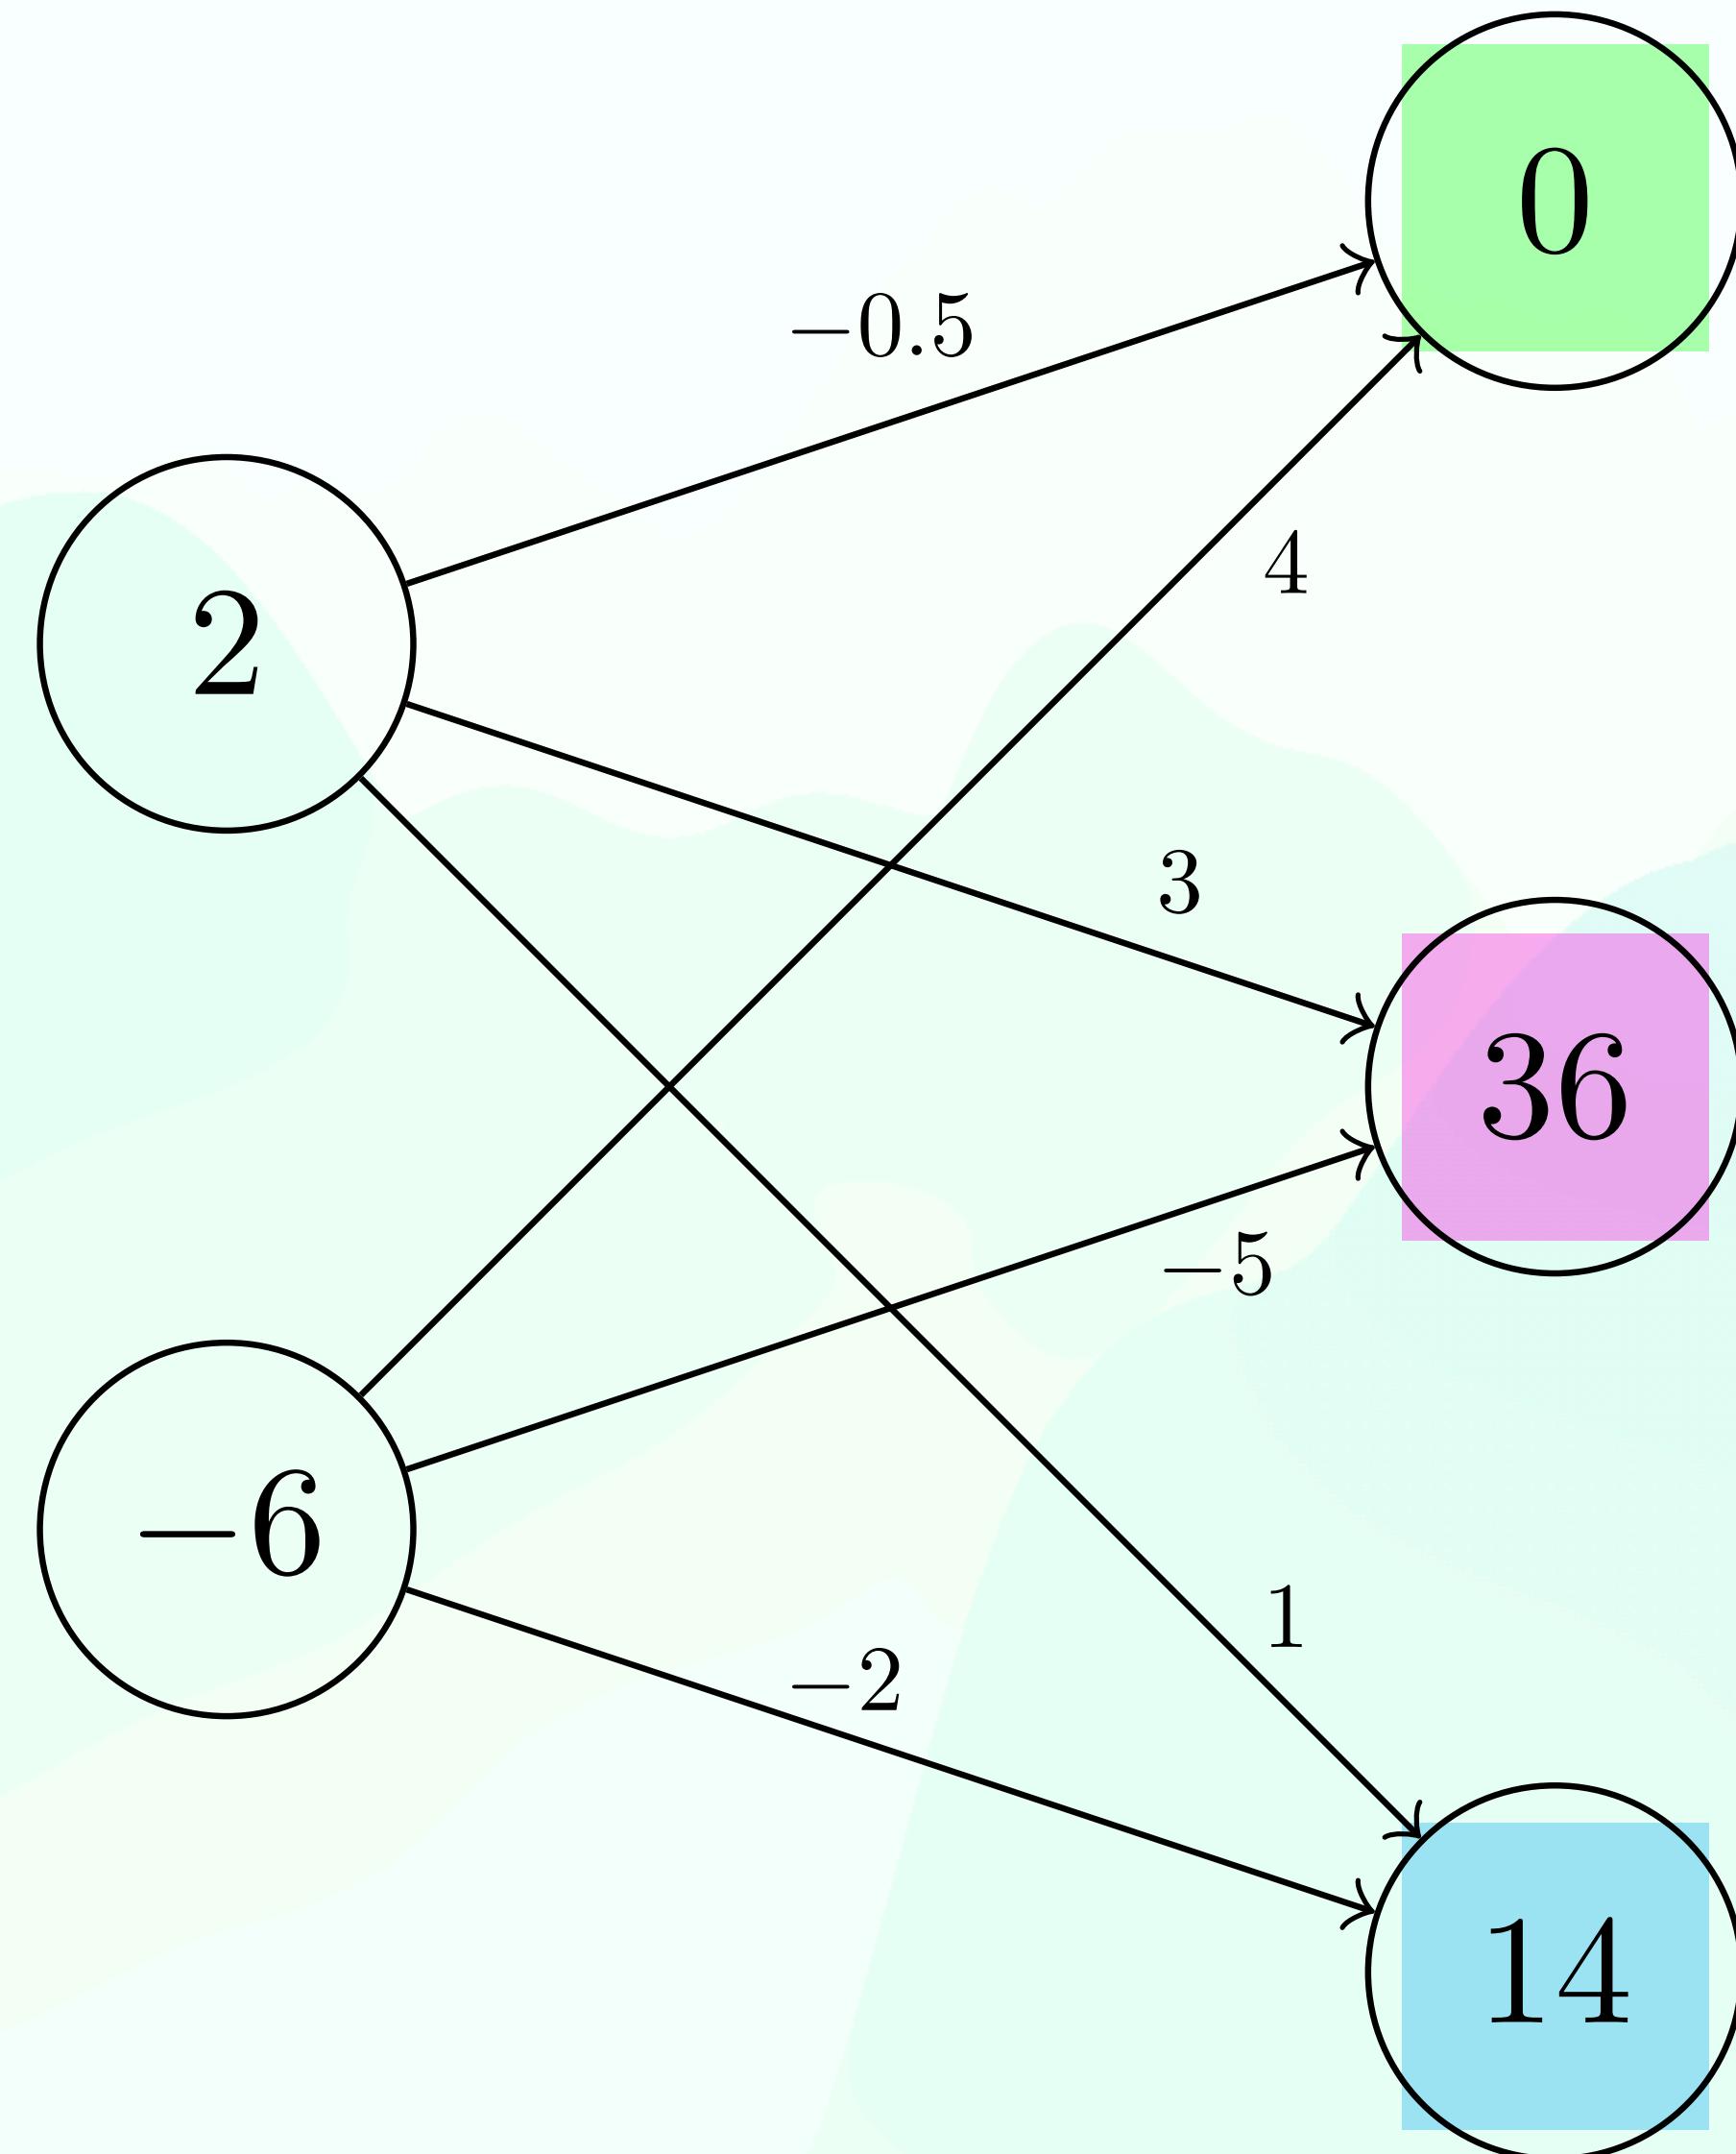
# Feedforward-Schritt



- Aktivierung ergibt sich durch Aufruf der Aktivierungsfunktion  $\sigma$  mit gewichteter Summe  $z$
- Wir verwenden hier  $\sigma = \text{ReLU}$

$$\begin{pmatrix} a_0^{(1)} \\ a_1^{(1)} \\ a_2^{(1)} \end{pmatrix} = \text{ReLU} \left[ \begin{pmatrix} z_0^{(1)} \\ z_1^{(1)} \\ z_2^{(1)} \end{pmatrix} \right]$$
$$= \text{ReLU} \left[ \begin{pmatrix} -25 \\ 36 \\ 14 \end{pmatrix} \right] = \begin{pmatrix} 0 \\ 36 \\ 14 \end{pmatrix}$$

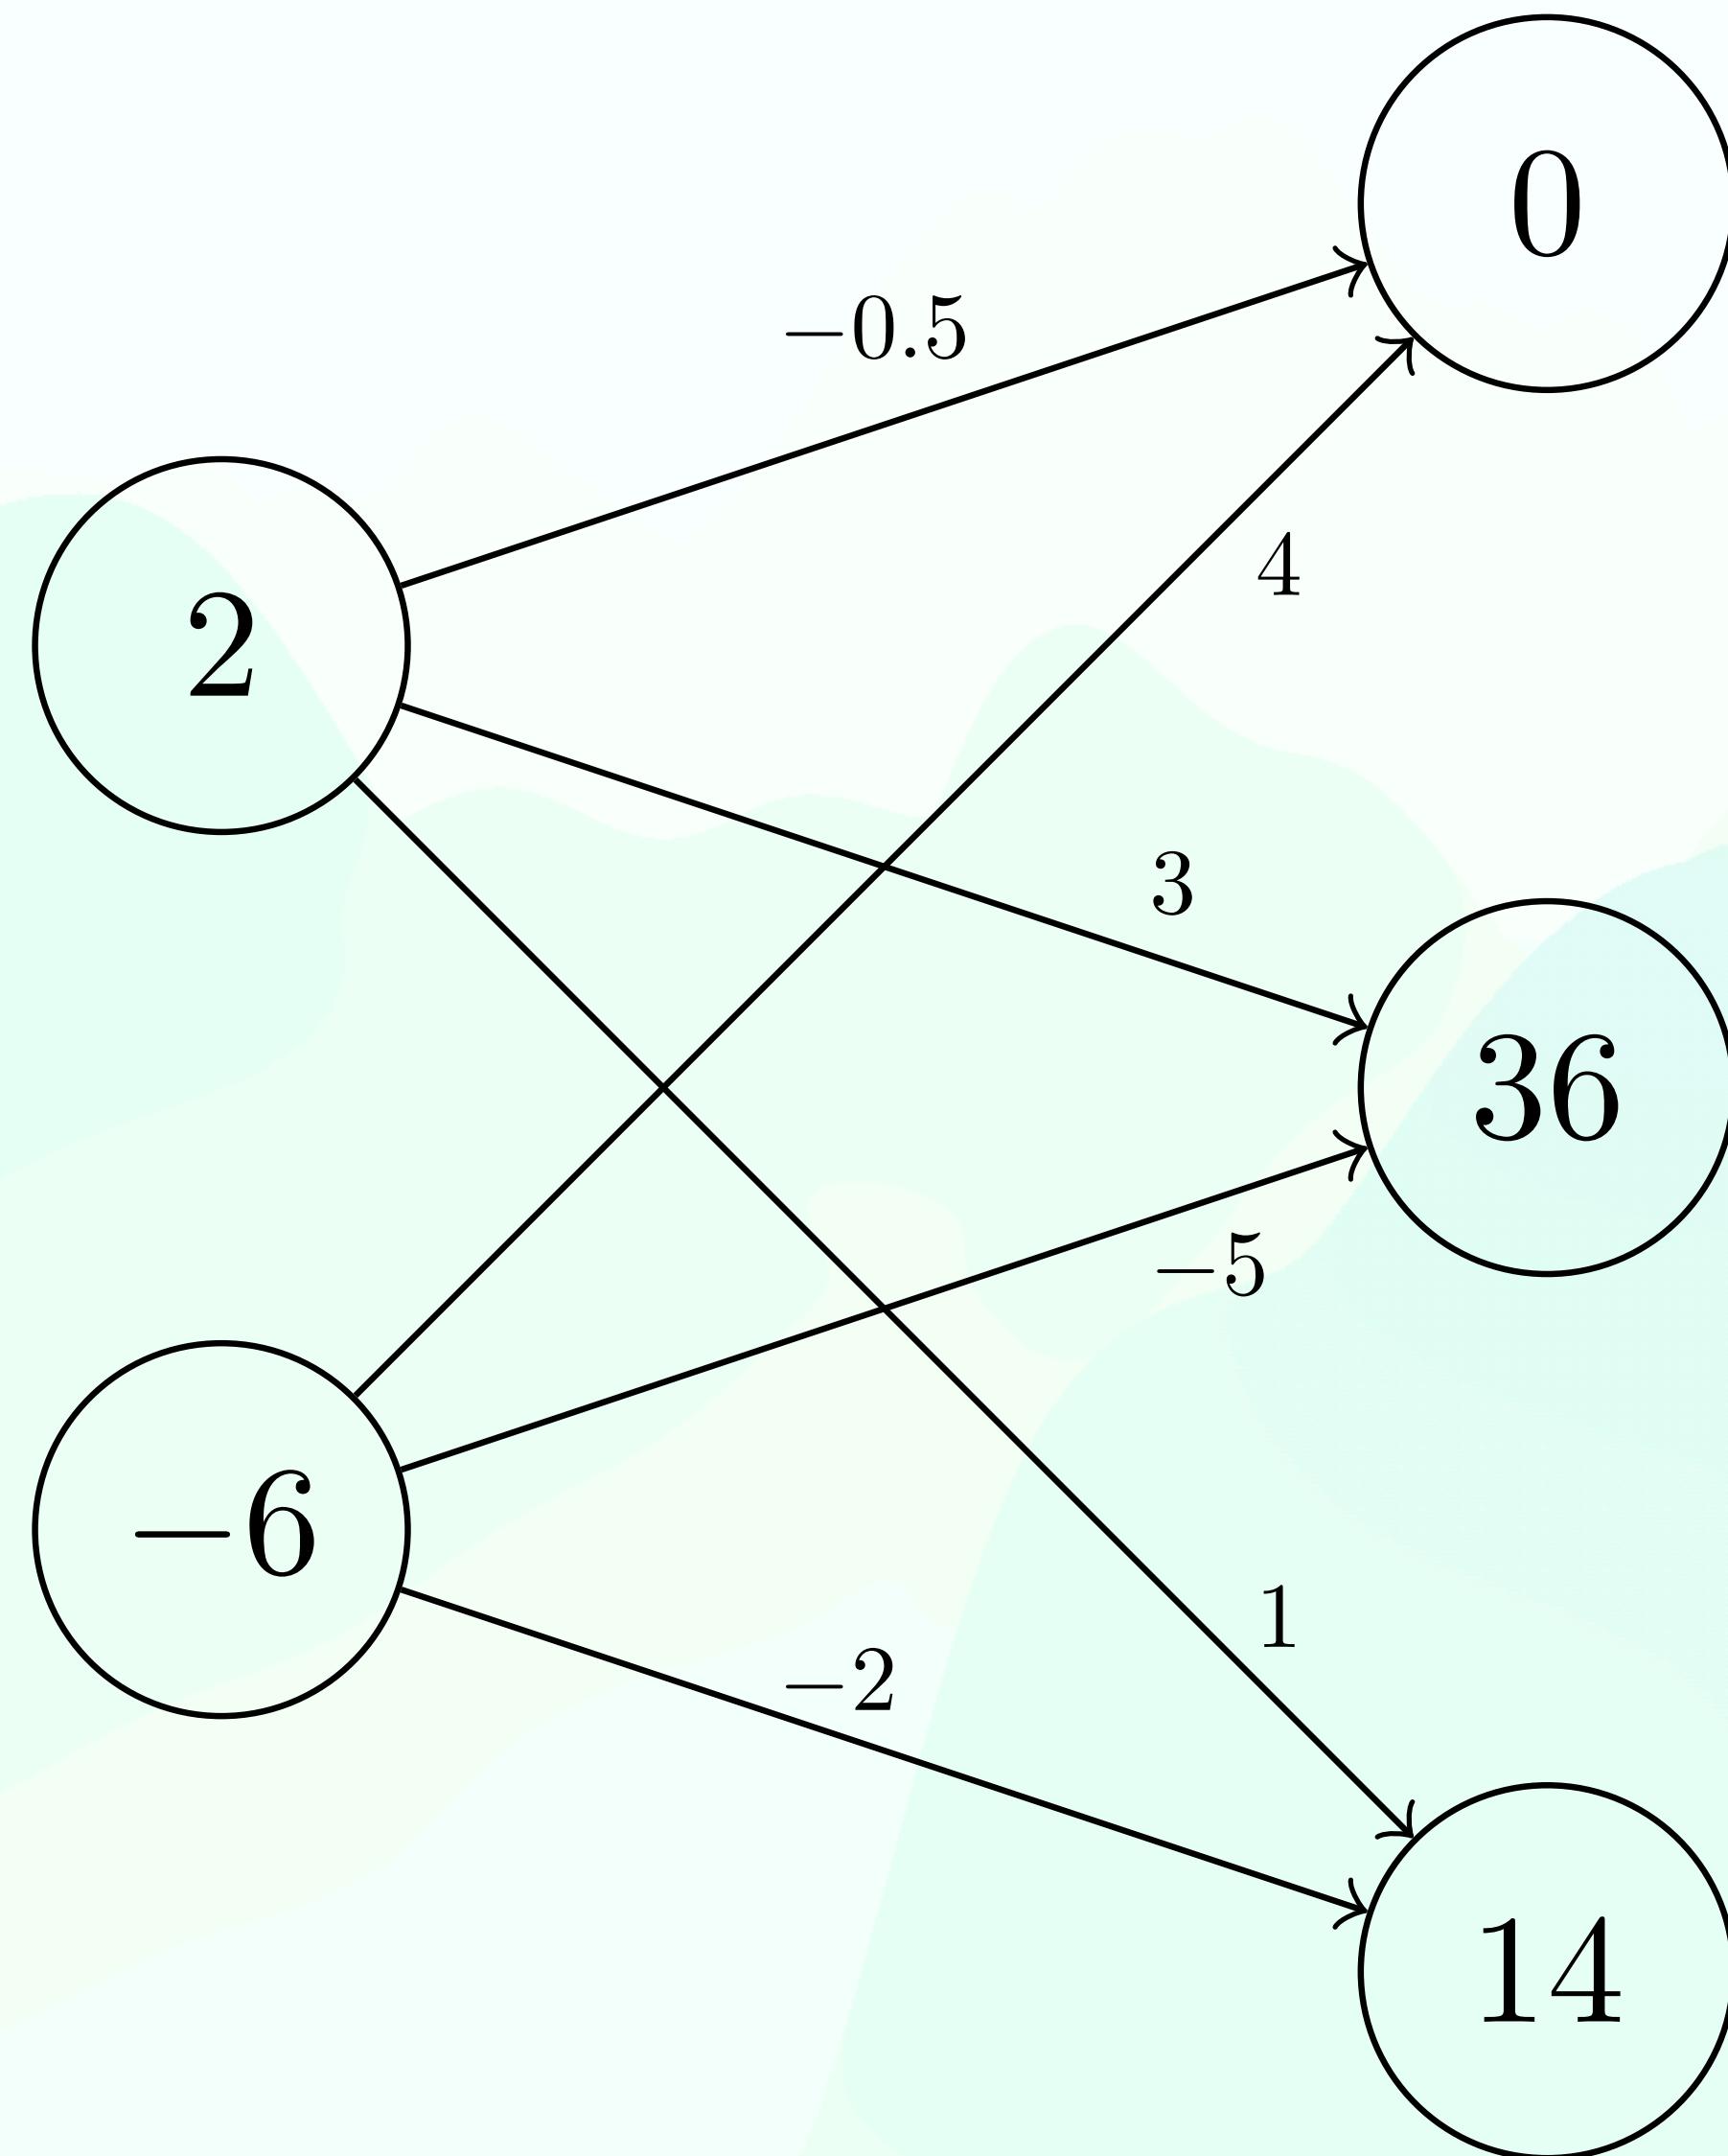
# Feedforward-Schritt



- Aktivierung ergibt sich durch Aufruf der Aktivierungsfunktion  $\sigma$  mit gewichteter Summe  $z$
- Wir verwenden hier  $\sigma = \text{ReLU}$

$$\begin{pmatrix} a_0^{(1)} \\ a_1^{(1)} \\ a_2^{(1)} \end{pmatrix} = \text{ReLU} \left[ \begin{pmatrix} z_0^{(1)} \\ z_1^{(1)} \\ z_2^{(1)} \end{pmatrix} \right]$$
$$= \text{ReLU} \left[ \begin{pmatrix} -25 \\ 36 \\ 14 \end{pmatrix} \right] = \begin{pmatrix} 0 \\ 36 \\ 14 \end{pmatrix}$$

# Feedforward-Schritt



- Diese Berechnungsschritte werden jeweils von einem Layer zum nächsten wiederholt, bis am Output-Layer die **Prediction** vorliegt

# Erweiterung des Konstruktors um Aktivierungsfunktionen



```
def __init__(  
    self,  
    structure,  
    output_activation_func=relu,  
    hidden_activation_func=sigmoid,  
):  
    self.structure = structure  
    self.output_activation_func = output_activation_func  
    self.hidden_activation_func = hidden_activation_func  
    self.__init_layers()  
    self.__init_weights()
```

# Erweiterung des Konstruktors um Aktivierungsfunktionen



```
def __init__(  
    self,  
    structure,  
    output_activation_func=relu,  
    hidden_activation_func=sigmoid,  
):  
    self.structure = structure  
    self.output_activation_func = output_activation_func  
    self.hidden_activation_func = hidden_activation_func  
    self.__init_layers()  
    self.__init_weights()
```

Zunächst fügen wir unserem Konstruktor zwei weitere Parameter für die Aktivierungsfunktionen in Output- und Hidden Layer hinzu.

Diesmal sind die Parameter allerdings **optional**: Übergeben wir bei der Objekterzeugung nichts, würden als **Default**-Werte die ReLU-Funktion im Output-Layer und die Sigmoid-Funktion im Hidden Layer verwendet werden.

# Erweiterung des Konstruktors um Aktivierungsfunktionen



```
def __init__(  
    self,  
    structure,  
    output_activation_func=relu,  
    hidden_activation_func=sigmoid,  
):  
    self.structure = structure  
    self.output_activation_func = output_activation_func  
    self.hidden_activation_func = hidden_activation_func  
    self.__init_layers()  
    self.__init_weights()
```

Die übergebenen Parameter (bzw. deren Defaultwerte) weisen wir gleichnamigen Eigenschaften des NeuralNetwork-Objekts zu.

# Prediction mit Feedforward-Algorithmus erzeugen



```
def predict(self, X):
    if len(X) != self.structure[0]:
        raise Exception("Falsche Anzahl an Input-Werten übergeben")

    self.activations[0][1:] = X

    for l in range(1, len(self.structure)):
        self.weighted_sums[l][:] = numpy.matmul(self.weights[l], self.activations[l-1])

        if l == len(self.structure) - 1:
            self.activations[l][:] = self.output_activation_func(self.weighted_sums[l])
        else:
            self.activations[l][1:] = self.hidden_activation_func(self.weighted_sums[l])

    return self.activations[-1]
```

# Prediction mit Feedforward-Algorithmus erzeugen



```
def predict(self, X):
    if len(X) != self.structure[0]:
        raise Exception("Falsche Anzahl an Input-Werten übergeben")

    self.activations[0][1:] = X

    for l in range(1, len(self.structure)):
        self.weighted_sums[l][:] = numpy.matmul(self.weights[l], self.activations[l-1])

        if l == len(self.structure) - 1:
            self.activations[l][:] = self.output_activation_func(self.weighted_sums[l])
        else:
            self.activations[l][1:] = self.hidden_activation_func(self.weighted_sums[l])

    return self.activations[-1]
```

Wir deklarieren die Methode `predict`, diesmal nicht als privat, denn sie soll von außerhalb der Klasse aufrufbar sein. Ihr soll als Parameter ein Vektor `X` mit den Inputs übergeben werden, für die eine Vorhersage berechnet werden soll.

# Prediction mit Feedforward-Algorithmus erzeugen



```
def predict(self, X):
    if len(X) != self.structure[0]:
        raise Exception("Falsche Anzahl an Input-Werten übergeben")

    self.activations[0][1:] = X

    for l in range(1, len(self.structure)):
        self.weighted_sums[l][:] = numpy.matmul(self.weights[l], self.activations[l-1])

        if l == len(self.structure) - 1:
            self.activations[l][:] = self.output_activation_func(self.weighted_sums[l])
        else:
            self.activations[l][1:] = self.hidden_activation_func(self.weighted_sums[l])

    return self.activations[-1]
```

Zuerst prüfen wir, ob die Anzahl der übergebenen Inputs gleich der Anzahl der Input-Neuronen abzüglich einem Bias-Neuron ist.

Falls nicht, erzeugen wir eine Fehlermeldung mit einer `Exception`.

# Prediction mit Feedforward-Algorithmus erzeugen



```
def predict(self, X):
    if len(X) != self.structure[0]:
        raise Exception("Falsche Anzahl an Input-Werten übergeben")

    self.activations[0][1:] = X

    for l in range(1, len(self.structure)):
        self.weighted_sums[l][:] = numpy.matmul(self.weights[l], self.activations[l-1])

        if l == len(self.structure) - 1:
            self.activations[l][:] = self.output_activation_func(self.weighted_sums[l])
        else:
            self.activations[l][1:] = self.hidden_activation_func(self.weighted_sums[l])

    return self.activations[-1]
```

Ist der Test bestanden, belegen wir den ersten Layer unseres Netzes (den mit dem Index 0) mit den übergebenen Input-Aktivierungen. Dabei müssen wir allerdings das Bias-Neuron unangetastet lassen.

# Prediction mit Feedforward-Algorithmus erzeugen



```
def predict(self, X):
    if len(X) != self.structure[0]:
        raise Exception("Falsche Anzahl an Input-Werten übergeben")

    self.activations[0][1:] = X

    for l in range(1, len(self.structure)):
        self.weighted_sums[l][:] = numpy.matmul(self.weights[l], self.activations[l-1])

        if l == len(self.structure) - 1:
            self.activations[l][:] = self.output_activation_func(self.weighted_sums[l])
        else:
            self.activations[l][1:] = self.hidden_activation_func(self.weighted_sums[l])

    return self.activations[-1]
```

Dazu verwenden wir die Slice-Syntax von numpy. Wir überschreiben im Aktivierungsvektor nur die Einträge ab dem Index 1.

# Prediction mit Feedforward-Algorithmus erzeugen



```
def predict(self, X):
    if len(X) != self.structure[0]:
        raise Exception("Falsche Anzahl an Input-Werten übergeben")

    self.activations[0][1:] = X

    for l in range(1, len(self.structure)):
        self.weighted_sums[l][:] = numpy.matmul(self.weights[l], self.activations[l-1])

        if l == len(self.structure) - 1:
            self.activations[l][:] = self.output_activation_func(self.weighted_sums[l])
        else:
            self.activations[l][1:] = self.hidden_activation_func(self.weighted_sums[l])

    return self.activations[-1]
```

Für die weiteren Layer benutzen wir wieder eine **for**-Schleife, beginnend beim Index 1 (dem des ersten Hidden-Layers). Wieder gibt uns die Laufvariable **l** den Index des jeweils aktuellen Layers an.

# Prediction mit Feedforward-Algorithmus erzeugen



```
def predict(self, X):
    if len(X) != self.structure[0]:
        raise Exception("Falsche Anzahl an Input-Werten übergeben")

    self.activations[0][1:] = X

    for l in range(1, len(self.structure)):
        self.weighted_sums[l][:] = numpy.matmul(self.weights[l], self.activations[l-1])

        if l == len(self.structure) - 1:
            self.activations[l][:] = self.output_activation_func(self.weighted_sums[l])
        else:
            self.activations[l][1:] = self.hidden_activation_func(self.weighted_sums[l])

    return self.activations[-1]
```

Zunächst berechnen wir im aktuellen Layer  $l$  die gewichteten Summen als Produkte seiner Gewichtsmatrix und des Aktivierungsvektors des vorherigen Layers  $l-1$ . Die Matrixmultiplikation wird dabei von `numpy.matmul` erledigt.

# Prediction mit Feedforward-Algorithmus erzeugen



```
def predict(self, X):
    if len(X) != self.structure[0]:
        raise Exception("Falsche Anzahl an Input-Werten übergeben")

    self.activations[0][1:] = X

    for l in range(1, len(self.structure)):
        self.weighted_sums[l][:] = numpy.matmul(self.weights[l], self.activations[l-1])

        if l == len(self.structure) - 1:
            self.activations[l][:] = self.output_activation_func(self.weighted_sums[l])
        else:
            self.activations[l][1:] = self.hidden_activation_func(self.weighted_sums[l])

    return self.activations[-1]
```

Wir wollen den Vektor bei jedem Durchlauf Wiederverwenden und überschreiben nur seine Elemente, daher der nach vorne und hinten offene Slice.

# Prediction mit Feedforward-Algorithmus erzeugen



```
def predict(self, X):
    if len(X) != self.structure[0]:
        raise Exception("Falsche Anzahl an Input-Werten übergeben")

    self.activations[0][1:] = X

    for l in range(1, len(self.structure)):
        self.weighted_sums[l][:] = numpy.matmul(self.weights[l], self.activations[l-1])

        if l == len(self.structure) - 1:
            self.activations[l][:] = self.output_activation_func(self.weighted_sums[l])
        else:
            self.activations[l][1:] = self.hidden_activation_func(self.weighted_sums[l])

    return self.activations[-1]
```

Anschließend berechnen wir die Aktivierungen. Für den Output-Layer (identifizierbar am Index  $l$ ) rufen wir dafür die beim Erzeugen des Netzes übergebene Output-Aktivierungsfunktion mit dem soeben berechneten Vektor der gewichteten Summen auf.

# Prediction mit Feedforward-Algorithmus erzeugen



```
def predict(self, X):
    if len(X) != self.structure[0]:
        raise Exception("Falsche Anzahl an Input-Werten übergeben")

    self.activations[0][1:] = X

    for l in range(1, len(self.structure)):
        self.weighted_sums[l][:] = numpy.matmul(self.weights[l], self.activations[l-1])

        if l == len(self.structure) - 1:
            self.activations[l][:] = self.output_activation_func(self.weighted_sums[l])
        else:
            self.activations[l][1:] = self.hidden_activation_func(self.weighted_sums[l])

    return self.activations[-1]
```

Auch hier verwenden wir den Vektor wieder und überschreiben alle Elemente darin mithilfe des offenen Slices.

# Prediction mit Feedforward-Algorithmus erzeugen



```
def predict(self, X):
    if len(X) != self.structure[0]:
        raise Exception("Falsche Anzahl an Input-Werten übergeben")

    self.activations[0][1:] = X

    for l in range(1, len(self.structure)):
        self.weighted_sums[l][:] = numpy.matmul(self.weights[l], self.activations[l-1])

        if l == len(self.structure) - 1:
            self.activations[l][:] = self.output_activation_func(self.weighted_sums[l])
        else:
            self.activations[l][1:] = self.hidden_activation_func(self.weighted_sums[l])

    return self.activations[-1]
```

Auf dieselbe Weise berechnen wir die Aktivierungen der Hidden-Layer für alle anderen Indizes  $l$  und rufen dabei die andere übergebene Aktivierungsfunktion auf.

# Prediction mit Feedforward-Algorithmus erzeugen



```
def predict(self, X):
    if len(X) != self.structure[0]:
        raise Exception("Falsche Anzahl an Input-Werten übergeben")

    self.activations[0][1:] = X

    for l in range(1, len(self.structure)):
        self.weighted_sums[l][:] = numpy.matmul(self.weights[l], self.activations[l-1])

        if l == len(self.structure) - 1:
            self.activations[l][:] = self.output_activation_func(self.weighted_sums[l])
        else:
            self.activations[l][1:] = self.hidden_activation_func(self.weighted_sums[l])

    return self.activations[-1]
```

Hier müssen wir darauf achten, die Aktivierung des Bias-Neurons des Hidden-Layers nicht zu überschreiben. Dazu lassen wir den Slice erst ab Index 1 beginnen.

# Prediction mit Feedforward-Algorithmus erzeugen



```
def predict(self, X):
    if len(X) != self.structure[0]:
        raise Exception("Falsche Anzahl an Input-Werten übergeben")

    self.activations[0][1:] = X

    for l in range(1, len(self.structure)):
        self.weighted_sums[l][:] = numpy.matmul(self.weights[l], self.activations[l-1])

        if l == len(self.structure) - 1:
            self.activations[l][:] = self.output_activation_func(self.weighted_sums[l])
        else:
            self.activations[l][1:] = self.hidden_activation_func(self.weighted_sums[l])

    return self.activations[-1]
```

Nachdem die Schleife auf diese Weise die Aktivierungen in allen Layern berechnet hat, geben wir die **Aktivierungen des Output-Layers** zurück. Sie enthalten die **Prediction** unseres neuronalen Netzes.

# Prediction mit Feedforward-Algorithmus erzeugen



```
def predict(self, X):
    if len(X) != self.structure[0]:
        raise Exception("Falsche Anzahl an Input-Werten übergeben")

    self.activations[0][1:] = X

    for l in range(1, len(self.structure)):
        self.weighted_sums[l][:] = numpy.matmul(self.weights[l], self.activations[l-1])

    if l == len(self.structure) - 1:
        self.activations[l][:] = self.output_activation_func(self.weighted_sums[l])
    else:
        self.activations[l][1:] = self.hidden_activation_func(self.weighted_sums[l])

return self.activations[-1]
```

Um das letzte Element der Liste activations zu erhalten, verwenden wir den Index `-1`.

# Erster Test des Prediction-Algorithmus



```
if __name__ == '__main__':
    nn = NeuralNetwork(structure=[3, 4, 2])
    X = numpy.array([[0.7], [0.1], [0.5]])
    prediction = nn.predict(X)
    print(prediction)
```

# Erster Test des Prediction-Algorithmus



```
if __name__ == '__main__':
    nn = NeuralNetwork(structure=[3, 4, 2])
    X = numpy.array([[0.7], [0.1], [0.5]])
    prediction = nn.predict(X)
    print(prediction)
```

Wir legen einen Vektor mit irgendwelchen Input-Daten an. Wichtig ist nur, dass er genau so viele Elemente enthält, wie es der erste Eintrag des Parameters `structure` vorgibt — denn er bestimmt die Zahl der Input-Neuronen.

# Erster Test des Prediction-Algorithmus



```
if __name__ == '__main__':
    nn = NeuralNetwork(structure=[3, 4, 2])
    X = numpy.array([[0.7], [0.1], [0.5]])
    prediction = nn.predict(X)
    print(prediction)
```

Für unseren Input-Vektor  $X$  lassen wir eine Vorhersage berechnen und speichern sie in der Variable `prediction`.

# Erster Test des Prediction-Algorithmus



```
if __name__ == '__main__':
    nn = NeuralNetwork(structure=[3, 4, 2])
    X = numpy.array([[0.7], [0.1], [0.5]])
    prediction = nn.predict(X)
    print(prediction)
```

Wir geben mit einem einfachen `print` die Vorhersage auf der Konsole aus. Sie ist ein zweielementiger Vektor, da `structure` genau zwei Output-Neuronen vorsieht. Da die Gewichte in unserem Netz mit Zufallszahlen vorbelegt werden, hängt auch dieses Ergebnis vom Zufall ab.

# Kostenfunktion

- Gibt ein Maß für die Genauigkeit der Prediction an
- Gegeben: berechnete ( $A^{(l)}$ ) und erwartete ( $Y$ ) Aktivierung der Neuronen im Output-Layer

# Kostenfunktion

- Gibt ein Maß für die Genauigkeit der Prediction an
- Gegeben: berechnete ( $A^{(l)}$ ) und erwartete ( $Y$ ) Aktivierung der Neuronen im Output-Layer
- Kostenfunktion **Squared Error Loss (SEL)** berechnet das Quadrat der Differenz:

$$C_i = (A^{(l)} - Y)^2 = \left[ \begin{pmatrix} a_0^{(l)} \\ a_1^{(l)} \\ \vdots \\ a_n^{(l)} \end{pmatrix} - \begin{pmatrix} y_0 \\ y_1 \\ \vdots \\ y_n \end{pmatrix} \right]^2$$

# Kostenfunktion – Beispiel

- Seien  $A^{(l)}$  die tatsächliche und  $Y$  die erwartete Aktivierung des Output-Layers:

$$A^{(l)} = \begin{pmatrix} 0.9 \\ 0.3 \\ 0.6 \end{pmatrix}$$

$$Y = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}$$

# Kostenfunktion – Beispiel

- Seien  $A^{(l)}$  die tatsächliche und  $Y$  die erwartete Aktivierung des Output-Layers:

$$A^{(l)} = \begin{pmatrix} 0.9 \\ 0.3 \\ 0.6 \end{pmatrix} \quad Y = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}$$

- Dann betragen die Kosten nach **Squared Error Loss**:

$$C = \left[ \begin{pmatrix} 0.9 \\ 0.3 \\ 0.6 \end{pmatrix} - \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} \right]^2 = \begin{pmatrix} -0.1 \\ 0.3 \\ -0.4 \end{pmatrix}^2 = \begin{pmatrix} 0.01 \\ 0.09 \\ 0.16 \end{pmatrix}$$

# Kostenfunktion – Beispiel

- Seien  $A^{(l)}$  die tatsächliche und  $Y$  die erwartete Aktivierung des Output-Layers:

$$A^{(l)} = \begin{pmatrix} 0.9 \\ 0.3 \\ 0.6 \end{pmatrix} \quad Y = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}$$

- Dann betragen die Kosten nach **Squared Error Loss**:

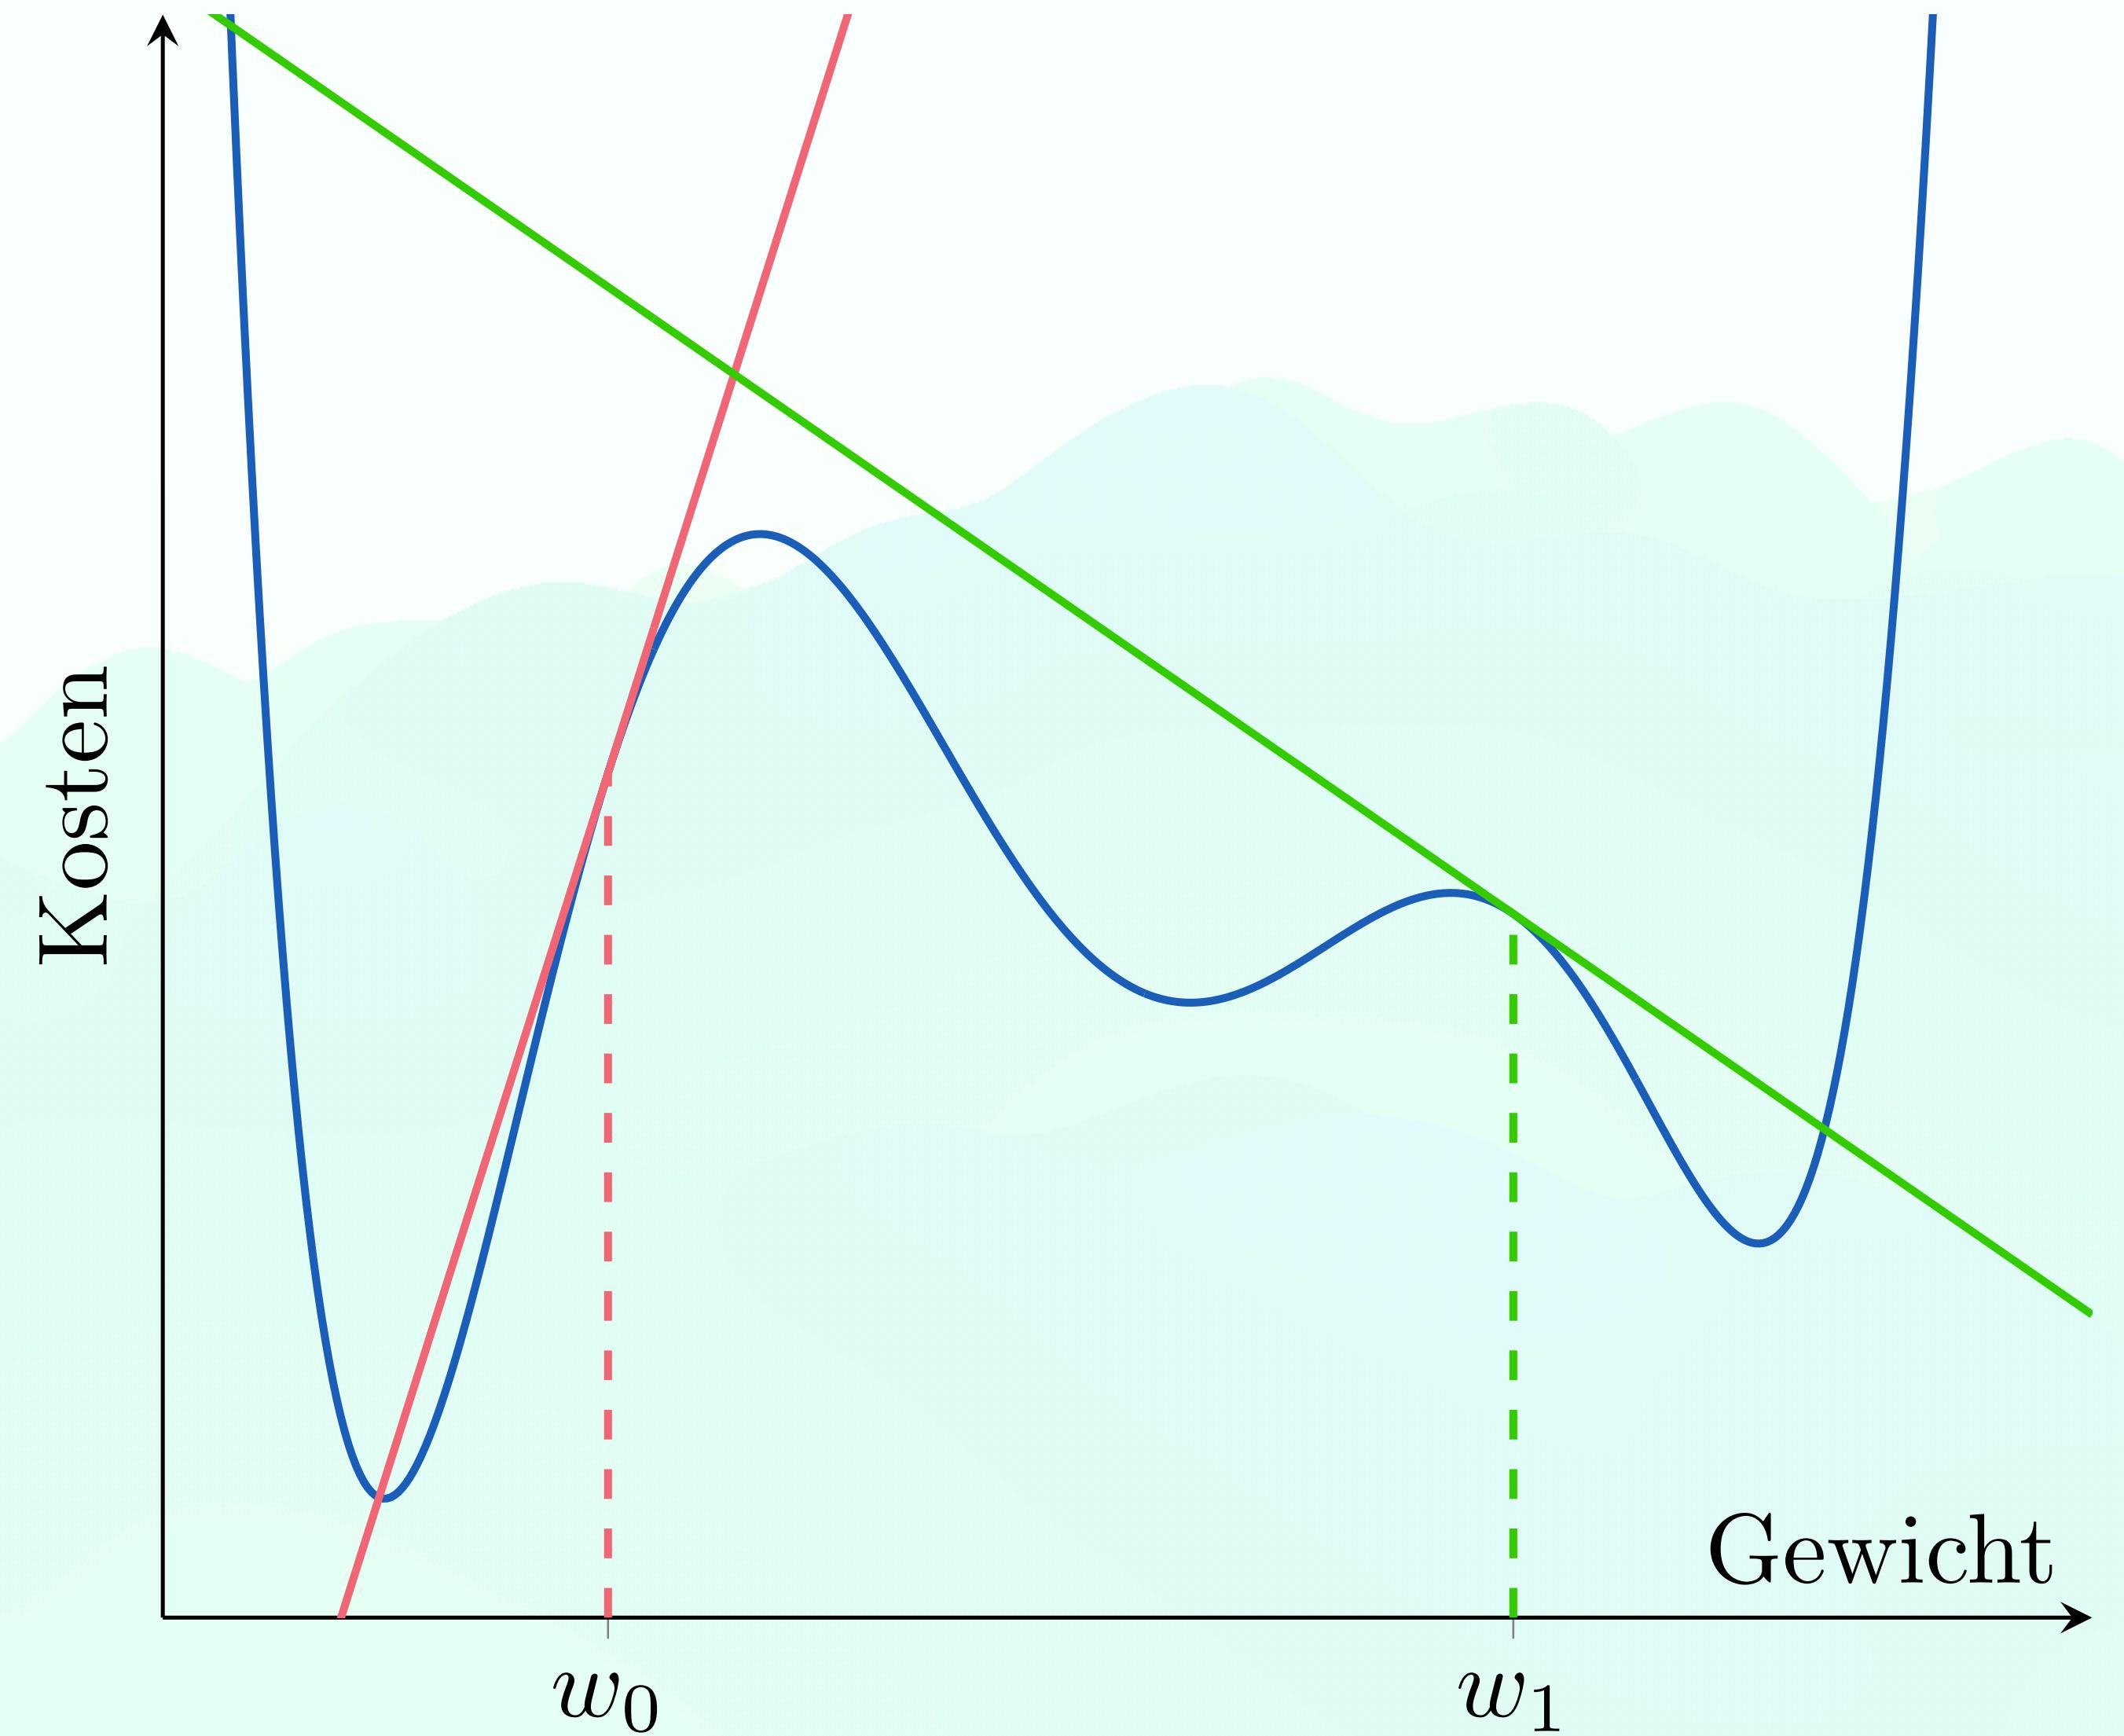
$$C = \left[ \begin{pmatrix} 0.9 \\ 0.3 \\ 0.6 \end{pmatrix} - \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} \right]^2 = \begin{pmatrix} -0.1 \\ 0.3 \\ -0.4 \end{pmatrix}^2 = \begin{pmatrix} 0.01 \\ 0.09 \\ 0.16 \end{pmatrix}$$

Im ersten Neuron am niedrigsten,  
da Abweichung am geringsten

Im dritten Neuron am höchsten,  
da Abweichung am größten

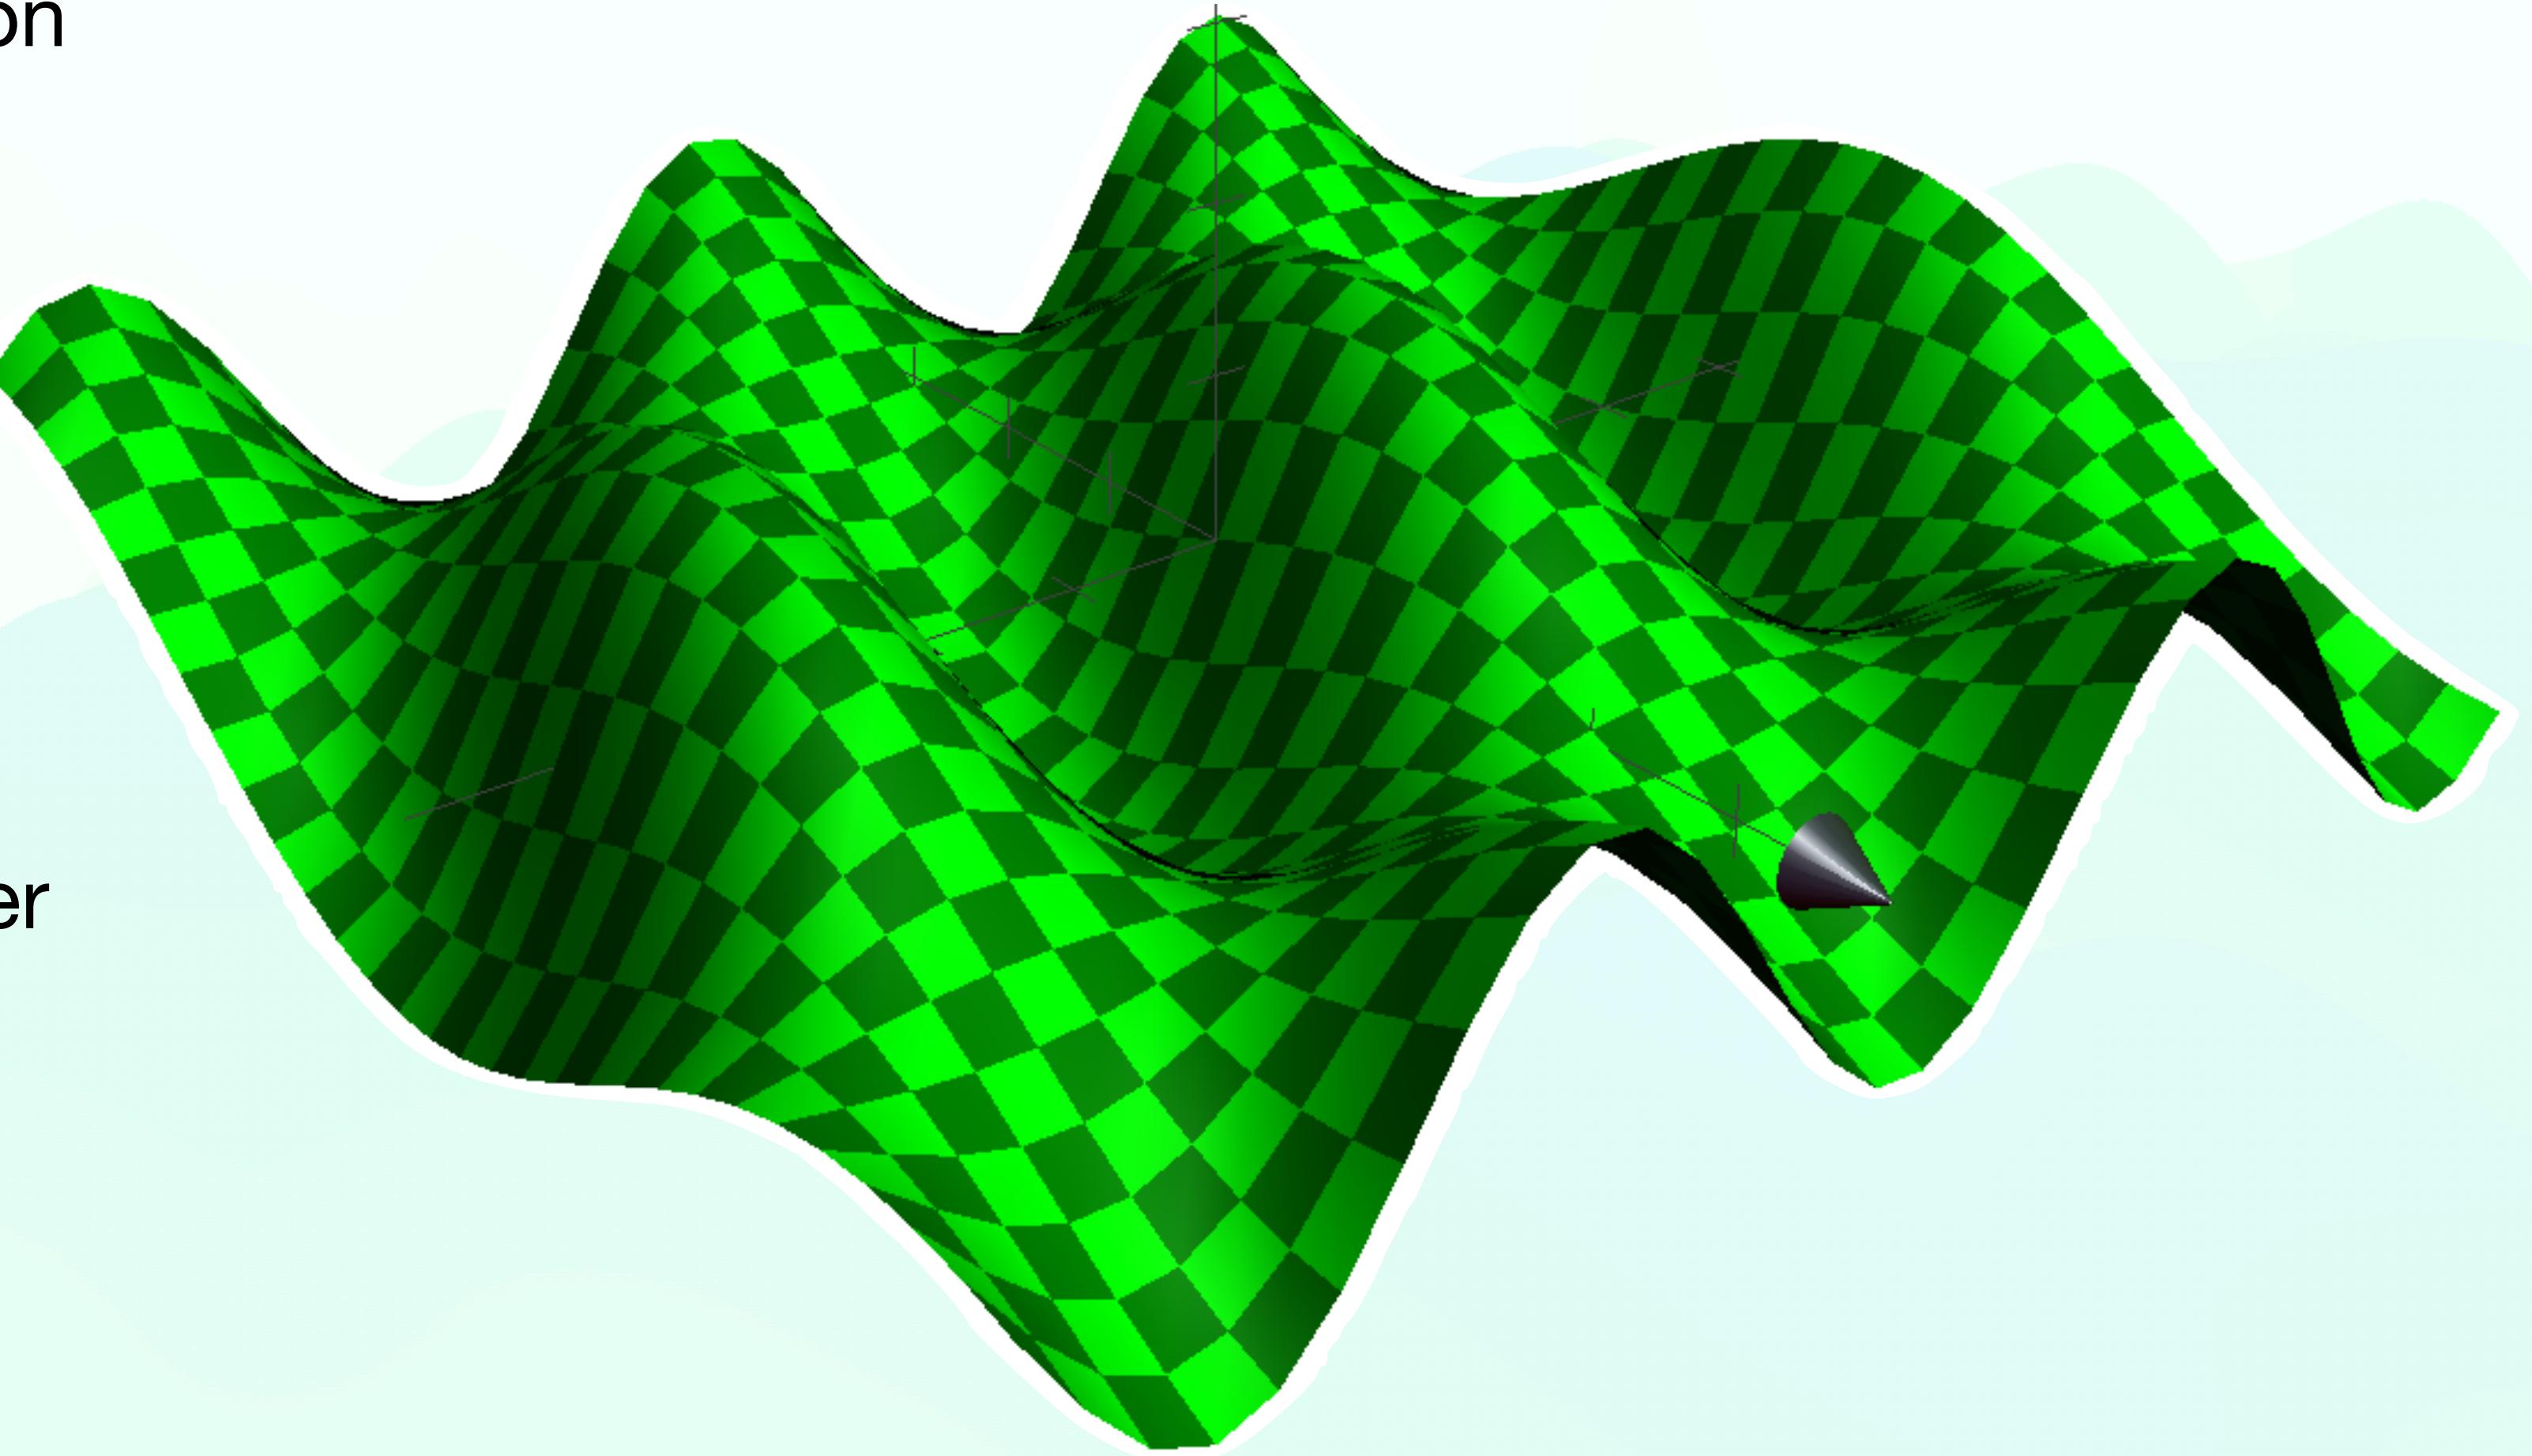
# Kostenfunktion

- Kostenfunktion soll minimiert werden
- **Gradient Descent:** Folge dem Weg des steilsten Abstiegs
- Je steiler der Gradient, desto größer die Schritte
- Neuronale Netze als **Universal Function Approximator**



# Kostenfunktion

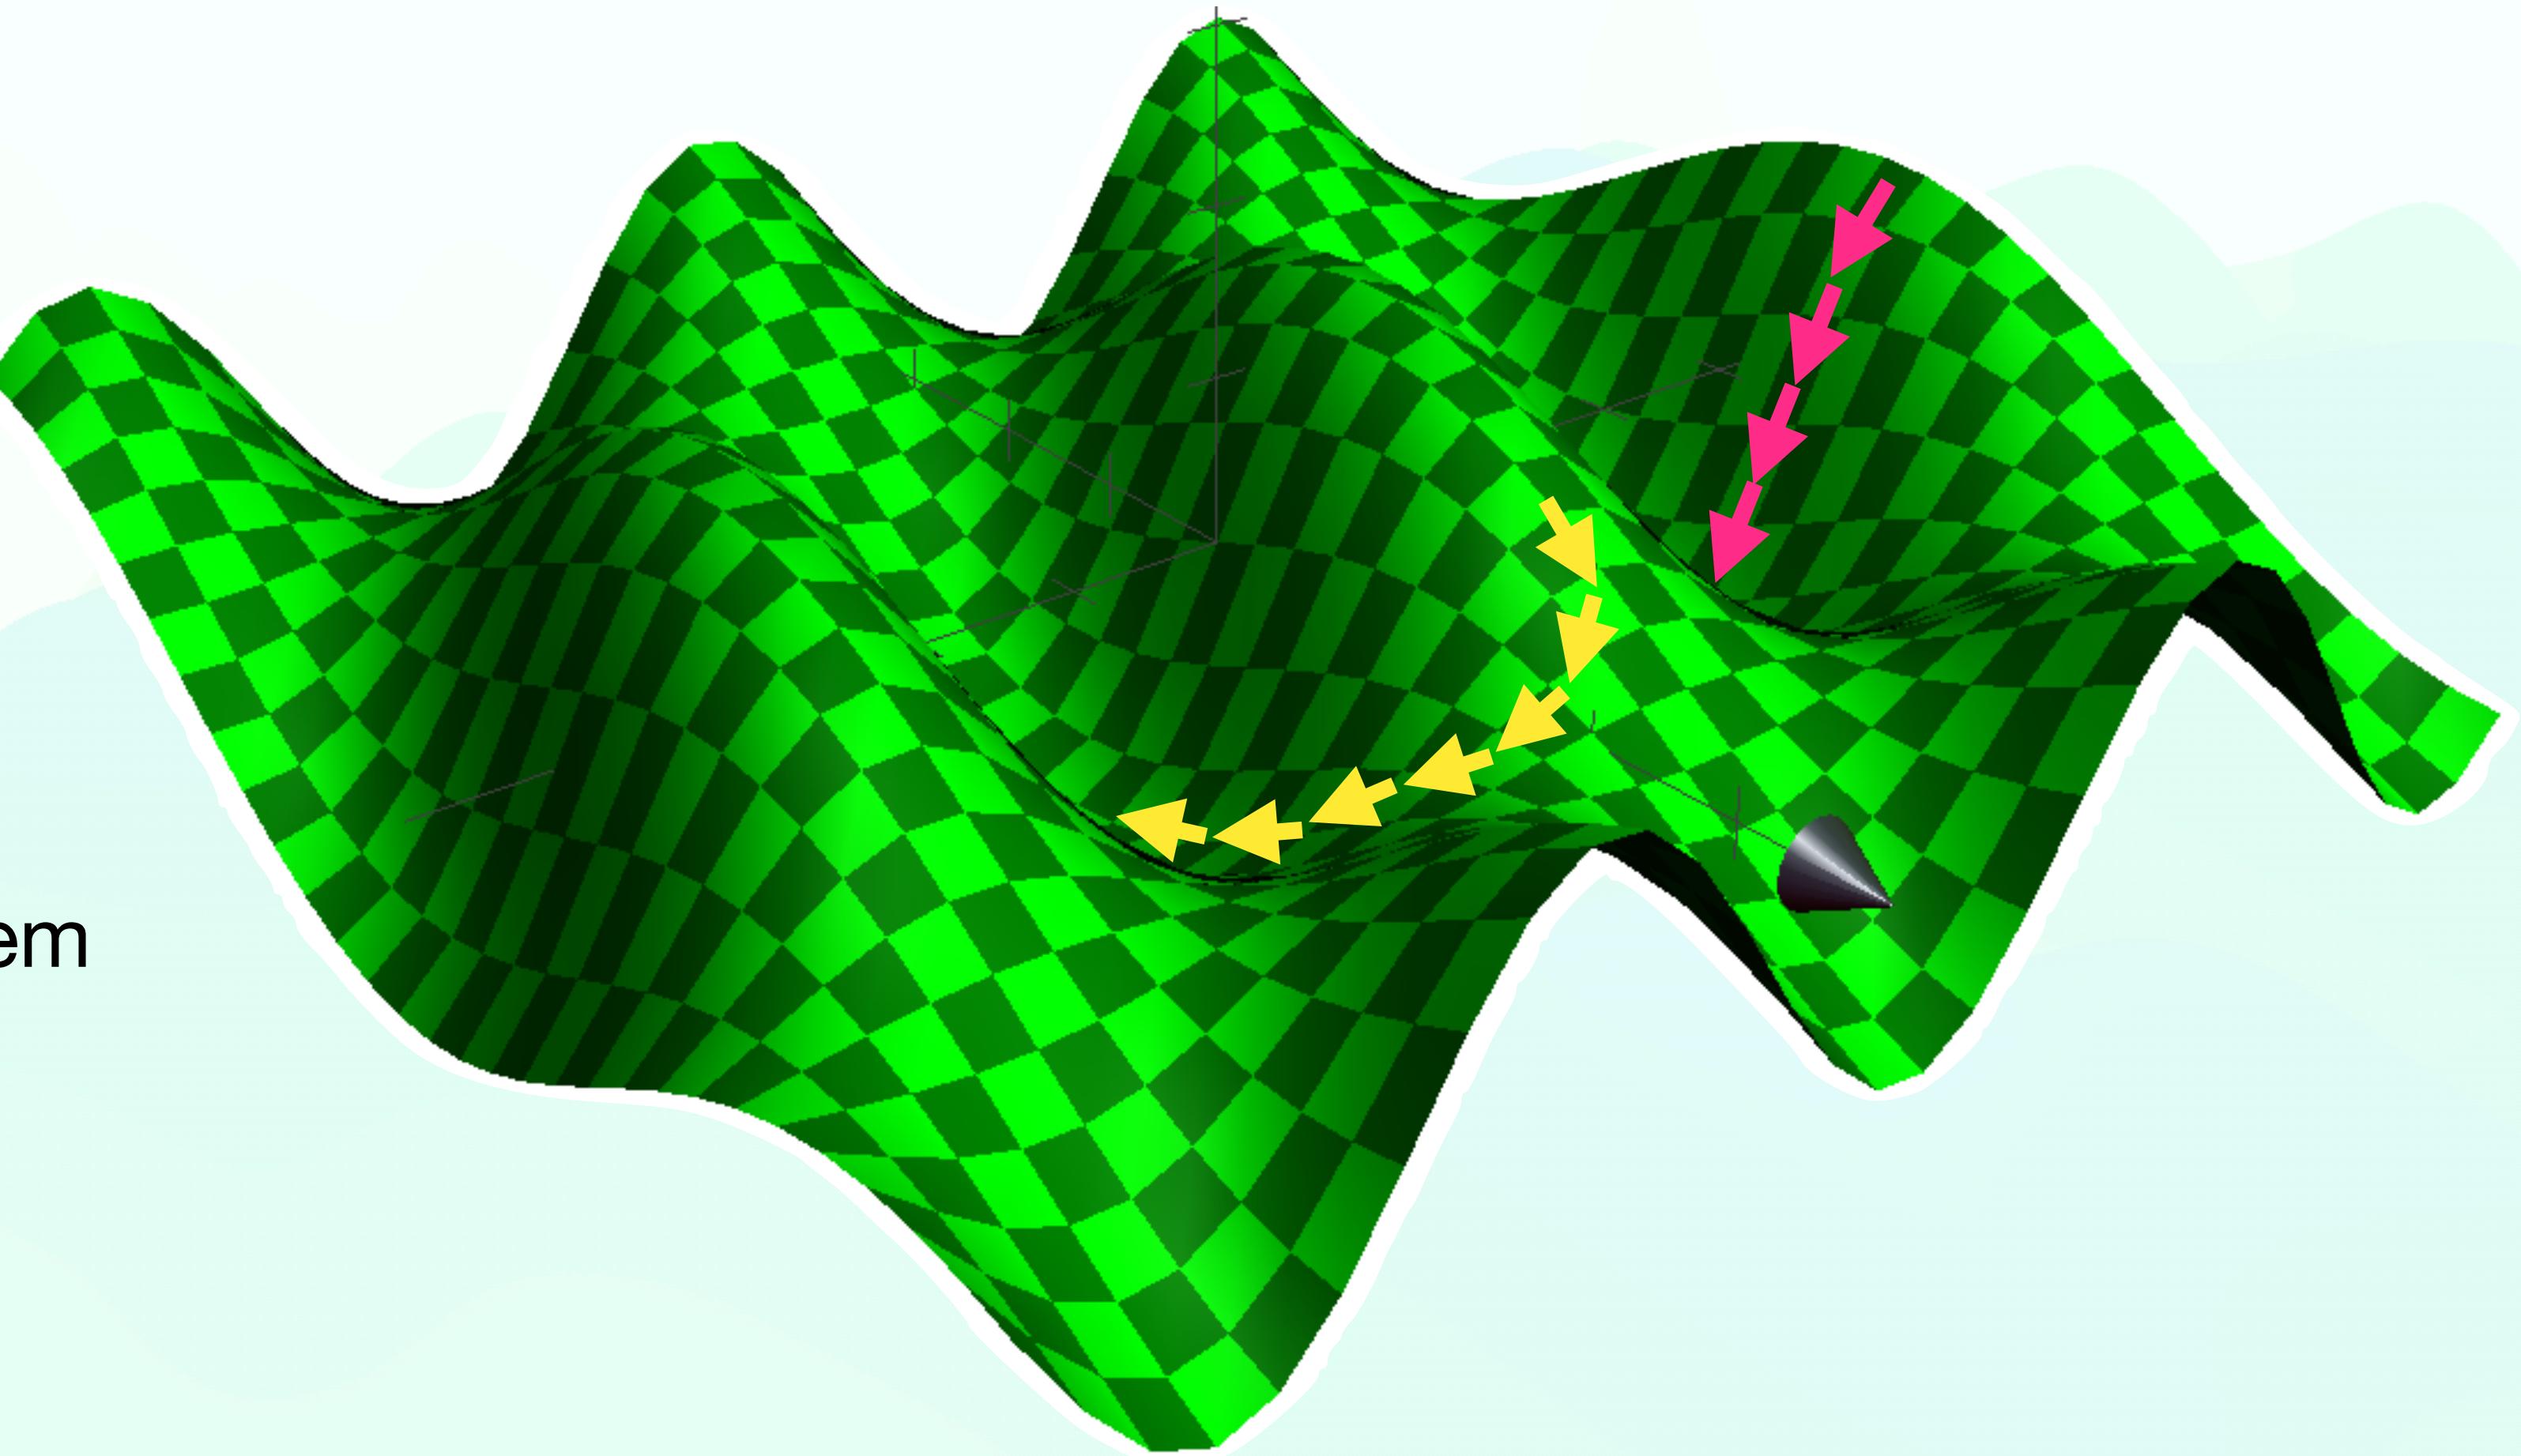
- In der Praxis ist die Kostenfunktion multidimensional
- Keine Garantie, dass Gradient Descent das **globale Minimum** findet
- Forschung zeigt, dass bei gut strukturierten Trainingsdaten die **lokalen Minima** von etwa gleicher Qualität sind [1]



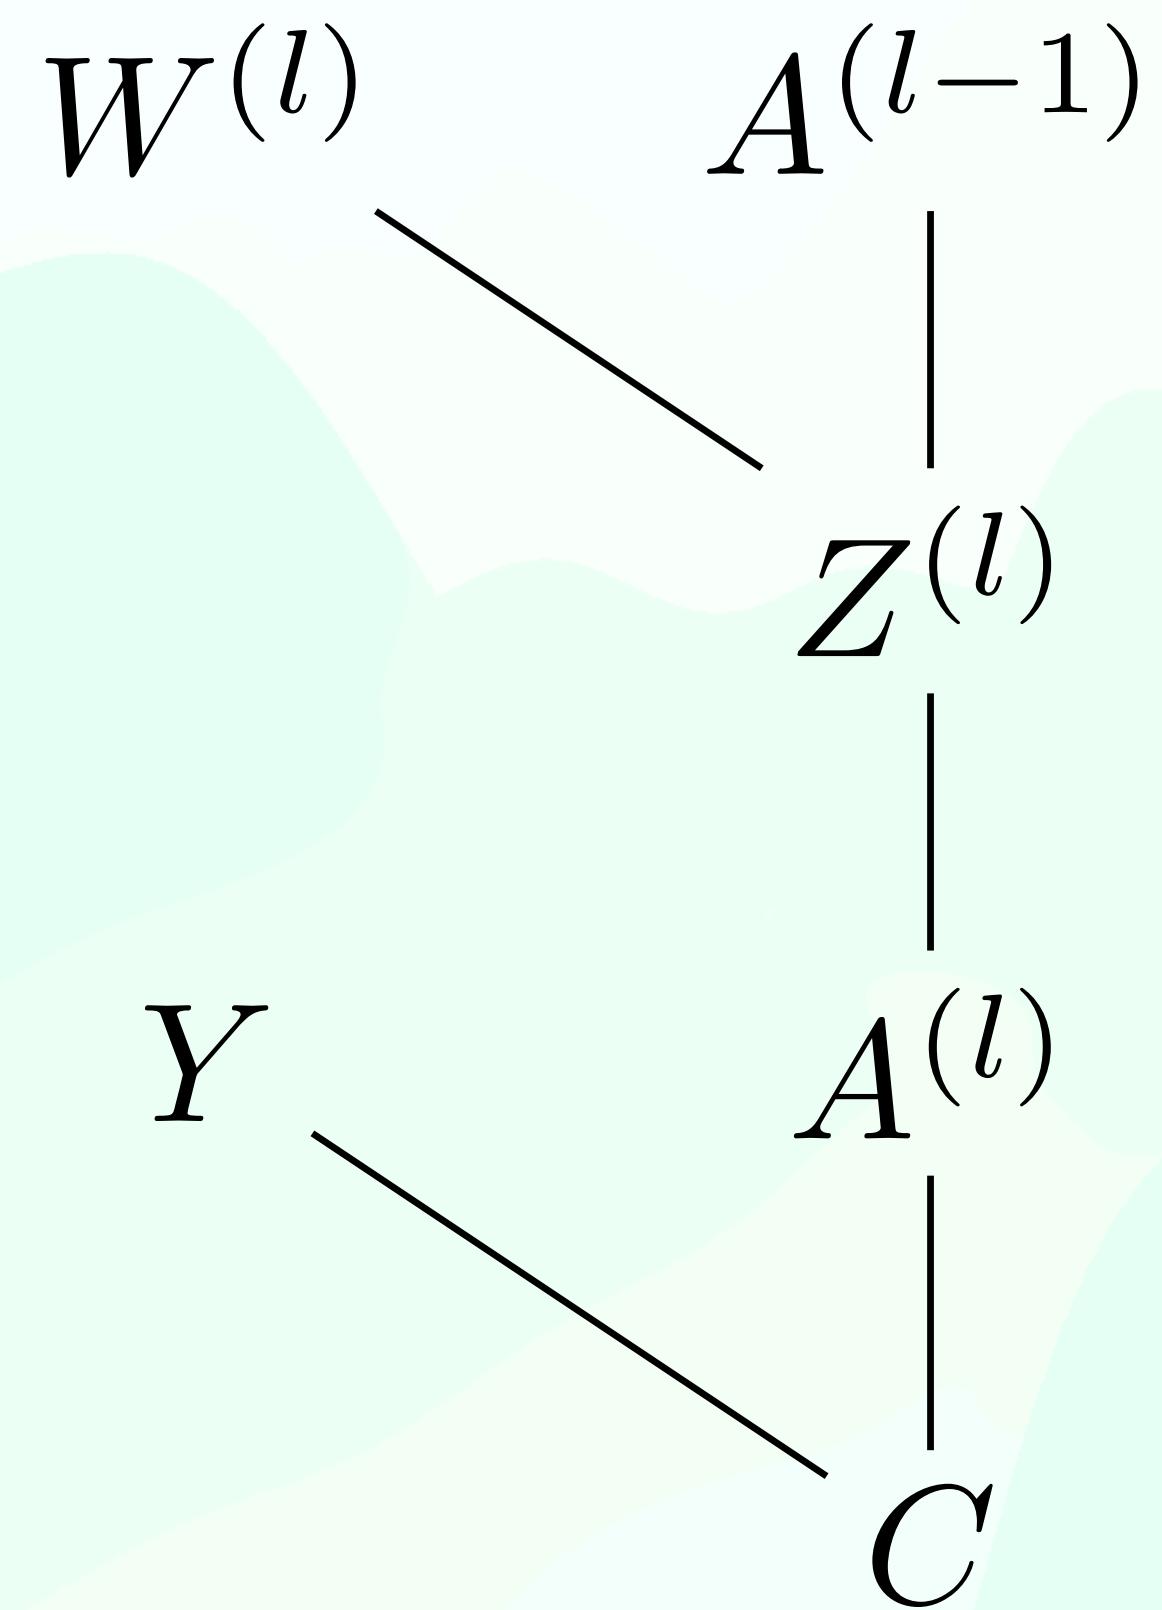
[1] <https://arxiv.org/pdf/1412.0233>

# Gradient Descent

- Berechne Gradientenvektor  $\nabla C$ , der die Richtung des steilsten Anstiegs der Kostenfunktion angibt
- Mache einen Schritt in Richtung  $-\nabla C$
- Wiederhole beides so lange, bis ausreichende Konvergenz zu einem lokalen Minimum vorliegt



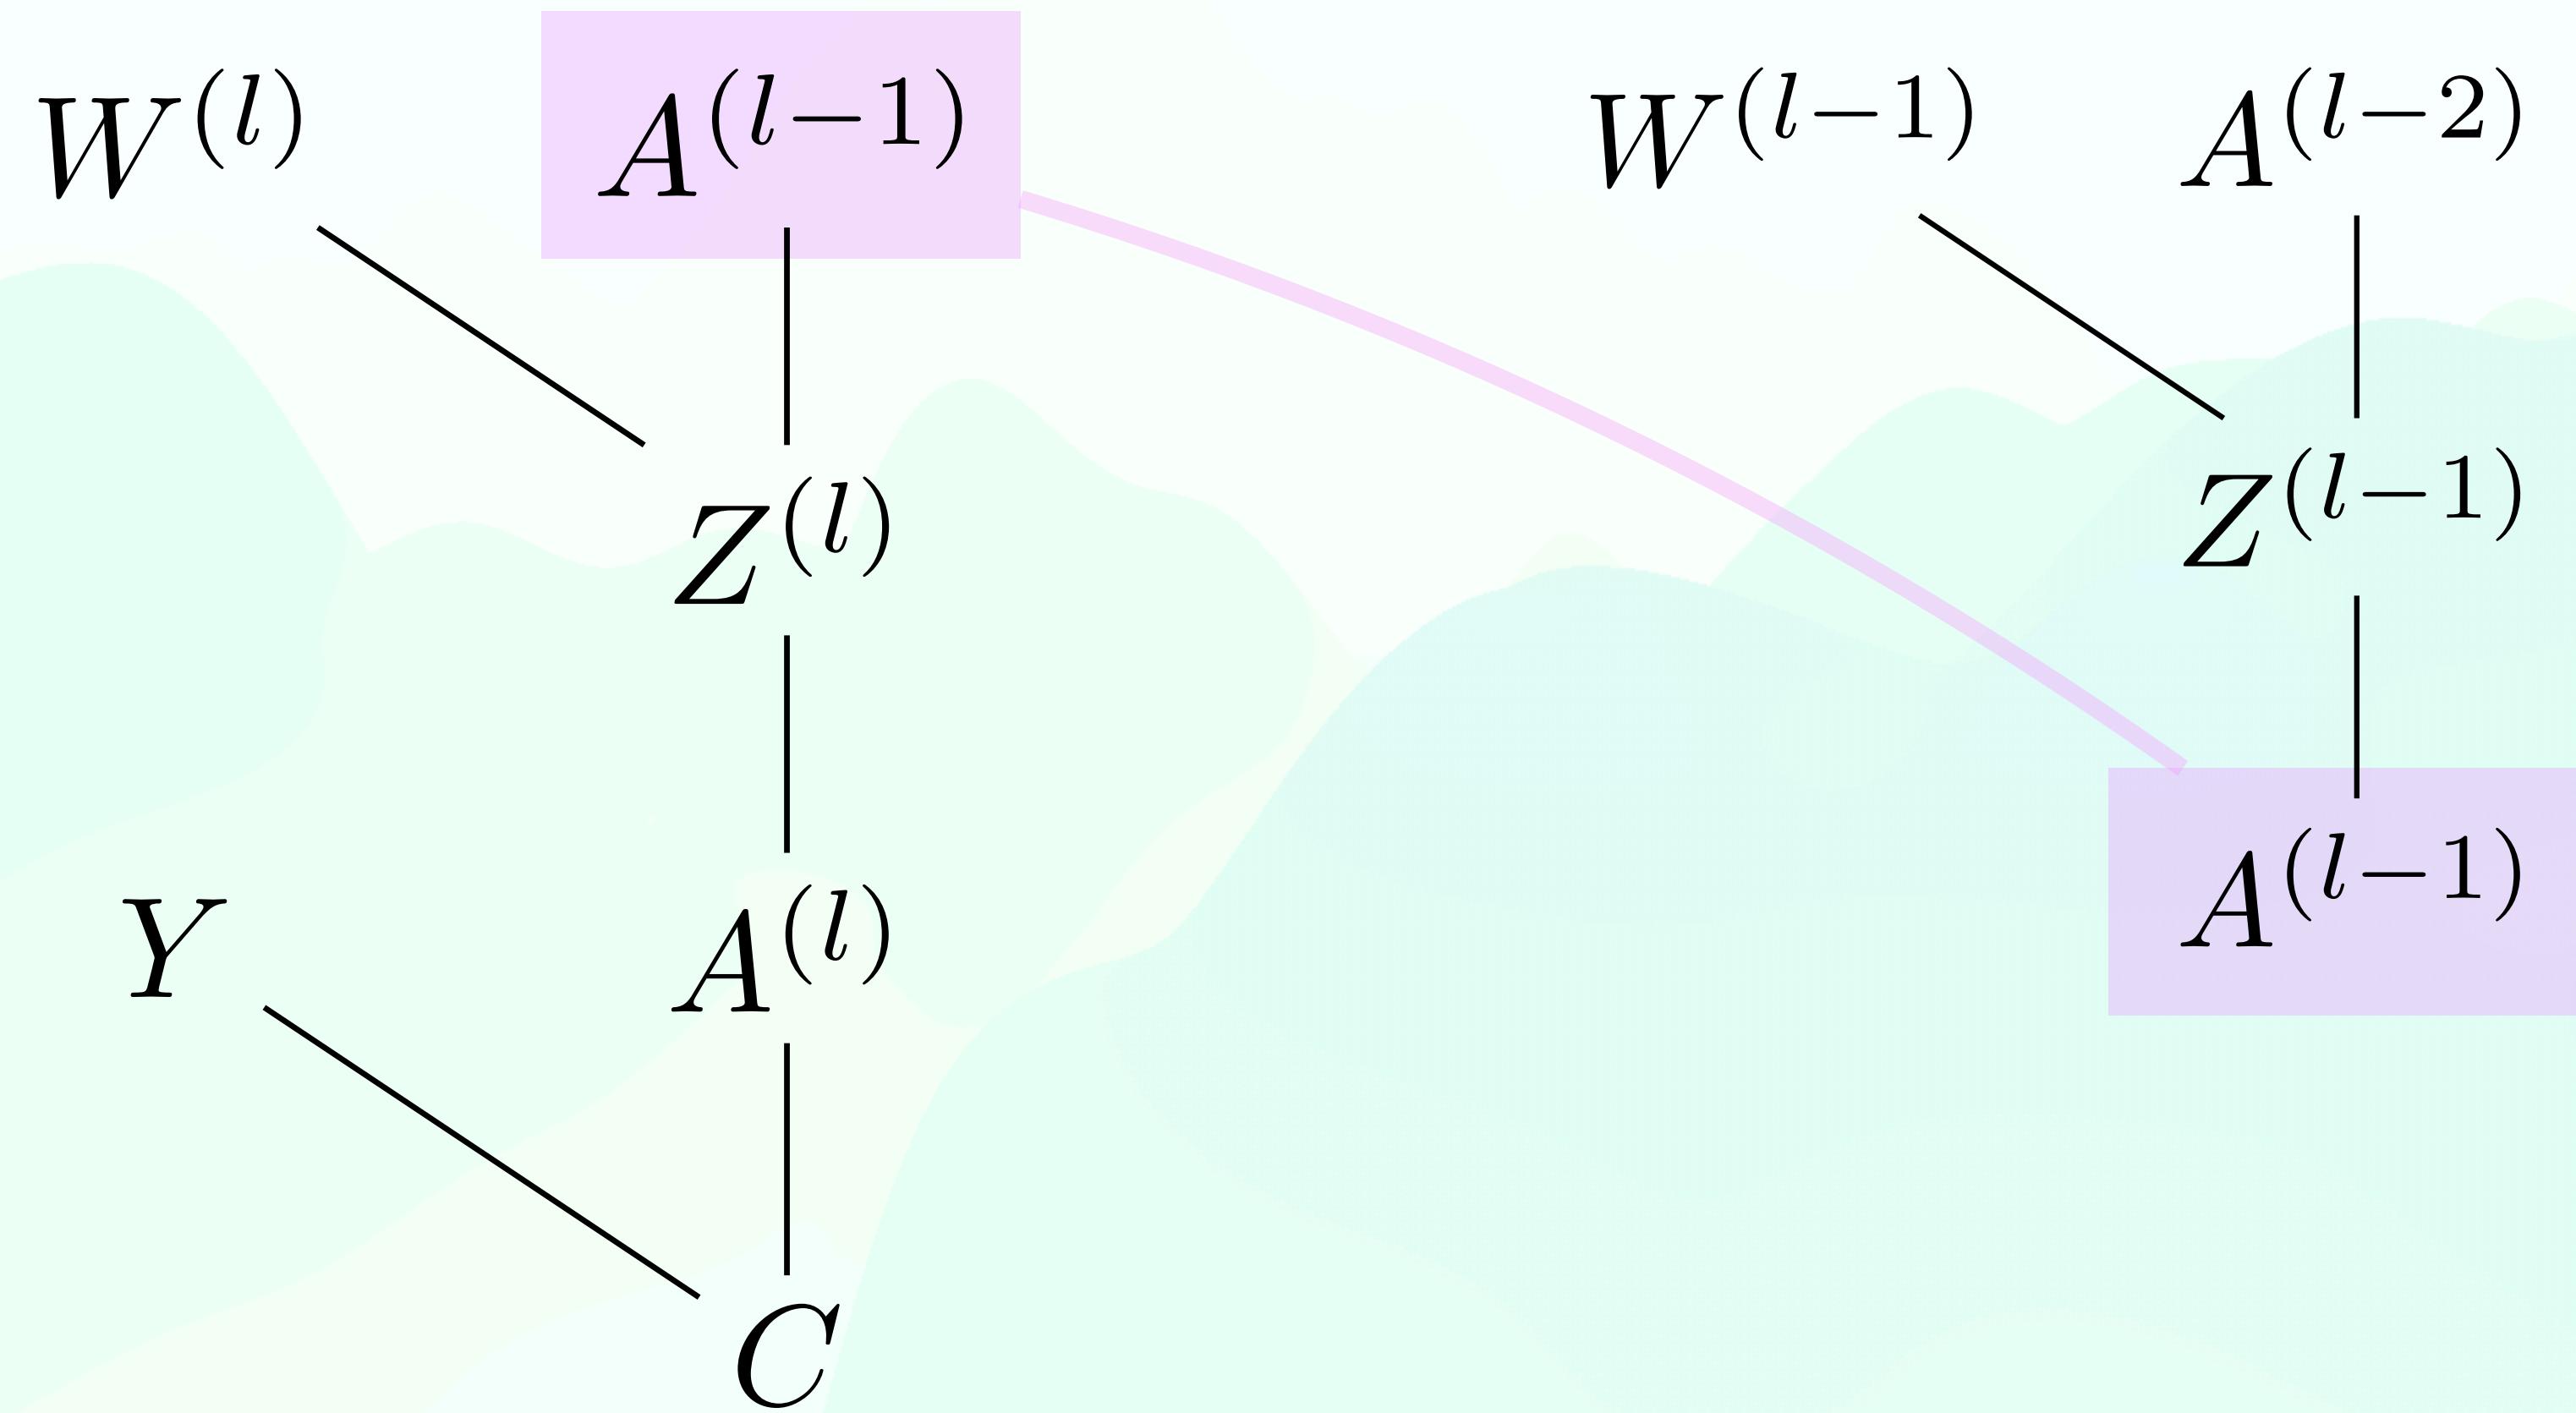
# Ableitung der Kostenfunktion



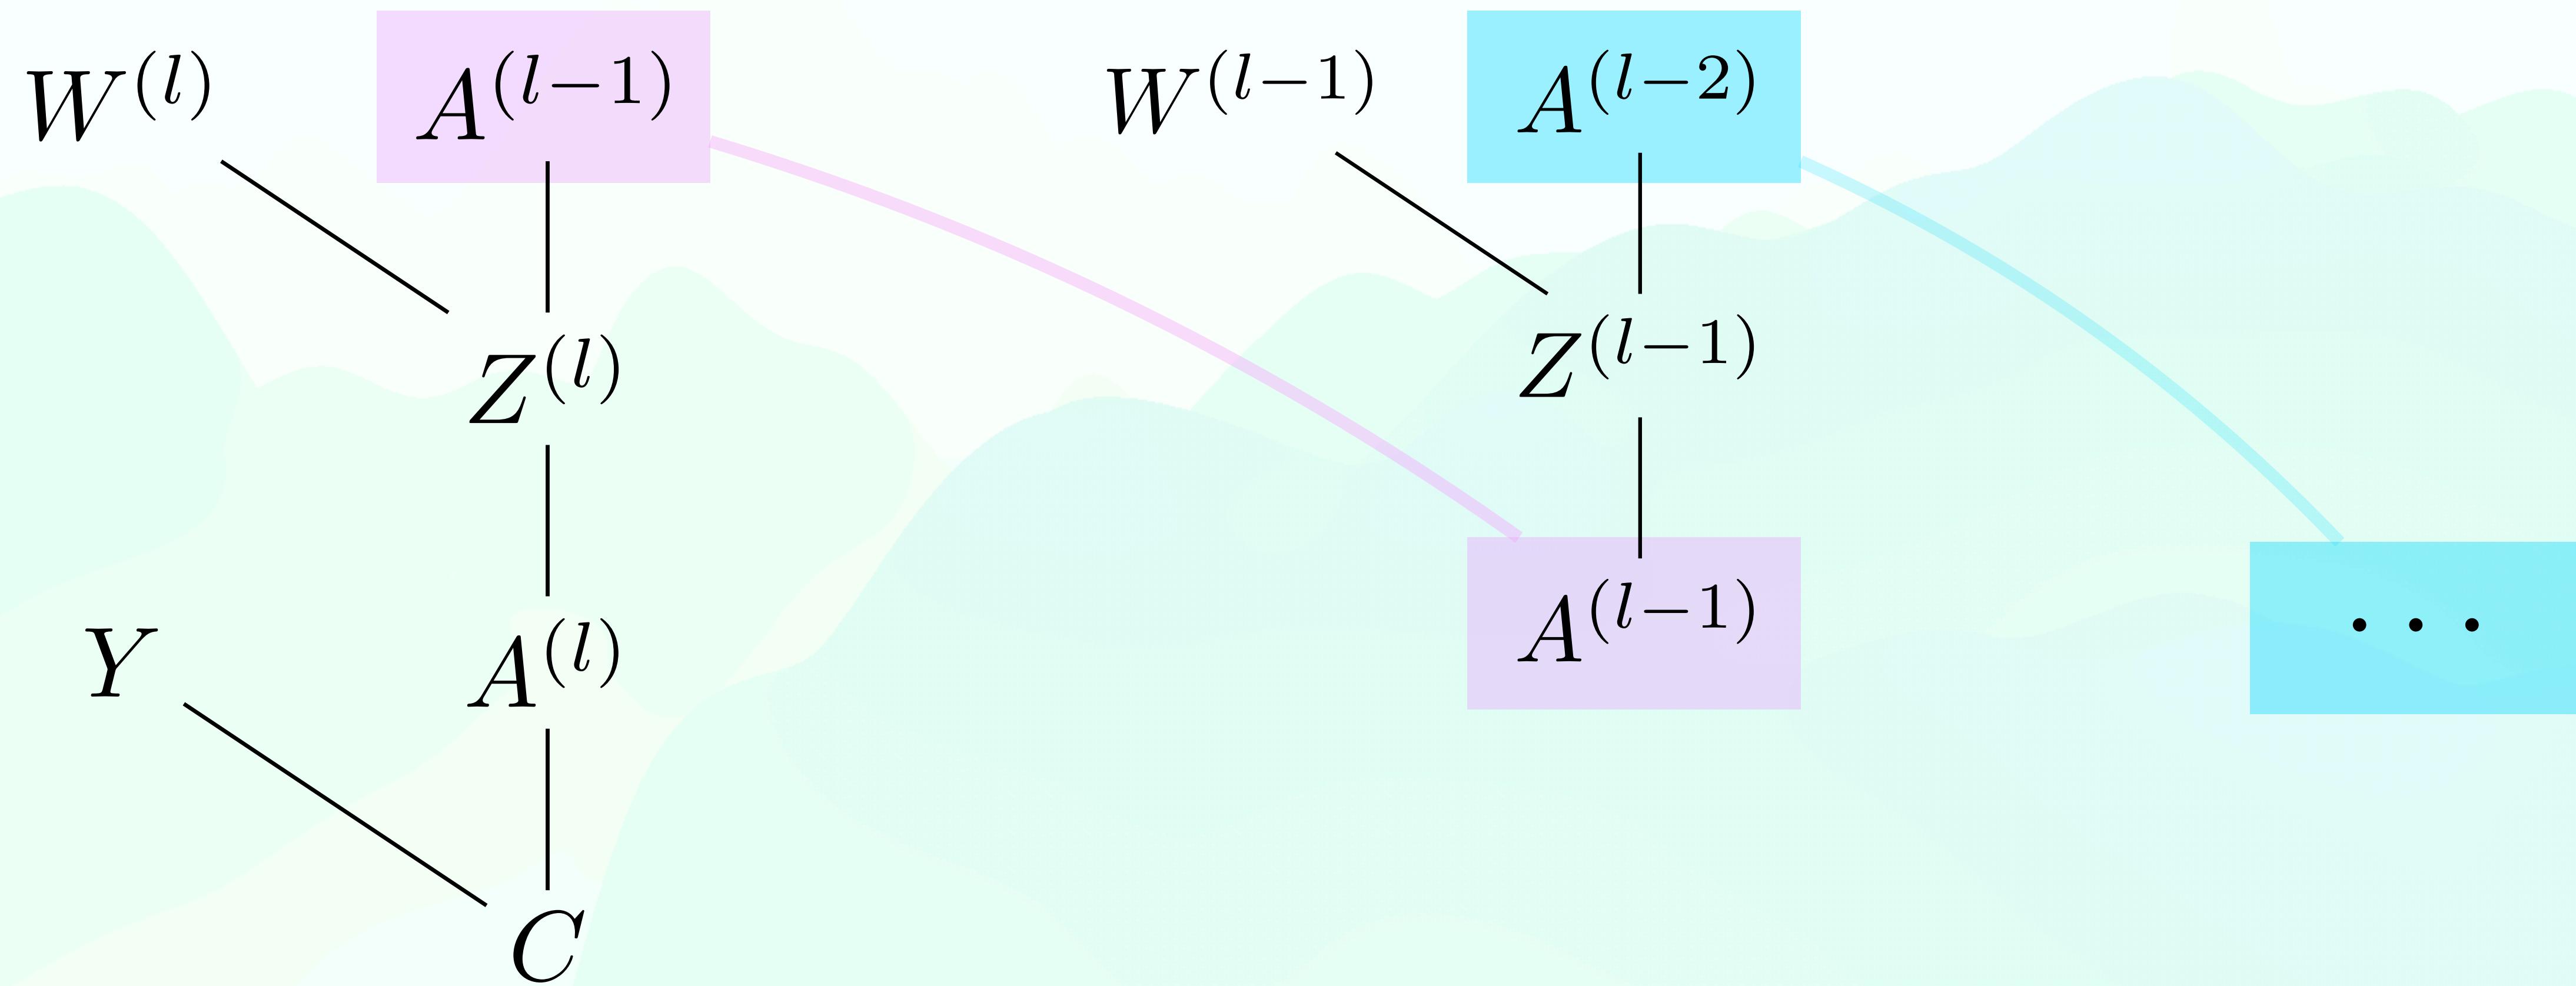
# Ableitung der Kostenfunktion



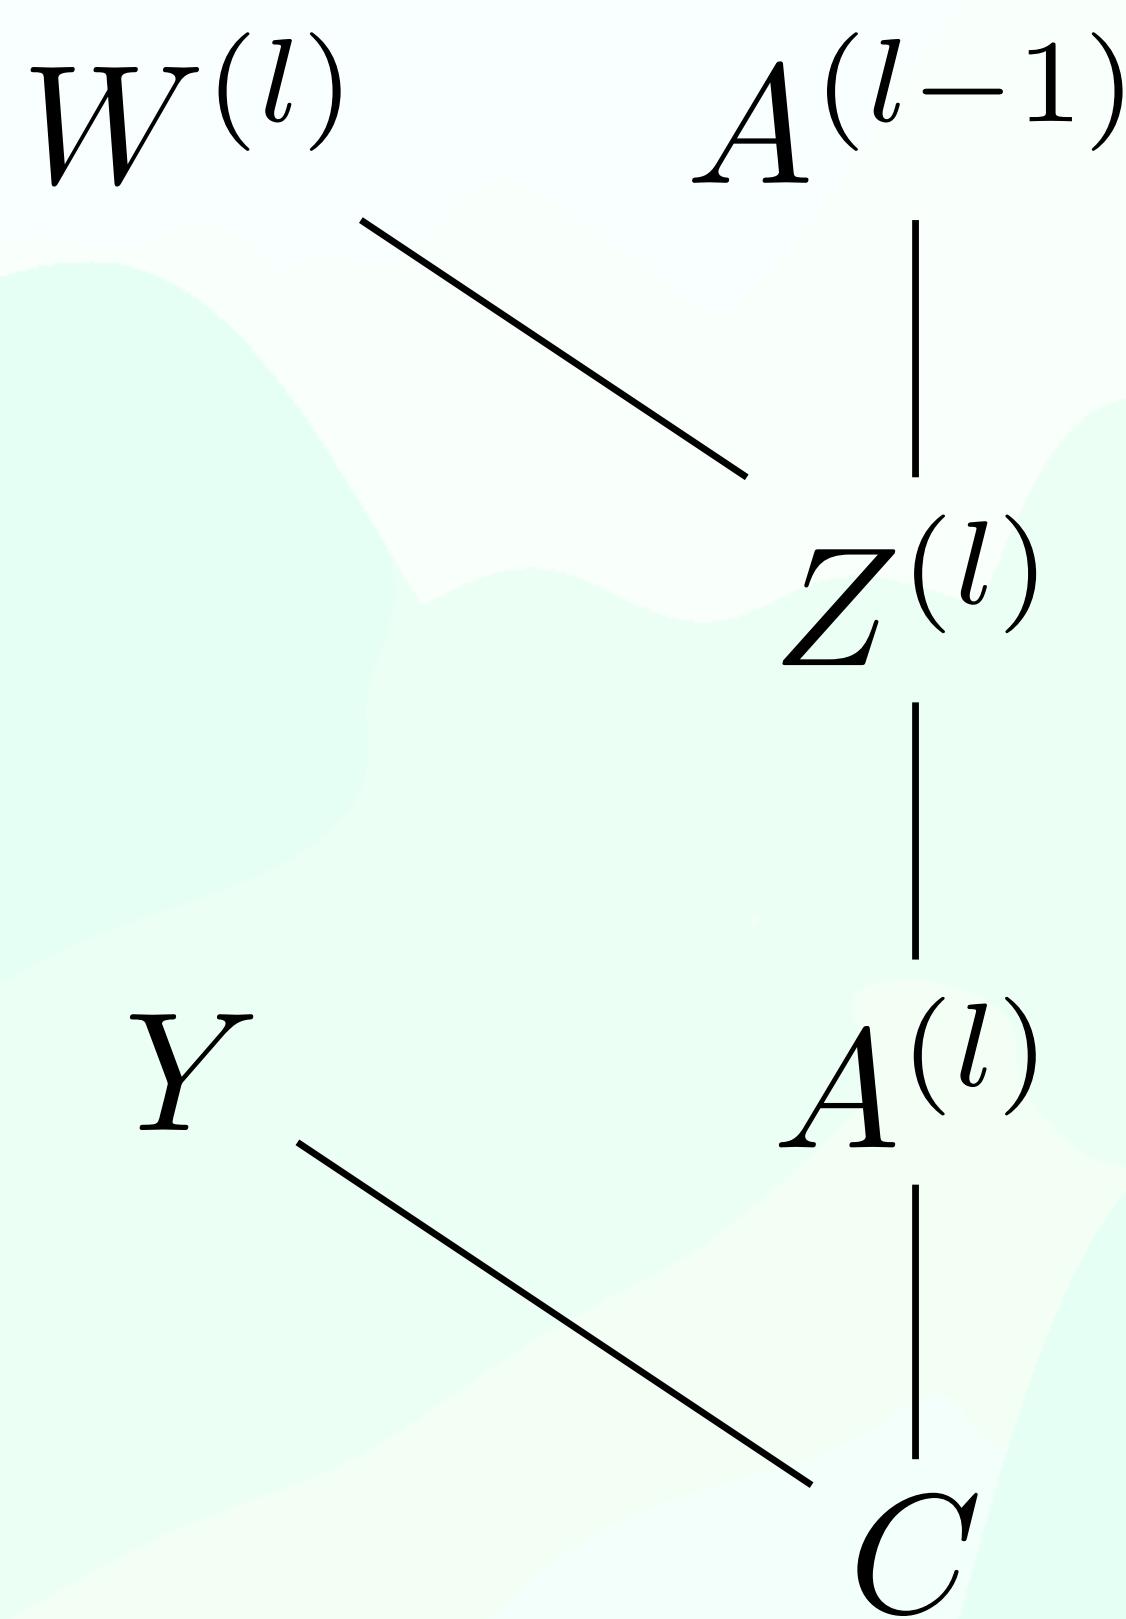
# Ableitung der Kostenfunktion



# Ableitung der Kostenfunktion

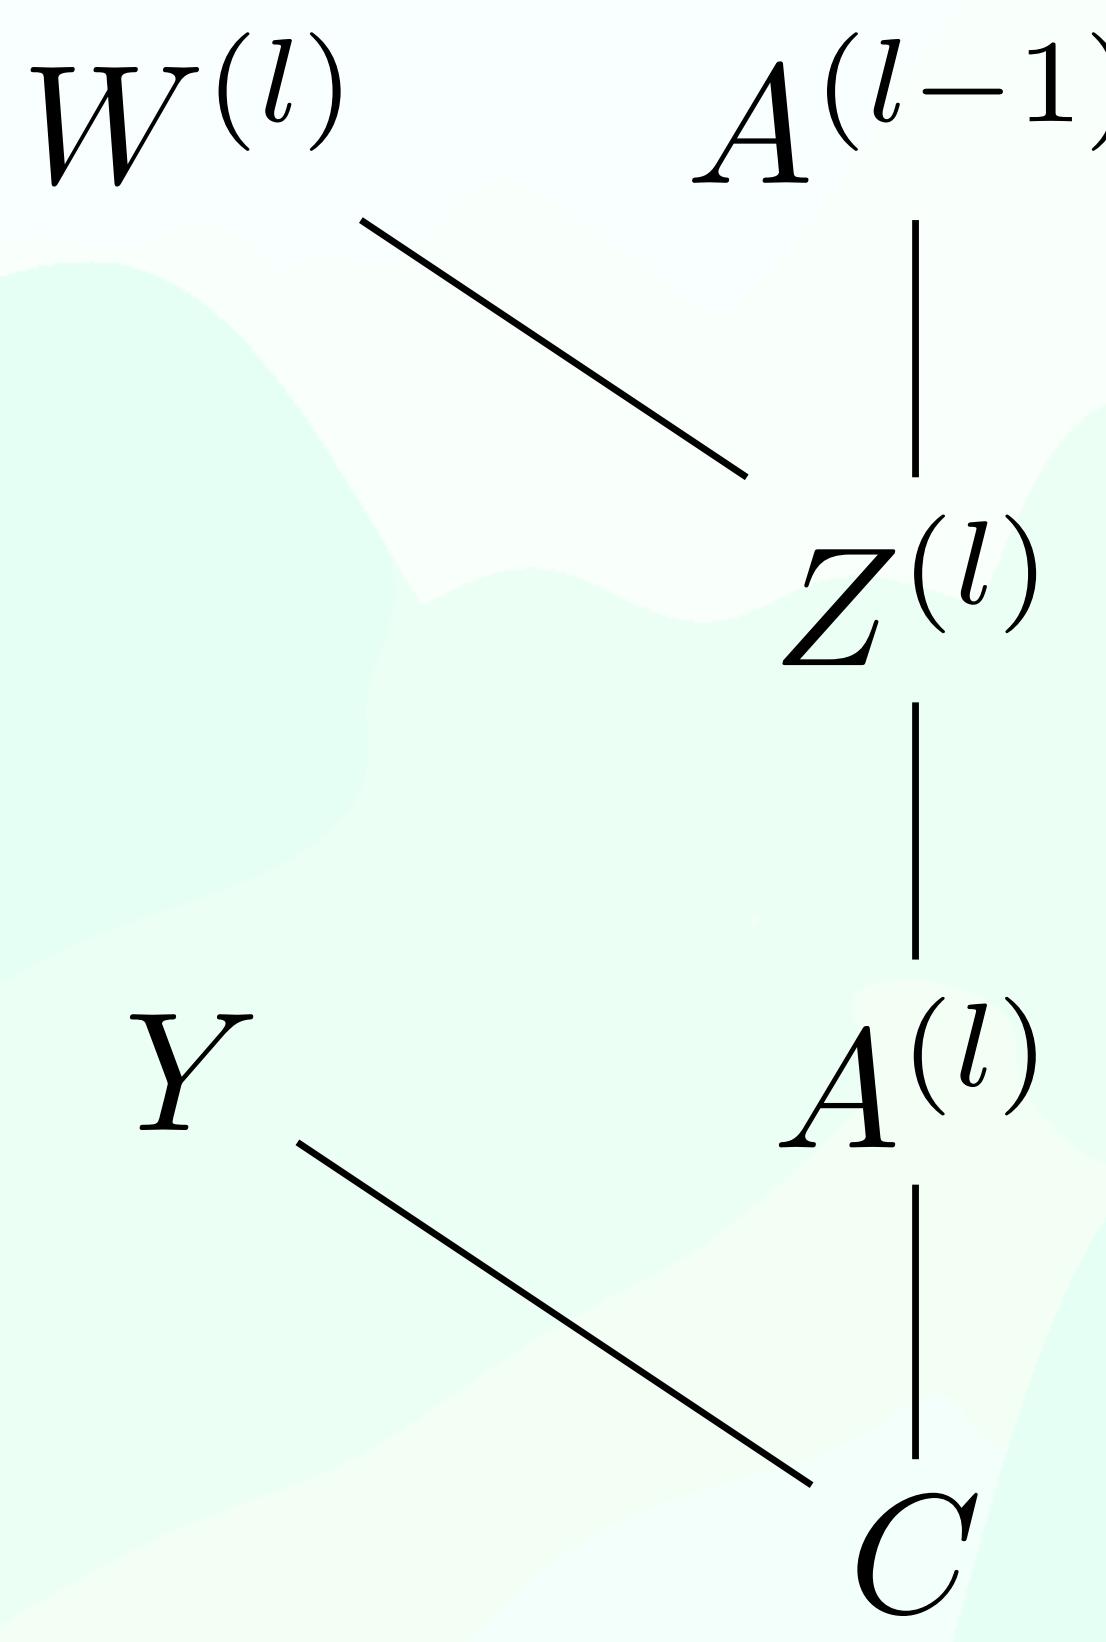


# Ableitung der Kostenfunktion



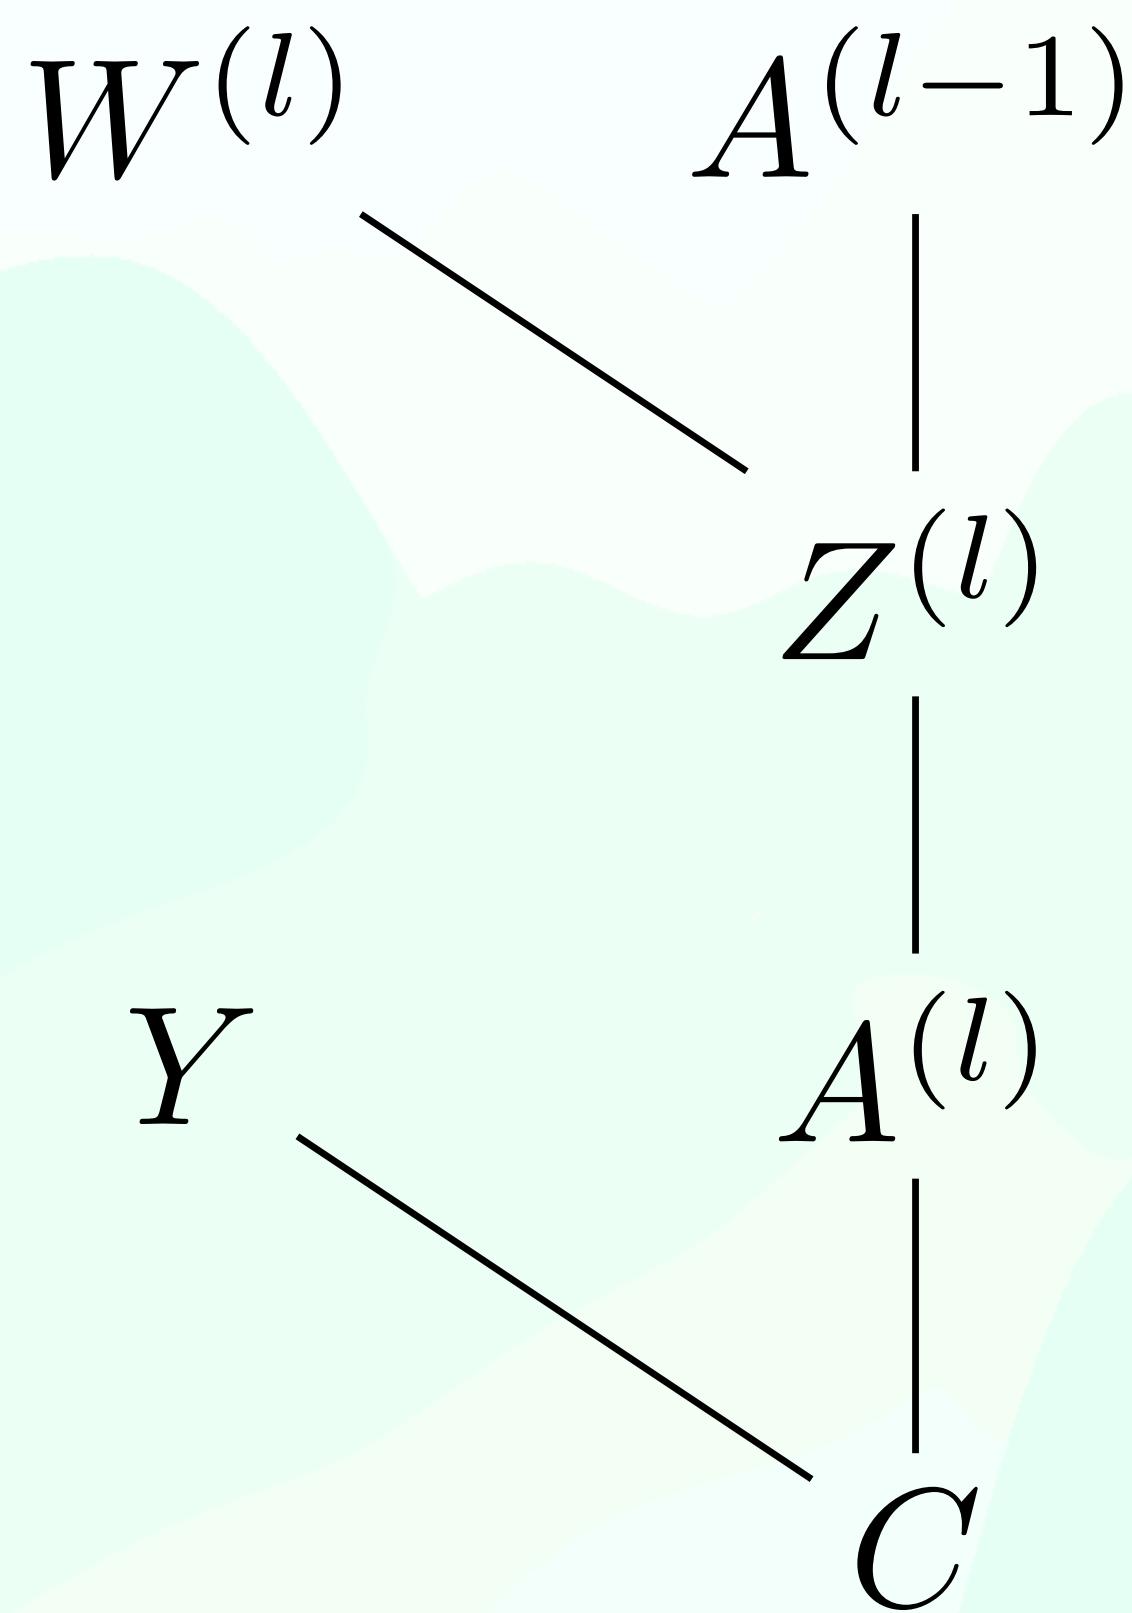
- Aktivierungen des Layers  $l - 1$  können nicht direkt beeinflusst werden, sondern nur durch Anpassung der Gewichte im Layer  $l - 1$

# Ableitung der Kostenfunktion



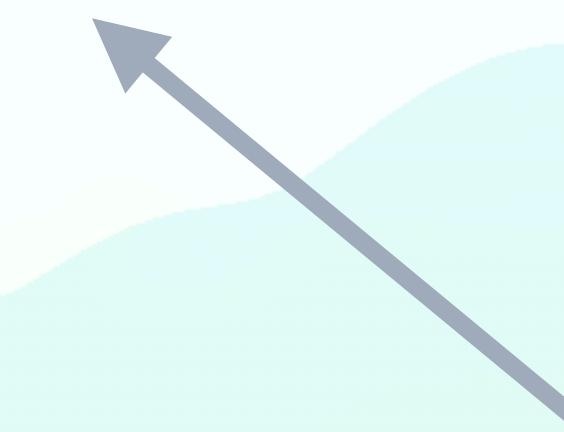
- Aktivierungen des Layers  $l - 1$  können nicht direkt beeinflusst werden, sondern nur durch Anpassung der Gewichte im Layer  $l - 1$
- Idee der **Backpropagation**:
  - Berechne, in welche Richtung die Gewichte zum Output-Layer angepasst werden müssen, um Kosten zu verringern
  - Benutze diese Information, um diese Richtung auch für die Gewichte des vorherigen Layers zu berechnen
  - Wiederhole diese Schritte von Layer zu Layer „rückwärts“ durch das Netz bis zu den Gewichten vom Input-Layer zum ersten Hidden-Layer

# Ableitung der Kostenfunktion



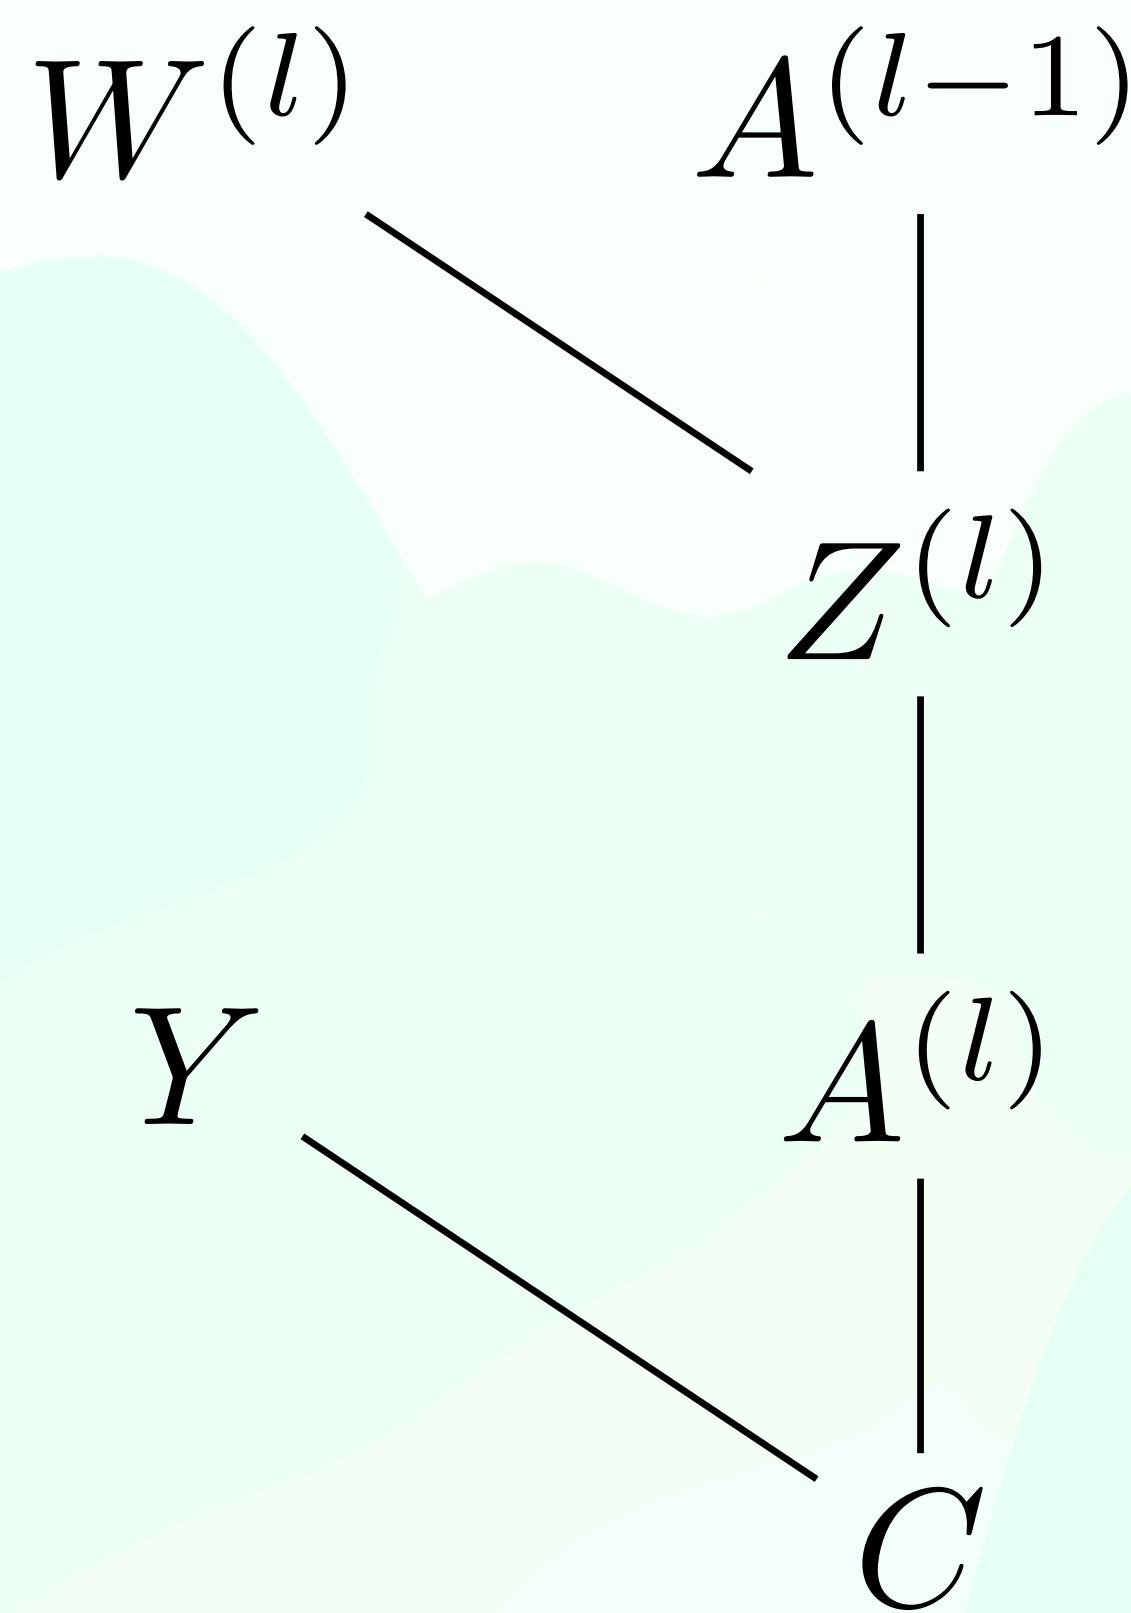
Für jedes  $w_{jk}^{(l)}$  gesucht:

$$\frac{\partial C}{\partial w_{jk}^{(l)}}$$



Welchen Einfluss auf  $C$  hat  
eine winzige Änderung in  $w_{jk}^{(l)}$ ?

# Ableitung der Kostenfunktion



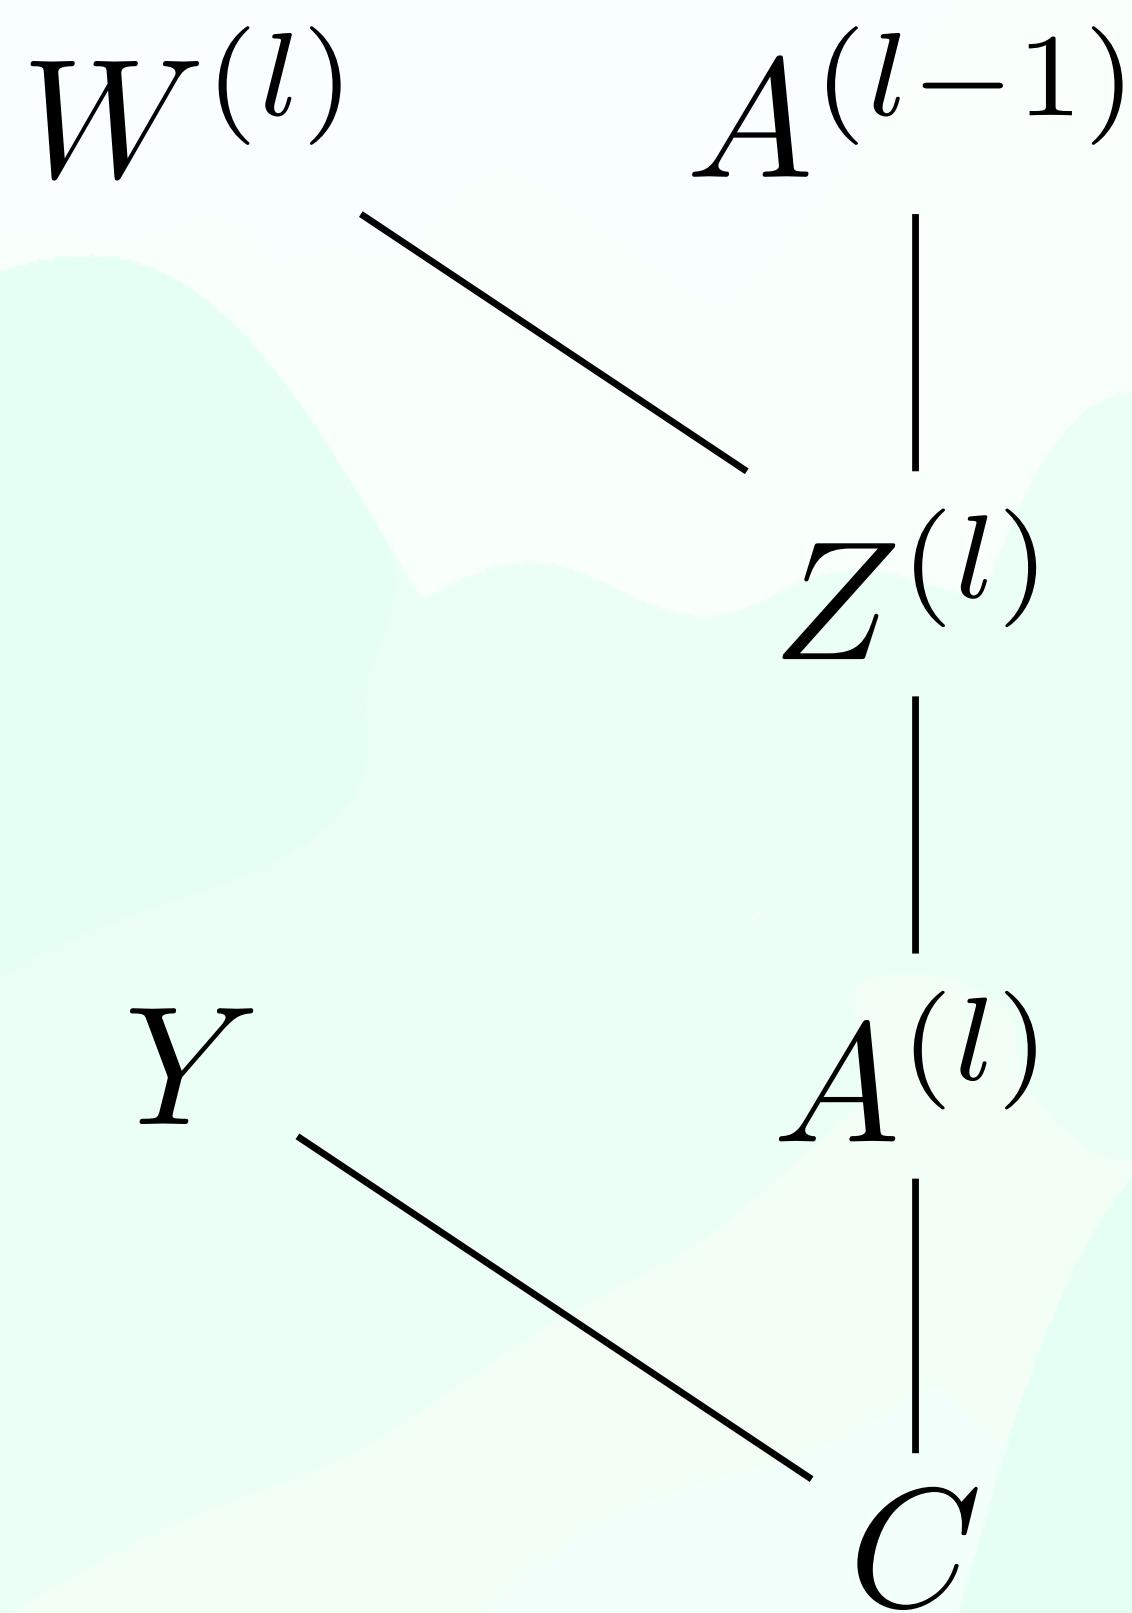
Für jedes  $w_{jk}^{(l)}$  gesucht:

$$\frac{\partial C}{\partial w_{jk}^{(l)}}$$

Die Ableitung von  $C$  nach  $w_{jk}^{(l)}$

Welchen Einfluss auf  $C$  hat  
eine winzige Änderung in  $w_{jk}^{(l)}$ ?

# Ableitung der Kostenfunktion



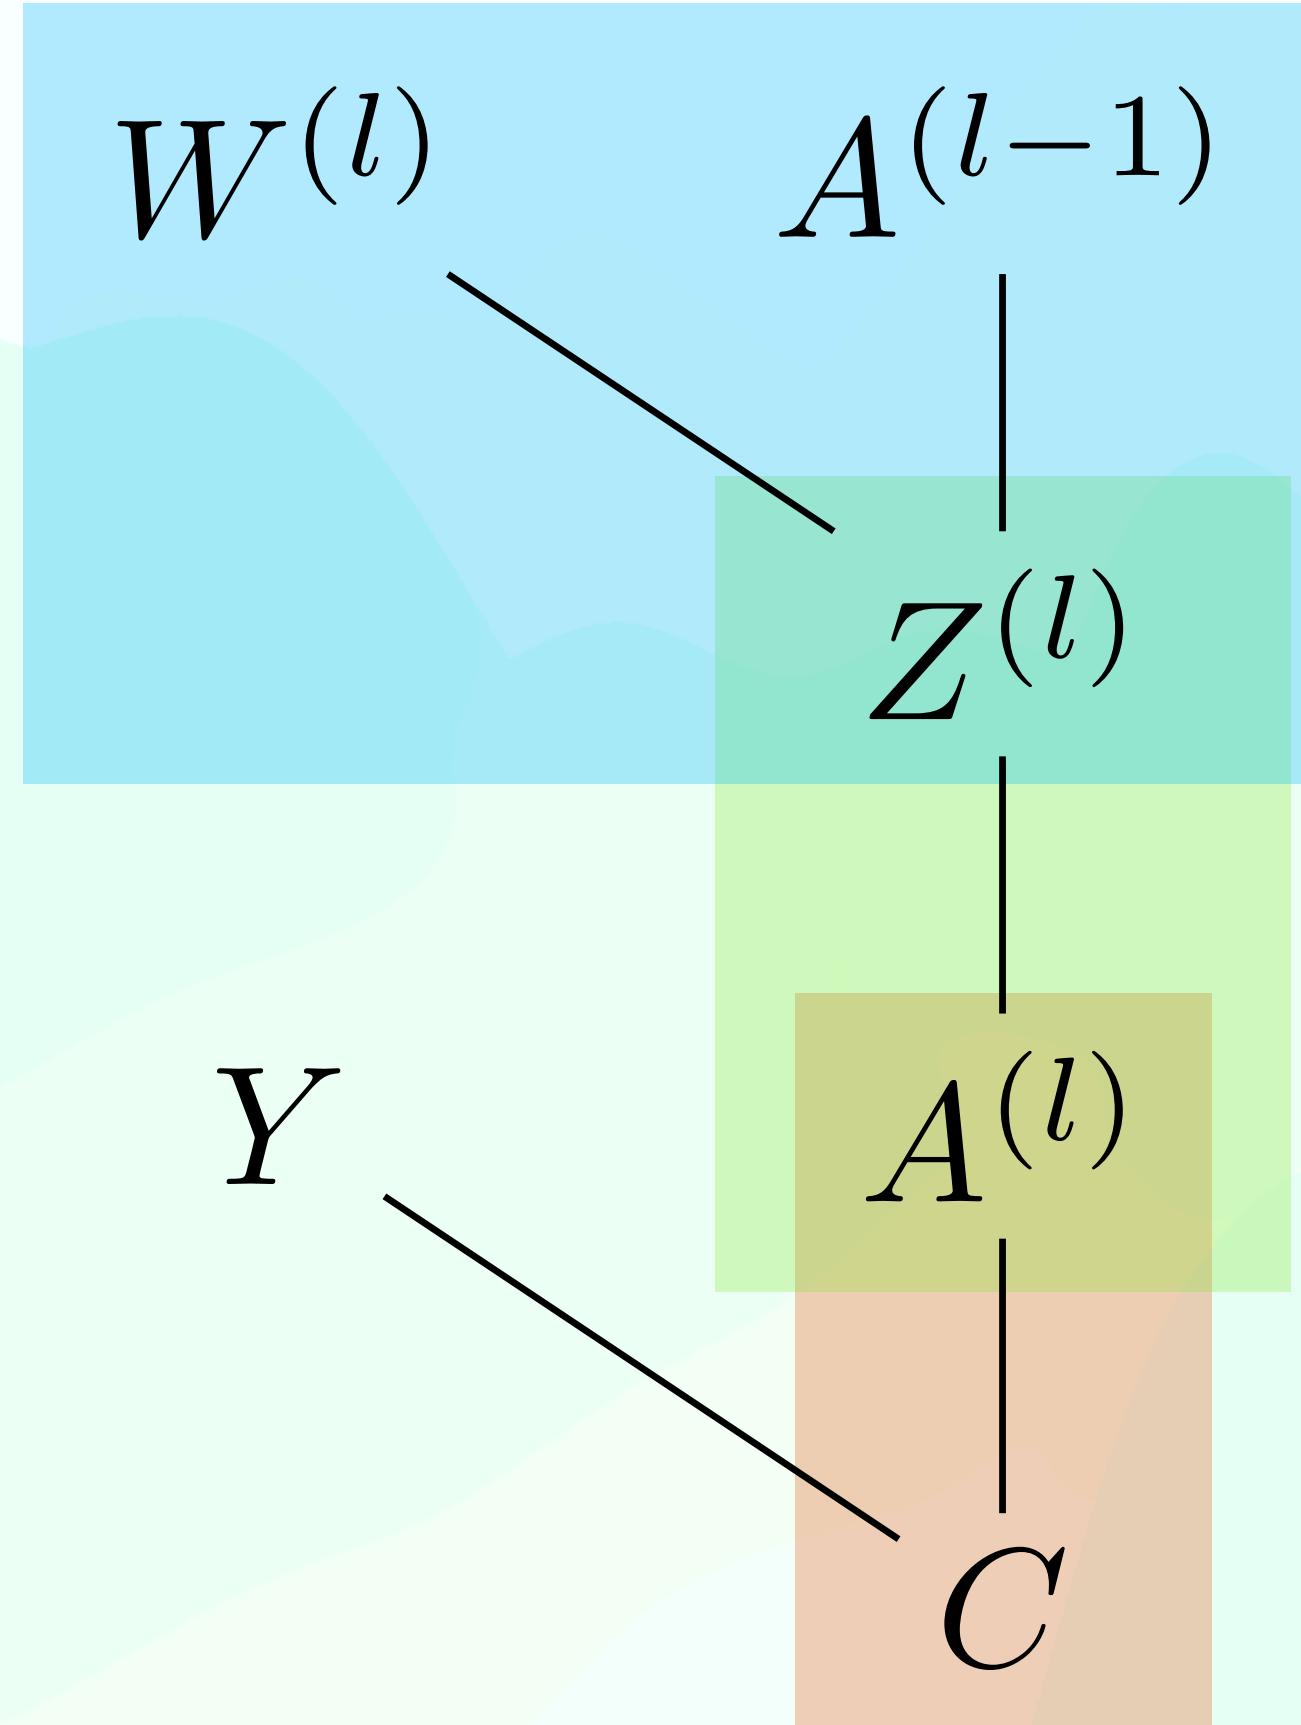
Für jedes  $w_{jk}^{(l)}$  gesucht:  $\frac{\partial C}{\partial w_{jk}^{(l)}}$

Aus Kettenregel der Differentialrechnung folgt:

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

1

# Ableitung der Kostenfunktion



Für jedes  $w_{jk}^{(l)}$  gesucht:  $\frac{\partial C}{\partial w_{jk}^{(l)}}$

Aus Kettenregel der Differentialrechnung folgt:

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

1

A diagram illustrating the chain rule for backpropagation. It shows three adjacent colored boxes representing neurons in a layer: orange for  $a_j^{(l)}$ , green for  $z_j^{(l)}$ , and blue for  $w_{jk}^{(l)}$ . Three grey arrows point upwards from the bottom neuron  $a_j^{(l)}$  to the top neuron  $w_{jk}^{(l)}$ , representing the flow of gradients through the activation function and weight matrix.

Alle Ableitungen entlang der  
Kette werden multipliziert

# Ableitung der Kostenfunktion

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

Welchen Einfluss auf  $C$  hat  
eine winzige Änderung in  $a_j^{(l)}$ ?

Welchen Einfluss auf  $a_j^{(l)}$  hat  
eine winzige Änderung in  $z_j^{(l)}$ ?

Welchen Einfluss auf  $z_j^{(l)}$  hat  
eine winzige Änderung in  $w_{jk}^{(l)}$ ?

# Ableitung der Kostenfunktion

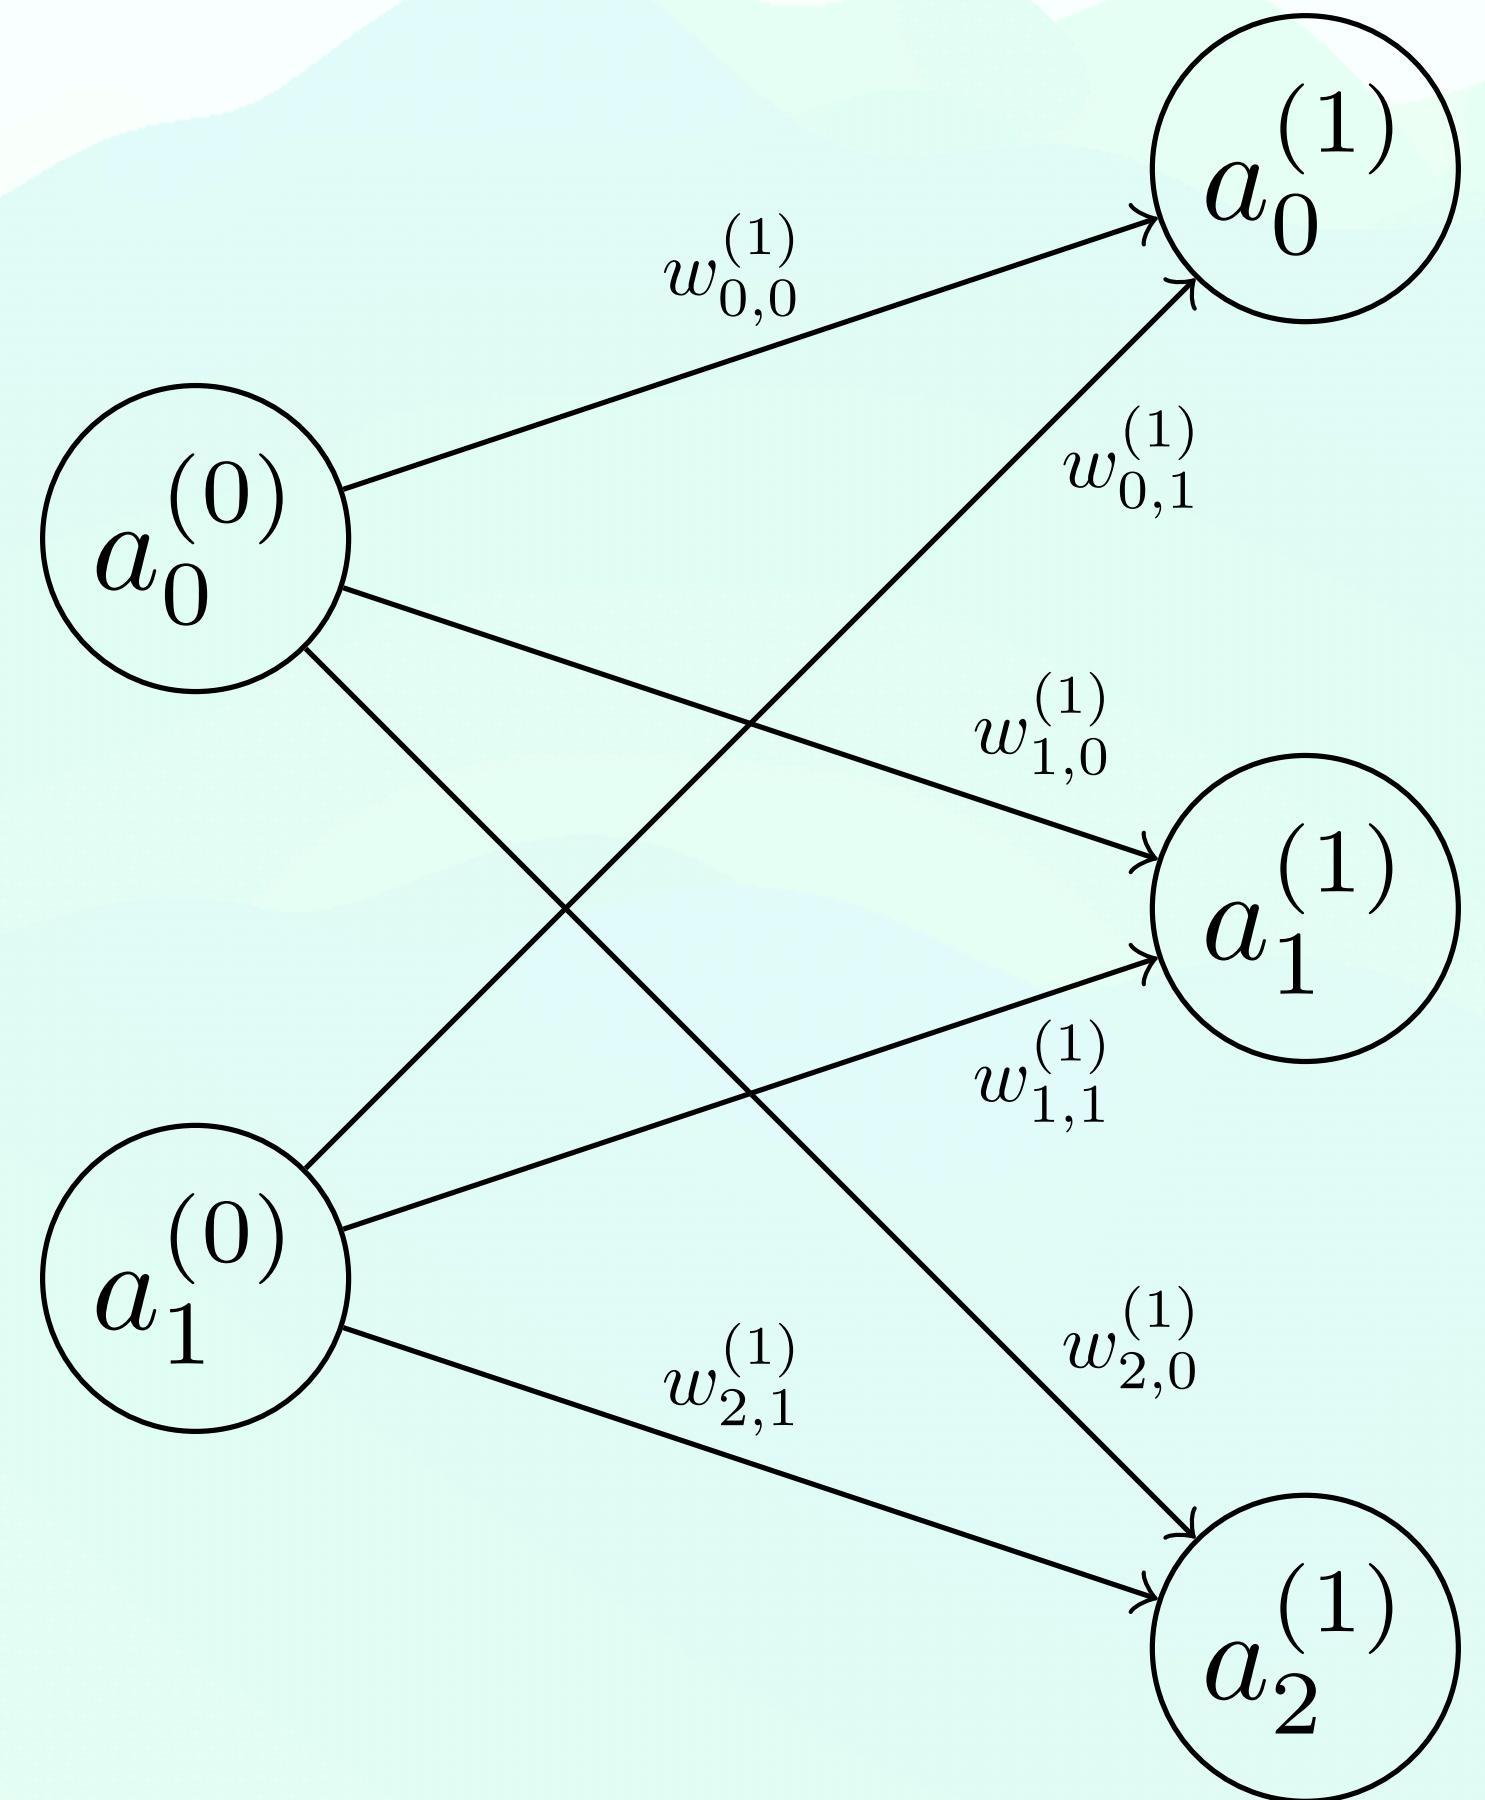
$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

# Ableitung der Kostenfunktion

- Sei  $n^{(l-1)}$  die Anzahl der Neuronen in Layer  $l - 1$ , dann gilt:

$$z_j^{(l)} = \sum_{m=0}^{n^{(l-1)}-1} w_{jm}^{(l)} a_m^{(l-1)}$$

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

- Sei  $n^{(l-1)}$  die Anzahl der Neuronen in Layer  $l - 1$ , dann gilt:

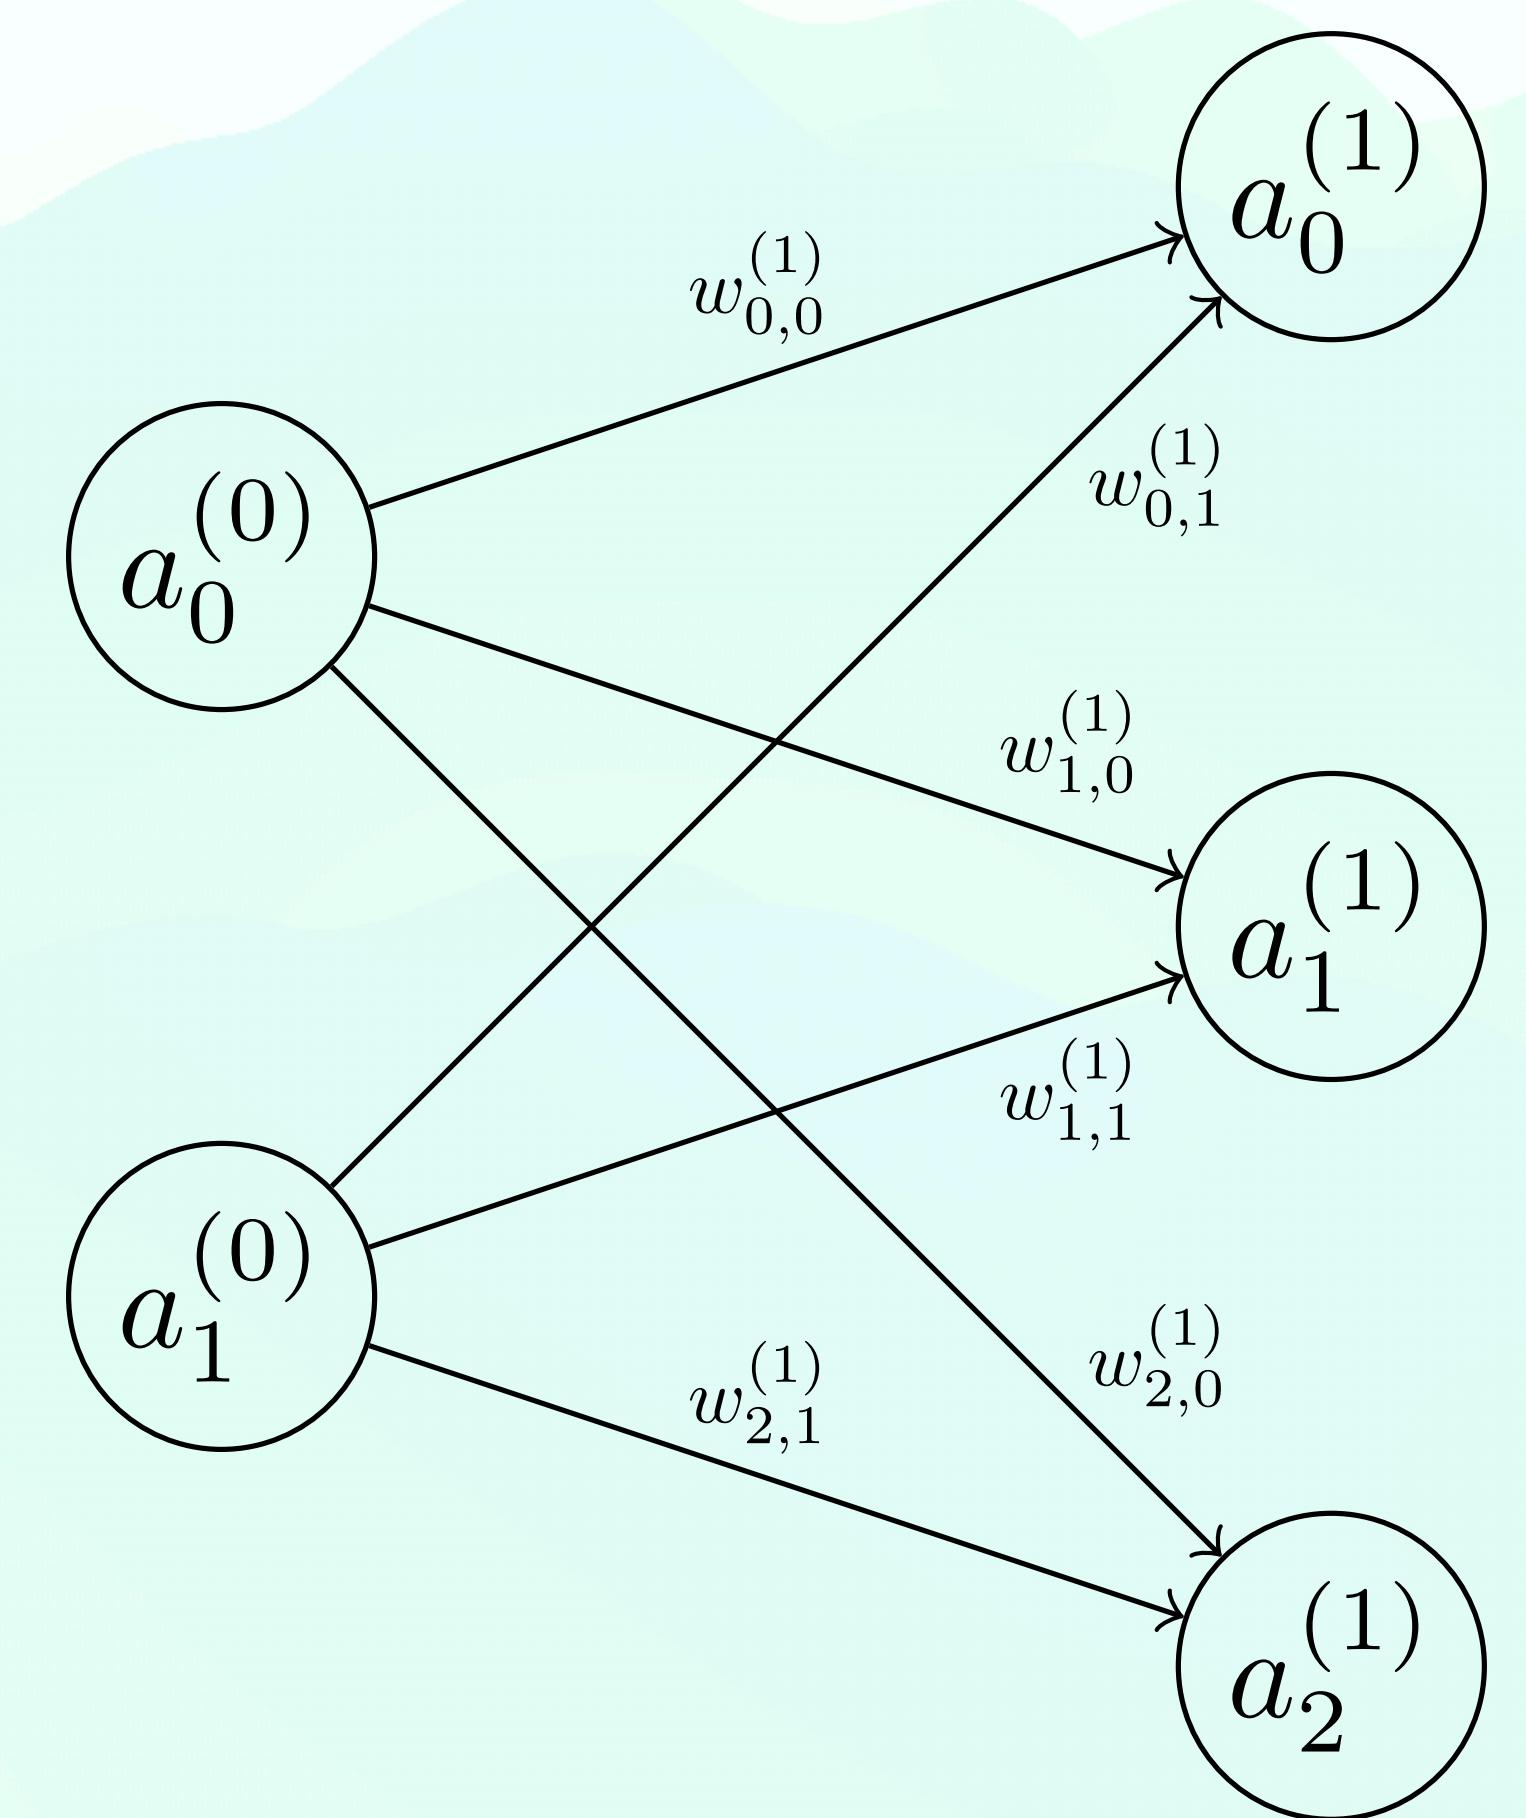
$$z_j^{(l)} = \sum_{m=0}^{n^{(l-1)}-1} w_{jm}^{(l)} a_m^{(l-1)}$$

- Nur ein Term in dieser Summe hängt von  $w_{jk}^{(l)}$  ab, alle anderen Gewichte sind im Sinne dieses Differentials Konstanten.
- Daher gilt:

$$\frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}} = \frac{\partial w_{jk}^{(l)} a_k^{(l-1)}}{\partial w_{jk}^{(l)}} = a_k^{(l-1)}$$

2

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

Mit anderen Worten:

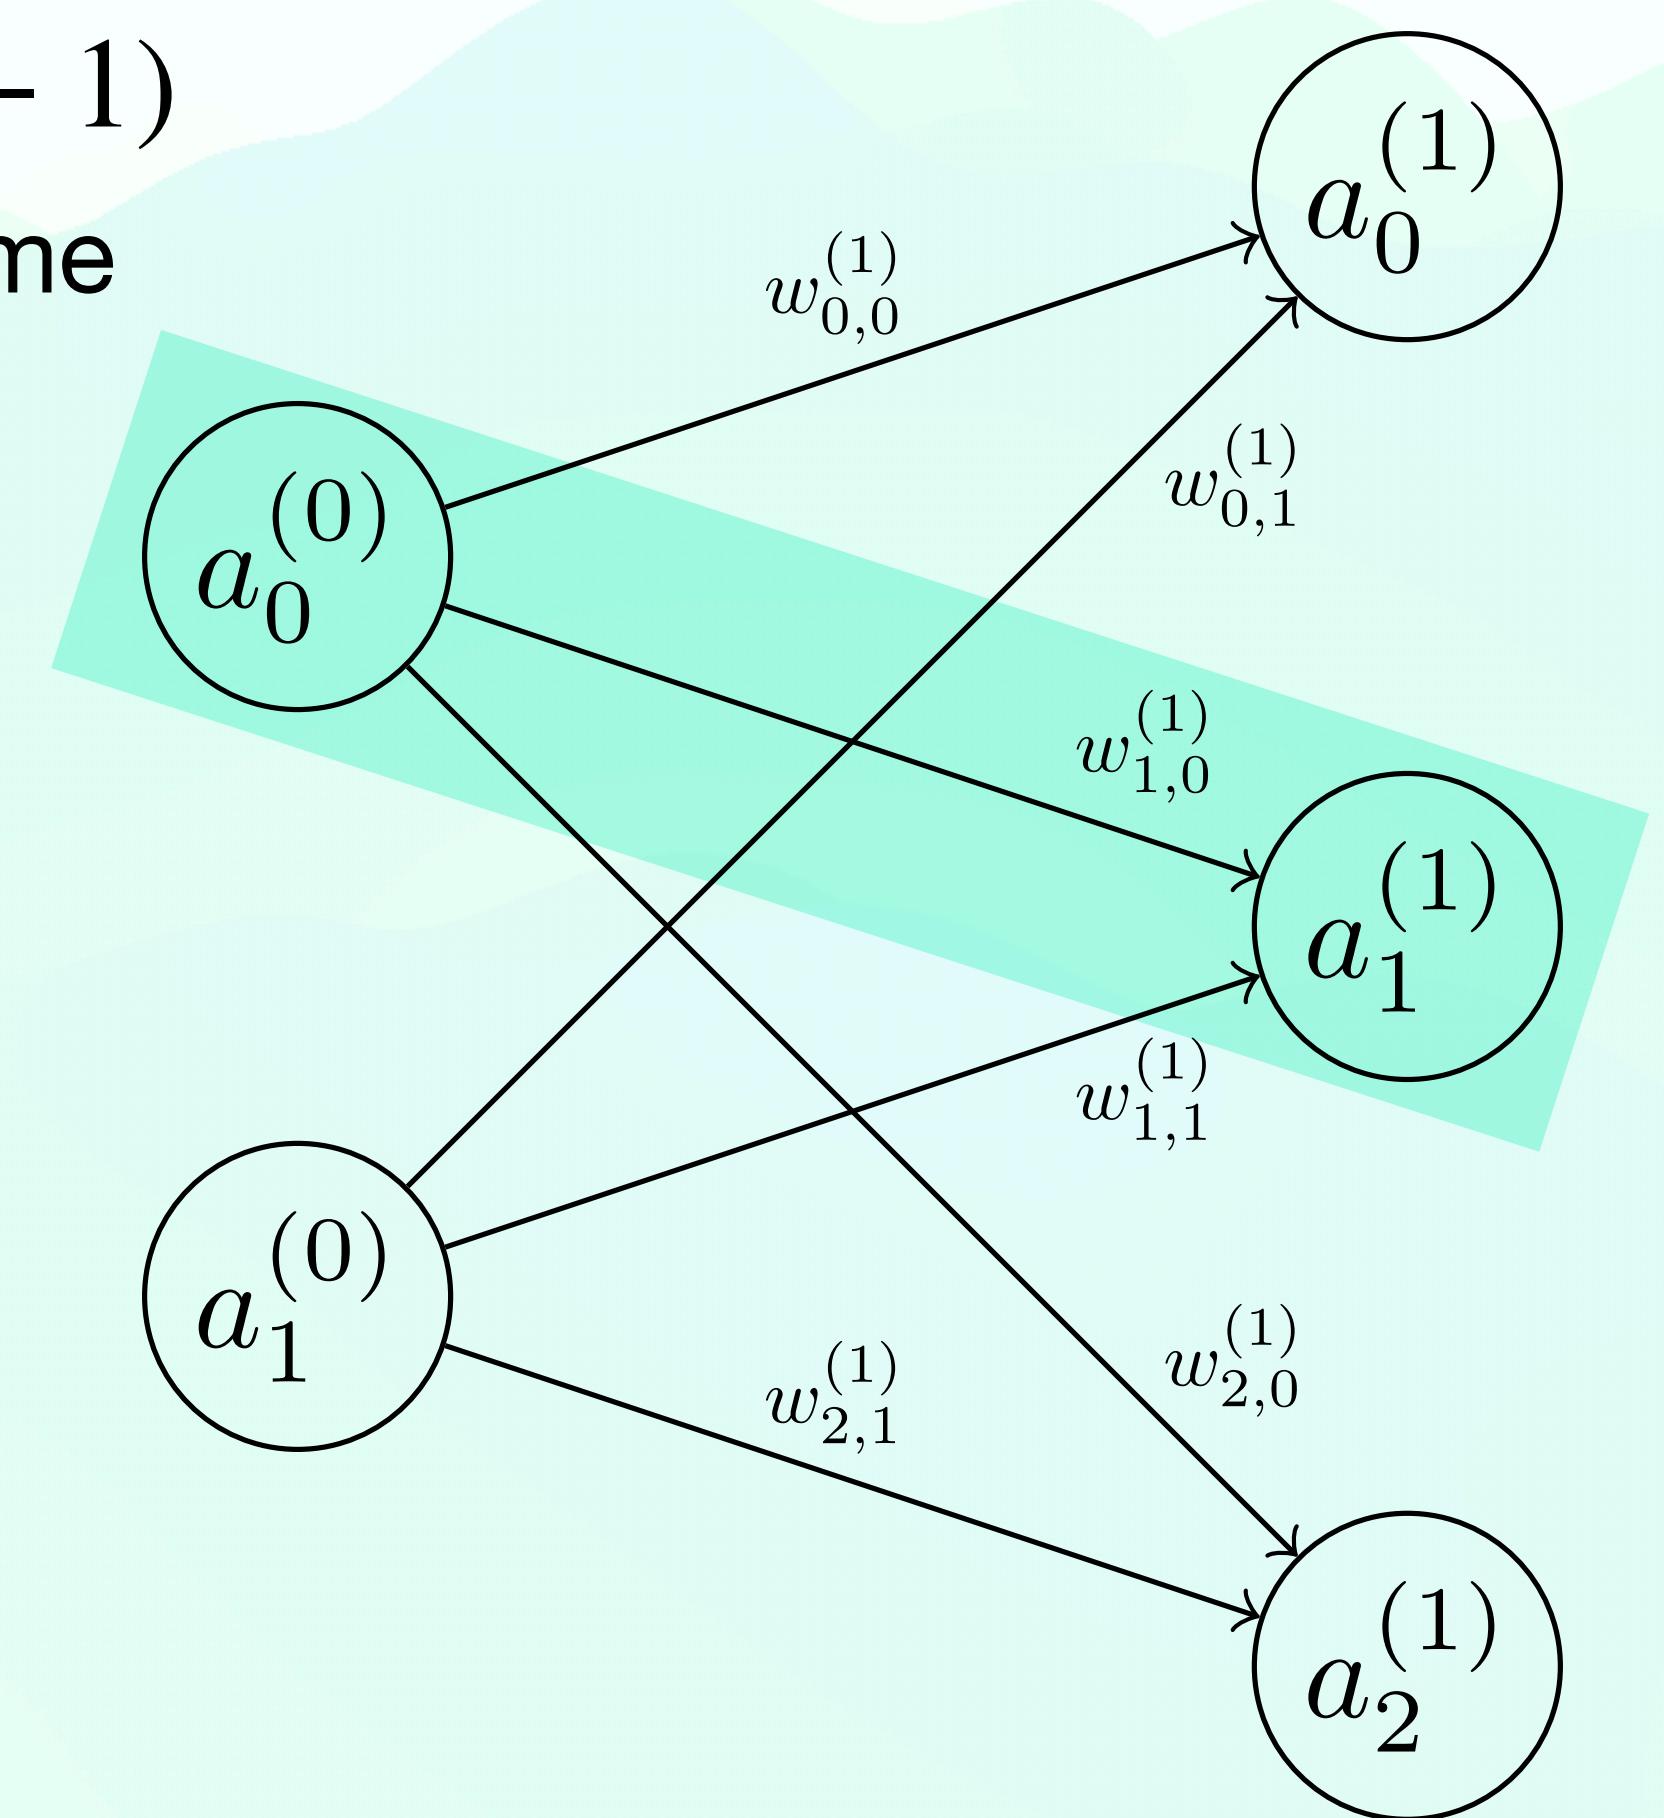
Eine Änderung des Gewichts vom  $k$ -ten Neuron des Layers  $(l - 1)$  zum  $j$ -ten Neuron des Layers  $l$  beeinflusst die gewichtete Summe im  $j$ -ten Neuron in Layer  $l$  genau in der Höhe der Aktivierung des  $k$ -ten Neurons in Layer  $l - 1$ .



$$\frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}} = \frac{\partial w_{jk}^{(l)} a_k^{(l-1)}}{\partial w_{jk}^{(l)}} = a_k^{(l-1)}$$

2

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

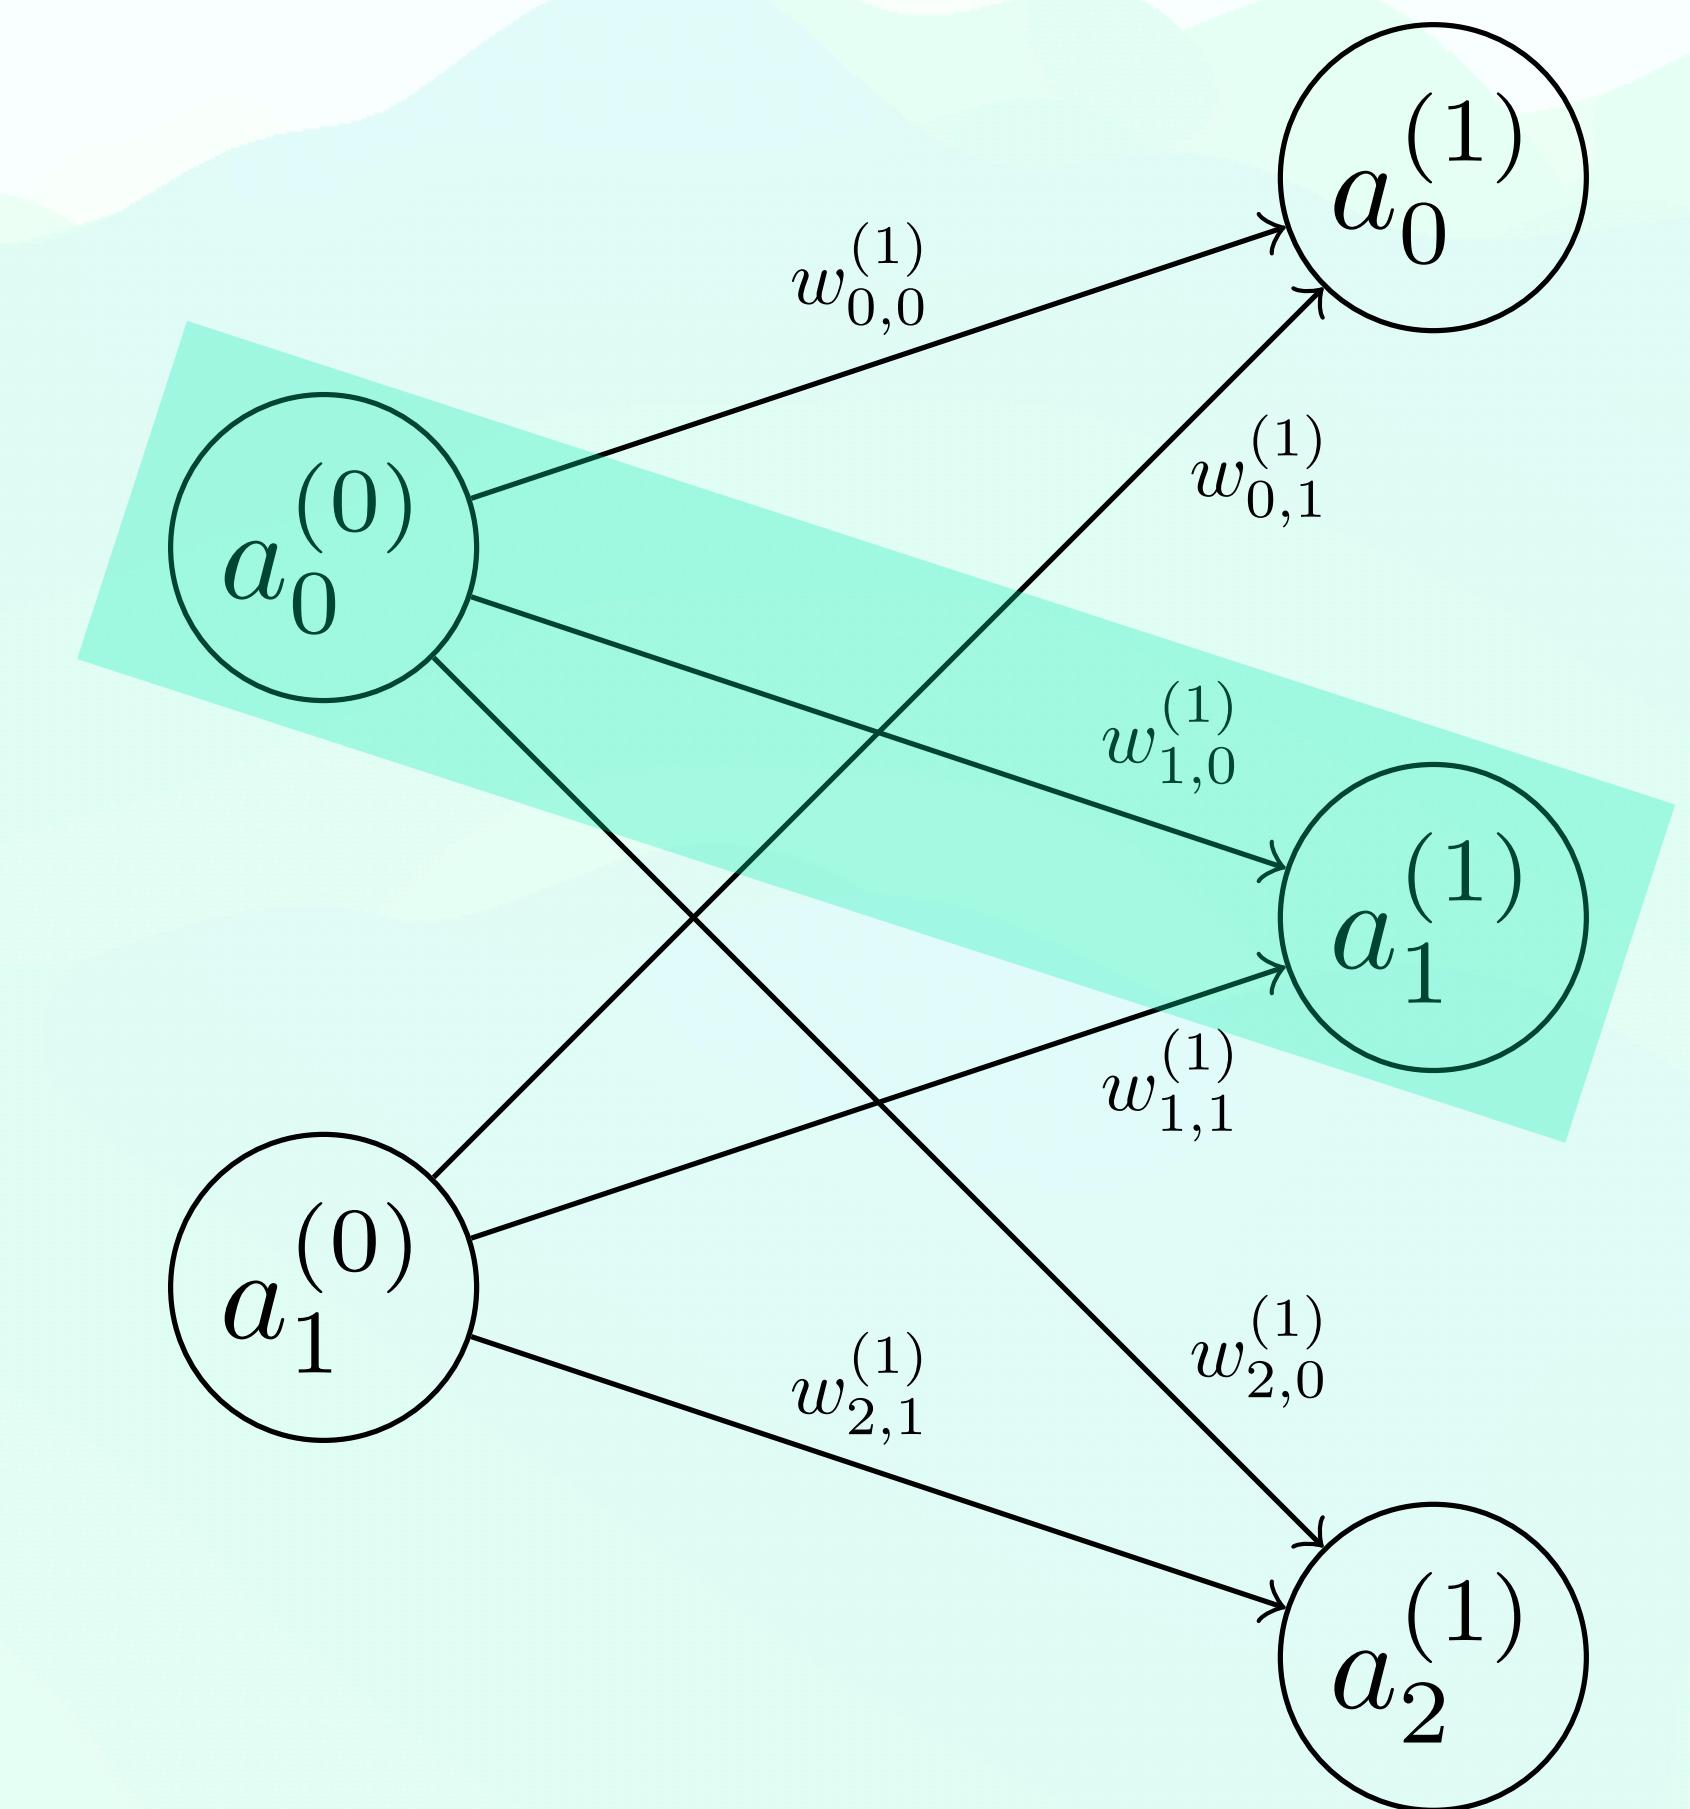
Noch einfacher:

Der Einfluss eines bestimmten **Gewichts** auf die **gewichtete Summe** ist exakt so groß wie die **Aktivierung** des Neurons, von dem es kommt.

$$\frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}} = \frac{\partial w_{jk}^{(l)} a_k^{(l-1)}}{\partial w_{jk}^{(l)}} = a_k^{(l-1)}$$

2

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

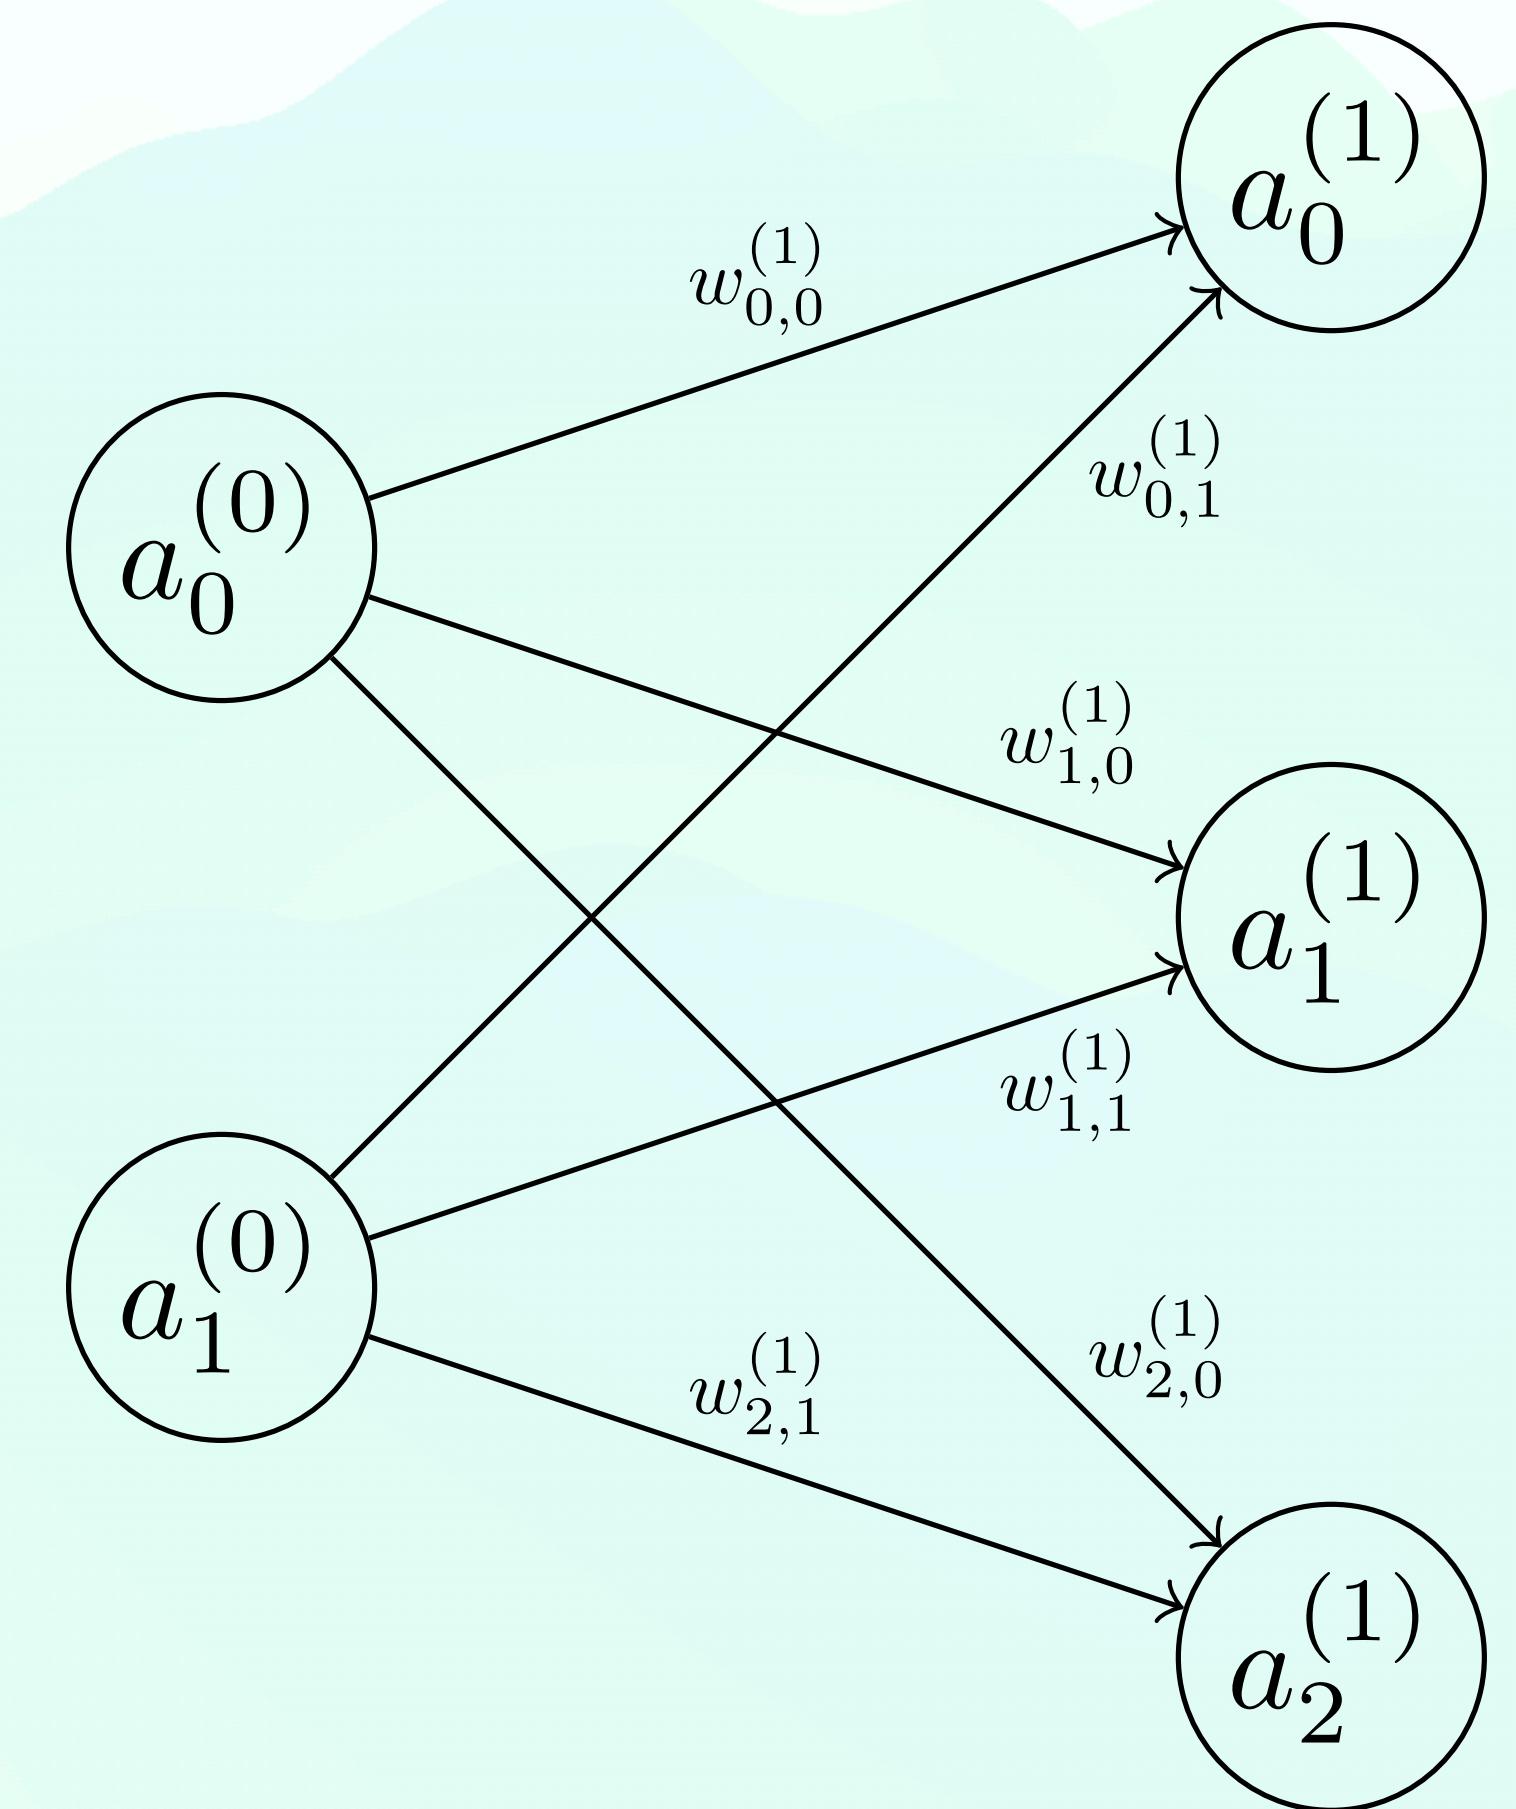
$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

# Ableitung der Kostenfunktion

- Aktivierung ergibt sich aus Aufruf der Aktivierungsfunktion mit der gewichteten Summe:

$$a_j^{(l)} = \sigma^{(l)} \left( z_j^{(l)} \right)$$

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

- Aktivierung ergibt sich aus Aufruf der Aktivierungsfunktion mit der gewichteten Summe:

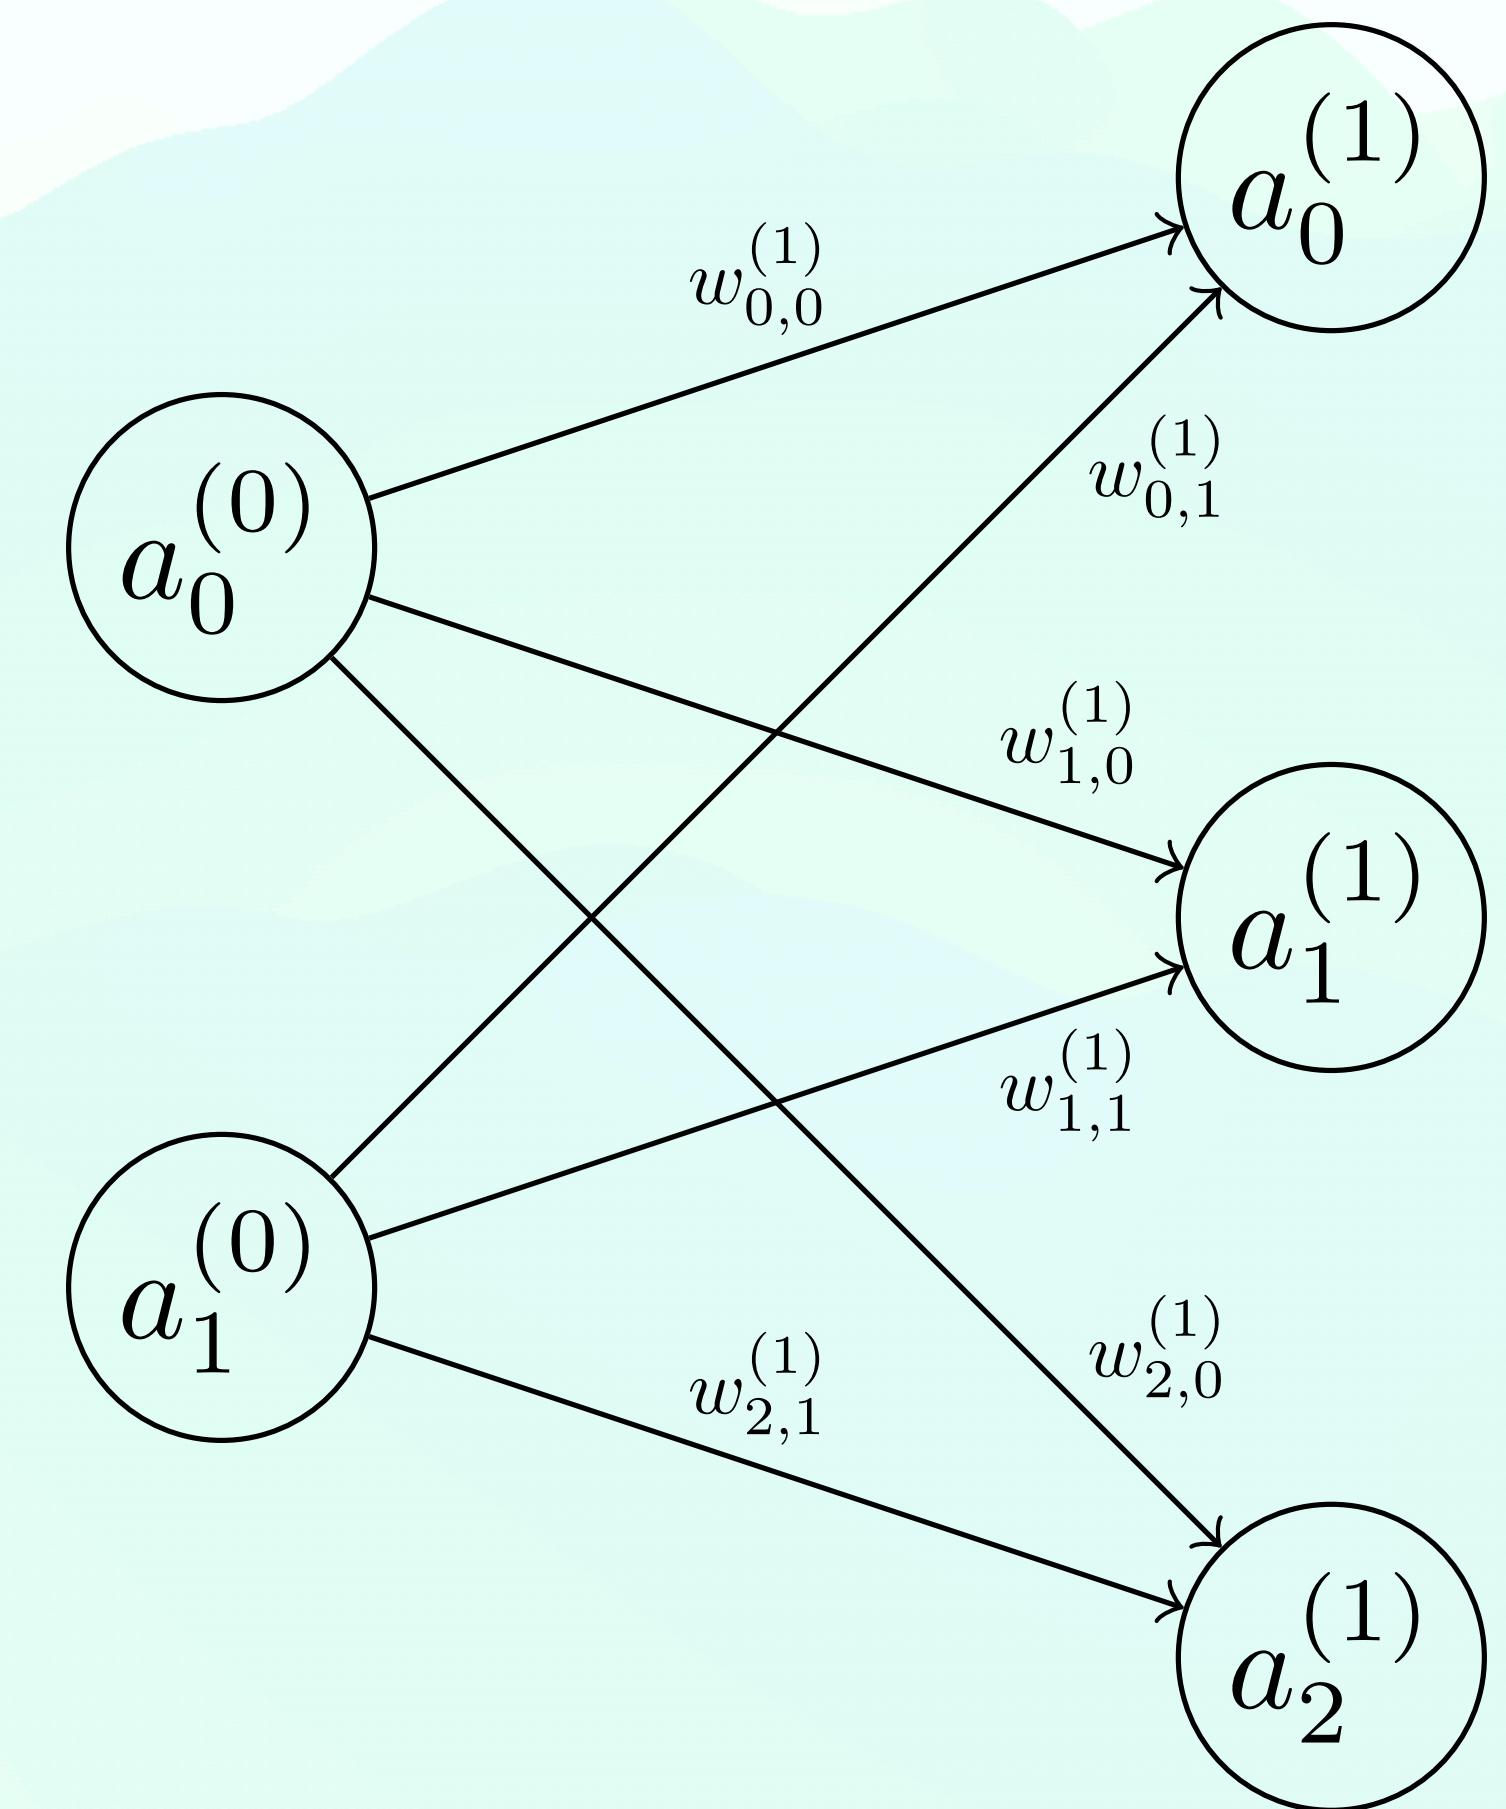
$$a_j^{(l)} = \sigma^{(l)} \left( z_j^{(l)} \right)$$

- Daher gilt:

$$\frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} = \sigma^{(l)'} \left( z_j^{(l)} \right)$$

3

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

- Aktivierung ergibt sich aus Aufruf der Aktivierungsfunktion mit der gewichteten Summe:

$$a_j^{(l)} = \sigma^{(l)} \left( z_j^{(l)} \right)$$

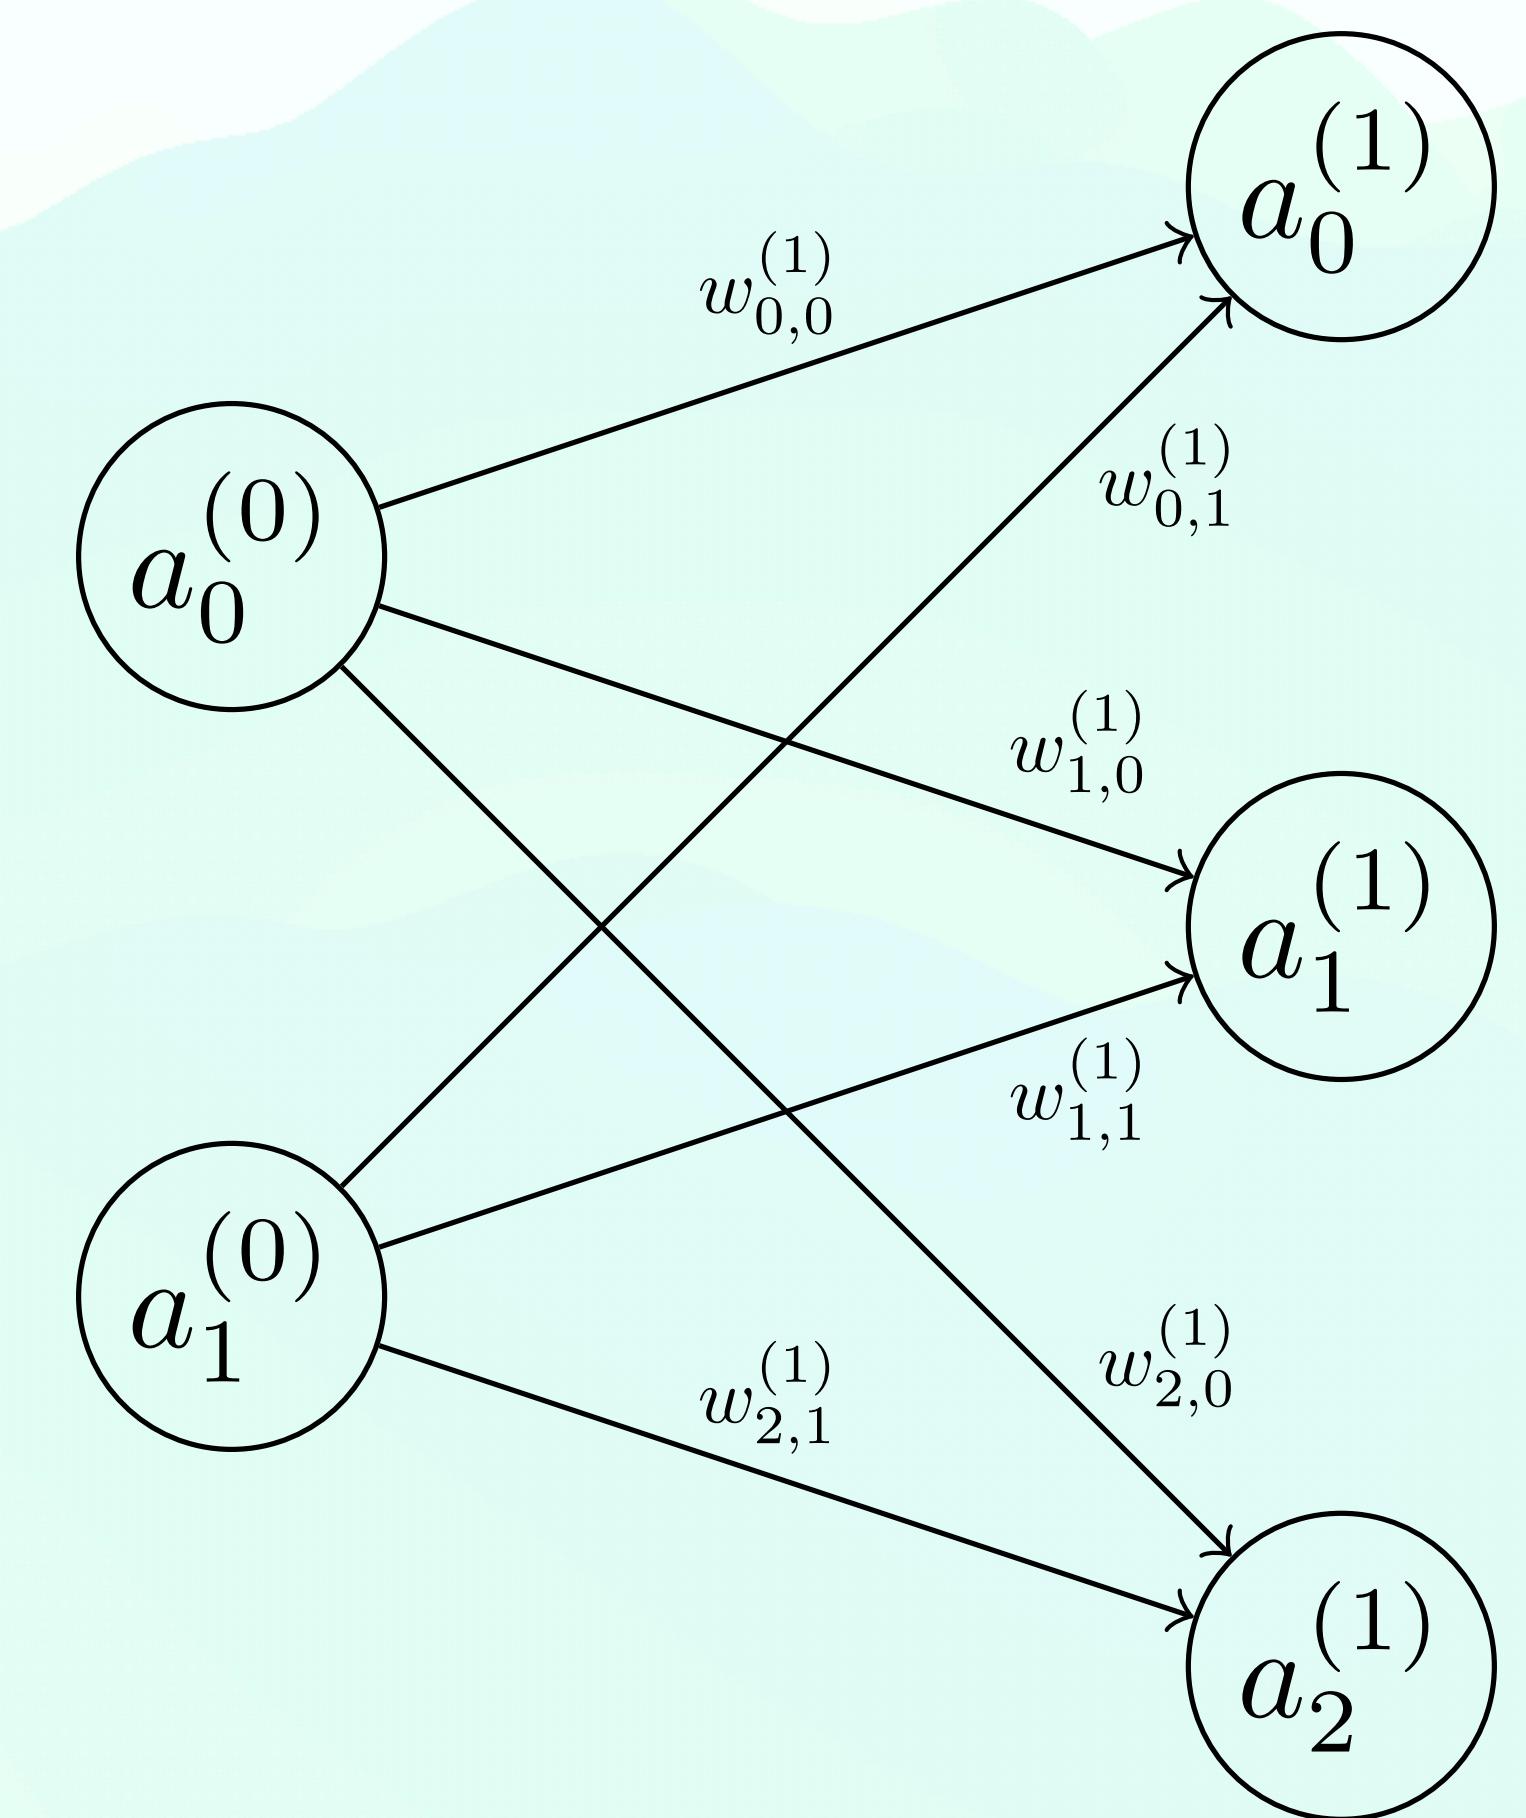
- Daher gilt:

$$\frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} = \sigma^{(l)'} \left( z_j^{(l)} \right)$$

3

- Wichtig bei der Wahl der Aktivierungsfunktion zu beachten: Berechnung sollte performant möglich sein und keinen **Vanishing Gradient** haben

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

$$\frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} = \sigma^{(l)'}(z_j^{(l)}) \quad 3$$

- ReLU und Sigmoid sind besonders einfach zu differenzieren:

$f(x)$	$f'(x)$
$\text{ReLU}(x) = \begin{cases} x & \text{wenn } x > 0 \\ 0 & \text{sonst} \end{cases}$	$\text{ReLU}'(x) = \begin{cases} 1 & \text{wenn } x > 0 \\ 0 & \text{sonst} \end{cases}$
$\sigma(x) = \frac{1}{1 + e^{-x}}$	$\sigma'(x) = \sigma(x) \cdot (1 - \sigma(x))$

# Ableitungen der Aktivierungsfunktionen



```
def relu(z, derivative=False):
    if derivative:
        return numpy.heaviside(z, 1)
    return numpy.maximum(z, 0)

def sigmoid(z, derivative=False):
    if derivative:
        return sigmoid(z) * (1 - sigmoid(z))
    return 1 / (1 + numpy.exp(-z))

def identity(z, derivative=False):
    if derivative:
        return numpy.ones_like(z)
    return z
```

# Ableitungen der Aktivierungsfunktionen



```
def relu(z, derivative=False):
    if derivative:
        return numpy.heaviside(z, 1)
    return numpy.maximum(z, 0)

def sigmoid(z, derivative=False):
    if derivative:
        return sigmoid(z) * (1 - sigmoid(z))
    return 1 / (1 + numpy.exp(-z))

def identity(z, derivative=False):
    if derivative:
        return numpy.ones_like(z)
    return z
```

Wir erweitern die Aktivierungsfunktionen jeweils um die Möglichkeit, auch ihre eigene **Ableitung** für  $z$  zu berechnen. Um die Ableitung zu erhalten, können wir dann künftig für den Parameter `derivative` den Wert `True` übergeben. Standardmäßig steht dieser Parameter aber auf `False`, ohne Parameter berechnet die Funktion also weiterhin die Aktivierung.

# Ableitungen der Aktivierungsfunktionen

$$\text{ReLU}'(x) = \begin{cases} 1 & \text{wenn } x > 0 \\ 0 & \text{sonst} \end{cases}$$



```
def relu(z, derivative=False):
    if derivative:
        return numpy.heaviside(z, 1)
    return numpy.maximum(z, 0)

def sigmoid(z, derivative=False):
    if derivative:
        return sigmoid(z) * (1 - sigmoid(z))
    return 1 / (1 + numpy.exp(-z))

def identity(z, derivative=False):
    if derivative:
        return numpy.ones_like(z)
    return z
```

Im Falle der ReLU-Funktion benutzen wir für den Fall, dass die Ableitung berechnet werden soll, die Funktion `numpy.heaviside`. Sie nimmt eine Matrix entgegen und gibt eine neue Matrix gleichen Formats zurück, in der alle Elemente `1` sind, die in der originalen Matrix größer als `0` waren, und alle Elemente `0` sind, die in der originalen Matrix kleiner als `0` waren. Dies entspricht genau der Ableitung von ReLU.

Der zweite Parameter `1` sagt aus, dass Werte gleich `0` in der Ergebnismatrix den Wert `1` bekommen sollen.

# Ableitungen der Aktivierungsfunktionen

$$\sigma'(x) = \sigma(x) \cdot (1 - \sigma(x))$$



```
def relu(z, derivative=False):
    if derivative:
        return numpy.heaviside(z, 1)
    return numpy.maximum(z, 0)

def sigmoid(z, derivative=False):
    if derivative:
        return sigmoid(z) * (1 - sigmoid(z))
    return 1 / (1 + numpy.exp(-z))

def identity(z, derivative=False):
    if derivative:
        return numpy.ones_like(z)
    return z
```

Für die Sigmoid-Funktion berechnen wir die Ableitung nach unserer **rekursiven** Berechnungsvorschrift.

# Ableitungen der Aktivierungsfunktionen



```
def relu(z, derivative=False):
    if derivative:
        return numpy.heaviside(z, 1)
    return numpy.maximum(z, 0)

def sigmoid(z, derivative=False):
    if derivative:
        return sigmoid(z) * (1 - sigmoid(z))
    return 1 / (1 + numpy.exp(-z))

def identity(z, derivative=False):
    if derivative:
        return numpy.ones_like(z)
    return z
```

Die Ableitung der Identitätsfunktion  $f(x) = x$  hat triviale Weise für jedes  $x$  den Wert 1.

# Ableitung der Kostenfunktion

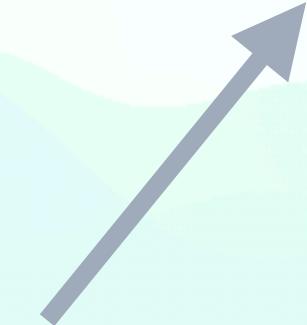
$$\frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} = \sigma^{(l)'}(z_j^{(l)})$$

3

Das bedeutet im Falle von ReLU als Aktivierungsfunktion:  
Da der Wert der Ableitung immer entweder 0 oder 1 ist,  
wird entweder das gesamte Produkt 0, oder es vereinfacht  
sich auf die beiden anderen Differentialterme.

$$\text{ReLU}'(x) = \begin{cases} 1 & \text{wenn } x > 0 \\ 0 & \text{sonst} \end{cases}$$

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

# Ableitung der Kostenfunktion

- Kosten nach Squared Error Loss:

$$C = \left( A^{(l)} - Y \right)^2$$

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

# Ableitung der Kostenfunktion

- Kosten nach Squared Error Loss:

$$C = \left( A^{(l)} - Y \right)^2$$

- Wir betrachten die einzelne Neuronenaktivierung  $a_j^{(l)}$ , und sie fließt nur durch den Term  $\left( a_j^{(l)} - y_j \right)^2$  in die Kosten ein. Für diesen gilt (z. B. nach Kettenregel) die Ableitung:

$$\frac{\partial C}{\partial a_j^{(l)}} = 2 \left( a_j^{(l)} - y_j \right)$$

4

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

# Ableitung der Kostenfunktion

- Kosten nach Squared Error Loss:

$$C = \left( A^{(l)} - Y \right)^2$$

- Wir betrachten die einzelne Neuronenaktivierung  $a_j^{(l)}$ , und sie fließt nur durch den Term  $\left( a_j^{(l)} - y_j \right)^2$  in die Kosten ein. Für diesen gilt (z. B. nach Kettenregel) die Ableitung:

$$\frac{\partial C}{\partial a_j^{(l)}} = 2 \left( a_j^{(l)} - y_j \right)$$

4

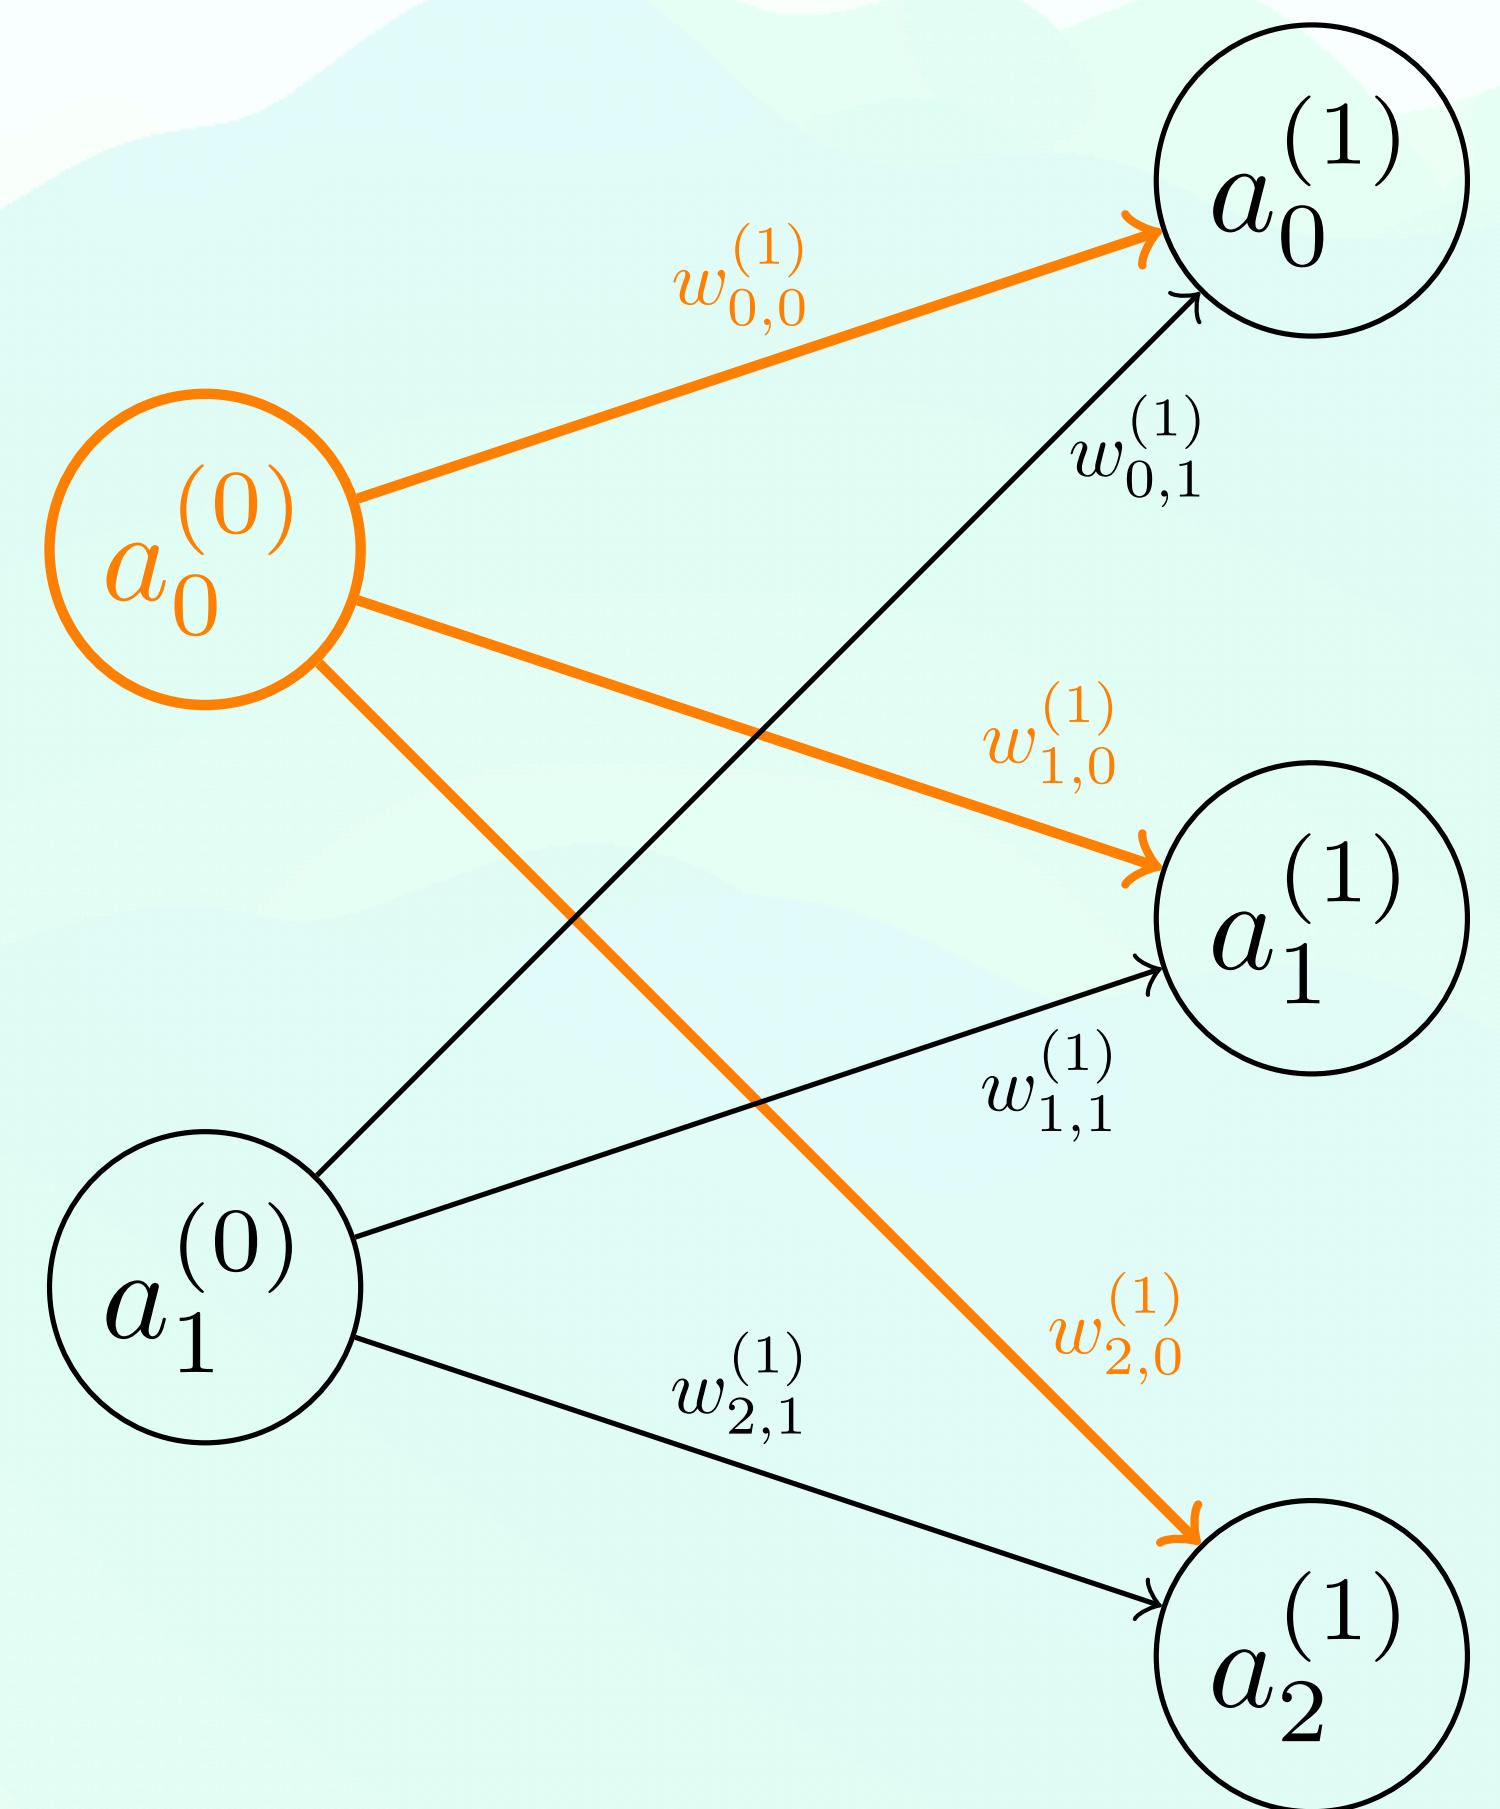
- Diese Berechnung ist natürlich nur im **Output-Layer** möglich, da nur hier die Kosten direkt von den erwarteten Outputs  $y_j$  abhängen!

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

# Ableitung der Kostenfunktion

- Die Aktivierung eines **inneren Neurons** beeinflusst die Kosten im nächsten Layer durch **alle ausgehenden Gewichte**

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

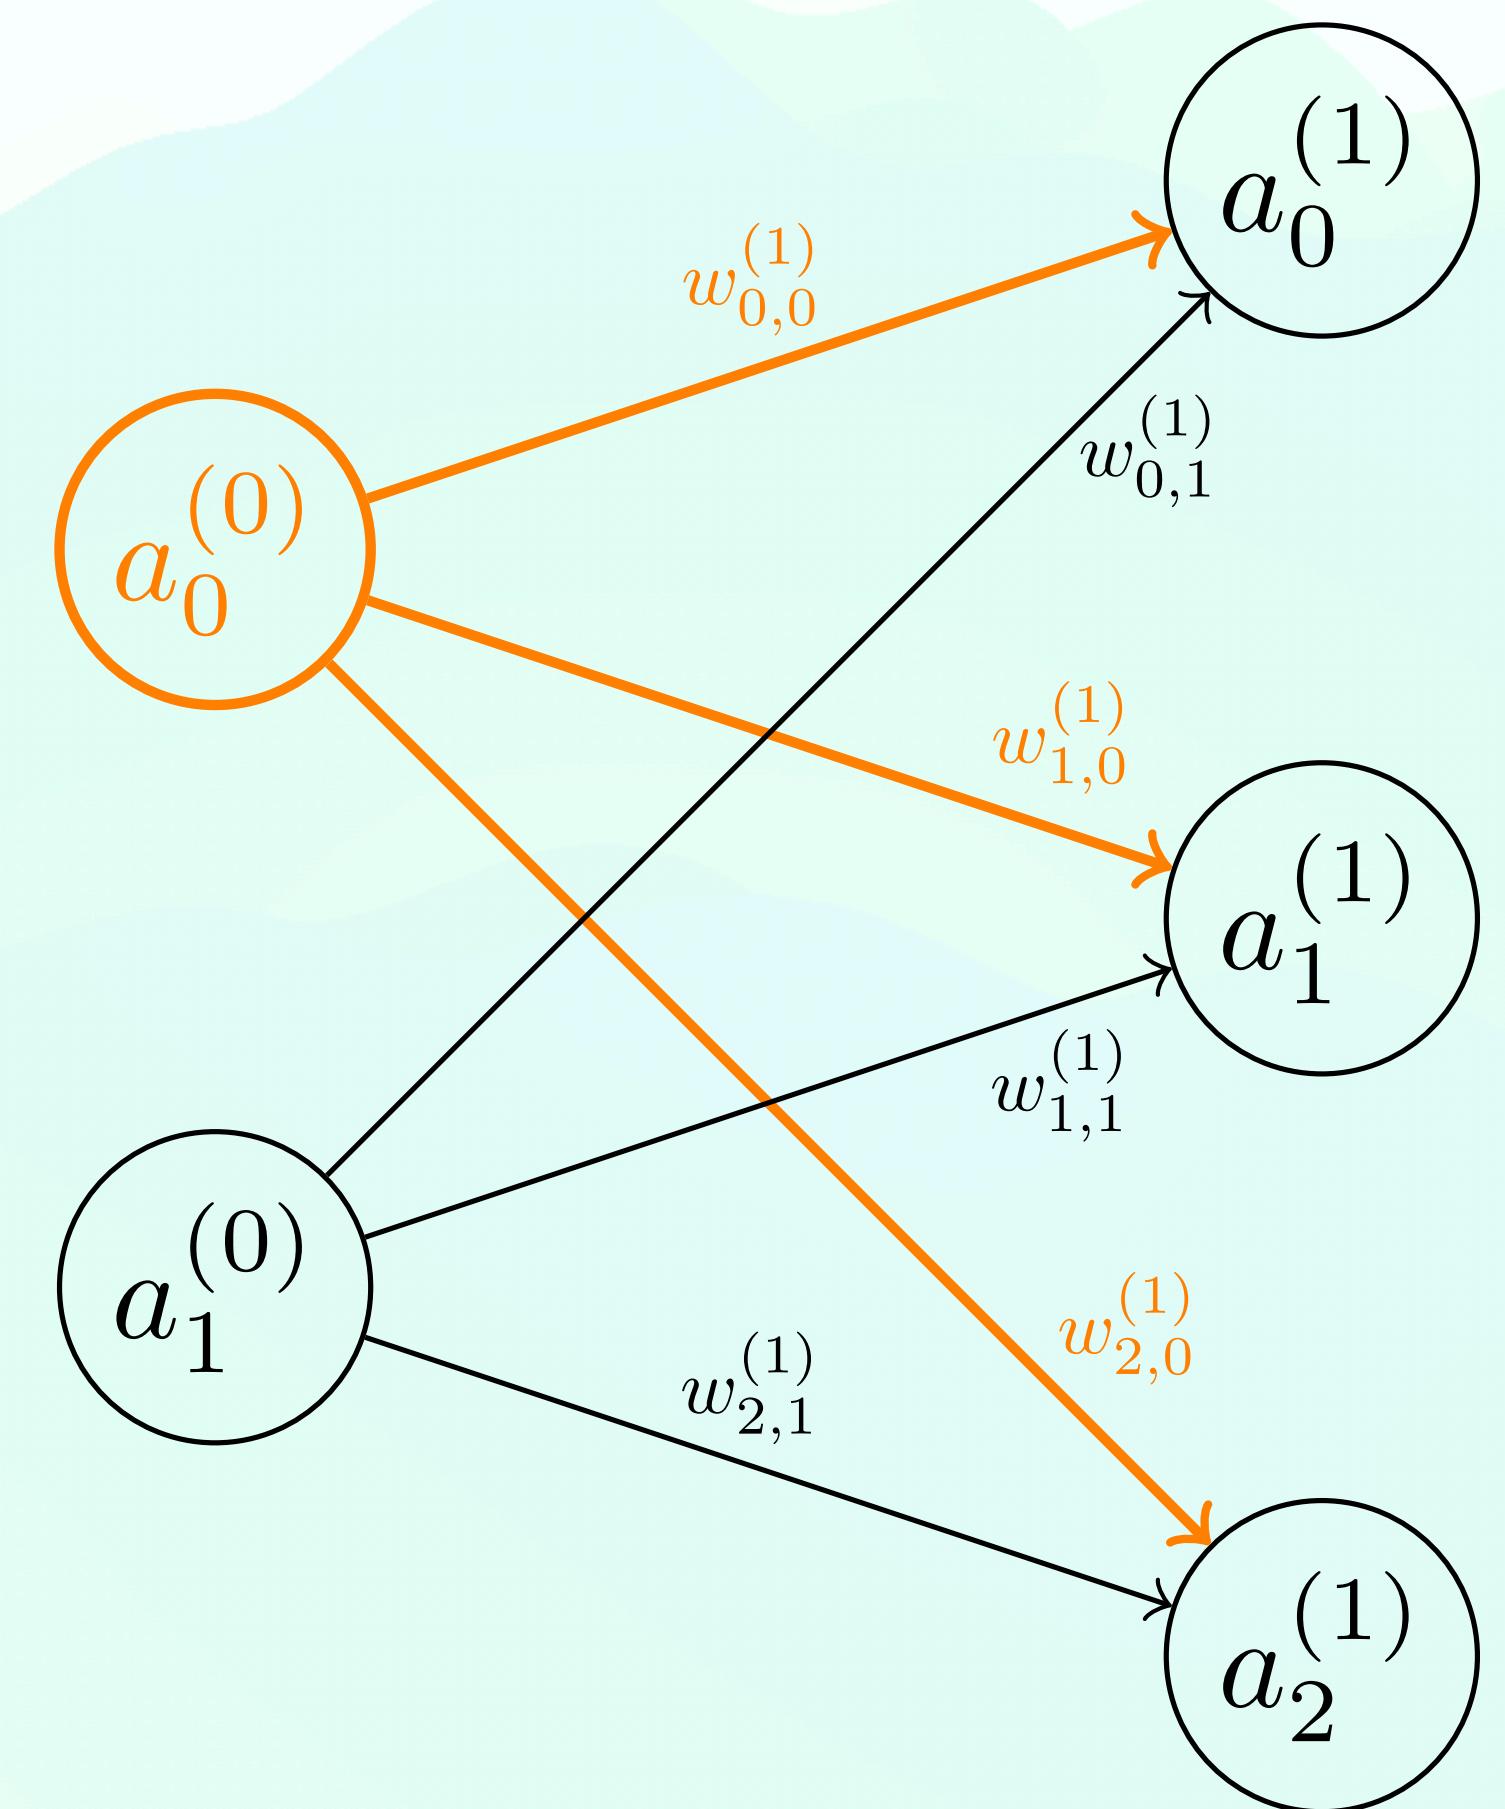


# Ableitung der Kostenfunktion

- Die Aktivierung eines **inneren Neurons** beeinflusst die Kosten im nächsten Layer durch **alle ausgehenden Gewichte**
- Daher müssen alle diese Einflüsse addiert werden:

$$\frac{\partial C}{\partial a_j^{(l)}} = \sum_{i=0}^{n^{(l+1)}-1} \left( \frac{\partial C}{\partial a_i^{(l+1)}} \frac{\partial a_i^{(l+1)}}{\partial z_i^{(l+1)}} \frac{\partial z_i^{(l+1)}}{\partial a_j^{(l)}} \right)$$

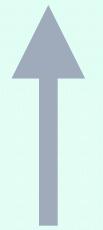
$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

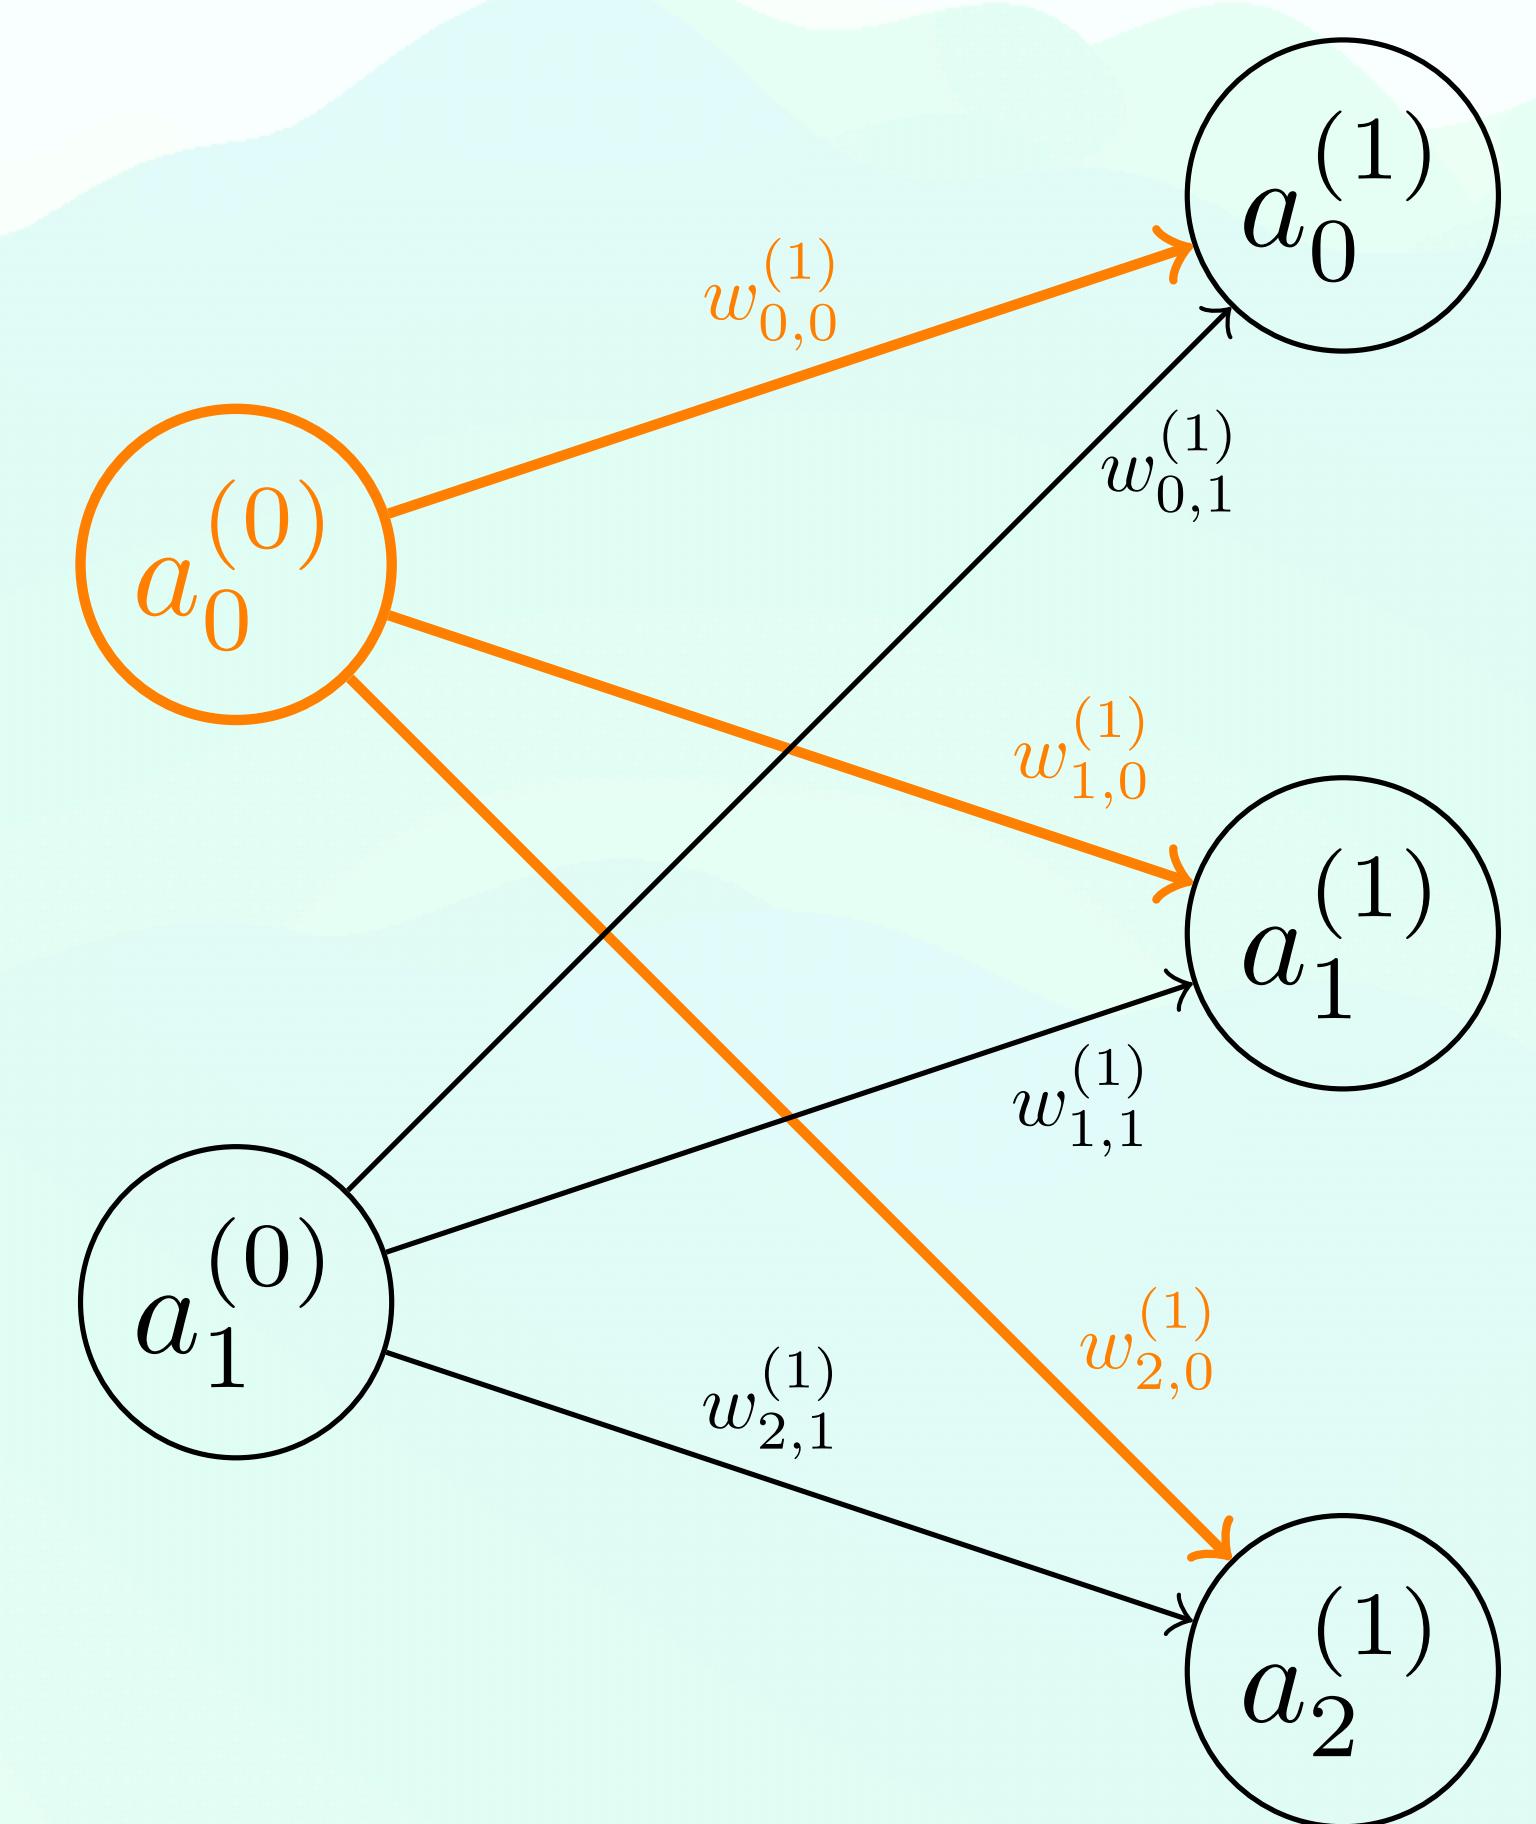
- Die Aktivierung eines **inneren Neurons** beeinflusst die Kosten im nächsten Layer durch **alle ausgehenden Gewichte**
- Daher müssen alle diese Einflüsse addiert werden:

$$\frac{\partial C}{\partial a_j^{(l)}} = \sum_{i=0}^{n^{(l+1)}-1} \left( \frac{\partial C}{\partial a_i^{(l+1)}} \frac{\partial a_i^{(l+1)}}{\partial z_i^{(l+1)}} \frac{\partial z_i^{(l+1)}}{\partial a_j^{(l)}} \right)$$



Erneut die Kettenregel: Jede „Kette“, also jeder Pfad, durch den  $a_j^{(l)}$  die Kosten beeinflusst, wird in sich multipliziert, und die einzelnen Ketten dann addiert

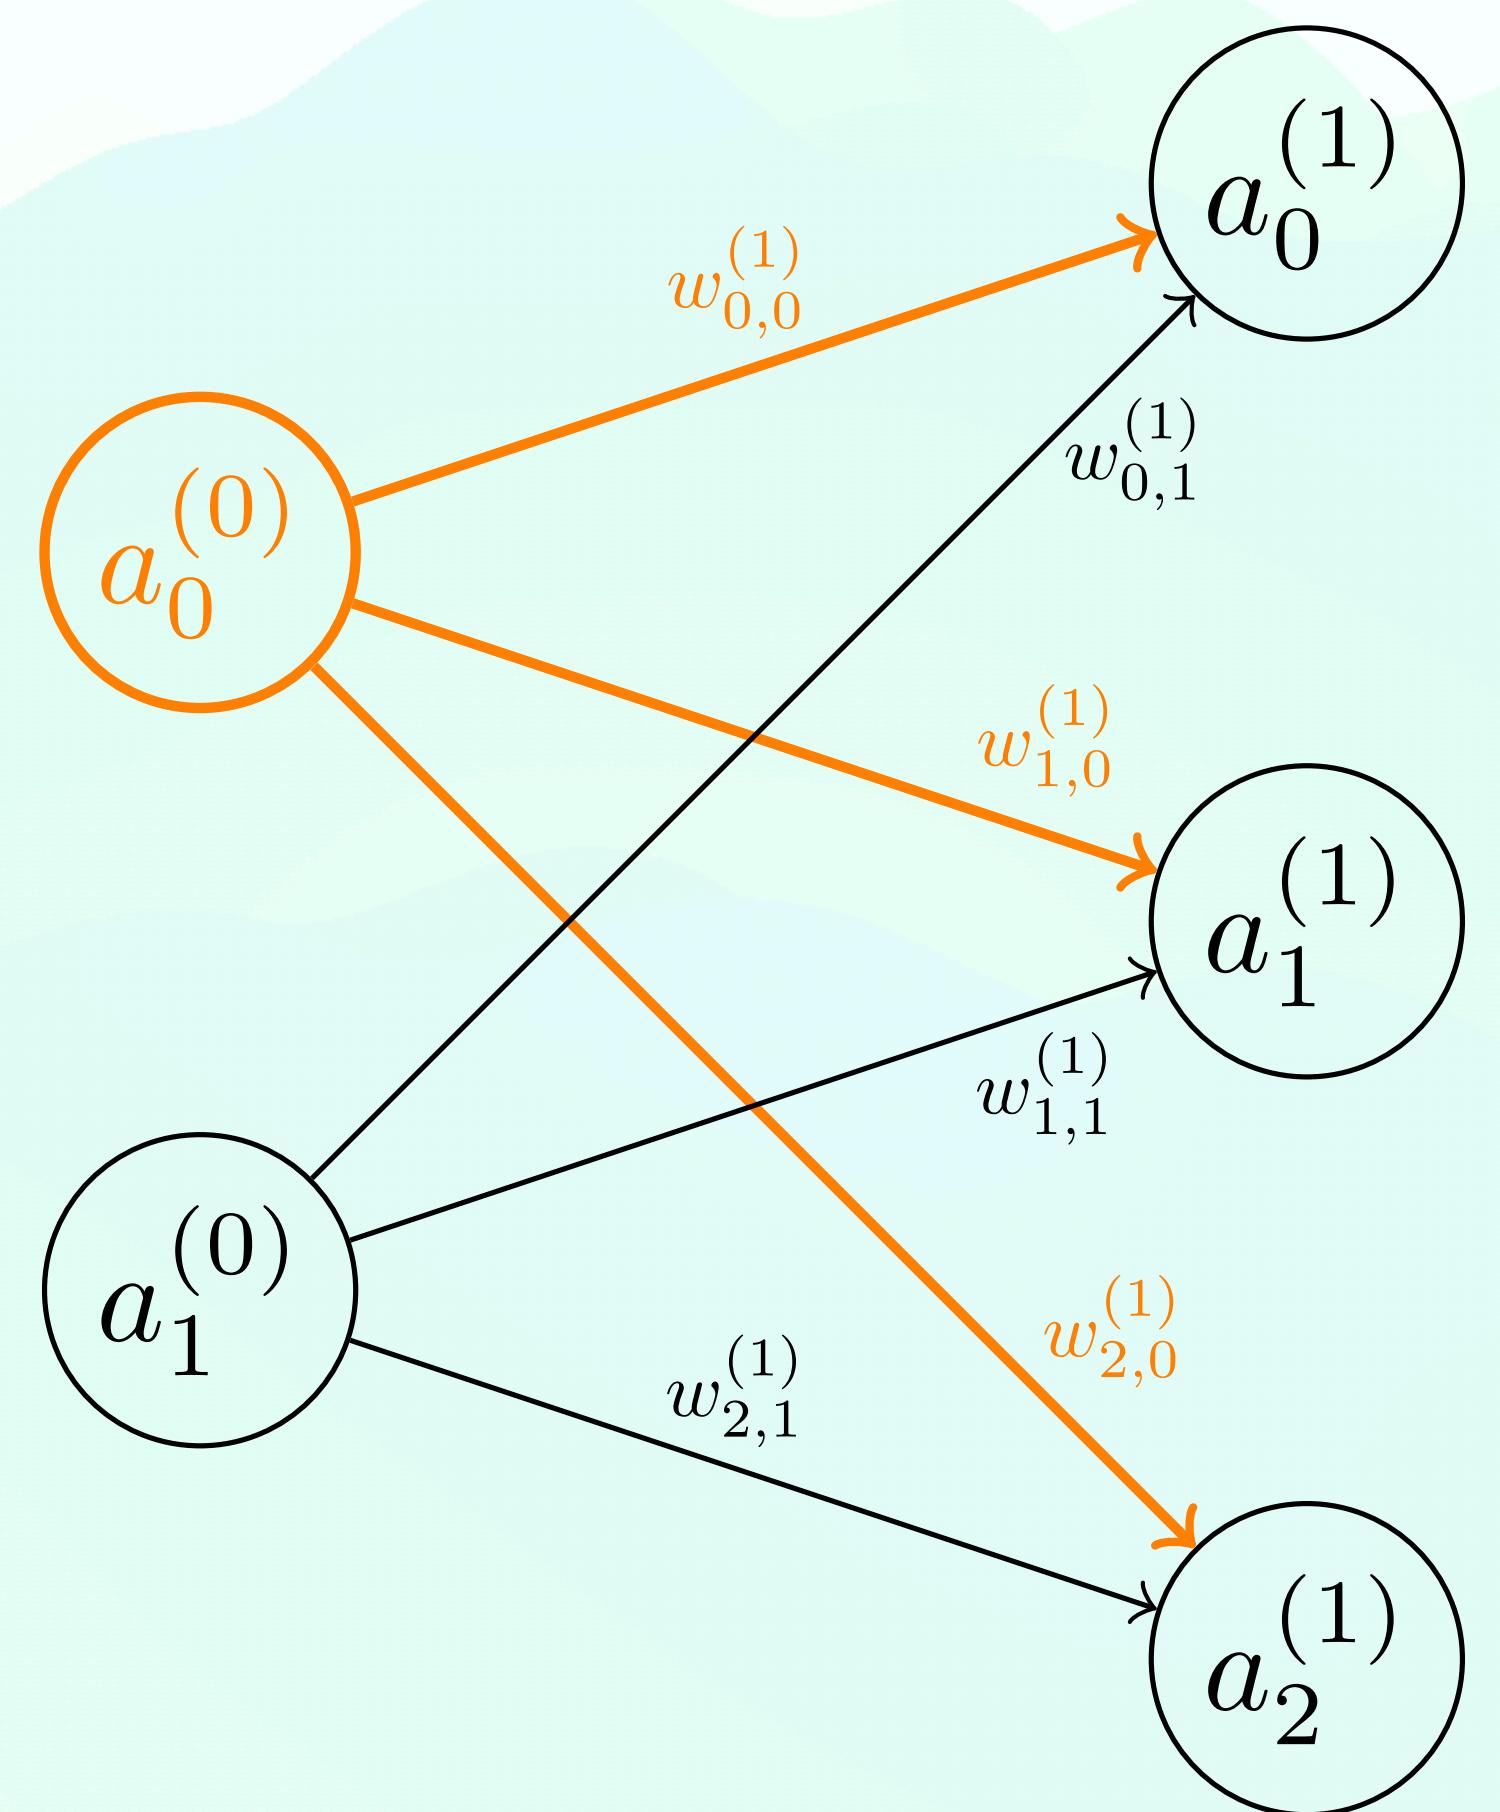
$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

$$\frac{\partial C}{\partial a_j^{(l)}} = \sum_{i=0}^{n^{(l+1)}-1} \left( \frac{\partial C}{\partial a_i^{(l+1)}} \frac{\partial a_i^{(l+1)}}{\partial z_i^{(l+1)}} \frac{\partial z_i^{(l+1)}}{\partial a_j^{(l)}} \right)$$

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

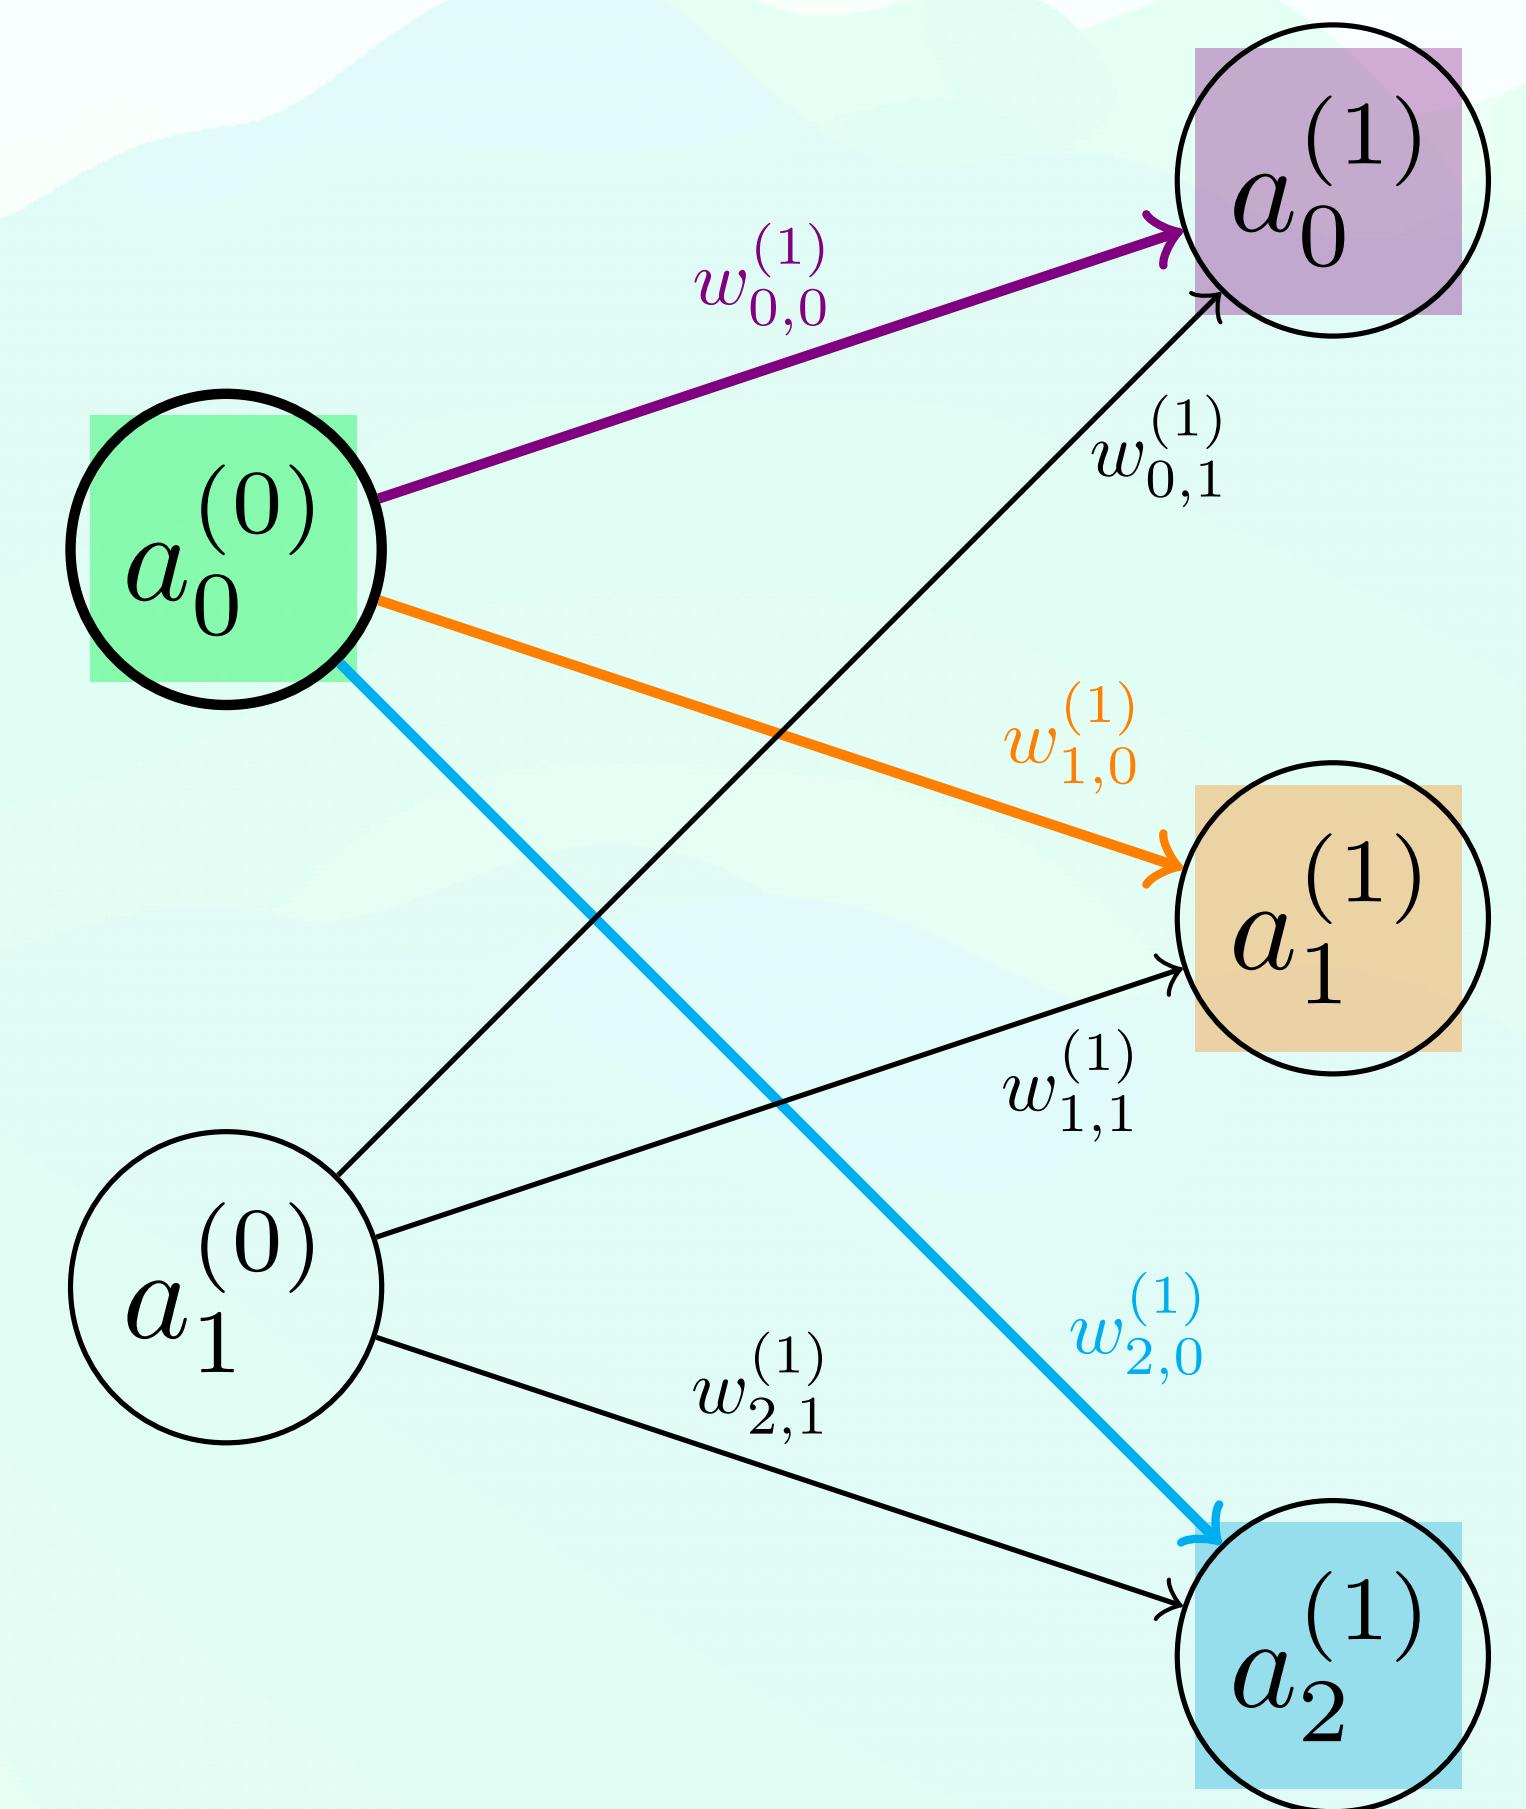
$$\frac{\partial C}{\partial a_j^{(l)}} = \sum_{i=0}^{n^{(l+1)}-1} \left( \frac{\partial C}{\partial a_i^{(l+1)}} \frac{\partial a_i^{(l+1)}}{\partial z_i^{(l+1)}} \frac{\partial z_i^{(l+1)}}{\partial a_j^{(l)}} \right)$$

- Für den Ausschnitt aus dem Beispielnetz rechts bedeutet das:

$$\frac{\partial C}{\partial a_0^{(0)}} = \frac{\partial C}{\partial a_0^{(1)}} \frac{\partial a_0^{(1)}}{\partial z_0^{(1)}} \frac{\partial z_0^{(1)}}{\partial a_0^{(0)}} +$$

$$+ \frac{\partial C}{\partial a_1^{(1)}} \frac{\partial a_1^{(1)}}{\partial z_1^{(1)}} \frac{\partial z_1^{(1)}}{\partial a_0^{(0)}} +$$

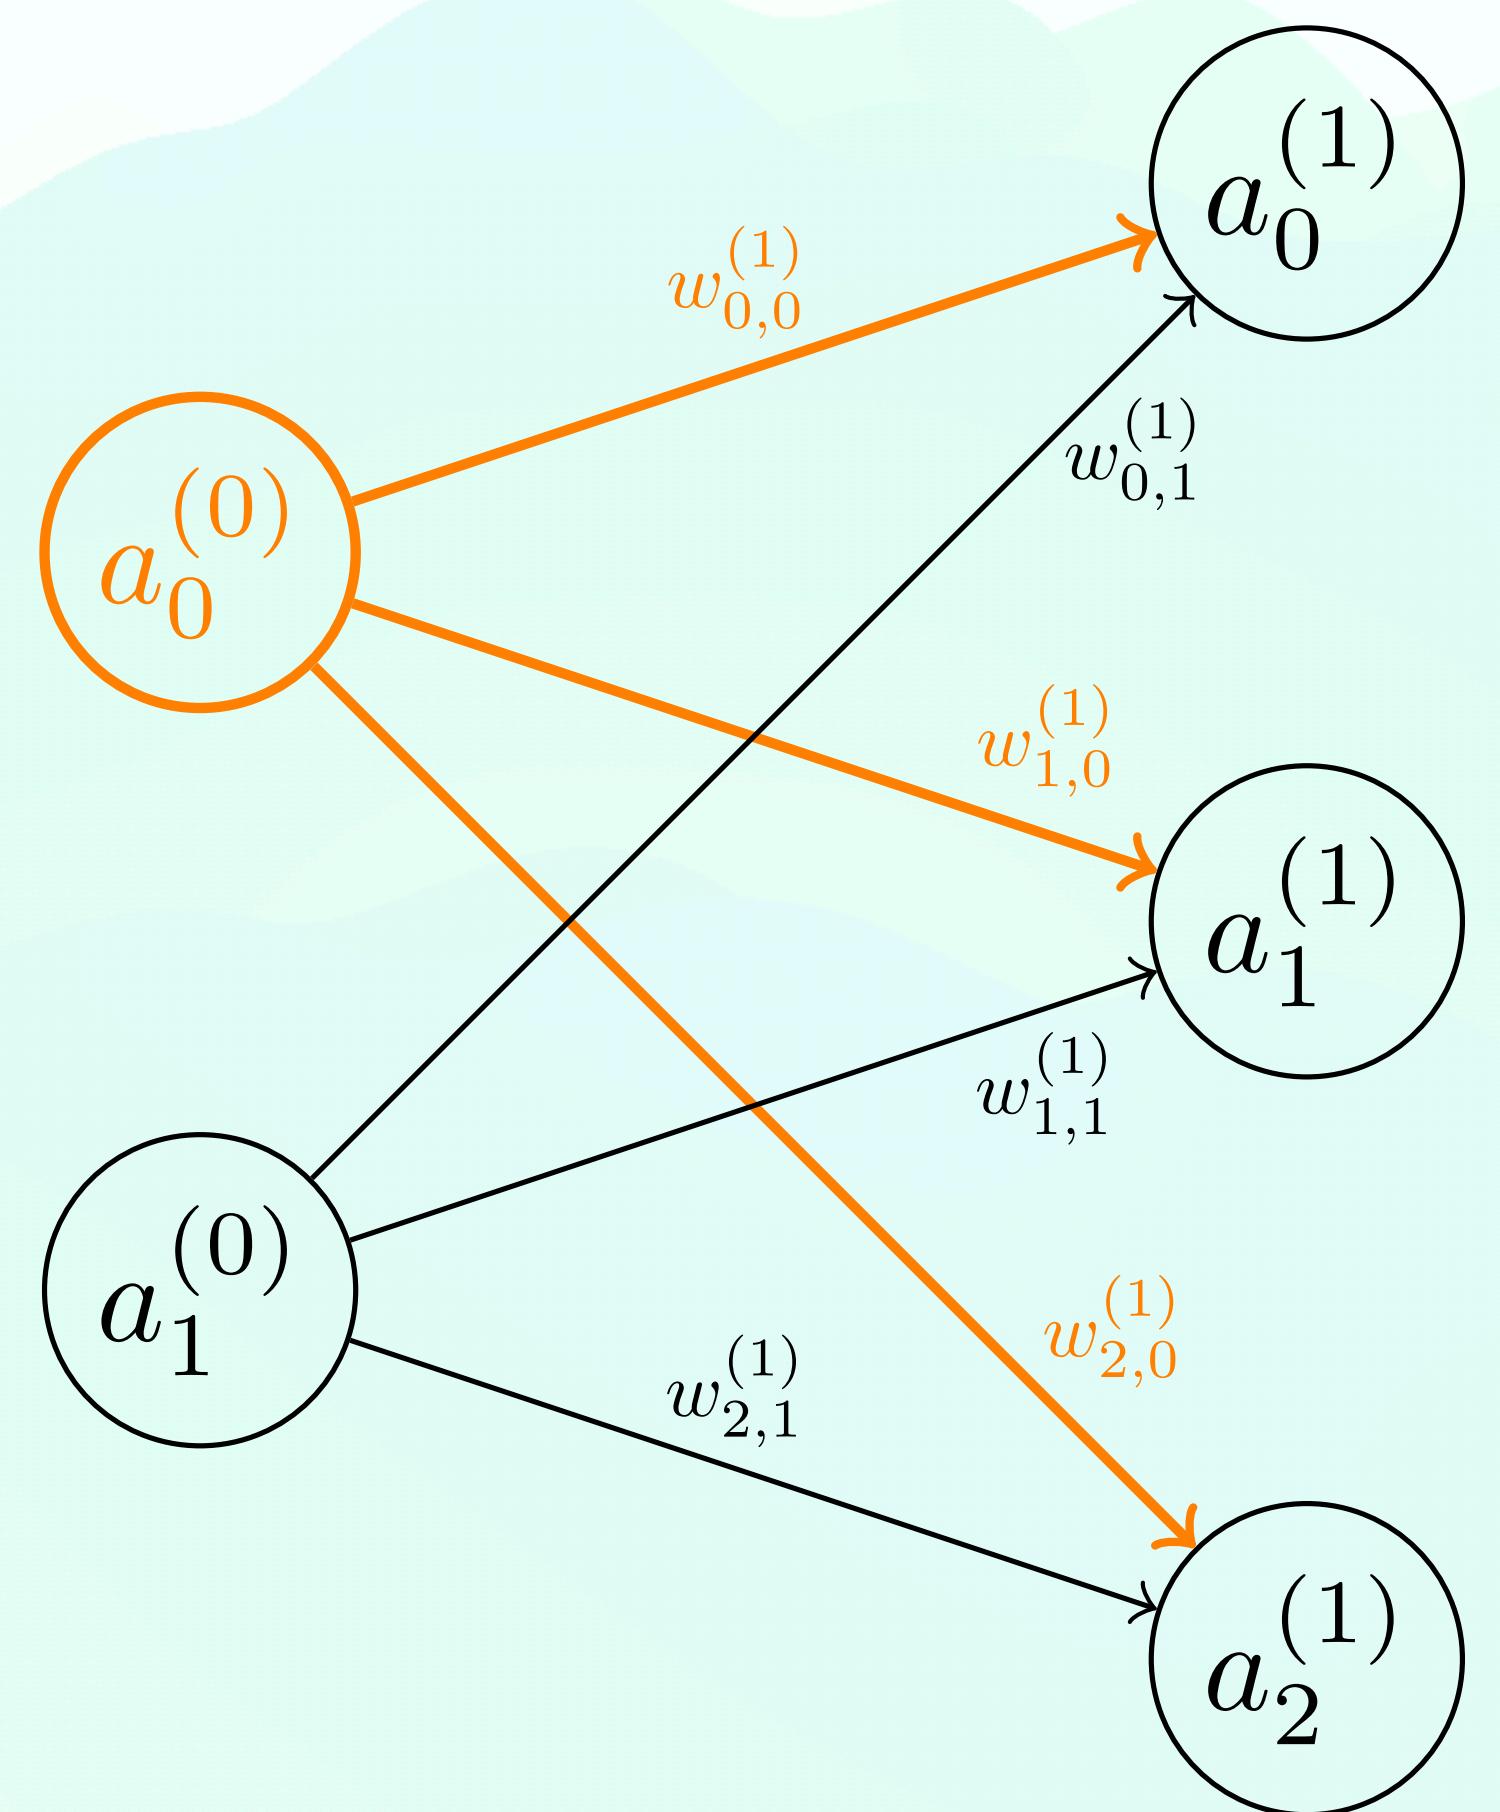
$$+ \frac{\partial C}{\partial a_2^{(1)}} \frac{\partial a_2^{(1)}}{\partial z_2^{(1)}} \frac{\partial z_2^{(1)}}{\partial a_0^{(0)}}$$



# Ableitung der Kostenfunktion

$$\frac{\partial C}{\partial a_j^{(l)}} = \sum_{i=0}^{n^{(l+1)}-1} \left( \frac{\partial C}{\partial a_i^{(l+1)}} \frac{\partial a_i^{(l+1)}}{\partial z_i^{(l+1)}} \frac{\partial z_i^{(l+1)}}{\partial a_j^{(l)}} \right)$$

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

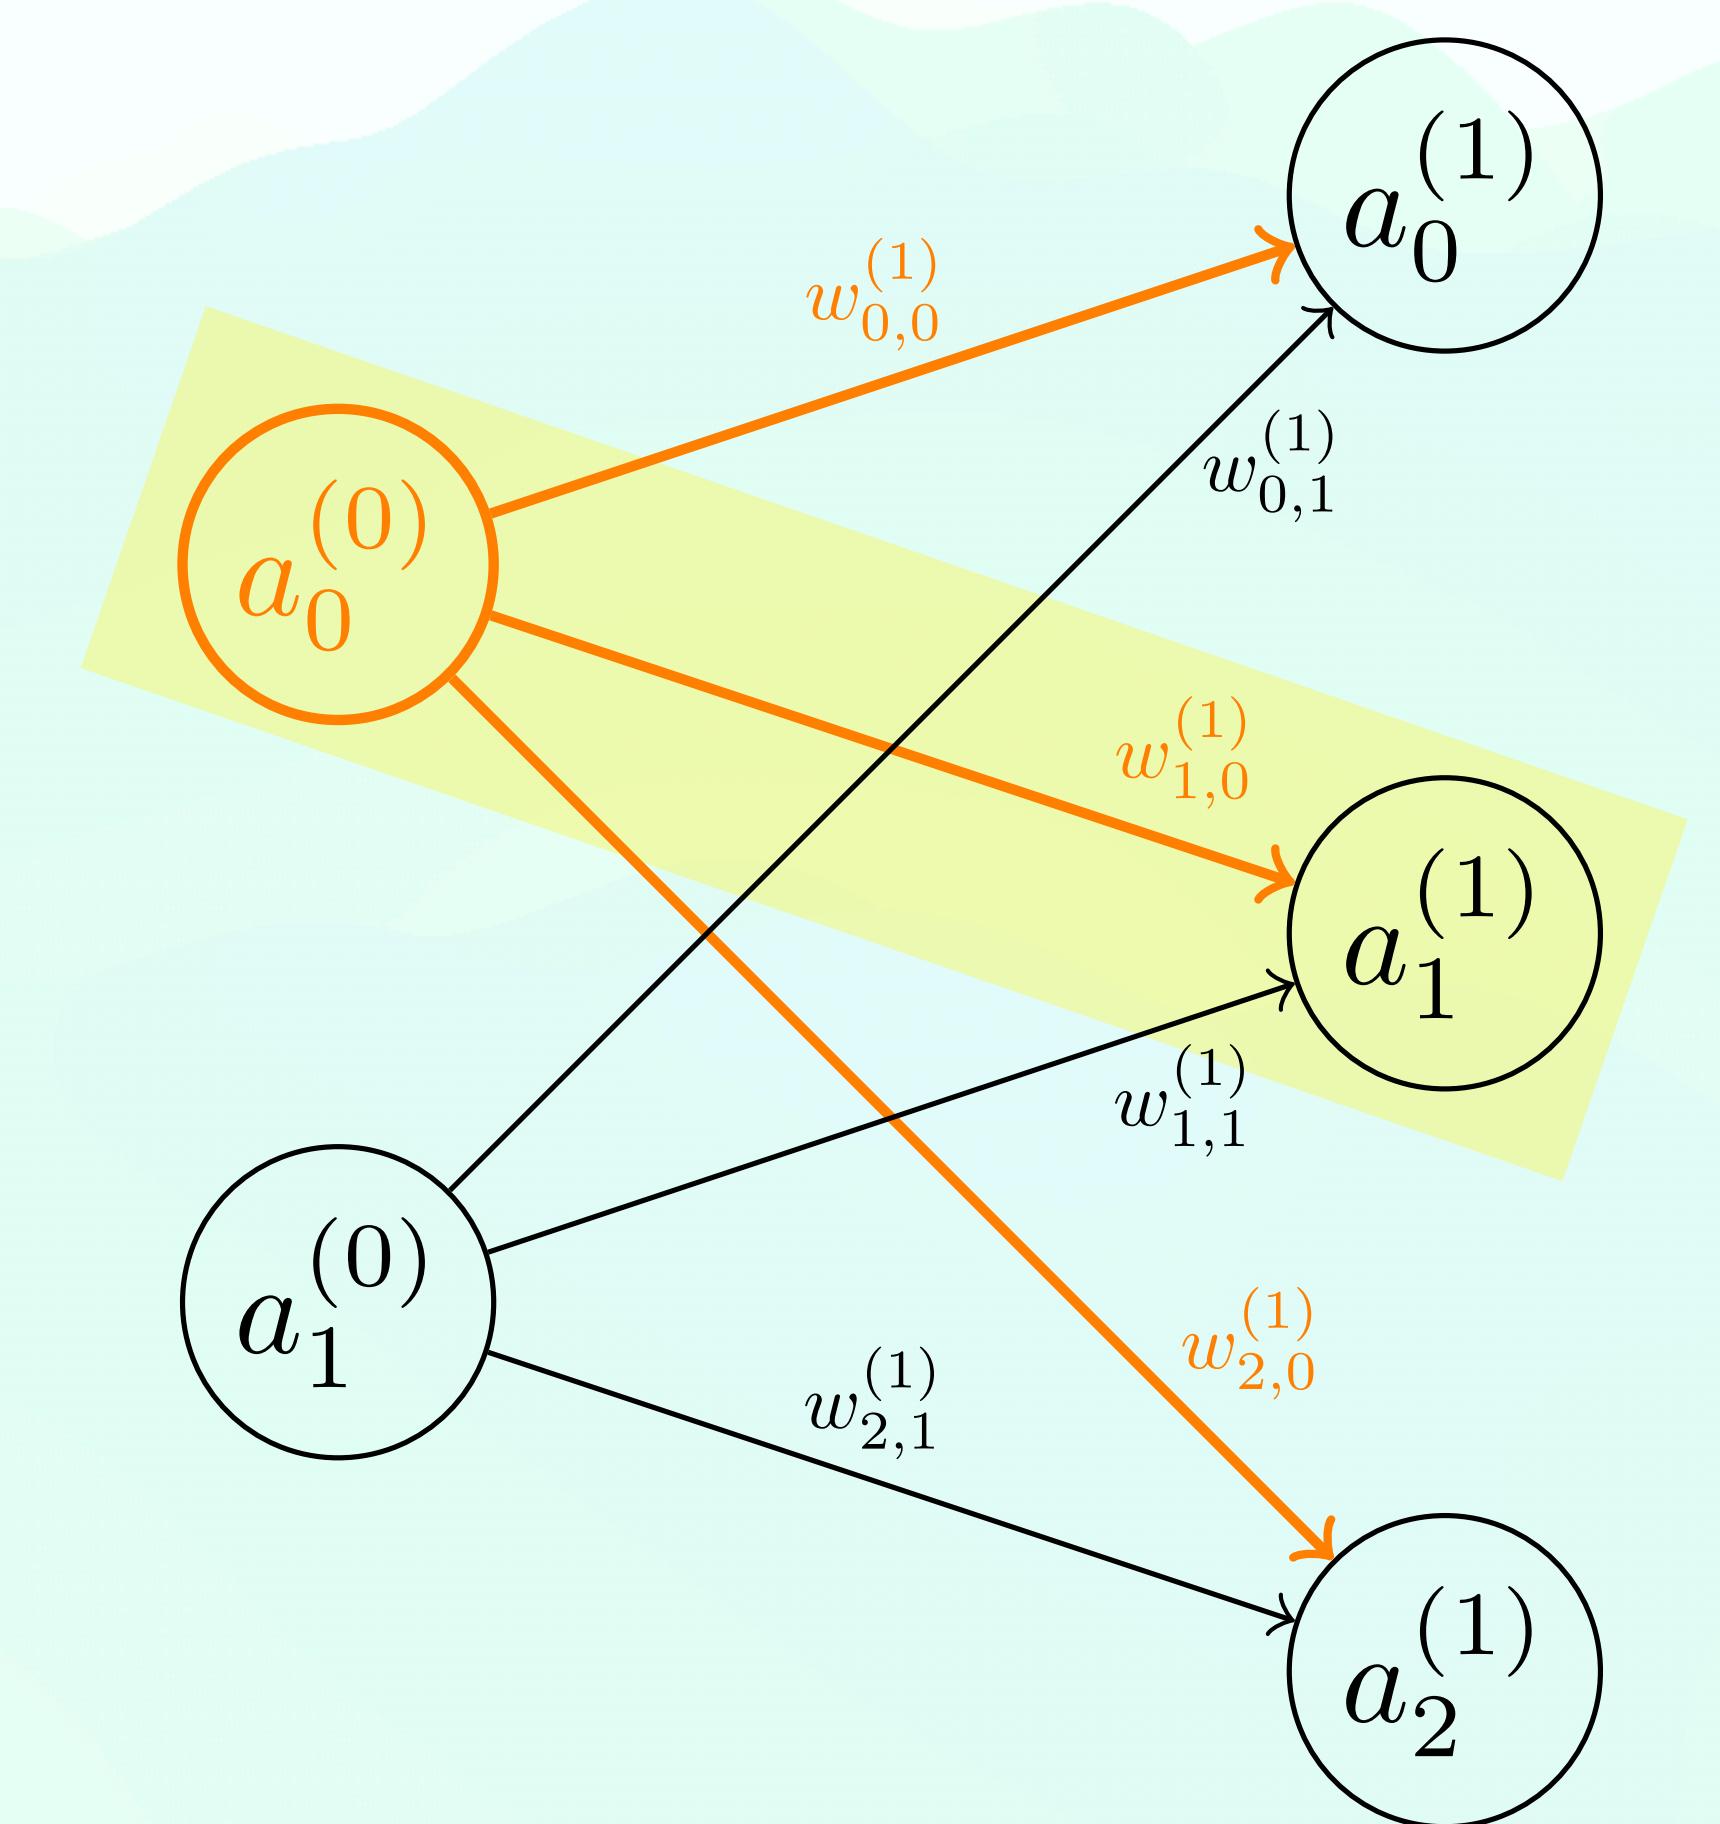


# Ableitung der Kostenfunktion

$$\frac{\partial C}{\partial a_j^{(l)}} = \sum_{i=0}^{n^{(l+1)}-1} \left( \frac{\partial C}{\partial a_i^{(l+1)}} \frac{\partial a_i^{(l+1)}}{\partial z_i^{(l+1)}} \frac{\partial z_i^{(l+1)}}{\partial a_j^{(l)}} \right)$$

Der Einfluss der einzelnen **Neuronenaktivierung** auf die **gewichtete Summe** ist hier genau so groß, wie das **Gewicht** zwischen beiden betroffenen Neuronen:  $w_{ij}^{(l+1)}$

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

$$\frac{\partial C}{\partial a_j^{(l)}} = \sum_{i=0}^{n^{(l+1)}-1} \left( \frac{\partial C}{\partial a_i^{(l+1)}} \frac{\partial a_i^{(l+1)}}{\partial z_i^{(l+1)}} \frac{\partial z_i^{(l+1)}}{\partial a_j^{(l)}} \right)$$

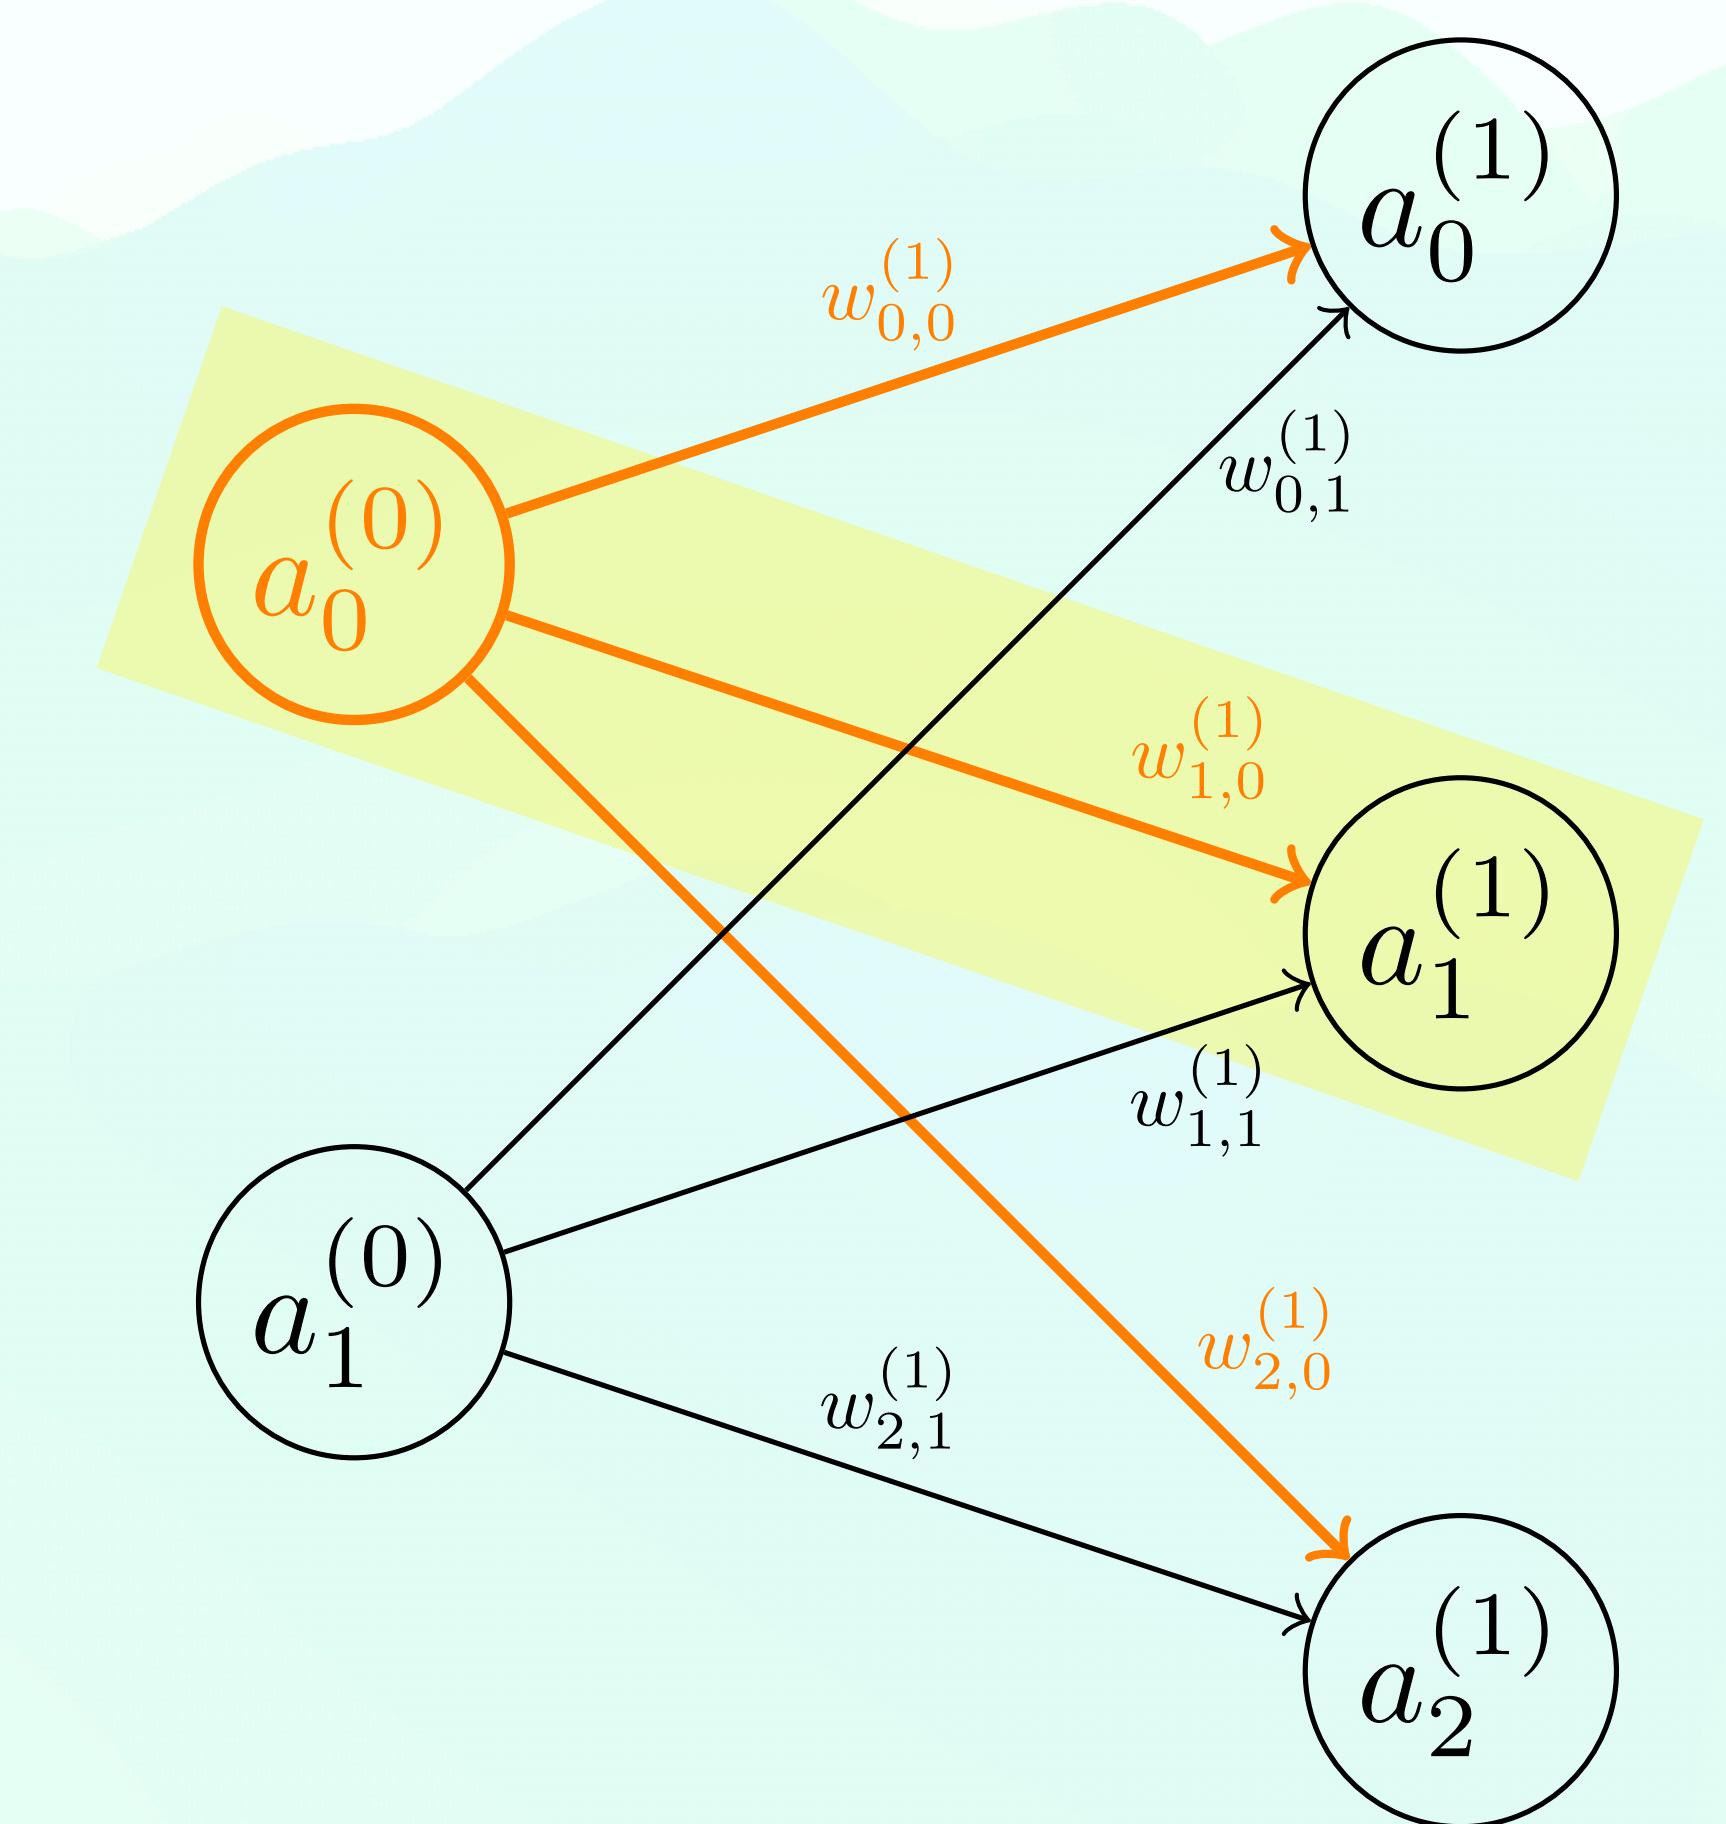
Der Einfluss der einzelnen **Neuronenaktivierung** auf die **gewichtete Summe** ist hier genau so groß, wie das **Gewicht** zwischen beiden betroffenen Neuronen:  $w_{ij}^{(l+1)}$

Daher können wir vereinfachen:

$$\frac{\partial C}{\partial a_j^{(l)}} = \sum_{i=0}^{n^{(l+1)}-1} \left( \frac{\partial C}{\partial a_i^{(l+1)}} \frac{\partial a_i^{(l+1)}}{\partial z_i^{(l+1)}} w_{ij}^{(l+1)} \right)$$

5

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

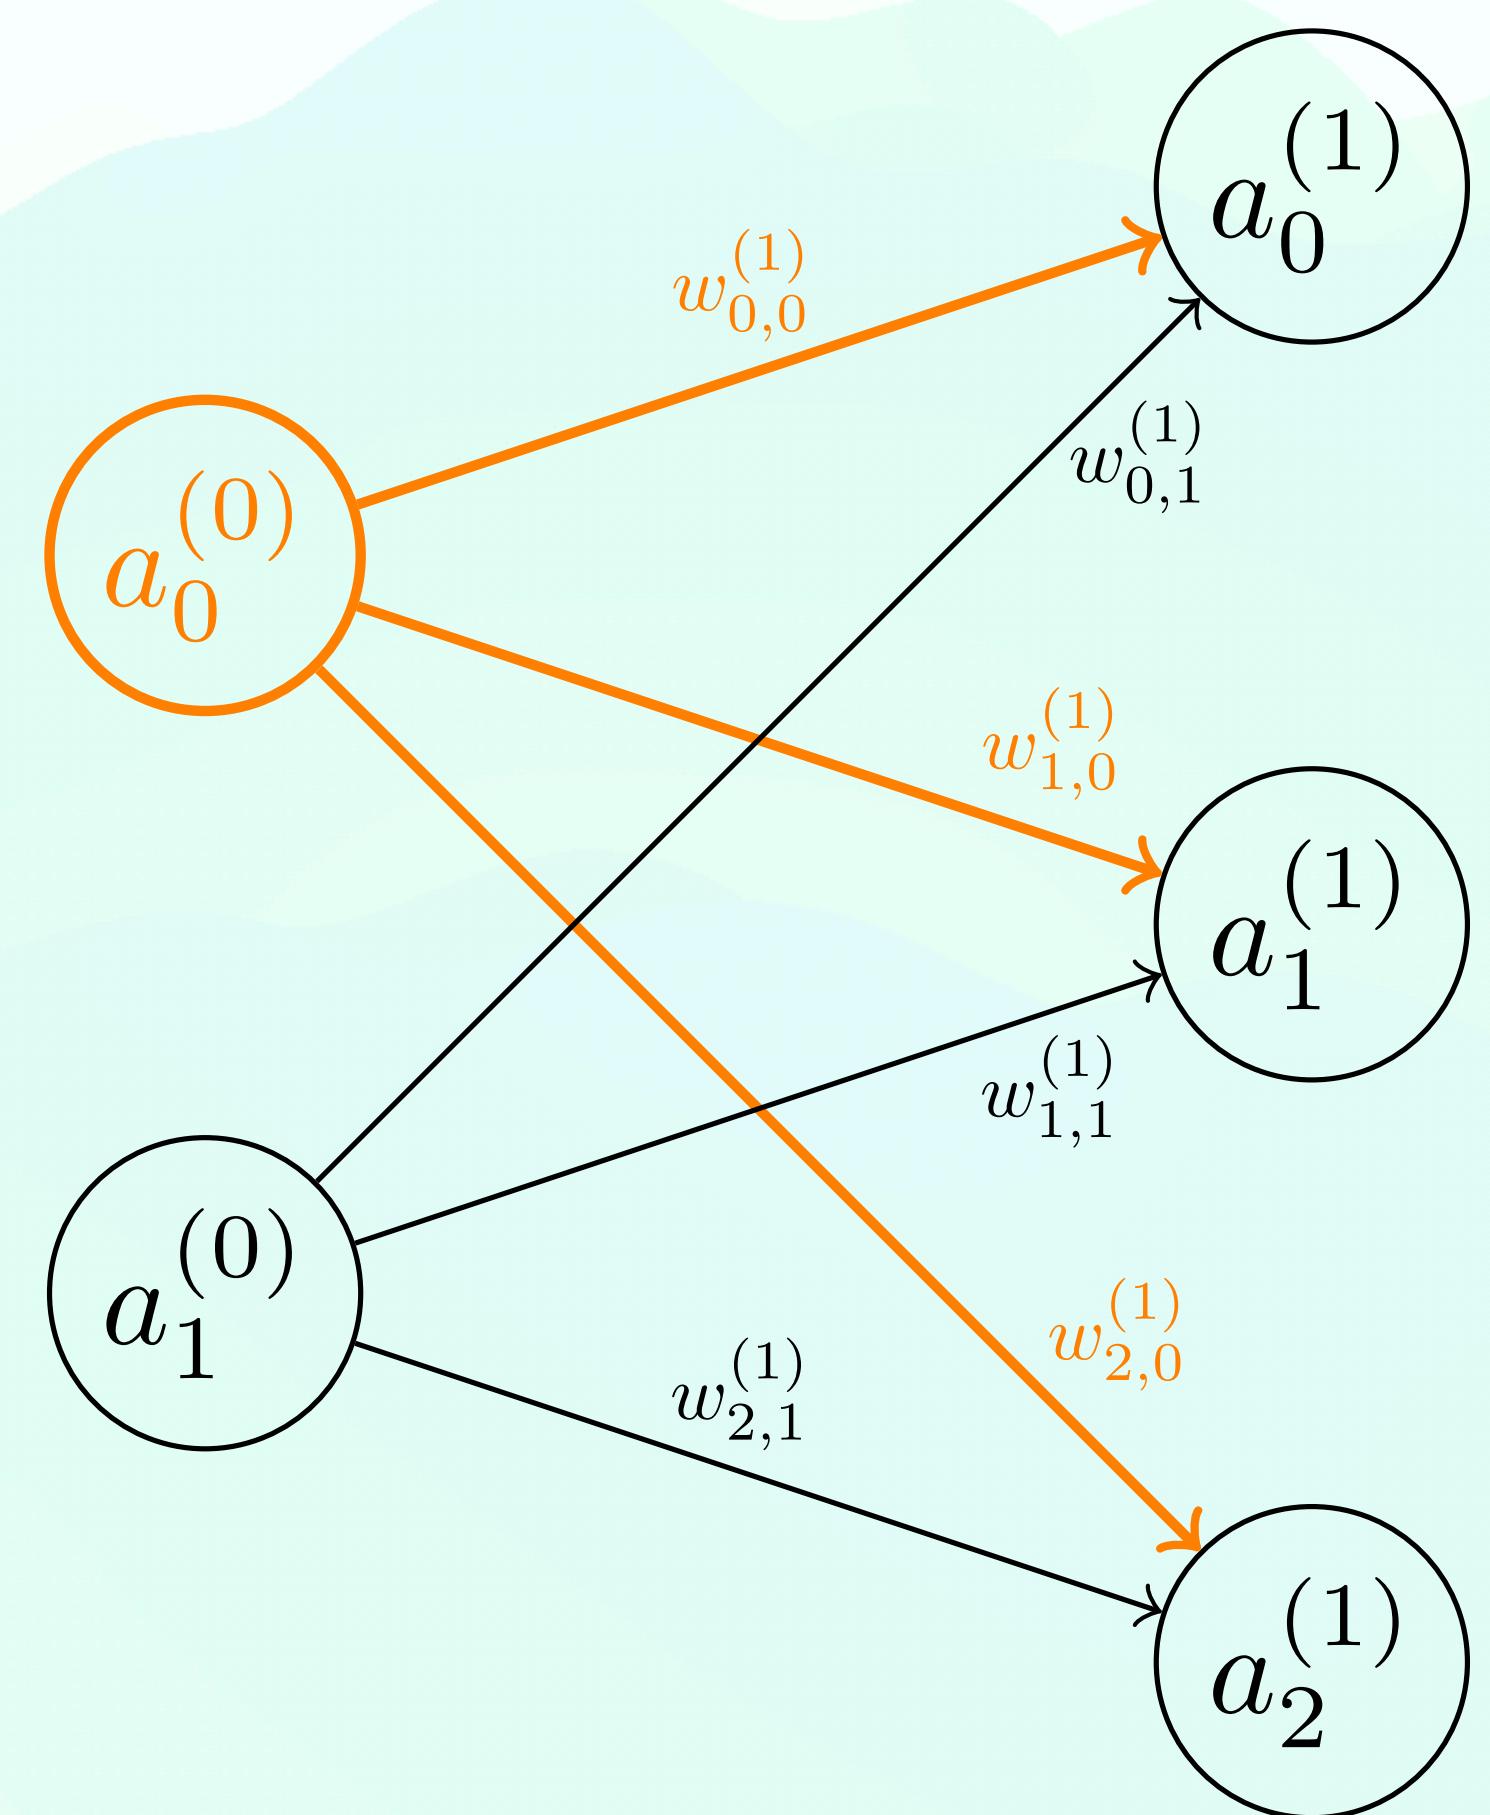


# Ableitung der Kostenfunktion

$$\frac{\partial C}{\partial a_j^{(l)}} = \sum_{i=0}^{n^{(l+1)}-1} \left( \frac{\partial C}{\partial a_i^{(l+1)}} \frac{\partial a_i^{(l+1)}}{\partial z_i^{(l+1)}} w_{ij}^{(l+1)} \right)$$

5

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

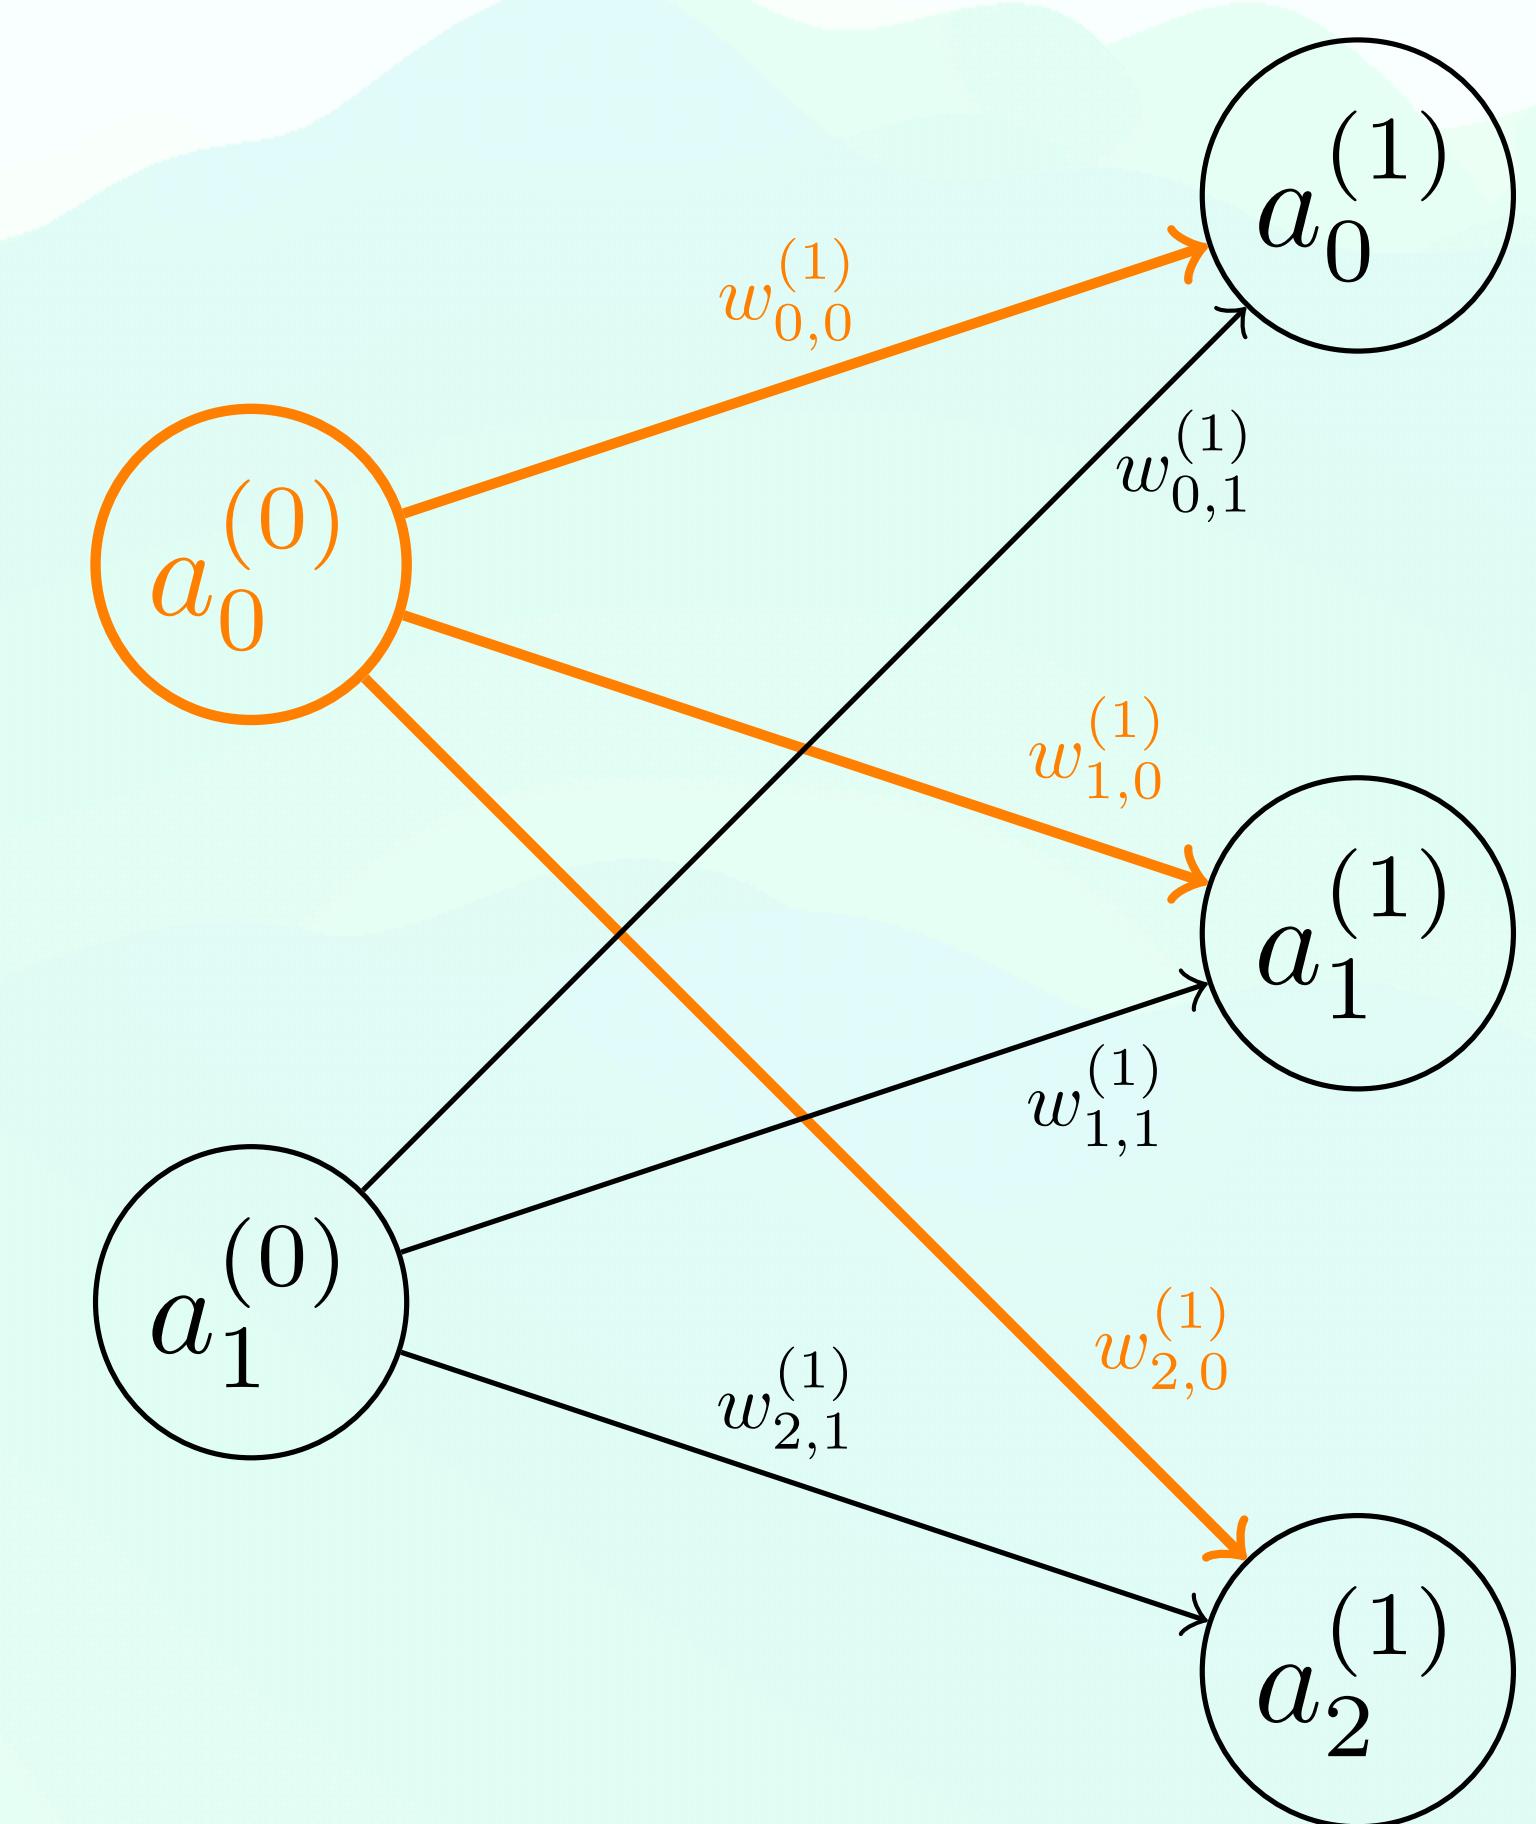
$$\frac{\partial C}{\partial a_j^{(l)}} = \sum_{i=0}^{n^{(l+1)}-1} \left( \frac{\partial C}{\partial a_i^{(l+1)}} \frac{\partial a_i^{(l+1)}}{\partial z_i^{(l+1)}} w_{ij}^{(l+1)} \right)$$

5

Der erhaltene Ausdruck ist **rekursiv**:

Um den Einfluss einer Aktivierung im **weiter innen liegenden Layer  $l$**  auf die Kosten zu ermitteln, muss zuerst der Einfluss der Aktivierungen des **nachfolgenden Layers  $l + 1$**  bekannt sein.

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

$$\frac{\partial C}{\partial a_j^{(l)}} = \sum_{i=0}^{n^{(l+1)}-1} \left( \frac{\partial C}{\partial a_i^{(l+1)}} \frac{\partial a_i^{(l+1)}}{\partial z_i^{(l+1)}} w_{ij}^{(l+1)} \right)$$

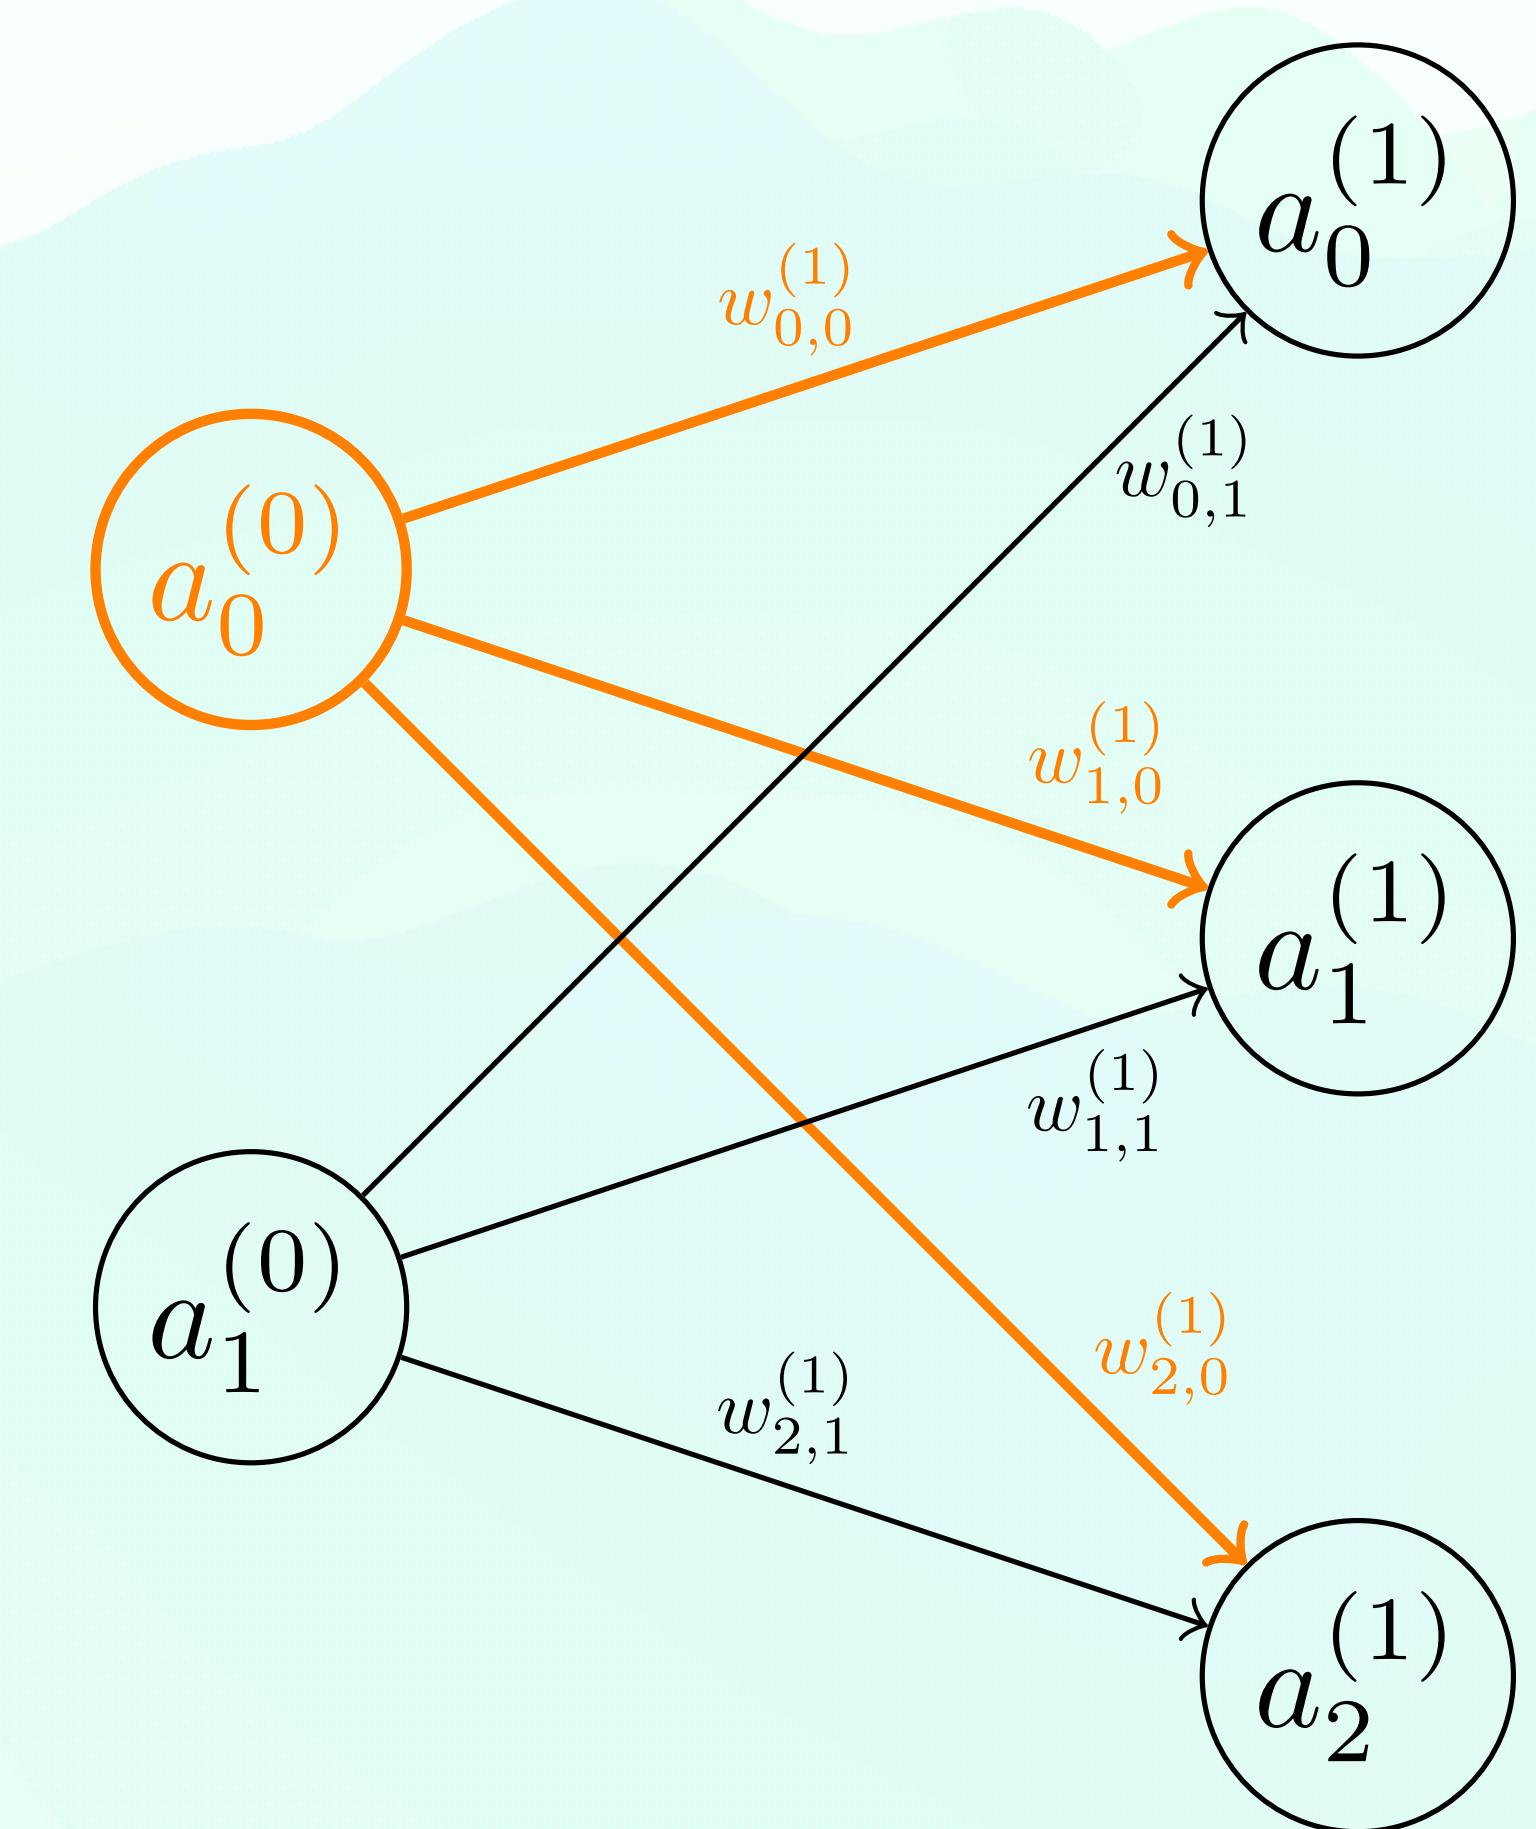
5

Der erhaltene Ausdruck ist **rekursiv**:

Um den Einfluss einer Aktivierung im **weiter innen liegenden Layer  $l$**  auf die Kosten zu ermitteln, muss zuerst der Einfluss der Aktivierungen des **nachfolgenden Layers  $l + 1$**  bekannt sein.

Wenn  $l + 1$  der Output-Layer ist, ist das der Rekursionsabbruch und es greift Gleichung 4.

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

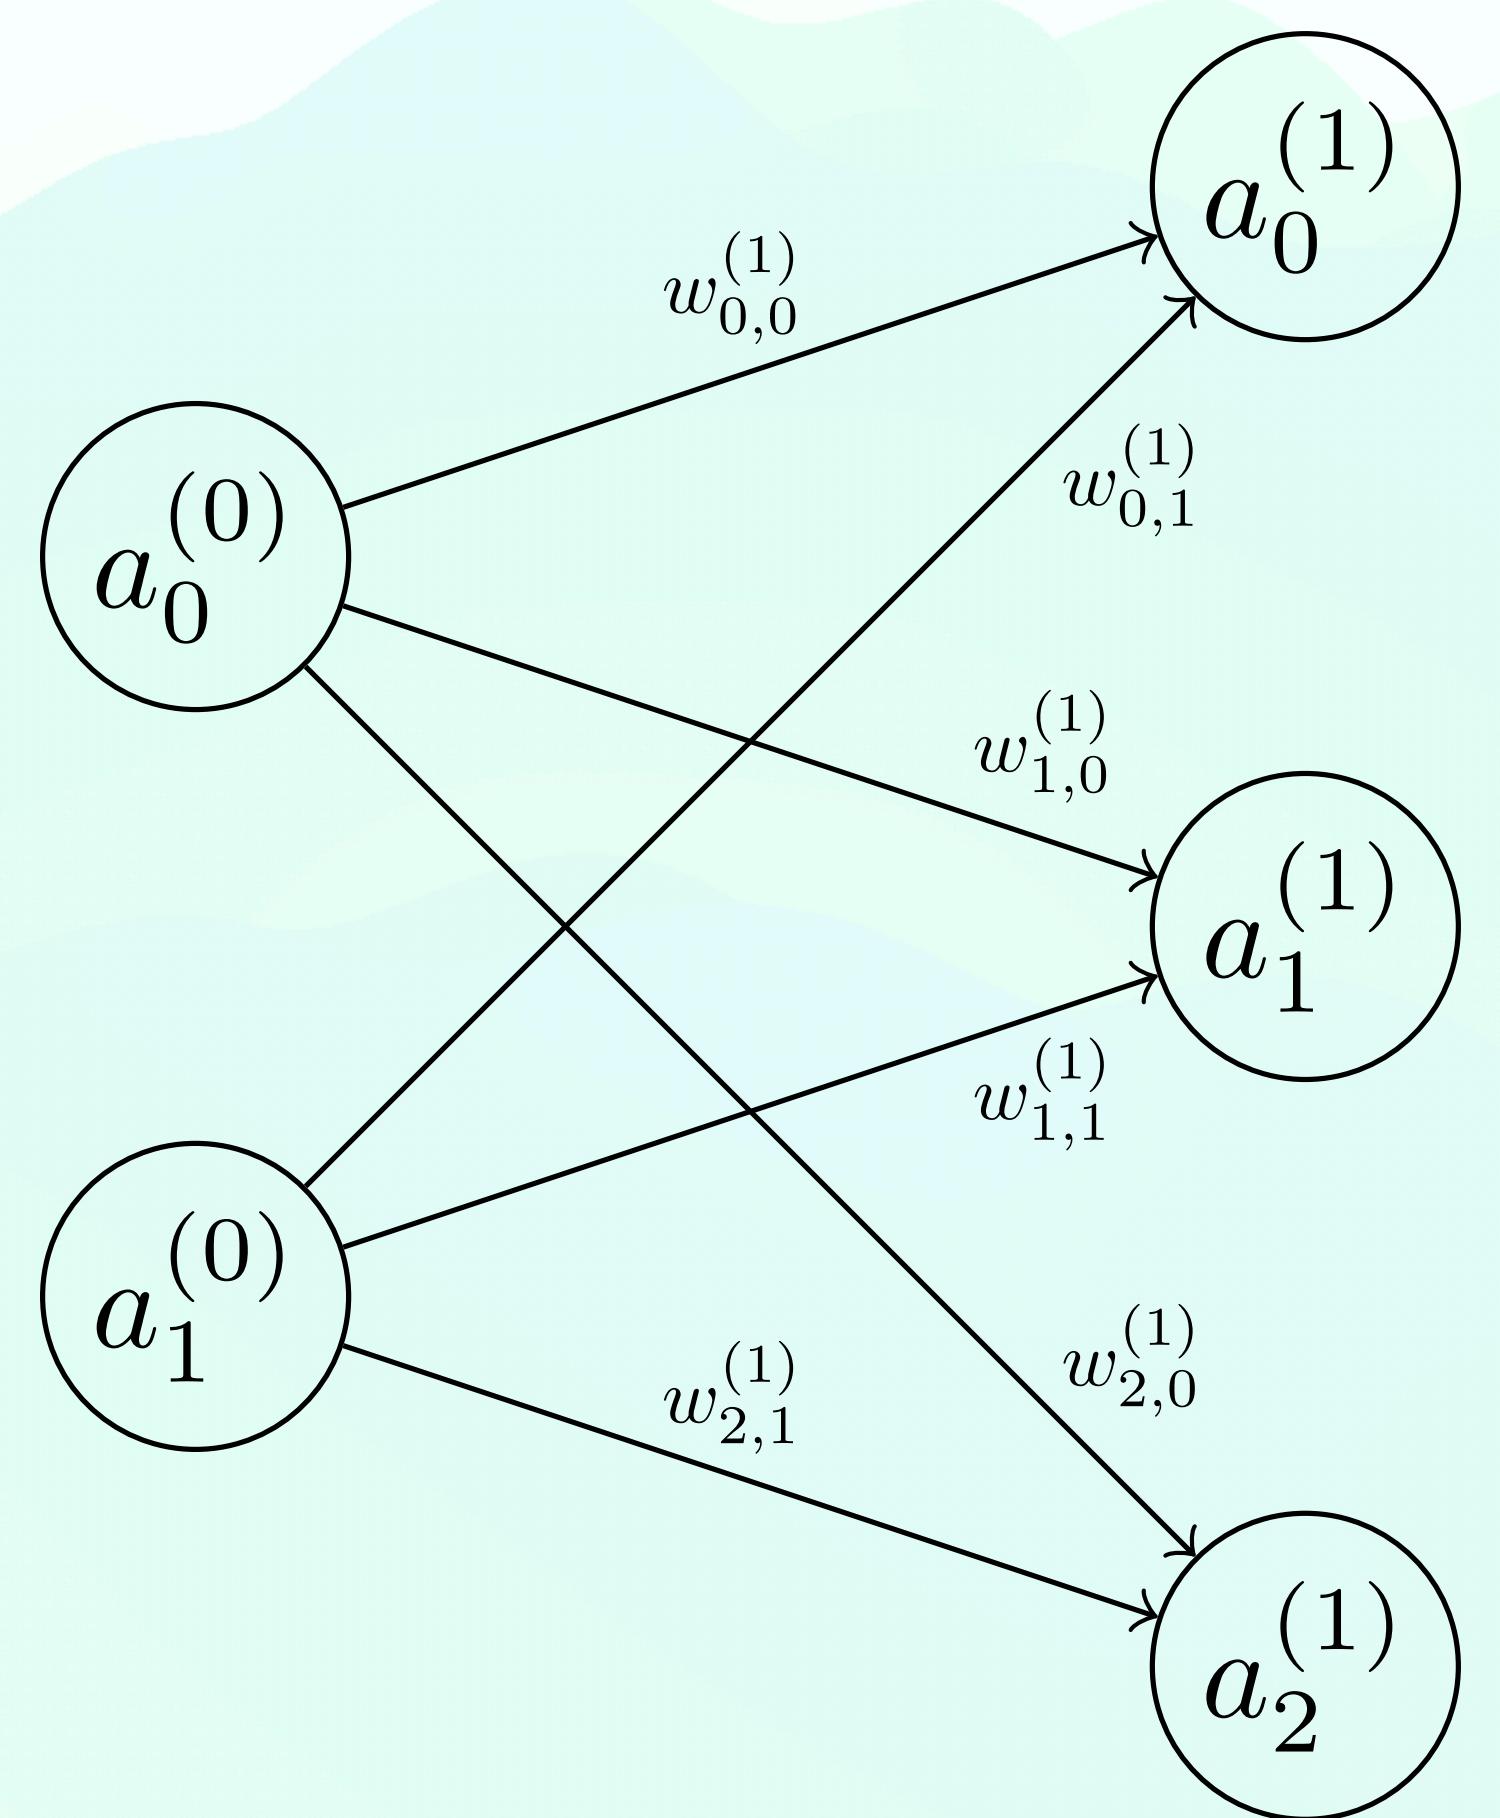
- Zur Erinnerung:

$$\frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}} = \frac{\partial w_{jk}^{(l)} a_k^{(l-1)}}{\partial w_{jk}^{(l)}} = a_k^{(l-1)}$$

2

1

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

- Zur Erinnerung:

$$\frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}} = \frac{\partial w_{jk}^{(l)} a_k^{(l-1)}}{\partial w_{jk}^{(l)}} = a_k^{(l-1)}$$

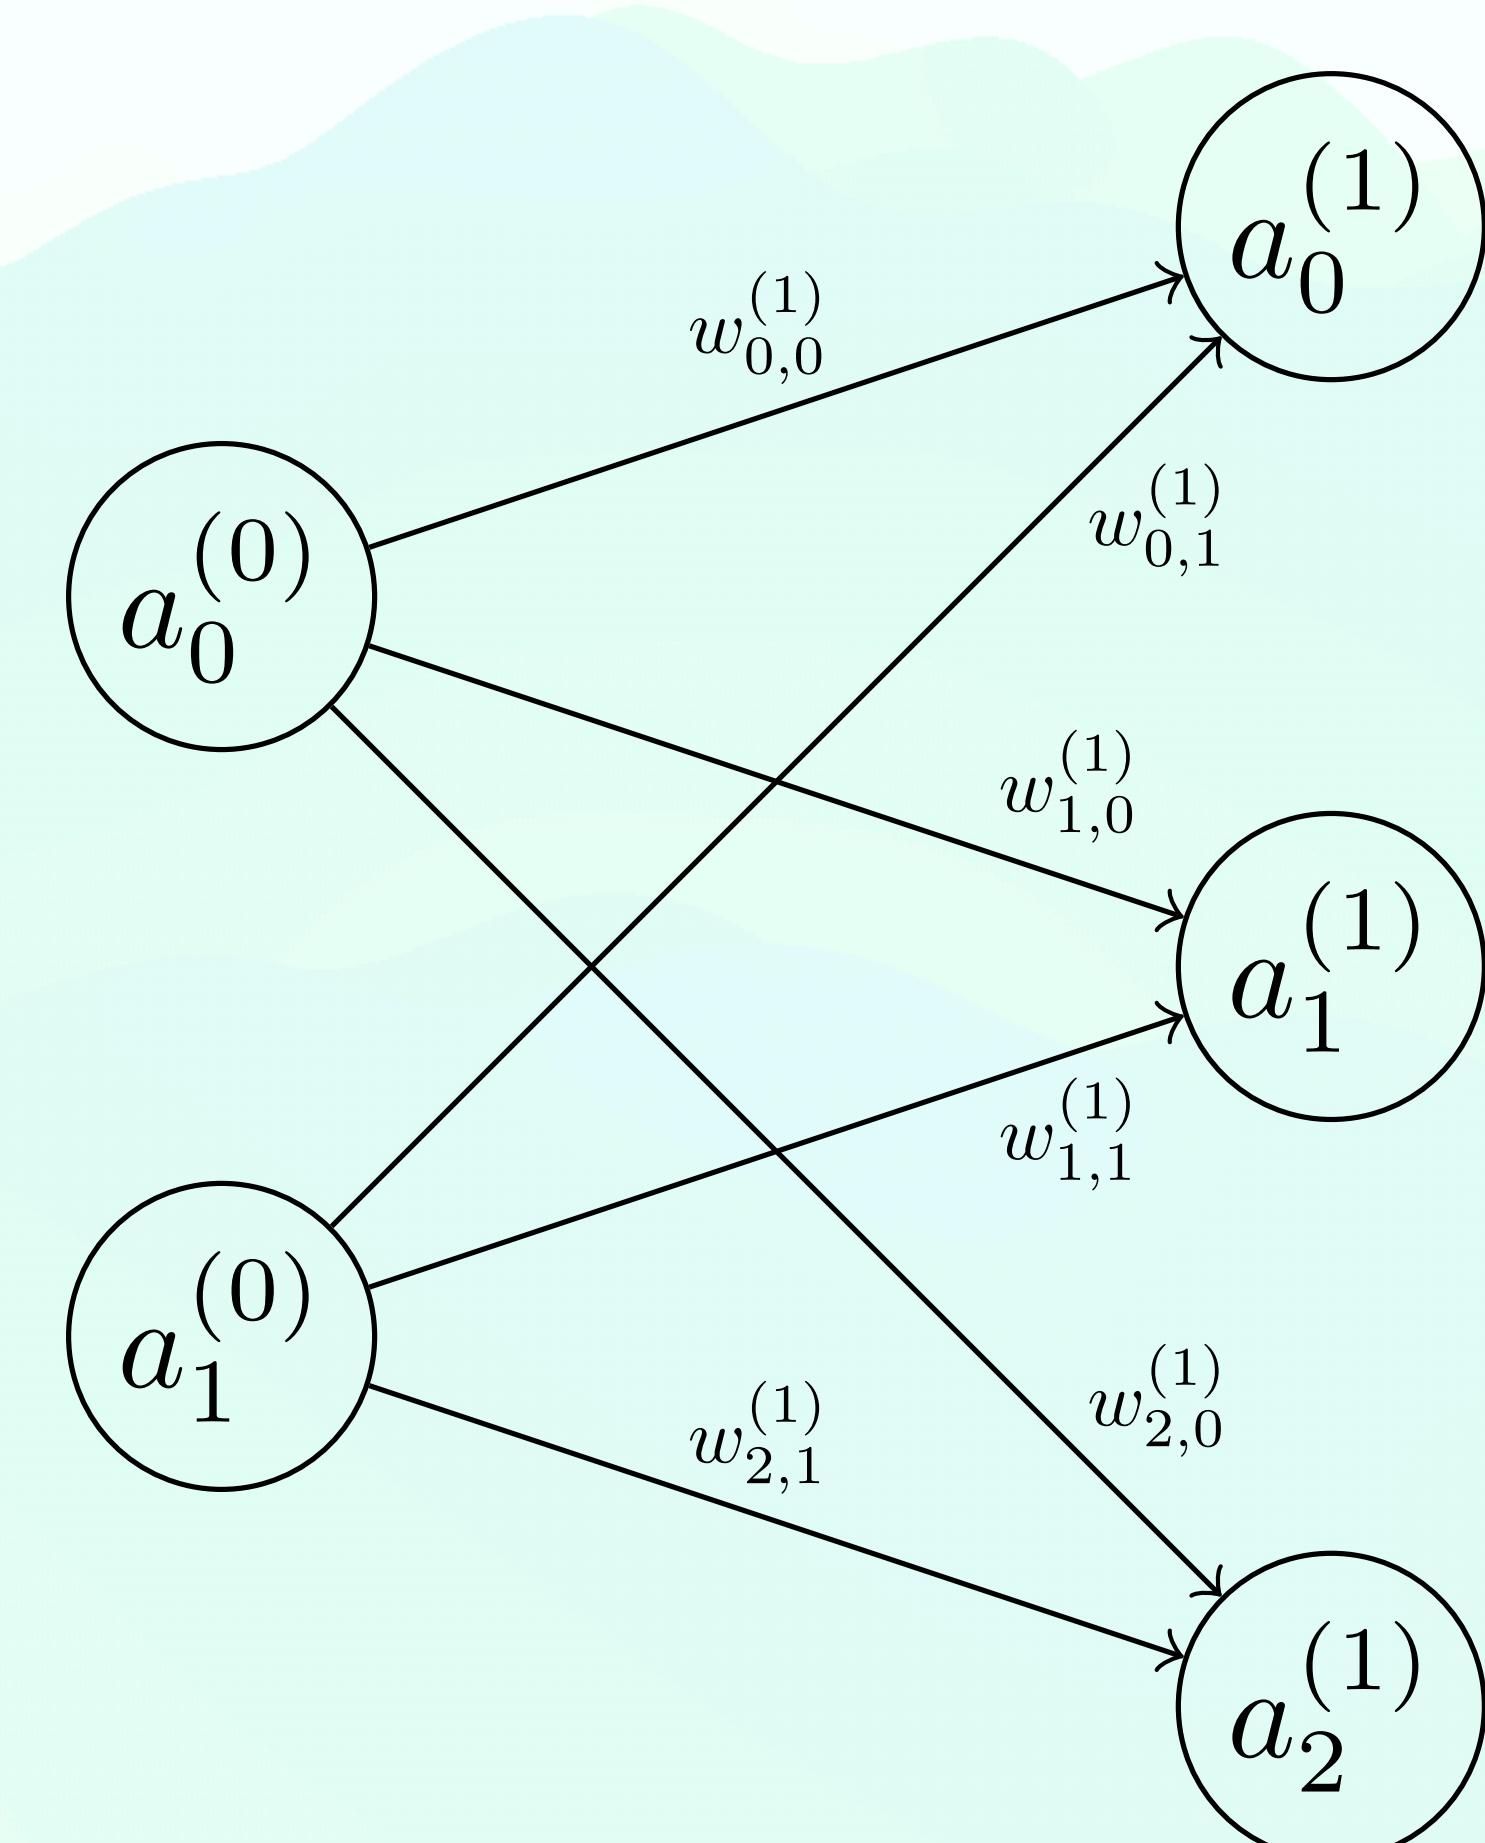
2

- Einsetzen von 2 in 1 ergibt:

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \cdot a_k^{(l-1)}$$

1

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

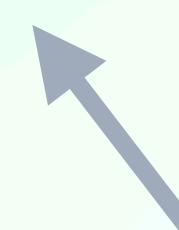
- Zur Erinnerung:

$$\frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}} = \frac{\partial w_{jk}^{(l)} a_k^{(l-1)}}{\partial w_{jk}^{(l)}} = a_k^{(l-1)}$$

2

- Einsetzen von 2 in 1 ergibt:

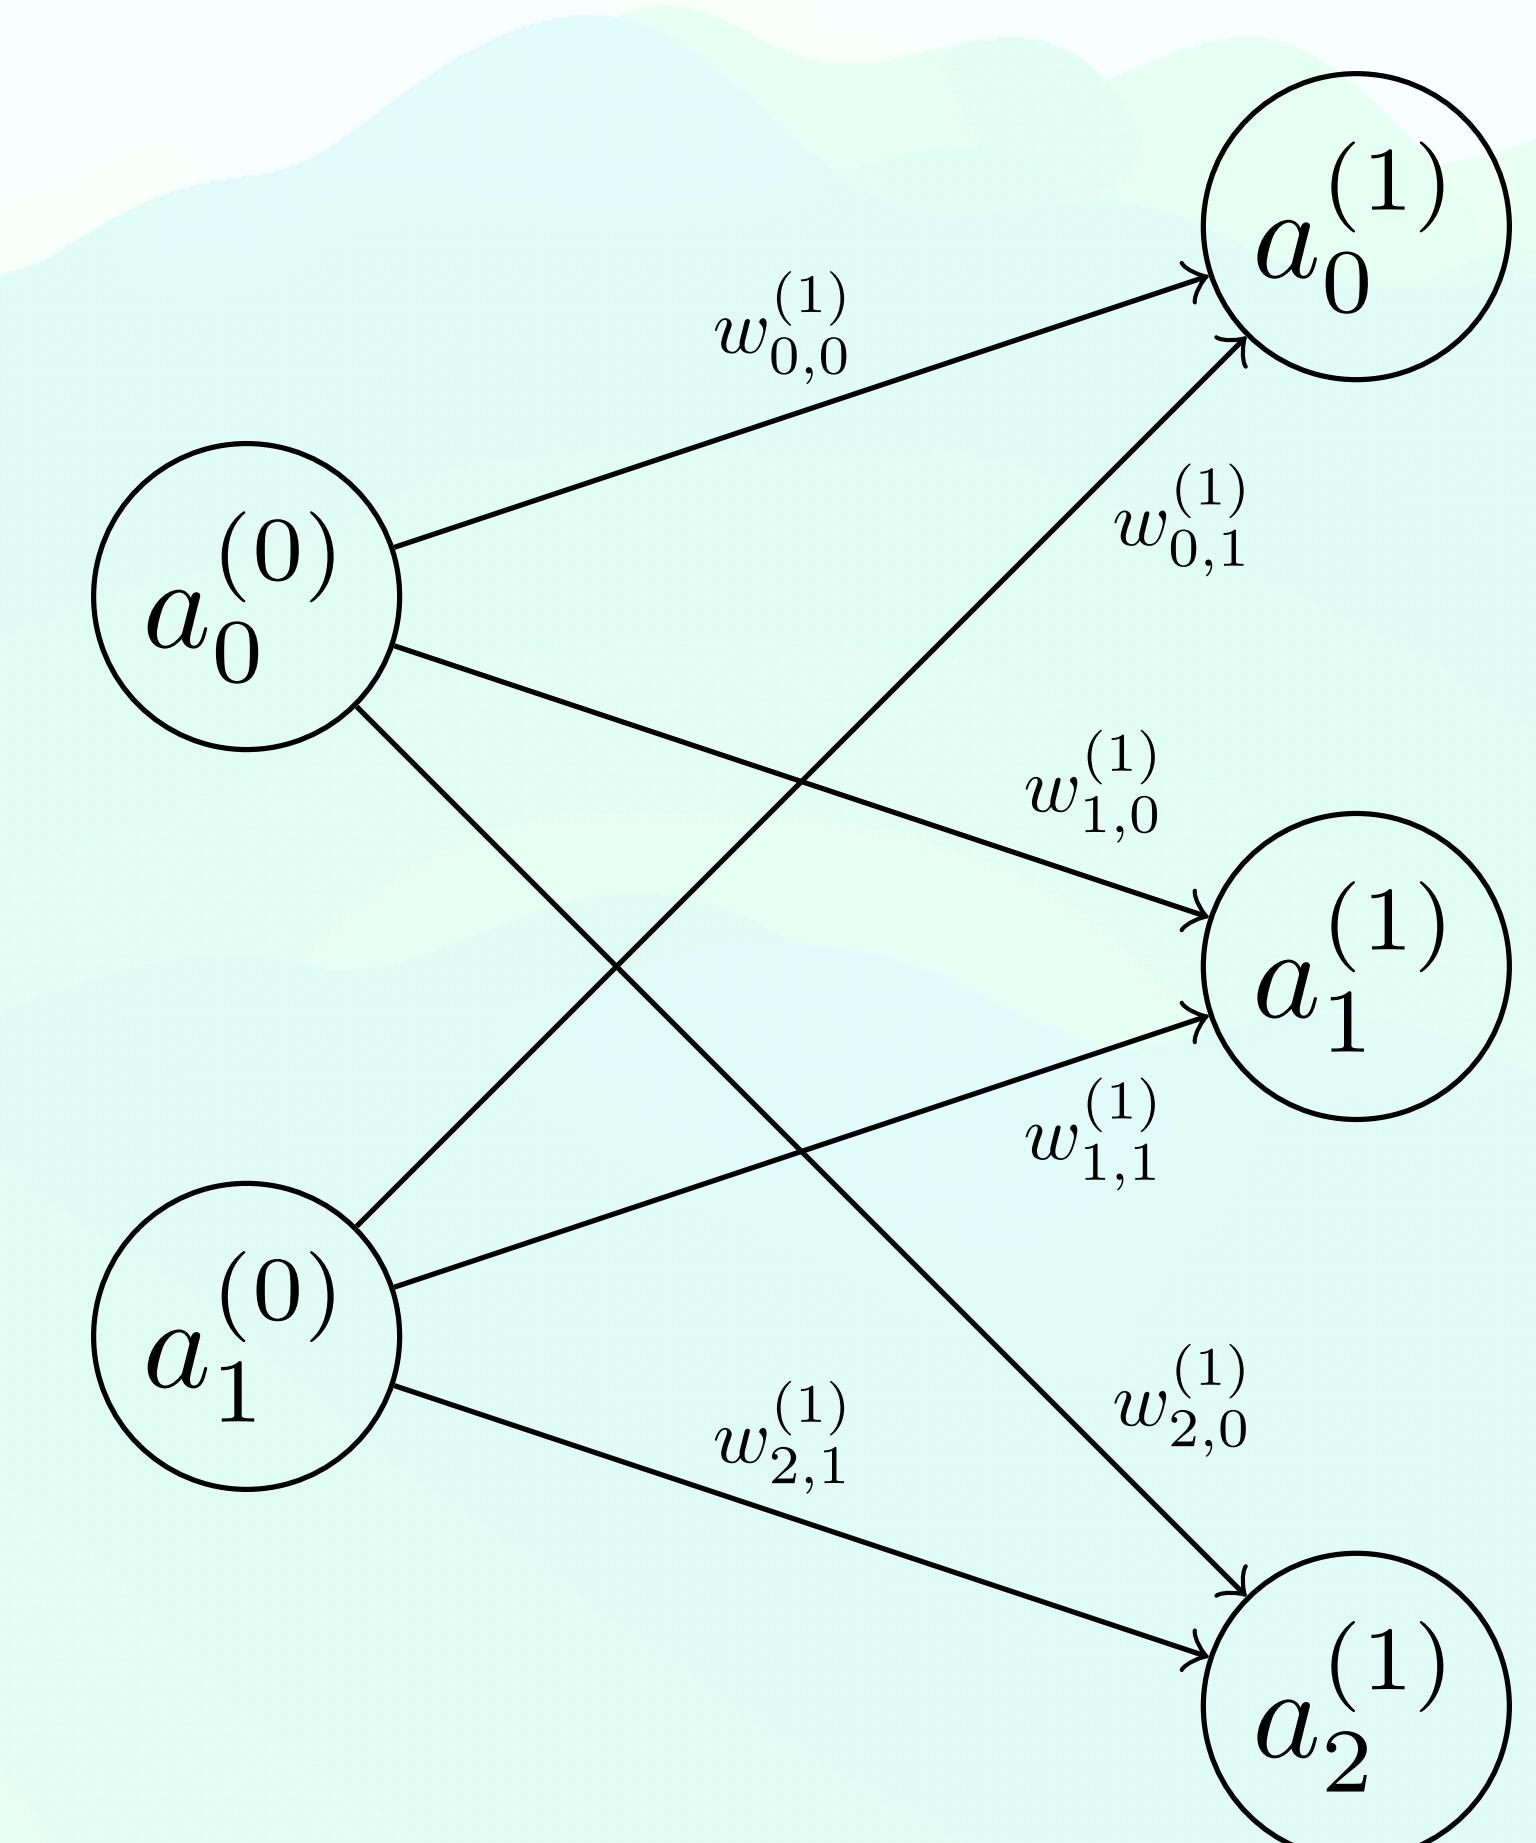
$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \cdot a_k^{(l-1)}$$



Das ist am Ende unsere gesuchte Komponente des Gradienten-Vektors  $\nabla C$  für das Gewicht  $w_{jk}^{(l)}$

1

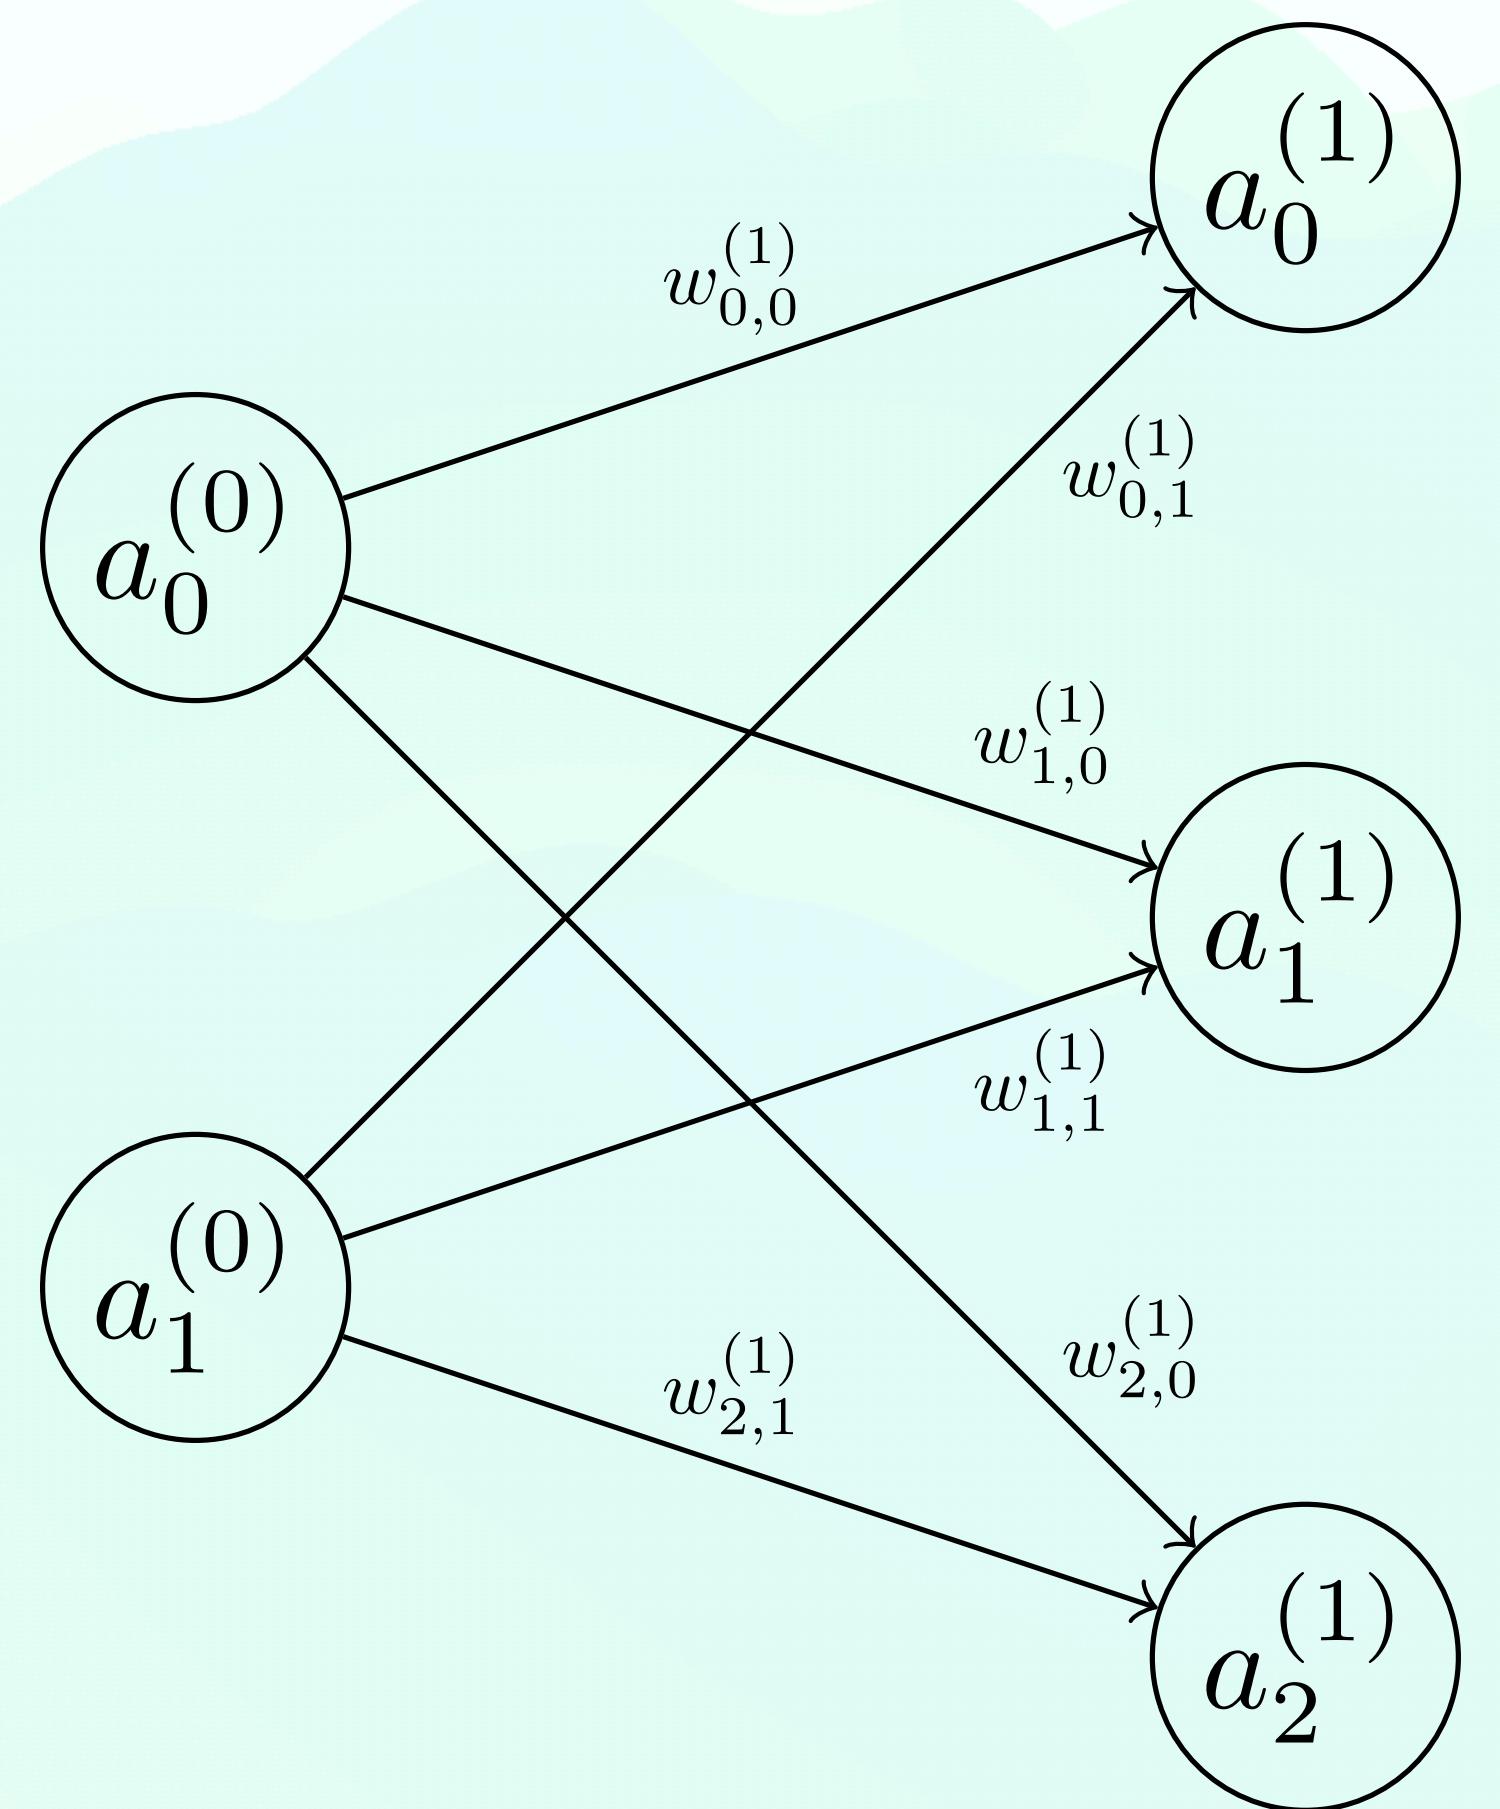
$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \cdot a_k^{(l-1)}$$

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

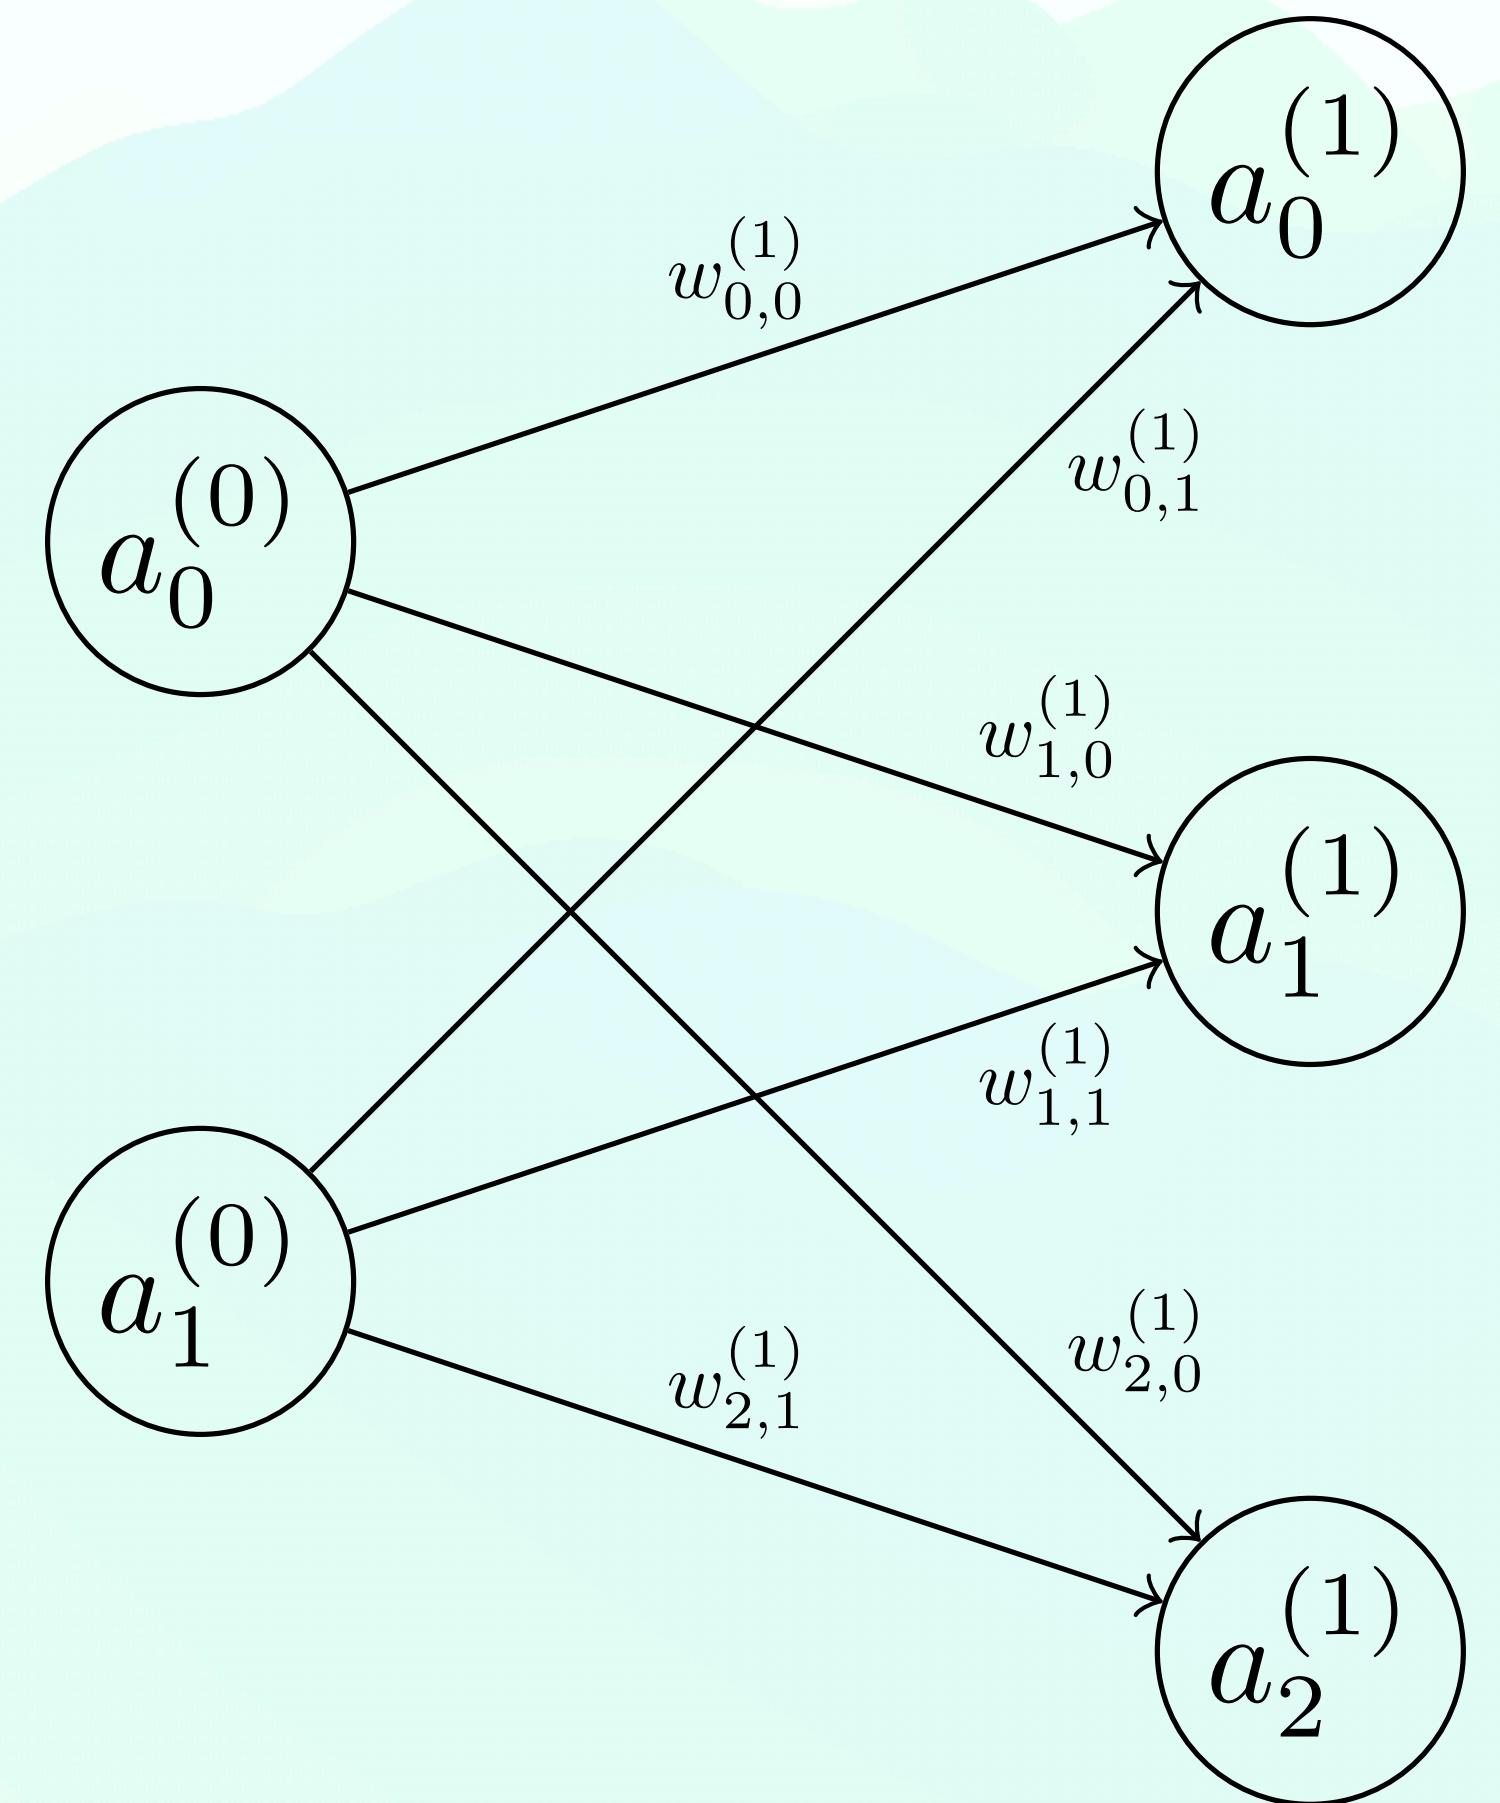


# Ableitung der Kostenfunktion

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \cdot a_k^{(l-1)}$$

- Wir definieren:  $\delta_j^{(l)} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \cdot a_k^{(l-1)}$$

- Wir definieren:

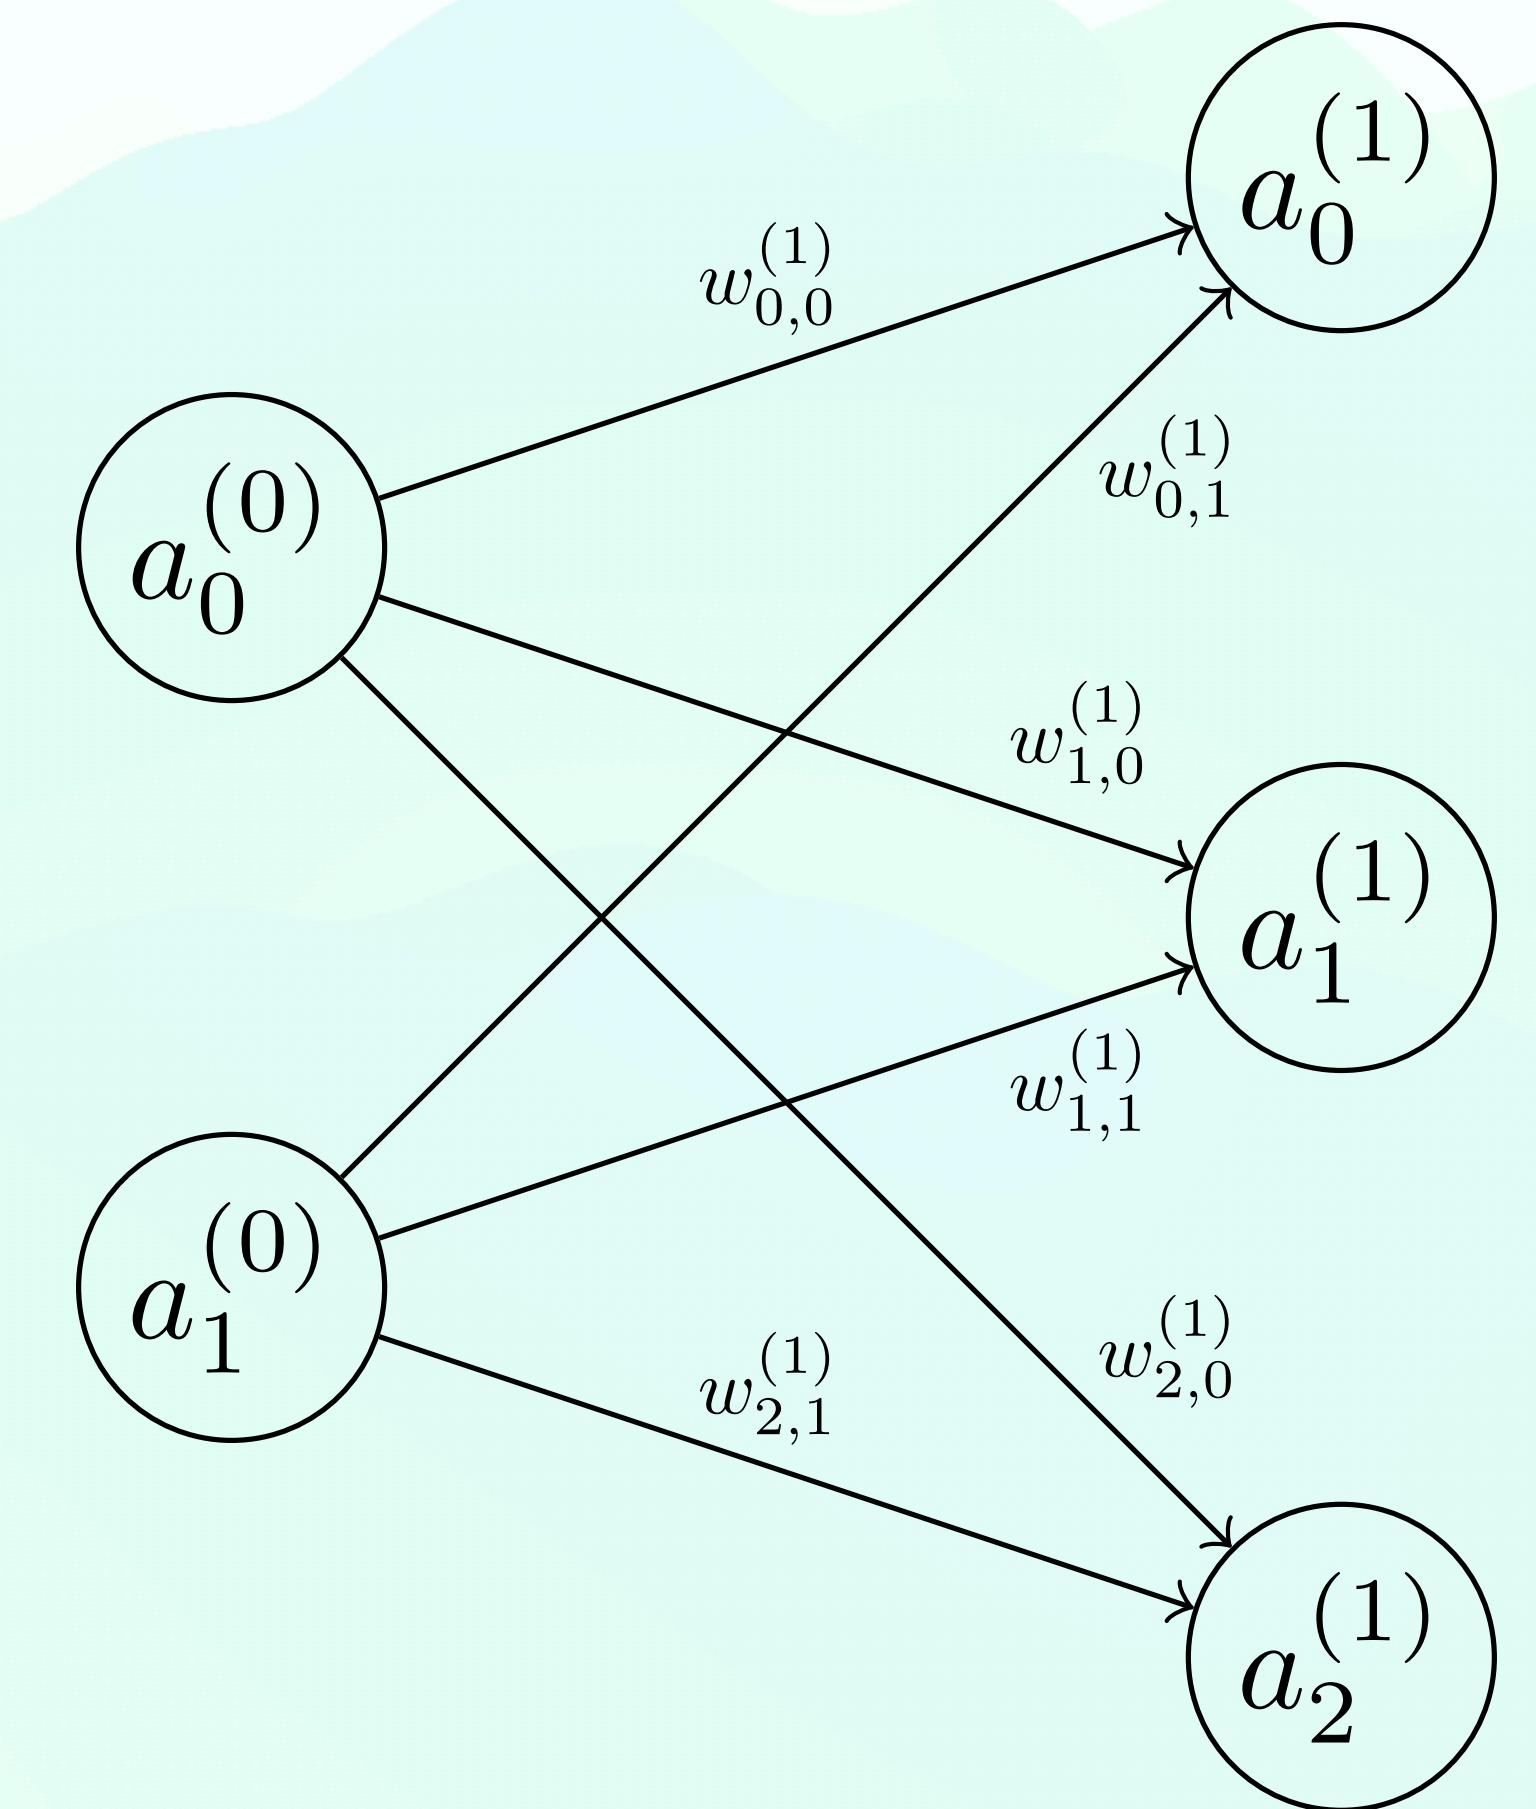
$$\delta_j^{(l)} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}}$$

- Und damit:

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \cdot a_k^{(l-1)} = \delta_j^{(l)} \cdot a_k^{(l-1)}$$

6

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$



# Ableitung der Kostenfunktion

$$\delta_j^{(l)} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}}$$

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

# Ableitung der Kostenfunktion

$$\delta_j^{(l)} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}}$$

- Durch Einsetzen von 3, 4 und 5 erhalten wir:

$$\delta_j^{(l)} = \begin{cases} 2 \left( a_j^{(l)} - y_j \right) \cdot \sigma^{(l)'} \left( z_j^{(l)} \right) & \text{für den Output-Layer} \\ \left( \sum_{i=0}^{n^{(l+1)}-1} \frac{\partial C}{\partial a_i^{(l+1)}} \frac{\partial a_i^{(l+1)}}{\partial z_i^{(l+1)}} w_{ij}^{(l+1)} \right) \cdot \sigma^{(l)'} \left( z_j^{(l)} \right) & \text{für innere Layer} \end{cases}$$

# Ableitung der Kostenfunktion

$$\delta_j^{(l)} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}}$$

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

- Durch Einsetzen von 3, 4 und 5 erhalten wir:

$$\delta_j^{(l)} = \begin{cases} 2 \left( a_j^{(l)} - y_j \right) \cdot \sigma^{(l)'} \left( z_j^{(l)} \right) & \text{für den Output-Layer} \\ \left( \sum_{i=0}^{n^{(l+1)}-1} \frac{\partial C}{\partial a_i^{(l+1)}} \frac{\partial a_i^{(l+1)}}{\partial z_i^{(l+1)}} w_{ij}^{(l+1)} \right) \cdot \sigma^{(l)'} \left( z_j^{(l)} \right) & \text{für innere Layer} \end{cases}$$

Hier sehen wir die **Rekursion** und die Ähnlichkeit zu  $\delta_j^{(l)}$ :

Dieser Ausdruck entspricht  $\delta_i^{(l+1)}$

# Ableitung der Kostenfunktion

$$\delta_j^{(l)} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}}$$

$$\delta_j^{(l)} = \begin{cases} 2 \left( a_j^{(l)} - y_j \right) \cdot \sigma^{(l)'} \left( z_j^{(l)} \right) & \text{für den Output-Layer} \\ \left( \sum_{i=0}^{n^{(l+1)}-1} \delta_i^{(l+1)} w_{ij}^{(l+1)} \right) \cdot \sigma^{(l)'} \left( z_j^{(l)} \right) & \text{für innere Layer} \end{cases}$$

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

7

# Ableitung der Kostenfunktion

$$\delta_j^{(l)} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}}$$

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

Wir sehen also, dass die partielle Ableitung im Layer  $l$  von der partiellen Ableitung im nächsten Layer  $l + 1$  abhängt. Wir fangen im Output-Layer an und arbeiten uns von hinten nach vorne: **Backpropagation**

$$\delta_j^{(l)} = \begin{cases} 2 \left( a_j^{(l)} - y_j \right) \cdot \sigma^{(l)'} \left( z_j^{(l)} \right) & \text{für den Output-Layer} \\ \left( \sum_{i=0}^{n^{(l+1)}-1} \delta_i^{(l+1)} w_{ij}^{(l+1)} \right) \cdot \sigma^{(l)'} \left( z_j^{(l)} \right) & \text{für innere Layer} \end{cases}$$

7

# Ableitung der Kostenfunktion

$$\delta_j^{(l)} = \begin{cases} 2 \left( a_j^{(l)} - y_j \right) \cdot \sigma^{(l)'} \left( z_j^{(l)} \right) & \text{für den Output-Layer} \\ \left( \sum_{i=0}^{n^{(l+1)}-1} \delta_i^{(l+1)} w_{ij}^{(l+1)} \right) \cdot \sigma^{(l)'} \left( z_j^{(l)} \right) & \text{für innere Layer} \end{cases}$$

7

# Ableitung der Kostenfunktion

$$\delta_j^{(l)} = \begin{cases} 2 \left( a_j^{(l)} - y_j \right) \cdot \sigma^{(l)'} \left( z_j^{(l)} \right) & \text{für den Output-Layer} \\ \left( \sum_{i=0}^{n^{(l+1)}-1} \delta_i^{(l+1)} w_{ij}^{(l+1)} \right) \cdot \sigma^{(l)'} \left( z_j^{(l)} \right) & \text{für innere Layer} \end{cases}$$

7

- Laut Gleichung 6 gilt zur Berechnung der Komponente des Gradienten-Vektors:

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \delta_j^{(l)} \cdot a_k^{(l-1)}$$

- Wir haben also nun alles, was nötig ist, um für jedes Gewicht in unserem neuronalen Netz den Anteil an der Gradientenrichtung zur Verringerung der Kosten zu bestimmen!

# Anpassung der Gewichte

- Der Betrag, um den wir das Gewicht  $w_{jk}^{(l)}$  anpassen müssen, berechnet sich wie folgt:

$$\Delta w_{jk}^{(l)} = -\eta \cdot \frac{\partial C}{\partial w_{jk}^{(l)}} = -\eta \cdot \delta_j^{(l)} \cdot a_k^{(l-1)}$$

8

# Anpassung der Gewichte

- Der Betrag, um den wir das Gewicht  $w_{jk}^{(l)}$  anpassen müssen, berechnet sich wie folgt:

$$\Delta w_{jk}^{(l)} = -\eta \cdot \frac{\partial C}{\partial w_{jk}^{(l)}} = -\eta \cdot \delta_j^{(l)} \cdot a_k^{(l-1)}$$

8

Der Gradient würde uns die Richtung des steilsten **Anstiegs** anzeigen, deswegen drehen wir das Vorzeichen um: Uns interessiert der **Gradientenabstieg**.

Wir wollen die Kostenfunktion **minimieren**.

# Anpassung der Gewichte

- Der Betrag, um den wir das Gewicht  $w_{jk}^{(l)}$  anpassen müssen, berechnet sich wie folgt:

$$\Delta w_{jk}^{(l)} = -\eta \cdot \frac{\partial C}{\partial w_{jk}^{(l)}} = -\eta \cdot \delta_j^{(l)} \cdot a_k^{(l-1)}$$

8

Die Lernrate  $\eta$  (gesprochen: „Eta“) gibt an, wie groß oder klein die Gewichtsanpassungsschritte sein sollen, also wie schnell oder langsam unser Netz lernen soll.

# Anpassung der Gewichte

- Der Betrag, um den wir das Gewicht  $w_{jk}^{(l)}$  anpassen müssen, berechnet sich wie folgt:

$$\Delta w_{jk}^{(l)} = -\eta \cdot \frac{\partial C}{\partial w_{jk}^{(l)}} = -\eta \cdot \delta_j^{(l)} \cdot a_k^{(l-1)}$$

8

Die Lernrate  $\eta$  (gesprochen: „Eta“) gibt an, wie groß oder klein die Gewichtsanpassungsschritte sein sollen, also wie schnell oder langsam unser Netz lernen soll.

Eine zu hohe Lernrate könnte die Anpassung übers Ziel hinaus schießen lassen und das lokale Minimum der Kostenfunktion verfehlten.

# Anpassung der Gewichte

- Der Betrag, um den wir das Gewicht  $w_{jk}^{(l)}$  anpassen müssen, berechnet sich wie folgt:

$$\Delta w_{jk}^{(l)} = -\eta \cdot \frac{\partial C}{\partial w_{jk}^{(l)}} = -\eta \cdot \delta_j^{(l)} \cdot a_k^{(l-1)}$$

8

Der Einfluss, den eine kleine Änderung unseres Gewichts auf die Kosten hätte – also die Richtung, in die sich die Kostenfunktion bei einer kleinen Änderung des Gewichts entwickeln würde.

# Anpassung der Gewichte

- Der Betrag, um den wir das Gewicht  $w_{jk}^{(l)}$  anpassen müssen, berechnet sich wie folgt:

$$\Delta w_{jk}^{(l)} = -\eta \cdot \frac{\partial C}{\partial w_{jk}^{(l)}} = -\eta \cdot \delta_j^{(l)} \cdot a_k^{(l-1)}$$

8

Dieses Delta muss auf den bisherigen Wert des Gewichts addiert werden, um die Kosten zu senken.

# Anpassung der Gewichte

- Der Betrag, um den wir das Gewicht  $w_{jk}^{(l)}$  anpassen müssen, berechnet sich wie folgt:

$$\Delta w_{jk}^{(l)} = -\eta \cdot \frac{\partial C}{\partial w_{jk}^{(l)}} = -\eta \cdot \delta_j^{(l)} \cdot a_k^{(l-1)}$$

8

Dieses Delta muss auf den bisherigen Wert des Gewichts addiert werden, um die Kosten zu senken.

Aber: Jedes Trainingsbeispiel erzeugt ein eigenes  $\Delta w_{jk}^{(l)}$ . Wir bilden den **Mittelwert aus allen** und addieren diesen auf das Gewicht.

# Anpassung der Gewichte

- Der Betrag, um den wir das Gewicht  $w_{jk}^{(l)}$  anpassen müssen, berechnet sich wie folgt:

$$\Delta w_{jk}^{(l)} = -\eta \cdot \frac{\partial C}{\partial w_{jk}^{(l)}} = -\eta \cdot \delta_j^{(l)} \cdot a_k^{(l-1)}$$

8

Dieses Delta muss auf den bisherigen Wert des Gewichts addiert werden, um die Kosten zu senken.

Aber: Jedes Trainingsbeispiel erzeugt ein eigenes  $\Delta w_{jk}^{(l)}$ . Wir bilden den **Mittelwert aus allen** und addieren diesen auf das Gewicht.

Und das natürlich für alle Gewichte im neuronalen Netz ...

# Backpropagation-Algorithmus



```
def __init__(  
    self,  
    structure,  
    n_iterations=1000,  
    output_activation_func=relu,  
    hidden_activation_func=sigmoid,  
):  
    self.structure = structure  
    self.n_iterations = n_iterations  
    self.output_activation_func = output_activation_func  
    self.hidden_activation_func = hidden_activation_func  
    self.__init_layers()  
    self.__init_weights()
```

Wir erweitern zunächst unseren Konstruktor um einen Parameter `n_iterations` für die Anzahl der Iterationen, die während des Trainings durchgeführt werden sollen. Als Default-Wert legen wir `1000` fest.

# Backpropagation-Algorithmus



```
def train(self, training_data):
    for i in range(self.n_iterations):
        for (X, Y) in training_data:
            if len(Y) != self.structure[-1]:
                raise Exception("Falsche Anzahl an erwarteten Output-Werten übergeben")

            prediction = self.predict(X)
            error = prediction - Y
            output_layer_derivative = 2 * error
```

Dann deklarieren wir neben `predict` eine zweite öffentliche Methode namens `train`, die im Parameter `training_data` einen Trainingsdatensatz entgegennimmt und mit ihm das Netz trainieren wird.

# Backpropagation-Algorithmus



```
def train(self, training_data):
    for i in range(self.n_iterations):
        for (X, Y) in training_data:
            if len(Y) != self.structure[-1]:
                raise Exception("Falsche Anzahl an erwarteten Output-Werten übergeben")

            prediction = self.predict(X)
            error = prediction - Y
            output_layer_derivative = 2 * error
```

Der Trainingsdatensatz soll dabei eine Liste von **Tupeln** sein, die jeweils einen Satz an Inputs und die dazugehörigen erwarteten Outputs enthalten. Sowohl Inputs als auch Outputs sollen darin als numpy-Spaltenvektoren gegeben sein.

# Backpropagation-Algorithmus



```
def train(self, training_data):
    for i in range(self.n_iterations):
        for (X, Y) in training_data:
            if len(Y) != self.structure[-1]:
                raise Exception("Falsche Anzahl an erwarteten Output-Werten übergeben")

            prediction = self.predict(X)
            error = prediction - Y
            output_layer_derivative = 2 * error
```

Zunächst soll eine `for`-Schleife dafür sorgen, dass alle folgenden Trainingsschritte entsprechend der übergebenen Zahl an Iterationen wiederholt werden.

# Backpropagation-Algorithmus



```
def train(self, training_data):
    for i in range(self.n_iterations):
        for (X, Y) in training_data:
            if len(Y) != self.structure[-1]:
                raise Exception("Falsche Anzahl an erwarteten Output-Werten übergeben")

            prediction = self.predict(X)
            error = prediction - Y
            output_layer_derivative = 2 * error
```

Eine weitere `for`-Schleife iteriert durch jedes einzelne Tupel unserer `training_data`, wobei jeweils der aktuelle Input-Satz in `X` und der erwartete Output-Satz in `Y` abgelegt wird.

# Backpropagation-Algorithmus



```
def train(self, training_data):
    for i in range(self.n_iterations):
        for (X, Y) in training_data:
            if len(Y) != self.structure[-1]:
                raise Exception("Falsche Anzahl an erwarteten Output-Werten übergeben")
```

```
prediction = self.predict(X)
error = prediction - Y
output_layer_derivative = 2 * error
```

Wenn die Anzahl der erwarteten Outputs im aktuellen Trainingsbeispiel nicht mit der Anzahl der Neuronen im Output-Layer übereinstimmt, erzeugen wir auch hier eine Exception.

# Backpropagation-Algorithmus



```
def train(self, training_data):
    for i in range(self.n_iterations):
        for (X, Y) in training_data:
            if len(Y) != self.structure[-1]:
                raise Exception("Falsche Anzahl an erwarteten Output-Werten übergeben")
```

```
prediction = self.predict(X)
error = prediction - Y
output_layer_derivative = 2 * error
```

Dann erzeugen wir eine Vorhersage für die aktuellen Inputs mithilfe der `predict`-Methode, die wir zuvor implementiert haben.

# Backpropagation-Algorithmus



```
def train(self, training_data):
    for i in range(self.n_iterations):
        for (X, Y) in training_data:
            if len(Y) != self.structure[-1]:
                raise Exception("Falsche Anzahl an erwarteten Output-Werten übergeben")

            prediction = self.predict(X)
            error = prediction - Y
            output_layer_derivative = 2 * error
```

Die Abweichung zwischen vorhergesagtem und erwartetem Output legen wir in der Variable `error` ab. Sowohl `prediction` als auch `Y` sind in diesem Fall Vektoren, trotzdem können wir dank numpy ganz einfach den Minus-Operator verwenden.

# Backpropagation-Algorithmus

$$\frac{\partial C}{\partial a_j^{(l)}} = 2 \left( a_j^{(l)} - y_j \right)$$

4



```
def train(self, training_data):
    for i in range(self.n_iterations):
        for (X, Y) in training_data:
            if len(Y) != self.structure[-1]:
                raise Exception("Falsche Anzahl an erwarteten Output-Werten übergeben")

            prediction = self.predict(X)
            error = prediction - Y
            output_layer_derivative = 2 * error
```

Nach Gleichung 4 ist die Ableitung der Kosten nach den Aktivierungen im Output-Layer gleich dem Doppelten dieser Differenz. Wir legen sie zur späteren Verwendung in einer Variable ab.

# Backpropagation-Algorithmus



Diesen Block müssen wir noch vor unserer Iterations-Schleife einfügen. In ihm werden noch einige für die Backpropagation benötigte Variablen angelegt.

```
def train(self, training_data):
    partial_deltas = []
    for l in range(len(self.structure)):
        partial_deltas.append(numpy.zeros_like(self.weighted_sums[l]))

    delta_W = [None]
    for l in range(1, len(self.structure)):
        delta_W.append(numpy.zeros_like(self.weights[l]))

    for i in range(self.n_iterations):
        # ...
```

# Backpropagation-Algorithmus



```
def train(self, training_data):
    partial_deltas = []
    for l in range(len(self.structure)):
        partial_deltas.append(numpy.zeros_like(self.weighted_sums[l]))

    delta_W = [None]
    for l in range(1, len(self.structure)):
        delta_W.append(numpy.zeros_like(self.weights[l]))

    for i in range(self.n_iterations):
        # ...
```

Zunächst deklarieren wir eine Liste für die partiellen Ableitungen  $\delta_j$  der einzelnen Layer. Die Einträge der Liste sollen jeweils Vektoren sein.

# Backpropagation-Algorithmus



```
def train(self, training_data):
    partial_deltas = []
    for l in range(len(self.structure)):
        partial_deltas.append(numpy.zeros_like(self.weighted_sums[l]))

    delta_W = [None]
    for l in range(1, len(self.structure)):
        delta_W.append(numpy.zeros_like(self.weights[l]))

    for i in range(self.n_iterations):
        # ...
```

Mit einer Schleife iterieren wir durch alle Layer und fügen für jeden einen mit Nullen vorbefüllten Vektor hinzu, dessen Dimensionen identisch zu dem Vektor der gewichteten Summen sein sollen. Wir verzichten also auf einen  $\delta$ -Eintrag für das Bias-Neuron des jeweiligen Layers, da es sich nicht auf vorherige Layer auswirken soll.

# Backpropagation-Algorithmus



```
def train(self, training_data):
    partial_deltas = []
    for l in range(len(self.structure)):
        partial_deltas.append(numpy.zeros_like(self.weighted_sums[l]))

    delta_W = [None]
    for l in range(1, len(self.structure)):
        delta_W.append(numpy.zeros_like(self.weights[l]))

    for i in range(self.n_iterations):
        # ...
```

Auch für die errechneten Gewichtsanpassungen  $\Delta w$  legen wir eine Liste an. Jedes Element der Liste soll am Ende für einen Layer stehen und ist analog zu den Gewichten selbst eine Matrix.

# Backpropagation-Algorithmus



```
def train(self, training_data):
    partial_deltas = []
    for l in range(len(self.structure)):
        partial_deltas.append(numpy.zeros_like(self.weighted_sums[l]))

    delta_W = [None]
    for l in range(1, len(self.structure)):
        delta_W.append(numpy.zeros_like(self.weights[l]))

    for i in range(self.n_iterations):
        # ...
```

Wie bei den Gewichtsmatrizen auch legen wir für den Layer-Index  $0$  ein später nicht verwendetes Element in der Liste ab. Damit sorgen wir für konsistente Indizes, indem z. B. die  $\Delta w$  vom Input-Layer zum ersten Hidden-Layer den Index  $1$  bekommen.

# Backpropagation-Algorithmus



```
def train(self, training_data):
    partial_deltas = []
    for l in range(len(self.structure)):
        partial_deltas.append(numpy.zeros_like(self.weighted_sums[l]))

    delta_W = [None]
    for l in range(1, len(self.structure)):
        delta_W.append(numpy.zeros_like(self.weights[l]))

    for i in range(self.n_iterations):
        # ...
```

Dann iterieren wir wie gehabt durch die Layer, fangen dabei aber erst bei Index 1 an, da Index 0 bereits durch das Dummy-Element abgehandelt ist.

# Backpropagation-Algorithmus



```
def train(self, training_data):
    partial_deltas = []
    for l in range(len(self.structure)):
        partial_deltas.append(numpy.zeros_like(self.weighted_sums[l]))

    delta_W = [None]
    for l in range(1, len(self.structure)):
        delta_W.append(numpy.zeros_like(self.weights[l]))

    for i in range(self.n_iterations):
        # ...
```

Die Matrizen in jedem Layer erzeugen wir dann mit demselben Format wie die jeweiligen Gewichtsmatrizen. Das erledigt `numpy.zeros_like` und sorgt gleichzeitig dafür, dass alle Elemente der Matrizen mit `0` vorbelegt sind. Mit `append` fügen wir schließlich die Matrix zur Liste hinzu.

# Backpropagation-Algorithmus



```
def __init__(  
    self,  
    structure,  
    n_iterations=1000,  
    eta=0.01,  
    output_activation_func=relu,  
    hidden_activation_func=sigmoid,  
):  
    self.structure = structure  
    self.n_iterations = n_iterations  
    self.eta = eta  
    self.output_activation_func = output_activation_func  
    self.hidden_activation_func = hidden_activation_func  
    self.__init_layers()  
    self.__init_weights()
```

Bevor wir die Backpropagation weiter implementieren können, müssen wir unserem neuronalen Netz noch einen letzten Parameter hinzufügen: die Lernrate  $\eta$ , genannt `eta`. Wir lassen sie uns im Konstruktor **optional** übergeben, geben ihr ansonsten den Default-Wert von `0.01`, und speichern sie in einer gleichnamigen Objekt-Eigenschaft.

# Backpropagation-Algorithmus



Jetzt springen wir wieder zurück in unsere Trainingsschleife und fügen diesen Block ein, der die eigentliche Backpropagation durchführt und dafür unsere gerade angelegten Variablen `partial_deltas` und `delta_W` verwendet.

```
# ...
output_layer_derivative = 2 * error

for l in range(len(self.structure) - 1, 0, -1):
    if l == len(self.structure) - 1:
        partial_deltas[l][:] = output_layer_derivative * \
            self.output_activation_func(self.weighted_sums[l], derivative=True)
    else:
        partial_deltas[l][:] = \
            numpy.matmul(self.weights[l+1][:, 1:].T, partial_deltas[l+1]) * \
            self.hidden_activation_func(self.weighted_sums[l], derivative=True)

    delta_W[l][:] += -self.eta * numpy.matmul(partial_deltas[l], self.activations[l-1].T)
```

# Backpropagation-Algorithmus



```
# ...
output_layer_derivative = 2 * error

for l in range(len(self.structure) - 1, 0, -1):
    if l == len(self.structure) - 1:
        partial_deltas[l][:] = output_layer_derivative * \
            self.output_activation_func(self.weighted_sums[l], derivative=True)
    else:
        partial_deltas[l][:] = \
            numpy.matmul(self.weights[l+1][:, 1:].T, partial_deltas[l+1]) * \
            self.hidden_activation_func(self.weighted_sums[l], derivative=True)

    delta_w[l][:] += -self.eta * numpy.matmul(partial_deltas[l], self.activations[l-1].T)
```

Da wir uns bei der Backpropagation von **hinten nach vorne** durch das Netz bewegen müssen, lassen wir unsere **for**-Schleife diesmal rückwärts laufen. Der `range`-Funktion müssen wir dafür drei Parameter übergeben.

# Backpropagation-Algorithmus



```
# ...
output_layer_derivative = 2 * error

for l in range(len(self.structure) - 1, 0, -1):
    if l == len(self.structure) - 1:
        partial_deltas[l][:] = output_layer_derivative * \
            self.output_activation_func(self.weighted_sums[l], derivative=True)
    else:
        partial_deltas[l][:] = \
            numpy.matmul(self.weights[l+1][:, 1:].T, partial_deltas[l+1]) * \
            self.hidden_activation_func(self.weighted_sums[l], derivative=True)

    delta_w[l][:] += -self.eta * numpy.matmul(partial_deltas[l], self.activations[l-1].T)
```

Zuerst als Startindex den des letzten Layers (Länge der Layer-Liste minus 1), dann eine 0 für den Wert für  $l$ , bei dem die Schleife abbricht, und zuletzt die Schrittänge von -1, die dafür sorgt, dass  $l$  bei jedem Schleifendurchlauf um 1 herunterzählt.

# Backpropagation-Algorithmus



```
# ...
output_layer_derivative = 2 * error
```

```
for l in range(len(self.structure) - 1, 0, -1):
    if l == len(self.structure) - 1:
        partial_deltas[l][:] = output_layer_derivative * \
            self.output_activation_func(self.weighted_sums[l], derivative=True)
    else:
        partial_deltas[l][:] = \
            numpy.matmul(self.weights[l+1][:, 1:].T, partial_deltas[l+1]) * \
            self.hidden_activation_func(self.weighted_sums[l], derivative=True)

    delta_w[l][:] += -self.eta * numpy.matmul(partial_deltas[l], self.activations[l-1].T)
```

Zuerst wird  $l$  den Index des Output-Layers haben, und da sich in ihm die Berechnung von den anderen Layern unterscheidet, bauen wir eine Fallunterscheidung ein.

# Backpropagation-Algorithmus

$$\delta_j^{(l)} = 2 \left( a_j^{(l)} - y_j \right) \cdot \sigma^{(l)'} \left( z_j^{(l)} \right)$$

7

Für den Output-Layer berechnet sich die partielle Ableitung  $\delta_j$  wie im ersten Fall von Gleichung 7 angegeben. Da wir die Ableitung der Aktivierungsfunktion benötigen, rufen wir sie mit dem Parameter `derivative=True` auf.

```
● ● ●  
# ...  
output_layer_derivative = 2 * error  
  
for l in range(len(self.structure) - 1, 0, -1):  
    if l == len(self.structure) - 1:  
        partial_deltas[l][:] = output_layer_derivative * \  
            self.output_activation_func(self.weighted_sums[l], derivative=True)  
    else:  
        partial_deltas[l][:] = \  
            numpy.matmul(self.weights[l+1][:, 1:].T, partial_deltas[l+1]) * \  
            self.hidden_activation_func(self.weighted_sums[l], derivative=True)  
  
    delta_w[l][:] += -self.eta * numpy.matmul(partial_deltas[l], self.activations[l-1].T)
```

# Backpropagation-Algorithmus

$$\delta_j^{(l)} = 2 \left( a_j^{(l)} - y_j \right) \cdot \sigma^{(l)'} \left( z_j^{(l)} \right)$$

7



```
# ...
output_layer_derivative = 2 * error

for l in range(len(self.structure) - 1, 0, -1):
    if l == len(self.structure) - 1:
        partial_deltas[l][:] = output_layer_derivative * \
            self.output_activation_func(self.weighted_sums[l], derivative=True)
    else:
        partial_deltas[l][:] = \
            numpy.matmul(self.weights[l+1][:, 1:].T, partial_deltas[l+1]) * \
            self.hidden_activation_func(self.weighted_sums[l], derivative=True)

delta_w[l][:] += -self.eta * numpy.matmul(partial_deltas[l], self.activations[l-1].T)
```

Ein \ am Ende der Zeile bedeutet, dass aus Platzgründen ein Zeilenumbruch gesetzt und der Ausdruck in der nächsten Zeile fortgeführt wird.

# Backpropagation-Algorithmus

$$\delta_j^{(l)} = \left( \sum_{i=0}^{n^{(l+1)}-1} \delta_i^{(l+1)} w_{ij}^{(l+1)} \right) \cdot \sigma^{(l)'} \left( z_j^{(l)} \right)$$

7



# ...

```
output_layer_derivative = 2 * error

for l in range(len(self.structure) - 1, 0, -1):
    if l == len(self.structure) - 1:
        partial_deltas[l][:] = output_layer_derivative * \
            self.output_activation_func(self.weighted_sums[l], derivative=True)
    else:
        partial_deltas[l][:] = \
            numpy.matmul(self.weights[l+1][:, 1:].T, partial_deltas[l+1]) * \
            self.hidden_activation_func(self.weighted_sums[l], derivative=True)

    delta_w[l][:] += -self.eta * numpy.matmul(partial_deltas[l], self.activations[l-1].T)
```

Für die Hidden Layer richten wir uns nach dem zweiten Fall in Gleichung 7. Der zweite Faktor ist fast identisch, auch hier rufen wir die Aktivierungsfunktion (diesmal die für die Hidden-Layer) mit den gewichteten Summen und **derivative=True** als Parameter auf.

# Backpropagation-Algorithmus

$$\delta_j^{(l)} = \left( \sum_{i=0}^{n^{(l+1)}-1} \delta_i^{(l+1)} w_{ij}^{(l+1)} \right) \cdot \sigma^{(l)'} \left( z_j^{(l)} \right)$$

7



```
# ...
output_layer_derivative = 2 * error

for l in range(len(self.structure) - 1, 0, -1):
    if l == len(self.structure) - 1:
        partial_deltas[l][:] = output_layer_derivative * \
            self.output_activation_func(self.weighted_sums[l], derivative=True)
    else:
        partial_deltas[l][:] = \
            numpy.matmul(self.weights[l+1][:, 1:].T, partial_deltas[l+1]) * \
            self.hidden_activation_func(self.weighted_sums[l], derivative=True)

    delta_w[l][:] += -self.eta * numpy.matmul(partial_deltas[l], self.activations[l-1].T)
```

Die große Summe im ersten Faktor führen wir auf eine **Matrixmultiplikation** der Gewichte zum nächsten Layer und der partiellen Ableitungen des nächsten Layers zurück.

# Backpropagation-Algorithmus

$$\delta_j^{(l)} = \left( \sum_{i=0}^{n^{(l+1)}-1} \delta_i^{(l+1)} w_{ij}^{(l+1)} \right) \cdot \sigma^{(l)'} \left( z_j^{(l)} \right)$$

7



```
# ...
output_layer_derivative = 2 * error

for l in range(len(self.structure) - 1, 0, -1):    partial_deltas
    if l == len(self.structure) - 1:
        partial_deltas[l][:] = output_layer_derivative * \
            self.output_activation_func(self.weighted_sums[l], derivative=True)
    else:
        partial_deltas[l][:] = \
            numpy.matmul(self.weights[l+1][:, 1:].T, partial_deltas[l+1]) * \
            self.hidden_activation_func(self.weighted_sums[l], derivative=True)

delta_w[l][:] += -self.eta * numpy.matmul(partial_deltas[l], self.activations[l-1].T)
```

Mit der Slice-Syntax schneiden wir dafür die erste Spalte der Gewichtsmatrix heraus, also die von den Bias-Neuronen ausgehenden Gewichte. Die Bias-Neuronen sollen sich nicht auf die vorherigen Layer auswirken und daher keinen Eintrag in

partial\_deltas erzeugen.

# Backpropagation-Algorithmus

$$\delta_j^{(l)} = \left( \sum_{i=0}^{n^{(l+1)}-1} \delta_i^{(l+1)} w_{ij}^{(l+1)} \right) \cdot \sigma^{(l)'} \left( z_j^{(l)} \right)$$

7



```
# ...
output_layer_derivative = 2 * error

for l in range(len(self.structure) - 1, 0, -1):
    if l == len(self.structure) - 1:
        partial_deltas[l][:] = output_layer_derivative * \
            self.output_activation_func(self.weighted_sums[l], derivative=True)
    else:
        partial_deltas[l][:] = \
            numpy.matmul(self.weights[l+1][:, 1:].T, partial_deltas[l+1]) * \
            self.hidden_activation_func(self.weighted_sums[l], derivative=True)

    delta_w[l][:] += -self.eta * numpy.matmul(partial_deltas[l], self.activations[l-1].T)
```

Von der auf diese Weise zurechtgeschnittenen Matrix benötigen wir die transponierte Version (siehe nächste Folie), die wir von numpy mit .T erhalten.

# Matrixtransposition – Beispiel

$$W = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}$$



$$W^T = \begin{pmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{pmatrix}$$

# Matrixtransposition – Beispiel

$$W = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}$$

2 Zeilen, 3 Spalten



$$W^T = \begin{pmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \\ 6 \end{pmatrix}$$

3 Zeilen, 2 Spalten

# Matrixtransposition

- Eine Matrix zu **transponieren** heißt, ihre **Zeilen** und **Spalten** die Rollen tauschen zu lassen.

# Matrixtransposition

- Eine Matrix zu **transponieren** heißt, ihre **Zeilen** und **Spalten** die Rollen tauschen zu lassen.
- Sei eine Matrix  $W$  mit  $m$  Zeilen und  $n$  Spalten gegeben durch:

$$W = \begin{pmatrix} w_{1,1} & \dots & w_{1,n} \\ \vdots & \ddots & \vdots \\ w_{m,1} & \dots & w_{m,n} \end{pmatrix}$$

# Matrixtransposition

- Eine Matrix zu **transponieren** heißt, ihre **Zeilen** und **Spalten** die Rollen tauschen zu lassen.
- Sei eine Matrix  $W$  mit  $m$  Zeilen und  $n$  Spalten gegeben durch:

$$W = \begin{pmatrix} w_{1,1} & \dots & w_{1,n} \\ \vdots & \ddots & \vdots \\ w_{m,1} & \dots & w_{m,n} \end{pmatrix}$$

- Dann ist ihre transponierte Matrix  $W^T$  definiert als:

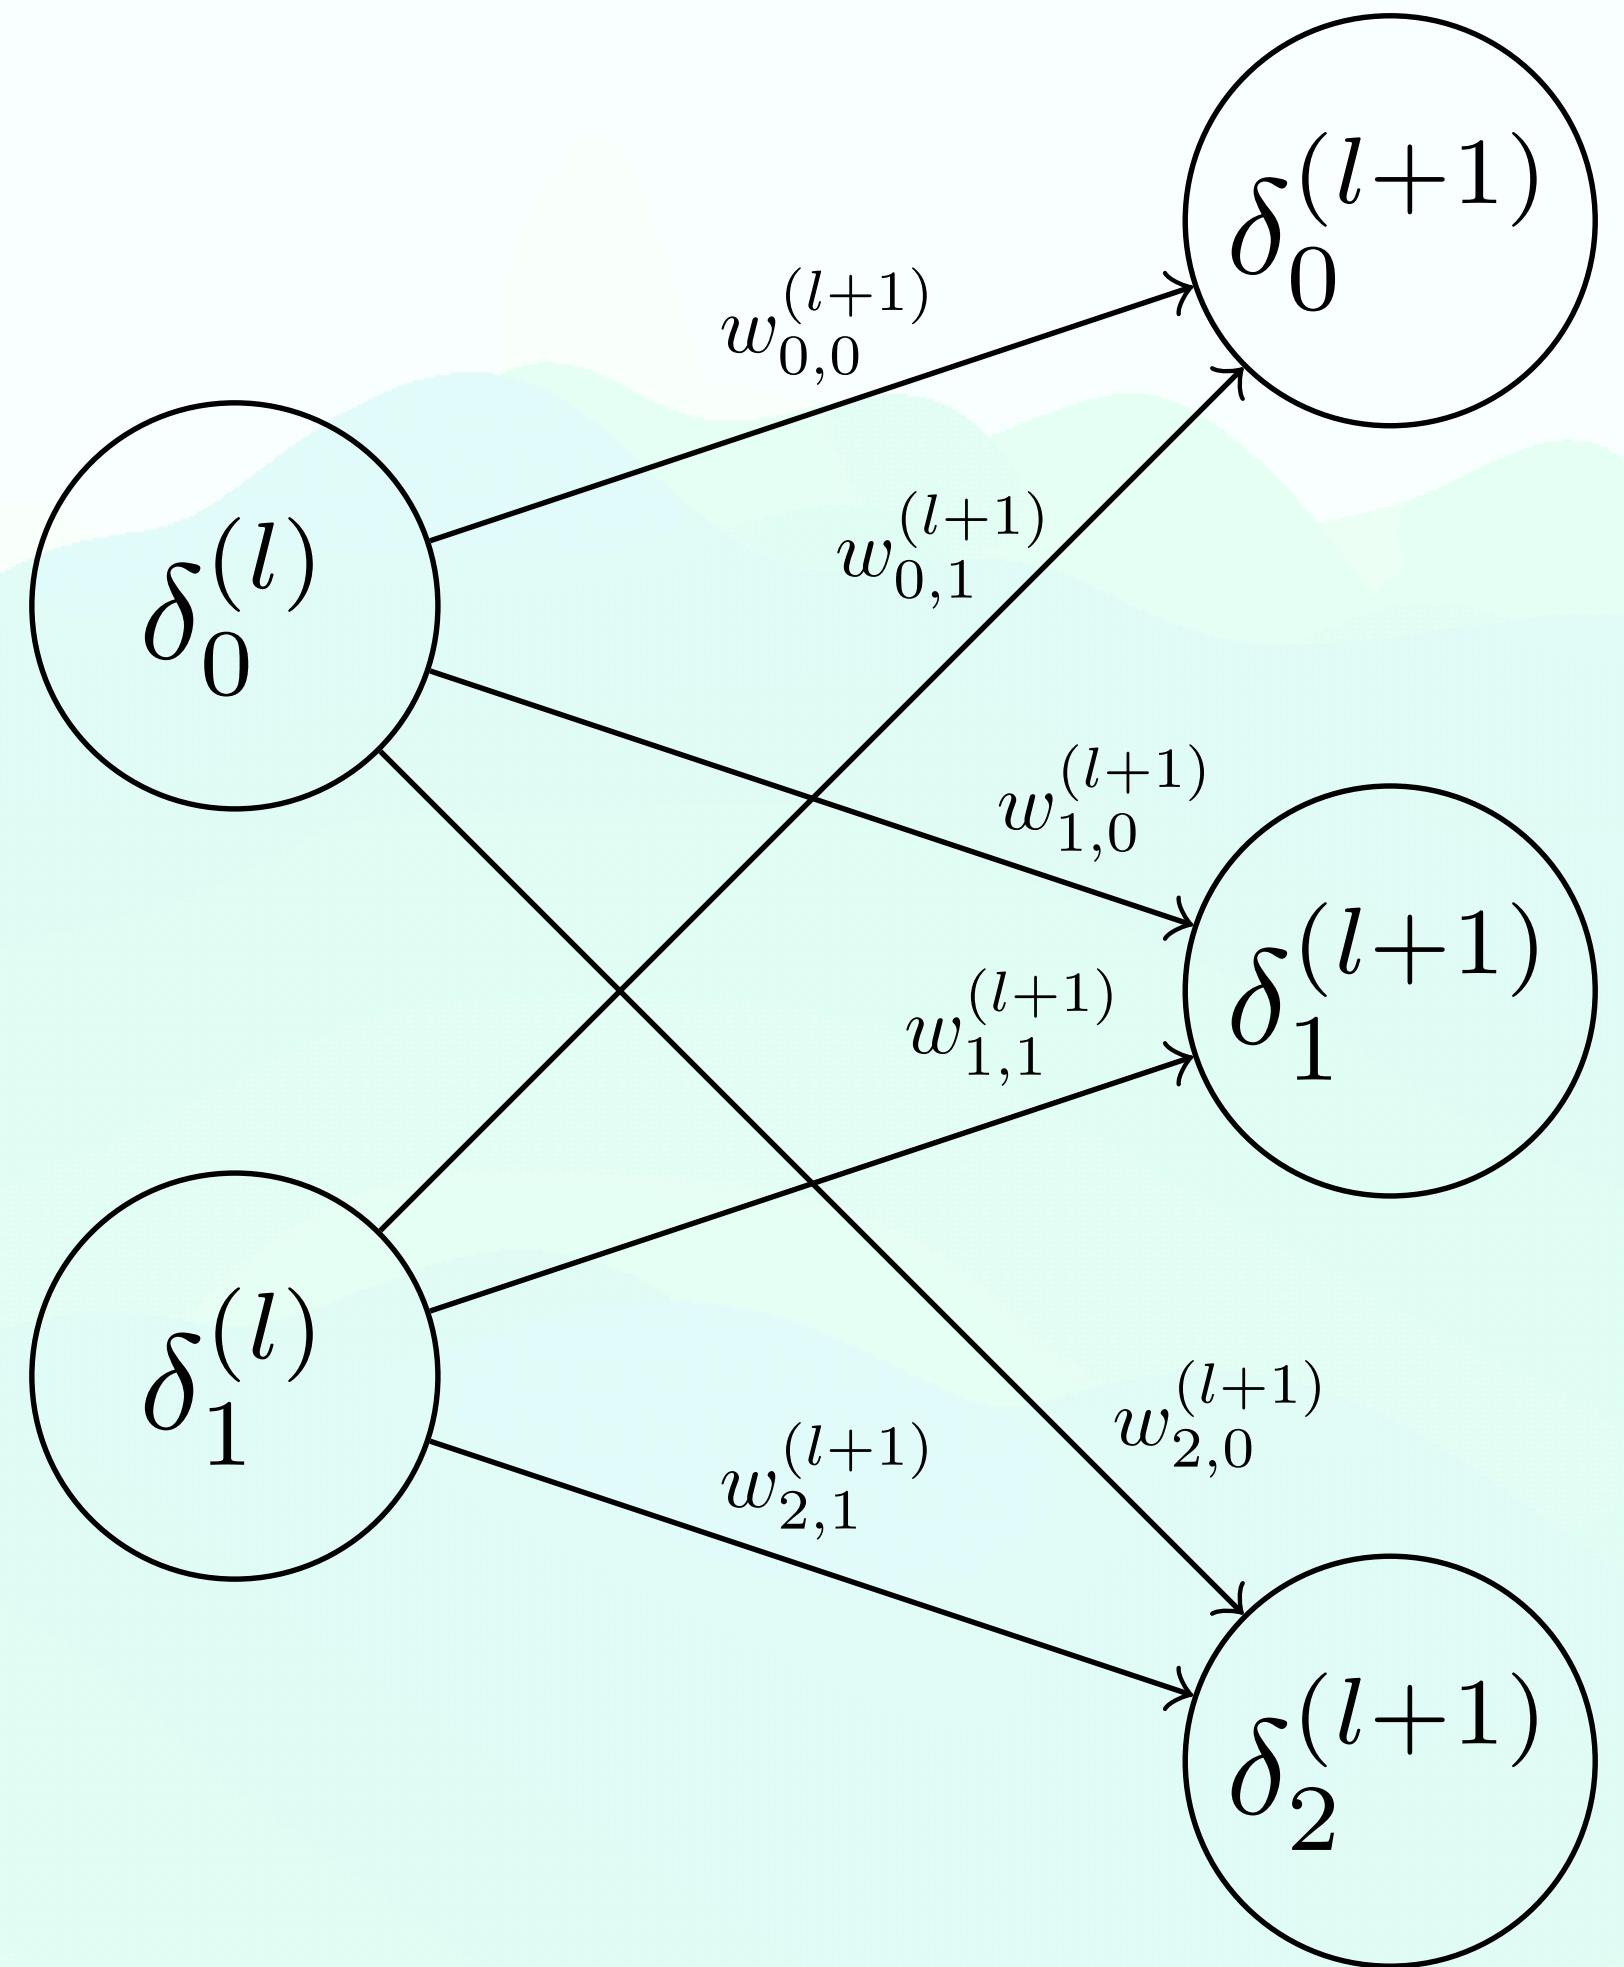
$$W^T = \begin{pmatrix} w_{1,1} & \dots & w_{m,1} \\ \vdots & \ddots & \vdots \\ w_{1,n} & \dots & w_{m,n} \end{pmatrix}$$

# Backpropagation als Matrixmultiplikation

$$\delta_j^{(l)} = \left( \sum_{i=0}^{n^{(l+1)}-1} \delta_i^{(l+1)} w_{ij}^{(l+1)} \right) \cdot \sigma^{(l)'}(z_j^{(l)})$$

7

Es werden die  $\delta_i$  und die  $w_{ij}$  von Layer  $l + 1$  miteinander multipliziert.



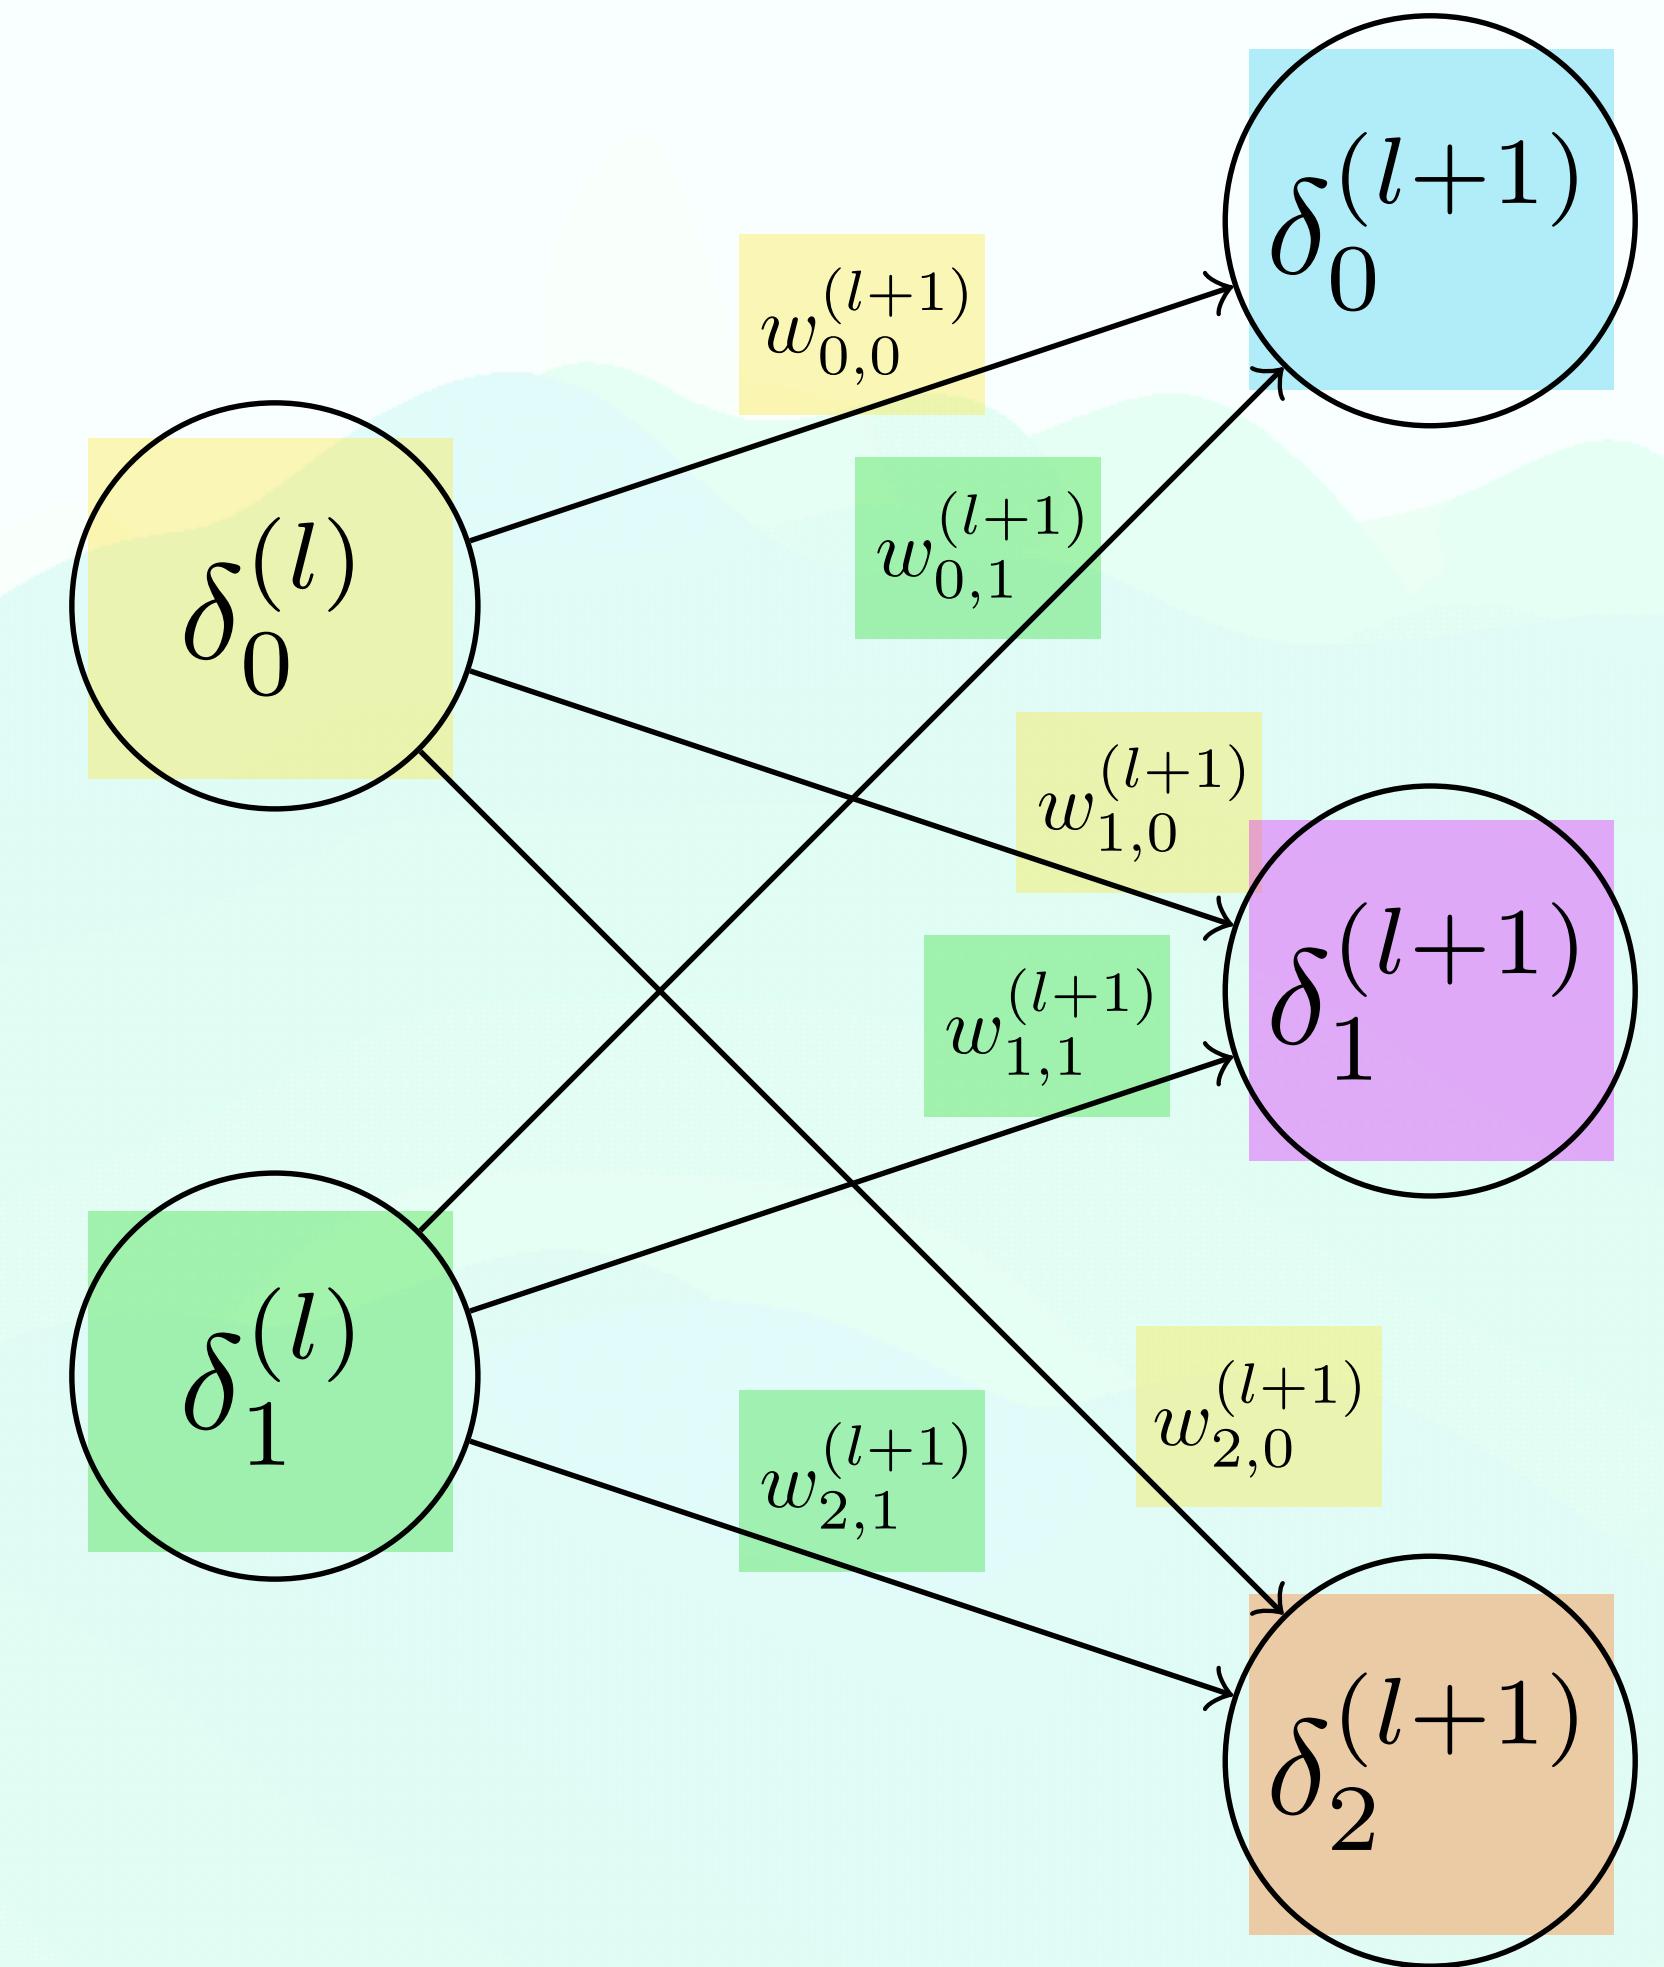
# Backpropagation als Matrixmultiplikation

$$\delta_j^{(l)} = \left( \sum_{i=0}^{n^{(l+1)}-1} \delta_i^{(l+1)} w_{ij}^{(l+1)} \right) \cdot \sigma^{(l)'}(z_j^{(l)})$$
7

Es werden die  $\delta_i$  und die  $w_{ij}$  von Layer  $l + 1$  miteinander multipliziert.

Für die einzelnen  $\delta_j^{(l)}$  ergeben sich also folgende Summen:

$\delta_j^{(l)}$	Summe für $\delta_j^{(l)}$
$\delta_0^{(l)}$	$\delta_0^{(l+1)} w_{0,0}^{(l+1)} + \delta_1^{(l+1)} w_{1,0}^{(l+1)} + \delta_2^{(l+1)} w_{2,0}^{(l+1)}$
$\delta_1^{(l)}$	$\delta_0^{(l+1)} w_{0,1}^{(l+1)} + \delta_1^{(l+1)} w_{1,1}^{(l+1)} + \delta_2^{(l+1)} w_{2,1}^{(l+1)}$



# Backpropagation als Matrixmultiplikation

$\delta_j^{(l)}$	Summe für $\delta_j^{(l)}$
$\delta_0^{(l)}$	$\delta_0^{(l+1)}w_{0,0}^{(l+1)} + \delta_1^{(l+1)}w_{1,0}^{(l+1)} + \delta_2^{(l+1)}w_{2,0}^{(l+1)}$
$\delta_1^{(l)}$	$\delta_0^{(l+1)}w_{0,1}^{(l+1)} + \delta_1^{(l+1)}w_{1,1}^{(l+1)} + \delta_2^{(l+1)}w_{2,1}^{(l+1)}$

Die beiden zu multiplizierenden Matrizen dafür sind:

$$\vec{\delta}^{(l+1)} = \begin{pmatrix} \delta_0^{(l+1)} \\ \delta_1^{(l+1)} \\ \delta_2^{(l+1)} \end{pmatrix}$$

$$W^{(l+1)} = \begin{pmatrix} w_{0,0}^{(l+1)} & w_{0,1}^{(l+1)} \\ w_{1,0}^{(l+1)} & w_{1,1}^{(l+1)} \\ w_{2,0}^{(l+1)} & w_{2,1}^{(l+1)} \end{pmatrix}$$

# Backpropagation als Matrixmultiplikation

$\delta_j^{(l)}$	Summe für $\delta_j^{(l)}$
$\delta_0^{(l)}$	$\delta_0^{(l+1)}w_{0,0}^{(l+1)} + \delta_1^{(l+1)}w_{1,0}^{(l+1)} + \delta_2^{(l+1)}w_{2,0}^{(l+1)}$
$\delta_1^{(l)}$	$\delta_0^{(l+1)}w_{0,1}^{(l+1)} + \delta_1^{(l+1)}w_{1,1}^{(l+1)} + \delta_2^{(l+1)}w_{2,1}^{(l+1)}$

Doch für die Matrixmultiplikation muss die erste Matrix so viele **Spalten** haben wie die zweite **Zeilen** hat.

Die beiden zu multiplizierenden Matrizen dafür sind:

$$\vec{\delta}^{(l+1)} = \begin{pmatrix} \delta_0^{(l+1)} \\ \delta_1^{(l+1)} \\ \delta_2^{(l+1)} \end{pmatrix}$$

$$W^{(l+1)} = \begin{pmatrix} w_{0,0}^{(l+1)} & w_{0,1}^{(l+1)} \\ w_{1,0}^{(l+1)} & w_{1,1}^{(l+1)} \\ w_{2,0}^{(l+1)} & w_{2,1}^{(l+1)} \end{pmatrix}$$

# Backpropagation als Matrixmultiplikation

$\delta_j^{(l)}$	Summe für $\delta_j^{(l)}$
$\delta_0^{(l)}$	$\delta_0^{(l+1)}w_{0,0}^{(l+1)} + \delta_1^{(l+1)}w_{1,0}^{(l+1)} + \delta_2^{(l+1)}w_{2,0}^{(l+1)}$
$\delta_1^{(l)}$	$\delta_0^{(l+1)}w_{0,1}^{(l+1)} + \delta_1^{(l+1)}w_{1,1}^{(l+1)} + \delta_2^{(l+1)}w_{2,1}^{(l+1)}$

Doch für die Matrixmultiplikation muss die erste Matrix so viele **Spalten** haben wie die zweite **Zeilen** hat.

Wenn wir  $W^{(l+1)}$  transponieren, erhalten wir eine Matrix mit zwei Zeilen und **drei Spalten**, und können diese transponierte Matrix dann mit  $\vec{\delta}^{(l+1)}$  (**drei Zeilen**) multiplizieren.

Die beiden zu multiplizierenden Matrizen dafür sind:

$$\vec{\delta}^{(l+1)} = \begin{pmatrix} \delta_0^{(l+1)} \\ \delta_1^{(l+1)} \\ \delta_2^{(l+1)} \end{pmatrix}$$

$$W^{(l+1)} = \begin{pmatrix} w_{0,0}^{(l+1)} & w_{0,1}^{(l+1)} \\ w_{1,0}^{(l+1)} & w_{1,1}^{(l+1)} \\ w_{2,0}^{(l+1)} & w_{2,1}^{(l+1)} \end{pmatrix}$$

# Backpropagation als Matrixmultiplikation

$\delta_j^{(l)}$	Summe für $\delta_j^{(l)}$
$\delta_0^{(l)}$	$\delta_0^{(l+1)}w_{0,0}^{(l+1)} + \delta_1^{(l+1)}w_{1,0}^{(l+1)} + \delta_2^{(l+1)}w_{2,0}^{(l+1)}$
$\delta_1^{(l)}$	$\delta_0^{(l+1)}w_{0,1}^{(l+1)} + \delta_1^{(l+1)}w_{1,1}^{(l+1)} + \delta_2^{(l+1)}w_{2,1}^{(l+1)}$

Doch für die Matrixmultiplikation muss die erste Matrix so viele **Spalten** haben wie die zweite **Zeilen** hat.

Wenn wir  $W^{(l+1)}$  transponieren, erhalten wir eine Matrix mit zwei Zeilen und **drei Spalten**, und können diese transponierte Matrix dann mit  $\vec{\delta}^{(l+1)}$  (**drei Zeilen**) multiplizieren.

Das Ergebnis ist eine Matrix mit **einer Spalte** und **zwei Zeilen**.

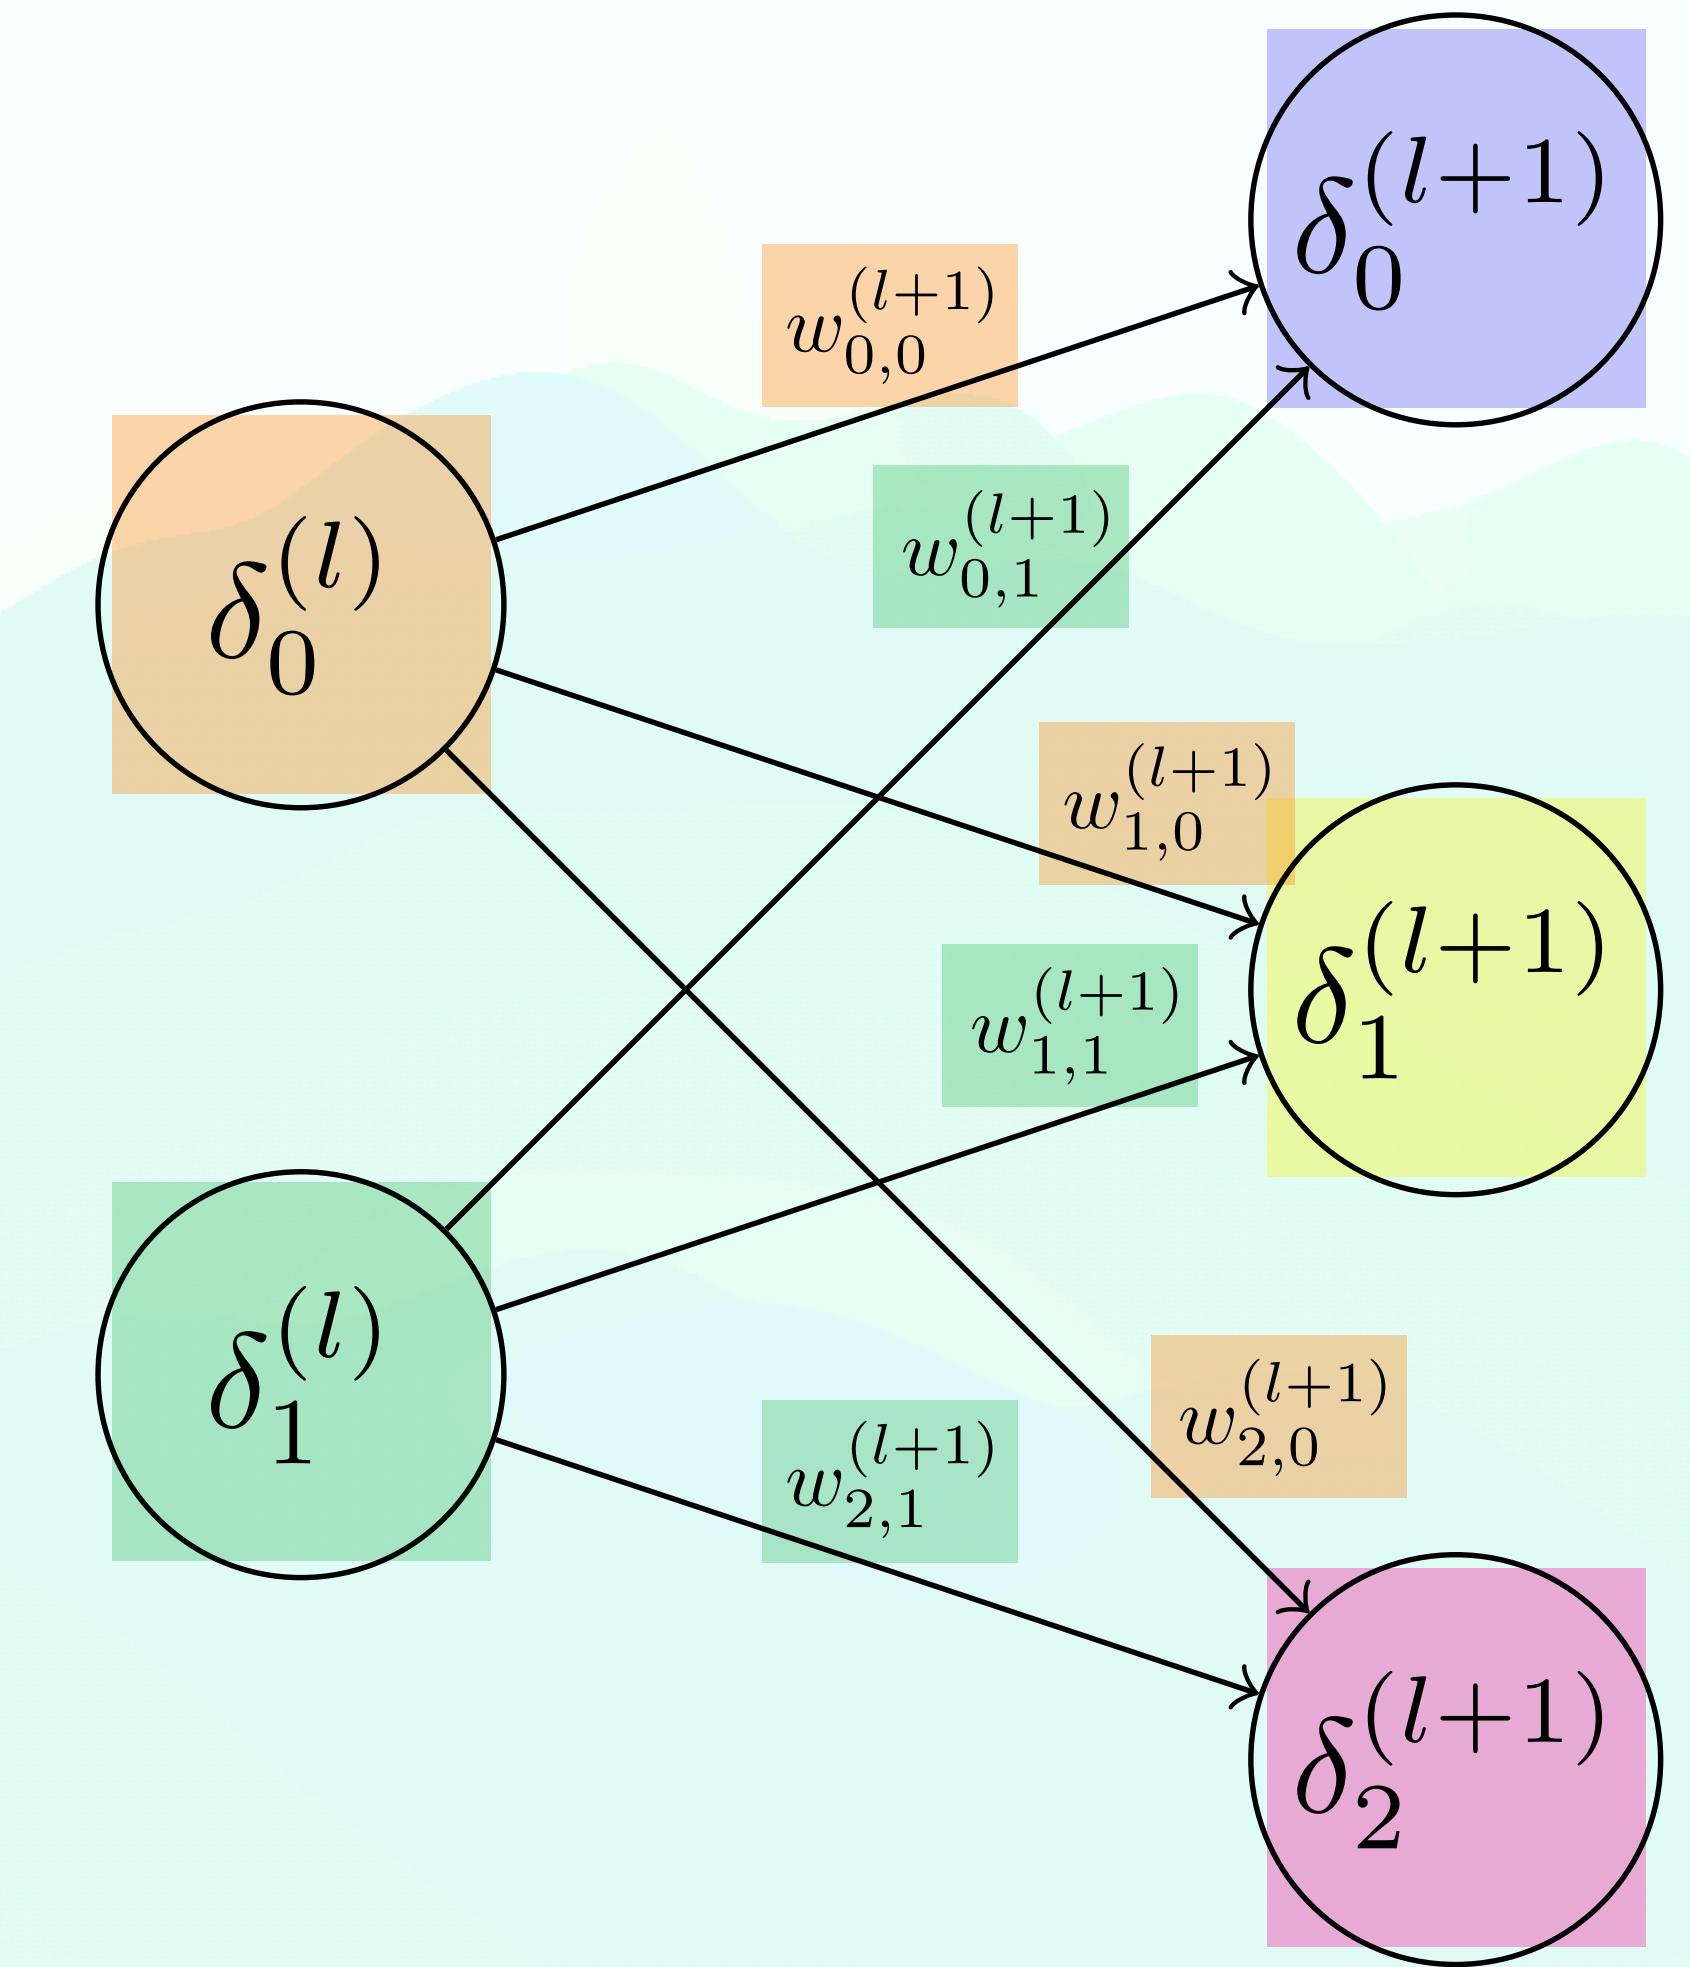
Die beiden zu multiplizierenden Matrizen dafür sind:

$$\vec{\delta}^{(l+1)} = \begin{pmatrix} \delta_0^{(l+1)} \\ \delta_1^{(l+1)} \\ \delta_2^{(l+1)} \end{pmatrix}$$

$$W^{(l+1)} = \begin{pmatrix} w_{0,0}^{(l+1)} & w_{0,1}^{(l+1)} \\ w_{1,0}^{(l+1)} & w_{1,1}^{(l+1)} \\ w_{2,0}^{(l+1)} & w_{2,1}^{(l+1)} \end{pmatrix}$$

# Backpropagation als Matrixmultiplikation

$$\begin{aligned}
 & \left( W^{(l+1)} \right)^T \times \vec{\delta}^{(l+1)} = \\
 & \begin{pmatrix} w_{0,0}^{(l+1)} & w_{1,0}^{(l+1)} & w_{2,0}^{(l+1)} \\ w_{0,1}^{(l+1)} & w_{1,1}^{(l+1)} & w_{2,1}^{(l+1)} \end{pmatrix} \times \begin{pmatrix} \delta_0^{(l+1)} \\ \delta_1^{(l+1)} \\ \delta_2^{(l+1)} \end{pmatrix} = \\
 & \left( \begin{array}{c|c} w_{0,0}^{(l+1)} \delta_0^{(l+1)} & + w_{1,0}^{(l+1)} \delta_1^{(l+1)} & + w_{2,0}^{(l+1)} \delta_2^{(l+1)} \\ \hline w_{0,1}^{(l+1)} \delta_0^{(l+1)} & + w_{1,1}^{(l+1)} \delta_1^{(l+1)} & + w_{2,1}^{(l+1)} \delta_2^{(l+1)} \end{array} \right) = \begin{pmatrix} \delta_0^{(l)} \\ \delta_1^{(l)} \end{pmatrix}
 \end{aligned}$$



# Backpropagation-Algorithmus

$$\Delta w_{jk}^{(l)} = -\eta \cdot \delta_j^{(l)} \cdot a_k^{(l-1)}$$

8



```
# ...
output_layer_derivative = 2 * error
```

```
for l in range(len(self.structure) - 1, 0, -1):
    if l == len(self.structure) - 1:
        partial_deltas[l][:] = output_layer_derivative * \
            self.output_activation_func(self.weighted_sums[l], derivative=True)
    else:
        partial_deltas[l][:] = \
            numpy.matmul(self.weights[l+1][:, 1:].T, partial_deltas[l+1]) * \
            self.hidden_activation_func(self.weighted_sums[l], derivative=True)

    delta_w[l][:] += -self.eta * numpy.matmul(partial_deltas[l], self.activations[l-1].T)
```

Im letzten Schritt berechnen wir nach Gleichung 8 die Gewichtsanpassungen  $\Delta w$  für den aktuellen Layer  $l$ , also den ermittelten Gradienten zur Minimierung der Kostenfunktion.

# Backpropagation-Algorithmus

$$\Delta w_{jk}^{(l)} = -\eta \cdot \delta_j^{(l)} \cdot a_k^{(l-1)}$$

8



```
# ...
output_layer_derivative = 2 * error
```

```
for l in range(len(self.structure) - 1, 0, -1):
    if l == len(self.structure) - 1:
        partial_deltas[l][:] = output_layer_derivative * \
            self.output_activation_func(self.weighted_sums[l], derivative=True)
    else:
        partial_deltas[l][:] = \
            numpy.matmul(self.weights[l+1][:, 1:].T, partial_deltas[l+1]) * \
            self.hidden_activation_func(self.weighted_sums[l], derivative=True)

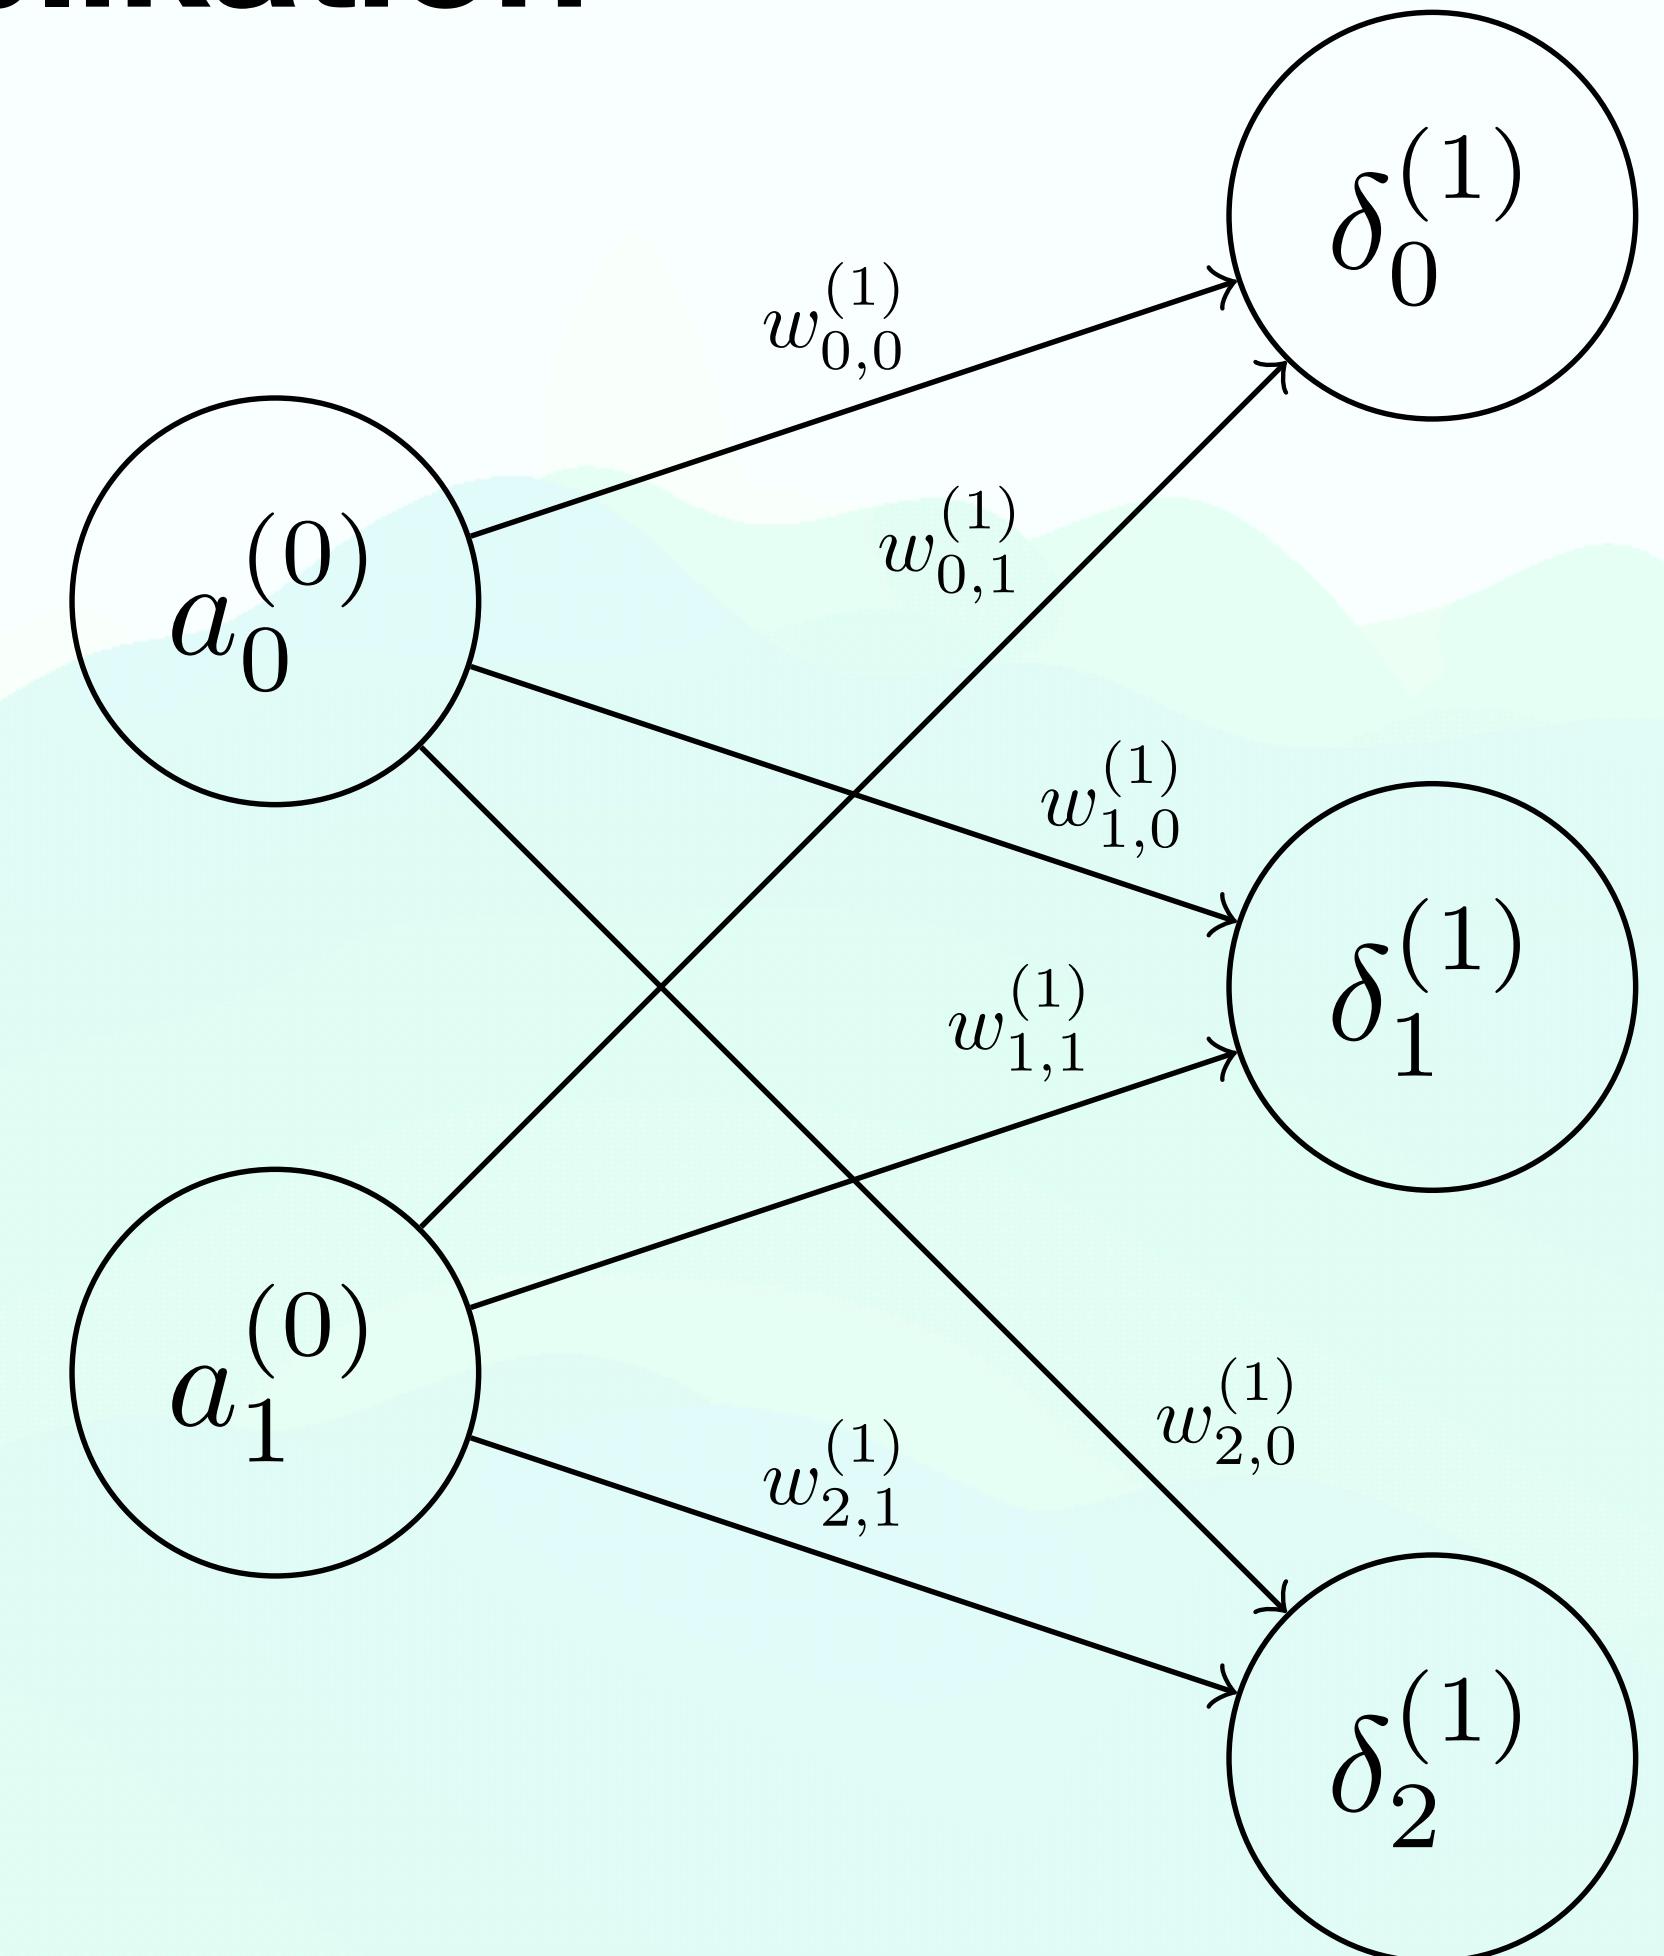
    delta_w[l][:] += -self.eta * numpy.matmul(partial_deltas[l], self.activations[l-1].T)
```

Um die Multiplikationen der partiellen Ableitungen des Layers  $l$  und der Aktivierungen des Layers  $l-1$  nicht einzeln ausführen zu müssen, führen wir auch diese Operation auf eine Matrixmultiplikation zurück (siehe nächste Folien).

# Anpassung der Gewichte als Matrixmultiplikation

$$\Delta w_{jk}^{(l)} = -\eta \cdot \delta_j^{(l)} \cdot a_k^{(l-1)}$$

8



# Anpassung der Gewichte als Matrixmultiplikation

$$\Delta w_{jk}^{(l)} = -\eta \cdot \delta_j^{(l)} \cdot a_k^{(l-1)}$$

8

Das heißt für das Beispielnetz rechts:

$$\Delta w_{0,0}^{(1)} = -\eta \cdot \delta_0^{(1)} \cdot a_0^{(0)}$$

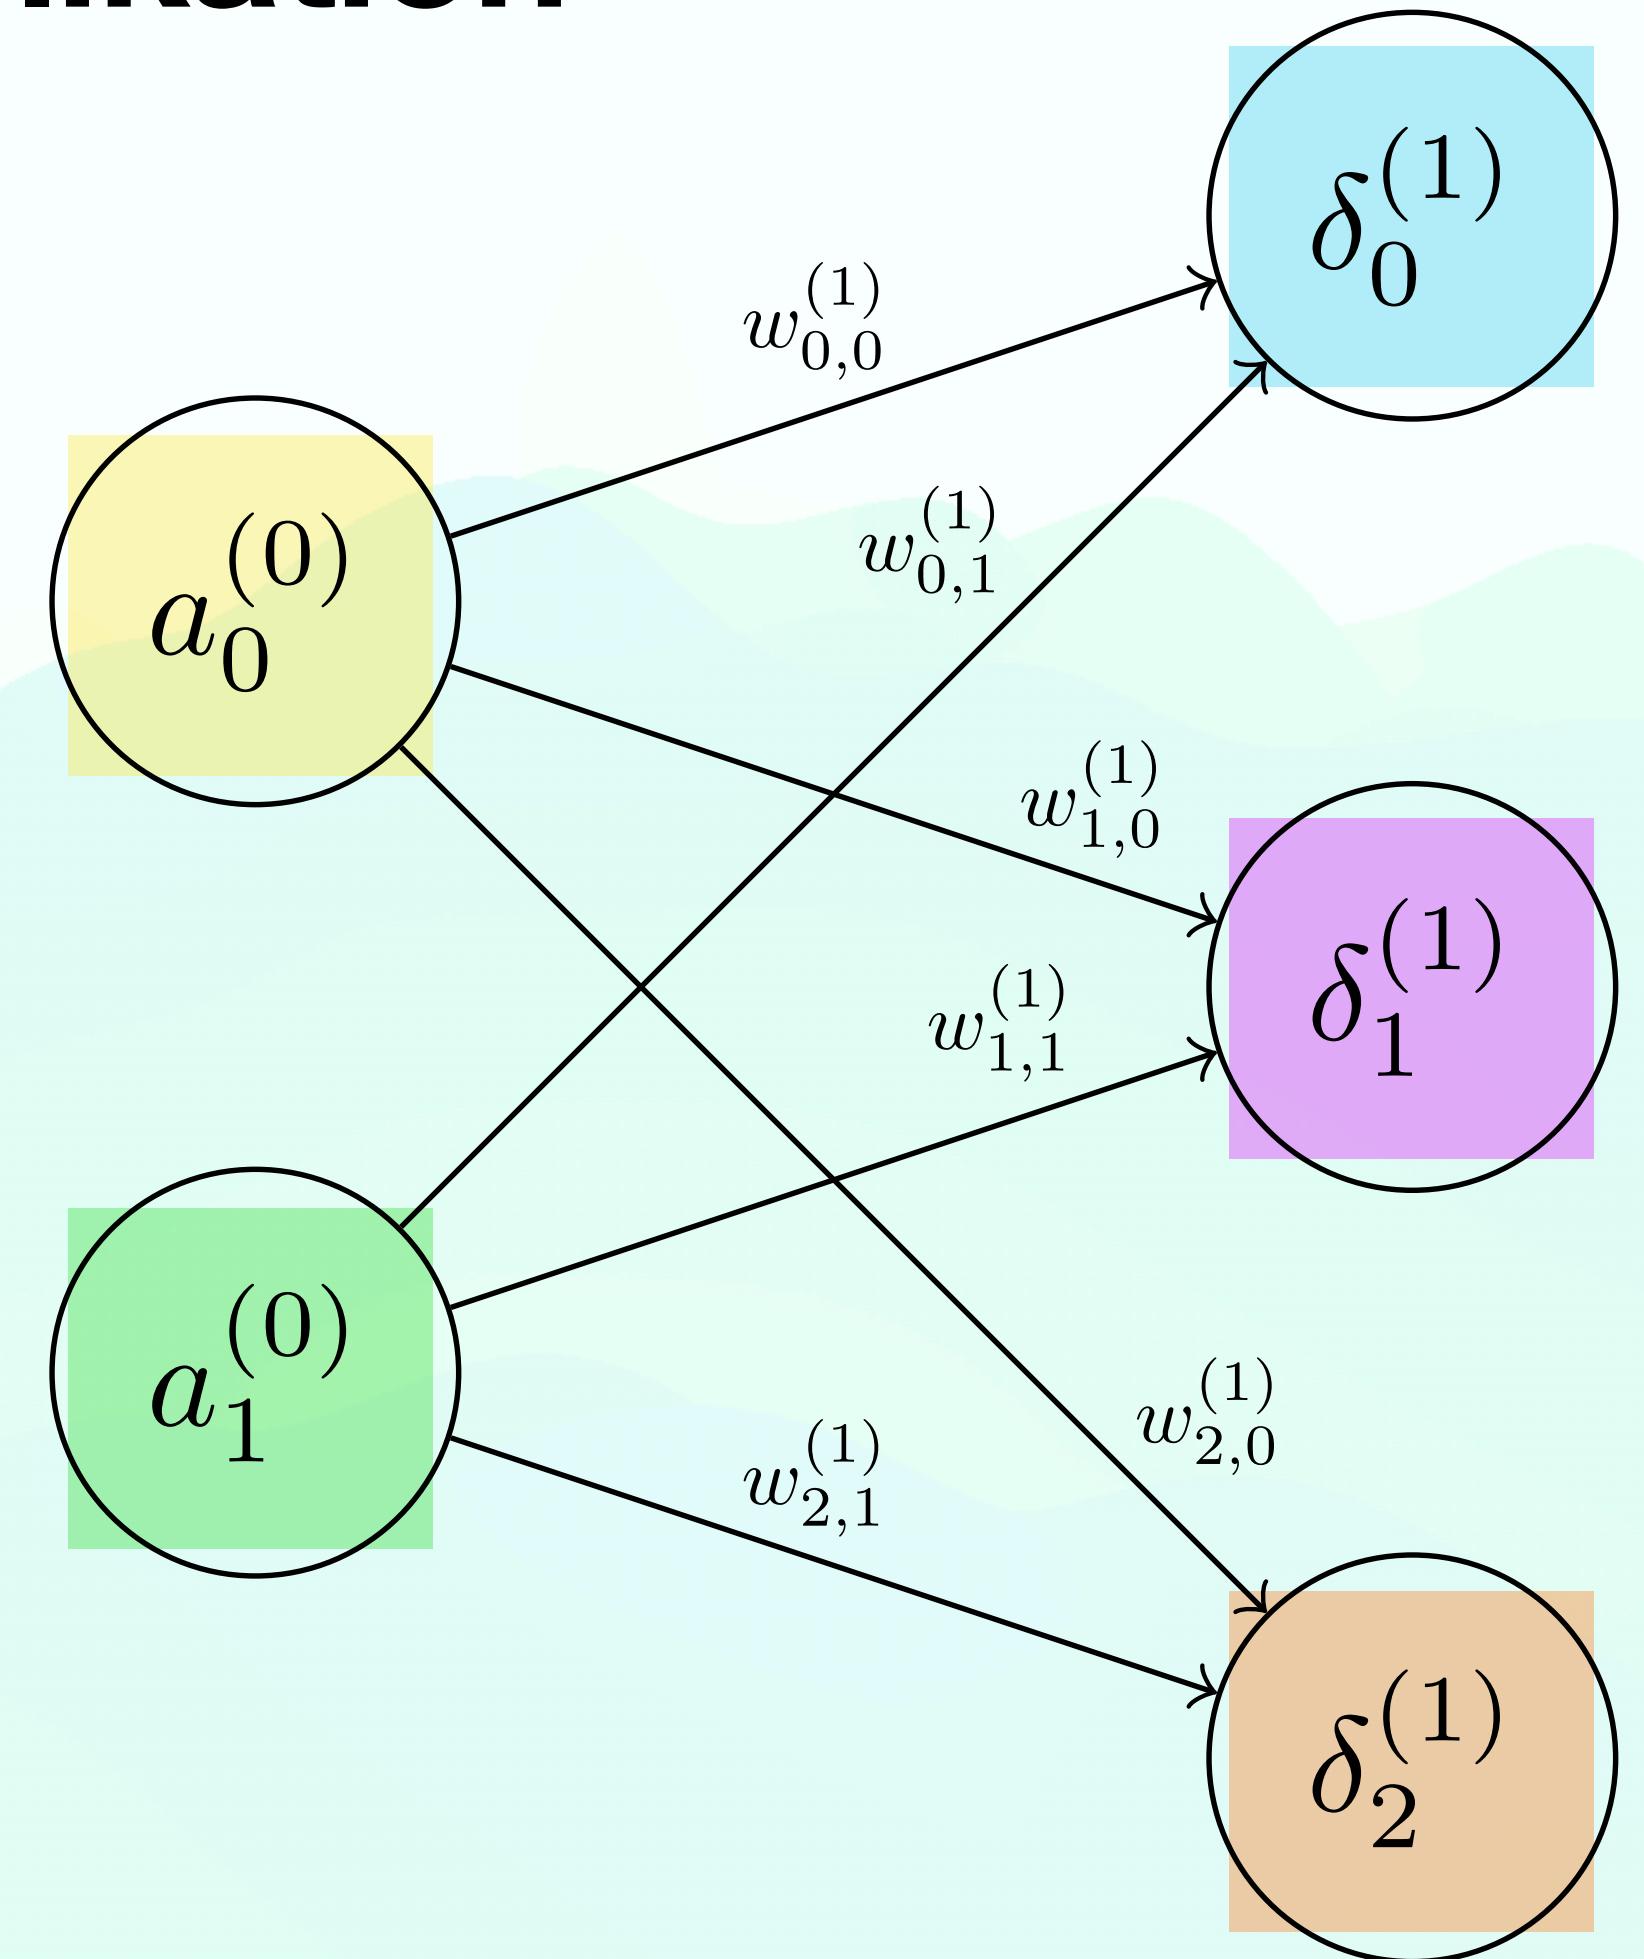
$$\Delta w_{1,0}^{(1)} = -\eta \cdot \delta_1^{(1)} \cdot a_0^{(0)}$$

$$\Delta w_{2,0}^{(1)} = -\eta \cdot \delta_2^{(1)} \cdot a_0^{(0)}$$

$$\Delta w_{0,1}^{(1)} = -\eta \cdot \delta_0^{(1)} \cdot a_1^{(0)}$$

$$\Delta w_{1,1}^{(1)} = -\eta \cdot \delta_1^{(1)} \cdot a_1^{(0)}$$

$$\Delta w_{2,1}^{(1)} = -\eta \cdot \delta_2^{(1)} \cdot a_1^{(0)}$$



# Anpassung der Gewichte als Matrixmultiplikation

$$\Delta w_{jk}^{(l)} = -\eta \cdot \delta_j^{(l)} \cdot a_k^{(l-1)}$$

8

Das heißt für das Beispielnetz rechts:

$$\Delta w_{0,0}^{(1)} = -\eta \cdot \delta_0^{(1)} \cdot a_0^{(0)}$$

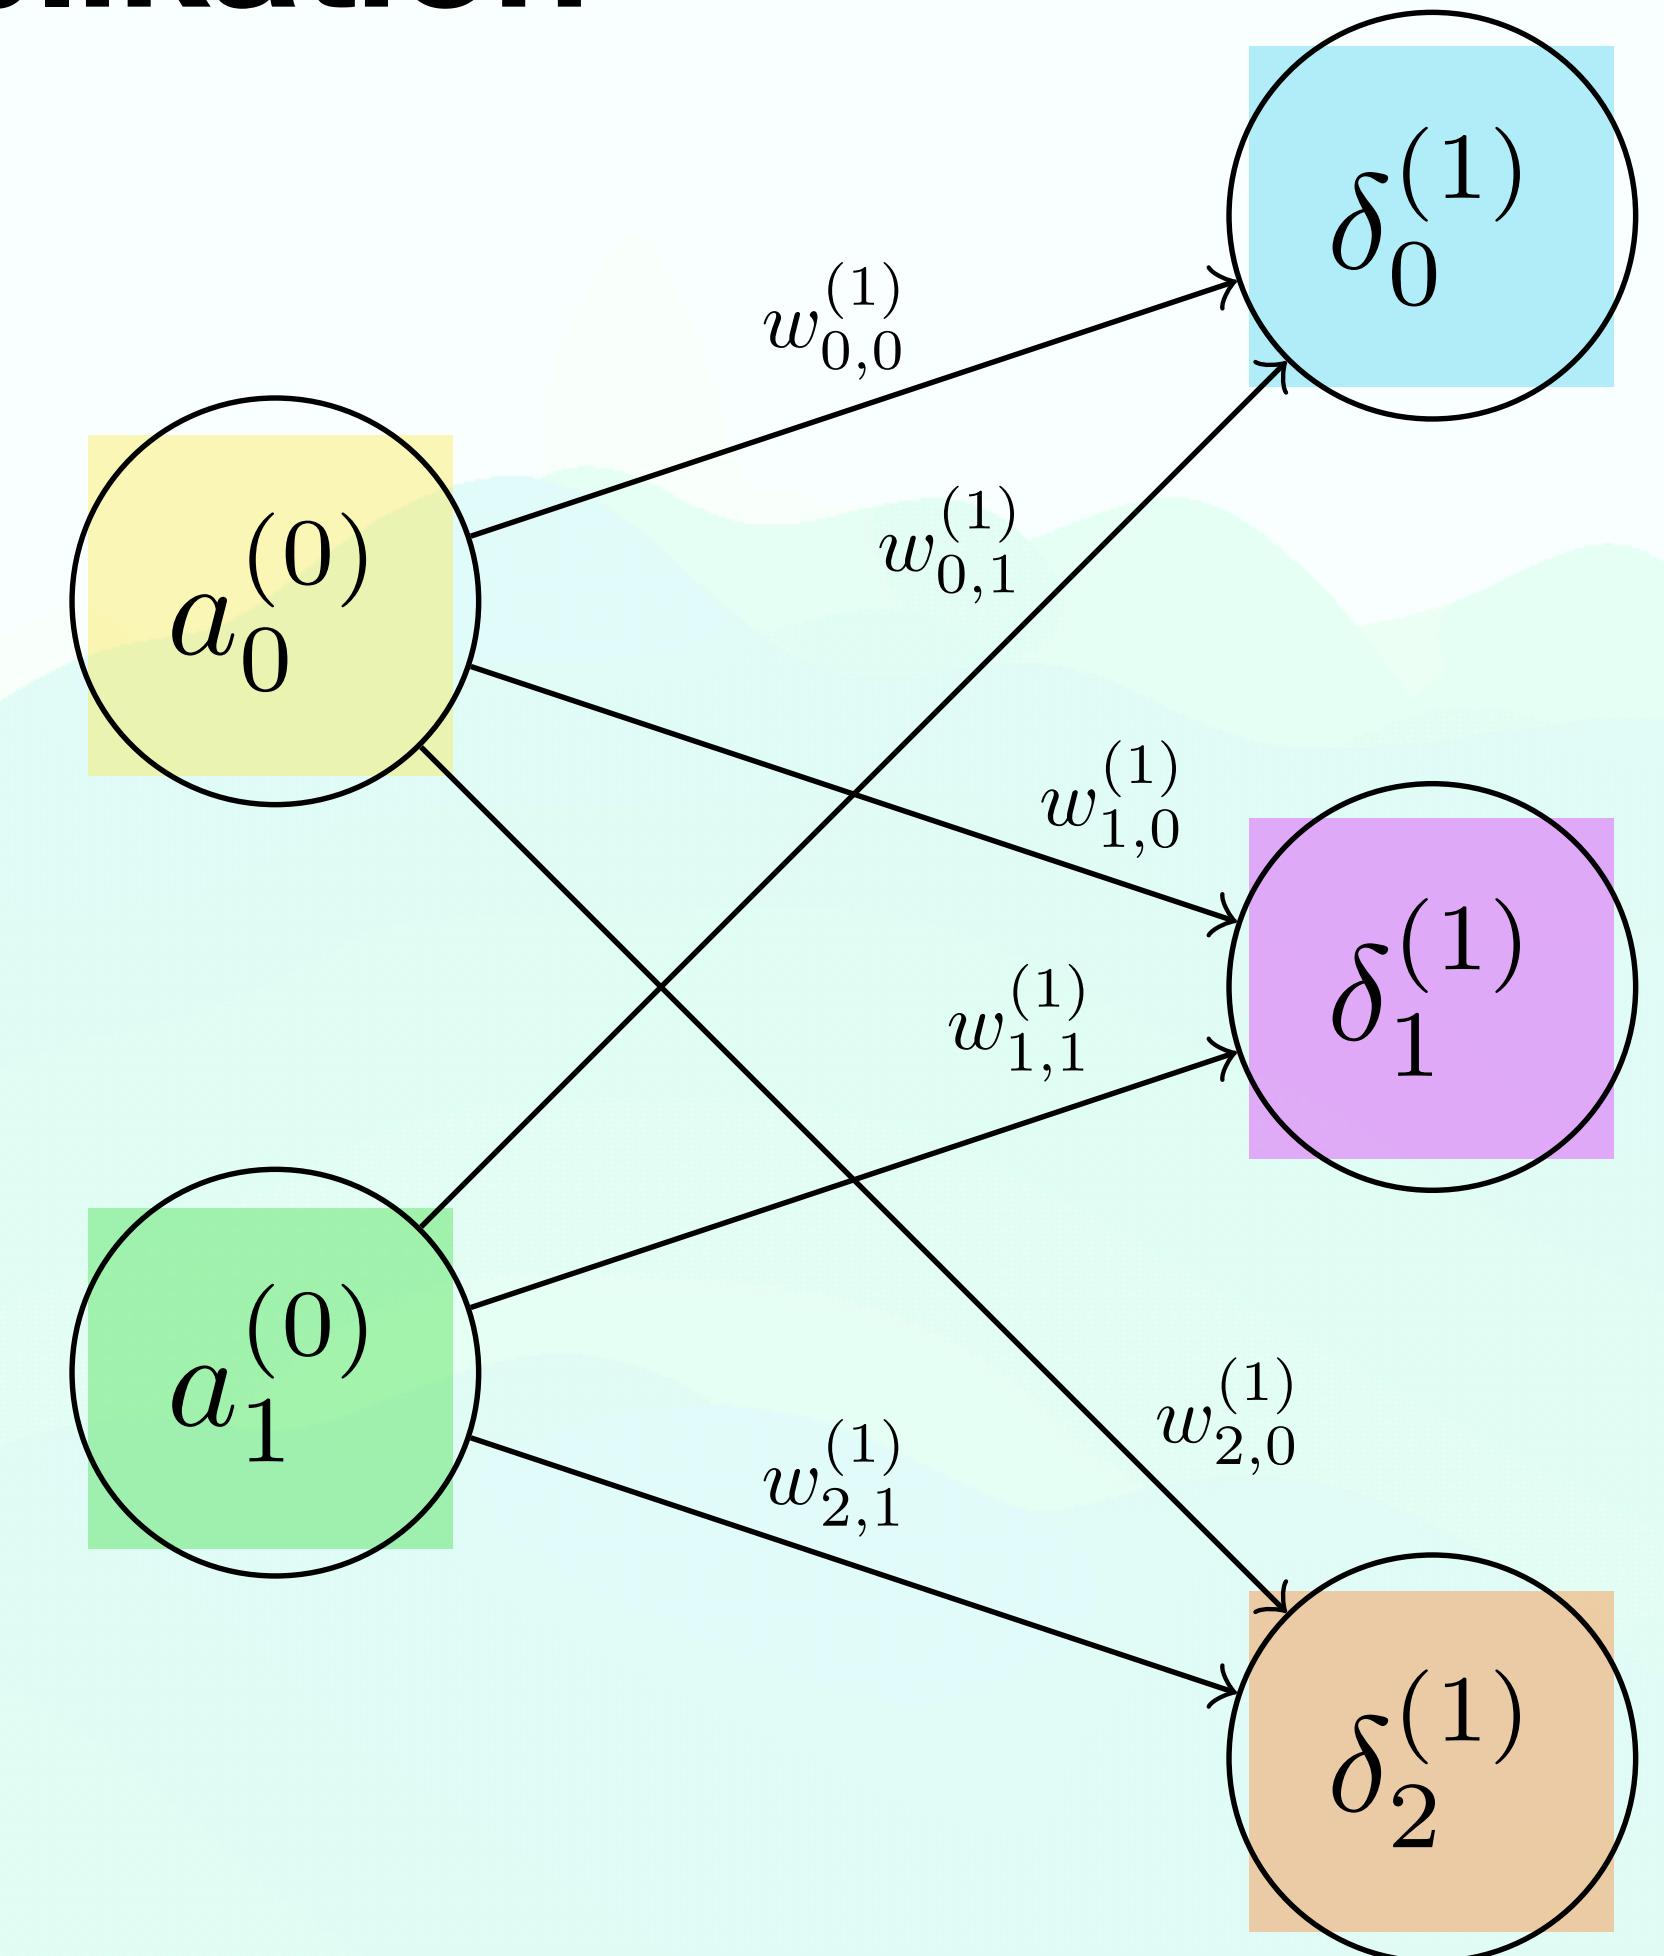
$$\Delta w_{0,1}^{(1)} = -\eta \cdot \delta_0^{(1)} \cdot a_1^{(0)}$$

$$\Delta w_{1,0}^{(1)} = -\eta \cdot \delta_1^{(1)} \cdot a_0^{(0)}$$

$$\Delta w_{1,1}^{(1)} = -\eta \cdot \delta_1^{(1)} \cdot a_1^{(0)}$$

$$\Delta w_{2,0}^{(1)} = -\eta \cdot \delta_2^{(1)} \cdot a_0^{(0)}$$

$$\Delta w_{2,1}^{(1)} = -\eta \cdot \delta_2^{(1)} \cdot a_1^{(0)}$$



$\Delta W^{(1)}$  soll eine Matrix vom gleichen Format wie  $W^{(1)}$  sein, also **drei Zeilen und zwei Spalten** haben

# Anpassung der Gewichte als Matrixmultiplikation

$$\Delta w_{0,0}^{(1)} = -\eta \cdot \delta_0^{(1)} \cdot a_0^{(0)}$$

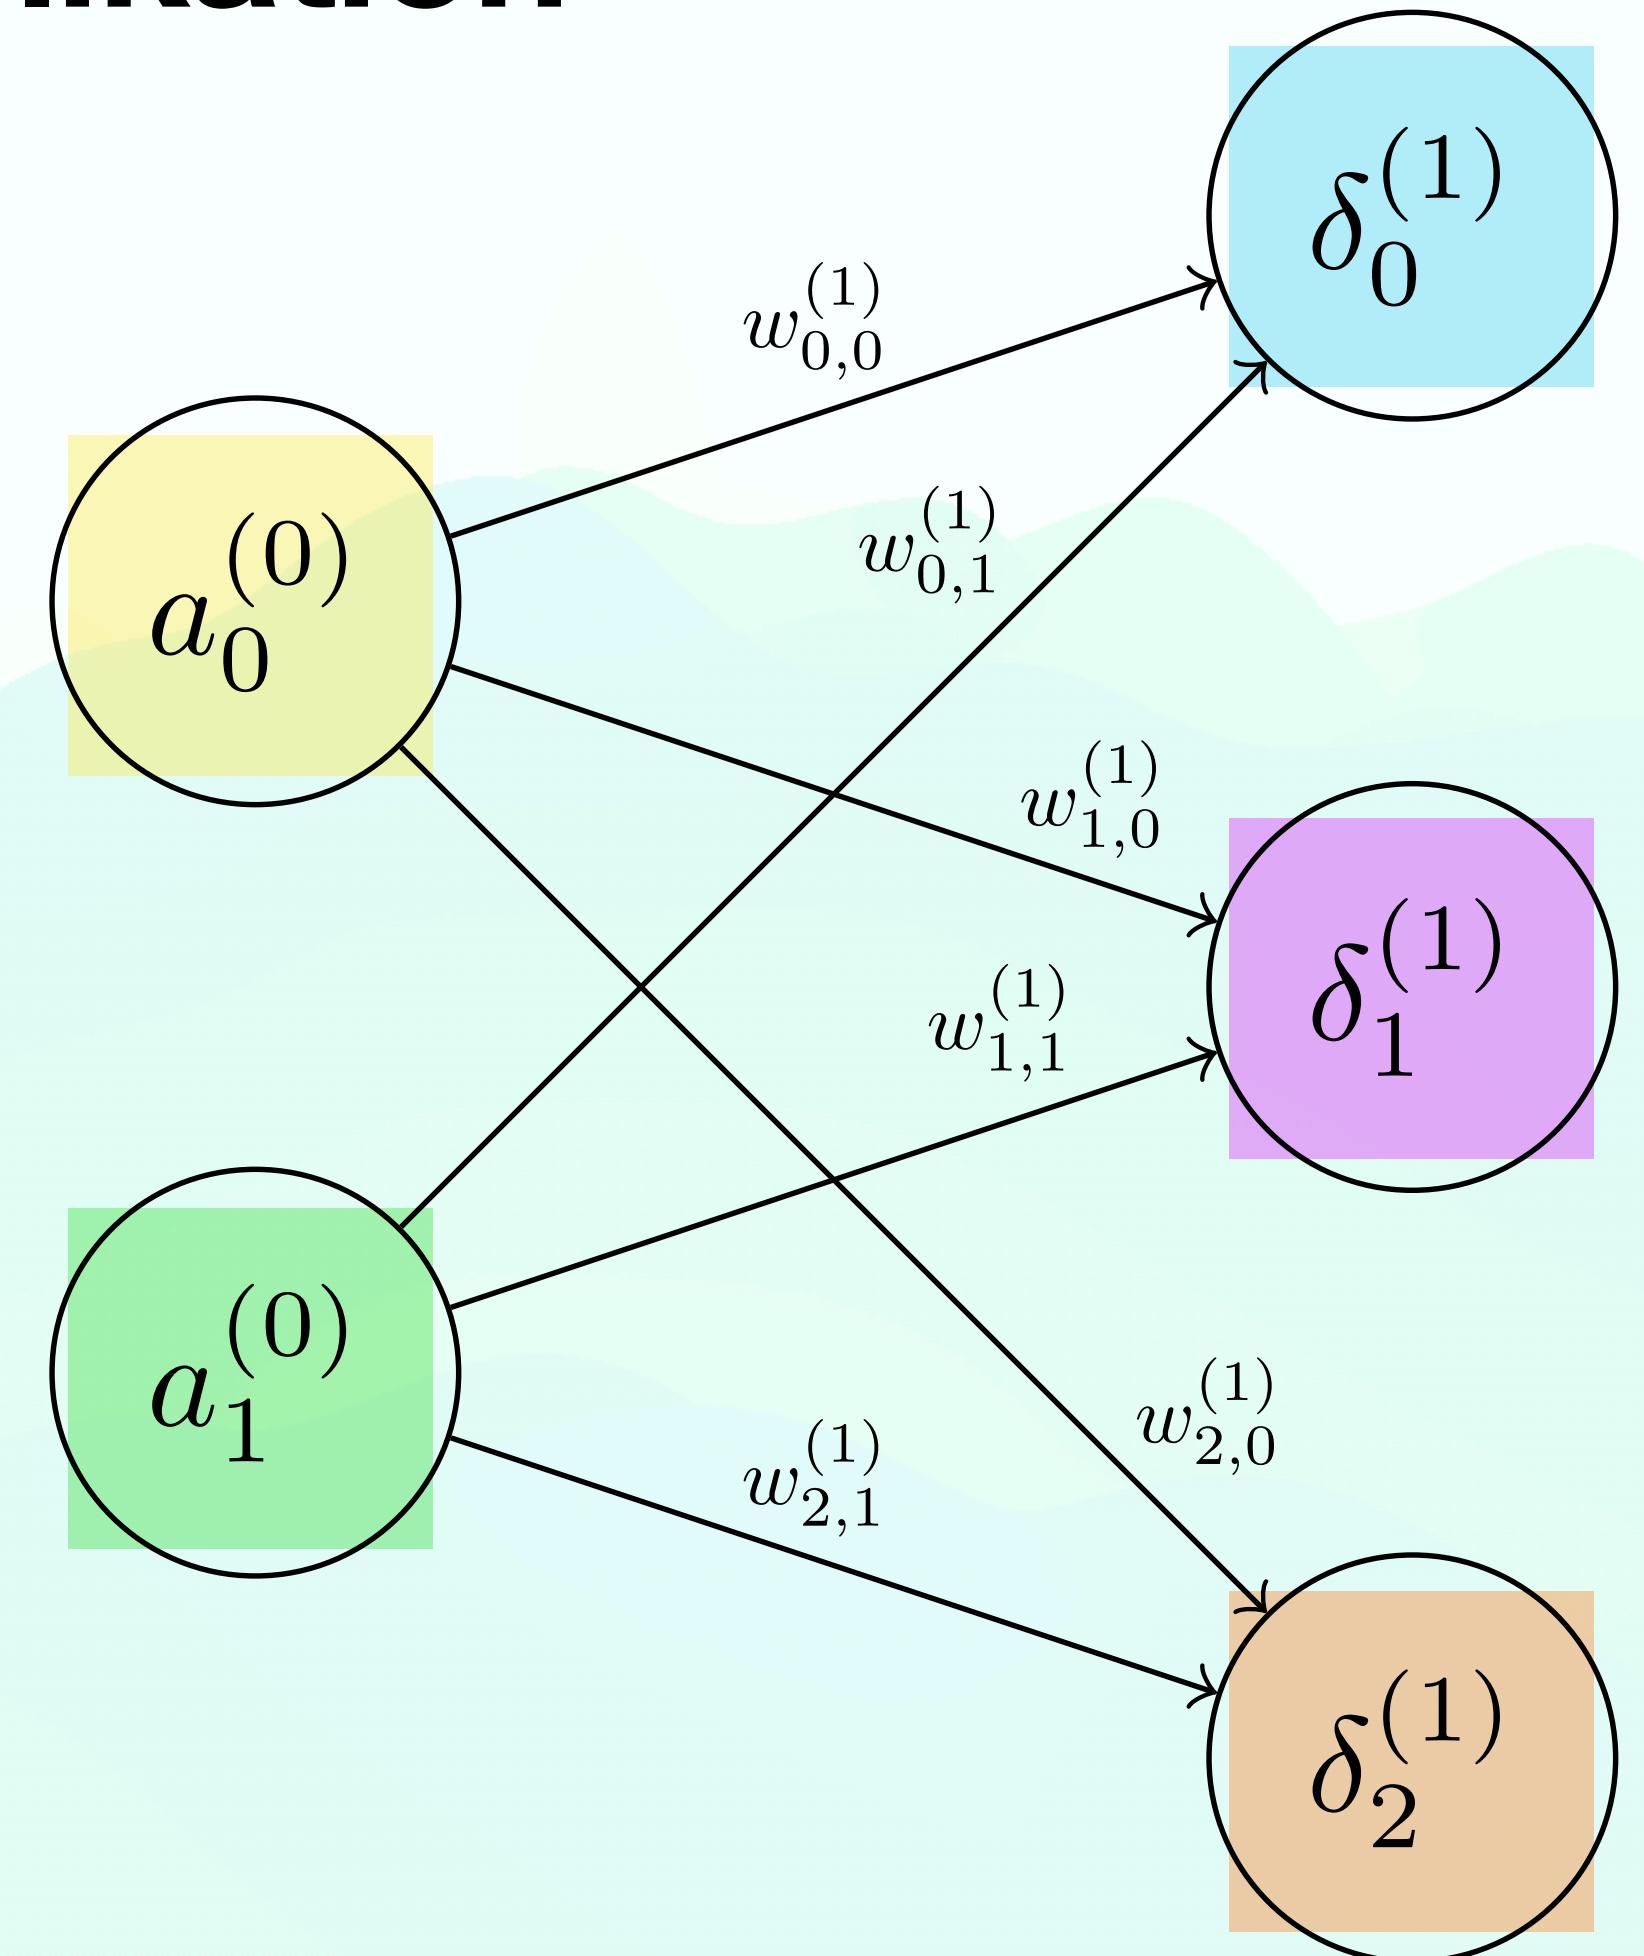
$$\Delta w_{1,0}^{(1)} = -\eta \cdot \delta_1^{(1)} \cdot a_0^{(0)}$$

$$\Delta w_{2,0}^{(1)} = -\eta \cdot \delta_2^{(1)} \cdot a_0^{(0)}$$

$$\Delta w_{0,1}^{(1)} = -\eta \cdot \delta_0^{(1)} \cdot a_1^{(0)}$$

$$\Delta w_{1,1}^{(1)} = -\eta \cdot \delta_1^{(1)} \cdot a_1^{(0)}$$

$$\Delta w_{2,1}^{(1)} = -\eta \cdot \delta_2^{(1)} \cdot a_1^{(0)}$$



# Anpassung der Gewichte als Matrixmultiplikation

$$\Delta w_{0,0}^{(1)} = -\eta \cdot \delta_0^{(1)} \cdot a_0^{(0)}$$

$$\Delta w_{0,1}^{(1)} = -\eta \cdot \delta_0^{(1)} \cdot a_1^{(0)}$$

$$\Delta w_{1,0}^{(1)} = -\eta \cdot \delta_1^{(1)} \cdot a_0^{(0)}$$

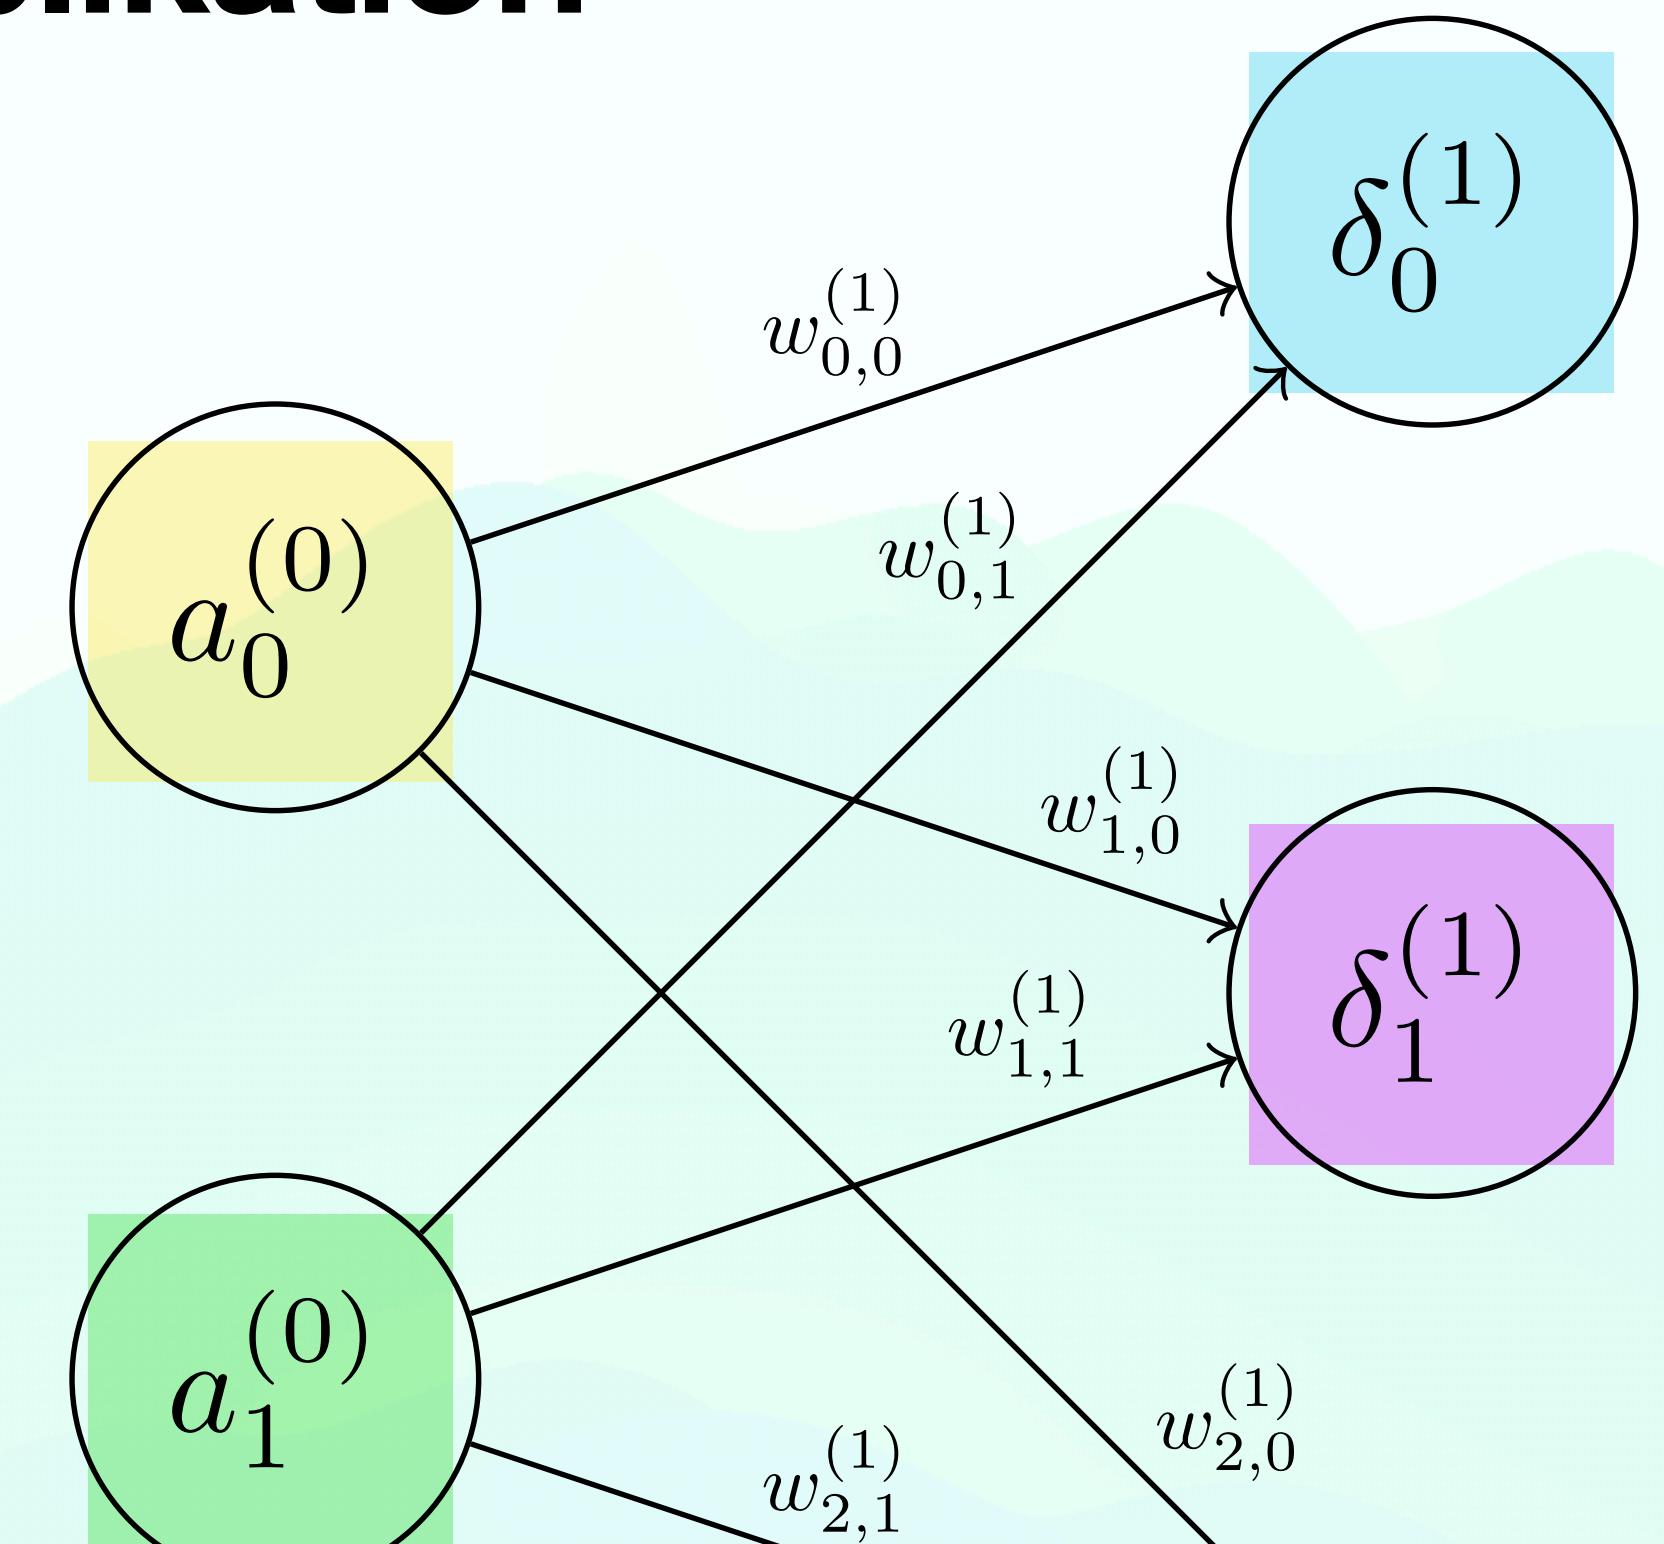
$$\Delta w_{1,1}^{(1)} = -\eta \cdot \delta_1^{(1)} \cdot a_1^{(0)}$$

$$\Delta w_{2,0}^{(1)} = -\eta \cdot \delta_2^{(1)} \cdot a_0^{(0)}$$

$$\Delta w_{2,1}^{(1)} = -\eta \cdot \delta_2^{(1)} \cdot a_1^{(0)}$$

Das erreichen wir, indem wir den Vektor mit den Deltas (**eine Spalte, drei Zeilen**) mit dem transponierten Vektor der Aktivierungen (**zwei Spalten, eine Zeile**) multiplizieren:

$$\Delta W^{(1)} = -\eta \cdot \left( \delta^{(1)} A^{(l-1)^T} \right) = -\eta \cdot \left[ \begin{pmatrix} \delta_0^{(1)} \\ \delta_1^{(1)} \\ \delta_2^{(1)} \end{pmatrix} \left( \begin{matrix} a_0^{(0)} & a_1^{(0)} \end{matrix} \right) \right]$$



# Anpassung der Gewichte als Matrixmultiplikation

$$\Delta w_{0,0}^{(1)} = -\eta \cdot \delta_0^{(1)} \cdot a_0^{(0)}$$

$$\Delta w_{0,1}^{(1)} = -\eta \cdot \delta_0^{(1)} \cdot a_1^{(0)}$$

$$\Delta w_{1,0}^{(1)} = -\eta \cdot \delta_1^{(1)} \cdot a_0^{(0)}$$

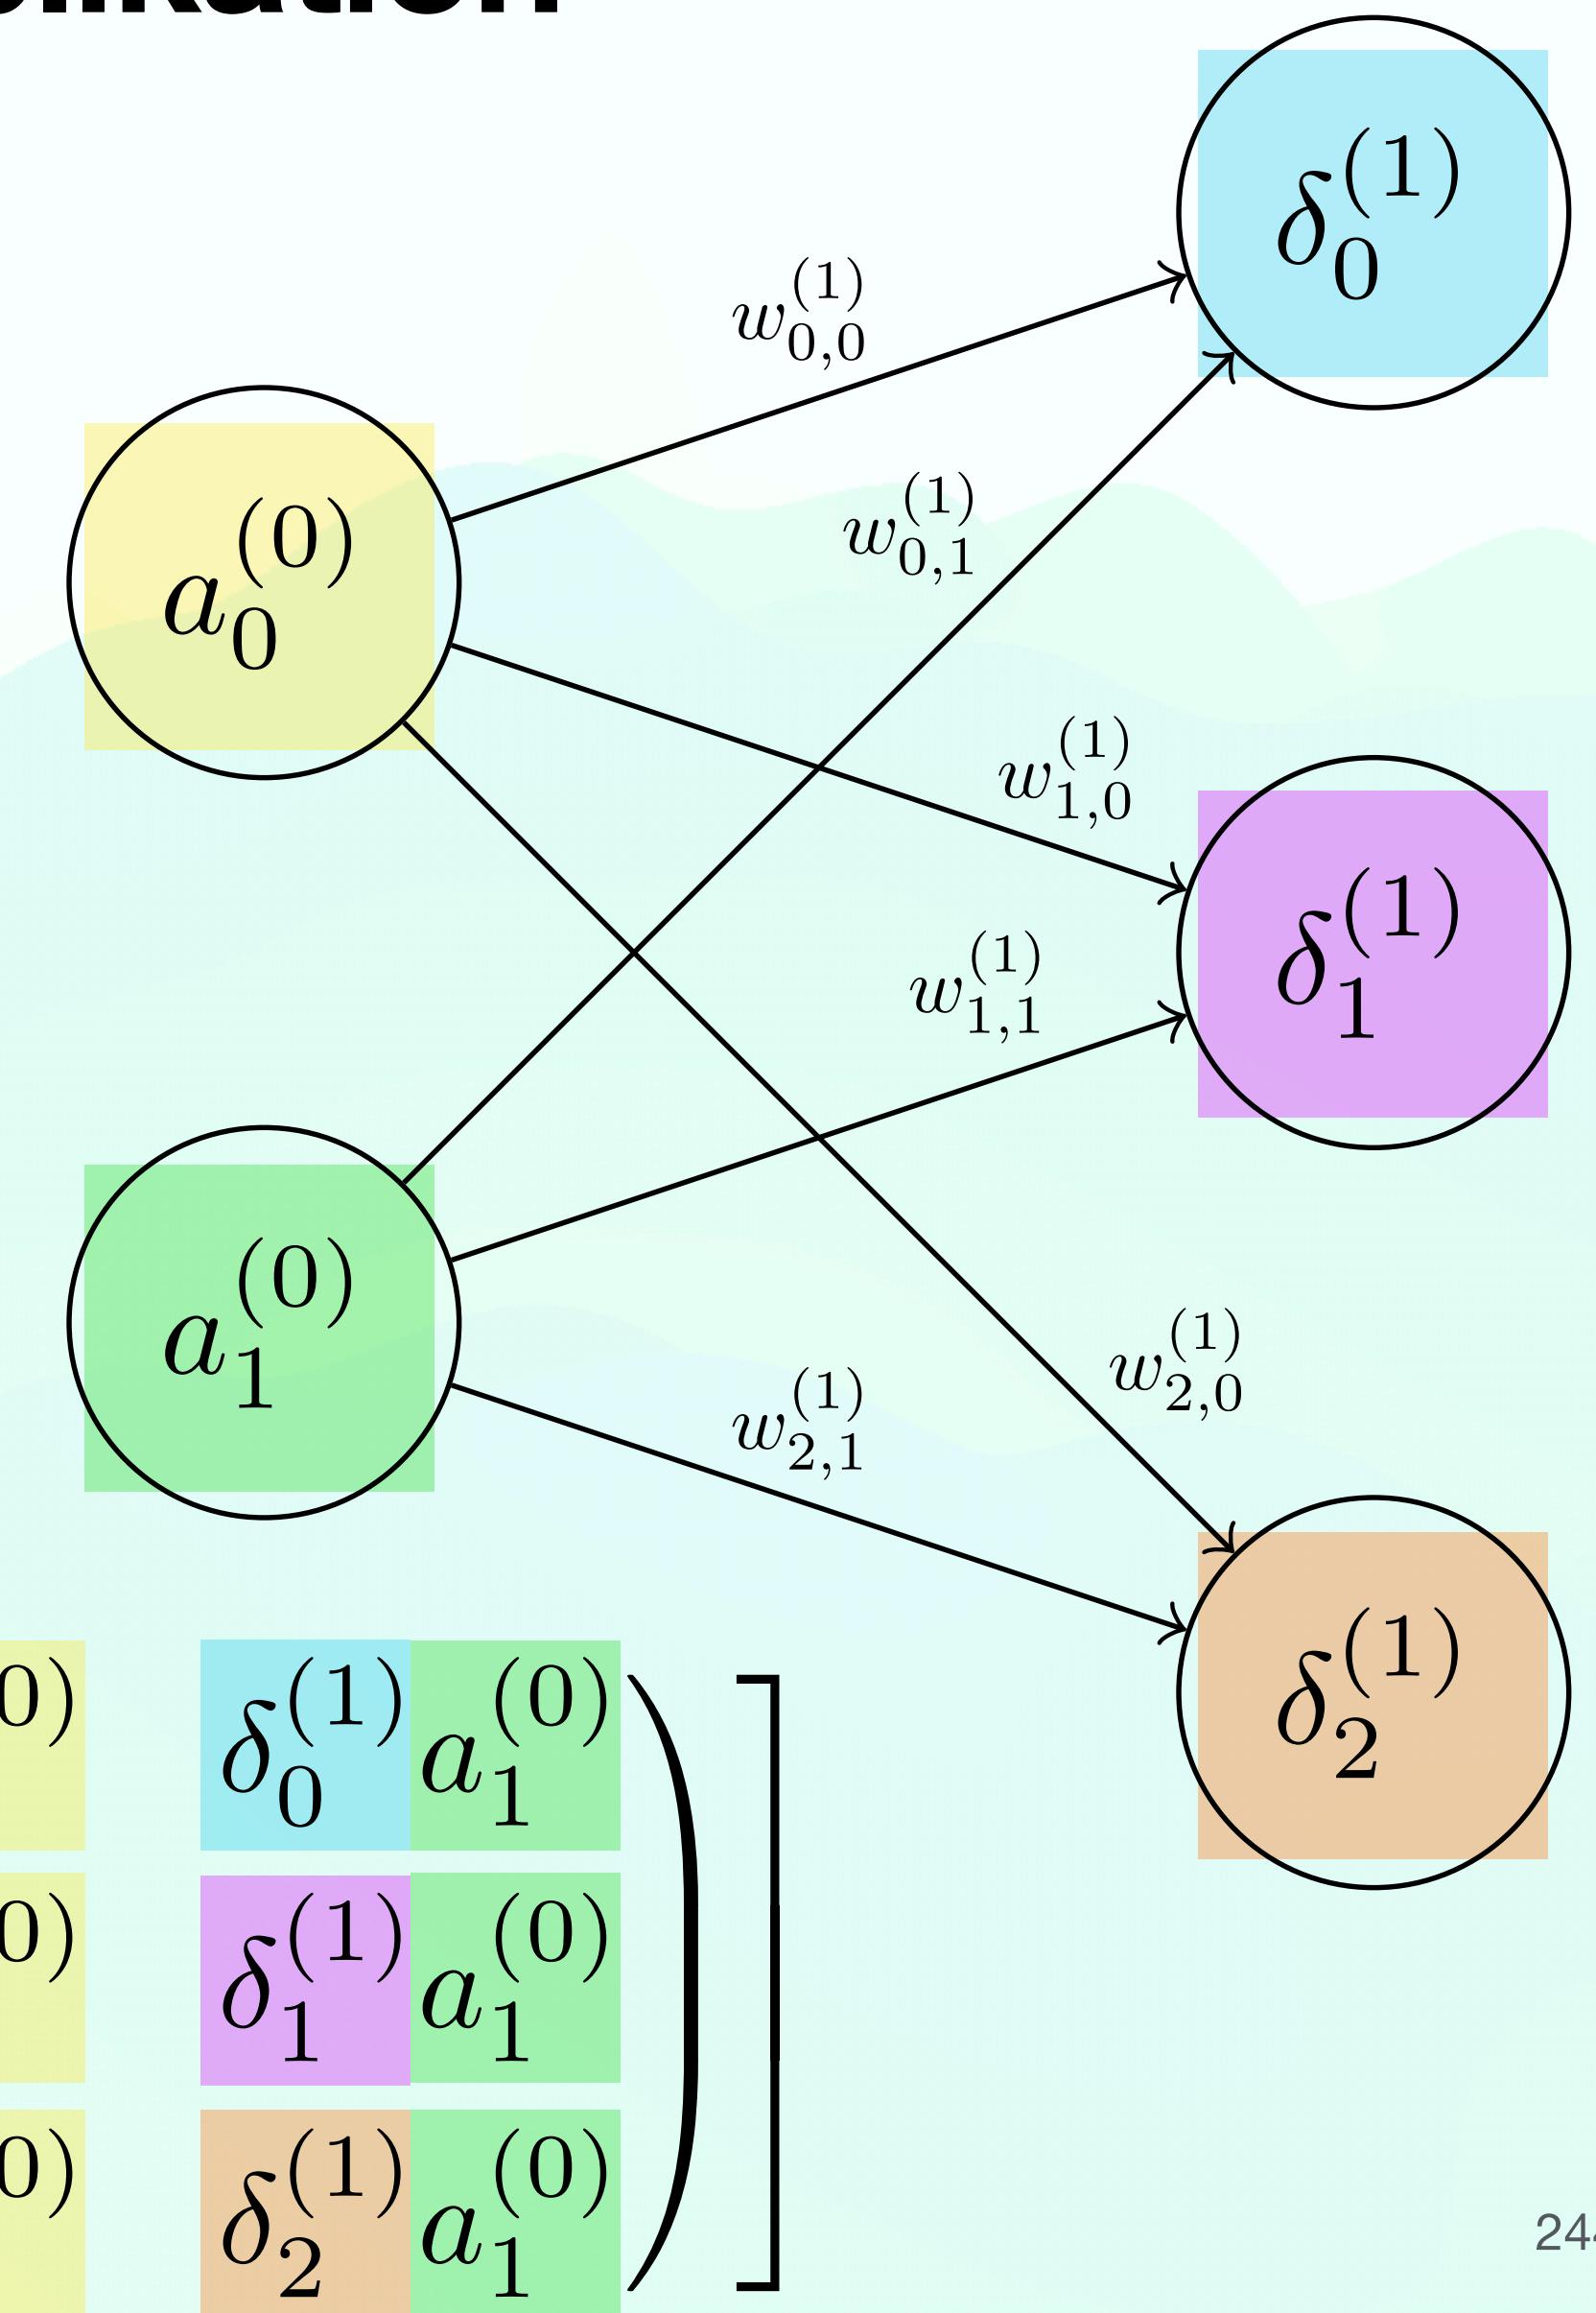
$$\Delta w_{1,1}^{(1)} = -\eta \cdot \delta_1^{(1)} \cdot a_1^{(0)}$$

$$\Delta w_{2,0}^{(1)} = -\eta \cdot \delta_2^{(1)} \cdot a_0^{(0)}$$

$$\Delta w_{2,1}^{(1)} = -\eta \cdot \delta_2^{(1)} \cdot a_1^{(0)}$$

Das erreichen wir, indem wir den Vektor mit den Deltas (**eine Spalte, drei Zeilen**) mit dem transponierten Vektor der Aktivierungen (**zwei Spalten, eine Zeile**) multiplizieren:

$$\Delta W^{(1)} = -\eta \cdot \left[ \begin{pmatrix} \delta_0^{(1)} \\ \delta_1^{(1)} \\ \delta_2^{(1)} \end{pmatrix} \left( \begin{matrix} a_0^{(0)} & a_1^{(0)} \end{matrix} \right) \right] = -\eta \cdot \left[ \begin{pmatrix} \delta_0^{(1)} & a_0^{(0)} \\ \delta_1^{(1)} & a_0^{(0)} \\ \delta_2^{(1)} & a_0^{(0)} \end{pmatrix} \left( \begin{matrix} \delta_0^{(1)} & a_1^{(0)} \\ \delta_1^{(1)} & a_1^{(0)} \\ \delta_2^{(1)} & a_1^{(0)} \end{matrix} \right) \right]$$



# Backpropagation-Algorithmus

$$\Delta w_{jk}^{(l)} = -\eta \cdot \delta_j^{(l)} \cdot a_k^{(l-1)}$$

8



```
# ...  
output_layer_derivative = 2 * error
```

```
for l in range(len(self.structure) - 1, 0, -1):  
    if l == len(self.structure) - 1:  
        partial_deltas[l][:] = output_layer_derivative * \  
            self.output_activation_func(self.weighted_sums[l], derivative=True)  
    else:  
        partial_deltas[l][:] = \  
            numpy.matmul(self.weights[l+1][:, 1:].T, partial_deltas[l+1]) * \  
            self.hidden_activation_func(self.weighted_sums[l], derivative=True)  
  
    delta_w[l][:] += -self.eta * numpy.matmul(partial_deltas[l], self.activations[l-1].T)
```

Das Ergebnis wird dann mit der Lernrate  $\eta$  multipliziert und bekommt ein negatives Vorzeichen, da wir uns in die Richtung des steilsten Gradientenabstiegs bewegen wollen.

# Backpropagation-Algorithmus

$$\Delta w_{jk}^{(l)} = -\eta \cdot \delta_j^{(l)} \cdot a_k^{(l-1)}$$

8

Ganz wichtig zu beachten: Wir wollen unsere gewünschten Gewichtsanpassungen der einzelnen Trainingsbeispiele zunächst nur aufsummieren und bilden später den Durchschnitt. Dafür benutzen wir die Python-Syntax `+=`. Wir weisen den Wert damit nicht direkt zu, sondern addieren ihn auf den bisherigen Wert auf.

```
# ...
output_layer_derivative = 2 * error

for l in range(len(self.structure) - 1, 0, -1):
    if l == len(self.structure) - 1:
        partial_deltas[l][:] = output_layer_derivative * \
            self.output_activation_func(self.weighted_sums[l], derivative=True)
    else:
        partial_deltas[l][:] = \
            numpy.matmul(self.weights[l+1][:, 1:].T, partial_deltas[l+1]) * \
            self.hidden_activation_func(self.weighted_sums[l], derivative=True)

    delta_w[l][:] += -self.eta * numpy.matmul(partial_deltas[l], self.activations[l-1].T)
```

# Backpropagation-Algorithmus



```
for i in range(self.n_iterations):
    for (X, Y) in training_data:
        # ...

    for l in range(1, len(delta_W)):
        self.weights[l][:] += delta_W[l] / len(training_data)
        delta_W[l][:] = 0
```

# Backpropagation-Algorithmus



```
for i in range(self.n_iterations):
    for (X, Y) in training_data:
        # ...

        for l in range(1, len(delta_W)):
            self.weights[l][:] += delta_W[l] / len(training_data)
            delta_W[l][:] = 0
```

Zum Schluss führen wir den eigentlichen Lernschritt durch und passen die Gewichte an. Dafür legen wir zunächst eine weitere `for`-Schleife durch alle Layer des Netzes an, und zwar nach dem Ende der Schleife, die durch alle Trainingsdatensätze iteriert ist. Beide Schleifen müssen also auf derselben Einrückungsebene liegen.

# Backpropagation-Algorithmus



```
for i in range(self.n_iterations):
    for (X, Y) in training_data:
        #

        for l in range(1, len(delta_W)):
            self.weights[l][:] += delta_W[l] / len(training_data)
            delta_W[l][:] = 0
```

Wir nehmen unsere Matrix mit den einzelnen, für jedes Trainingsbeispiel aufsummierten  $\Delta w$  im aktuellen Layer  $l$  und teilen sie durch die Anzahl der Trainingsbeispiele, um den Mittelwert zu berechnen. Eine Matrix geteilt durch eine Zahl ergibt in numpy praktischerweise wieder eine Matrix, in der jedes Element durch diese Zahl geteilt wurde.

# Backpropagation-Algorithmus



```
for i in range(self.n_iterations):
    for (X, Y) in training_data:
        # ...

    for l in range(1, len(delta_W)):
        self.weights[l][:] += delta_W[l] / len(training_data)
        delta_W[l][:] = 0
```

Zu beachten ist auch hier wieder die Syntax `+=`.

Wir wollen  $\Delta w$  auf die bestehenden Gewichte addieren, und sie nicht einfach überschreiben.

# Backpropagation-Algorithmus



```
for i in range(self.n_iterations):
    for (X, Y) in training_data:
        #

        for l in range(1, len(delta_W)):
            self.weights[l][:] += delta_W[l] / len(training_data)
            delta_W[l][:] = 0
```

Bevor die nächste Iteration der äußersten Schleife beginnt, müssen die  $\Delta w$  wieder auf 0 zurückgesetzt werden, da der hier aufsummierte Wert nur für die aktuelle Trainingsiteration gilt.

# Damit ist unser neuronales Netz einsatzbereit!

Jetzt müssen wir nur noch eine Aufgabe dafür finden ...

# Das neuronale Netz trainieren

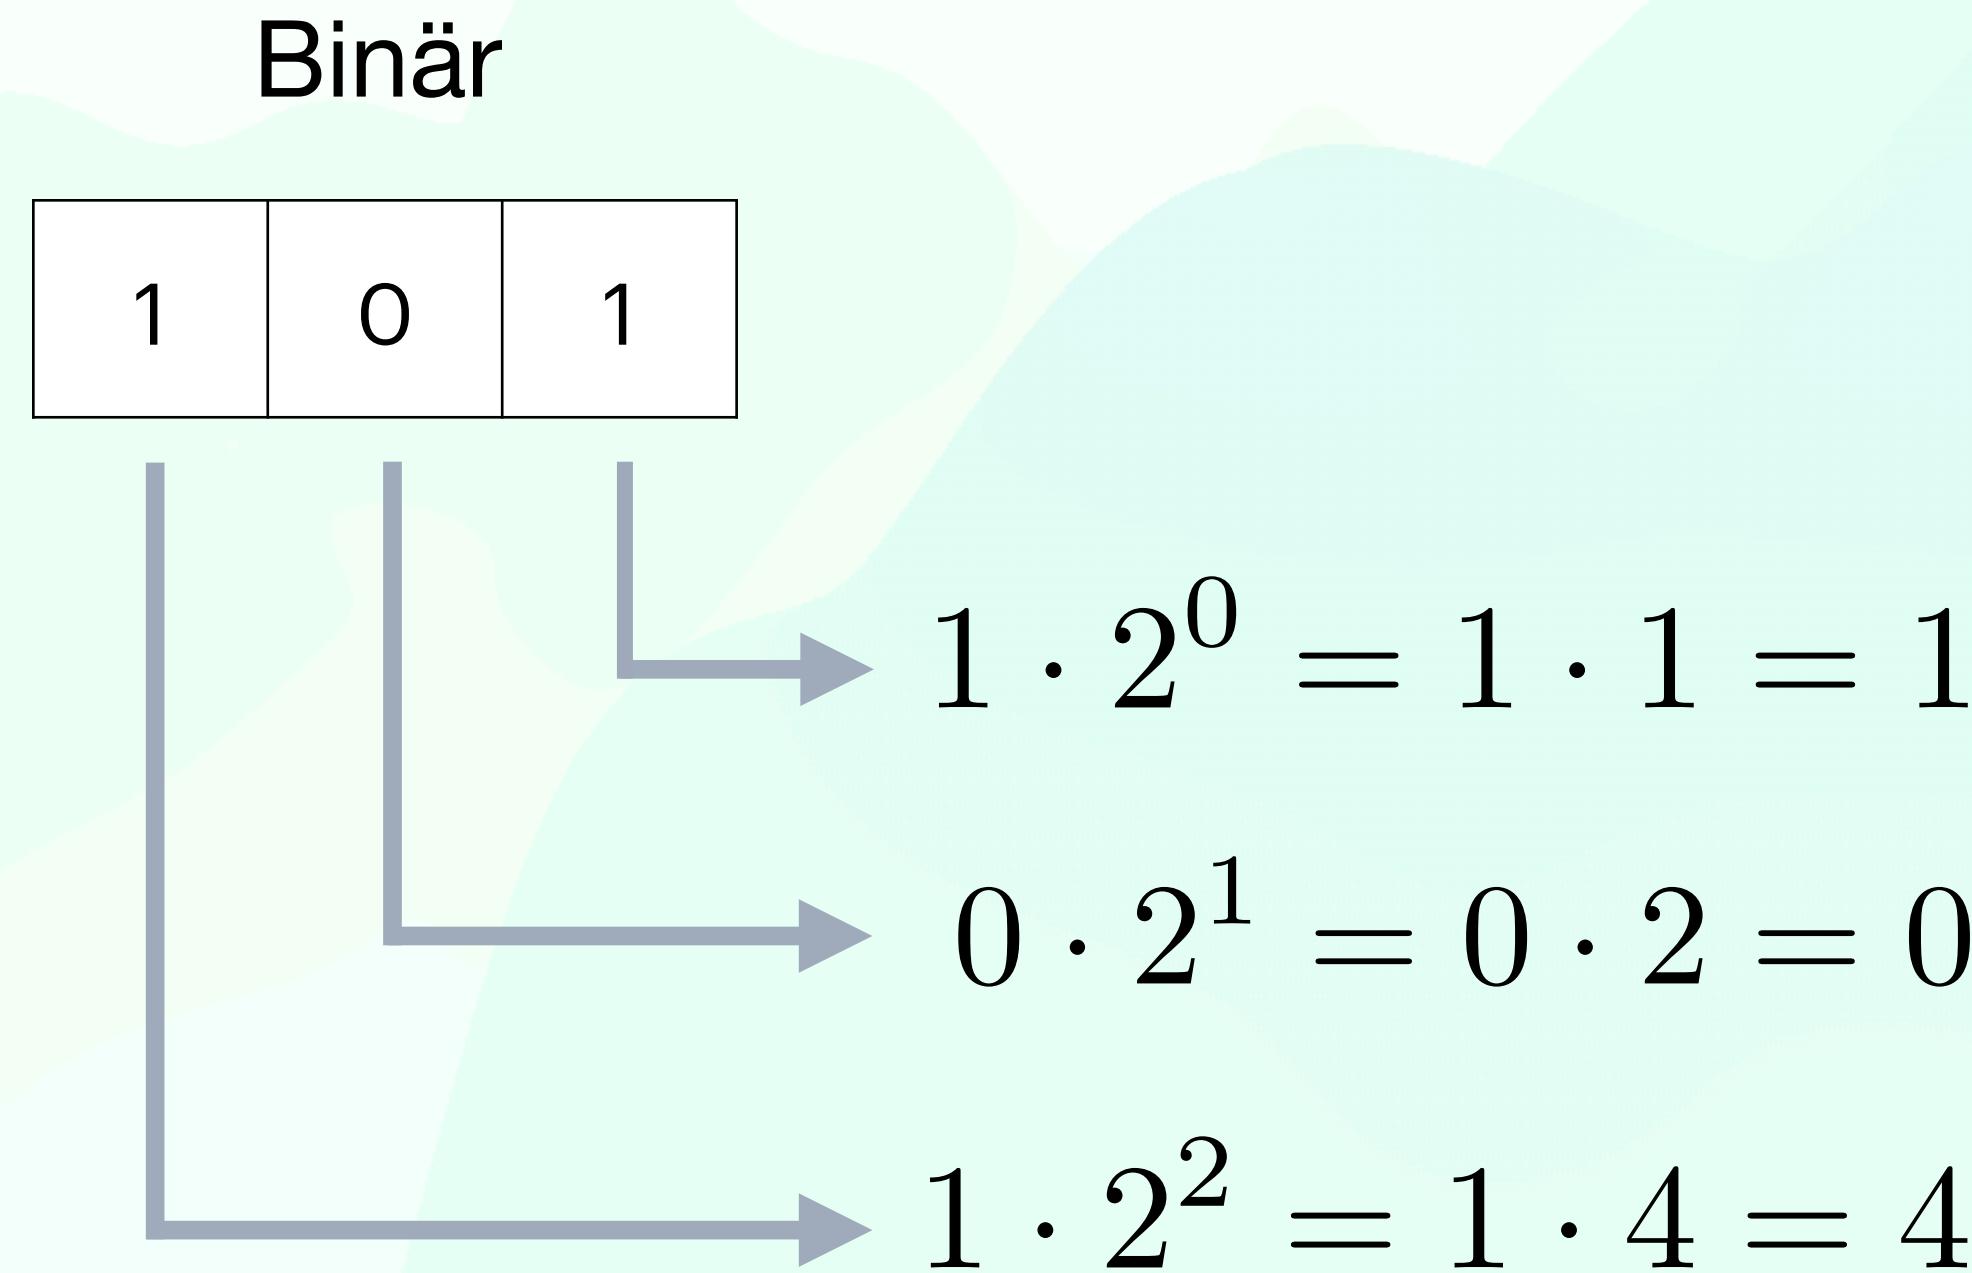
- Unser neuronales Netz soll lernen, dreistellige Binärzahlen in Dezimalzahlen umzuwandeln

# Das neuronale Netz trainieren

- Unser neuronales Netz soll lernen, dreistellige Binärzahlen in Dezimalzahlen umzuwandeln
- Binärzahlen bestehen nur aus den Ziffern 0 und 1, diese können direkt als Input-Aktivierungen verwendet werden

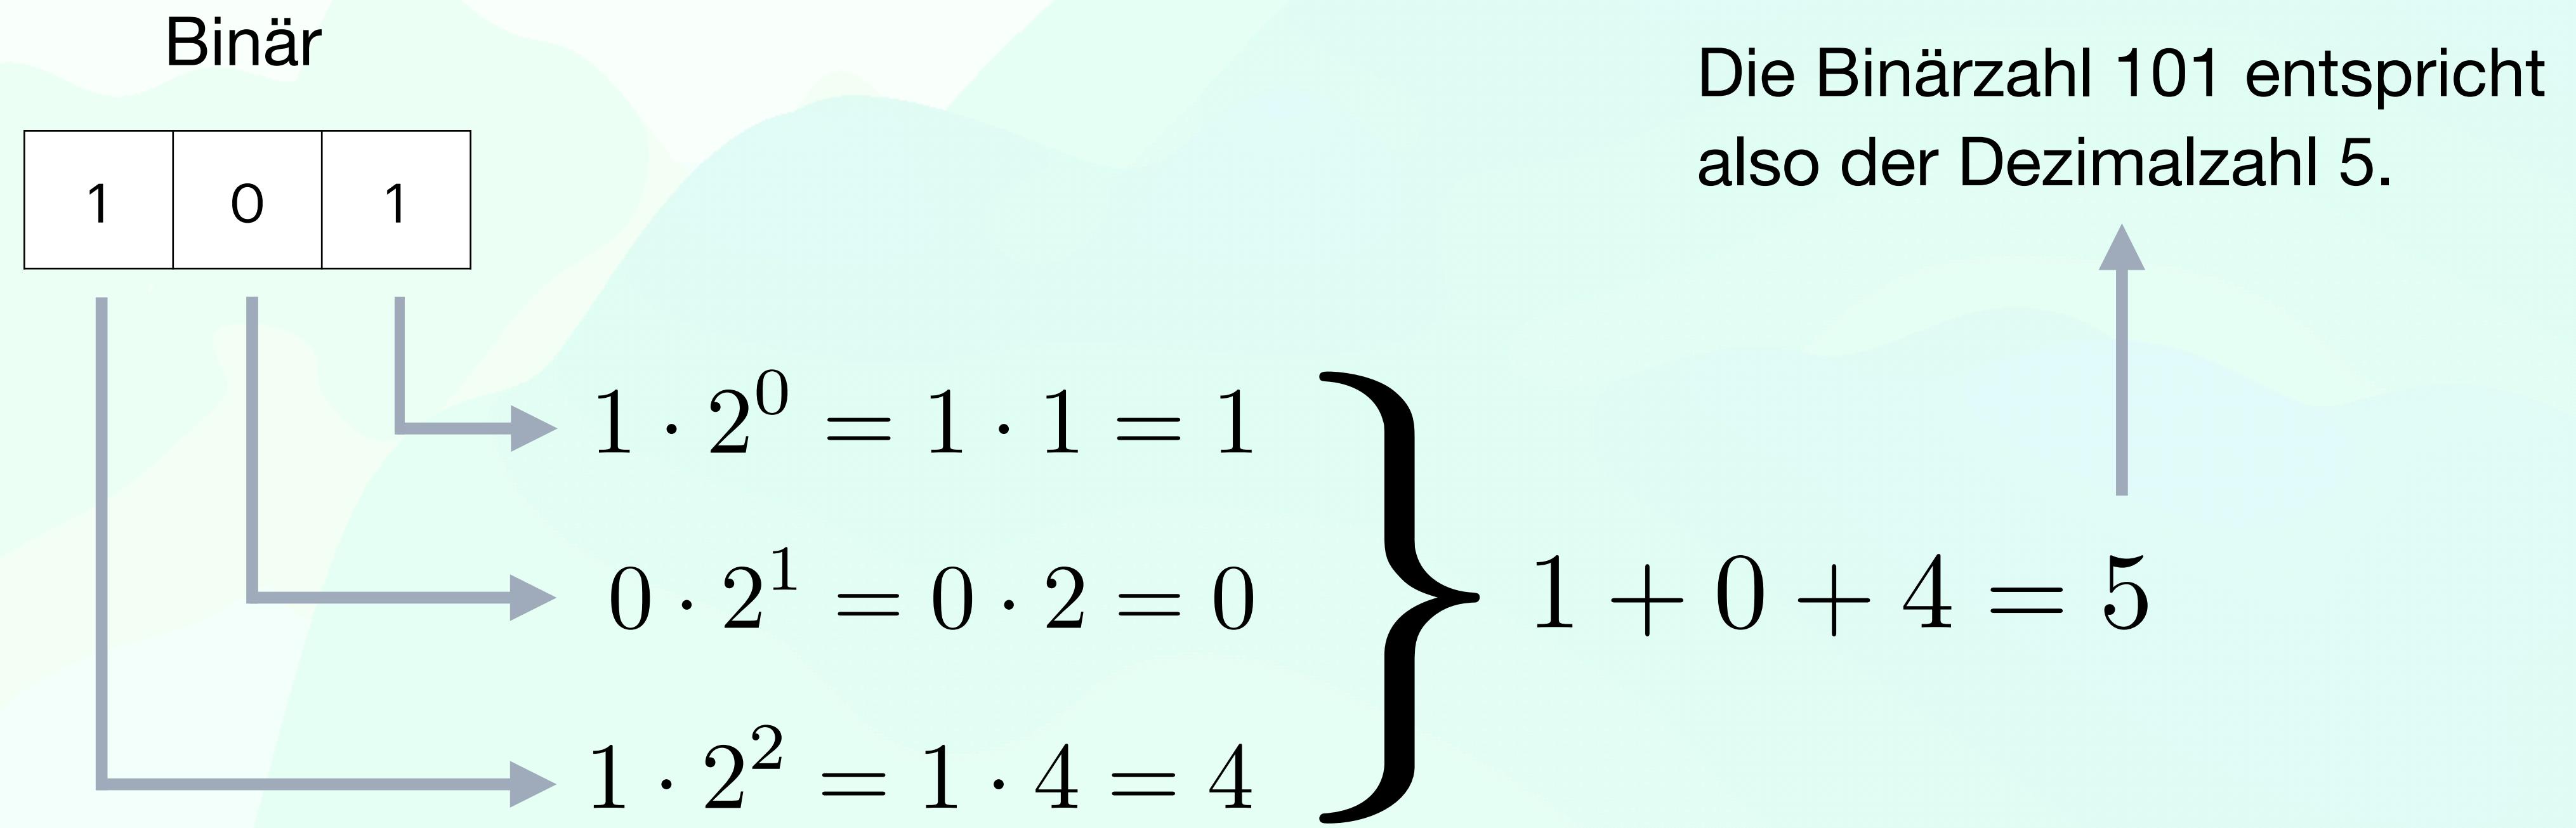
# Das neuronale Netz trainieren

- Unser neuronales Netz soll lernen, dreistellige Binärzahlen in Dezimalzahlen umzuwandeln
- Binärzahlen bestehen nur aus den Ziffern 0 und 1, diese können direkt als Input-Aktivierungen verwendet werden



# Das neuronale Netz trainieren

- Unser neuronales Netz soll lernen, dreistellige Binärzahlen in Dezimalzahlen umzuwandeln
- Binärzahlen bestehen nur aus den Ziffern 0 und 1, diese können direkt als Input-Aktivierungen verwendet werden



# Das neuronale Netz trainieren

- Auf dieselbe Weise können wir alle acht dreistelligen Binärzahlen in ihre Dezimaldarstellung umwandeln:

Binär	Dezimal
000	0
001	1
010	2
011	3
100	4
101	5
110	6
111	7

# Das neuronale Netz trainieren

- Auf dieselbe Weise können wir alle acht dreistelligen Binärzahlen in ihre Dezimaldarstellung umwandeln:

Binär	Dezimal
000	0
001	1
010	2
011	3
100	4
101	5
110	6
111	7

Dies wird der Trainingsdatensatz für unser neuronales Netz sein.

**Aber:** Eine Zahl werden wir im Training bewusst weglassen – in der Hoffnung, dass unser Netz sie trotzdem lernt!

# Das neuronale Netz trainieren

- Auf dieselbe Weise können wir alle acht dreistelligen Binärzahlen in ihre Dezimaldarstellung umwandeln:

Binär	Dezimal
000	0
001	1
010	2
011	3
100	4
101	5
110	6
111	7

Dies wird der Trainingsdatensatz für unser neuronales Netz sein.

**Aber:** Eine Zahl werden wir im Training bewusst weglassen – in der Hoffnung, dass unser Netz sie trotzdem lernt!

Es handelt sich um ein **Regressionsproblem**. Wir brauchen im **Input-Layer** drei Neuronen und im **Output-Layer eins**.

Mit der Anzahl der Hidden Layer und ihrer Neuronen experimentieren wir.

# Binärumwandlung trainieren

```
● ● ●

if __name__ == '__main__':
    nn = NeuralNetwork(
        structure=[3, 4, 1],
        eta=0.01,
        n_iterations=3000,
        output_activation_func=relu,
        hidden_activation_func=relu
    )

    training_data = [
        (numpy.array([[0], [0], [0]]), numpy.array([[0]])),
        (numpy.array([[0], [0], [1]]), numpy.array([[1]])),
        (numpy.array([[0], [1], [0]]), numpy.array([[2]])),
        (numpy.array([[0], [1], [1]]), numpy.array([[3]])),
        (numpy.array([[1], [0], [0]]), numpy.array([[4]])),
        (numpy.array([[1], [1], [0]]), numpy.array([[6]])),
        (numpy.array([[1], [1], [1]]), numpy.array([[7]])),
    ]
    nn.train(training_data)
    input = numpy.array([[1], [0], [1]])
    prediction = nn.predict(input)

    print("Vorhersage für unbekannten Input", input, ":", prediction[0, 0])

    for X, _ in training_data:
        output = nn.predict(X)
        print("Vorhersage für bekannten Input", X, ":", output[0, 0])
```

Wir ersetzen unseren bestehenden Hauptprogrammblock durch die Konfiguration und das Training eines `NeuralNetwork`-Objekts mit unserem Binärzahlen-Datensatz.

# Binärumwandlung trainieren

```
● ● ●

if __name__ == '__main__':
    nn = NeuralNetwork(
        structure=[3, 4, 1],
        eta=0.01,
        n_iterations=3000,
        output_activation_func=relu,
        hidden_activation_func=relu
    )

    training_data = [
        (numpy.array([[0], [0], [0]]), numpy.array([[0]])),
        (numpy.array([[0], [0], [1]]), numpy.array([[1]])),
        (numpy.array([[0], [1], [0]]), numpy.array([[2]])),
        (numpy.array([[0], [1], [1]]), numpy.array([[3]])),
        (numpy.array([[1], [0], [0]]), numpy.array([[4]])),
        (numpy.array([[1], [1], [0]]), numpy.array([[6]])),
        (numpy.array([[1], [1], [1]]), numpy.array([[7]])),
    ]
    nn.train(training_data)
    input = numpy.array([[1], [0], [1]])
    prediction = nn.predict(input)

    print("Vorhersage für unbekannten Input", input, ":", prediction[0, 0])

    for X, _ in training_data:
        output = nn.predict(X)
        print("Vorhersage für bekannten Input", X, ":", output[0, 0])
```

Unser Netzwerk erzeugen wir anfangs mit nur einem Hidden Layer mit vier Neuronen. Sowohl Hidden als auch Output-Layer sollen als Aktivierungsfunktionen jeweils ReLU verwenden. Als Lernrate verwenden wir 0,01 und führen 3.000 Trainings-Iterationen durch.

# Binärumwandlung trainieren

```
● ● ●

if __name__ == '__main__':
    nn = NeuralNetwork(
        structure=[3, 4, 1],
        eta=0.01,
        n_iterations=3000,
        output_activation_func=relu,
        hidden_activation_func=relu
    )

    training_data = [
        (numpy.array([[0], [0], [0]]), numpy.array([[0]])),
        (numpy.array([[0], [0], [1]]), numpy.array([[1]])),
        (numpy.array([[0], [1], [0]]), numpy.array([[2]])),
        (numpy.array([[0], [1], [1]]), numpy.array([[3]])),
        (numpy.array([[1], [0], [0]]), numpy.array([[4]])),
        (numpy.array([[1], [1], [0]]), numpy.array([[6]])),
        (numpy.array([[1], [1], [1]]), numpy.array([[7]])),
    ]
    nn.train(training_data)
    input = numpy.array([[1], [0], [1]])
    prediction = nn.predict(input)

    print("Vorhersage für unbekannten Input", input, ":", prediction[0, 0])

    for X, _ in training_data:
        output = nn.predict(X)
        print("Vorhersage für bekannten Input", X, ":", output[0, 0])
```

Dann definieren wir unseren Trainingsdatensatz. Er ist eine Liste von Tupeln, die jeweils aus Input- und erwarteten Output-Aktivierungen besteht. Die Binärdarstellung der Zahl 5 (101) lassen wir dabei weg.

# Binärumwandlung trainieren

```
● ● ●

if __name__ == '__main__':
    nn = NeuralNetwork(
        structure=[3, 4, 1],
        eta=0.01,
        n_iterations=3000,
        output_activation_func=relu,
        hidden_activation_func=relu
    )

    training_data = [
        (numpy.array([[0], [0], [0]]), numpy.array([[0]])),
        (numpy.array([[0], [0], [1]]), numpy.array([[1]])),
        (numpy.array([[0], [1], [0]]), numpy.array([[2]])),
        (numpy.array([[0], [1], [1]]), numpy.array([[3]])),
        (numpy.array([[1], [0], [0]]), numpy.array([[4]])),
        (numpy.array([[1], [1], [0]]), numpy.array([[6]])),
        (numpy.array([[1], [1], [1]]), numpy.array([[7]])),
    ]
    nn.train(training_data)
    input = numpy.array([[1], [0], [1]])
    prediction = nn.predict(input)

    print("Vorhersage für unbekannten Input", input, ":", prediction[0, 0])

    for X, _ in training_data:
        output = nn.predict(X)
        print("Vorhersage für bekannten Input", X, ":", output[0, 0])
```

Wir müssen die Listen jeweils zweidimensional übergeben, damit numpy eindeutige Informationen über die Form der Vektoren hat. `numpy.array` erzeugt eine Matrix und erwartet die Elemente zeilenweise. Unser Netzwerk erwartet die Input- und Output-Vektoren als Zeilenvektoren.

# Binärumwandlung trainieren

```
● ● ●

if __name__ == '__main__':
    nn = NeuralNetwork(
        structure=[3, 4, 1],
        eta=0.01,
        n_iterations=3000,
        output_activation_func=relu,
        hidden_activation_func=relu
    )

    training_data = [
        (numpy.array([[0], [0], [0]]), numpy.array([[0]])),
        (numpy.array([[0], [0], [1]]), numpy.array([[1]])),
        (numpy.array([[0], [1], [0]]), numpy.array([[2]])),
        (numpy.array([[0], [1], [1]]), numpy.array([[3]])),
        (numpy.array([[1], [0], [0]]), numpy.array([[4]])),
        (numpy.array([[1], [1], [0]]), numpy.array([[6]])),
        (numpy.array([[1], [1], [1]]), numpy.array([[7]])),
    ]
    nn.train(training_data)
    input = numpy.array([[1], [0], [1]])
    prediction = nn.predict(input)

    print("Vorhersage für unbekannten Input", input, ":", prediction[0, 0])

    for X, _ in training_data:
        output = nn.predict(X)
        print("Vorhersage für bekannten Input", X, ":", output[0, 0])
```

Mit dem Trainingsdatensatz können wir unsere soeben implementierte **fit**-Methode aufrufen und damit das eigentliche Training durchführen.

# Binärumwandlung trainieren

```
● ● ●

if __name__ == '__main__':
    nn = NeuralNetwork(
        structure=[3, 4, 1],
        eta=0.01,
        n_iterations=3000,
        output_activation_func=relu,
        hidden_activation_func=relu
    )

    training_data = [
        (numpy.array([[0], [0], [0]]), numpy.array([[0]])),
        (numpy.array([[0], [0], [1]]), numpy.array([[1]])),
        (numpy.array([[0], [1], [0]]), numpy.array([[2]])),
        (numpy.array([[0], [1], [1]]), numpy.array([[3]])),
        (numpy.array([[1], [0], [0]]), numpy.array([[4]])),
        (numpy.array([[1], [1], [0]]), numpy.array([[6]])),
        (numpy.array([[1], [1], [1]]), numpy.array([[7]])),
    ]
    nn.train(training_data)
    input = numpy.array([[1], [0], [1]])
    prediction = nn.predict(input)

    print("Vorhersage für unbekannten Input", input, ":", prediction[0, 0])

    for X, _ in training_data:
        output = nn.predict(X)
        print("Vorhersage für bekannten Input", X, ":", output[0, 0])
```

Wir erzeugen einen Input-Datensatz  
für unsere in den Trainingsdaten  
fehlende Binärkombination ...

# Binärumwandlung trainieren

```
● ● ●
```

```
if __name__ == '__main__':
    nn = NeuralNetwork(
        structure=[3, 4, 1],
        eta=0.01,
        n_iterations=3000,
        output_activation_func=relu,
        hidden_activation_func=relu
    )
```

```
training_data = [
    (numpy.array([[0], [0], [0]]), numpy.array([[0]])),
    (numpy.array([[0], [0], [1]]), numpy.array([[1]])),
    (numpy.array([[0], [1], [0]]), numpy.array([[2]])),
    (numpy.array([[0], [1], [1]]), numpy.array([[3]])),
    (numpy.array([[1], [0], [0]]), numpy.array([[4]])),
    (numpy.array([[1], [1], [0]]), numpy.array([[6]])),
    (numpy.array([[1], [1], [1]]), numpy.array([[7]])),
]
```

```
nn.train(training_data)
input = numpy.array([[1], [0], [1]])
prediction = nn.predict(input)
```

```
print("Vorhersage für unbekannten Input", input, ":", prediction[0, 0])
```

```
for X, _ in training_data:
    output = nn.predict(X)
    print("Vorhersage für bekannten Input", X, ":", output[0, 0])
```

... und lassen unser frisch  
trainiertes Netz eine  
Vorhersage dafür treffen.

# Binärumwandlung trainieren

```
● ● ●

if __name__ == '__main__':
    nn = NeuralNetwork(
        structure=[3, 4, 1],
        eta=0.01,
        n_iterations=3000,
        output_activation_func=relu,
        hidden_activation_func=relu
    )

    training_data = [
        (numpy.array([[0], [0], [0]]), numpy.array([[0]])),
        (numpy.array([[0], [0], [1]]), numpy.array([[1]])),
        (numpy.array([[0], [1], [0]]), numpy.array([[2]])),
        (numpy.array([[0], [1], [1]]), numpy.array([[3]])),
        (numpy.array([[1], [0], [0]]), numpy.array([[4]])),
        (numpy.array([[1], [1], [0]]), numpy.array([[6]])),
        (numpy.array([[1], [1], [1]]), numpy.array([[7]])),
    ]
    nn.train(training_data)
    input = numpy.array([[1], [0], [1]])
    prediction = nn.predict(input)

    print("Vorhersage für unbekannten Input", input, ":", prediction[0, 0])

    for X, _ in training_data:
        output = nn.predict(X)
        print("Vorhersage für bekannten Input", X, ":", output[0, 0])
```

Diese Vorhersage geben wir auf der Konsole aus.

# Binärumwandlung trainieren

```
● ● ●

if __name__ == '__main__':
    nn = NeuralNetwork(
        structure=[3, 4, 1],
        eta=0.01,
        n_iterations=3000,
        output_activation_func=relu,
        hidden_activation_func=relu
    )

    training_data = [
        (numpy.array([[0], [0], [0]]), numpy.array([[0]])),
        (numpy.array([[0], [0], [1]]), numpy.array([[1]])),
        (numpy.array([[0], [1], [0]]), numpy.array([[2]])),
        (numpy.array([[0], [1], [1]]), numpy.array([[3]])),
        (numpy.array([[1], [0], [0]]), numpy.array([[4]])),
        (numpy.array([[1], [1], [0]]), numpy.array([[6]])),
        (numpy.array([[1], [1], [1]]), numpy.array([[7]])),
    ]
    nn.train(training_data)
    input = numpy.array([[1], [0], [1]])
    prediction = nn.predict(input)

    print("Vorhersage für unbekannten Input", input, ":", prediction[0, 0])

    for X, _ in training_data:
        output = nn.predict(X)
        print("Vorhersage für bekannten Input", X, ":", output[0, 0])
```

Auf dieselbe Weise erzeugen wir auch für die dem Netz bereits bekannten Input-Kombinationen Vorhersagen und geben sie auf der Konsole aus.

# Fragen

1. Warum hat die Aktivierungsfunktion ReLU ein „Dying-Neuron-Problem“ und wie kann man es lösen?
2. Was ist Overfitting?
3. Warum verwendet man in einem neuronalen Netz Aktivierungsfunktionen und benutzt nicht einfach die gewichtete Summe als Aktivierung?

# Softmax für Klassifikationsnetzwerke

- Hilfreich für Klassifikation: Outputs als Wahrscheinlichkeiten interpretierbar
- Sigmoid liefert zwar Werte zwischen 0 und 1, aber ihre Summe ergibt nicht 1

# Softmax für Klassifikationsnetzwerke

- Hilfreich für Klassifikation: Outputs als Wahrscheinlichkeiten interpretierbar
- Sigmoid liefert zwar Werte zwischen 0 und 1, aber ihre Summe ergibt nicht 1
- Lösung: **Softmax** als Aktivierungsfunktion im Output-Layer
- Sei  $n^{(l)}$  die Anzahl der Neuronen in Layer  $l$ :

$$a_i^{(l)} = \text{softmax}\left(z_i^{(l)}\right) = \frac{e^{z_i^{(l)}}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}}$$

# Softmax für Klassifikationsnetzwerke

- Hilfreich für Klassifikation: Outputs als Wahrscheinlichkeiten interpretierbar
- Sigmoid liefert zwar Werte zwischen 0 und 1, aber ihre Summe ergibt nicht 1
- Lösung: **Softmax** als Aktivierungsfunktion im Output-Layer
- Sei  $n^{(l)}$  die Anzahl der Neuronen in Layer  $l$ :

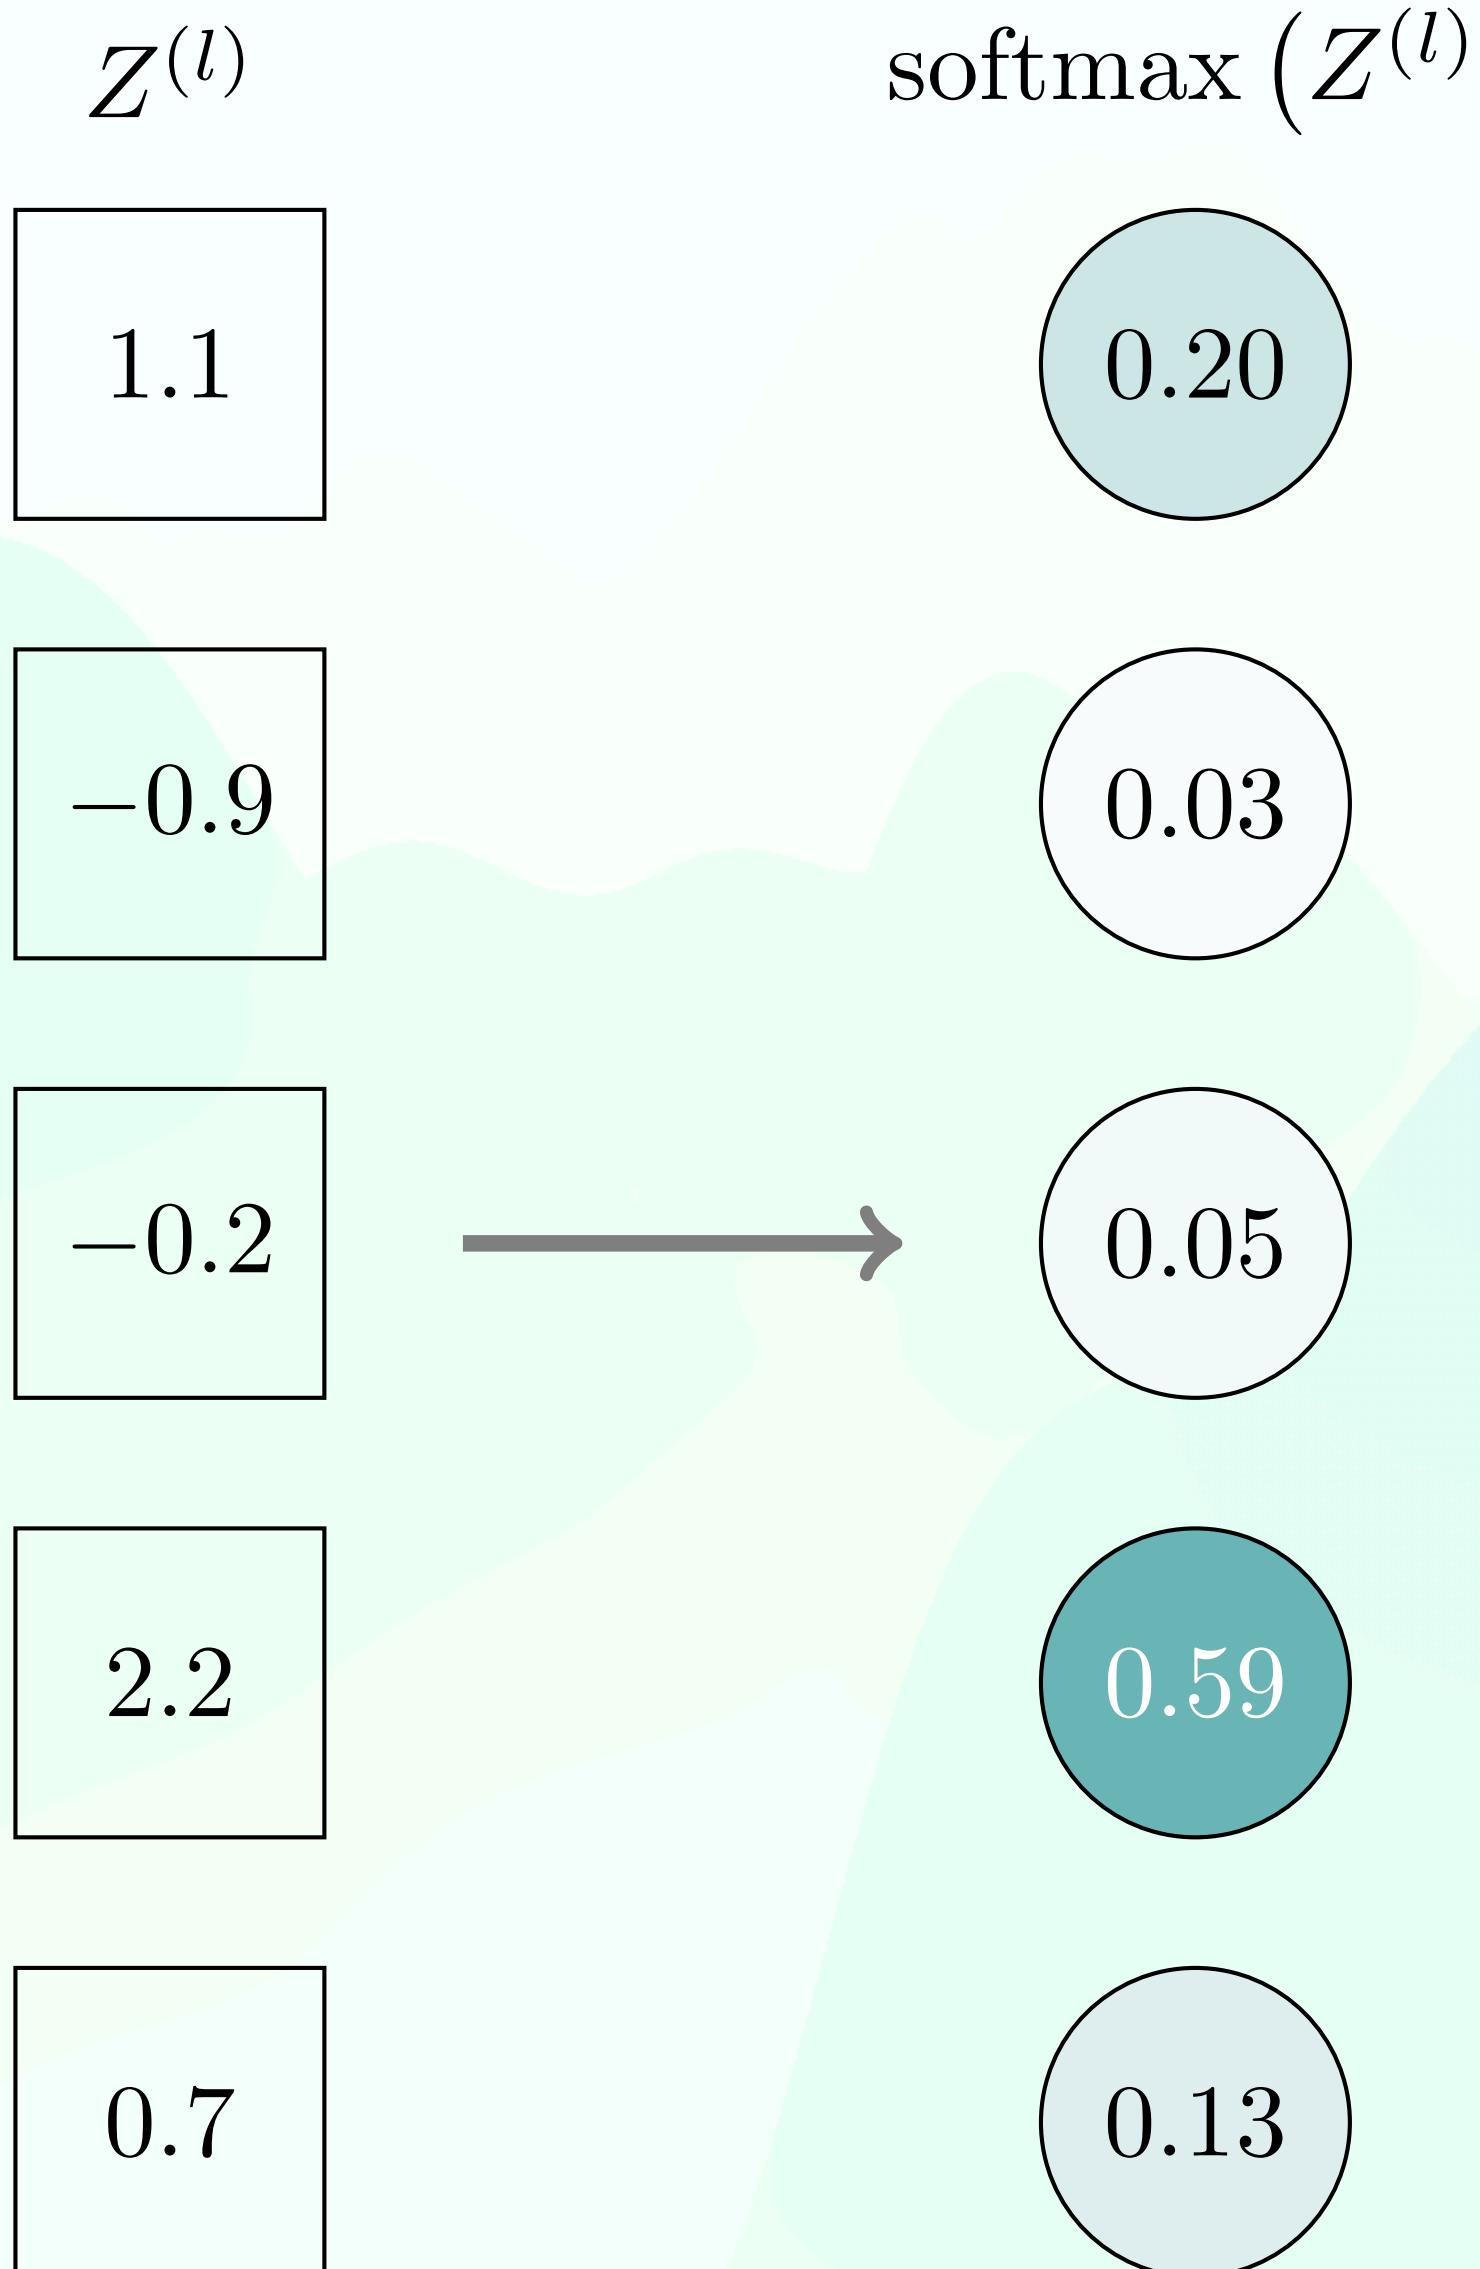
$$a_i^{(l)} = \text{softmax}\left(z_i^{(l)}\right) = \frac{e^{z_i^{(l)}}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}}$$

- Softmax hängt also von allen gewichteten Summen des Layers ab!

# Softmax für Klassifikationsnetzwerke

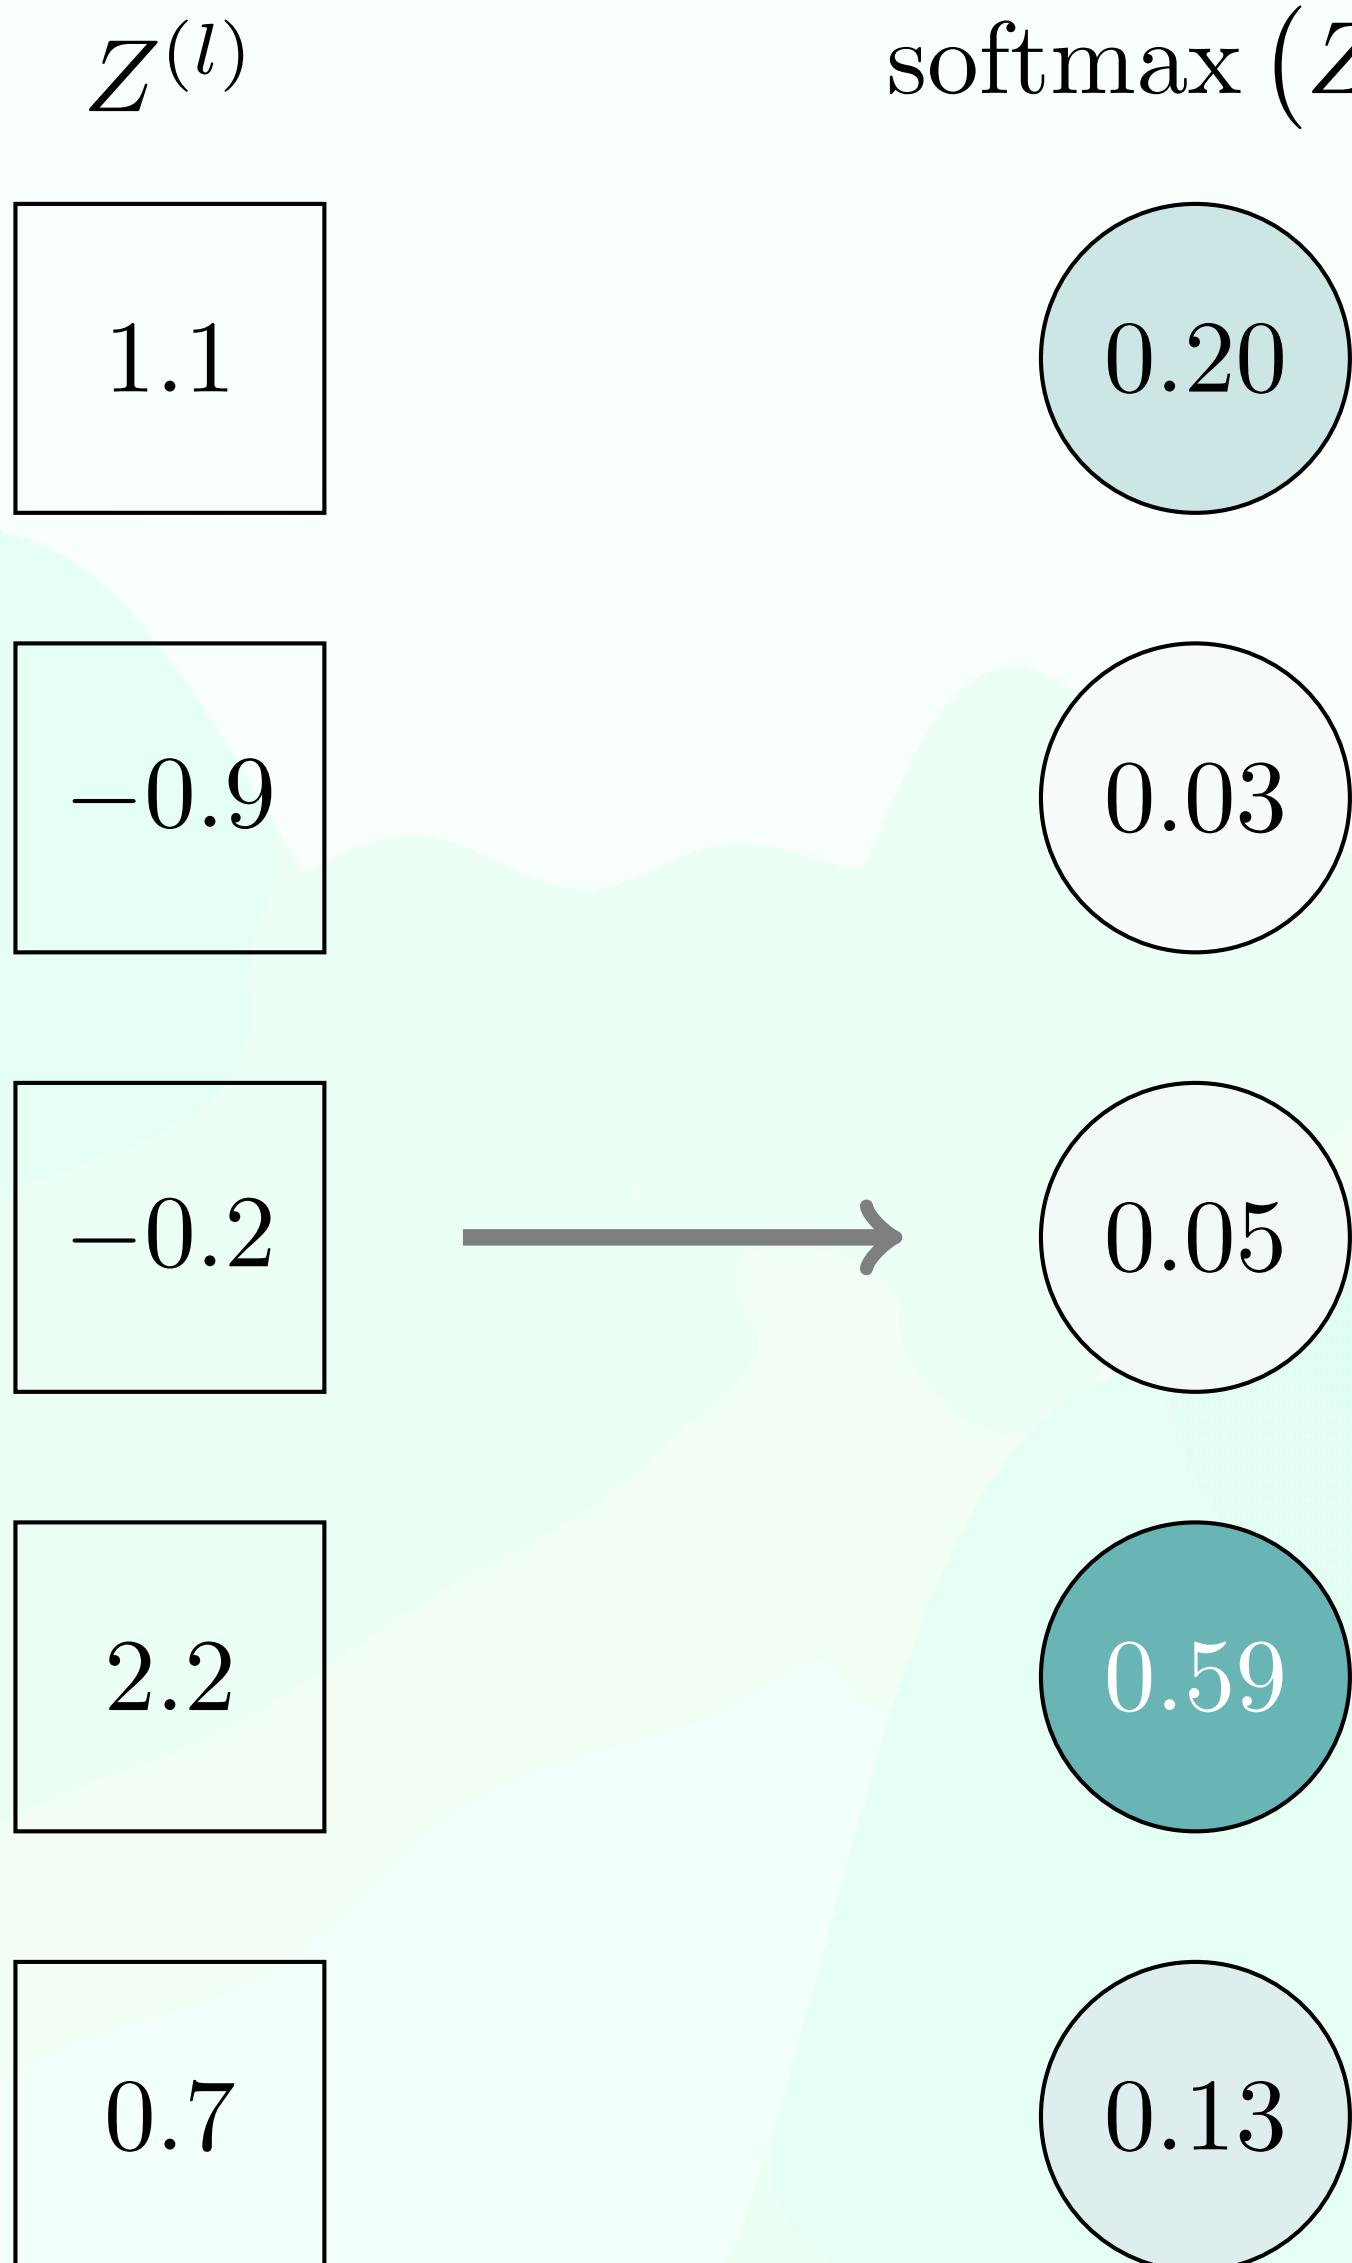
$$\text{softmax}\left(z_i^{(l)}\right) = \frac{e^{z_i^{(l)}}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}}$$

# Softmax für Klassifikationsnetzwerke



$$\text{softmax}\left(z_i^{(l)}\right) = \frac{e^{z_i^{(l)}}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}}$$

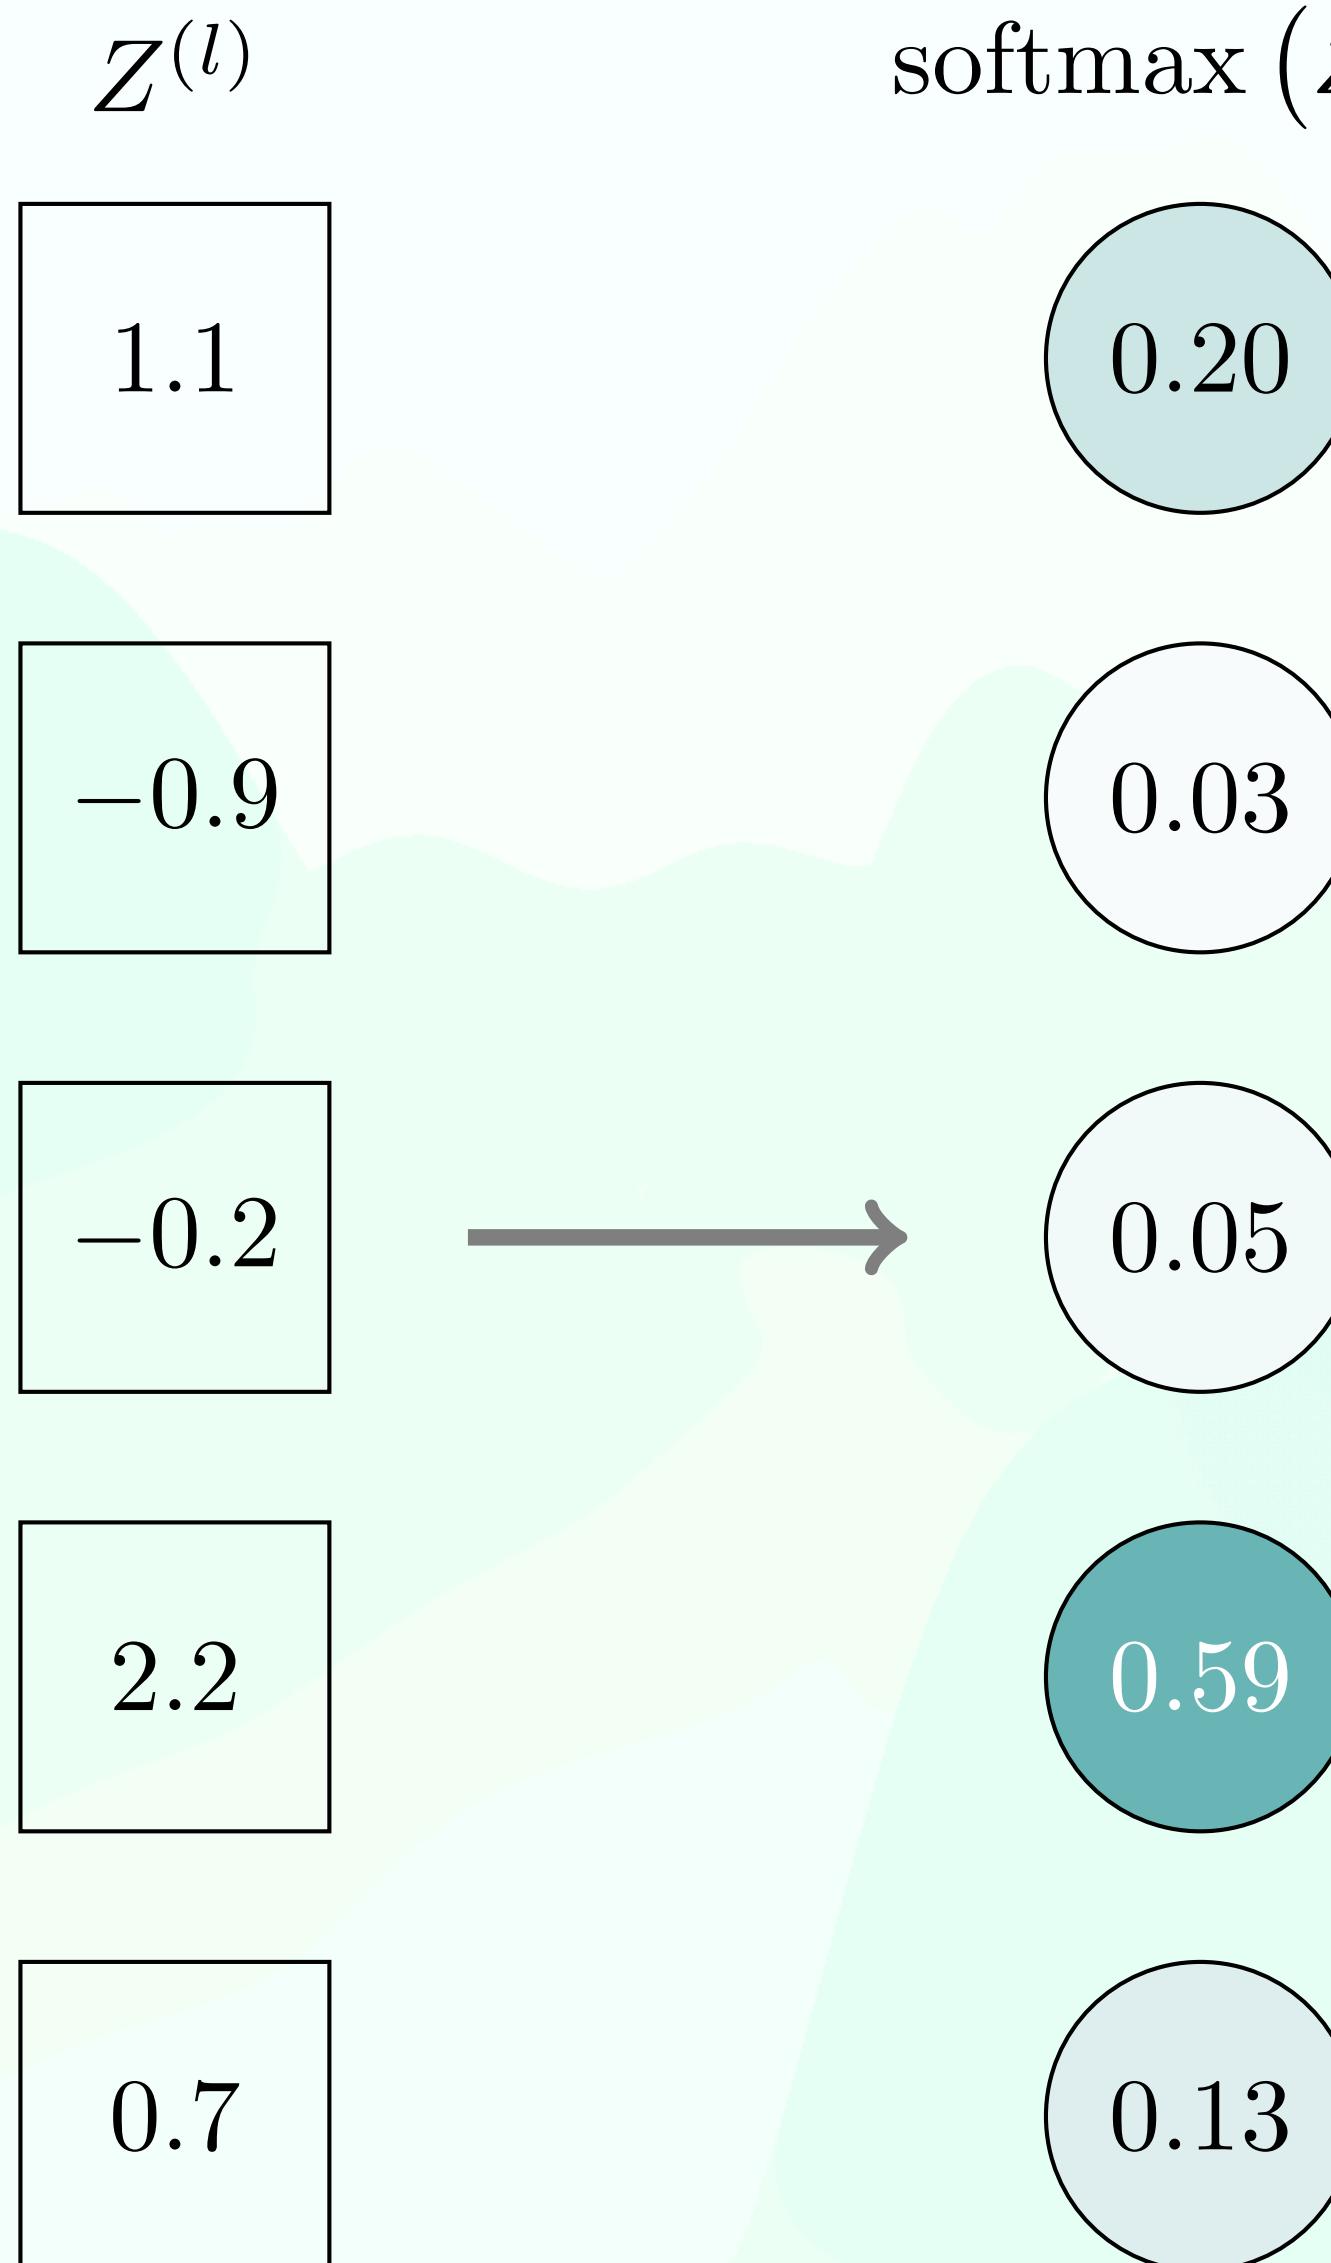
# Softmax für Klassifikationsnetzwerke



$$\text{softmax}\left(z_i^{(l)}\right) = \frac{e^{z_i^{(l)}}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}}$$

Output-Aktivierungen ergeben in Summe 1, können damit wie Wahrscheinlichkeiten behandelt werden.

# Softmax für Klassifikationsnetzwerke



$$\text{softmax}\left(z_i^{(l)}\right) = \frac{e^{z_i^{(l)}}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}}$$

Output-Aktivierungen ergeben in Summe 1, können damit wie Wahrscheinlichkeiten behandelt werden.

Rangordnung der gewichteten Summen bleibt nach Softmax-Aktivierung erhalten:

$$z_k^{(l)} > z_m^{(l)} \iff \text{softmax}\left(z_k^{(l)}\right) > \text{softmax}\left(z_m^{(l)}\right)$$

Softmax ist **ordnungserhaltende Transformation**.

# Numerisch stabiler Softmax

- **Problem:** Für große  $z$  wird auch  $e^z$  sehr groß und kann den Wertebereich klassischer Datentypen in Programmiersprachen leicht übersteigen

$$\text{softmax}\left(z_i^{(l)}\right) = \frac{e^{z_i^{(l)}}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}}$$

# Numerisch stabiler Softmax

- **Problem:** Für große  $z$  wird auch  $e^z$  sehr groß und kann den Wertebereich klassischer Datentypen in Programmiersprachen leicht übersteigen
- **Lösung:** Wir ziehen den größten Wert aus  $Z^{(l)}$  von allen Exponenten ab, bevor wir potenzieren:

$$\text{softmax}^*(z_i^{(l)}) = \frac{e^{z_i^{(l)} - \max(Z^{(l)})}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)} - \max(Z^{(l)})}}$$

$$\text{softmax}(z_i^{(l)}) = \frac{e^{z_i^{(l)}}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}}$$

# Numerisch stabiler Softmax

- **Problem:** Für große  $z$  wird auch  $e^z$  sehr groß und kann den Wertebereich klassischer Datentypen in Programmiersprachen leicht übersteigen
- **Lösung:** Wir ziehen den größten Wert aus  $Z^{(l)}$  von allen Exponenten ab, bevor wir potenzieren:

$$\text{softmax}^*(z_i^{(l)}) = \frac{e^{z_i^{(l)} - \max(Z^{(l)})}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)} - \max(Z^{(l)})}}$$

- Damit gilt für alle Exponenten  $x \leq 0$ , und damit  $e^x \leq 1$
- Das Resultat bleibt gleich:  $\text{softmax}^*(z_i^{(l)}) = \text{softmax}(z_i^{(l)})$

$$\text{softmax}(z_i^{(l)}) = \frac{e^{z_i^{(l)}}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}}$$

# Beweis

$$\text{softmax}^* \left( z_i^{(l)} \right) = \text{softmax} \left( z_i^{(l)} \right)$$

# Beweis

Es gilt:  $a^{m+n} = a^m \cdot a^n$

$$\text{softmax}^*(z_i^{(l)}) = \text{softmax}(z_i^{(l)})$$

# Beweis

$$\text{softmax}^*(z_i^{(l)}) = \text{softmax}(z_i^{(l)})$$

Es gilt:  $a^{m+n} = a^m \cdot a^n$

Daraus und aus dem Distributivgesetz folgt:

$$\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)} - c} = \sum_{j=0}^{n^{(l)}-1} (e^{z_j^{(l)}} \cdot e^{-c}) = e^{-c} \cdot \sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}$$

# Beweis

$$\text{softmax}^*(z_i^{(l)}) = \text{softmax}(z_i^{(l)})$$

Es gilt:  $a^{m+n} = a^m \cdot a^n$

Daraus und aus dem Distributivgesetz folgt:

$$\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)} - c} = \sum_{j=0}^{n^{(l)}-1} (e^{z_j^{(l)}} \cdot e^{-c}) = e^{-c} \cdot \sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}$$

Und damit:

$$\frac{e^{z_i^{(l)} - c}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)} - c}} = \frac{e^{z_i^{(l)}} \cdot e^{-c}}{e^{-c} \cdot \sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}} = \frac{e^{z_i^{(l)}}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}}$$

# Beweis

$$\text{softmax}^*(z_i^{(l)}) = \text{softmax}(z_i^{(l)})$$

Es gilt:  $a^{m+n} = a^m \cdot a^n$

Daraus und aus dem Distributivgesetz folgt:

$$\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)} - c} = \sum_{j=0}^{n^{(l)}-1} (e^{z_j^{(l)}} \cdot e^{-c}) = e^{-c} \cdot \sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}$$

Und damit:

$$\frac{e^{z_i^{(l)} - c}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)} - c}} = \frac{e^{z_i^{(l)}} \cdot e^{-c}}{e^{-c} \cdot \sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}} = \frac{e^{z_i^{(l)}}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}}$$

# Softmax-Aktivierungsfunktion

$$\text{softmax}^*(z_i^{(l)}) = \frac{e^{z_i^{(l)} - \max(Z^{(l)})}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)} - \max(Z^{(l)})}}$$



```
def softmax(z):
    stabilized_z = z - numpy.max(z)
    exp_z = numpy.exp(stabilized_z)

    return exp_z / numpy.sum(exp_z)
```

Um in unserem Netzwerk auch Softmax-Aktivierungen zuzulassen, implementieren wir auch diese Aktivierungsfunktion neben den anderen. Wir verwenden dabei natürlich die numerisch stabile Variante.

# Softmax-Aktivierungsfunktion

$$\text{softmax}^*(z_i^{(l)}) = \frac{e^{z_i^{(l)} - \max(Z^{(l)})}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)} - \max(Z^{(l)})}}$$



```
def softmax(z):
    stabilized_z = z - numpy.max(z)
    exp_z = numpy.exp(stabilized_z)

    return exp_z / numpy.sum(exp_z)
```

Zunächst berechnen wir für alle Einträge aus  $Z^{(l)}$  ihre Differenz mit dem größten Eintrag aus diesem Vektor. Heraus kommt wieder ein Vektor mit all diesen Differenzen.

# Softmax-Aktivierungsfunktion

$$\text{softmax}^*(z_i^{(l)}) = \frac{e^{z_i^{(l)} - \max(Z^{(l)})}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)} - \max(Z^{(l)})}}$$



```
def softmax(z):
    stabilized_z = z - numpy.max(z)
    exp_z = numpy.exp(stabilized_z)

    return exp_z / numpy.sum(exp_z)
```

Dann lassen wir uns von `numpy` die Exponentialfunktion für all diese Werte berechnen. In `exp_z` steht dann ein Vektor mit allen Potenzen zur Basis  $e$ .

# Softmax-Aktivierungsfunktion

$$\text{softmax}^*(z_i^{(l)}) = \frac{e^{z_i^{(l)} - \max(Z^{(l)})}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)} - \max(Z^{(l)})}}$$



```
def softmax(z):
    stabilized_z = z - numpy.max(z)
    exp_z = numpy.exp(stabilized_z)

    return exp_z / numpy.sum(exp_z)
```

Zuletzt berechnen wir das Verhältnis zwischen jeder einzelnen Potenz und der Summe aller Potenzen – dank `numpy` für den gesamten Vektor `exp_z` auf einmal. Das Ergebnis ist wieder ein Vektor, der für jede gewichtete Summe des Layers ihre Umwandlung in die entsprechende Softmax-Aktivierung enthält.

# Fragen

- Warum werden beim Softmax Potenzen verwendet, und die  $z_i$  nicht einfach direkt ins Verhältnis zu ihrer Summe gesetzt?

$$\text{softmax} \left( z_i^{(l)} \right) = \frac{e^{z_i^{(l)}}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}}$$

vs.

$$S \left( z_i^{(l)} \right) = \frac{z_i^{(l)}}{\sum_{j=0}^{n^{(l)}-1} z_j^{(l)}}$$

# Fragen

- Warum wird als Basis ausgerechnet e verwendet?

$$\text{softmax}\left(z_i^{(l)}\right) = \frac{e^{z_i^{(l)}}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}}$$

# Cross-Entropy Loss

- Passende Kostenfunktion zu Softmax: **Cross-Entropy Loss**
- Sei  $Y$  ein **One-Hot-kodierter** Vektor der erwarteten Output-Aktivierungen, dann betragen die Kosten nach Cross-Entropy Loss:

$$C = - \sum_{i=0}^{n^{(l)}-1} y_i \cdot \ln \left( a_i^{(l)} \right)$$

# Cross-Entropy Loss

- Passende Kostenfunktion zu Softmax: **Cross-Entropy Loss**
- Sei  $Y$  ein **One-Hot-kodierter** Vektor der erwarteten Output-Aktivierungen, dann betragen die Kosten nach Cross-Entropy Loss:

$$C = - \sum_{i=0}^{n^{(l)}-1} y_i \cdot \ln \left( a_i^{(l)} \right)$$

- Beispiel:

$$Y = \begin{pmatrix} 0 \\ 0 \\ 1 \\ 0 \end{pmatrix}$$

„One-Hot“, alle anderen Einträge sind 0

# Cross-Entropy Loss

- Passende Kostenfunktion zu Softmax: **Cross-Entropy Loss**
- Sei  $Y$  ein **One-Hot-kodierter** Vektor der erwarteten Output-Aktivierungen, dann betragen die Kosten nach Cross-Entropy Loss:

$$C = - \sum_{i=0}^{n^{(l)}-1} y_i \cdot \ln(a_i^{(l)})$$

Nur die eine zugehörige Aktivierung im Output-Layer fließt in die Kosten ein!

- Beispiel:

$$Y = \begin{pmatrix} 0 \\ 0 \\ 1 \\ 0 \end{pmatrix}$$

„One-Hot“, alle anderen Einträge sind 0

# Cross-Entropy Loss - Beispiel

- Gegeben:

$$Y = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \quad A^{(l)} = \begin{pmatrix} 0.1 \\ 0.7 \\ 0.2 \end{pmatrix}$$

$$C = - \sum_{i=0}^{n^{(l)}-1} y_i \cdot \ln \left( a_i^{(l)} \right)$$

# Cross-Entropy Loss - Beispiel

- Gegeben:

$$Y = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \quad A^{(l)} = \begin{pmatrix} 0.1 \\ 0.7 \\ 0.2 \end{pmatrix}$$

- Dann betragen die Kosten nach Cross-Entropy Loss:

$$C = - (0 \cdot \ln(0.1) + 1 \cdot \ln(0.7) + 0 \cdot \ln(0.2))$$

$$C = - \sum_{i=0}^{n^{(l)}-1} y_i \cdot \ln(a_i^{(l)})$$

# Cross-Entropy Loss - Beispiel

- Gegeben:

$$Y = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \quad A^{(l)} = \begin{pmatrix} 0.1 \\ 0.7 \\ 0.2 \end{pmatrix}$$

- Dann betragen die Kosten nach Cross-Entropy Loss:

$$\begin{aligned} C &= - (0 \cdot \ln(0.1) + 1 \cdot \ln(0.7) + 0 \cdot \ln(0.2)) \\ &= - \ln(0.7) \end{aligned}$$

$$C = - \sum_{i=0}^{n^{(l)}-1} y_i \cdot \ln(a_i^{(l)})$$

# Cross-Entropy Loss - Beispiel

- Gegeben:

$$Y = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \quad A^{(l)} = \begin{pmatrix} 0.1 \\ 0.7 \\ 0.2 \end{pmatrix}$$

- Dann betragen die Kosten nach Cross-Entropy Loss:

$$\begin{aligned} C &= - (0 \cdot \ln(0.1) + 1 \cdot \ln(0.7) + 0 \cdot \ln(0.2)) \\ &= - \ln(0.7) \\ &\approx 0.3567 \end{aligned}$$

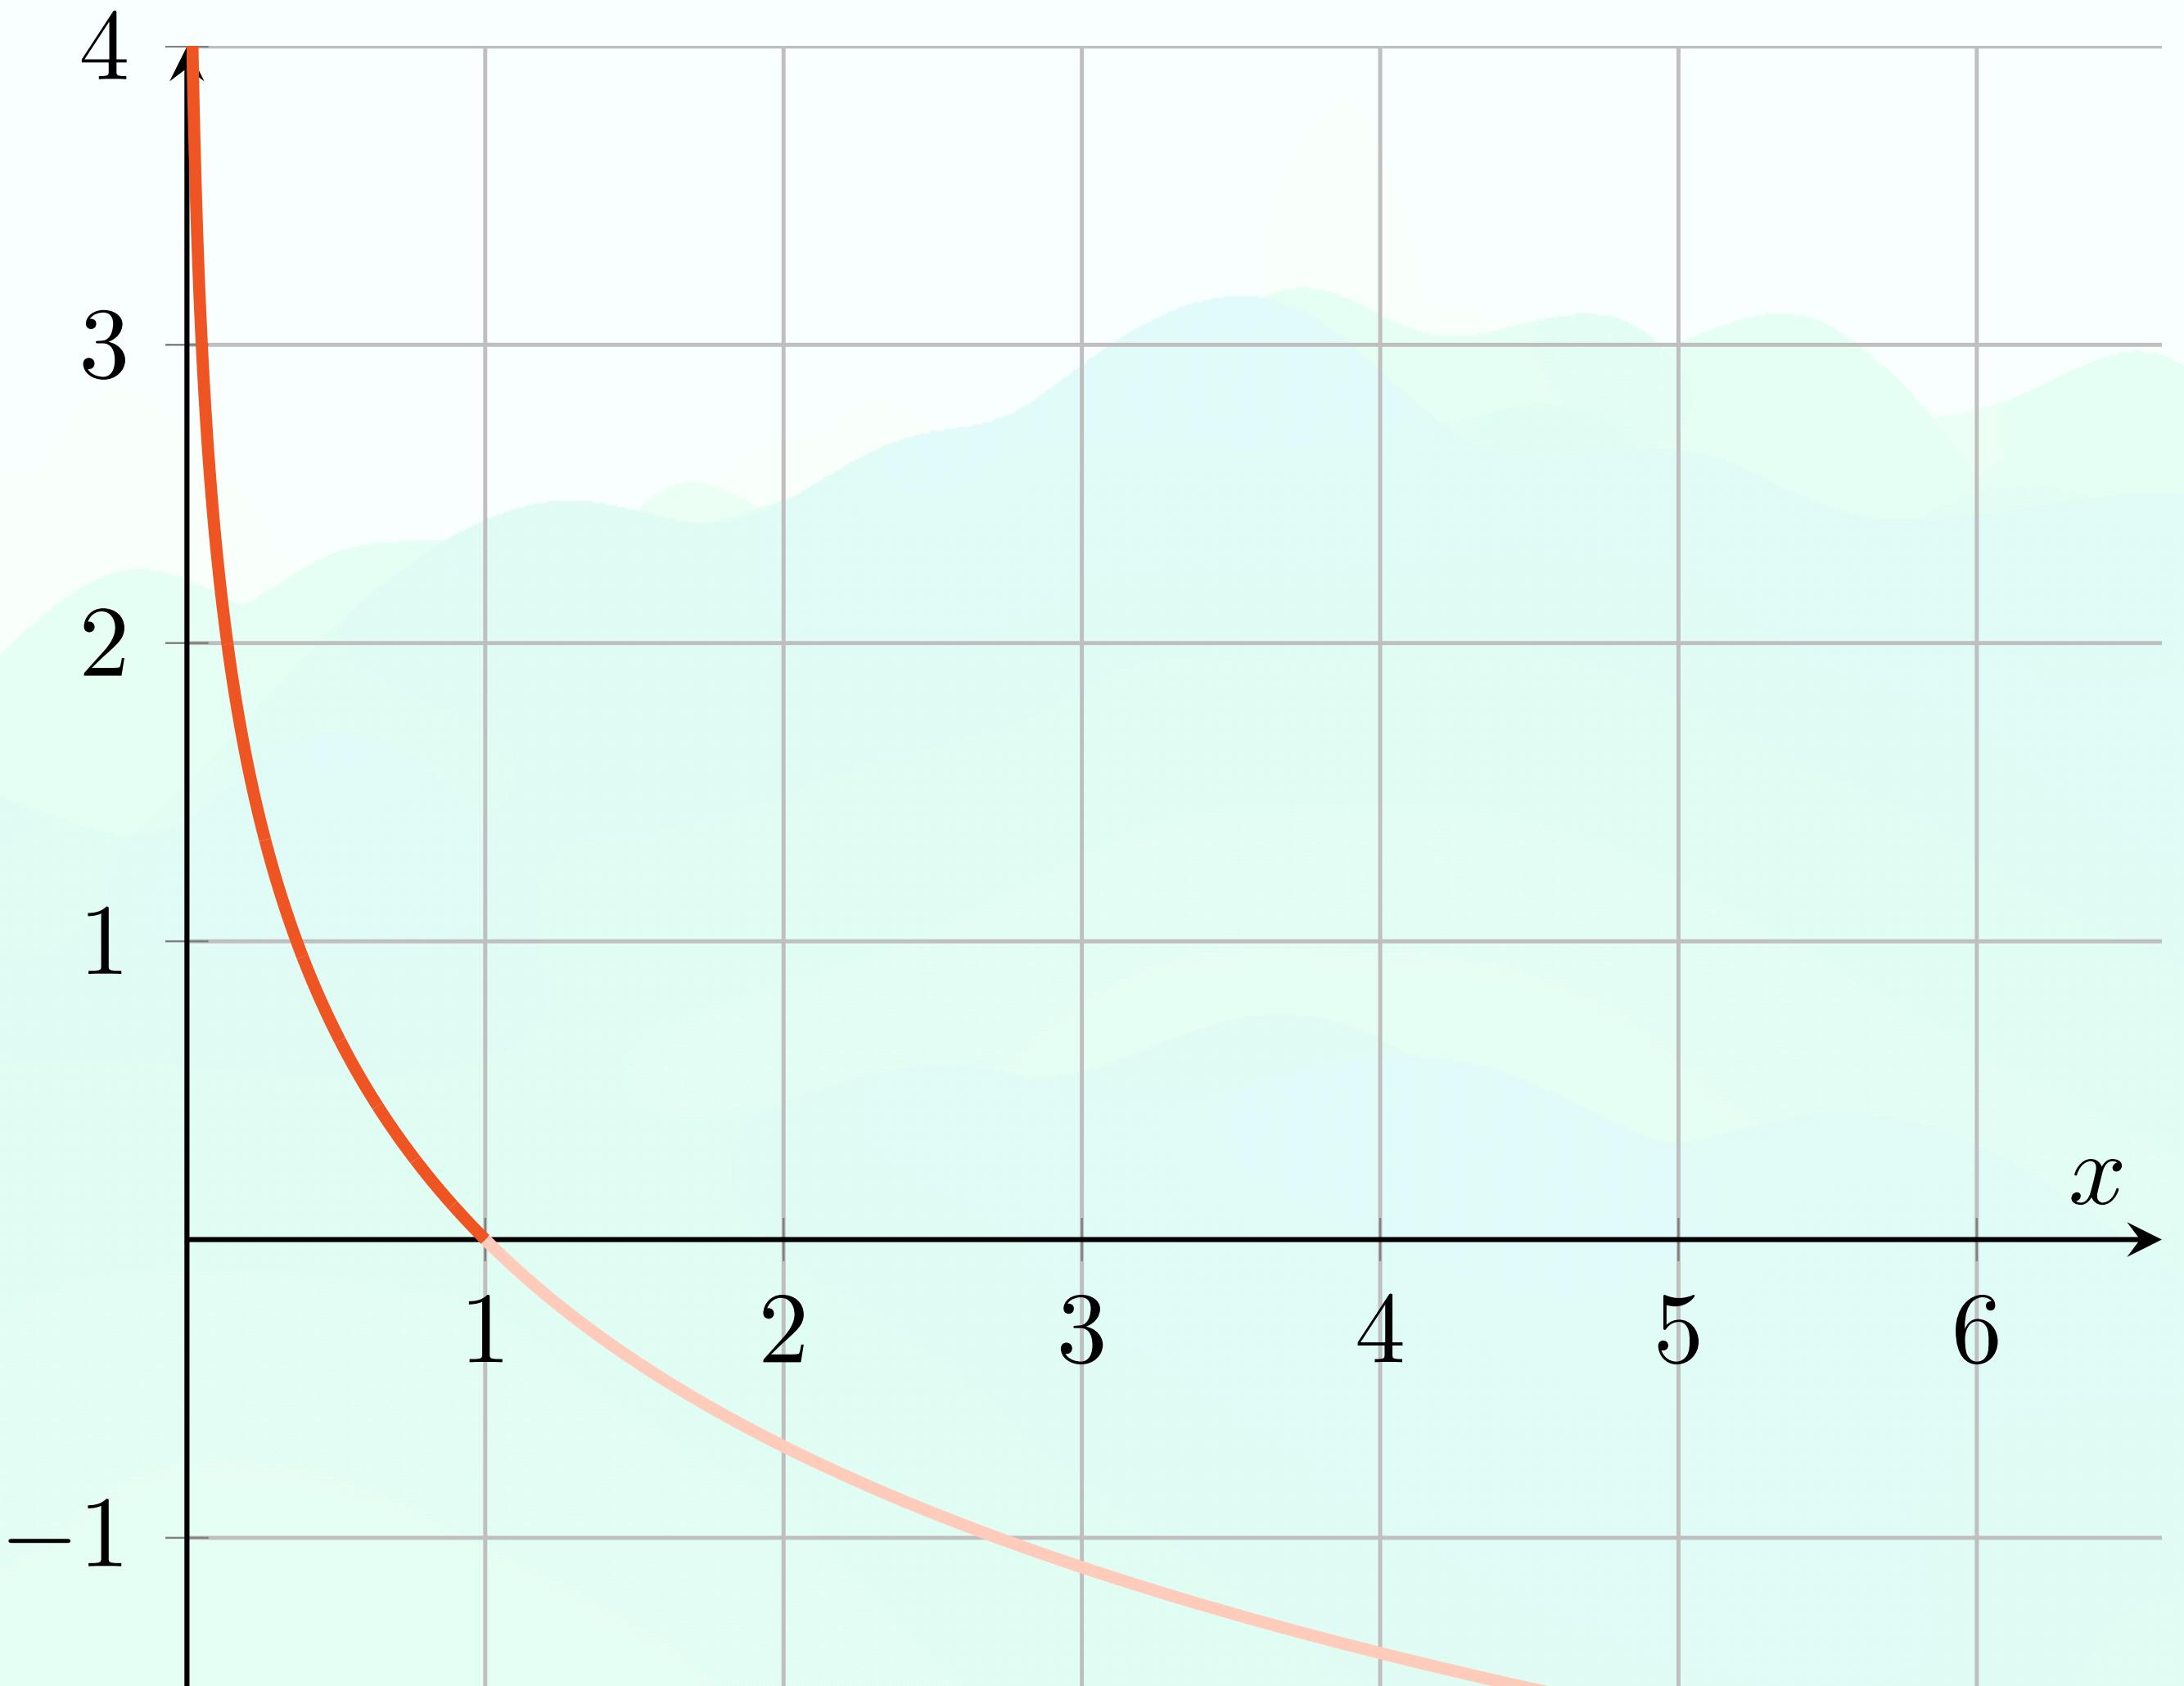
$$C = - \sum_{i=0}^{n^{(l)}-1} y_i \cdot \ln(a_i^{(l)})$$

# Cross-Entropy Loss

$$C = - \sum_{i=0}^{n^{(l)}-1} y_i \cdot \ln(a_i^{(l)})$$

- Kosten nähern sich der 0, je näher die Aktivierung an 1 ist
- Für  $x$  gegen 0 steigen die Kosten exponentiell, daher sehr guter Gradient
- Aktivierungen kleiner als 0 und größer als 1 dank Softmax nicht möglich

$$y = -\ln(x)$$



# Ableitung von Softmax und Cross-Entropy Loss

- Die Kombination aus Softmax als Aktivierungsfunktion im Output-Layer und Cross-Entropy Loss als Kostenfunktion erfordert eine Anpassung der Backpropagation

# Ableitung von Softmax und Cross-Entropy Loss

- Die Kombination aus Softmax als Aktivierungsfunktion im Output-Layer und Cross-Entropy Loss als Kostenfunktion erfordert eine Anpassung der Backpropagation
- Die Gesamtableitung berechnet sich nach wie vor mit Gleichung 1:

1

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

# Ableitung von Softmax und Cross-Entropy Loss

- Die Kombination aus Softmax als Aktivierungsfunktion im Output-Layer und Cross-Entropy Loss als Kostenfunktion erfordert eine Anpassung der Backpropagation
- Die Gesamtableitung berechnet sich nach wie vor mit Gleichung 1:

1

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

Bleibt unverändert, da nicht beeinflusst von Softmax

# Ableitung von Softmax und Cross-Entropy Loss

- Die Kombination aus Softmax als Aktivierungsfunktion im Output-Layer und Cross-Entropy Loss als Kostenfunktion erfordert eine Anpassung der Backpropagation
- Die Gesamtableitung berechnet sich nach wie vor mit Gleichung 1:

$$1 \quad \frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

Bleibt unverändert, da nicht beeinflusst von Softmax

Im Prinzip unser gesuchter Ausdruck der Ableitung für Kombination aus Softmax und Cross-Entropy Loss.

**Aber:** Bei Softmax hängt die Aktivierung eines einzelnen Output-Neurons von allen gewichteten Summen im Output-Layer ab!

# Ableitung von Softmax

- Vereinbarung:  $s_i^{(l)} = \text{softmax}\left(z_i^{(l)}\right) = \frac{e^{z_i^{(l)}}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}} = \text{softmax}^*\left(z_i^{(l)}\right)$

# Ableitung von Softmax

- Vereinbarung:  $s_i^{(l)} = \text{softmax}\left(z_i^{(l)}\right) = \frac{e^{z_i^{(l)}}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}} = \text{softmax}^*\left(z_i^{(l)}\right)$
- Da  $s_i^{(l)}$  von allen  $z_j^{(l)}$  abhängt, brauchen wir für alle  $z_j^{(l)}$  die Ableitung:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

# Ableitung von Softmax

- Vereinbarung:  $s_i^{(l)} = \text{softmax}\left(z_i^{(l)}\right) = \frac{e^{z_i^{(l)}}}{\sum_{j=0}^{n^{(l)}-1} e^{z_j^{(l)}}} = \text{softmax}^*\left(z_i^{(l)}\right)$
- Da  $s_i^{(l)}$  von allen  $z_j^{(l)}$  abhängt, brauchen wir für alle  $z_j^{(l)}$  die Ableitung:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$
- Wir benutzen einen Trick und suchen zunächst:

$$\frac{\partial}{\partial z_j^{(l)}} \ln\left(s_i^{(l)}\right)$$

# Ableitung von Softmax

Gesucht:

$$\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$$

Für  $\ln(x)$  gilt die Ableitung:  $\ln'(x) = \frac{1}{x}$

# Ableitung von Softmax

Gesucht:

$$\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$$

Für  $\ln(x)$  gilt die Ableitung:  $\ln'(x) = \frac{1}{x}$

Daraus folgt mithilfe der Kettenregel:

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{1}{s_i^{(l)}} \cdot \frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$$

# Ableitung von Softmax

Gesucht:

$$\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$$

Für  $\ln(x)$  gilt die Ableitung:  $\ln'(x) = \frac{1}{x}$

Daraus folgt mithilfe der Kettenregel:

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{1}{s_i^{(l)}} \cdot \frac{\partial s_i^{(l)}}{\partial z_j^{(l)}} \quad | \quad \cdot s_i^{(l)}$$

# Ableitung von Softmax

Gesucht:

$$\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$$

Für  $\ln(x)$  gilt die Ableitung:  $\ln'(x) = \frac{1}{x}$

Daraus folgt mithilfe der Kettenregel:

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{1}{s_i^{(l)}} \cdot \frac{\partial s_i^{(l)}}{\partial z_j^{(l)}} \quad | \quad \cdot s_i^{(l)}$$

$$\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}} = s_i^{(l)} \cdot \frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)})$$

I

# Ableitung von Softmax

$$\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}} = s_i^{(l)} \cdot \frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)})$$

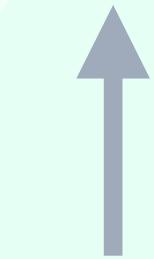
Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

# Ableitung von Softmax

Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

$$\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}} = s_i^{(l)} \cdot \frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)})$$

$$\ln(s_i^{(l)}) = \ln \left( \frac{e^{z_i^{(l)}}}{\sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}} \right)$$



Definition Softmax

# Ableitung von Softmax

Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

$$\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}} = s_i^{(l)} \cdot \frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)})$$

$$\ln(s_i^{(l)}) = \ln\left(\frac{e^{z_i^{(l)}}}{\sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}}\right) = \ln(e^{z_i^{(l)}}) - \ln\left(\sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}\right)$$

Allgemeine Regel bei  
Logarithmen von Brüchen:

$$\log_x \frac{a}{b} = \log_x a - \log_x b$$

# Ableitung von Softmax

Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

$$\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}} = s_i^{(l)} \cdot \frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)})$$

$$\begin{aligned} \ln(s_i^{(l)}) &= \ln \left( \frac{e^{z_i^{(l)}}}{\sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}} \right) = \ln(e^{z_i^{(l)}}) - \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right) \\ &= z_i^{(l)} - \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right) \end{aligned}$$

$e^x$  und  $\ln(x)$  sind  
Umkehroperationen  
voneinander

# Ableitung von Softmax

$$\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}} = s_i^{(l)} \cdot \frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)})$$

$$\ln(s_i^{(l)}) = z_i^{(l)} - \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right)$$

Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

# Ableitung von Softmax

Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

$$\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}} = s_i^{(l)} \cdot \frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)})$$

$$\ln(s_i^{(l)}) = z_i^{(l)} - \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right)$$

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{\partial z_i^{(l)}}{\partial z_j^{(l)}} - \frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right)$$

Ableitung der Differenz ist gleich  
der Differenz der Ableitungen

# Ableitung von Softmax

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{\partial z_i^{(l)}}{\partial z_j^{(l)}} - \frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right)$$

Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

# Ableitung von Softmax

Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{\partial z_i^{(l)}}{\partial z_j^{(l)}} - \frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right)$$

$$\frac{\partial z_i^{(l)}}{\partial z_j^{(l)}} = 1_{\{i=j\}} = \begin{cases} 1 & \text{falls } i = j \\ 0 & \text{sonst} \end{cases}$$

II

# Ableitung von Softmax

Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{\partial z_i^{(l)}}{\partial z_j^{(l)}} - \frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right)$$

$$\frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right) = \frac{1}{\sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}} \cdot \frac{\partial}{\partial z_j^{(l)}} \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}$$

Anwendung der Kettenregel

# Ableitung von Softmax

Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{\partial z_i^{(l)}}{\partial z_j^{(l)}} - \frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right)$$

$$\frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right) = \frac{1}{\sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}} \cdot \frac{\partial}{\partial z_j^{(l)}} \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}$$

$$\frac{\partial}{\partial z_j^{(l)}} \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} = \frac{\partial}{\partial z_j^{(l)}} \left( e^{z_0^{(l)}} + e^{z_1^{(l)}} + \dots + e^{z_j^{(l)}} + \dots + e^{z_n^{(l)}} \right)$$

# Ableitung von Softmax

Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{\partial z_i^{(l)}}{\partial z_j^{(l)}} - \frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right)$$

$$\frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right) = \frac{1}{\sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}} \cdot \frac{\partial}{\partial z_j^{(l)}} \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}$$

$$\frac{\partial}{\partial z_j^{(l)}} \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} = \frac{\partial}{\partial z_j^{(l)}} \left( e^{z_0^{(l)}} + e^{z_1^{(l)}} + \dots + e^{z_j^{(l)}} + \dots + e^{z_n^{(l)}} \right) = e^{z_j^{(l)}}$$

Für die Ableitung ist nur  $e^{z_j^{(l)}}$  relevant, alle anderen Summanden sind Konstanten

# Ableitung von Softmax

Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{\partial z_i^{(l)}}{\partial z_j^{(l)}} - \frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right)$$

$$\frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right) = \frac{1}{\sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}} \cdot \frac{\partial}{\partial z_j^{(l)}} \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}$$

$$\frac{\partial}{\partial z_j^{(l)}} \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} = \frac{\partial}{\partial z_j^{(l)}} \left( e^{z_0^{(l)}} + e^{z_1^{(l)}} + \dots + e^{z_j^{(l)}} + \dots + e^{z_n^{(l)}} \right) = e^{z_j^{(l)}}$$

$e^x$  ist seine eigene Ableitung:

$$(e^x)' = e^x$$



# Ableitung von Softmax

Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{\partial z_i^{(l)}}{\partial z_j^{(l)}} - \frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right)$$

$$\frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right) = \frac{1}{\sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}} \cdot e^{z_j^{(l)}}$$

$$\frac{\partial}{\partial z_j^{(l)}} \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} = \frac{\partial}{\partial z_j^{(l)}} \left( e^{z_0^{(l)}} + e^{z_1^{(l)}} + \dots + e^{z_j^{(l)}} + \dots + e^{z_n^{(l)}} \right) = e^{z_j^{(l)}}$$

# Ableitung von Softmax

Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{\partial z_i^{(l)}}{\partial z_j^{(l)}} - \frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right)$$

$$\frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right) = \frac{1}{\sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}} \cdot e^{z_j^{(l)}}$$

# Ableitung von Softmax

Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{\partial z_i^{(l)}}{\partial z_j^{(l)}} - \frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right)$$

$$\frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right) = \frac{1}{\sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}} \cdot e^{z_j^{(l)}} = \frac{e^{z_j^{(l)}}}{\sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}}$$

# Ableitung von Softmax

Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{\partial z_i^{(l)}}{\partial z_j^{(l)}} - \frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right)$$

$$\frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right) = \frac{1}{\sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}} \cdot e^{z_j^{(l)}} = \frac{e^{z_j^{(l)}}}{\sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}}$$

Dieser Ausdruck entspricht der  
Softmax-Aktivierung im  $j$ -ten  
Neuron von Layer  $l$

# Ableitung von Softmax

Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{\partial z_i^{(l)}}{\partial z_j^{(l)}} - \frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right)$$

$$\frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right) = \frac{1}{\sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}} \cdot e^{z_j^{(l)}} = \frac{e^{z_j^{(l)}}}{\sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}} = s_j^{(l)}$$

# Ableitung von Softmax

Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{\partial z_i^{(l)}}{\partial z_j^{(l)}} - s_j^{(l)}$$

$$\frac{\partial}{\partial z_j^{(l)}} \ln \left( \sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}} \right) = \frac{1}{\sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}} \cdot e^{z_j^{(l)}} = \frac{e^{z_j^{(l)}}}{\sum_{k=0}^{n^{(l)}-1} e^{z_k^{(l)}}} = s_j^{(l)}$$

# Ableitung von Softmax

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{\partial z_i^{(l)}}{\partial z_j^{(l)}} - s_j^{(l)}$$

Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

# Ableitung von Softmax

Gesucht:  $\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{\partial z_i^{(l)}}{\partial z_j^{(l)}} - s_j^{(l)}$$

Einsetzen des Ausdrucks aus Gleichung II ergibt:

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = 1_{\{i=j\}} - s_j^{(l)} = \begin{cases} 1 - s_j^{(l)} & \text{falls } i = j \\ -s_j^{(l)} & \text{sonst} \end{cases}$$

# Ableitung von Softmax

Gesucht:

$$\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$$

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{\partial z_i^{(l)}}{\partial z_j^{(l)}} - s_j^{(l)}$$

Einsetzen des Ausdrucks aus Gleichung II ergibt:

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = 1_{\{i=j\}} - s_j^{(l)} = \begin{cases} 1 - s_j^{(l)} & \text{falls } i = j \\ -s_j^{(l)} & \text{sonst} \end{cases}$$

Einsetzen in Gleichung I ergibt:

$$\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}} = s_i^{(l)} \cdot \frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = s_i^{(l)} \cdot (1_{\{i=j\}} - s_j^{(l)})$$

III

# Ableitung von Softmax

$$\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}} = s_i^{(l)} \cdot \left( 1_{\{i=j\}} - s_j^{(l)} \right)$$



# Ableitung von Softmax

$$\frac{\partial s_i^{(l)}}{\partial z_j^{(l)}} = s_i^{(l)} \cdot \left( 1_{\{i=j\}} - s_j^{(l)} \right)$$

III

Der gefundene Ausdruck entspricht der Ableitung  
der Aktivierung nach den gewichteten Summen.

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

# Ableitung von Cross-Entropy Loss

Wir müssen auch noch die Ableitung unserer neuen Kostenfunktion einbeziehen: Cross-Entropy Loss

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

# Ableitung von Cross-Entropy Loss

Gesucht:

$$\frac{\partial C}{\partial z_j^{(l)}}$$

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

# Ableitung von Cross-Entropy Loss

Gesucht:

$$\frac{\partial C}{\partial z_j^{(l)}}$$

Nach Definition von Cross-Entropy Loss gilt:

$$\frac{\partial C}{\partial z_j^{(l)}} = -\frac{\partial}{\partial z_j^{(l)}} \sum_{i=0}^{n^{(l)}-1} y_i \cdot \ln(s_i^{(l)})$$

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

Nach Definition von Cross-Entropy Loss gilt:

$$\frac{\partial C}{\partial z_j^{(l)}} = -\frac{\partial}{\partial z_j^{(l)}} \sum_{i=0}^{n^{(l)}-1} y_i \cdot \ln(s_i^{(l)})$$

Laut Produktregel gilt:  $(u \cdot v)' = u' \cdot v + u \cdot v'$

Da  $y_i$  aber im Sinne der Ableitung nach  $z_j^{(l)}$  konstant ist, wird  $y'_i = 0$ .

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

Nach Definition von Cross-Entropy Loss gilt:

$$\frac{\partial C}{\partial z_j^{(l)}} = -\frac{\partial}{\partial z_j^{(l)}} \sum_{i=0}^{n^{(l)}-1} y_i \cdot \ln(s_i^{(l)})$$

Laut Produktregel gilt:  $(u \cdot v)' = u' \cdot v + u \cdot v'$

Da  $y_i$  aber im Sinne der Ableitung nach  $z_j^{(l)}$  konstant ist, wird  $y'_i = 0$ .

Relevant ist also nur der zweite Summand der Produktregel:

$$u \cdot v' = y_i \cdot \frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)})$$

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

Nach Definition von Cross-Entropy Loss gilt:

$$\frac{\partial C}{\partial z_j^{(l)}} = - \frac{\partial}{\partial z_j^{(l)}} \sum_{i=0}^{n^{(l)}-1} y_i \cdot \ln(s_i^{(l)})$$

$$= - \sum_{i=0}^{n^{(l)}-1} y_i \cdot \frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)})$$

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

Nach Definition von Cross-Entropy Loss gilt:

$$\frac{\partial C}{\partial z_j^{(l)}} = - \frac{\partial}{\partial z_j^{(l)}} \sum_{i=0}^{n^{(l)}-1} y_i \cdot \ln(s_i^{(l)})$$

$$= - \sum_{i=0}^{n^{(l)}-1} y_i \cdot \frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)})$$

Diesen Ausdruck kennen wir aus Gleichung I:

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{1}{s_i^{(l)}} \cdot \frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$$

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

Nach Definition von Cross-Entropy Loss gilt:

$$\frac{\partial C}{\partial z_j^{(l)}} = - \frac{\partial}{\partial z_j^{(l)}} \sum_{i=0}^{n^{(l)}-1} y_i \cdot \ln(s_i^{(l)})$$

$$= - \sum_{i=0}^{n^{(l)}-1} y_i \cdot \frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)})$$

$$= - \sum_{i=0}^{n^{(l)}-1} \frac{y_i}{s_i^{(l)}} \cdot \frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$$

Diesen Ausdruck kennen wir aus Gleichung I:

$$\frac{\partial}{\partial z_j^{(l)}} \ln(s_i^{(l)}) = \frac{1}{s_i^{(l)}} \cdot \frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$$

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial z_j^{(l)}} = - \sum_{i=0}^{n^{(l)}-1} \frac{y_i}{s_i^{(l)}} \cdot \frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$$

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial z_j^{(l)}} = - \sum_{i=0}^{n^{(l)}-1} \frac{y_i}{s_i^{(l)}} \cdot \frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$$



Diesen Ausdruck haben wir  
bereits in Gleichung III bestimmt.

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\begin{aligned}\frac{\partial C}{\partial z_j^{(l)}} &= - \sum_{i=0}^{n^{(l)}-1} \frac{y_i}{s_i^{(l)}} \cdot \frac{\partial s_i^{(l)}}{\partial z_j^{(l)}} \\ &= - \sum_{i=0}^{n^{(l)}-1} \frac{y_i}{s_i^{(l)}} \cdot s_i^{(l)} \cdot \left(1_{\{i=j\}} - s_j^{(l)}\right)\end{aligned}$$

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial z_j^{(l)}} = - \sum_{i=0}^{n^{(l)}-1} \frac{y_i}{s_i^{(l)}} \cdot \frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$$

$$= - \sum_{i=0}^{n^{(l)}-1} \frac{y_i}{s_i^{(l)}} \cdot s_i^{(l)} \cdot \left( 1_{\{i=j\}} - s_j^{(l)} \right)$$

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial z_j^{(l)}} = - \sum_{i=0}^{n^{(l)}-1} \frac{y_i}{s_i^{(l)}} \cdot \frac{\partial s_i^{(l)}}{\partial z_j^{(l)}}$$

$$= - \sum_{i=0}^{n^{(l)}-1} \frac{y_i}{s_i^{(l)}} \cdot s_i^{(l)} \cdot \left( 1_{\{i=j\}} - s_j^{(l)} \right)$$

$$= - \sum_{i=0}^{n^{(l)}-1} y_i \cdot \left( 1_{\{i=j\}} - s_j^{(l)} \right)$$

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial z_j^{(l)}} = - \sum_{i=0}^{n^{(l)}-1} y_i \cdot \left( 1_{\{i=j\}} - s_j^{(l)} \right)$$

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\begin{aligned}\frac{\partial C}{\partial z_j^{(l)}} &= - \sum_{i=0}^{n^{(l)}-1} y_i \cdot \left( 1_{\{i=j\}} - s_j^{(l)} \right) \\ &= - \left( \sum_{i=0}^{n^{(l)}-1} y_i \cdot 1_{\{i=j\}} - \sum_{i=0}^{n^{(l)}-1} y_i \cdot s_j^{(l)} \right)\end{aligned}$$

Mithilfe des Distributivgesetzes  
formen wir die Summe um.

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial z_j^{(l)}} = - \sum_{i=0}^{n^{(l)}-1} y_i \cdot \left( 1_{\{i=j\}} - s_j^{(l)} \right)$$

$$= - \left( \sum_{i=0}^{n^{(l)}-1} y_i \cdot 1_{\{i=j\}} - \sum_{i=0}^{n^{(l)}-1} y_i \cdot s_j^{(l)} \right)$$

$$= \sum_{i=0}^{n^{(l)}-1} y_i \cdot s_j^{(l)} - \sum_{i=0}^{n^{(l)}-1} y_i \cdot 1_{\{i=j\}}$$

Die Klammer lösen wir auf nach der Regel:

$$-(a - b) = -a + b = b - a$$

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial z_j^{(l)}} = \sum_{i=0}^{n^{(l)}-1} y_i \cdot s_j^{(l)} - \sum_{i=0}^{n^{(l)}-1} y_i \cdot 1_{\{i=j\}}$$

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial z_j^{(l)}} = \sum_{i=0}^{n^{(l)}-1} y_i \cdot s_j^{(l)} - \sum_{i=0}^{n^{(l)}-1} y_i \cdot 1_{\{i=j\}}$$



Nur für den Fall  $i = j$  wird der zweite Faktor in dieser Summe 1, sonst ist er 0. Also wird das Ergebnis der Summe immer  $y_j$  sein.

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial z_j^{(l)}} = \sum_{i=0}^{n^{(l)}-1} y_i \cdot s_j^{(l)} - \sum_{i=0}^{n^{(l)}-1} y_i \cdot 1_{\{i=j\}}$$

$$= \left( \sum_{i=0}^{n^{(l)}-1} y_i \cdot s_j^{(l)} \right) - y_j$$

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial z_j^{(l)}} = \sum_{i=0}^{n^{(l)}-1} y_i \cdot s_j^{(l)} - \sum_{i=0}^{n^{(l)}-1} y_i \cdot 1_{\{i=j\}}$$

$$= \left( \sum_{i=0}^{n^{(l)}-1} y_i \cdot s_j^{(l)} \right) - y_j$$

Aus der ersten Summe können wir nach dem Distributivgesetz das  $s_j^{(l)}$  herausziehen, da es nicht von der Zählvariable  $i$  abhängt.

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial z_j^{(l)}} = \sum_{i=0}^{n^{(l)}-1} y_i \cdot s_j^{(l)} - \sum_{i=0}^{n^{(l)}-1} y_i \cdot 1_{\{i=j\}}$$

$$= \left( \sum_{i=0}^{n^{(l)}-1} y_i \cdot s_j^{(l)} \right) - y_j$$

$$= \left( s_j^{(l)} \cdot \sum_{i=0}^{n^{(l)}-1} y_i \right) - y_j$$

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial z_j^{(l)}} = \left( s_j^{(l)} \cdot \sum_{i=0}^{n^{(l)}-1} y_i \right) - y_j$$

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial z_j^{(l)}} = \left( s_j^{(l)} \cdot \sum_{i=0}^{n^{(l)}-1} y_i \right) - y_j$$

Der Output-Vektor  $Y$  ist One-Hot-kodiert: Genau ein Eintrag hat den Wert 1, alle anderen den Wert 0.

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial z_j^{(l)}} = \left( s_j^{(l)} \cdot \sum_{i=0}^{n^{(l)}-1} y_i \right) - y_j$$

Der Output-Vektor  $Y$  ist One-Hot-kodiert: Genau ein Eintrag hat den Wert 1, alle anderen den Wert 0.

Die Summe aller Einträge ist demzufolge ebenfalls immer 1.

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial z_j^{(l)}} = \left( s_j^{(l)} \cdot \sum_{i=0}^{n^{(l)}-1} y_i \right) - y_j$$

$$= s_j^{(l)} - y_j$$

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial z_j^{(l)}} = s_j^{(l)} - y_j$$

IV

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial z_j^{(l)}} = s_j^{(l)} - y_j$$

IV

Die ersten beiden Faktoren unserer Gesamtableitung vereinfachen sich also bei der Kombination aus Softmax und Cross-Entropy Loss für den Output-Layer auf diese simple Differenz.

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial z_j^{(l)}} = s_j^{(l)} - y_j$$

IV

$$\frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}} = a_k^{(l-1)}$$

2

Der hintere Faktor bleibt der gleiche, den wir schon aus Gleichung 2 kennen.

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \frac{\partial C}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}}$$

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

$$\frac{\partial C}{\partial z_j^{(l)}} = s_j^{(l)} - y_j$$

IV

$$\frac{\partial z_j^{(l)}}{\partial w_{jk}^{(l)}} = a_k^{(l-1)}$$

2

Aus den Gleichungen IV und 2 ergibt sich damit:

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \left( s_j^{(l)} - y_j \right) \cdot a_k^{(l-1)}$$

V

# Ableitung von Cross-Entropy Loss

Gesucht:  $\frac{\partial C}{\partial z_j^{(l)}}$

Diese Gleichung gilt aber nur, wenn:

- Layer  $l$  als Aktivierungsfunktion Softmax verwendet
- Layer  $l$  als Kostenfunktion Cross-Entropy Loss verwendet
- Alle erwarteten Output-Vektoren  $Y$  One-Hot-kodiert sind

$$\frac{\partial C}{\partial w_{jk}^{(l)}} = \left( s_j^{(l)} - y_j \right) \cdot a_k^{(l-1)}$$



# Ableitung von Cross-Entropy Loss

$$\frac{\partial C}{\partial z_j^{(l)}} = s_j^{(l)} - y_j$$

IV



```
# ...
error = prediction - Y
output_layer_derivative = 2 * error

for l in range(len(self.structure) - 1, 0, -1):
    if l == len(self.structure) - 1:
        if self.output_activation_func == softmax:
            partial_deltas[l][:] = error
        else:
            partial_deltas[l][:] = output_layer_derivative * \
                self.output_activation_func(self.weighted_sums[l], derivative=True)
    else:
        # ...
```

Um die neue Ableitung für Softmax-Layer zu implementieren, brauchen wir eine neue Fallunterscheidung für die verwendete Aktivierungsfunktion. Wir gehen hier davon aus, dass sie nur für den Output-Layer relevant ist.

# Ableitung von Cross-Entropy Loss

$$\frac{\partial C}{\partial z_j^{(l)}} = s_j^{(l)} - y_j$$

IV



```
# ...
error = prediction - Y
output_layer_derivative = 2 * error

for l in range(len(self.structure) - 1, 0, -1):
    if l == len(self.structure) - 1:
        if self.output_activation_func == softmax:
            partial_deltas[l][:] = error
        else:
            partial_deltas[l][:] = output_layer_derivative * \
                self.output_activation_func(self.weighted_sums[l], derivative=True)
    else:
        # ...
```

Wenn im Output-Layer die Softmax-Funktion zur Aktivierung verwendet wird, verwenden wir nach Gleichung IV einfach die Differenz aus berechnetem und erwartetem Output als partielle Ableitung.

# Ableitung von Cross-Entropy Loss



```
# ...
error = prediction - Y
output_layer_derivative = 2 * error

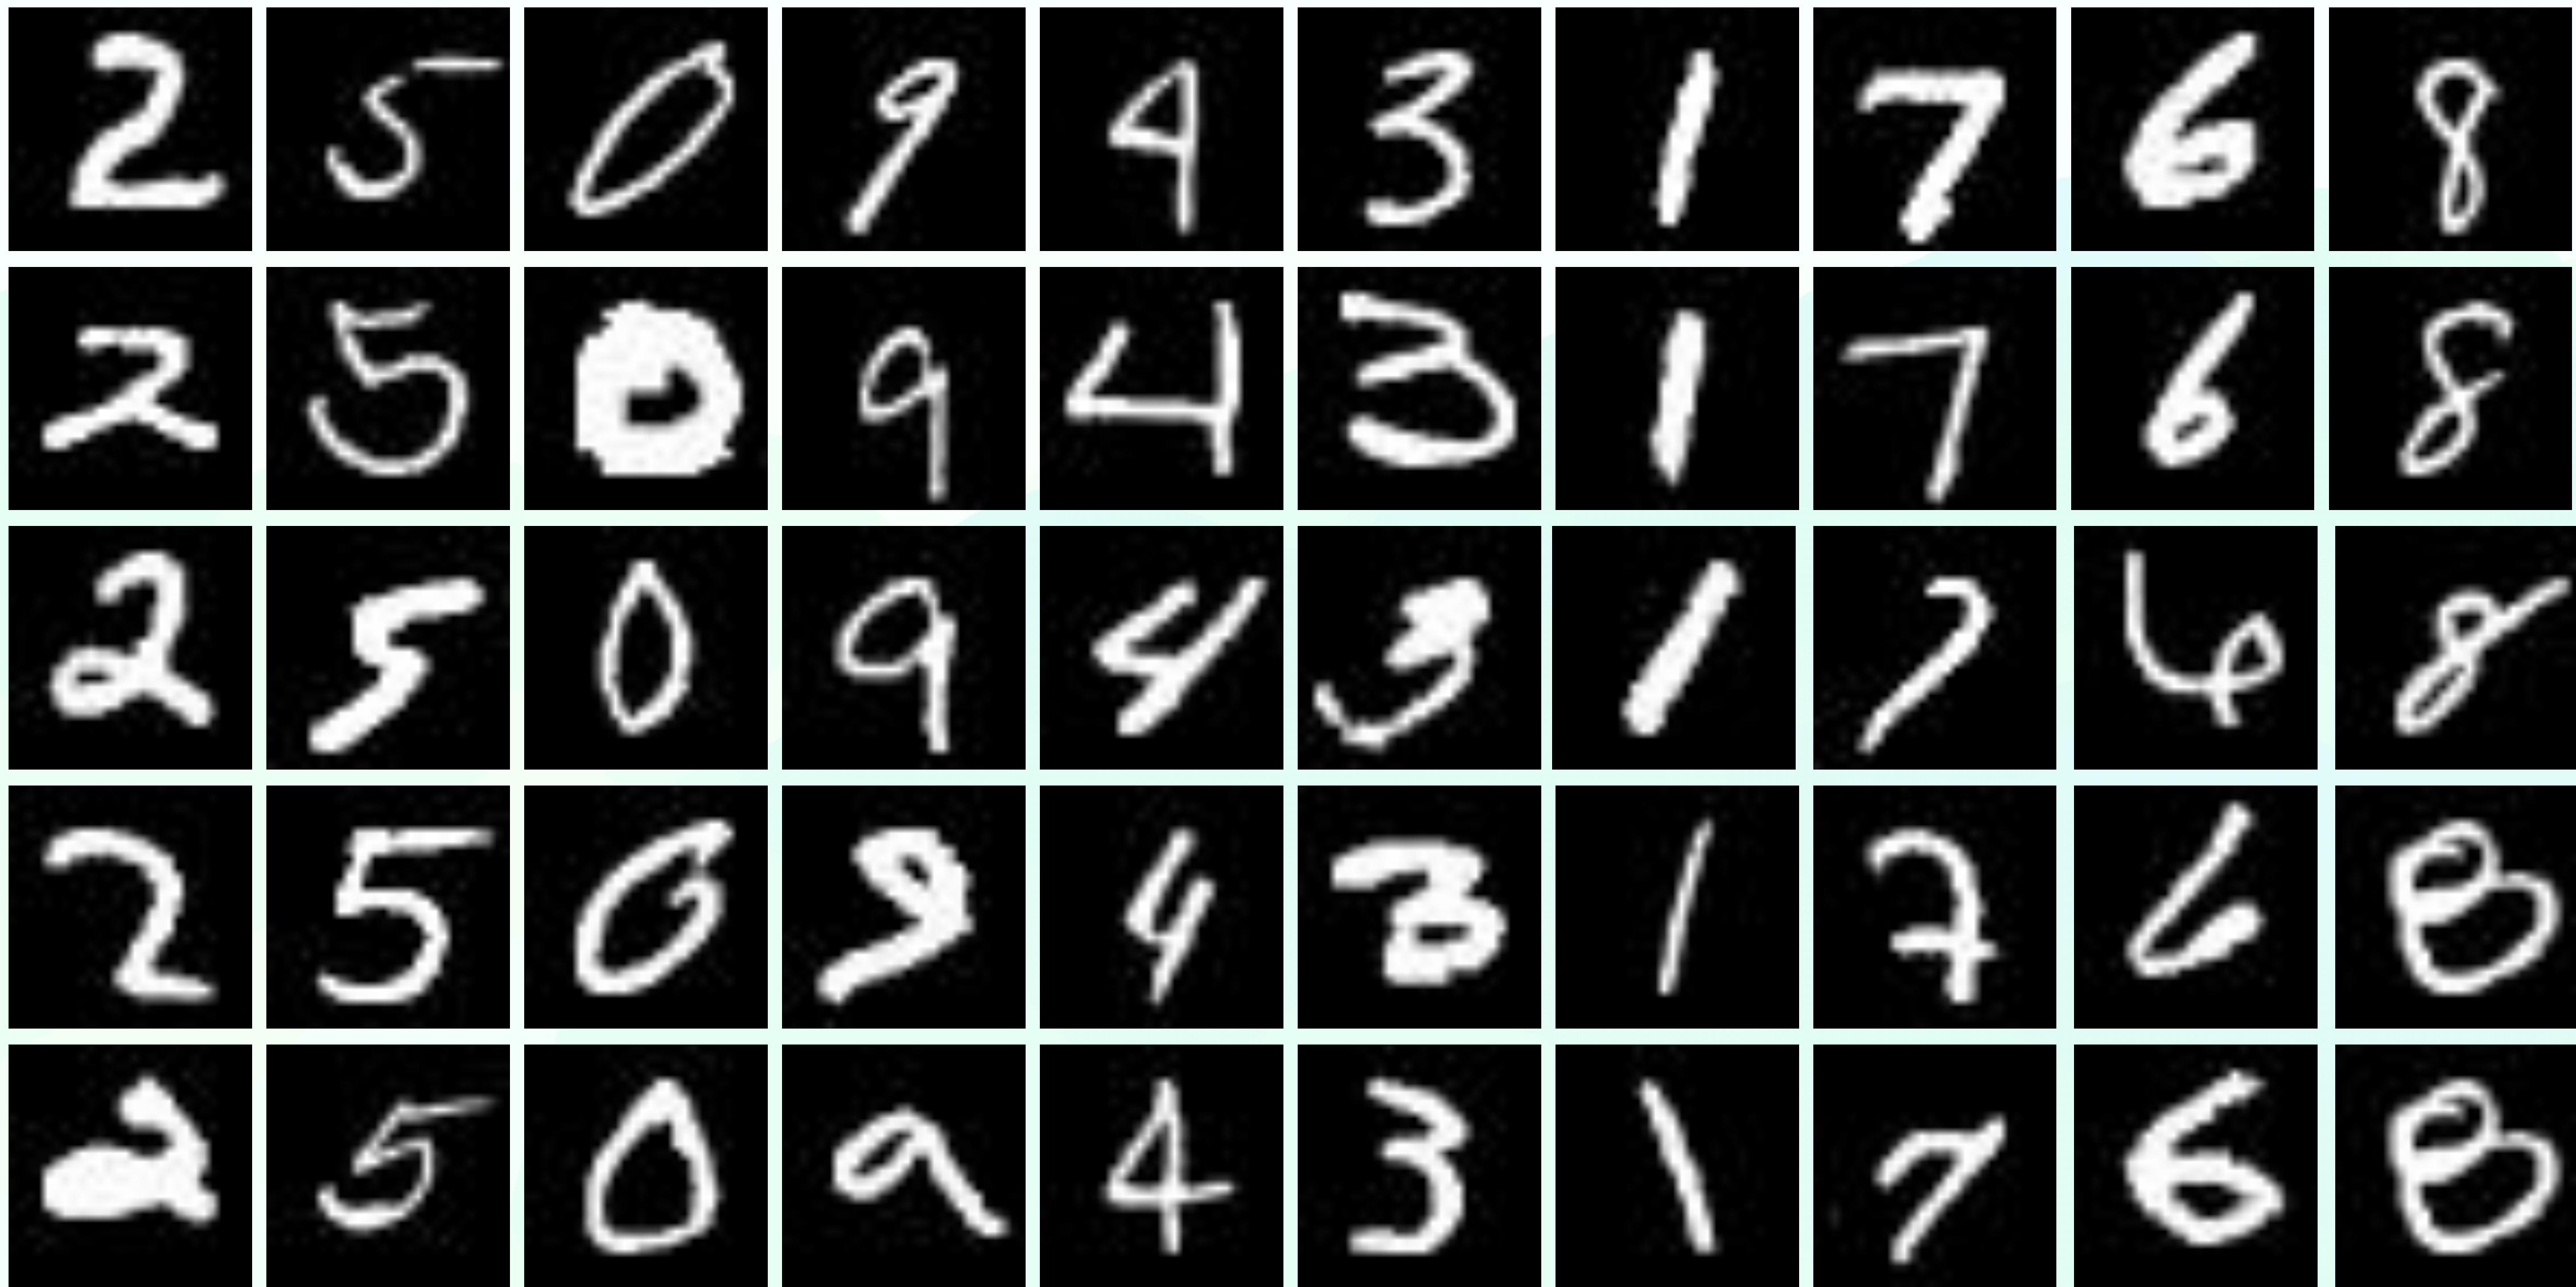
for l in range(len(self.structure) - 1, 0, -1):
    if l == len(self.structure) - 1:
        if self.output_activation_func == softmax:
            partial_deltas[l][:] = error
        else:
            partial_deltas[l][:] = output_layer_derivative * \
                self.output_activation_func(self.weighted_sums[l], derivative=True)
    else:
        # ...
```

Die alte Implementierung für andere Aktivierungsfunktionen bleibt erhalten und wandert jetzt in den `else`-Block.

# Ein Klassifikationsproblem trainieren: MNIST

- Datensatz mit Graustufenbildern handgeschriebener Ziffern
- Trainingsdaten: 60.000 Bilder, mit Labels
- Testdaten: 10.000 Bilder, ohne Labels
- Das „Hello World“ des Machine Learnings
- **Ziel:** Klassifikation eines Input-Bilds in die Klassen 0 bis 9

# Ein Klassifikationsproblem trainieren: MNIST



# Ein Klassifikationsproblem trainieren: MNIST

- Training eines Netzes mit derart vielen Trainingsdatensätzen erfordert wesentlich mehr Iterationen für ausreichende Konvergenz
- Jedes Bild hat  $28 \cdot 28 = 784$  Pixel, für jeden Pixel brauchen wir ein Eingangsneuron

# Ein Klassifikationsproblem trainieren: MNIST

- Training eines Netzes mit derart vielen Trainingsdatensätzen erfordert wesentlich mehr Iterationen für ausreichende Konvergenz
- Jedes Bild hat  $28 \cdot 28 = 784$  Pixel, für jeden Pixel brauchen wir ein Eingangsneuron
- Um die Komplexität zu bewältigen, soll unsere Klasse `NeuralNetwork` weitere Anforderungen erfüllen:
  - Jede Trainingsiteration soll nur über einen zufällig gewählten Teil der Trainingsdatensätze laufen (**Mini-Batches**), die genaue Anzahl soll parametrisierbar sein
  - Nach dem Training sollen die ermittelten Gewichte in einer Datei gespeichert und später wieder geladen werden können, um das zeitaufwändige Training nicht jedes Mal wiederholen zu müssen

# Mit Mini-Batches trainieren



```
def __init__(  
    self,  
    # ...  
    hidden_activation_func=relu,  
    batch_size=0  
):  
    # ...  
    self.hidden_activation_func = hidden_activation_func  
    self.batch_size = batch_size
```

Wir bauen zunächst einen neuen Konstruktor-Parameter für die Größe unserer Batches ein. Der Default-Wert 0 soll bedeuten, dass in jeder Iteration *alle* Trainingsdaten verwendet werden und kein Batching betrieben wird.

# Mit Mini-Batches trainieren

Da wir die Batches zufällig bestimmen wollen, importieren wir das Package `random`, damit wir es im nächsten Schritt verwenden können.

```
● ● ●  
import random
```

# Mit Mini-Batches trainieren



```
def train(self, training_data):
    # ...

    for i in range(self.n_iterations):
        training_batch = (
            training_data
            if self.batch_size == 0
            else random.sample(training_data, self.batch_size)
        )

        for (X, Y) in training_batch:
            # ...
```

Innerhalb der Iterationsschleife unserer `train`-Methode berechnen wir aus unseren Trainingsdaten ein Batch der gewünschten Größe, und führen die einzelnen Trainingsdurchläufe dann darauf aus.

# Mit Mini-Batches trainieren



```
def train(self, training_data):
    # ...

    for i in range(self.n_iterations):
        training_batch = (
            training_data
            if self.batch_size == 0
            else random.sample(training_data, self.batch_size)
        )

        for (X, Y) in training_batch:
            # ...
```

Als Batch benutzen wir die vollständigen Trainingsdaten, falls die `batch_size` mit `0` angegeben wurde. Andernfalls schneiden wir mit `random.sample` ein zufälliges Subset aus den Trainingsdaten aus.

# Mit Mini-Batches trainieren



```
def train(self, training_data):
    # ...

    for i in range(self.n_iterations):
        training_batch = (
            training_data
            if self.batch_size == 0
            else random.sample(training_data, self.batch_size)
        )

        for (X, Y) in training_batch:
            # ...
```

`random.sample` erwartet als Parameter zuerst die Liste und dann die Anzahl der zu wählenden Elemente daraus. Der Rückgabewert ist dann wieder eine Liste mit dieser Anzahl an Elementen.

# Mit Mini-Batches trainieren



```
def train(self, training_data):
    # ...

    for i in range(self.n_iterations):
        training_batch = (
            training_data
            if self.batch_size == 0
            else random.sample(training_data, self.batch_size)
        )

        for (X, Y) in training_batch:
            # ...
```

Wir passen dann auch den Kopf dieser `for`-Schleife an und iterieren nur noch über das so ermittelte Trainings-Batch und nicht mehr über alle Trainingsdaten.

# Mit Mini-Batches trainieren

Zum Schluss sorgen wir auch noch dafür, dass der Mittelwert der Gewichtsanpassungen korrekt bleibt. Wenn wir nur noch über das Subset in `training_batch` iterieren, dürfen wir natürlich  $\Delta W$  nur durch dessen Anzahl an Elementen teilen.

```
● ● ●

for (X, Y) in training_batch:
    # ...

    for l in range(1, len(delta_W)):
        self.weights[l][:] += delta_W[l] / len(training_batch)
        delta_W[l][:] = 0
```

# Speichern und Laden trainierter Gewichte



```
def __init__(  
    self,  
    structure=None,  
    # ...  
    batch_size=0  
):  
    self.structure = structure  
    # ...  
    self.batch_size = batch_size  
  
    if isinstance(self.structure, list):  
        self.__init_layers()  
        self.__init_weights()
```

# Speichern und Laden trainierter Gewichte



```
def __init__(  
    self,  
    structure=None,  
    # ...  
    batch_size=0  
):  
    self.structure = structure  
    # ...  
    self.batch_size = batch_size  
  
    if isinstance(self.structure, list):  
        self.__init_layers()  
        self.__init_weights()
```

Um ein `NeuralNetwork`-Objekt auch anhand gespeicherter Gewichte laden zu können, modifizieren wir zuerst unseren Konstruktor ein wenig und machen den `structure`-Parameter optional. Wird keine Struktur (also `None`) übergeben, soll diese später aus den gespeicherten Gewichten rekonstruiert werden.

# Speichern und Laden trainierter Gewichte



```
def __init__(  
    self,  
    structure=None,  
    # ...  
    batch_size=0  
):  
    self.structure = structure  
    # ...  
    self.batch_size = batch_size  
  
    if isinstance(self.structure, list):  
        self.__init_layers()  
        self.__init_weights()
```

Die bestehenden Aufrufe der Initialisierungsfunktionen führen wir dann nur noch aus, wenn im `structure`-Parameter eine Liste übergeben wurde (also nicht `None`).

# Speichern und Laden trainierter Gewichte



```
def save_to_file(self, filename):  
    numpy.savez(filename, *self.weights[1:])
```

# Speichern und Laden trainierter Gewichte



```
def save_to_file(self, filename):  
    numpy.savez(filename, *self.weights[1:])
```

Die Klasse bekommt dann eine weitere Methode, die zum Speichern der trainierten Gewichte aufgerufen werden kann. Als Parameter soll ihr ein Dateiname übergeben werden können.

# Speichern und Laden trainierter Gewichte



```
def save_to_file(self, filename):  
    numpy.savez(filename, *self.weights[1:])
```

numpy bietet die Funktion `savez` zum Speichern einer Liste von Arrays (also Vektoren oder Matrizen) in einer Datei. Als Namen für die Datei verwenden wir den übergebenen Parameter.

# Speichern und Laden trainierter Gewichte



```
def save_to_file(self, filename):
    numpy.savez(filename, *self.weights[1:])
```

Wichtig ist der Asterisk vor `self.weights`: Mit ihm verteilen wir die Liste der Gewichtsmatrizen auf mehrere Funktionsparameter, statt die ganze Liste als einen Parameter zu übergeben. `savez` erwartet die Arrays einzeln, und nicht in eine Liste verpackt.

# Speichern und Laden trainierter Gewichte



```
def save_to_file(self, filename):  
    numpy.savez(filename, *self.weights[1:])
```

Außerdem soll das Dummy-Element an Index 0 der Liste nicht mitgespeichert werden. Daher überspringen wir es mit einem Slice.

# Speichern und Laden trainierter Gewichte



```
def load_from_file(self, filename):
    loaded_weights = numpy.load(filename)
    self.weights = [None] + [loaded_weights[key] for key in loaded_weights]
    self.structure = []

    for l in range(1, len(self.weights)):
        self.structure.append(self.weights[l].shape[1] - 1)

    self.structure.append(self.weights[-1].shape[0])
    self.__init_layers()
```

# Speichern und Laden trainierter Gewichte



```
def load_from_file(self, filename):
    loaded_weights = numpy.load(filename)
    self.weights = [None] + [loaded_weights[key] for key in loaded_weights]
    self.structure = []

    for l in range(1, len(self.weights)):
        self.structure.append(self.weights[l].shape[1] - 1)

    self.structure.append(self.weights[-1].shape[0])
    self.__init_layers()
```

Zuletzt brauchen wir auch noch eine Methode, um aus den gespeicherten Gewichten das neuronale Netz zu rekonstruieren. Auch hier übergeben wir den Namen der Datei, in der unsere Gewichtsmatrizen gespeichert sind.

# Speichern und Laden trainierter Gewichte



```
def load_from_file(self, filename):
    loaded_weights = numpy.load(filename)
    self.weights = [None] + [loaded_weights[key] for key in loaded_weights]
    self.structure = []

    for l in range(1, len(self.weights)):
        self.structure.append(self.weights[l].shape[1] - 1)

    self.structure.append(self.weights[-1].shape[0])
    self.__init_layers()
```

Mit `numpy.load` können wir die gespeicherten Arrays wiederherstellen. Wir bekommen sie in einem Dictionary mit den Keys `arr_0`, `arr_1` usw.

# Speichern und Laden trainierter Gewichte



Um die Gewichtsmatrizen in einer einfachen flachen Liste zu erhalten, verwenden wir die List-Comprehension-Syntax von Python.

```
def load_from_file(self, filename):
    loaded_weights = numpy.load(filename)
    self.weights = [None] + [loaded_weights[key] for key in loaded_weights]
    self.structure = []

    for l in range(1, len(self.weights)):
        self.structure.append(self.weights[l].shape[1] - 1)

    self.structure.append(self.weights[-1].shape[0])
    self.__init_layers()
```

# Speichern und Laden trainierter Gewichte



Für jeden Key, den wir im geladenen Dictionary finden, lesen wir den entsprechenden Eintrag aus dem Dictionary und schreiben ihn an die nächste freie Stelle der Ergebnisliste.

```
def load_from_file(self, filename):
    loaded_weights = numpy.load(filename)
    self.weights = [None] + [loaded_weights[key] for key in loaded_weights]
    self.structure = []

    for l in range(1, len(self.weights)):
        self.structure.append(self.weights[l].shape[1] - 1)

    self.structure.append(self.weights[-1].shape[0])
    self.__init_layers()
```

# Speichern und Laden trainierter Gewichte



```
def load_from_file(self, filename):
    loaded_weights = numpy.load(filename)
    self.weights = [None] + [loaded_weights[key] for key in loaded_weights]
    self.structure = []

    for l in range(1, len(self.weights)):
        self.structure.append(self.weights[l].shape[1] - 1)

    self.structure.append(self.weights[-1].shape[0])
    self.__init_layers()
```

Durch Verkettung mit dem +-Operator schreiben wir auch wieder das Dummy-Element an den Anfang der Ergebnisliste, um die korrekte Indizierung der Gewichtsmatrizen zu gewährleisten.

# Speichern und Laden trainierter Gewichte



```
def load_from_file(self, filename):
    loaded_weights = numpy.load(filename)
    self.weights = [None] + [loaded_weights[key] for key in loaded_weights]
    self.structure = []

    for l in range(1, len(self.weights)):
        self.structure.append(self.weights[l].shape[1] - 1)

    self.structure.append(self.weights[-1].shape[0])
    self.__init_layers()
```

In `self.weights` steht anschließend wieder die originale Liste von Gewichtsmatrizen, die das zuvor trainierte Netzwerk erzeugt hat.

# Speichern und Laden trainierter Gewichte



```
def load_from_file(self, filename):
    loaded_weights = numpy.load(filename)
    self.weights = [None] + [loaded_weights[key] for key in loaded_weights]
    self.structure = []

    for l in range(1, len(self.weights)):
        self.structure.append(self.weights[l].shape[1] - 1)

    self.structure.append(self.weights[-1].shape[0])
    self.__init_layers()
```

Aus den so geladenen Gewichtsmatrizen wollen wir nun die Struktur des Netzes rekonstruieren. Wir initialisieren `self.structure` als leere Liste, die wir nach und nach befüllen.

# Speichern und Laden trainierter Gewichte



```
def load_from_file(self, filename):
    loaded_weights = numpy.load(filename)
    self.weights = [None] + [loaded_weights[key] for key in loaded_weights]
    self.structure = []

    for l in range(1, len(self.weights)):
        self.structure.append(self.weights[l].shape[1] - 1)

    self.structure.append(self.weights[-1].shape[0])
    self.__init_layers()
```

Wir iterieren durch die Gewichtsmatrizen, um daraus die benötigten Anzahlen der Neuronen pro Layer auszulesen. Wir beginnen bei Index 1, weil an Index 0 ein Dummy-Element steht, das wir nur aus Gründen der konsistenten Indizierung angelegt haben.

# Speichern und Laden trainierter Gewichte



```
def load_from_file(self, filename):
    loaded_weights = numpy.load(filename)
    self.weights = [None] + [loaded_weights[key] for key in loaded_weights]
    self.structure = []

    for l in range(1, len(self.weights)):
        self.structure.append(self.weights[l].shape[1] - 1)

    self.structure.append(self.weights[-1].shape[0])
    self.__init_layers()
```

Pro Layer wird eine Zahl in die `structure`-Liste eingefügt. Dazu lesen wir aus der jeweiligen Gewichtsmatrix die Anzahl der Spalten (zweite Dimension, also Index 1) und ziehen davon 1 ab, da wir das Bias-Neuron ignorieren wollen.

# Speichern und Laden trainierter Gewichte



```
def load_from_file(self, filename):
    loaded_weights = numpy.load(filename)
    self.weights = [None] + [loaded_weights[key] for key in loaded_weights]
    self.structure = []

    for l in range(1, len(self.weights)):
        self.structure.append(self.weights[l].shape[1] - 1)

    self.structure.append(self.weights[-1].shape[0])
    self.__init_layers()
```

Mit `shape` erhalten wir ein Tupel, dessen Einträge die Zeilen- und Spaltenanzahl der Matrix sind. An Index `1` steht also die Anzahl der Spalten und damit die Anzahl der eingehenden Neuronen.

# Speichern und Laden trainierter Gewichte



```
def load_from_file(self, filename):
    loaded_weights = numpy.load(filename)
    self.weights = [None] + [loaded_weights[key] for key in loaded_weights]
    self.structure = []

    for l in range(1, len(self.weights)):
        self.structure.append(self.weights[l].shape[1] - 1)

    self.structure.append(self.weights[-1].shape[0])
    self.__init_layers()
```

Für den Output-Layer brauchen wir eine Sonderbehandlung, da es nach ihm keine Gewichtsmatrix mehr gibt, aus der wir die Zahl der eingehenden Neuronen auslesen könnten.

Wir lesen stattdessen die Anzahl der Zeilen der allerletzten Matrix aus. Diese Anzahl gibt an, wie viele Gewichte zum letzten Layer führen und damit wie viele Output-Neuronen es gibt.

# Speichern und Laden trainierter Gewichte

```
● ● ●

def load_from_file(self, filename):
    loaded_weights = numpy.load(filename)
    self.weights = [None] + [loaded_weights[key] for key in loaded_weights]
    self.structure = []

    for l in range(1, len(self.weights)):
        self.structure.append(self.weights[l].shape[1] - 1)

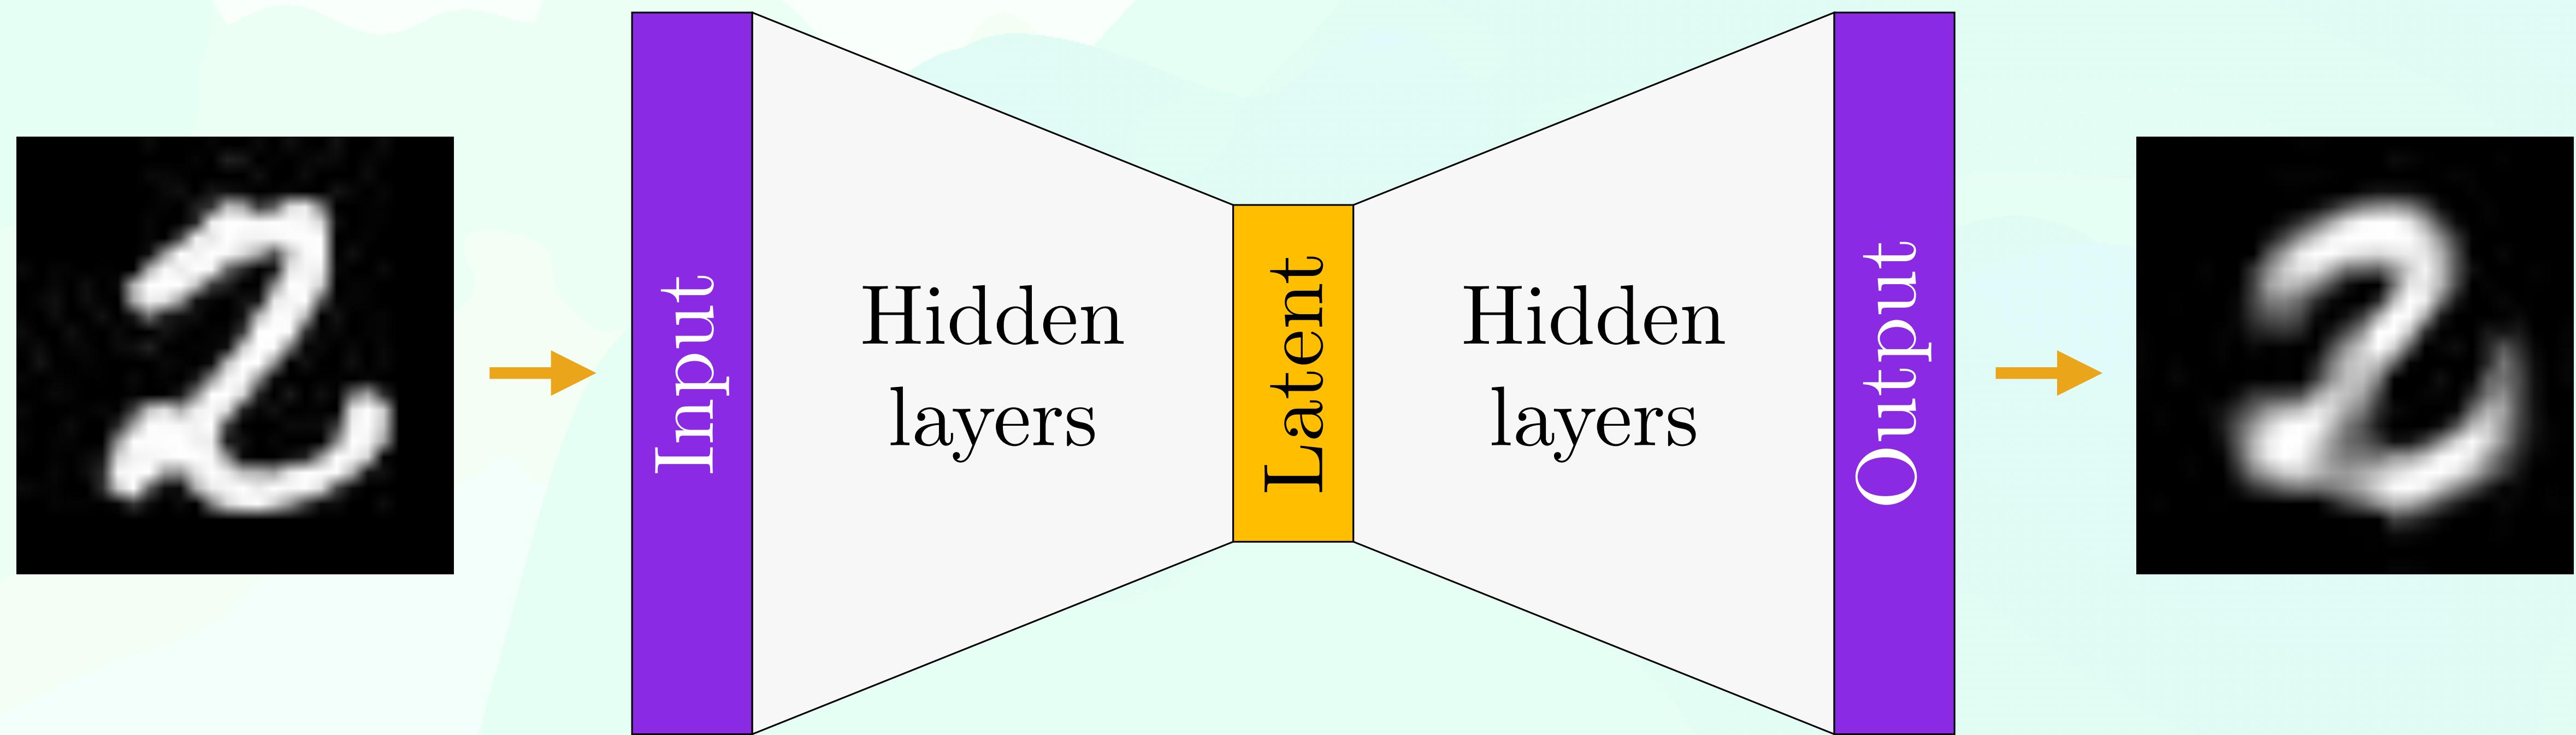
    self.structure.append(self.weights[-1].shape[0])
    self.__init_layers()
```

Nachdem wir die `structure`-Liste so aufgebaut haben, können wir danach unsere bestehende Methode `__init_layers` aufrufen. Sie wird die Liste wie gehabt verwenden, um die Vektoren für gewichtete Summen und Aktivierungen anzulegen.

# Neuronale Netze als Autoencoder

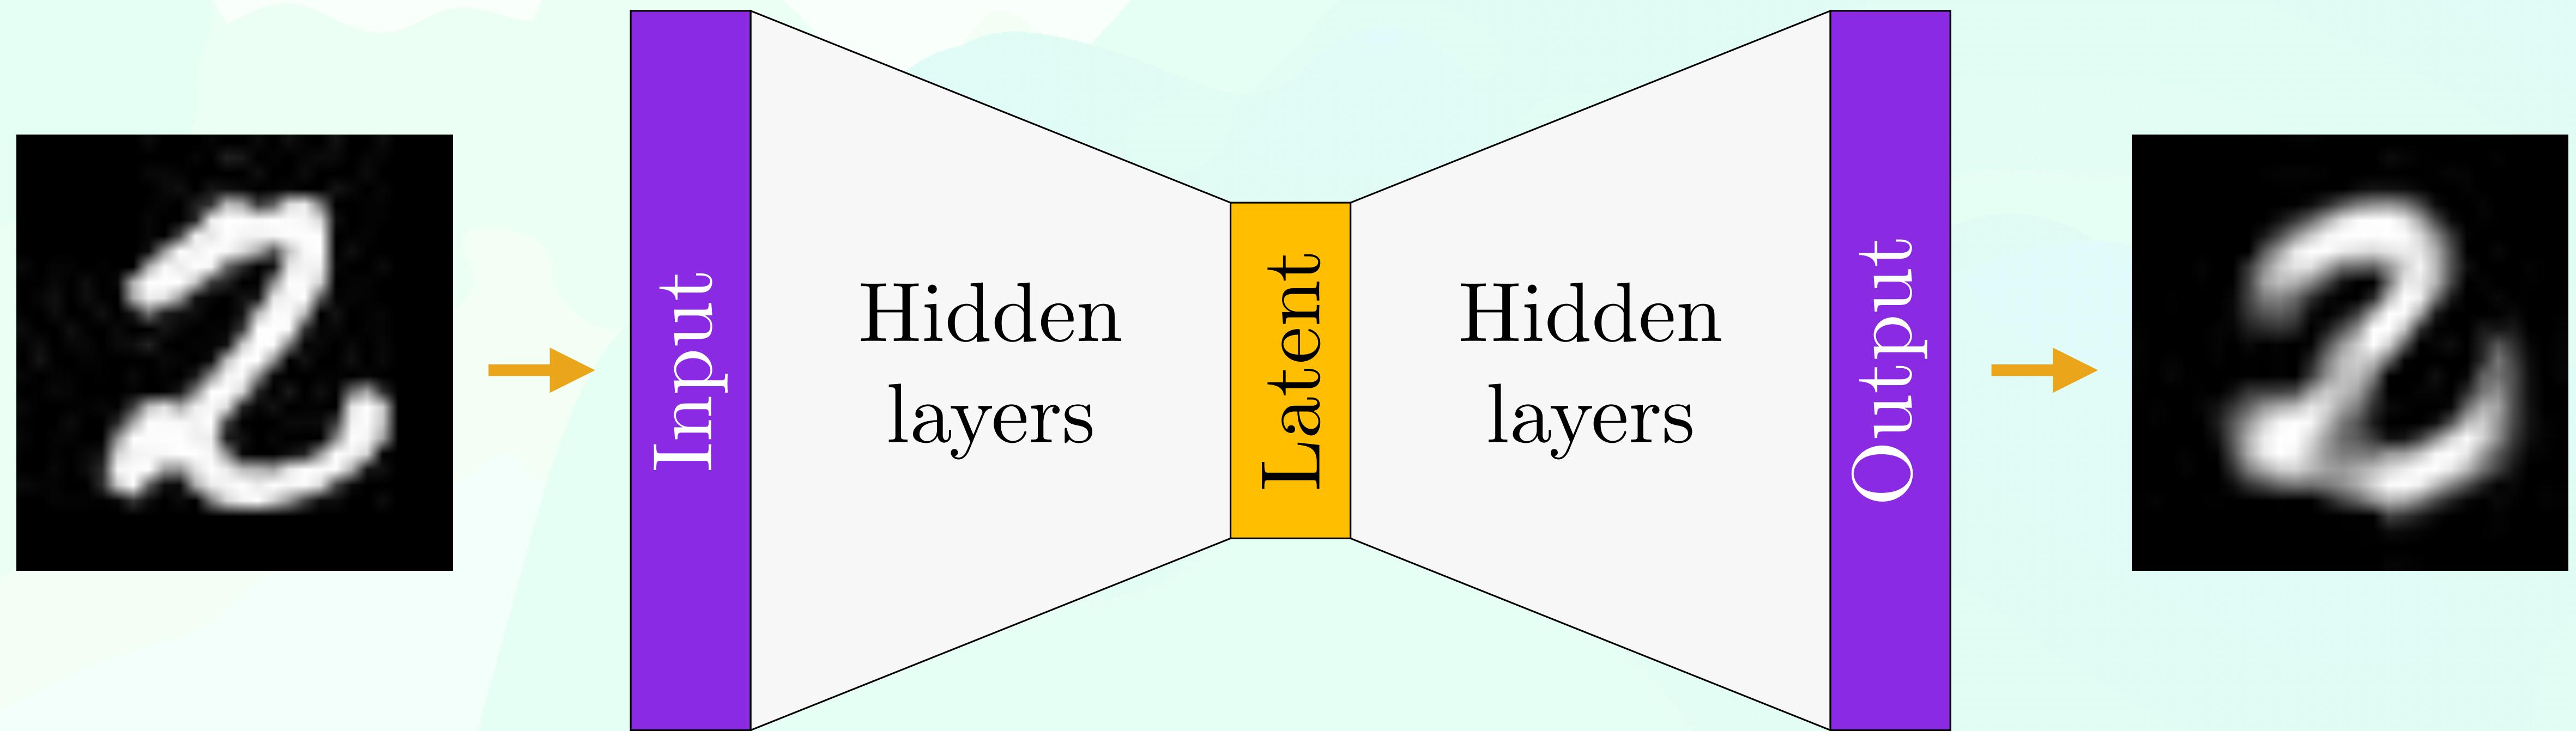
# Neuronale Netze als Autoencoder

- Idee: Output des Netzes soll möglichst identisch zum Input sein (Unsupervised bzw. Self-Supervised Learning)
- Zwischen Input- und Output-Layer hat das Netz dabei ein „Bottleneck“, um möglichst effiziente Darstellung der Input-Daten zu lernen

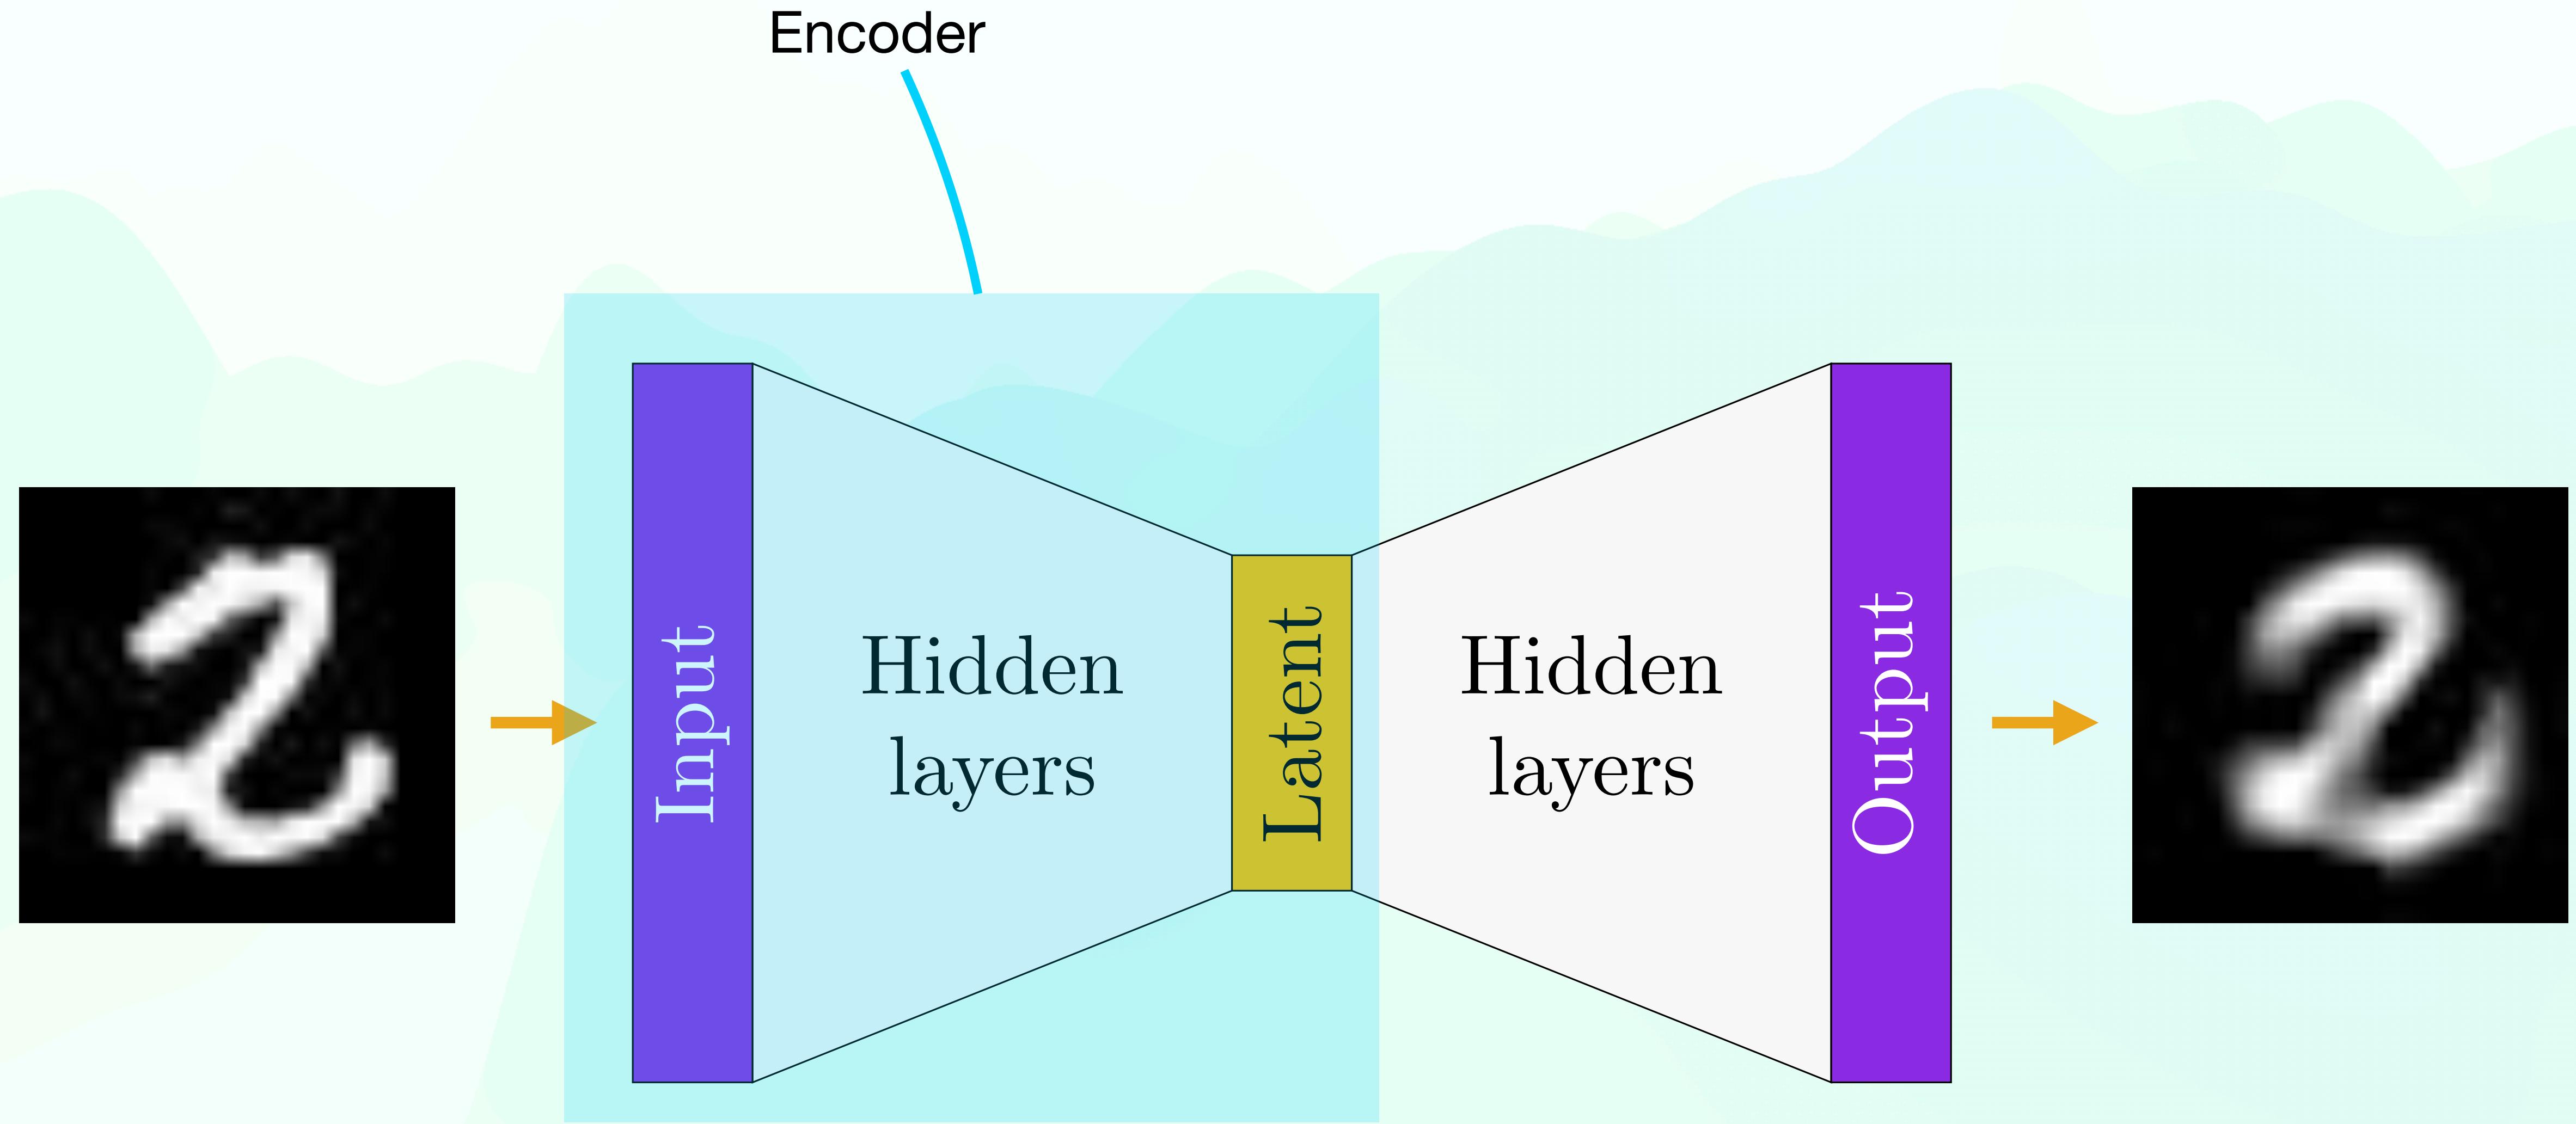


# Neuronale Netze als Autoencoder

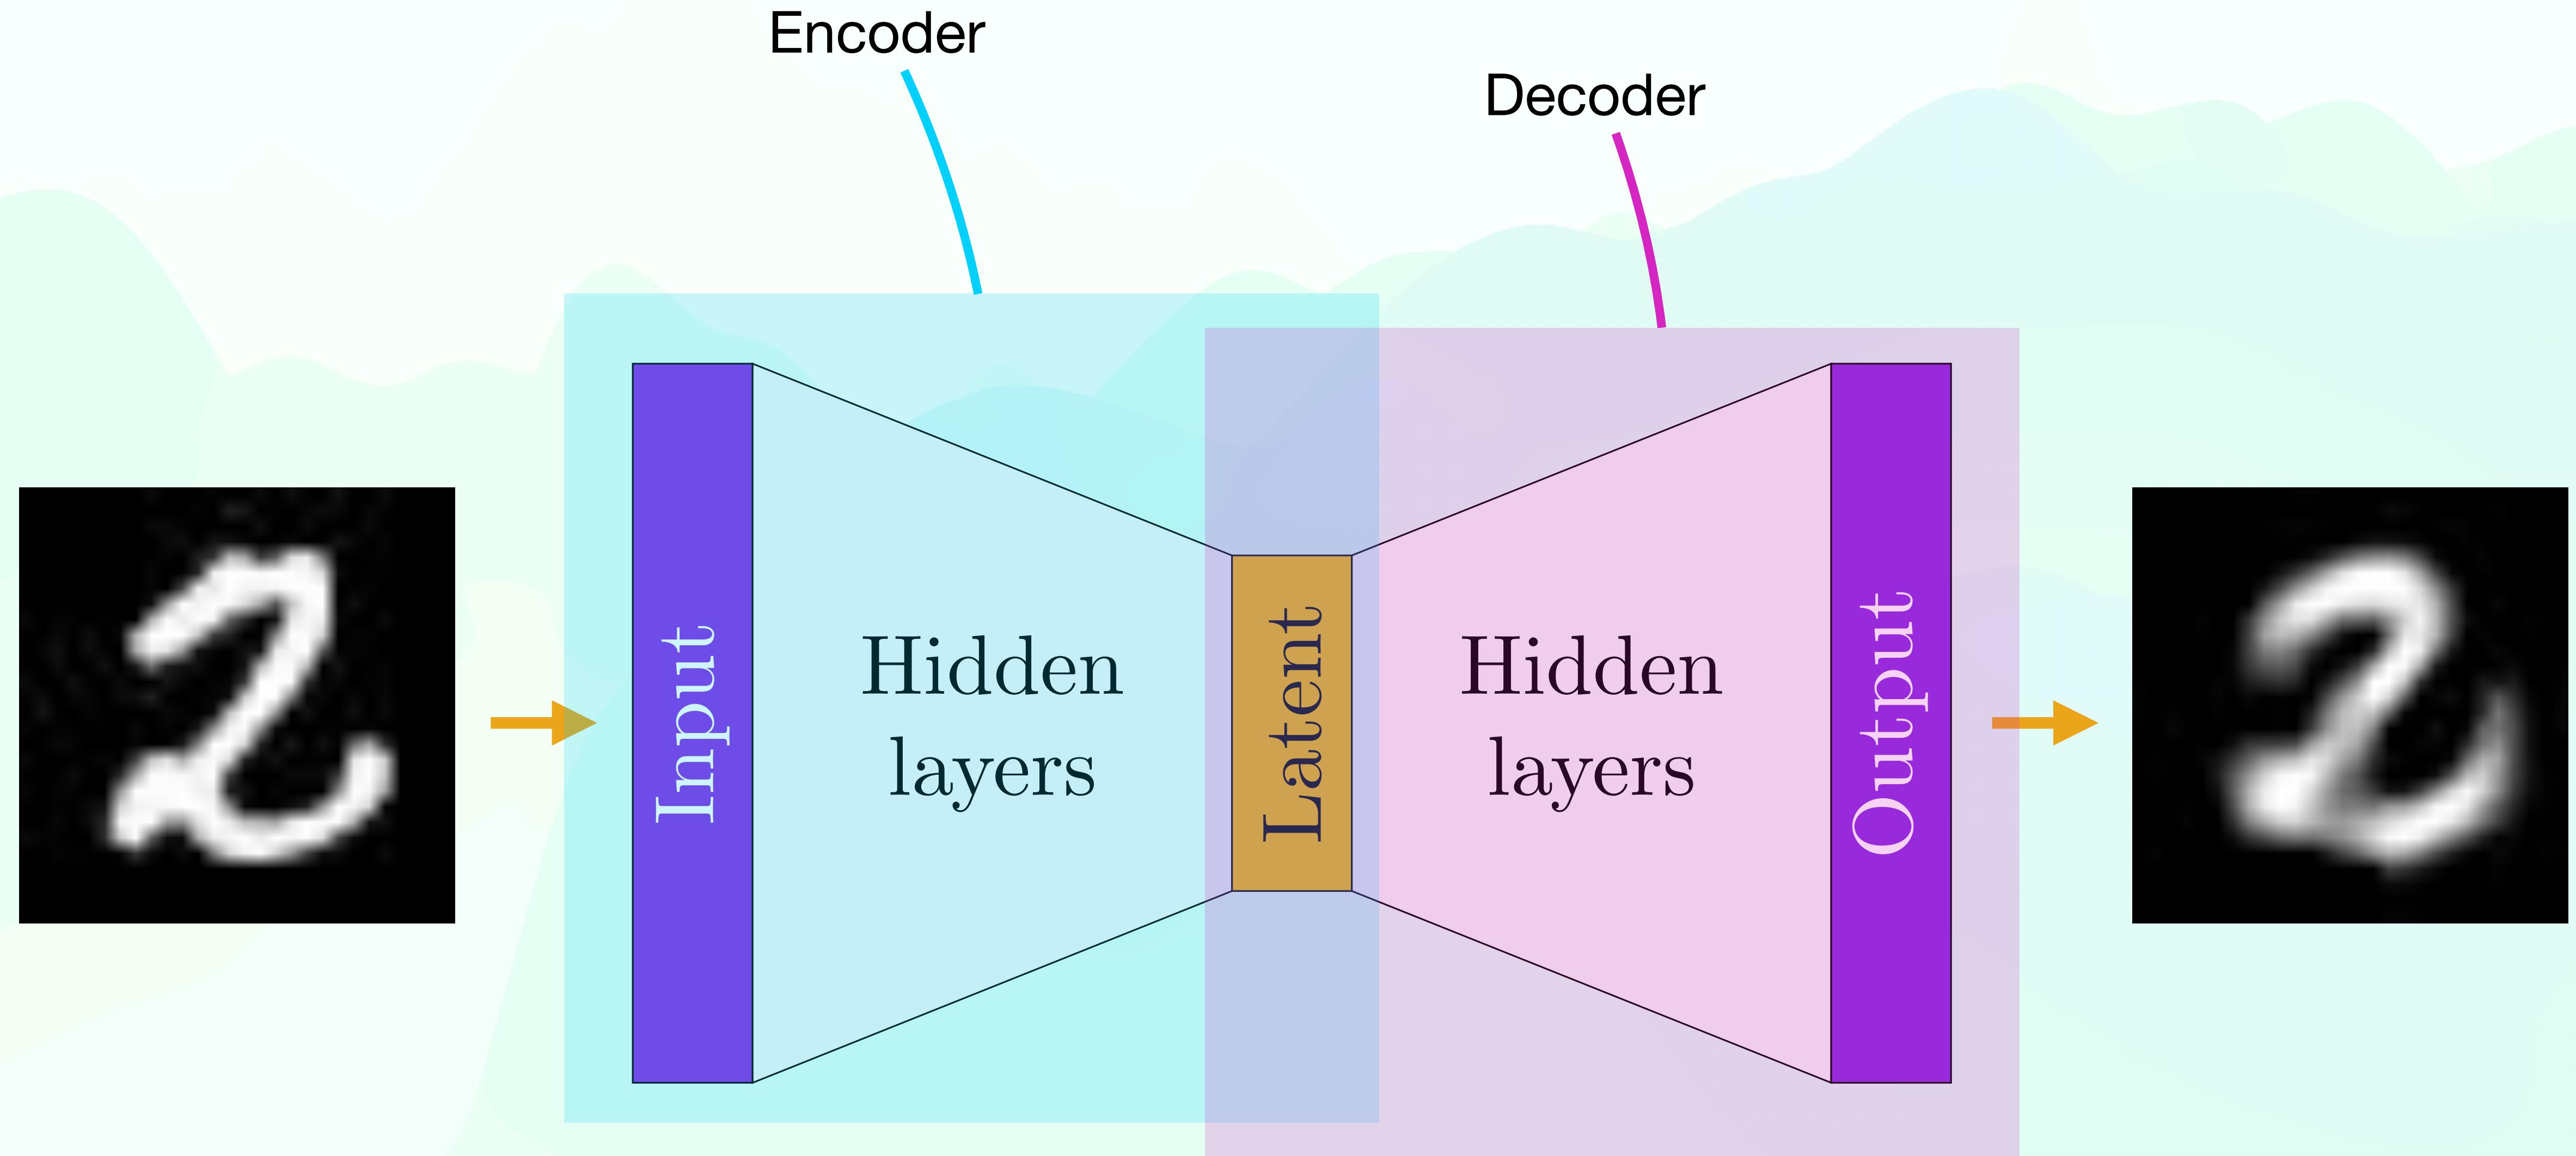
- Die Engstelle im Latent-Layer führt zu **Dimensionalitätsreduktion**
- Latent-Darstellung eines Inputs nennt man auch **Embedding**



# Neuronale Netze als Autoencoder

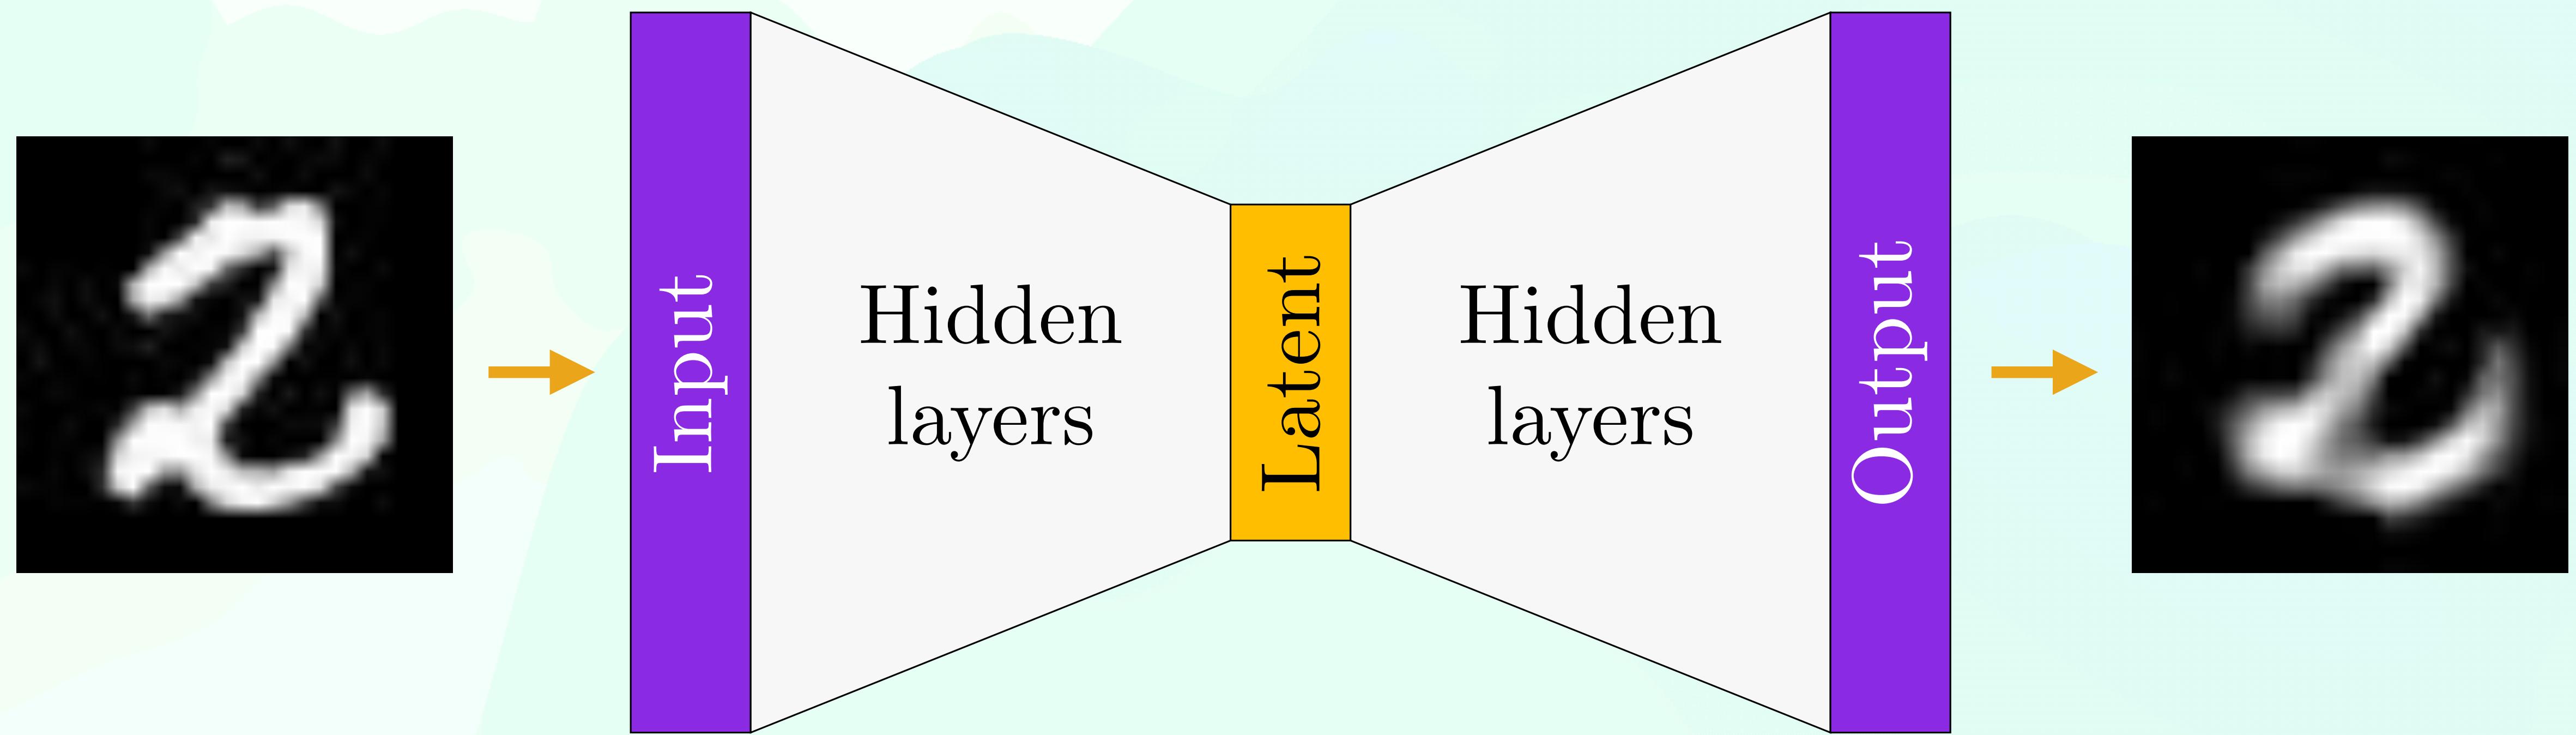


# Neuronale Netze als Autoencoder



# Neuronale Netze als Autoencoder

- Wir wollen herausfinden, wie sich Änderungen der Aktivierungen des Latent-Layers auf die Vorhersage auswirken
- Welches Latent-Neuron steht für welches Feature im Input-Space?



# Erweiterung für Vorhersagen von Latent-Vektoren



Wir müssen unsere `predict`-Methode anpassen. Sie soll mit dem übergebenen Vektor nicht mehr unbedingt nur den Input-Layer bestücken, sondern einen beliebigen Layer des Netzes. Die Vorhersage soll dann von dort ausgehend wie gehabt berechnet werden.

```
def predict(self, X, start_layer=0):
    if len(X) != self.structure[start_layer]:
        raise Exception("Falsche Anzahl an Input-Werten übergeben")

    self.activations[start_layer][1:] = X

    for l in range(start_layer + 1, len(self.structure)):
        self.weighted_sums[l][:] = numpy.matmul(self.weights[l], self.activations[l-1])
        # ...
```

# Erweiterung für Vorhersagen von Latent-Vektoren



Zunächst fügen wir der Methode dafür einen optionalen Parameter `start_layer` hinzu. Er steht für den Layer-Index, ab dem die Berechnung der Vorhersage beginnen soll.

```
def predict(self, X, start_layer=0):
    if len(X) != self.structure[start_layer]:
        raise Exception("Falsche Anzahl an Input-Werten übergeben")

    self.activations[start_layer][1:] = X

    for l in range(start_layer + 1, len(self.structure)):
        self.weighted_sums[l][:] = numpy.matmul(self.weights[l], self.activations[l-1])
        # ...
```

# Erweiterung für Vorhersagen von Latent-Vektoren



Der Layer, der mit den übergebenen Werten belegt werden soll, muss natürlich vorher auch für die Formatprüfung ausgewählt werden. Wir müssen hier also die  $0$  durch den neuen Parameter ersetzen.

```
def predict(self, X, start_layer=0):
    if len(X) != self.structure[start_layer]:
        raise Exception("Falsche Anzahl an Input-Werten übergeben")

    self.activations[start_layer][1:] = X

    for l in range(start_layer + 1, len(self.structure)):
        self.weighted_sums[l][:] = numpy.matmul(self.weights[l], self.activations[l-1])
        # ...
```

# Erweiterung für Vorhersagen von Latent-Vektoren



Dasselbe gilt dann auch für das eigentliche Überschreiben des Layers. Wo hier vorher stets der Input-Layer (Index 0) ausgewählt wurde, muss der Index jetzt aus dem Parameter ausgelesen werden.

```
def predict(self, X, start_layer=0):
    if len(X) != self.structure[start_layer]:
        raise Exception("Falsche Anzahl an Input-Werten übergeben")

    self.activations[start_layer][1:] = X

    for l in range(start_layer + 1, len(self.structure)):
        self.weighted_sums[l][:] = numpy.matmul(self.weights[l], self.activations[l-1])
        # ...
```

# Erweiterung für Vorhersagen von Latent-Vektoren



Die Feedforward-Berechnung, die sich dann ergibt, soll natürlich auch erst vom so überschriebenen Layer aus beginnen. Die `for`-Schleife zählt also nun erst ab dem darauffolgenden Index, denn der gibt den ersten Layer an, für den wir gewichtete Summen und Aktivierungen berechnen müssen.

```
def predict(self, X, start_layer=0):
    if len(X) != self.structure[start_layer]:
        raise Exception("Falsche Anzahl an Input-Werten übergeben")

    self.activations[start_layer][1:] = X

    for l in range(start_layer + 1, len(self.structure)):
        self.weighted_sums[l][:] = numpy.matmul(self.weights[l], self.activations[l-1])
        # ...
```





# Empfehlungen

# Empfehlungen

## Videoserie „Neural Networks“ von 3Blue1Brown

								Average over all training data ...	
$w_0$	-0.08	+0.02	-0.02	+0.11	-0.05	-0.14	...	→	-0.08
$w_1$	-0.11	+0.11	+0.07	+0.02	+0.09	+0.05	...	→	+0.12
$w_2$	-0.07	-0.04	-0.01	+0.02	+0.13	-0.15	...	→	-0.06
:	:	:	:	:	:	:	..		:
$w_{13,001}$	+0.13	+0.08	-0.06	-0.09	-0.02	+0.04	...	→	+0.04

**Neural networks**

3Blue1Brown - 1/8

Neural Networks From the ground up 18:40

But what is a neural network? | Deep learning chapter 1

3Blue1Brown

Gradient descent, how neural networks learn | DL2

3Blue1Brown

How machines learn 20:33

Backpropagation, step-by-step | DL3

3Blue1Brown

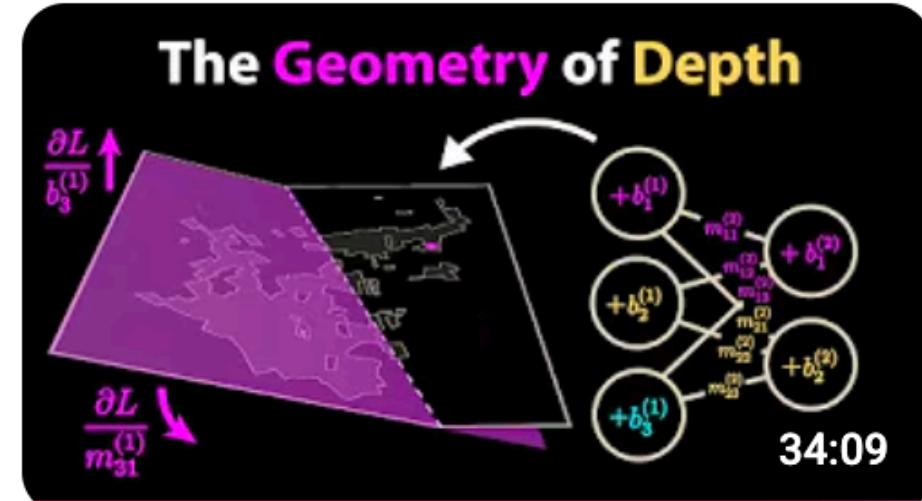
Backpropagation calculus | DL4

3Blue1Brown

# Empfehlungen

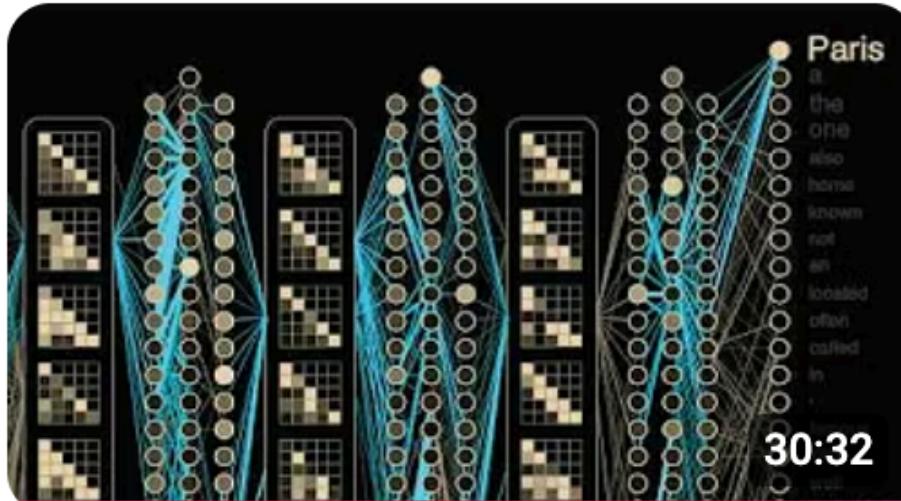
## Youtube-Kanal „Welch Labs“

The screenshot shows the Welch Labs YouTube channel page. It features a large circular profile picture with a white 'W' on a blue square background. The channel name "Welch Labs" is displayed in a large, bold, black font. Below it, the handle "@WelchLabsVideo" and subscriber count "774.000 Abonnenten" are shown, along with the number of videos "128 Videos". A description "Great math & science stories. ...mehr" follows, along with a link "welchlabs.com/resources und 1 weiterer Link". A "Abonniert" button with a bell icon is present. Navigation tabs include "Übersicht", "Videos" (which is underlined), "Shorts", "Playlists", and "Beiträge". A search bar is at the top right. Below the tabs, sorting options "Neueste", "Beliebt" (selected), and "Älteste" are shown.



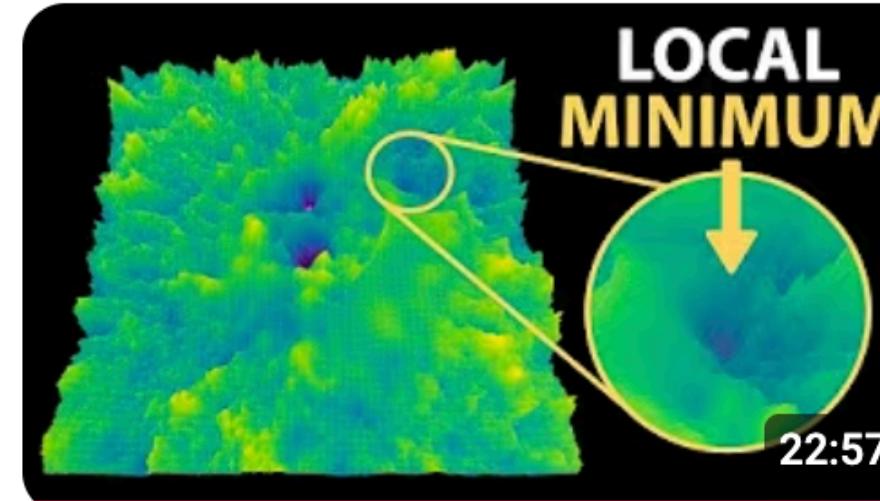
Warum Deep Learning  
außergewöhnlich gut funktioniert

242.451 Aufrufe • vor 2 Wochen



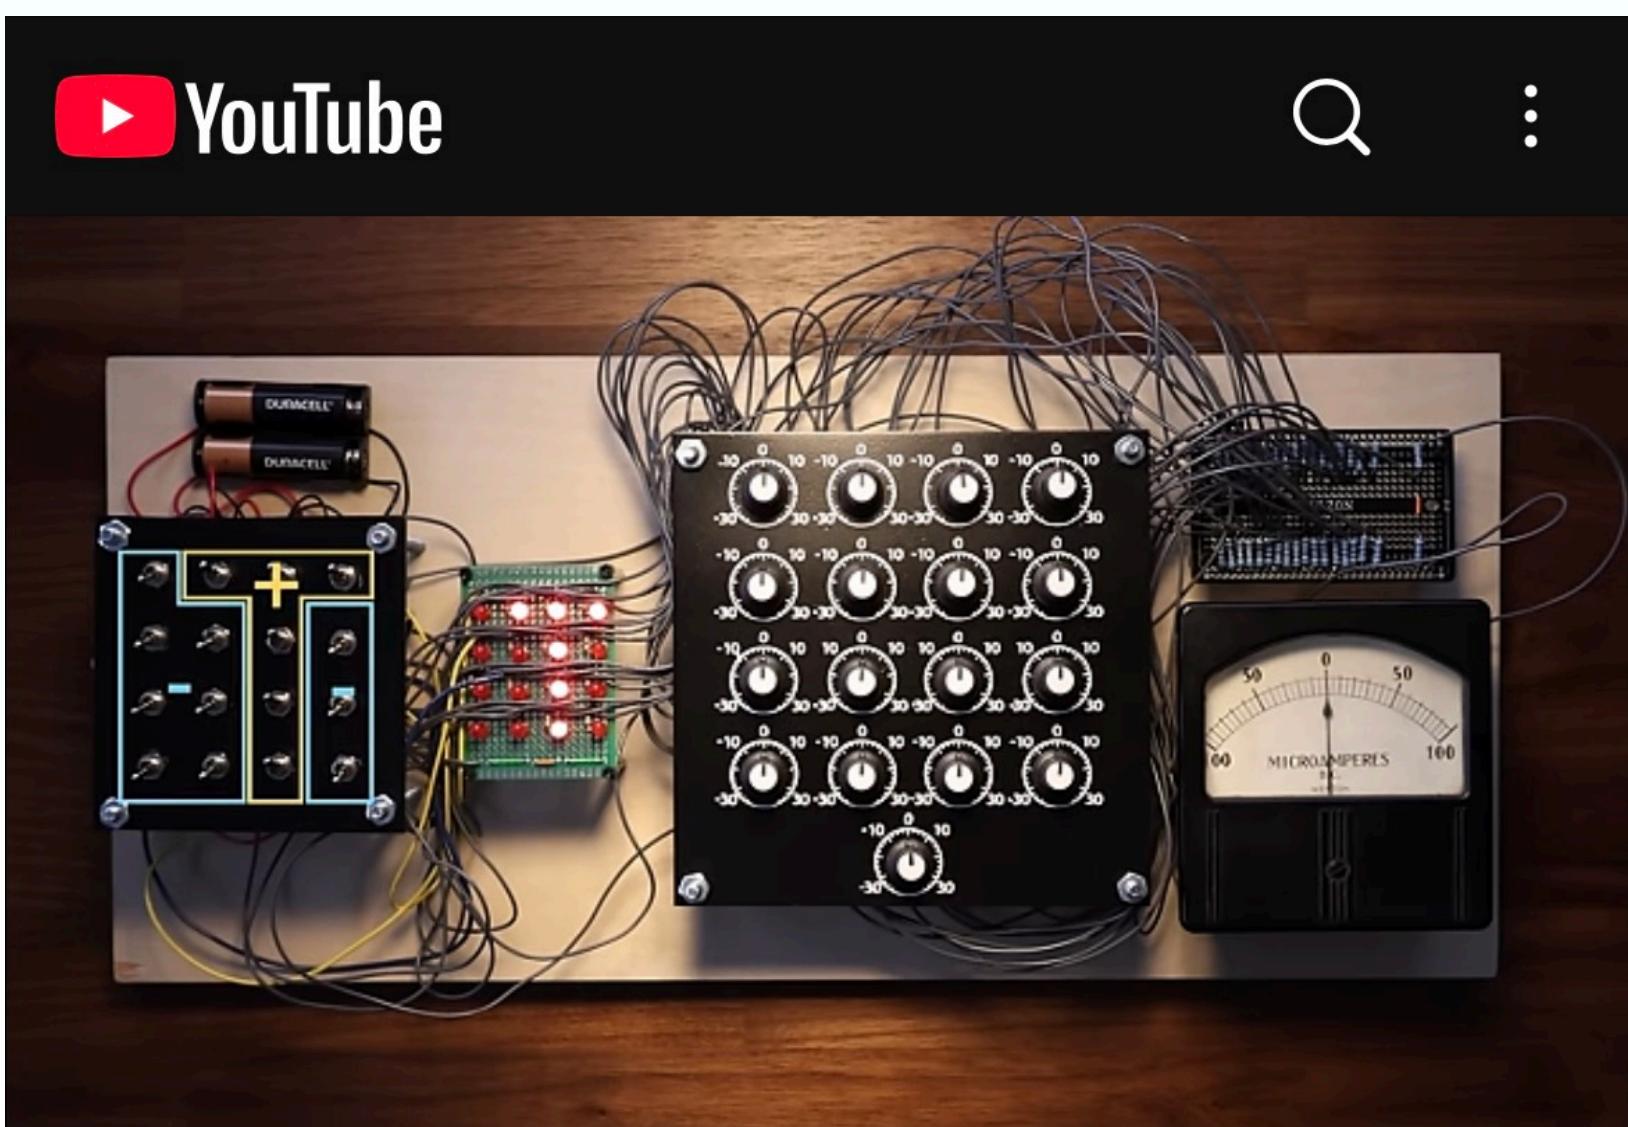
Das F=ma der künstlichen  
Intelligenz [Backpropagation]

159.480 Aufrufe • vor 2 Monaten



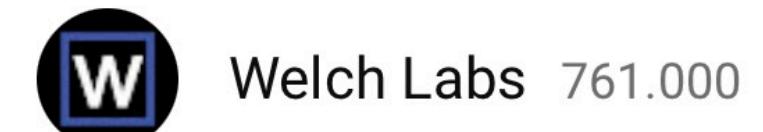
The Misconception that Almost  
Stopped AI [How Models Learn Pa...]

526.237 Aufrufe • vor 3 Monaten



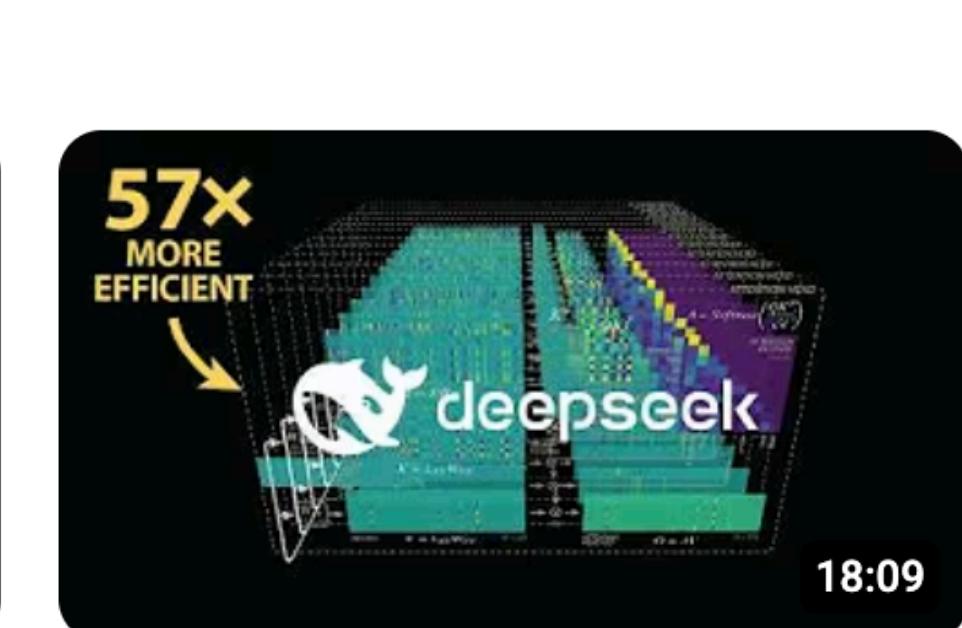
ChatGPT is made from 100 million of these  
[The Perceptron]

629.662 Aufrufe • vor 6 Monaten ...mehr



Welch Labs 761.000

Abonniert



Das Geniale an DeepSeeks 57-  
facher Effizienzsteigerung [MLA]

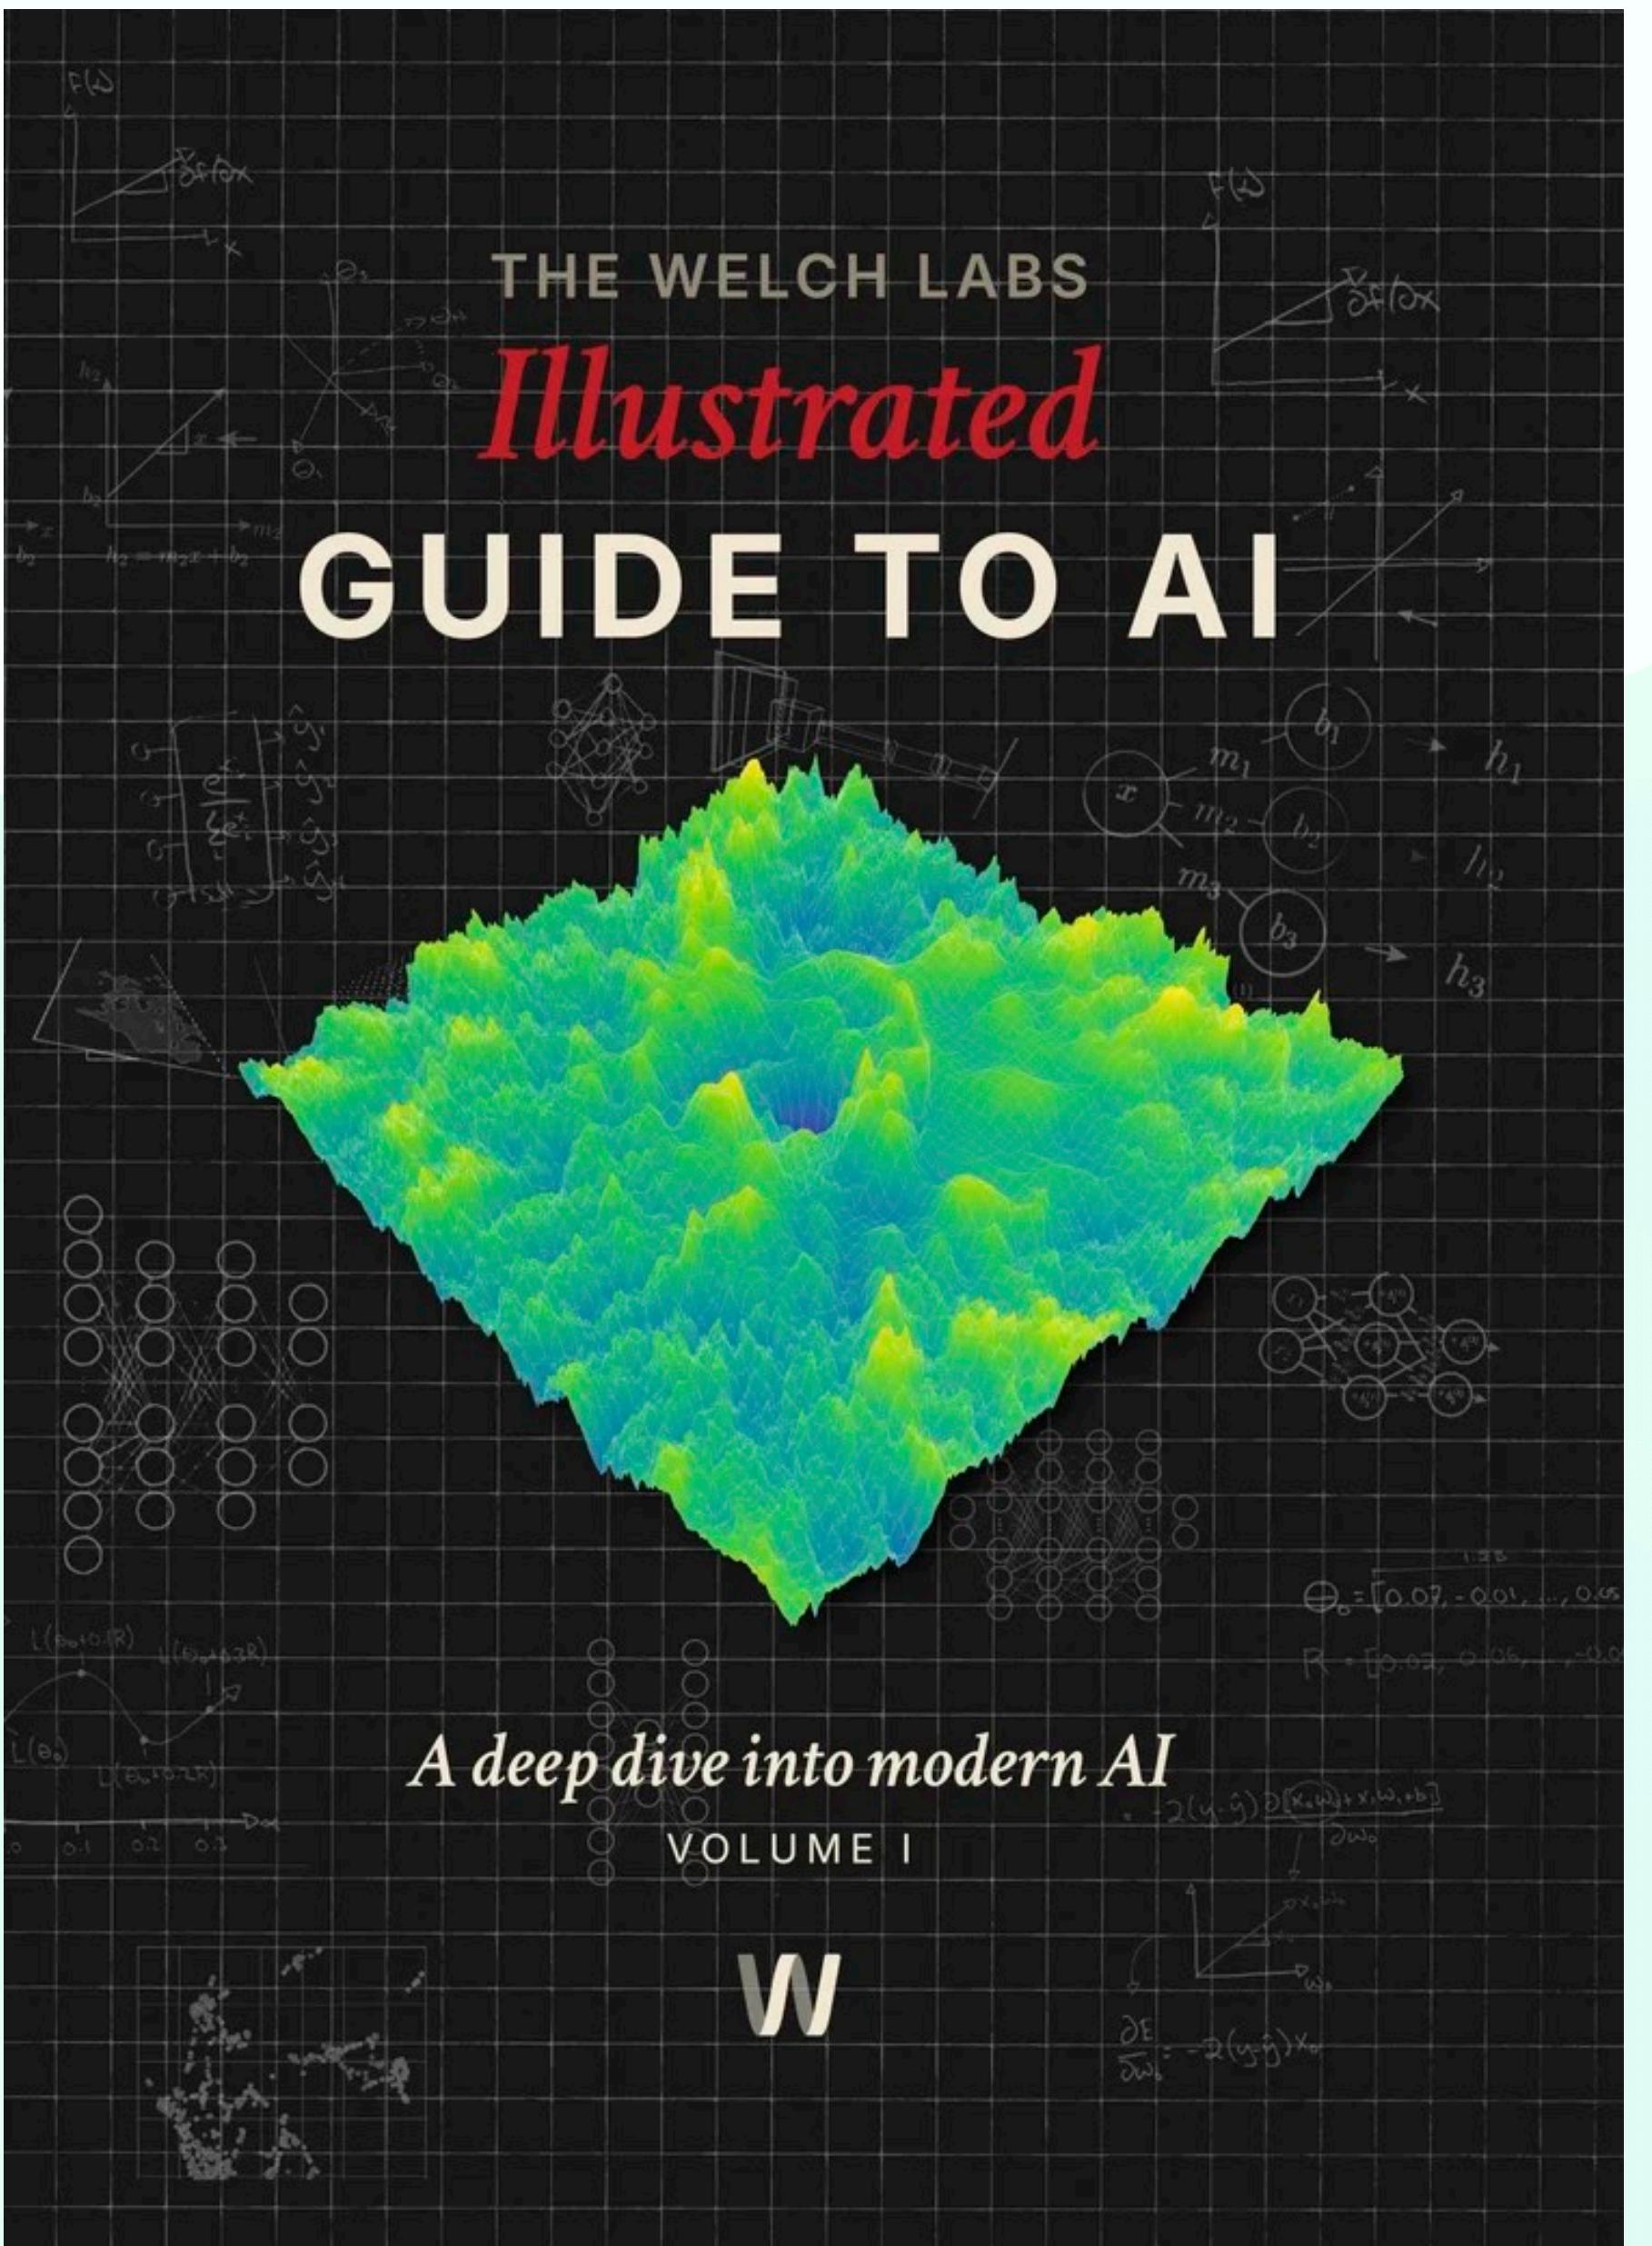
725.376 Aufrufe • vor 5 Monaten

# Empfehlungen

## Illustrated Guide To AI

A deep dive into modern AI

The Welch Labs, 2025



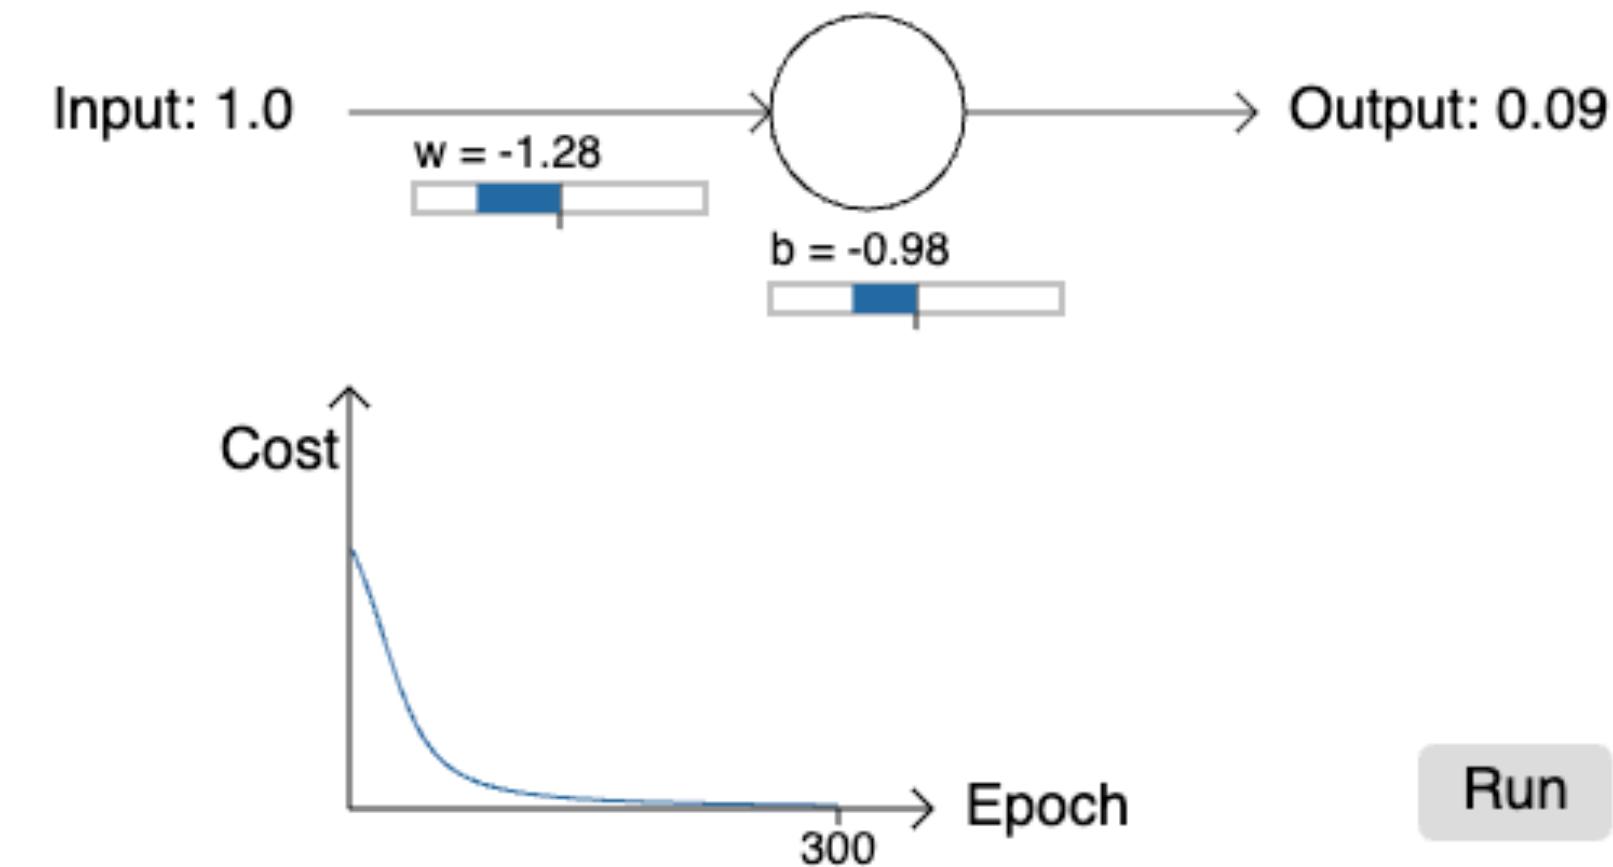
# Empfehlungen

## Neural Networks and Deep Learning

Michael Nielsen

Kostenloses E-Book

be needed before our neuron gets near the desired output, 0.0. Click on "Run" in the bottom right corner below to see how the neuron learns an output much closer to 0.0. Note that this isn't a pre-recorded animation, your browser is actually computing the gradient, then using the gradient to update the weight and bias, and displaying the result. The learning rate is  $\eta = 0.15$ , which turns out to be slow enough that we can follow what's happening, but fast enough that we can get substantial learning in just a few seconds. The cost is the quadratic cost function,  $C$ , introduced back in Chapter 1. I'll remind you of the exact form of the cost function shortly, so there's no need to go and dig up the definition. Note that you can run the animation multiple times by clicking on "Run" again.



# Empfehlungen

Vorlesungsreihe „MIT Introduction to Deep Learning“ ([Youtube](#), [Webseite](#))

The image is a promotional graphic for the MIT 6.S191 course. On the left, large text reads "MIT 6.S191 Introduction to Deep Learning". Below it, a subtitle states: "MIT's introductory program on deep learning methods with applications in computer vision, and more!". On the right, there is a video player interface showing two speakers, a man in a blue sweater and a woman in a white shirt, standing in front of a chalkboard. The MIT logo is in the top left corner of the video frame. Below the video player are two buttons: one for "Current MIT" students and one for "Everyone".

**MIT 6.S191**  
**Introduction to Deep Learning**

MIT's introductory program on deep learning methods with applications in computer vision, and more!

Current MIT  
MIT Students only

Everyone  
All: Public and MIT students

# Empfehlungen

## Neuronale Netze selbst programmieren

Tariq Rashid

dpunkt.verlag/O'Reilly 2017

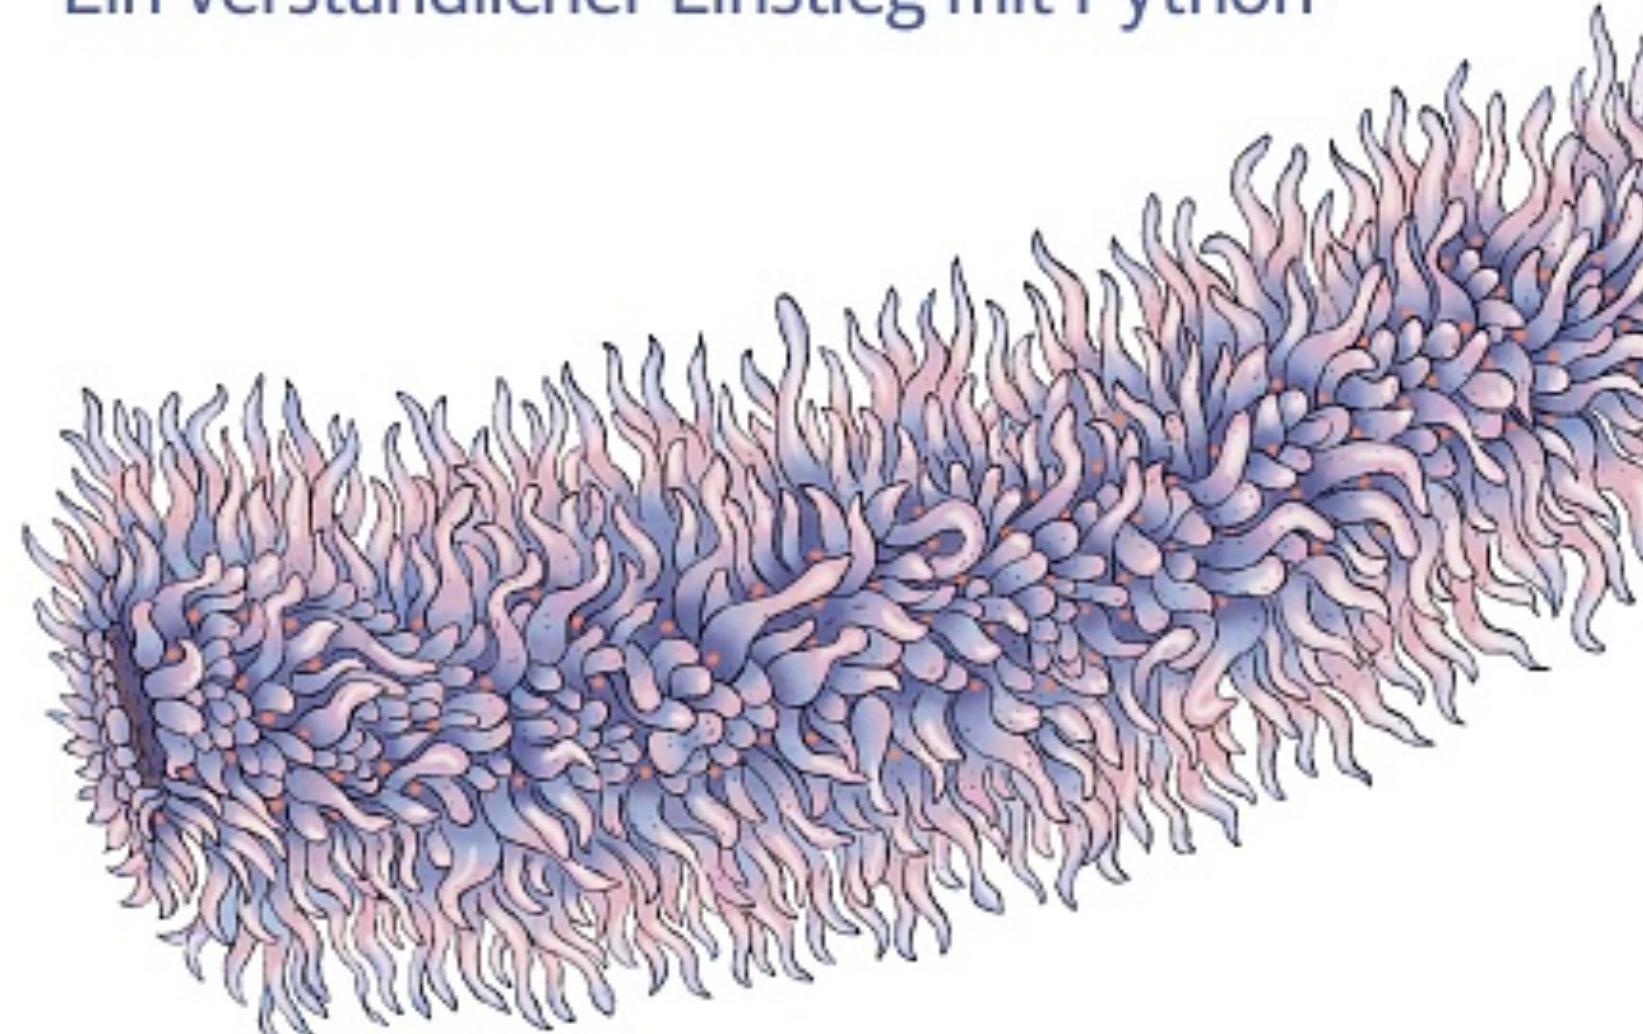
ISBN: 9781 492 064 046

O'REILLY®

2. Auflage  
aktualisiert und  
erweitert

# Neuronale Netze selbst programmieren

Ein verständlicher Einstieg mit Python



Tariq Rashid

Übersetzung von Frank Langenau

# Empfehlungen

## Neuronale Netze programmieren mit Python

Jochen Steinwendner/Roland Schwaiger  
Rheinwerk Computing 2020  
ISBN: 9783 8362 7450 0

